

Análisis Exploratorio de Datos

FACULTAD
DE
CIENCIAS
UNIVERSIDAD DE GRANADA



Los Del DGIIM, losdeldgiim.github.io

Doble Grado en Ingeniería Informática y Matemáticas
Universidad de Granada



Esta obra está bajo una Licencia Creative Commons Atribución-NoComercial-SinDerivadas 4.0 Internacional (CC BY-NC-ND 4.0).

Eres libre de compartir y redistribuir el contenido de esta obra en cualquier medio o formato, siempre y cuando des el crédito adecuado a los autores originales y no persigas fines comerciales.

Análisis Exploratorio de Datos

Los Del DGIIM, losdeldgiim.github.io

José Juan Urrutia Milán

Granada, 2026

Índice general

1. Introducción al Análisis Exploratorio de Datos	5
1.1. Estadísticos	8
1.1.1. Tipos de percentiles	9
1.1.2. Medidas robustas de posición central	11
1.1.3. Medidas robustas de dispersión	11
1.1.4. Medidas robustas de forma	12
1.2. Construcción de diagrama de cajas con bigotes	12

1. Introducción al Análisis Exploratorio de Datos

Para entender la estructura de los datos, el Análisis Exploratorio de Datos (AED) se desarrolla:

- Descubriendo la estructura subyacente.
- Detectando las variables importantes.
- Detectando datos anómalos (*outliers*).
- Comprobando las hipótesis subyacentes a un análisis.
- Desarrollando modelos *ad hoc*.

Mientras que la **Estadística descriptiva** tiene la finalidad de resumir conjuntos de datos aportando medidas o estadísticos y la **Estadística gráfica** es un conjunto de técnicas para mostrar y caracterizar los datos, el **Análisis Exploratorio de Datos** es una metodología para estudiar la estructura de los datos, basada en técnicas que permiten manejar el conjunto completo de datos para poner de manifiesto su estructura, no para mostrarlos simplemente.

El estudio de los datos debe abordarse desde la filosofía exploratoria:

Excepticismo. El investigador debe adoptar una postura escéptica respecto a las medidas que sintetizan los datos, puesto que pueden ocultar o malinterpretar ciertos aspectos de los datos.

Apertura. El investigador debe estar abierto a nuevos modelos no previstos, que pueden surgir al realizar el AED.

A modo de resumen, podemos decir que:

Estadística clásica. A partir de los datos, se presupone un modelo basado en hipótesis (linealidad, normalidad, ...) y el análisis suele basarse en la estimación y contraste de los parámetros del modelo. Se basa en realizar resúmenes de datos.

Estadística bayesiana. Además de lo anterior, se suelen imponer hipótesis sobre la distribución a priori de los parámetros.

AED. A partir de los datos, el análisis se basa en una metodología para estudiar la estructura, patrones y anomalías. A partir de la información se **decide** el modelo más apropiado, sin asumir hipótesis previas. Se basa en tratar de usar todos los datos, utilizando para ello gráficas.

El AED complementa la Estadística tradicional, pero es una metodología que no tiene por qué conducir a la estimación de modelos.

Ejemplo. ¿Alguna vez has escuchado que la esperanza de vida en la Edad Media era de 30 años? ¿Realmente era raro superar los 40 años de edad?

Este es uno de los más famosos errores en un análisis estadístico. Contamos con los siguientes datos de cuántas muertes se corresponden a cada grupo de edad en la Edad Media para un total de 1000 muertes:

Grupo de Edad	Edad Media	Muertes
0	0.5	200
1–4	2.5	150
5–9	7.5	50
10–14	12.5	30
15–19	17.5	30
20–24	22.5	35
25–29	27.5	35
30–34	32.5	35
35–39	37.5	40
40–44	42.5	40
45–49	47.5	40
50–54	52.5	45
55–59	57.5	45
60–64	62.5	60
65–69	67.5	65
70–74	72.5	60
75–79	77.5	30
80+	82.5	10

Tabla 1.1: Datos demográficos ordenados por cohorte de edad en la Edad Media.

A partir de ellos, si queremos calcular cuál es la edad más probable a la que se moría una persona, lo primero que se nos ocurre es calcular la esperanza de edad media de defunción. Hagámoslo en R:

```

1 library(ggplot2)
  library(dplyr)

  # 1. Definir la tabla de datos
5 datos <- read.csv(text = '
  "Grupo_Edad","Edad_Media","Muertes_dx"
  "0",0.5,200
  "1-4",2.5,150
  "5-9",7.5,50
10 "10-14",12.5,30
  "15-19",17.5,30
  "20-24",22.5,35
  "25-29",27.5,35
  "30-34",32.5,35
15 "35-39",37.5,40
  "40-44",42.5,40
  "45-49",47.5,40
  "50-54",52.5,45
  "55-59",57.5,45
20 "60-64",62.5,60
  "65-69",67.5,65
  "70-74",72.5,60
  "75-79",77.5,30
  "80+",82.5,10
25 ')

  # 2. Calcular la edad media ponderada por el número de muertes
media_ponderada <- sum(datos$Edad_Media * datos$Muertes_dx) /
                    sum(datos$Muertes_dx)
30 media_ponderada

```

Figura 1.1: Cálculo de la esperanza del dataset en R.

Obtenemos que `media_ponderada = 30.325`, por lo que sí, parece que la gente se moría a los 30 años, aunque parece ser una edad muy temprana, a pesar de las condiciones duras de la época. Vamos a representar gráficamente este valor:

```

1 ggplot(datos, aes(x = Edad_Media, weight = Muertes_dx)) +
  geom_histogram(binwidth = 5, fill = "skyblue", color = "black", boundary = 0)
  +
  geom_vline(xintercept = media_ponderada, color = "blue", linewidth = 1.2,
    linetype = "dashed") +
  annotate("text", x = media_ponderada + 3, y = max(datos$Muertes_dx) * 0.9,
5     label = paste("Media:", round(media_ponderada, 2)), color = "blue",
    hjust = 0) +
  labs(
    title = "Distribución de Muertes por Edad",
    x = "Edad Media del Grupo",
    y = "Número de Muertes"
10 ) +
  theme_minimal()

```

Obtenemos el siguiente gráfico:




Figura 1.2: Gráfico obtenido de R.

Ahora sí que vemos lo que está pasando: resulta que en la Edad Media había muchísima mortalidad natal, por lo que una gran cantidad (de 1000 muertes, 350 se corresponden a personas de menos de 5 años) de personas no superaba los 5 años. Sin embargo, este hecho no tiene nada que ver con la calidad de vida de una persona que consigue superar esta mortalidad infantil, por lo que estamos tratando mal los datos: no se trata de una única variable aleatoria, tenemos una distribución bimodal como resultado de la suma de dos variables aleatorias: mortalidad infantil y esperanza de vida.

La media solo hace un buen resumen de los datos cuando la distribución es unimodal. Así, lo que debíamos haber hecho al calcular la edad media de defunción es quedarnos solo con las personas de una edad en adelante. Este margen habría que estudiar bien dónde ponerlo pero parece que a partir de los 10 años esta mortalidad infantil deja de tener tanta relevancia:

```
1 # 1. Quedarme con los datos de personas mayores de 10 años
  datos_filtrados <- datos[datos$Edad_Media >= 10, ]

# 2. Calcular la edad media ponderada por el número de muertes
5 media_filtrados_ponderada <- sum(datos_filtrados$Edad_Media *
  datos_filtrados$Muertes_dx) / sum(datos_filtrados$Muertes_dx)
media_filtrados_ponderada
```


Obtenemos `media_filtrados_ponderada = 49.125`, grafiquémoslo:

```
1 ggplot(datos, aes(x = Edad_Media, weight = Muertes_dx)) +
  geom_histogram(binwidth = 5, fill = "skyblue", color = "black", boundary = 0)
  +
  geom_vline(xintercept = media_ponderada, color = "blue", linewidth = 1.2,
    linetype = "dashed") +
```

```

5   annotate("text", x = media_ponderada + 3, y = max(datos$Muertes_dx) * 0.9,
        label = paste("Media:", round(media_ponderada, 2)), color = "blue",
        hjust = 0) +
  geom_vline(xintercept = media_filtrados_ponderada, color = "red", linewidth =
1.2, linetype = "dashed") +
  annotate("text", x = media_filtrados_ponderada + 3, y = max(datos$Muertes_dx)
* 0.9,
        label = paste("Media (>= 10):", round(media_filtrados_ponderada, 2)),
        color = "red", hjust = 0) +
10  labs(
    title = "Distribución de Muertes por Edad",
    x = "Edad Media del Grupo",
    y = "Número de Muertes"
  ) +
  theme_minimal()
15

```



1.1. Estadísticos

Definición 1.1.1. Una medida se considera **resistente** si muestra poca sensibilidad frente a valores anómalos (*outliers*).

Ejemplo. Consideremos las dos siguientes distribuciones de datos experimentales:

Dato	Frecuencia Muestra 1	Frecuencia Muestra 2
10	2	2
11	1	1
12	2	2
13	1	1
14	1	1
15	3	3
16	1	1
17	0	0
18	1	1
19	1	0
20	0	0
$\vdots$	$\vdots$	$\vdots$
57	0	1

Figura 1.3: Datos experimentales.

Vemos que en los datos superiores parece que tenemos un *outlier* en la segunda muestra, puesto que 57 parece ser un valor raro respecto al resto de valores.

Si calculamos varias medidas estadísticas:

Medida	Muestra 1	Muestra 2
N	13	13
Media	13.8462	16.7692
Mediana	14	14
Desv. típica	2.8533	12.3231
Varianza	8.141	151.859
Asimetría	0.310	3.368
Curtosis	-0.688	11.774

Tabla 1.2: Medidas estadísticas.

Vemos que casi todas las medidas estadísticas se han modificado bastante, salvo la mediana, que ha permanecido igual, porque la mediana no está basada en frecuencias, sino en cuartiles. Podríamos decir que la mediana es una medida resistente.

Definición 1.1.2. Una medida se dice **robusta** si muestra poca sensibilidad frente al incumplimiento de hipótesis de partida en los modelos probabilísticos.

1.1.1. Tipos de percentiles

Para una variable aleatoria X con función de distribución F , se define para $p \in]0, 1[$ su p -ésimo percentil como:

$$Q(p) = F^{-1}(p) = \inf\{x : F(x) \geq p\}$$

Si tenemos una muestra $X_1, \dots, X_n$ de tamaño n , Hyndman y Fan realizaron una clasificación de los 9 tipos de percentiles que podemos considerar, clasificándolos en percentiles para variables discretas o para variables continuas. Todos estos percentiles tienen algo en común:

- En primer lugar se calcula $np + m$, para m una constante predefinida.
- Se toma $i = \lfloor np + m \rfloor$ la parte entera y $g = np + m - i$ la parte decimal.
- En función de los cálculos obtenidos se fija un valor de γ y se toma:

$$Q(p) = (1 - \gamma)X_i + \gamma X_{i+1}$$

Veamos todos los tipos de percentiles que podemos encontraros:

Para variables discretas

1. Se toma $m = 0$, por lo que $np = i + g$.
 - Si $g = 0$ se toma $\gamma = 0$, es decir, $Q_1(p) = X_i$.
 - Si $g \neq 0$ se toma $\gamma = 1$, es decir, $Q_1(p) = X_{i+1}$.

Este percentil se denomina **EMPIRICAL**.

2. Se toma $m = 0$, por lo que $np = i + g$.
 - Si $g = 0$ se toma $\gamma = 0,5$, es decir, $Q_2(p) = 0,5(X_i + X_{i+1})$.
 - Si $g \neq 0$ se toma $\gamma = 1$, es decir, $Q_2(p) = X_{i+1}$.

Este percentil se denomina **AEMPIRICAL**.

3. Se toma $m = -\frac{1}{2}$, por lo que $np - \frac{1}{2} = i + g$.
 - Si $g = 0$ y i es impar se toma $\gamma = 0$, es decir, $Q_3(p) = X_i$.
 - Si $g \neq 0$ o i es par se toma $\gamma = 1$, es decir, $Q_3(p) = X_{i+1}$.

Este percentil se denomina **SAS**, estadístico de orden más cercano.

Para variables continuas

4. Se toma $m = 0$, por lo que $np = i + g$.
En este caso se toma $\gamma = g$, con lo que:

$$Q_4(p) = (1 - g)X_i + gX_{i+1}$$

Este percentil se denomina **WAVERAGE**.

5. Se toma $m = \frac{1}{2}$, por lo que $np + \frac{1}{2} = i + g$.
 - Si $F(pn) < 0,5$ se toma $Q_5(p) = X_i$.
 - Si $F(pn) \geq 0,5$ se toma $Q_5(p) = X_{i+1}$.

Este percentil se denomina **ROUND**.

6. Se toma $m = p$, por lo que $(n + 1)p = i + g$.

Se toma $\gamma = g$, con lo que:

$$Q_6(p) = (1 - g)X_i + gX_{i+1}$$

Este percentil se denomina **H AVERAGE-Tuckey**, es el por defecto en SPSS.

7. Se toma $m = 1 - p$, por lo que $(n - 1)p + 1 = i + g$. Se toma $\gamma = g$, con lo que:

$$Q_7(p) = (1 - g)X_i + gX_{i+1}$$

Este percentil es el por defecto en R y Excel.

8. Se toma $m = (p+1)/3$, por lo que $n + \frac{p}{3} + \frac{1}{3} = i + g$. Se toma $\gamma = g$, con lo que:

$$Q_8(p) = (1 - g)X_i + gX_{i+1}$$

Este percentil se denomina “Insesgado respecto a la mediana”.

9. Se toma $m = \frac{p}{4} + \frac{3}{8}$, por lo que $n + \frac{p}{4} + \frac{3}{8} = i + g$. Se toma $\gamma = g$, con lo que:

$$Q_8(p) = (1 - g)X_i + gX_{i+1}$$

Este percentil se denomina “Insesgado para distribuciones normales”.

1.1.2. Medidas robustas de posición central

Las medidas que menos se influyen por datos anómalos son las medidas basadas en percentiles, puesto que muchos datos han de cambiar para que un percentil cambie. Veamos algunas de estas medidas:

Mediana.

$$Me = Q(0,5)$$

Punto medio entre cuartiles.

$$\overline{Q} = \frac{Q(0,25) + Q(0,75)}{2}$$

Esta medida puede ayudarnos a detectar si una distribución unimodal es simétrica o si presenta una acumulación a la izquierda o derecha:

- Si $Me < \overline{Q}$, entonces la distribución se acumula a la izquierda.
- Si $Me > \overline{Q}$, entonces la distribución se acumula a la derecha.




Figura 1.4: Función de densidad con asimetría, división por cuantiles y punto medio entre cuantiles.

Trimedia.

$$TRI = \frac{Me + \bar{Q}}{2}$$

Cuatrimedia. Es la media aritmética considerando solo los valores que se encuentran contenidos estrictamente entre el primer y el tercer cuartil, es decir, esta medida no tiene en cuenta el 25 % de los datos más pequeños y el 25 % de los datos más grandes.

1.1.3. Medidas robustas de dispersión

Rango intercuartílico.

$$RIQ = Q(0,75) - Q(0,25)$$

MEDA. Es la MEDiana de las Desviaciones Absolutas respecto a la mediana.

Coefficiente de variación cuartílico.

$$CV_c = \frac{RIQ/2}{\bar{Q}} = \frac{Q(0,75) - Q(0,25)}{Q(0,75) + Q(0,25)}$$

1.1.4. Medidas robustas de forma

Coefficiente de Asimetría de Yule.

$$H_1 = \frac{Q(0,9) + Q(0,1) - 2Me}{Q(0,9) - Q(0,1)} = \frac{\bar{Q}}{Me} - 1$$

La interpretación es la vista en la figura anterior:

- Si $H_1 = 0$ la distribución es simétrica.
- Si $H_1 > 0$ la distribución es asimétrica a la derecha.
- Si $H_1 < 0$ la distribución es asimétrica a la izquierda.

Coefficiente de Asimetría de David y Johnson.

$$H_2(\alpha) = \frac{\overline{Q}(\alpha) - Me}{\frac{RIQ(\alpha)}{2}}$$

Coefficiente de Asimetría de Kelly.

$$H_3 = \frac{Q(0,9) + Q(0,1) - 2Me}{Q(0,9) - Q(0,1)}$$

1.2. Construcción de diagrama de cajas con bigotes

Para una muestra de una variable aleatoria X de tamaño N usaremos el percentil tipo 6, o de HAVERAGE-Tuckey. Los pasos para construir una caja con bigotes son:

- Se representa la caja de modo que el extremo inferior de la misma se corresponda con el primer cuartil de Tuckey T_1 y que el extremo superior se corresponda con el tercer cuartil T_3 .

Posteriormente, se dibuja una línea dentro de la caja que se corresponde con la mediana Me .

- Los bigotes se construyen uniendo una línea desde el centro de la caja con el último (equivalentemente, primer) valor de la distribución que esté a una distancia máxima de un $RIQ = T_3 - T_1$.
- Los valores que se encuentran fuera de estos bigotes y a distancia máxima de $1,5RIQ$ se marcan individualmente.
- Un valor a distancia entre $1,5RIQ$ y $3RIQ$ se considera un valor alejado, o *outside*.
- Un valor a mayor distancia que $3RIQ$ se considera extremadamente alejado, o *far outside*.

Ejercicio 1.2.1. Demostrar:

1. Si $Z \rightsquigarrow \mathcal{N}(0, 1)$, entonces:

$$P[Q_1 - RIQ \leq Z \leq Q_3 + RIQ] \geq 0,95$$

2. Lo anterior es cierto para $X \rightsquigarrow \mathcal{N}(\mu, \sigma^2)$

Hagamos este ejercicio:

1. Tenemos que calcular entonces:

$$P[Q_1 - RIQ \leq Z \leq Q_3 + RIQ]$$

Para ello, como $\mathcal{N}(0, 1)$ es una distribución simétrica tenemos que calcular simplemente:

$$P[Q_1 - RIQ \leq Z] = P[Q_1 - Q_3 + Q_1 \leq Z] \stackrel{(*)}{=} P[3Q_1 \leq Z]$$

donde en $(*)$ hemos usado que $Q_3 = -Q_3$ por ser la distribución simétrica.

Consultamos el valor de Q_1 en la tabla de la normal $\mathcal{N}(0, 1)$, buscamos el menor x con $P[x \leq Z] \geq 0,25$, obteniendo aproximadamente $Q_1 = -0,68$. Ahora hemos de calcular $(3 \cdot 0,68 = 2,04)$:

$$P[3Q_1 \leq Z] \approx P[-2,04 \leq Z] = P[Z \leq 2,04] \approx 0,9793$$

Así, tenemos ahora que:

$$\begin{aligned} P[Q_1 - RIQ \leq Z \leq Q_3 + RIQ] &= 1 - 2 \cdot P[Z \leq Q_1 - RIQ] \\ &= 1 - 2(1 - P[Z \geq Q_1 - RIQ]) \\ &= -1 + 2P[Z \geq Q_1 - RIQ] \\ &\approx -1 + 2 \cdot 0,9793 = 0,9586 \end{aligned}$$

2. De la tipificación de las variables normales:

$$Z = \frac{X - \mu}{\sigma}$$

obtenemos que:

$$Q_1(Z) = \frac{Q_1(X) - \mu}{\sigma}$$

Por lo que es trivial que:

$$P[Q_1(X) - RIQ(X) \leq X \leq Q_3(X) + RIQ(X)] \geq 0,95$$

Ejercicio 1.2.2. Calcular la probabilidad de que un punto de una distribución $\mathcal{N}(0, 1)$ sea un *outside* o un *far outside*.