Análisis Exploratorio de Datos



Los Del DGIIM, losdeldgiim.github.io

Doble Grado en Ingeniería Informática y Matemáticas
Universidad de Granada

el crédito adecuado a los autores originales y no persigas fines comerciales.

Análisis Exploratorio de Datos

Los Del DGIIM, `losdeldgiim.github.io`

José Juan Urrutia Milán

Granada, 2026

Índice general

1. Introducción al Análisis Exploratorio de Datos

Para entender la estructura de los datos, el Análisis Exploratorio de Datos (AED) se desarrolla:

- Descubriendo la estructura subyacente.
- Detectando las variables importantes.
- Detectando datos anómalos (*outliers*).
- Comprobando las hipótesis subyacentes a un análisis.
- Desarrollando modelos *ad hoc*.

Mientras que la **Estadística descriptiva** tiene la finalidad de resumir conjuntos de datos aportando medidas o estadísticos y la **Estadística gráfica** es un conjunto de técnicas para mostrar y caracterizar los datos, el **Análisis Exploratorio de Datos** es una metodología para estudiar la estructura de los datos, basada en técnicas que permiten manejar el conjunto completo de datos para poner de manifiesto su estructura, no para mostrarlos simplemente.

El estudio de los datos debe abordarse desde la filosofía exploratoria:

Excepticismo. El investigador debe adoptar una postura escéptica respecto a las medidas que sintetizan los datos, puesto que pueden ocultar o malinterpretar ciertos aspectos de los datos.

Apertura. El investigador debe estar abierto a nuevos modelos no previstos, que pueden surgir al realizar el AED.

A modo de resumen, podemos decir que:

Estadística clásica. A partir de los datos, se presupone un modelo basado en hipótesis (linealidad, normalidad, ...) y el análisis suele basarse en la estimación y contraste de los parámetros del modelo. Se basa en realizar resúmenes de datos.

Estadística bayesiana. Además de lo anterior, se suelen imponer hipótesis sobre la distribución a priori de los parámetros.

AED. A partir de los datos, el análisis se basa en una metodología para estudiar la estructura, patrones y anomalías. A partir de la información se **decide** el modelo más apropiado, sin asumir hipótesis previas. Se basa en tratar de usar todos los datos, utilizando para ello gráficas.

El AED complementa la Estadística tradicional, pero es una metodología que no tiene por qué conducir a la estimación de modelos.

Ejemplo. ¿Alguna vez has escuchado que la esperanza de vida en la Edad Media era de 30 años? ¿Realmente era raro superar los 40 años de edad?

Este es uno de los más famosos errores en un análisis estadístico. Contamos con los siguientes datos de cuántas muertes se corresponden a cada grupo de edad en la Edad Media para un total de 1000 muertes:

Grupo de Edad	**Edad Media**	**Muertes**
0	0.5	200
1–4	2.5	150
5–9	7.5	50
10–14	12.5	30
15–19	17.5	30
20–24	22.5	35
25–29	27.5	35
30–34	32.5	35
35–39	37.5	40
40–44	42.5	40
45–49	47.5	40
50–54	52.5	45
55–59	57.5	45
60–64	62.5	60
65–69	67.5	65
70–74	72.5	60
75–79	77.5	30
80+	82.5	10

Tabla 1.1: Datos demográficos ordenados por cohorte de edad en la Edad Media.

A partir de ellos, si queremos calcular cuál es la edad más probable a la que se moría una persona, lo primero que se nos ocurre es calcular la esperanza de edad media de defunción. Hagámoslo en R:

```r
library(ggplot2)
library(dplyr)

# 1. Definir la tabla de datos
datos <- read.csv(text = '
"Grupo_Edad","Edad_Media","Muertes_dx"
"0",0.5,200
"1-4",2.5,150
"5-9",7.5,50
"10-14",12.5,30
"15-19",17.5,30
"20-24",22.5,35
"25-29",27.5,35
"30-34",32.5,35
"35-39",37.5,40
"40-44",42.5,40
"45-49",47.5,40
"50-54",52.5,45
"55-59",57.5,45
"60-64",62.5,60
"65-69",67.5,65
"70-74",72.5,60
"75-79",77.5,30
"80+",82.5,10
')

# 2. Calcular la edad media ponderada por el número de muertes
media_ponderada <- sum(datos$Edad_Media * datos$Muertes_dx) /
                   sum(datos$Muertes_dx)
media_ponderada
```

Figura 1.1: Cálculo de la esperanza del dataset en R.

Obtenemos que `media_ponderada = 30.325`, por lo que sí, parece que la gente se moría a los 30 años, aunque parece ser una edad muy temprana, a pesar de las condiciones duras de la época. Vamos a representar gráficamente este valor:

```r
ggplot(datos, aes(x = Edad_Media, weight = Muertes_dx)) +
  geom_histogram(binwidth = 5, fill = "skyblue", color = "black", boundary = 0)
  +
  geom_vline(xintercept = media_ponderada, color = "blue", linewidth = 1.2,
  linetype = "dashed") +
  annotate("text", x = media_ponderada + 3, y = max(datos$Muertes_dx) * 0.9,
           label = paste("Media:", round(media_ponderada, 2)), color = "blue",
           hjust = 0) +
  labs(
    title = "Distribución de Muertes por Edad",
    x = "Edad Media del Grupo",
    y = "Número de Muertes"
  ) +
  theme_minimal()
```

Obtenemos el siguiente gráfico:

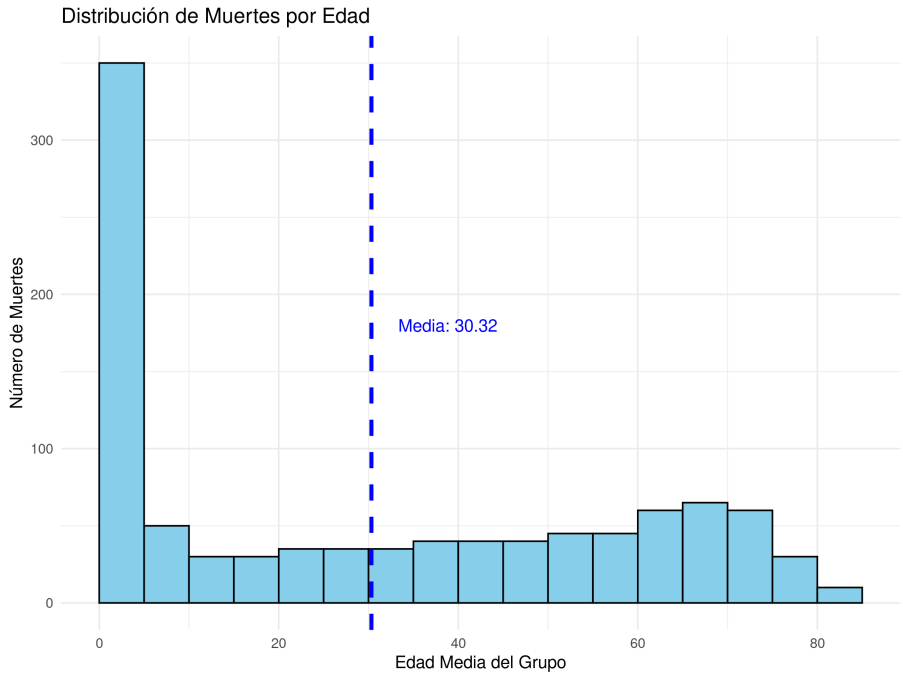


Figura 1.2: Gráfico obtenido de R.

Ahora sí que vemos lo que está pasando: resulta que en la Edad Media había muchísima mortalidad natal, por lo que una gran cantidad (de 1000 muertes, 350 se corresponden a personas de menos de 5 años) de personas no superaba los 5 años. Sin embargo, este hecho no tiene nada que ver con la calidad de vida de una persona que consigue superar esta mortalidad infantil, por lo que estamos tratando mal los datos: no se trata de una única variable aleatoria, tenemos una distribución bimodal como resultado de la suma de dos variables aleatorias: mortalidad infantil y esperanza de vida.

La media solo hace un buen resumen de los datos cuando la distribución es unimodal. Así, lo que debíamos haber hecho al calcular la edad media de defunción es quedarnos solo con las personas de una edad en adelante. Este margen habría que estudiar bien dónde ponerlo pero parece que a partir de los 10 años esta mortalidad infantil deja de tener tanta relevancia:

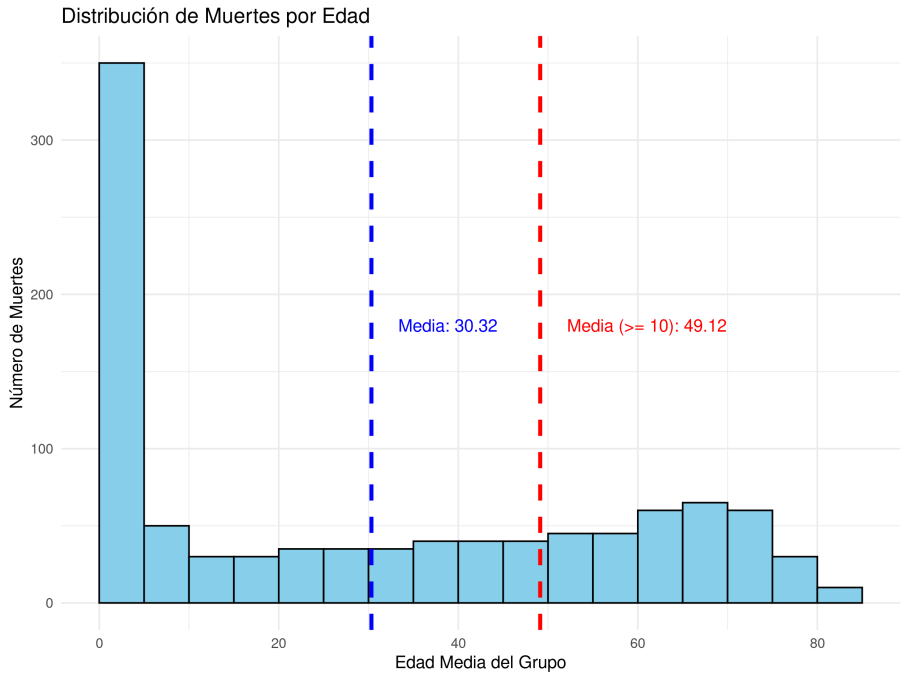
```
# 1. Quedarme con los datos de personas mayores de 10 años
datos_filtrados <- datos[datos$Edad_Media >= 10, ]

# 2. Calcular la edad media ponderada por el número de muertes
media_filtrados_ponderada <- sum(datos_filtrados$Edad_Media *
datos_filtrados$Muertes_dx) / sum(datos_filtrados$Muertes_dx)
media_filtrados_ponderada
```

Obtenemos `media_filtrados_ponderada = 49.125`, grafiquémoslo:

```
ggplot(datos, aes(x = Edad_Media, weight = Muertes_dx)) +
  geom_histogram(binwidth = 5, fill = "skyblue", color = "black", boundary = 0)
  +
  geom_vline(xintercept = media_ponderada, color = "blue", linewidth = 1.2,
  linetype = "dashed") +
```

```
  annotate("text", x = media_ponderada + 3, y = max(datos$Muertes_dx) * 0.9,
           label = paste("Media:", round(media_ponderada, 2)), color = "blue",
           hjust = 0) +
  geom_vline(xintercept = media_filtrados_ponderada, color = "red", linewidth =
  1.2, linetype = "dashed") +
  annotate("text", x = media_filtrados_ponderada + 3, y = max(datos$Muertes_dx)
  * 0.9,
           label = paste("Media (>= 10):", round(media_filtrados_ponderada, 2)),
           color = "red", hjust = 0) +
  labs(
    title = "Distribución de Muertes por Edad",
    x = "Edad Media del Grupo",
    y = "Número de Muertes"
  ) +
  theme_minimal()
```



1.1. Estadísticos

Definición 1.1.1. Una medida se considera **resistente** si muestra poca sensibilidad frente a valores anómalos (*outliers*).

Ejemplo. Consideremos las dos siguientes distribuciones de datos experimentales:

Dato	Frecuencia Muestra 1	Frecuecia Muestra 2
10	2	2
11	1	1
12	2	2
13	1	1
14	1	1
15	3	3
16	1	1
17	0	0
18	1	1
19	1	0
20	0	0
⋮	⋮	⋮
57	0	1

Figura 1.3: Datos experimentales.

Vemos que en los datos superiores parece que tenemos un *outlier* en la segunda muestra, puesto que 57 parece ser un valor raro respecto al resto de valores.
Si calculamos varias medidas estadísticas:

Medida	Muestra 1	Muestra 2
N	13	13
Media	13.8462	16.7692
Mediana	14	14
Desv. típica	2.8533	12.3231
Varianza	8.141	151.859
Asimetría	0.310	3.368
Curtosis	-0.688	11.774

Tabla 1.2: Medidas estadísticas.

Vemos que casi todas las medidas estadísticas se han modificado bastante, salvo la mediana, que ha permanecido igual, porque la mediana no está basada en frecuencias, sino en cuartiles. Podríamos decir que la mediana es una medida resistente.

Definición 1.1.2. Una medida se dice **robusta** si muestra poca sensibilidad frente al incumplimiento de hipótesis de partida en los modelos prababilísticos.

1.1.1. Tipos de percentiles

Para una variable aleatoria X con función de distribución F, se define para $p \in]0,1[$ su $p-$ésimo percentil como:

$$Q(p) = F^{-1}(p) = \text{ínf}\{x : F(x) \geqslant p\}$$

Si tenemos una muestra $X_1, \ldots, X_n$ de tamaño n, Hyndman y Fan realizaron una clasificación de los 9 tipos de percentiles que podemos considerar, clasificándolos en percentiles para variables discretas o para variables continuas. Todos estos percentiles tienen algo en común:

- En primer lugar se calcula $np + m$, para m una constante predefinida.
- Se toma $i = \lfloor np + m \rfloor$ la parte entera y $g = np + m - i$ la parte decimal.
- En función de los cálculos obtenidos se fija un valor de γ y se toma:

$$Q(p) = (1 - \gamma)X_i + \gamma X_{i+1}$$

Veamos todos los tipos de percentiles que podemos encontranos:

Para variables discretas

1. Se toma $m = 0$, por lo que $np = i + g$.

   - Si $g = 0$ se toma $\gamma = 0$, es decir, $Q_1(p) = X_i$.
   - Si $g \neq 0$ se toma $\gamma = 1$, es decir, $Q_1(p) = X_{i+1}$.

   Este percentil se denomina **EMPIRICAL**.

2. Se toma $m = 0$, por lo que $np = i + g$.

   - Si $g = 0$ se toma $\gamma = 0{,}5$, es decir, $Q_2(p) = 0{,}5(X_i + X_{i+1})$.
   - Si $g \neq 0$ se toma $\gamma = 1$, es decir, $Q_2(p) = X_{i+1}$.

   Este percentil se denomina **AEMPIRICAL**.

3. Se toma $m = -\frac{1}{2}$, por lo que $np - \frac{1}{2} = i + g$.

   - Si $g = 0$ y i es impar se toma $\gamma = 0$, es decir, $Q_3(p) = X_i$.
   - Si $g \neq 0$ o i es par se toma $\gamma = 1$, es decir, $Q_3(p) = X_{i+1}$

   Este percentil se denomina **SAS**, estadístico de orden más cercano.

Para variables continuas

4. Se toma $m = 0$, por lo que $np = i + g$.

   En este caso se toma $\gamma = g$, con lo que:

$$Q_4(p) = (1 - g)X_i + gX_{i+1}$$

   Este percentil se denomina **WAVERAGE**.

5. Se toma $m = \frac{1}{2}$, por lo que $np + \frac{1}{2} = i + g$.

   - Si $F(pn) < 0{,}5$ se toma $Q_5(p) = X_i$.
   - Si $F(pn) \geqslant 0{,}5$ se toma $Q_5(p) = X_{i+1}$

   Este percentil se denomina **ROUND**.

6. Se toma $m = p$, por lo que $(n+1)p = i + g$.

   Se toma $\gamma = g$, con lo que:

   $$Q_6(p) = (1-g)X_i + gX_{i+1}$$

   Este percentil se denomina **HAVERAGE-Tuckey**, es el por defecto en SPSS.

7. Se toma $m = 1-p$, por lo que $(n-1)p+1 = i+g$. Se toma $\gamma = g$, con lo que:

   $$Q_7(p) = (1-g)X_i + gX_{i+1}$$

   Este percentil es el por defecto en R y Excel.

8. Se toma $m = {}^{(p+1)}/_{3}$, por lo que $n + \frac{p}{3} + \frac{1}{3} = i + g$. Se toma $\gamma = g$, con lo que:

   $$Q_8(p) = (1-g)X_i + gX_{i+1}$$

   Este percentil se denomina "Insesgado respecto a la mediana".

9. Se toma $m = \frac{p}{4} + \frac{3}{8}$, por lo que $n + \frac{p}{4} + \frac{3}{8} = i + g$. Se toma $\gamma = g$, con lo que:

   $$Q_8(p) = (1-g)X_i + gX_{i+1}$$

   Este percentil se denomina "Insesgado para distribuciones normales".

1.1.2. Medidas robustas de posición central

Las medidas que menos se influencian por datos anómalos son las medidas basadas en percentiles, puesto que muchos datos han de cambiar para que un percentil cambie. Veamos algunas de estas medidas:

Mediana.

$$Me = Q(0{,}5)$$

Punto medio entre cuartiles.

$$\overline{Q} = \frac{Q(0{,}25) + Q(0{,}75)}{2}$$

Esta medida puede ayudarnos a detectar si una distribución unimodal es simétrica o si presenta una acumulacióna izquierda o derecha:

- Si $Me < \overline{Q}$, entonces la distribución se acumula a la izquierda.
- Si $Me > \overline{Q}$, entonces la distribución se acumula a la derecha.

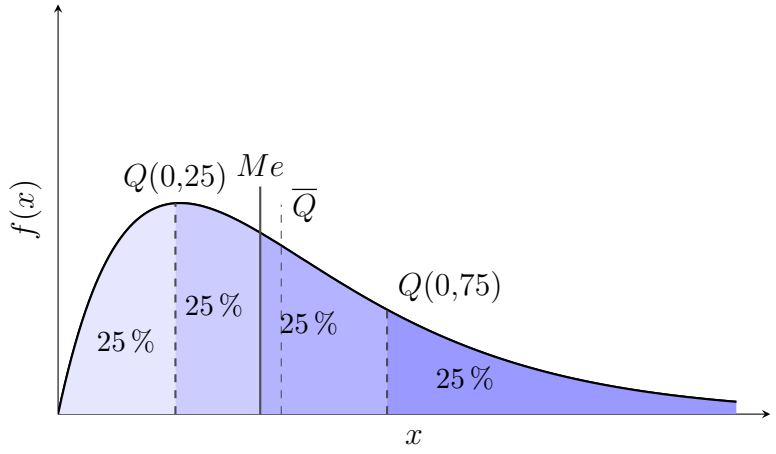


Figura 1.4: Función de densidad con asimetría, división por cuartiles y punto medio entre cuartiles.

Trimedia.

$$TRI = \frac{Me + \overline{Q}}{2}$$

Cuatrimedia. Es la media aritmética considerando solo los valores que se encuentran contenidos estrictamente entre el primer y el tercer cuartil, es decir, esta medida no tiene en cuenta el 25 % de los datos más pequeños y el 25 % de los datos más grandes.

1.1.3. Medidas robustas de dispersión

Rango intercuartílico.

$$RIQ = Q(0{,}75) - Q(0{,}25)$$

MEDA. Es la MEdiana de las Desviaciones Absolutas respecto a la mediana.

Coeficiente de variación cuartílico.

$$CVc = \frac{RIQ/2}{\overline{Q}} = \frac{Q(0{,}75) - Q(0{,}25)}{Q(0{,}75) + Q(0{,}25)}$$

1.1.4. Medidas robustas de forma

Coeficiente de Asimetría de Yule.

$$H_1 = \frac{Q(0{,}9) + Q(0{,}1) - 2Me}{Q(0{,}9) - Q(0{,}1)} = \frac{\overline{Q}}{Me} - 1$$

La interpretación es la vista en la figura anterior:

- Si $H_1 = 0$ la distribución es simétrica.
- Si $H_1 > 0$ la distribución es asimétrica a la derecha.
- Si $H_1 < 0$ la distribución es asimétrica a la izquierda.

Coeficiente de Asimetría de David y Johnson.

$$H_2(\alpha) = \frac{\overline{Q}(\alpha) - Me}{\frac{RIQ(\alpha)}{2}}$$

Coeficiente de Asimetría de Kelly.

$$H_3 = \frac{Q(0{,}9) + Q(0{,}1) - 2Me}{Q(0{,}9) - Q(0{,}1)}$$

1.2. Construcción de disgrama de cajas con bigotes

Para una muestra de una variable aleatoria X de tamaño N usaremos el percentil tipo 6, o de HAVERAGE-Tuckey. Los pasos para construir una caja con bigotes son:

- Se representa la caja de modo que el extremo inferior de la misma se corresponda con el primer cuartil de Tuckey T_1 y que el extremo superior se corresponda con el tercer cuartil T_3.

  Posteriormente, se dibuja una línea dentro de la caja que se corresponde con la mediana Me.

- Los bigotes se construyen uniendo una línea desde el centro de la caja con el último (equivalementente, primer) valor de la distribución que esté a una distancia máxima de un $RIQ = T_3 - T_1$.

- Los valores que se encuentran fuera de estos bigotes y a distancia máxima de $1{,}5RIQ$ se marcan individualmente.

- Un valor a distancia entre $1{,}5RIQ$ y $3RIQ$ se considera un valor alejado, o *outside*.

- Una valor a mayor distancia que $3RIQ$ se considera extremadamente alejado, o *far outside*.

Ejercicio 1.2.1. Demostrar:

1. Si $Z \rightsquigarrow \mathcal{N}(0,1)$, entonces:

$$P[Q_1 - RIQ \leqslant Z \leqslant Q_3 + RIQ] \geqslant 0{,}95$$

2. Lo anterior es cierto para $X \rightsquigarrow \mathcal{N}(\mu, \sigma^2)$

Hagamos este ejercicio:

1. Tenemos que calcular entonces:

$$P[Q_1 - RIQ \leqslant Z \leqslant Q_3 + RIQ]$$

Para ello, como $\mathcal{N}(0,1)$ es una distribución simétrica tenemos que calcular simplemente:

$$P[Q_1 - RIQ \leqslant Z] = P[Q_1 - Q_3 + Q_1 \leqslant Z] \overset{(*)}{=} P[3Q_1 \leqslant Z]$$

donde en $(*)$ hemos usado que $Q_3 = -Q_3$ por ser la distribución simétrica.

Consultamos el valor de Q_1 en la tabla de la normal $\mathcal{N}(0,1)$, buscamos el menor x con $P[x \leqslant Z] \geqslant 0{,}25$, obteniendo aproximadamente $Q_1 = -0{,}68$. Ahora hemos de calcular $(3 \cdot 0{,}68 = 2{,}04)$:

$$P[3Q_1 \leqslant Z] \approx P[-2{,}04 \leqslant Z] = P[Z \leqslant 2{,}04] \approx 0{,}9793$$

Así, tenemos ahora que:

$$\begin{aligned} P[Q_1 - RIQ \leqslant Z \leqslant Q_3 + RIQ] &= 1 - 2 \cdot P[Z \leqslant Q_1 - RIQ] \\ &= 1 - 2(1 - P[Z \geqslant Q_1 - RIQ]) \\ &= -1 + 2P[Z \geqslant Q_1 - RIQ] \\ &\approx -1 + 2 \cdot 0{,}9793 = 0{,}9586 \end{aligned}$$

2. De la tipificación de las variables normales:

$$Z = \frac{X - \mu}{\sigma}$$

obtenemos que:

$$Q_1(Z) = \frac{Q_1(X) - \mu}{\sigma}$$

Por lo que es trivial que:

$$P[Q_1(X) - RIQ(X) \leqslant X \leqslant Q_3(X) + RIQ(X)] \geqslant 0{,}95$$

Ejercicio 1.2.2. Calcular la probabilidad de que un punto de una distribución $\mathcal{N}(0,1)$ sea un *outside* o un *far outside*.

2. Detección de Datos Anómalos. Problema de la falta de simetría. Transformaciones.

2.1. Transformaciones

Imaginémonos que hemos detectado anomalías en una distribución, que pueden ser de dos tipos:

1. Existencia de datos anómalos.
2. Existencia de asimetría.

Estas pueden suceder ambas a la vez.

Si aplicamos una transformaciona a los datos $T(X)$, es posible que corrijamos la asimetría y la existencia de los datos anómalos. Cuando aplicamos una transformación debemos tener en cuenta cómo se afectan las distancias entre los datos.

La única distancia que no cambia la distancia entre los puntos es una transformación lineal, que solo cambia la escala de la distancia, mediante traslaciones y/o rotaciones, pero no cambia "la forma". Las usaremos para cambiar el dominio de nuestras distribuciones. Los tipos de transformaciones que vamos a tener son:

- Transformaciones lineales, para cambiar los dominios de las transformaciones.
- Transformaciones monótonas no lineales.
- Transformaciones no monótonas.

Las transformaciones no lineales modificarán las distancias entre los datos.
Sabemos que siempre es posible tener una transformación lineal $h : [a, b] \to [c, d]$. Las transformaciones cóncavas y convexas permiten transformar distancias, por ejemplo las cóncavas para valores pequeños permite acercarlos tras la transformación y para valores grandes permite alejarlos. Las convexas hacen lo contrario.
Las transformaciones cóncavas pueden servirnos para resolver problemas con distribuciones asimétricas a la izquierda y con colas largas a la derecha y datos anómalos a derecha.
Podemos encontrar también funciones que pasen de convexa a cóncava (como una S), que para datos alejados del centro los junta y para los datos del centro no.

La función seno en [-pi/2, pi/2]. Raíces impares con dominio centrado en cero. O tambien cóncava-convexa, con potencias impares, logaritmos plegados o raíces plegadas, que se escriben como sale en la diapositiva.

2.2. Escala de Tukey

Tukey creó un tipo de transformaciones para resolver esto. Esta escala podemos copiarla, que va desde la identidad (x), teniendo a la izquierda funciones cóncavas y a la derecha convexas.

Cuidado con aplicar transformaciones: Podemos pasar de tener una distribución asimétrica a la izquierda a tener una a la derecha por pasarnos.

¿Cuándo aplicar este procedimiento? Cuando podamos trabajar con los datos transformados sin problemas. Ejemplo: Los microarrays trabajan con los logaritmos, no con los datos transformados.

2.3. Análisis de Varianza

El test ANOVA era para estudiar una variable continua y separada en grupos. Cuando se dan una serie de condiciones, el objetivo era ver si la distribución de cada grupo era la misma o no. El constrate se basa en las hipótesis:

- Que las distribuciones de cada grupo sean normales, que puede rebajarse a que sean más o menos unimodales y simétricas.
- Que las varianzas de todas las distribuciones sean iguales.

Cuando no pasa esto hay que pasar a test no paramétricos, peron no son muy fiables, porque tienen poca potencia.

Siempre que sea posible aplicar transformaciones, hay transformaciones que permiten conservar la normalidad (si la hubiera) pero modificar las varianzas para que todas sean iguales, con el objetivo de aplicar ANOVA.
Tukey puso en marcha un grupo de transformaciones, que se basan en el logaritmo de la mediana y el IRQ. Por cada grupo tenemos un punto en un plano 2D. Si tenemos varios puntos y calculamos la pendiente de la recta uniendo los puntos más extremales, dio una tabla para aplicar transformaciones a los datos homocedásticos. Esto ha mejorado y en SPSS están estas transformaciones.

2.4. Estimación no paramétrica

Tenemos una variable X continua. Sus funciones de densidad y de distribución son:

$$F(x) = P[X \leqslant x] = \int_{-\infty}^{+\infty} F(x)\ dx \qquad f(x) = F'(x)$$

Imaginemos que nuestra intención es encontrar la función de densidad de X. Tenemos que:

$$f(x) = \frac{\partial}{\partial x}F(x) = \lim_{h\to 0}\frac{F(x+h)-F(x-h)}{2h} = \lim_{h\to 0} = \frac{P[x-h \leqslant X \leqslant X+h]}{2h}$$

Podemos usar el concepto de distribución empírica, una aproximación a la función de distribución:

$$\hat{F}(x) = \frac{1}{N}\#\{X : X \leqslant x\}$$

Así, si tenemos una muestra $\tilde{X} = \{x_1, \ldots, x_n\}$ tenemos:

$$\hat{F}(x) = \frac{1}{n}\#\{x_i : x_i \leqslant x\}$$

Así, podemos escribir para un h pequeño:

$$\hat{f}_h(x) = \frac{1}{2nh}\#\{x_i : x-h \leqslant x_i \leqslant x+h\}$$

Y podemos reescribir la condición $x-h \leqslant x_i \leqslant x+h$ como $\left|\frac{x-x_i}{h}\right| \leqslant 1$, por lo que:

$$\hat{f}_h(x) = \frac{1}{2nh}\#\left\{x_i : \left|\frac{x-x_i}{h}\right| \leqslant 1\right\}$$

Si ahora definimos $W : \mathbb{R} \to \mathbb{R}$ dada por:

$$W(x) = \begin{cases} 1/2 & |x| \leqslant 1 \\ 0 & x > 1 \end{cases}$$

A esta función la llamaremos núcleo.

Ejercicio 2.4.1. Demostrar que W es una función de densidad.
Es claro que $W(x) \geqslant 0 \quad \forall x \in \mathbb{R}$ y que W es integrable. Finalmente, tenemos que ver que:

$$\int_{-\infty}^{+\infty} W(x)\,dx = \int_{-1}^{1} W(x)\,dx = \int_{-1}^{1}\frac{1}{2}\,dx = \frac{2}{2} = 1$$

Por lo que W es una función de densidad.

Podemos escribir:

$$\hat{f}_h(x) = \frac{1}{nh}\sum_{i=1}^{n} W\left(\frac{x-x_i}{h}\right)$$

Lo que estamos haciendo es dado un punto x, mirar los puntos que hay dentro del intervalo $[x-h, x+h]$ y dividirlo entre el total de puntos que hay (n). Estamos dando a cada punto la misma importancia. Si h es convenientemente pequeño aproximamos esta función. Estamos haciendo un recubrimiento por núcleo. En este caso asigna a cada punto la misma probabilidad.

Dado un punto x y un h, podemos definir esta función evaluada en x. Se llama

Ejercicio 2.4.2. Demostrar que $\hat{f}_h$ para $h \in \mathbb{R}^+$ fijo es función de densidad, siempre que W lo sea.

Es claro nuevamente que $\hat{f}_h(x) \geqslant 0 \quad \forall x \in \mathbb{R}$ y que $\hat{f}_h$ es integrable. Finalmente, falta ver que:

$$\int_{-\infty}^{+\infty} \hat{f}_h \, dx = \frac{1}{n} \sum_{i=1}^{n} \int_{-\infty}^{+\infty} W\left(\frac{x - x_i}{h}\right) \frac{1}{h} \, dx \overset{(*)}{=} \frac{1}{n} \sum_{i=1}^{n} \int_{-\infty}^{+\infty} W(y) \, dy = \frac{n}{n} = 1$$

donde en $(*)$ hemos usado el Teorema de cambio de variable, para:

$$y = g(x) = \frac{x - x_i}{h}$$

se verifica que:

$$\int K(g(x))g'(x) \, dx = \int K(y) \, dy$$

ajustando bien los límites de integración.

Tenemos diferentes tipos de núcleos:

Uniforme.

$$K(x) = \begin{cases} 1/2 & |x| \leqslant 1 \\ 0 & x > 1 \end{cases}$$

Triangular.

$$K(x) = \begin{cases} 1 - |x| & |x| \leqslant 1 \\ 0 & x > 1 \end{cases}$$

Epanechnikov.

$$K(x) = \begin{cases} 3/4(1 - x^2) & |x| \leqslant 1 \\ 0 & x > 1 \end{cases}$$

Biweight.

$$K(x) = \begin{cases} 15/16(1 - x^2)^2 & |x| \leqslant 1 \\ 0 & x > 1 \end{cases}$$

Triweight.

$$K(x) = \begin{cases} 35/32(1 - x^2)^3 & |x| \leqslant 1 \\ 0 & x > 1 \end{cases}$$

Gaussian.

$$K(x) = (2\pi)^{-1/2} exp\{-x^2/2\}, \quad x \in \mathbb{R}$$

Y definiremos siempre:

$$\hat{f}_h(x) = \frac{1}{nh} \sum_{i=1}^{n} K(x, h)$$

Es aprovechar la idea de Darboux (Riemman) para aproximar el área debajo de una función $f(x)$ por sunas de áreas de rectángulos, pero usando rectángulos de distinta anchura.

El cálculo del valor h está estandarizado:

Gaussian. $h_0 = 1{,}059\hat{\sigma}n^{-1/5}$.

Uniforme. $h = 1{,}740h_0$.

Triangular. $h = 2{,}378h_0$.

Epanechnikov. $h = 2{,}214h_0$.

Biweight. $h = 2{,}623h_0$.

Triweight. $h = 2{,}978h_0$.

Este método es muy sencillo, pero se complica cuando la matriz (grid, `sapply`) de evaluaciones de K sea muy grande, ya sea por:

- Que nos den una muestra muy grande.
- Que queramos evaluar la función $\hat{f}_h$ en muchos puntos.

2.5. Mezclas

Las mezclas se detectan usualmente cuando tenemos una variable que no es unimodal. Cuando tenemos una mezcla $X \rightsquigarrow f(x \mid \theta)$, para k distribuciones parametrizadas:

$$\theta = (\theta_1, \ldots, \theta_k)$$

Así, la mezcla se supone que es una combinación lineal convexa:

$$f(x \mid \theta) = \sum_{i=1}^{k} \lambda_k f_i(x \mid \theta_i), \qquad \sum_{i=1}^{k} \lambda_i = 1$$

Esta es la expresión genérica de una **mezcla de distribuciones**.

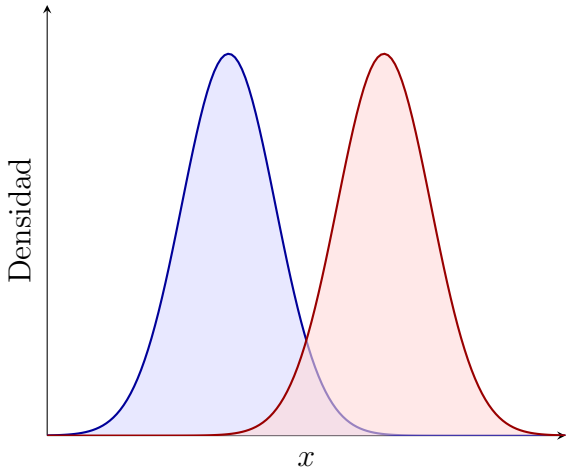


Figura 2.1: Valle formado por dos distribuciones normales de menor altura.

Ejemplo. Donde cada λ_i es la probabilidad de que un dato esté en la $i-$ésima muestra. En el ejemplo superior podemos observar una mezcla de dos variables, donde tendríamos los parámetros:

$$\theta = (\mu_1, \mu_2, \sigma_1, \sigma_2, \lambda_1, \lambda_2)$$

Por ejemplo, podría corresponderse con la variable `peso` en un dataset, donde no se ha separado el peso de los hombres y el de las mujeres.

En muchas ocasiones un histograma no puede mostrar esto pero a lo mejor la función `density` de R sí. Otra forma es hacer un test de normalidad sobre una variable que sabemos que tiene que ser normal (como el peso) y no nos da normal, revelando que hay problemas subyacentes.

El concepto de mezcla sirve también como técnica de agrupamiento, entendiendo que hay grupos distintos dentro de una misma variable porque hay varias distribuciones. Así, entendemos un grupo como un conjunto de datos sigue una misma distribución.

Si hacemos la máxima verosimilitud para una muestra $\{x_1, \ldots, x_n\}$:

$$L = \prod_{i=1}^{n} f(x_i) = \prod_{i=1}^{n} \sum_{j=1}^{k} \lambda_j f_j(x_i \mid \theta_j)$$

Ahora:

$$\log L = \sum_{i=1}^{n} \log f(x_i \mid \theta) = \sum_{i=1}^{n} \log \left(\sum_{j=1}^{k} \lambda_j f_j(x_i \mid \theta_j) \right)$$

Y trabajar con el logaritmo de la suma complica el asunto.

Dadas dos muestras de tamaños m_1 y m_2 y queremos comprar que son iguales, tomamos n probabillidades homogéneas $p_1, \ldots, p_n \in]0, 1[$ y calculamos los cuantiles $p_1, \ldots, p_n$, para ver si las muestras son comparables.
Pedir apuntes, estamos trabajando con una normal y lo que hacemos es:

$$\frac{\partial \log L}{\partial \mu_k} = -\frac{1}{2} \sum_{i=1}^{n} \frac{\lambda_k f_k(x_i \mid \theta_k)}{\sum_k \lambda_k f(x_i \mid \theta_k)} \frac{\partial}{\partial} (x - \mu_k)^{algo} \sum$$

No me he enterado de esto ni de las fórmulas. Al final el estimador se queda como:

$$\hat{\mu}_k = \sum_{i=1}^{n} \pi_{k|i} x_i$$

$$\hat{\Sigma}_k = \sum_{i=1}^{n} \pi_{k|i} (x_i - \hat{\mu}_k)^T (x_i - \mu_k)$$

Si consideramos las estimaciones, el λ_k depende de unas π que son desconocidas, pero los parámetros θ_k dependen de las π. Y la matriz de covarianza también.

Así, las estimaciones dependen de los parámetros. Este es el problema de la estimación de la mezcla de distribuciones, que no tiene una solución directa. Son técnicas de optimización o un algoritmo de datos faltantes para este problema. Nosotros lo haremos a lo salvaje, usando las herramientas que tenemos.

2.6. Densidad no paramétrica multivariante

La densidad sería (h_x, h_y son los anchos de banda):

$$f(x,y) = \frac{1}{nh_xh_y}\sum_{i=1}^{n} K\left(\frac{x-x_i}{h_x}, \frac{y-y_i}{h_y}\right)$$

Los kernels más utilizados son:

Kernel Gaussiano.

$$K(x,y) = \frac{1}{2\pi}e^{-\frac{1}{2}(x^2+y^2)}$$

Epanechnikov.

$$K(x,y) = \begin{cases} \frac{2}{\pi}(1-x^2-y^2) & \text{si } x^2+y^2<1 \\ 0 & \text{en otro caso} \end{cases}$$