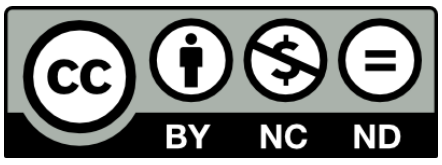
Inferencia Estadística



Los Del DGIIM, losdeldgiim.github.io

Doble Grado en Ingeniería Informática y Matemáticas
Universidad de Granada



Esta obra está bajo una Licencia Creative Commons Atribución-NoComercial-SinDerivadas 4.0 Internacional (CC BY-NC-ND 4.0).

Eres libre de compartir y redistribuir el contenido de esta obra en cualquier medio o formato, siempre y cuando des el crédito adecuado a los autores originales y no persigas fines comerciales.

Inferencia Estadística

Los Del DGIIM, losdeldgiim.github.io

José Juan Urrutia Milán

Granada, 2025

Índice general

1. Ejercicios de clase **5**
1.1. Estadísticos muestrales 5
1.2. Distribuciones en el muestreo de poblaciones normales 10
1.2.1. Muestreo en una población normal unidimensional 12
1.2.2. Muestreo en dos poblaciones normales unidimensionales 16
1.3. Suficiencia y completitud 20
1.4. Estimación puntual. Insesgadez y mínima varianza 32

2. Relaciones de Ejercicios **41**
2.1. Estadísticos muestrales 41
2.2. Distribuciones en el muestreo de poblaciones normales 56
2.3. Suficiencia y completitud 66

1. Ejercicios de clase

Este capítulo tiene el propósito de recoger todos los ejercicios propuestos en clase por parte de la profesora que acompañan a los contenidos teóricos. No se pretende que sean ejercicios de examen, sino que son ejercicios de práctica para afianzar los conceptos teóricos.

1.1. Estadísticos muestrales

Ejemplo. Obtener la función masa de probabilidad conjunta de una m.a.s. de $X \rightsquigarrow \mathcal{B}(k_0, p)$ y la función de densidad de una m.a.s. de $X \rightsquigarrow U(a, b)$.

Recordamos que si $X \rightsquigarrow \mathcal{B}(k_0, p)$, entonces:

$$P[X = x] = \binom{k_0}{x} p^x (1-p)^{n-x} \qquad \forall x \in \{0, \dots, k_0\}$$

Por lo que si tenemos una m.a.s. de n variables independientes e idénticamente distribuidas a X, $(X_1, \dots, X_n)$, su función de densidad vendrá dada por:

$$\begin{aligned} P[X_1 = x_1, \dots, X_n = x_n] &\overset{\text{indep.}}{=} \prod_{i=1}^{n} P[X_i = x_i] \overset{\text{id. d.}}{=} \prod_{i=1}^{n} P[X = x_i] \\ &= \prod_{i=1}^{n} \binom{k_0}{x_i} p^{x_i} (1-p)^{k_0 - x_i} = p^{\sum_{i=1}^{n} x_i} (1-p)^{nk_0 - \sum_{i=1}^{n} x_i} \prod_{i=1}^{n} \binom{k_0}{x_i} \\ &\quad \forall x_i \in \{0, \dots, k_0\} \end{aligned}$$

Si ahora $X \rightsquigarrow U(a, b)$ para ciertos $a, b \in \mathbb{R}$ con $a < b$, entonces:

$$f_X(x) = \frac{1}{b-a} \qquad \forall x \in [a, b]$$

de donde:

$$f_{(X_1,\dots,X_n)}(x_1, \dots, x_n) \overset{\text{indep.}}{=} \prod_{i=1}^{n} f_{X_i}(x_i) \overset{\text{id. d.}}{=} \prod_{i=1}^{n} f_X(x_i) = \prod_{i=1}^{n} \frac{1}{b-a} = \frac{1}{(b-a)^n} \qquad \forall x \in [a, b]$$

Ejemplo. Para cada realización muestral, $(x_1, \dots, x_n) \in \mathcal{X}^n$, $F^*_{x_1,\dots,x_n}$ es una función de distribución en $\mathbb{R}$. En particular es una función a saltos, con saltos de amplitud $1/n$ en los sucesivos valores muestrales ordenados de menor a mayor, supuestos que

sean distintos, y de saltos múltiplos en el caso de que varios valores muestrales coincidieran.

En las condiciones del enunciado, es decir, suponiendo que $x_1, \ldots, x_n$ están ordenados de menor a mayor y son distintos, entonces es fácil ver que:

$$F^*_{x_1,\ldots,x_n}(x) = \begin{cases} 0 & \text{si } x < x_1 \\ 1/n & \text{si } x_1 \leqslant x < x_2 \\ & \vdots \\ 1 & \text{si } x > x_n \end{cases} \qquad \forall x \in \mathbb{R}$$

Por lo que es claro que $F^*_{x_1,\ldots,x_n}$ es no decreciente, continua por la derecha, con límite 0 en $-\infty$ y con límite 1 en $+\infty$.

Ejemplo. Para todo $x \in \mathbb{R}$, $F^*_{X_1,\ldots,X_n}(x)$ es una variable aleatoria tal que $nF^*_{X_1,\ldots,X_n}(x) \rightsquigarrow \mathcal{B}(n, F(x))$ y:

$$E[F^*_{X_1,\ldots,X_n}(x)] = F(x), \qquad Var[F^*_{X_1,\ldots,X_n}(x)] = \frac{F(x)(1-F(x))}{n}$$

donde $F(x)$ es la función de distribución de X.

Recordamos que:

$$F^*_{X_1,\ldots,X_n}(x) = \frac{1}{n}\sum_{i=1}^{n} I_{]-\infty,x]}(X_i) \qquad \forall x \in \mathbb{R}$$

Fijado $x \in \mathbb{R}$, tenemos que $I_{]-\infty,x]}(X) \rightsquigarrow \mathcal{B}(1, P[X \leqslant x]) \equiv \mathcal{B}(1, F(x))$, por lo que por la propiedad reproductiva de la binomial tenemos que:

$$nF^*_{X_1,\ldots,X_n}(x) \rightsquigarrow \mathcal{B}(n, F(x))$$

Por lo que:

$$nE[F^*_{X_1,\ldots,X_n}(x)] = E[nF^*_{X_1,\ldots,X_n}(x)] = nF(x) \Longrightarrow E[F^*_{X_1,\ldots,X_n}(x)] = F(x)$$

Para la varianza:

$$n^2 Var[F^*_{X_1,\ldots,X_n}(x)] = Var[nF^*_{X_1,\ldots,X_n}(x)] = nF(x)(1-F(x)) \Longrightarrow$$
$$\Longrightarrow Var[F^*_{X_1,\ldots,X_n}(x)] = \frac{F(x)(1-F(x))}{n}$$

Ejemplo. Para valores grandes de n, en virtual del Teorema Central del Límite:

$$F^*_{X_1,\ldots,X_n}(x) \rightsquigarrow \mathcal{N}\left(F(x), \frac{F(x)(1-F(x))}{n}\right)$$

Sea $(X_1, \ldots, X_n)$ una m.a.s. de n muestras, sea:

$$S_n = \sum_{i=1}^{n} I_{]-\infty,x]}(X_i) \qquad \forall n \in \mathbb{N}$$

Por el Teorema Central del Límite tenemos que:

$$\frac{S_n - E[S_n]}{\sqrt{Var[S_n]}} \overset{n\to\infty}{\rightsquigarrow} \mathcal{N}(0,1) \Longrightarrow S_n \overset{n\to\infty}{\rightsquigarrow} \mathcal{N}\left(E[S_n], Var[S_n]\right)$$

Como $S_n \rightsquigarrow \mathcal{B}(n, F(x))$, entonces tenemos que:

$$\begin{aligned} E[S_n] &= nF(x) \\ Var[S_n] &= nF(x)(1-F(x)) \end{aligned}$$

Por lo que:

$$F^*_{X_1,\ldots,X_n}(x) = \frac{1}{n} S_n \overset{n\to\infty}{\rightsquigarrow} \mathcal{N}\left(F(x), \frac{F(x)(1-F(x))}{n}\right)$$

Ejemplo. Dada una muestra aleatoria simple formada por las observaciones $(3, 8, 5, 4, 5)$, obtener su función de distribución muestral y realizar la representación gráfica.

Aplicando la definición de la función de distribución muestral obtenemos que:

$$F^*_{(3,8,5,4,5)}(x) = \begin{cases} 0 & \text{si } x < 3 \\ 1/5 & \text{si } 3 \leqslant x < 4 \\ 2/5 & \text{si } 4 \leqslant x < 5 \\ 4/5 & \text{si } 5 \leqslant x < 8 \\ 1 & \text{si } x \geqslant 8 \end{cases}$$

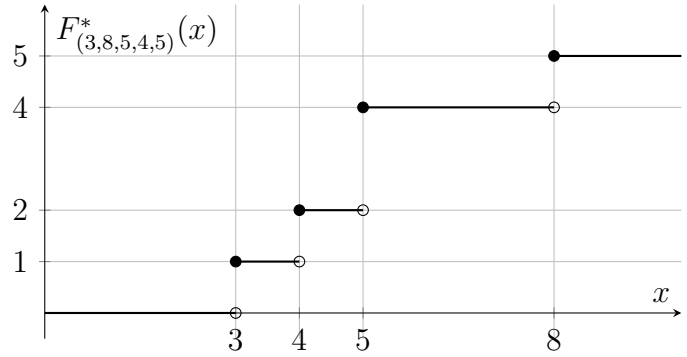


Figura 1.1: Representación gráfica de $F^*_{(3,8,5,4,5)}(x)$.

Ejemplo. Sea X una variable aleatoria con distribución $\mathcal{B}(1,p)$ con $p \in (0,1)$. Se toma una muestra de tamaño 5, $(X_1, X_2, X_3, X_4, X_5)$, y se obtiene la siguiente observación $(0, 1, 1, 0, 0)$. Determinar el valor de los estadísticos estudiados en la observación.

Aplicando las fórmulas vistas en clase obtenemos:

- Media:

$$\overline{X} = \frac{0+1+1+0+0}{5} = 0{,}4$$

- Varianza muestral:

$$\sigma^2 = \frac{(0-0{,}4)^2 + (1-0{,}4)^2 + (1-0{,}4)^2 + (0-0{,}4)^2 + (0-0{,}4)^2}{5} = \frac{1{,}2}{5} = 0{,}24$$

- Cuasivarianza:

$$s^2 = \frac{(0-0{,}4)^2 + (1-0{,}4)^2 + (1-0{,}4)^2 + (0-0{,}4)^2 + (0-0{,}4)^2}{5-1} = \frac{1{,}2}{4} = 0{,}3$$

- Estadísticos ordenados:

$$x_{(1)} = 0, \quad x_{(2)} = 0, \quad x_{(3)} = 0, \quad x_{(4)} = 1, \quad x_{(5)} = 1$$

Ejemplo. Sea $(X_1, \ldots, X_n)$ una m.a.s. y $\overline{X} = \dfrac{1}{n}\sum_{i=1}^{n} X_i$, entonces:

$$M_{\overline{X}}(t) = (M_X(t/n))^n$$

$$M_{\overline{X}}(t) = E\left[e^{t\overline{X}}\right] = E\left[e^{\frac{t}{n}\sum_{i=1}^{n} X_i}\right] = M_{\sum_{i=1}^{n} X_i}\left(\frac{t}{n}\right) \overset{\text{indep.}}{=} \prod_{i=1}^{n} M_{X_i}\left(\frac{t}{n}\right) \overset{\text{id. d.}}{=} \left(M_X\left(\frac{t}{n}\right)\right)^n$$

Ejemplo. Obtener la distribución muestral de $\overline{X}$ para $(X_1, \ldots, X_n)$ una m.a.s. de $X \rightsquigarrow \mathcal{N}(\mu, \sigma^2)$.

$$M_{\overline{X}}(t) = \left(M_X\left(\frac{t}{n}\right)\right)^n = \left(e^{\frac{\mu t}{n} + \frac{\sigma^2 t^2}{2n^2}}\right)^n = e^{\mu t + \frac{\sigma^2 t^2}{2n}}$$

Luego $\overline{X} \rightsquigarrow \mathcal{N}\left(\mu, \frac{\sigma^2}{n}\right)$, ya que la función generatriz de momentos caracteriza la distribución.

Proposición 1.1.1. Si tenemos una m.a.s. $(X_1, \ldots, X_n)$, entonces:

$$F_{X_{(n)}}(x) = (F_X(x))^n \qquad \forall x \in \mathbb{R}$$
$$F_{X_{(1)}}(x) = 1 - (1 - F_X(x))^n$$

Demostración. Para la distribución del máximo:

$$F_{X_{(n)}}(x) = P[X_{(n)} \leqslant x] = P[X_1 \leqslant x, \ldots, X_n \leqslant x] \overset{\text{indep.}}{=} \prod_{i=1}^{n} P[X_i \leqslant x]$$
$$\overset{\text{id. d.}}{=} \prod_{i=1}^{n} P[X \leqslant x] = (F_X(x))^n$$

Para la del mínimo:

$$F_{X_{(1)}}(x) = P[X_{(1)} \leqslant x] = 1 - P[X_{(1)} > x] = 1 - P[X_1 > x, \ldots, X_n > x]$$
$$\overset{\text{indep.}}{=} 1 - \prod_{i=1}^{n} P[X_i > x] \overset{\text{id. d.}}{=} 1 - (P[X > x])^n = 1 - (1 - F_X(x))^n$$

□

Ejemplo. Obtener las distribuciones muestrales de $X_{(1)}$ y $X_{(n)}$ para $X \rightsquigarrow U(a,b)$.

Si $X \rightsquigarrow U(a,b)$, entonces:

$$F_X(x) = \frac{x-a}{b-a} \qquad \forall x \in [a,b]$$

Por lo que aplicando la Proposición superior:

$$F_{X_{(n)}}(x) = (F_X(x))^n = \left(\frac{x-a}{b-a}\right)^n \qquad \forall x \in [a,b]$$

$$F_{X_{(1)}}(x) = 1-(1-F_X(x))^n = 1-\left(1-\frac{x-a}{b-a}\right)^n = 1-\left(\frac{b-x}{b-a}\right)^n \qquad \forall x \in [a,b]$$

Ejemplo. Sea $(X_1,\ldots,X_n)$ una m.a.s. de X. Entonces, para los momentos no centrados de orden k de la m.a.s. se tiene que:

$$E\left[A_k\right] = E[X^k]$$
$$Var\left[A_k\right] = \frac{Var[X^k]}{n}$$

Demostremos la primera igualdad:

$$E\left[A_k\right] = E\left[\frac{1}{n}\sum_{i=1}^n X_i^k\right] = \frac{1}{n}\sum_{i=1}^n E[X_i^k] \overset{\text{id. d.}}{=} \frac{1}{n}\sum_{i=1}^n E[X^k] = E[X^k]$$

Demostremos la segunda igualdad:

$$Var\left[A_k\right] = Var\left[\frac{1}{n}\sum_{i=1}^n X_i^k\right] = \frac{1}{n^2}Var\left[\sum_{i=1}^n X_i^k\right] \overset{\text{indep.}}{=} \frac{1}{n^2}\sum_{i=1}^n Var[X_i^k] \overset{\text{id. d.}}{=}$$
$$\overset{\text{id. d.}}{=} \frac{1}{n^2}\sum_{i=1}^n Var[X^k] = \frac{Var[X^k]}{n}$$

1.2. Distribuciones en el muestreo de poblaciones normales

Proposición 1.2.2. Sea $X \rightsquigarrow \mathcal{N}(0,1)$, entonces $X^2 \rightsquigarrow \chi^2(1)$.

Demostración. Sea $Y = X^2 = h(X)$, entonces $X = \pm\sqrt{Y} = h^{-1}(y)$, por lo que:

$$f_Y(y) = f_X(h_1^{-1}(y)) \left| \frac{dh_1^{-1}(y)}{dy} \right| + f_X(h_2^{-1}(y)) + \left| \frac{dh_2^{-1}(y)}{dy} \right|$$

Como $X \rightsquigarrow \mathcal{N}(0,1)$, entonces:

$$f_X(x) = \frac{1}{\sqrt{2\pi}} e^{\frac{-x^2}{2}} \qquad \forall x \in \mathbb{R}$$

De donde:

$$f_Y(y) = \frac{1}{\sqrt{2\pi}} e^{\frac{-(\sqrt{y})^2}{2}} \left| \frac{1}{2\sqrt{y}} \right| + \frac{1}{\sqrt{2\pi}} e^{\frac{-(-\sqrt{y})^2}{2}} \left| \frac{-1}{2\sqrt{y}} \right| = \frac{1}{\sqrt{2\pi y}} e^{\frac{-y}{2}} \qquad \forall y > 0$$

Por lo que $Y \rightsquigarrow \chi^2(1)$. □

Ejemplo. Calcula el valor de k o la probabilidad inducida:

a) $P[\chi^2(10) \geqslant k] = 0{,}005$.

Consultando la tabla de la distribución χ^2, obtenemos que $k = 25{,}1881$.

b) $P[\chi^2(45) \leqslant k] = 0{,}005$.

Tenemos que:

$$P[\chi^2(45) \leqslant k] = 1 - P[\chi^2(45) \geqslant k] = 0{,}005 \Longrightarrow P[\chi^2(45) \geqslant k] = 0{,}995$$

Consultando la tabla de la distribución χ^2, obtenemos que $k = 24{,}3110$.

c) $P[\chi^2(14) \geqslant 21{,}06]$

En este caso, no podemos consultar de forma directa los encabezados de la tabla de la distribución χ^2 y obtener el valor de la probabilidad, sino que tenemos que buscar qué columna de la tabla contiene el valor buscado. Podemos ver que:

$$P[\chi^2(14) \geqslant 21{,}06] \approx 0{,}1$$

d) $P[\chi^2(20) \leqslant 12{,}44]$

Tenemos que:

$$P[\chi^2(20) \leqslant 12{,}44] = 1 - P[\chi^2(20) \geqslant 12{,}44] \overset{(*)}{=} 1 - 0{,}9 = 0{,}1$$

donde en $(*)$ hemos consultado la tabla de la distribución χ^2.

Ejemplo. Calcula el valor de k o la probabilidad inducida:

a) $P[t(26) \geqslant k] = 0{,}05$

Consultando la tabla de la distribución t de Student, obtenemos que $k = 1{,}706$.

b) $P[t(20) \leqslant k] = 0{,}25$

Por la simetría de la distribución t de Student, tenemos que:

$$0{,}25 = P[t(20) \leqslant k] = P[t(20) \geqslant -k]$$

Consultando la tabla de la distribución t de Student, obtenemos que $-k = 0{,}6870$, luego $k = -0{,}6870$.

c) $P[t(26) \geqslant k] = 0{,}9$

Tenemos que:

$$0{,}9 = P[t(26) \geqslant k] = 1 - P[t(26) \leqslant k] = 1 - P[t(26) \geqslant -k] \Longrightarrow P[t(26) \geqslant -k] = 0{,}1$$

Consultando la tabla de la distribución t de Student, obtenemos que $-k = 1{,}3150$, luego $k = -1{,}3150$.

d) $P[t(21) \geqslant 1{,}721]$

Consultando la tabla de la distribución t de Student, obtenemos que:

$$P[t(21) \geqslant 1{,}721] \approx 0{,}05$$

e) $P[t(11) \leqslant 0{,}697]$

Consultando la tabla de la distribución t de Student, obtenemos que:

$$P[t(11) \leqslant 0{,}697] = 1 - P[t(11) \geqslant 0{,}697] \approx 1 - 0{,}25 = 0{,}75$$

f) $P[t(8) \leqslant -2{,}306]$

Tenemos que:

$$P[t(8) \leqslant -2{,}306] = P[t(8) \geqslant 2{,}306] = 0{,}025$$

Ejemplo. Calcula el valor de k o la probabilidad inducida:

a) $P[F(7,3) \leqslant k] = 0{,}95$

Consultando de manera directa la tabla de la distribución F de Snedecor, obtenemos que $k = 8{,}89$.

b) $P[F(8,4) \geqslant k] = 0{,}01$

$$0{,}01 = P[F(8,4) \geqslant k] = 1 - P[F(8,4) \leqslant k] \Longrightarrow P[F(8,4) \leqslant k] = 0{,}99$$

Consultando la tabla de la distribución F de Snedecor, obtenemos que $k = 14{,}8$.

c) $P[F(2,2) \leqslant 19]$

Consultando la tabla de la distribución F de Snedecor, obtenemos que:

$$P[F(2,2) \leqslant 19] = 0{,}95$$

d) $P[F(3,5) \geqslant 12{,}1]$

$$P[F(3,5) \geqslant 12{,}1] = 1 - P[F(3,5) \leqslant 12{,}1] \overset{(*)}{=} 1 - 0{,}99 = 0{,}01$$

donde en $(*)$ hemos consultado la tabla de la distribución F de Snedecor.

e) $P[F(60,40) \leqslant k] = 0{,}05$

Consultando la tabla de la distribución F de Snedecor, obtenemos que $k = 0{,}627$.

1.2.1. Muestreo en una población normal unidimensional

En lo que sigue, sea una $(X_1, \ldots, X_n)$ m.a.s. con $X \rightsquigarrow \mathcal{N}(\mu, \sigma^2)$.

Proposición 1.2.3. En dichas condiciones, veamos que:

$$\overline{X}, (X_1 - \overline{X}, \ldots, X_n - \overline{X}) \text{ son independientes}$$

Demostración. Para ellos, usaremos la caracterización de independencia de vectores aleatorios por la función generatriz de momentos conjunta. Es decir, buscamos probar

$$M_{\overline{X}, X_1 - \overline{X}, \ldots, X_n - \overline{X}}(t, t_1, \ldots, t_n) \overset{?}{=} M_{\overline{X}}(t) M_{X_1 - \overline{X}, \ldots, X_n - \overline{X}}(t_1, \ldots, t_n)$$

Por la reproductividad de la normal, todas las variables aleatorias que aparecen son normales, luego su función característica de momentos está definida en todo $\mathbb{R}$.

Por tanto, para todo $(t, t_1, \ldots, t_n) \in \mathbb{R}^{n+1}$, tenemos que:

$$
\begin{aligned}
M_{\overline{X}, X_1-\overline{X}, \ldots, X_n-\overline{X}}(t, t_1, \ldots, t_n) &= E\left[e^{(t,t_1,\ldots,t_n)\cdot(\overline{X}, X_1-\overline{X}, \ldots, X_n-\overline{X})}\right] = E\left[e^{t\overline{X}+\sum_{i=1}^{n}(X_i-\overline{X})t_i}\right] = \\
&= E\left[e^{\frac{t}{n}\sum_{i=1}^{n}X_i+\sum_{i=1}^{n}X_it_i-\sum_{i=1}^{n}\overline{X}t_i}\right] = E\left[e^{\frac{t}{n}\sum_{i=1}^{n}X_i+\sum_{i=1}^{n}X_it_i-\overline{X}\sum_{i=1}^{n}t_i}\right] = \\
&= E\left[e^{\frac{t}{n}\sum_{i=1}^{n}X_i+\sum_{i=1}^{n}X_it_i-\frac{1}{n}\sum_{i=1}^{n}X_i\sum_{i=1}^{n}t_i}\right] = E\left[e^{\frac{t}{n}\sum_{i=1}^{n}X_i+\sum_{i=1}^{n}X_it_i-\sum_{i=1}^{n}X_i\frac{1}{n}\sum_{i=1}^{n}t_i}\right] = \\
&= E\left[e^{\frac{t}{n}\sum_{i=1}^{n}X_i+\sum_{i=1}^{n}X_it_i-\sum_{i=1}^{n}X_i\bar{t}}\right] = E\left[e^{\sum_{i=1}^{n}X_i\frac{t}{n}+\sum_{i=1}^{n}X_it_i-\sum_{i=1}^{n}X_i\bar{t}}\right] = \\
&= E\left[e^{\sum_{i=1}^{n}X_i\left(\frac{t}{n}+t_i-\bar{t}\right)}\right] = E\left[\prod_{i=1}^{n}e^{X_i\left(\frac{t}{n}+t_i-\bar{t}\right)}\right] \overset{\text{indep.}}{=} \prod_{i=1}^{n}E\left[e^{X_i\left(\frac{t}{n}+t_i-\bar{t}\right)}\right] = \\
&= \prod_{i=1}^{n}M_{X_i}\left(\frac{t}{n}+t_i-\bar{t}\right) \overset{(*)}{=} \prod_{i=1}^{n}\exp\left[\left(\frac{t}{n}+t_i-\bar{t}\right)\mu+\left(\frac{t}{n}+t_i-\bar{t}\right)^2\frac{\sigma^2}{2}\right] = \\
&= \exp\left[\sum_{i=1}^{n}\left[\left(\frac{t}{n}+t_i-\bar{t}\right)\mu+\frac{\sigma^2}{2}\left(\frac{t^2}{n^2}+\left(t_i-\bar{t}\right)^2+2\frac{t}{n}(t_i-\bar{t})\right)\right]\right] = \\
&= \exp\left[\sum_{i=1}^{n}\frac{\mu t}{n}+\sum_{i=1}^{n}\mu(t_i-\bar{t})+\frac{\sigma^2}{2}\left(\sum_{i=1}^{n}\frac{t^2}{n^2}+\sum_{i=1}^{n}(t_i-\bar{t})^2+2\sum_{i=1}^{n}\frac{t}{n}(t_i-\bar{t})\right)\right] \overset{(**)}{=} \\
&\overset{(**)}{=} \exp\left[\frac{\cancel{n}\mu t}{\cancel{n}}+\mu\cancel{\sum_{i=1}^{n}(t_i-\bar{t})}+\frac{\sigma^2}{2}\left(\frac{\cancel{n}t^2}{n\cancel{^2}}+\sum_{i=1}^{n}(t_i-\bar{t})^2+2\frac{t}{n}\cancel{\sum_{i=1}^{n}(t_i-\bar{t})}\right)\right] = \\
&= \exp\left[\mu t+\frac{\sigma^2t^2}{2n}+\frac{\sigma^2}{2}\sum_{i=1}^{n}(t_i-\bar{t})^2\right]
\end{aligned}
$$

donde en $(*)$ hemos usado que todas las variables son idénticamente distribuidas a una $\mathcal{N}(\mu, \sigma^2)$; y en $(**)$ hemos usado que el momento centrado de primer orden es cero. Sabemos que:

$$
\begin{aligned}
M_{\overline{X}}(t) &= M_{\left(\overline{X}, X_1-\overline{X}, \ldots, X_n-\overline{X}\right)}(t, 0, ..., 0) = e^{\mu t+\frac{\sigma^2t^2}{2n}} \\
M_{(X_1-\overline{X}, \ldots, X_n-\overline{X})}(t_1, ..., t_n) &= M_{(\overline{X}, X_1-\overline{X}, \ldots, X_n-\overline{X})}(0, t_1, \ldots, t_n) \\
&= e^{\frac{\sigma^2}{2}\sum_{i=1}^{n}(t_i-\bar{t})^2}
\end{aligned}
$$

Por tanto, tenemos que el producto de las funciones generatrices de momentos es la generatriz de mmoentos conjunta, luego las variables son independientes. □

Corolario 1.2.3.1. En dichas condiciones, tenemos que:

1. $\overline{X} \rightsquigarrow \mathcal{N}(\mu, \frac{\sigma^2}{n})$
2. (Lema de Fisher): $\overline{X}$ y S^2 son independientes.
3. $\dfrac{(n-1)S^2}{\sigma^2} \rightsquigarrow \chi^2(n-1)$

4. $\dfrac{\overline{X}-\mu}{S/\sqrt{n}} \rightsquigarrow t(n-1)$

Demostración. Demostramos cada una de las afirmaciones:

- Se vio ya en el ejemplo 1.1.
- Como S^2 es función del vector de la Proposición anterior, tenemos que es independiente a $\overline{X}$, ya que las funciones de variables independientes son independientes.
- Queremos demostrar que:

$$\frac{(n-1)S^2}{\sigma^2} = \frac{\sum_{i=1}^{n}\left(X_i-\overline{X}\right)^2}{\sigma^2} \rightsquigarrow \chi^2(n-1)$$

Tenemos que:

$$\begin{aligned}\frac{\sum_{i=1}^{n}\left(X_i-\mu\right)^2}{\sigma^2} &= \frac{\sum_{i=1}^{n}\left(X_i-\overline{X}+\overline{X}-\mu\right)^2}{\sigma^2}\\ &= \frac{\sum_{i=1}^{n}\left(X_i-\overline{X}\right)^2+\sum_{i=1}^{n}\left(\overline{X}-\mu\right)^2+2\cancel{\sum_{i=1}^{n}(X_i-\overline{X})}(\overline{X}-\mu)}{\sigma^2}\\ &= \frac{\sum_{i=1}^{n}\left(X_i-\overline{X}\right)^2}{\sigma^2}+n\frac{\left(\overline{X}-\mu\right)^2}{\sigma^2}\end{aligned}$$

Notemos que estamos interesados en conocer la distribución de la primera parte de la suma. Notemos por A a la suma completa, por B a la primera parte y por C a la segunda parte, de forma que $A = B + C$. Veamos la distribución de cada término:

- Por un lado para A, tenemos que:

$$A = \frac{\sum_{i=1}^{n}\left(X_i-\mu\right)^2}{\sigma^2} = \sum_{i=1}^{n}\left(\frac{X_i-\mu}{\sigma}\right)^2 \overset{(*)}{=} \sum_{i=1}^{n} Z_i^2 \rightsquigarrow \chi^2(n)$$

  donde en $(*)$ hemos usado que $X_i \rightsquigarrow \mathcal{N}(\mu,\sigma^2)$, por lo que su variable tipificada $Z_i \rightsquigarrow \mathcal{N}(0,1)$. Además, en la última igualdad hemos empleado la construcción de la distribución χ^2 a partir de variables normales.

- Por otro lado, para C, del ejemplo 1.1, tenemos que $\overline{X} \rightsquigarrow \mathcal{N}(\mu, \frac{\sigma^2}{n})$, por lo que, tipificando

$$\frac{\overline{X}-\mu}{\sqrt{\sigma^2/n}} = \frac{\overline{X}-\mu}{\sigma/\sqrt{n}} = \sqrt{n}\frac{\overline{X}-\mu}{\sigma} \rightsquigarrow \mathcal{N}(0,1)$$

  Elevando al cuadrado y empleando la construcción de la distribución χ^2, obtenemos que:

$$C = n\frac{\left(\overline{X}-\mu\right)^2}{\sigma^2} \rightsquigarrow \chi^2(1)$$

Buscamos la distribución de B, y para ello, buscamos su caracterización por la función generatriz de momentos. Tenemos que $B = f(S^2)$, mientras que $C = g(\overline{X})$. Como, por el Lema de Fisher, $\overline{X}$ y S^2 son independientes, tenemos que B y C son independientes. Por lo que:

$$M_{A=B+C}(t) \overset{\text{indep.}}{=} M_B(t)M_C(t)$$

Veamos la función generatriz de momentos de A y C:

- Para A, tenemos que $A \rightsquigarrow \chi^2(n)$, por lo que:

$$M_A(t) = \frac{1}{(1-2t)^{n/2}} \qquad t < \frac{1}{2}$$

- Para C, tenemos que $C \rightsquigarrow \chi^2(1)$, por lo que:

$$M_C(t) = \frac{1}{(1-2t)^{\frac{1}{2}}} \qquad t < \frac{1}{2}$$

Por tanto, tenemos que:

$$M_B(t) = \frac{M_A(t)}{M_C(t)} = \frac{\dfrac{1}{(1-2t)^{\frac{n}{2}}}}{\dfrac{1}{(1-2t)^{\frac{1}{2}}}} = \frac{1}{(1-2t)^{\frac{n-1}{2}}} \qquad t < \frac{1}{2}$$

De aquí, deducimos que $B \rightsquigarrow \chi^2(n-1)$.

- Queremos ver que $\dfrac{\overline{X}-\mu}{S/\sqrt{n}} \rightsquigarrow t(n-1)$.

Para ello, al igual que la χ^2, lo más sencillo es ir a la construcción de t:

$$\left.\begin{array}{l} X \rightsquigarrow \mathcal{N}(0,1) \\ Y \rightsquigarrow \chi^2(n) \\ X \text{ e } Y \text{ independientes} \end{array}\right\} \Longrightarrow \frac{X}{\sqrt{Y/n}} \rightsquigarrow t(n)$$

Por un lado, como $\overline{X} \rightsquigarrow \mathcal{N}(\mu, \frac{\sigma^2}{n})$, tenemos que:

$$\frac{\overline{X}-\mu}{\sigma/\sqrt{n}} \rightsquigarrow \mathcal{N}(0,1)$$

Por otro lado, del punto anterior, tenemos que:

$$\frac{(n-1)S^2}{\sigma^2} \rightsquigarrow \chi^2(n-1)$$

Como $\overline{X}$ y S^2 son independientes por el Lema de Fisher, tenemos que ambas variables aleatorias consideradas son independientes, por lo que podemos aplicar la construcción de la distribución t:

$$\frac{\dfrac{\overline{X}-\mu}{\sigma/\sqrt{n}}}{\sqrt{\dfrac{\cancel{(n-1)}S^2}{\sigma^2\cancel{(n-1)}}}} = \frac{\dfrac{\overline{X}-\mu}{\cancel{\sigma}/\sqrt{n}}}{\dfrac{S}{\cancel{\sigma}}} = \frac{\overline{X}-\mu}{S/\sqrt{n}} \rightsquigarrow t(n-1)$$

□

Gracias a este corolario, podemos inferir sobre μ y σ^2 de la población normal a partir de una m.a.s. de la misma. En particular, tenemos que los siguientes resultados, con demostración evidente a partir del corolario anterior:

1. Si queremos inferir sobre μ:

   a) Si conocemos σ_0^2 (notaremos con el subíndice 0 que es un valor conocido), entonces:
   $$\frac{\overline{X}-\mu}{\sigma_0/\sqrt{n}} \rightsquigarrow \mathcal{N}(0,1)$$

   b) Si no conocemos σ^2, entonces:
   $$\frac{\overline{X}-\mu}{S/\sqrt{n}} \rightsquigarrow t(n-1)$$

2. Si queremos inferir sobre σ^2:

   a) Si conocemos μ_0, entonces:
   $$\frac{\sum_{i=1}^{n}(X_i-\mu_0)^2}{\sigma^2} \rightsquigarrow \chi^2(n)$$

   b) Si no conocemos μ, entonces:
   $$\frac{\sum_{i=1}^{n}(X_i-\overline{X})^2}{\sigma^2} \rightsquigarrow \chi^2(n-1)$$

1.2.2. Muestreo en dos poblaciones normales unidimensionales

En lo que sigue, sean $(X_1,\ldots,X_{n_1})$ y $(Y_1,\ldots,Y_{n_2})$ m.a.s. independientes con $X \rightsquigarrow \mathcal{N}(\mu_1,\sigma_1^2)$ y $Y \rightsquigarrow \mathcal{N}(\mu_2,\sigma_2^2)$.

Teorema 1.2.4 (Extensión del Lema de Fisher)**.** *Los vectores* $(\overline{X},\overline{Y})$, (S_1^2,S_2^2) *son independientes.*

Demostración. Usemos la función generatriz de momentos, ya que son independientes si y solo si:

$$M_{\left(\overline{X},\overline{Y},S_1^2,S_2^2\right)}(t_1,t_2,s_1,s_2) \stackrel{?}{=} M_{\left(\overline{X},\overline{Y}\right)}(t_1,t_2)M_{\left(S_1^2,S_2^2\right)}(s_1,s_2)$$

Como $\left(\overline{X},S_1^2\right) = f(X_1,\ldots,X_{n_1})$ y $\left(\overline{Y},S_2^2\right) = g(Y_1,\ldots,Y_{n_2})$, tenemos que ambos vectores son independientes, por lo que:

$$M_{\left(\overline{X},\overline{Y},S_1^2,S_2^2\right)}(t_1,t_2,s_1,s_2) = M_{\left(\overline{X},S_1^2\right)}(t_1,s_1)M_{\left(\overline{Y},S_2^2\right)}(t_2,s_2)$$

Aplicando ahora el Lema de Fisher a cada uno de los vectores, tenemos que:

$$M_{\left(\overline{X},\overline{Y},S_1^2,S_2^2\right)}(t_1,t_2,s_1,s_2) = M_{\overline{X}}(t_1)M_{S_1^2}(s_1)M_{\overline{Y}}(t_2)M_{S_2^2}(s_2)$$

Nuevamente, como $\overline{X} = f(X_1,\ldots,X_{n_1})$ y $\overline{Y} = g(Y_1,\ldots,Y_{n_2})$, y $S_1^2 = h(X_1,\ldots,X_{n_1})$ y $S_2^2 = k(Y_1,\ldots,Y_{n_2})$, tenemos que $\overline{X}$ y $\overline{Y}$ son independientes, y S_1^2 y S_2^2 son independientes. Por tanto:

$$M_{\left(\overline{X},\overline{Y},S_1^2,S_2^2\right)}(t_1,t_2,s_1,s_2) = M_{\left(\overline{X},\overline{Y}\right)}(t_1,t_2)M_{\left(S_1^2,S_2^2\right)}(s_1,s_2)$$

De aquí deducimos que los vectores $(\overline{X},\overline{Y})$ y (S_1^2,S_2^2) son independientes. □

Corolario 1.2.4.1. En dichas condiciones, tenemos que:

1. $$\frac{n_2}{n_1}\frac{\sigma_2^2}{\sigma_1^2}\frac{\sum_{i=1}^{n_1}(X_i-\mu_1)^2}{\sum_{i=1}^{n_2}(Y_i-\mu_2)^2} \rightsquigarrow F(n_1,n_2)$$

2. $\frac{S_1^2/\sigma_1^2}{S_2^2/\sigma_2^2} \rightsquigarrow F(n_1-1,n_2-1)$.
   En particular, si $\sigma_1=\sigma_2$, se tiene:
   $$\frac{S_1^2}{S_2^2} \rightsquigarrow F(n_1-1,n_2-1)$$

3. $$\frac{\overline{X}-\overline{Y}-(\mu_1-\mu_2)}{\sqrt{\frac{(n_1-1)S_1^2}{\sigma_1^2}+\frac{(n_2-1)S_2^2}{\sigma_2^2}}}\cdot\sqrt{\frac{n_1+n_2-2}{\frac{\sigma_1^2}{n_1}+\frac{\sigma_2^2}{n_2}}} \rightsquigarrow t(n_1+n_2-2).$$
   En particular, si $\sigma_1=\sigma_2$, se tiene:
   $$\frac{\overline{X}-\overline{Y}-(\mu_1-\mu_2)}{\sqrt{(n_1-1)S_1^2+(n_2-1)S_2^2}}\cdot\sqrt{\frac{n_1+n_2-2}{\frac{1}{n_1}+\frac{1}{n_2}}} \rightsquigarrow t(n_1+n_2-2)$$

Demostración. Demostramos cada una de las afirmaciones:

1. Partiremos de la construcción de la distribución F de Snedecor:
   $$\left.\begin{array}{l} X \rightsquigarrow \chi^2(m) \\ Y \rightsquigarrow \chi^2(n) \\ X \text{ e } Y \text{ independientes} \end{array}\right\} \Longrightarrow \frac{X/m}{Y/n} \rightsquigarrow F(m,n)$$

   Por otro lado, como $X \rightsquigarrow \mathcal{N}(\mu_1,\sigma_1^2)$ y $Y \rightsquigarrow \mathcal{N}(\mu_2,\sigma_2^2)$, y haciendo uso de la construcción de la distribución χ^2 a partir de variables normales, tenemos que:
   $$\frac{\sum_{i=1}^{n_1}(X_i-\mu_1)^2}{\sigma_1^2} \rightsquigarrow \chi^2(n_1) \qquad \frac{\sum_{i=1}^{n_2}(Y_i-\mu_2)^2}{\sigma_2^2} \rightsquigarrow \chi^2(n_2)$$

Como las m.a.s. son independientes y ambas distribuciones χ^2 son funciones de las m.a.s., tenemos que ambas variables son independientes. Por tanto, podemos aplicar la construcción de la distribución F de Snedecor:

$$\frac{\frac{\sum_{i=1}^{n_1}(X_i-\mu_1)^2}{n_1\sigma_1^2}}{\frac{\sum_{i=1}^{n_2}(Y_i-\mu_2)^2}{n_2\sigma_2^2}} = \frac{n_2}{n_1}\frac{\sigma_2^2}{\sigma_1^2}\frac{\sum_{i=1}^{n_1}(X_i-\mu_1)^2}{\sum_{i=1}^{n_2}(Y_i-\mu_2)^2} \rightsquigarrow F(n_1,n_2)$$

2. Seguimos buscando la construcción de F de Snedecor. Por el Colorario 1.2.3.1 sabemos que:

$$\frac{(n_1-1)S_1^2}{\sigma_1^2} \rightsquigarrow \chi^2(n_1-1) \qquad \frac{(n_2-1)S_2^2}{\sigma_2^2} \rightsquigarrow \chi^2(n_2-1)$$

Estas son independientes por ser funciones de ambas m.a.s., que son independientes. Dividimos:

$$\frac{\frac{\cancel{(n_1-1)}S_1^2}{\sigma_1^2\cancel{(n_1-1)}}}{\frac{\cancel{(n_2-1)}S_2^2}{\sigma_2^2\cancel{(n_2-1)}}} = \frac{S_1^2/\sigma_1^2}{S_2^2/\sigma_2^2} \rightsquigarrow F(n_1-1,n_2-1)$$

3. En este caso, buscamos aplicar la construcción de la distribución t de Student:

$$\left.\begin{array}{l} X \rightsquigarrow \mathcal{N}(0,1) \\ Y \rightsquigarrow \chi^2(n) \\ X \text{ e } Y \text{ independientes} \end{array}\right\} \Longrightarrow \frac{X}{\sqrt{Y/n}} \rightsquigarrow t(n)$$

Queremos probar:

$$\frac{\overline{X}-\overline{Y}-(\mu_1-\mu_2)}{\sqrt{\frac{(n_1-1)S_1^2}{\sigma_1^2}+\frac{(n_2-1)S_2^2}{\sigma_2^2}}}\sqrt{\frac{n_1+n_2-2}{\frac{\sigma_1^2}{n_1}+\frac{\sigma_2}{n_2}}} \rightsquigarrow t(n_1+n_2-2)$$

Tenemos que $\overline{X} \rightsquigarrow \mathcal{N}(\mu_1, \sigma_1^2/n_1)$ y $\overline{Y} \rightsquigarrow \mathcal{N}(\mu_2, \sigma_2^2/n_2)$. Además, tenemos que:

$$-\overline{Y} \rightsquigarrow \mathcal{N}(-\mu_2, \sigma_2^2/n_2)$$

Como $\overline{X}$ e $-\overline{Y}$ son funciones de m.a.s. independientes, tenemos que son independientes. Por tanto, por la reproductividad de la distribución normal, tenemos que:

$$\overline{X}-\overline{Y} \rightsquigarrow \mathcal{N}\left(\mu_1-\mu_2, \frac{\sigma_1^2}{n_1}+\frac{\sigma_2^2}{n_2}\right)$$

Tipificando, tenemos que:

$$\frac{\overline{X}-\overline{Y}-(\mu_1-\mu_2)}{\sqrt{\frac{\sigma_1^2}{n_1}+\frac{\sigma_2^2}{n_2}}} \rightsquigarrow \mathcal{N}(0,1)$$

Por otro lado, del Corolario 1.2.3.1, tenemos que:

$$\frac{(n_1-1)S_1^2}{\sigma_1^2} \rightsquigarrow \chi^2(n_1-1) \qquad \frac{(n_2-1)S_2^2}{\sigma_2^2} \qquad \rightsquigarrow \chi^2(n_2-1)$$

Como las m.a.s. son independientes, tenemos que estas dos variables aleatorias son independientes. Por la reproductividad de la distribución χ^2, tenemos que:

$$\frac{(n_1-1)S_1^2}{\sigma_1^2} + \frac{(n_2-1)S_2^2}{\sigma_2^2} \rightsquigarrow \chi^2(n_1+n_2-2)$$

Por la extensión del Lema de Fisher tenemos que las dos variables aleatorias que hemos calculado son independientes. Procedemos ahora a aplicar la construcción de la t de Student:

$$\frac{\dfrac{\overline{X}-\overline{Y}-(\mu_1-\mu_2)}{\sqrt{\frac{\sigma_1^2}{n_1}+\frac{\sigma_2^2}{n_2}}}}{\sqrt{\dfrac{\frac{(n_1-1)S_1^2}{\sigma_1^2}+\frac{(n_2-1)S_2^2}{\sigma_2^2}}{n_1+n_2-2}}} \rightsquigarrow t(n_1+n_2-2)$$

□

Gracias a estos resultados, podemos inferir sobre $\mu_1-\mu_2$ y σ_1^2/σ_2^2 a partir de dos m.a.s. independientes de poblaciones normales. En particular, tenemos los siguientes resultados:

1. Si queremos inferir sobre $\mu_1-\mu_2$ (comparación de medias):

   a) Si conocemos las varianzas poblacionales σ_{10}^2 y σ_{20}^2, entonces:

   $$\frac{(\overline{X}-\overline{Y})-(\mu_1-\mu_2)}{\sqrt{\frac{\sigma_{10}^2}{n_1}+\frac{\sigma_{20}^2}{n_2}}} \rightsquigarrow \mathcal{N}(0,1)$$

   b) Si las varianzas son desconocidas pero iguales ($\sigma_1^2=\sigma_2^2=\sigma^2$), entonces:

   $$\frac{(\overline{X}-\overline{Y})-(\mu_1-\mu_2)}{\sqrt{(n_1-1)S_1^2+(n_2-1)S_2^2}}\sqrt{\frac{n_1+n_2-2}{\frac{1}{n_1}+\frac{1}{n_2}}} \rightsquigarrow t(n_1+n_2-2)$$

2. Si queremos inferir sobre σ_1^2/σ_2^2 (comparación de varianzas):

   a) Si conocemos las medias μ_{10} y μ_{20}, entonces:

   $$\frac{n_1\sigma_1^2\sum_{i=1}^{n_2}(Y_i-\mu_{20})^2}{n_2\sigma_2^2\sum_{i=1}^{n_1}(X_i-\mu_{10})^2} \rightsquigarrow F(n_2,n_1)$$

   b) Si no conocemos las medias μ_1 y μ_2, entonces:

   $$\frac{\sigma_1^2S_2^2}{\sigma_2^2S_1^2} \rightsquigarrow F(n_2-1,n_1-1)$$

1.3. Suficiencia y completitud

Ejemplo. Sean X_1, X_2 variables aleatorias independientes tal que $X_1, X_2 \rightsquigarrow \mathcal{P}(\lambda)$. Probar que $X_1 + X_2$ es suficiente para λ pero $X_1 + 2X_2$ no lo es.

Demostración. Notamos por P_λ a la función masa de probabilidad, que dependerá de λ. Queremos probar que, condicionada a un valor de $X_1 + X_2$, no depende de λ. Fijado $k \in \mathbb{N}$, tenemos que:

$$P_\lambda[X_1 = x_1, X_2 = x_2 \mid X_1 + X_2 = k] = \frac{P_\lambda[X_1 = x_1, X_2 = x_2, X_1 + X_2 = k]}{P_\lambda[X_1 + X_2 = k]} = \\ = \begin{cases} \dfrac{P_\lambda[X_1 = x_1, X_2 = x_2]}{P_\lambda[X_1 + X_2 = k]} & \text{si } x_1 + x_2 = k \\ 0 & \text{si } x_1 + x_2 \neq k \end{cases}$$

Puesto que X_1 y X_2 son independientes, para $x_1 + x_2 = k$ tenemos que:

$$P_\lambda[X_1 = x_1, X_2 = x_2 \mid X_1 + X_2 = k] = \frac{P_\lambda[X_1 = x_1]P_\lambda[X_2 = x_2]}{P_\lambda[X_1 + X_2 = k]} \overset{(*)}{=} \frac{e^{-\lambda}\frac{\lambda^{x_1}}{x_1!} \cdot e^{-\lambda}\frac{\lambda^{x_2}}{x_2!}}{e^{-2\lambda}\frac{(2\lambda)^k}{k!}} = \\ = \frac{k!}{2^k x_1! x_2!}$$

donde en $(*)$ hemos usado la reproductividad de la distribución Poisson, que nos dice que $X_1 + X_2 \rightsquigarrow \mathcal{P}(2\lambda)$. Notemos que el resultado no depende de λ, por lo que $X_1 + X_2$ es suficiente para λ.

Por otro lado, queremos ver que $X_1 + 2X_2$ no es suficiente para λ. Para ello, no es necesario probarlo para todos los valores posibles, sino que basta con encontrar un contraejemplo. Tomemos $k = 2$ y la muestra $(x_1, x_2) = (0, 1)$, de forma que $x_1 + 2x_2 = 2$. Tenemos que:

$$P_\lambda[X_1 = 0, X_2 = 1 \mid X_1 + 2X_2 = 2] = \frac{P_\lambda[X_1 = 0, X_2 = 1, X_1 + 2X_2 = 2]}{P_\lambda[X_1 + 2X_2 = 2]} = \\ = \frac{P_\lambda[X_1 = 0, X_2 = 1]}{P_\lambda[X_1 + 2X_2 = 2]}$$

Por el Teorema de Cambio de Variable, tenemos que:

$$P_\lambda[X_1 + 2X_2 = 2] = \sum_{\substack{x_1, x_2 \in \mathbb{N} \\ x_1 + 2x_2 = 2}} P_\lambda[X_1 = x_1, X_2 = x_2] = \\ = P_\lambda[X_1 = 0, X_2 = 1] + P_\lambda[X_1 = 2, X_2 = 0]$$

Por tanto, tenemos que:

$$P_\lambda[X_1 = 0, X_2 = 1 \mid X_1 + 2X_2 = 2] = \frac{P_\lambda[X_1 = 0]P_\lambda[X_2 = 1]}{P_\lambda[X_1 = 0]P_\lambda[X_2 = 1] + P_\lambda[X_1 = 2]P_\lambda[X_2 = 0]} = \\ = \frac{e^{-\lambda}\frac{\lambda^0}{0!} \cdot e^{-\lambda}\frac{\lambda^1}{1!}}{e^{-\lambda}\frac{\lambda^0}{0!} \cdot e^{-\lambda}\frac{\lambda^1}{1!} + e^{-\lambda}\frac{\lambda^2}{2!} \cdot e^{-\lambda}\frac{\lambda^0}{0!}} = \frac{\lambda}{\lambda + \frac{\lambda^2}{2}} = \frac{2}{2 + \lambda}$$

Notemos que el resultado depende de λ, por lo que $X_1 + 2X_2$ no es suficiente para λ. □

Ejemplo. En n lanzamientos de una moneda, el número de caras es suficiente para la probabilidad de cara (notada p).

Demostración. Sea X la v.a. que representa el número de caras en un lanzamiento de la moneda, de forma que $X \rightsquigarrow \mathcal{B}(1,p)$. Sea $(X_1,\ldots,X_n)$ una m.a.s. de n lanzamientos de la moneda, y sea $T=\sum_{i=1}^{n} X_i$ el número total de caras en los n lanzamientos. Queremos ver que Y es suficiente para p. Para ello, fijado un valor $k\in\{0,\ldots,n\}$, tenemos que:

$$P_p[X_1=x_1,\ldots,X_n=x_n \mid T=k] = \frac{P_p[X_1=x_1,\ldots,X_n=x_n,T=k]}{P_p[T=k]} = \\ = \begin{cases} \dfrac{P_p[X_1=x_1,\ldots,X_n=x_n]}{P_p[T=k]} & \text{si } x_1+\ldots+x_n=k \\ 0 & \text{si } x_1+\ldots+x_n\neq k \end{cases}$$

Por otro lado, como $X_1,\ldots,X_n$ son independientes, en el caso de que se tenga que $x_1+\ldots+x_n=k$, tenemos que:

$$P_p[X_1=x_1,\ldots,X_n=x_n \mid T=k] = \frac{P_p[X_1=x_1]\cdots P_p[X_n=x_n]}{P_p[T=k]} \overset{(*)}{=} \\ \overset{(*)}{=} \frac{\prod_{i=1}^{n} p^{x_i}(1-p)^{1-x_i}}{\binom{n}{k}p^k(1-p)^{n-k}} = \frac{p^{\sum_{i=1}^{n} x_i}(1-p)^{\sum_{i=1}^{n} 1-x_i}}{\binom{n}{k}p^k(1-p)^{n-k}} = \\ = \frac{p^k(1-p)^{n-k}}{\binom{n}{k}p^k(1-p)^{n-k}} = \frac{1}{\binom{n}{k}}$$

donde en $(*)$ hemos usado que $T\rightsquigarrow\mathcal{B}(n,p)$. Notemos que el resultado no depende de p, por lo que T es suficiente para p. □

Ejemplo. Se supone que se ha lanzado una moneda 100 veces, y se sabe que se han obtenido 60 caras pero se han perdido los datos originales de si salió cara o cruz en cada tirada. Reconstruir la muestra.

Sea X la v.a. que representa el número de caras en un lanzamiento de la moneda, de forma que $X \rightsquigarrow \mathcal{B}(1,p)$. Sea $(X_1,\ldots,X_{100})$ una m.a.s. de 100 lanzamientos de la moneda, y sea $T=\sum_{i=1}^{100} X_i$ el número total de caras en los 100 lanzamientos, que sabemos que es suficiente para p, luego la información que nos da la muestra original se encuentra en T. Por tanto, podemos reconstruir la muestra original muestreando de la distribución condicional de $(X_1,\ldots,X_{100})$ dado que $T=60$, que en el ejemplo anterior hemos visto que es:

$$P[X_1=x_1,\ldots,X_{100}=x_{100} \mid T=60] = \begin{cases} \dfrac{1}{\binom{100}{60}} & \text{si } x_1+\ldots+x_{100}=60 \\ 0 & \text{si } x_1+\ldots+x_{100}\neq 60 \end{cases}$$

Por tanto, si $(X_1^*,\ldots,X_{100}^*)$ es una m.a.s. de la distribución condicionada al valor de $T=60$, tenemos que $(X_1^*,\ldots,X_{100}^*)$ sigue una distribución uniforme discreta

sobre el conjunto de todas las muestras posibles de 100 lanzamientos de la moneda que contienen exactamente 60 caras; es decir, $(X_1^*, \ldots, X_{100}^*) \rightsquigarrow \mathcal{U}(\mathcal{S})$, donde:

$$\mathcal{S} = \left\{(x_1, \ldots, x_{100}) \in \{0,1\}^{100} : x_1 + \ldots + x_{100} = 60\right\}$$

Teorema 1.3.5 (de Factorización de Neyman-Fisher (Discreto))**.** *Sea una v. a. $X \rightsquigarrow F \in \{F_\theta : \theta \in \Theta\}$, y sea $(X_1, \ldots, X_n)$ una m.a.s. de X. Sea f_θ la función masa de probabilidad de F_θ. Sea $T = T(X_1, \ldots, X_n)$ un estadístico. Entonces, T es suficiente para θ si y solo si existen funciones g_θ y h tales que:*

$$f_\theta(x_1, \ldots, x_n) = h(x_1, \ldots, x_n) g_\theta(T(x_1, \ldots, x_n)) \qquad \forall (x_1, \ldots, x_n) \in \mathcal{X}^n,\ \forall \theta \in \Theta$$

donde h no depende de θ.

Demostración. Demostramos cada una de las implicaciones:

$\Longrightarrow$) Supongamos que T es suficiente para θ. Entonces, para todo $(x_1, \ldots, x_n) \in \mathcal{X}^n$, $\theta \in \Theta$, y para cualquier $t \in T(\mathcal{X}^n)$ fijo, tenemos que:

$$P[X_1 = x_1, \ldots, X_n = x_n \mid T = t] = \frac{P_\theta[X_1 = x_1, \ldots, X_n = x_n, T = t]}{P_\theta[T = t]}$$

Evaluando en $t = T(x_1, \ldots, x_n)$, tenemos que:

$$P[X_1 = x_1, \ldots, X_n = x_n \mid T = t] = \frac{P_\theta[X_1 = x_1, \ldots, X_n = x_n]}{P_\theta[T = t]}$$

Despejando, tenemos que:

$$P_\theta[X_1 = x_1, \ldots, X_n = x_n] = P_\theta[T = t] P[X_1 = x_1, \ldots, X_n = x_n \mid T = t]$$

Por tanto, identificando

$$g_\theta(t) = P_\theta[T = t] \qquad h(x_1, \ldots, x_n) = P[X_1 = x_1, \ldots, X_n = x_n \mid T = T(x_1, \ldots, x_n)]$$

tenemos que:

$$P_\theta[X_1 = x_1, \ldots, X_n = x_n] = h(x_1, \ldots, x_n) g_\theta(T(x_1, \ldots, x_n))$$

$\Longleftarrow$) Supongamos que existen funciones g_θ y h tales que, para todo $(x_1, \ldots, x_n) \in \mathcal{X}^n$ y $\theta \in \Theta$, se cumple que:

$$P_\theta[X_1 = x_1, \ldots, X_n = x_n] = h(x_1, \ldots, x_n) g_\theta(T(x_1, \ldots, x_n))$$

Entonces, para cualquier $t \in T(\mathcal{X}^n)$, tenemos que:

$$P_\theta[X_1 = x_1, \ldots, X_n = x_n \mid T = t] = \frac{P_\theta[X_1 = x_1, \ldots, X_n = x_n, T = t]}{P_\theta[T = t]} =$$

$$= \begin{cases} \dfrac{P_\theta[X_1 = x_1, \ldots, X_n = x_n]}{P_\theta[T = t]} & \text{si } T(x_1, \ldots, x_n) = t \\ 0 & \text{si } T(x_1, \ldots, x_n) \neq t \end{cases}$$

En el caso de que $T(x_1, \ldots, x_n) = t$, tenemos que:

$$P_\theta[X_1 = x_1, \ldots, X_n = x_n \mid T = t] = \frac{h(x_1, \ldots, x_n) g_\theta(T(x_1, \ldots, x_n))}{\sum\limits_{\substack{(x_1,\ldots,x_n)\in\mathcal{X}^n \\ T(x_1,\ldots,x_n)=t}} P_\theta[X_1 = x_1, \ldots, X_n = x_n]} =$$

$$= \frac{h(x_1, \ldots, x_n) g_\theta(t)}{\sum\limits_{\substack{(x_1,\ldots,x_n)\in\mathcal{X}^n \\ T(x_1,\ldots,x_n)=t}} h(x_1, \ldots, x_n) g_\theta(t)} =$$

$$= \frac{h(x_1, \ldots, x_n)}{\sum\limits_{\substack{(x_1,\ldots,x_n)\in\mathcal{X}^n \\ T(x_1,\ldots,x_n)=t}} h(x_1, \ldots, x_n)}$$

Notemos que el resultado no depende de θ, por lo que T es suficiente para θ. □

Ejemplo. Sea X una v.a. tal que $X \rightsquigarrow F \in \{\mathcal{N}(\mu, \sigma^2) : \mu \in \mathbb{R}, \sigma^2 > 0\}$. Estudiar la suficiencia en los casos de:

1. σ_0^2 conocida.

   Consideramos una m.a.s. $(X_1, \ldots, X_n)$ de X. Sea $T = T(X_1, \ldots, X_n)$ un estadístico. Por el Teorema de Factorización de Neyman-Fisher, T es suficiente para μ si y solo si existen funciones g_μ y h tales que:

   $$f_\mu(x_1, \ldots, x_n) = h(x_1, \ldots, x_n) g_\mu(T(x_1, \ldots, x_n)) \qquad \forall (x_1, \ldots, x_n) \in \mathbb{R}^n, \, \forall \mu \in \mathbb{R}$$

   Tenemos que:

   $$f_\mu(x_1, \ldots, x_n) \overset{\text{i.i.d.}}{=} \prod_{i=1}^n f_\mu(x_i) = \prod_{i=1}^n \frac{1}{\sqrt{2\pi\sigma_0^2}} \exp\left(-\frac{(x_i - \mu)^2}{2\sigma_0^2}\right) =$$

   $$= \frac{1}{(2\pi\sigma_0^2)^{n/2}} \exp\left(-\frac{\sum\limits_{i=1}^n (x_i - \mu)^2}{2\sigma_0^2}\right) =$$

   $$= \frac{1}{(2\pi\sigma_0^2)^{n/2}} \exp\left(-\frac{\sum\limits_{i=1}^n (x_i^2 - 2\mu x_i + \mu^2)}{2\sigma_0^2}\right) =$$

   $$= \frac{1}{(2\pi\sigma_0^2)^{n/2}} \exp\left(-\frac{\sum\limits_{i=1}^n x_i^2 - 2\mu \sum\limits_{i=1}^n x_i + n\mu^2}{2\sigma_0^2}\right) =$$

   $$= \frac{1}{(2\pi\sigma_0^2)^{n/2}} \exp\left(-\frac{\sum\limits_{i=1}^n x_i^2}{2\sigma_0^2}\right) \exp\left(-\frac{-2\mu \sum\limits_{i=1}^n x_i + n\mu^2}{2\sigma_0^2}\right)$$

Por tanto, identificando términos, tenemos que:

$$h(x_1, \ldots, x_n) = \frac{1}{(2\pi\sigma_0^2)^{n/2}} \exp\left(-\frac{\sum_{i=1}^{n} x_i^2}{2\sigma_0^2} \right)$$
$$g_\mu(T(x_1, \ldots, x_n)) = \exp\left(-\frac{-2\mu T(x_1, \ldots, x_n) + n\mu^2}{2\sigma_0^2} \right)$$

Por tanto, por el Teorema de Factorización de Neyman-Fisher, tenemos que $T(X_1, \ldots, X_n) = \sum_{i=1}^{n} X_i$ es suficiente para μ. En particular, como $\overline{X} = 1/n \cdot T$, tenemos que $\overline{X}$ es suficiente para μ.

2. μ_0 conocida.

   En este caso, identificando términos, tenemos que:

$$h(x_1, \ldots, x_n) = 1$$
$$g_{\sigma^2}(T(x_1, \ldots, x_n)) = \frac{1}{(2\pi\sigma^2)^{n/2}} \exp\left(-\frac{T(x_1, \ldots, x_n)}{2\sigma^2} \right)$$

   Por tanto, por el Teorema de Factorización de Neyman-Fisher, tenemos que $T(X_1, \ldots, X_n) = \sum_{i=1}^{n} (X_i - \mu_0)^2$ es suficiente para σ^2. Como $\mu_0 = E[X] = E[\overline{X}]$, tenemos que $S^2 = 1/n-1 \cdot T$ es suficiente para σ^2.

3. μ y σ^2 desconocidas.

   En este caso, identificando términos, tenemos de forma directa que:

$$h(x_1, \ldots, x_n) = 1$$

   Puesto que el parámetro es bidimensional, el estadístico suficiente debe ser, al menos, bidimensional. Por tanto, podemos tomar como estadístico suficiente (T_1, T_2), donde:

$$T_1(X_1, \ldots, X_n) = \sum_{i=1}^{n} X_i \qquad T_2(X_1, \ldots, X_n) = \sum_{i=1}^{n} (X_i)^2$$

   De esta forma, tenemos que:

$$g_{\mu,\sigma^2}(T_1(x_1, \ldots, x_n), T_2(x_1, \ldots, x_n)) = \\ = \frac{1}{(2\pi\sigma^2)^{n/2}} \exp\left(-\frac{T_2(x_1, \ldots, x_n) - 2\mu T_1(x_1, \ldots, x_n) + n\mu^2}{2\sigma^2} \right)$$

   De esta forma, por el Teorema de Factorización de Neyman-Fisher, tenemos que (T_1, T_2) es suficiente para (μ, σ^2).

Ejemplo. Sea $(X_1, \ldots, X_n)$ una m.a.s de la v.a. $X \rightsquigarrow \mathcal{B}(1,p)$, con $p \in]0,1[$. Encontrar un estadístico suficiente y completo asociado a la muestra.

Buscamos un estadístico suficiente. Por el Teorema de Factorización de Neyman-Fisher, T es suficiente para p si y solo si existen funciones g_p y h tales que:

$$P_p[X_1 = x_1, \ldots, X_n = x_n] = h(x_1, \ldots, x_n) g_p(T(x_1, \ldots, x_n)) \qquad \forall (x_1, \ldots, x_n) \in \{0,1\}^n,\ \forall p \in]0,1[$$

Tenemos que:

$$P_p[X_1 = x_1, \ldots, X_n = x_n] \overset{\text{i.i.d.}}{=} \prod_{i=1}^n P_p[X_i = x_i] = \prod_{i=1}^n p^{x_i}(1-p)^{1-x_i} = p^{\sum_{i=1}^n x_i}(1-p)^{\sum_{i=1}^n 1-x_i} =$$
$$= p^{\sum_{i=1}^n x_i}(1-p)^{n-\sum_{i=1}^n x_i}$$

Por tanto, identificando términos, tenemos que:

$$h(x_1, \ldots, x_n) = 1$$
$$g_p(T(x_1, \ldots, x_n)) = p^{T(x_1,\ldots,x_n)}(1-p)^{n-T(x_1,\ldots,x_n)}$$

Por tanto, por el Teorema de Factorización de Neyman-Fisher, tenemos que $T(X_1, \ldots, X_n) = \sum_{i=1}^n X_i$ es suficiente para p. Veamos ahora si T es completo. Sea g una función medible tal que $E_p[g(T)] = 0$ para todo $p \in]0,1[$. Probemos que $P_p[g(T) = 0] = 1$ para todo $p \in]0,1[$. Por reproductividad, se tiene $T \rightsquigarrow \mathcal{B}(n,p)$. Por tanto, para todo $p \in]0,1[$, tenemos que:

$$E_p[g(T)] = \sum_{k=0}^n g(k) P_p[T = k] = \sum_{k=0}^n g(k) \binom{n}{k} p^k (1-p)^{n-k} =$$
$$= (1-p)^n \sum_{k=0}^n g(k) \binom{n}{k} \left(\frac{p}{1-p}\right)^k = 0$$

Sea $q = p/1-p$. Entonces, para todo $q \in]0, +\infty[$, tenemos que:

$$\sum_{k=0}^n g(k) \binom{n}{k} q^k = 0$$

Notemos que el polinomio $\sum_{k=0}^n g(k)\binom{n}{k} q^k$ tiene grado a lo sumo n. Por tanto, como tiene infinitas raíces, debe ser el polinomio nulo. Por tanto, tenemos que:

$$g(k)\binom{n}{k} = 0 \qquad \forall k \in \{0, \ldots, n\}$$

Por tanto, tenemos que $g(k) = 0$ para todo $k \in \{0, \ldots, n\}$. Por tanto, hemos visto que:

$$\{0, \ldots, n\} \subset \{k \in \mathbb{N} : g(k) = 0\}$$

Por tanto:

$$1 = P_p[T \in \{0, \ldots, n\}] \leqslant P_p[g(T) = 0] \leqslant 1$$

Por tanto, $P_p[g(T) = 0] = 1$ para todo $p \in]0,1[$; luego T es completo para p.

Ejemplo. Sea $(X_1, \ldots, X_n)$ una m.a.s. de la v.a. $X \rightsquigarrow \mathcal{U}(0, \theta)$, con $\theta > 0$. Encontrar un estadístico suficiente y completo asociado a la muestra.

Buscamos un estadístico suficiente. Por el Teorema de Factorización de Neyman-Fisher, T es suficiente para θ si y solo si existen funciones g_θ y h tales que:

$$f_\theta(x_1, \ldots, x_n) = h(x_1, \ldots, x_n) g_\theta(T(x_1, \ldots, x_n)) \qquad \forall (x_1, \ldots, x_n) \in \mathbb{R}^n, \ \forall \theta > 0$$

Tenemos que:

$$f_\theta(x_1, \ldots, x_n) \overset{\text{i.i.d.}}{=} \prod_{i=1}^n f_\theta(x_i) = \prod_{i=1}^n \frac{1}{\theta} = \frac{1}{\theta^n} \qquad \text{si } (x_1, \ldots, x_n) \in [0, \theta]^n$$

Notemos que la función de densidad no depende de $(x_1, \ldots, x_n)$, salvo por la condición de que $(x_1, \ldots, x_n) \in [0, \theta]^n$. Por tanto, hemos de emplear la función indicadora para expresar la dependencia de $(x_1, \ldots, x_n)$. Notemos que:

$$f_\theta(x_1, \ldots, x_n) = \frac{1}{\theta^n} \, \mathrm{I}_{[0,\infty]}(x_{(1)}) \, \mathrm{I}_{]-\infty,0]}(x_{(n)} - \theta) \qquad \forall (x_1, \ldots, x_n) \in \mathbb{R}^n, \ \forall \theta > 0$$

Por tanto, identificando términos, tenemos que:

$$h(x_1, \ldots, x_n) = \mathrm{I}_{[0,\infty]}(x_{(1)})$$
$$g_\theta(T(x_1, \ldots, x_n)) = \frac{1}{\theta^n} \, \mathrm{I}_{]-\infty,0]}(T(x_1, \ldots, x_n) - \theta)$$

Por tanto, por el Teorema de Factorización de Neyman-Fisher, tenemos que $T(X_1, \ldots, X_n) = X_{(n)}$ es suficiente para θ. Para estudiar su completitud, hemos de calcular en primer lugar la función de densidad de T. Tenemos que:

$$F_{X_{(n)}}(x) = P[X_{(n)} \leqslant x] = P[X_1 \leqslant x, \ldots, X_n \leqslant x] = \prod_{i=1}^n P[X_i \leqslant x] = \prod_{i=1}^n F_X(x) = F_X(x)^n$$

Por tanto, tenemos que:

$$f_{X_{(n)}}(x) = \frac{d}{dx} F_{X_{(n)}}(x) = n F_X(x)^{n-1} f_X(x) = n \left(\frac{x}{\theta}\right)^{n-1} \frac{1}{\theta} = \frac{n x^{n-1}}{\theta^n} \qquad \text{si } x \in [0, \theta]$$

Sea g una función medible tal que $E_\theta[g(T)] = 0$ para todo $\theta > 0$. Probemos que $P_\theta[g(T) = 0] = 1$ para todo $\theta > 0$. Tenemos que:

$$E_\theta[g(T)] = \int_0^\theta g(x) f_{X_{(n)}}(x) dx = \int_0^\theta g(x) \frac{n x^{n-1}}{\theta^n} dx = \frac{n}{\theta^n} \int_0^\theta g(x) x^{n-1} dx = 0 \qquad \forall \theta > 0$$

Por tanto, como el primer término no se puede anular, se tiene:

$$\int_0^\theta g(x) x^{n-1} dx = 0 \qquad \forall \theta > 0$$

Notemos que la función $g(x)x^{n-1}$ es continua, y por tanto integrable. Derivando con respecto a θ, tenemos que:

$$g(\theta)\theta^{n-1} = 0 \qquad \forall \theta > 0$$

Esto implica que $g(\theta) = 0$ para todo $\theta > 0$, luego:

$$\mathbb{R}^+ \subset \{x \in \mathbb{R} : g(x) = 0\}$$

Por tanto:

$$1 = P_\theta[T \in \mathbb{R}^+] \leqslant P_\theta[g(T) = 0] \leqslant 1$$

Por tanto, $P_\theta[g(T) = 0] = 1$ para todo $\theta > 0$; luego T es completo para θ.

Ejemplo. Demostrar que las siguientes familias de distribuciones son una familia exponencial uniparamétrica:

1. $\mathcal{P}(\lambda)$, con $\lambda > 0$

   En primer lugar, tenemos que $\lambda \in \Theta = \mathbb{R}^+$. Además, tenemos que:

   $$\chi = \mathbb{N} \qquad \forall \lambda \in \Theta$$

   Por último, para cada $\lambda \in \Theta$ y $x \in \chi$, tenemos que:

   $$P_\lambda[X = x] = e^{-\lambda}\frac{\lambda^x}{x!} = \exp\left(-\lambda + \ln\left(\frac{\lambda^x}{x!}\right)\right) = \exp\left(\ln(\lambda)x - \lambda - \ln(x!)\right)$$

   Por tanto, identificando términos, tenemos que:

   $$\begin{aligned} Q(\lambda) &= \ln(\lambda) \\ T(x) &= x \\ D(\lambda) &= -\lambda \\ S(x) &= -\ln(x!) \end{aligned}$$

   Por tanto, $\mathcal{P}(\lambda)$ es una familia exponencial uniparamétrica.

2. $\mathcal{B}(k_0, p)$, con $p \in]0,1[$ y $k_0 \in \mathbb{N}$ fijo.

   En primer lugar, tenemos que $p \in \Theta =]0,1[$. Además, tenemos que:

   $$\chi = \{0, 1, \ldots, k_0\} \qquad \forall p \in \Theta$$

   Por último, tenemos que:

   $$\begin{aligned} P_p[X = x] = \binom{k_0}{x} p^x (1-p)^{k_0 - x} &= \exp\left(\ln\left(\binom{k_0}{x} p^x (1-p)^{k_0-x}\right)\right) = \\ &= \exp\left(\ln\left(\binom{k_0}{x}\right) + x\ln(p) + (k_0 - x)\ln(1-p)\right) = \\ &= \exp\left(\ln\left(\binom{k_0}{x}\right) + x\ln\left(\frac{p}{1-p}\right) + k_0\ln(1-p)\right) \qquad \forall x \in \chi,\ \forall p \in \Theta \end{aligned}$$

   Por tanto, identificando términos, tenemos que:

   $$\begin{aligned} Q(p) &= \ln\left(\frac{p}{1-p}\right) \\ T(x) &= x \\ D(p) &= k_0 \ln(1-p) \\ S(x) &= \ln\left(\binom{k_0}{x}\right) \end{aligned}$$

Ejemplo. La $\mathcal{N}(\mu, \sigma^2)$ es una familia exponencial uniparamétrica en cada parámetro y bi-paramétrica en los dos parámetros.

Veamos primero que $\mathcal{N}(\mu, \sigma^2)$ es una familia exponencial uniparamétrica en μ para σ^2 conocida. En este caso, tenemos que:

$$\begin{aligned}
\Theta &= \mathbb{R} \\
\chi &= \mathbb{R} \\
f_\mu(x) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(x-\mu)^2}{2\sigma^2}\right) &= \exp\left(-\frac{(x-\mu)^2}{2\sigma^2} - \frac{1}{2}\ln(2\pi\sigma^2)\right) = \\
= \exp\left(-\frac{x^2 - 2\mu x + \mu^2}{2\sigma^2} - \frac{1}{2}\ln(2\pi\sigma^2)\right) &= \exp\left(\frac{\mu x}{\sigma^2} - \frac{\mu^2}{2\sigma^2} - \frac{x^2}{2\sigma^2} - \frac{1}{2}\ln(2\pi\sigma^2)\right)
\end{aligned}$$

Por tanto, identificando términos, tenemos que:

$$\begin{aligned}
Q(\mu) &= \frac{\mu}{\sigma^2} \\
T(x) &= x \\
D(\mu) &= -\frac{\mu^2}{2\sigma^2} \\
S(x) &= -\frac{x^2}{2\sigma^2} - \frac{1}{2}\ln(2\pi\sigma^2)
\end{aligned}$$

Vemos por tanto que $\mathcal{N}(\mu, \sigma^2)$ es una familia exponencial uniparamétrica en μ para σ^2 conocida. Veamos ahora que $\mathcal{N}(\mu, \sigma^2)$ es una familia exponencial uniparamétrica en σ^2 para μ conocida. En este caso, tenemos que:

$$\begin{aligned}
\Theta &= \mathbb{R}^+ \\
\chi &= \mathbb{R} \\
f_{\sigma^2}(x) &= \exp\left(-\frac{(x-\mu)^2}{2\sigma^2} - \frac{1}{2}\ln(2\pi\sigma^2)\right)
\end{aligned}$$

Por tanto, identificando términos, tenemos que:

$$\begin{aligned}
Q(\sigma^2) &= -\frac{1}{2\sigma^2} \\
T(x) &= (x-\mu)^2 \\
D(\sigma^2) &= -\frac{1}{2}\ln(2\pi\sigma^2) \\
S(x) &= 0
\end{aligned}$$

Por tanto, $\mathcal{N}(\mu, \sigma^2)$ es una familia exponencial uniparamétrica en σ^2 para μ conocida. Veamos por último que $\mathcal{N}(\mu, \sigma^2)$ es una familia exponencial bi-paramétrica en (μ, σ^2). En este caso, tenemos que:

$$\begin{aligned}
\Theta &= \mathbb{R} \times \mathbb{R}^+ \\
\chi &= \mathbb{R} \\
f_{\mu,\sigma^2}(x) &= \exp\left(\frac{\mu x}{\sigma^2} - \frac{\mu^2}{2\sigma^2} - \frac{x^2}{2\sigma^2} - \frac{1}{2}\ln(2\pi\sigma^2)\right)
\end{aligned}$$

Por tanto, identificando términos, tenemos que:

$$\begin{aligned} Q_1(\mu,\sigma^2) &= \frac{\mu}{\sigma^2} \\ Q_2(\mu,\sigma^2) &= -\frac{1}{2\sigma^2} \\ T_1(x) &= x \\ T_2(x) &= x^2 \\ D(\mu,\sigma^2) &= -\frac{\mu^2}{2\sigma^2} - \frac{1}{2}\ln(2\pi\sigma^2) \\ S(x) &= 0 \end{aligned}$$

Por tanto, $\mathcal{N}(\mu,\sigma^2)$ es una familia exponencial bi-paramétrica en (μ,σ^2).

Teorema 1.3.6. *Si se tiene una v.a. $X \rightsquigarrow \{F_\theta, \theta \in \Theta\}$ con familia de funciones asociadas, $\{f_\theta(x), \theta \in \Theta\}$, siendo f.d.d. o f.m.p. según el caso, donde la familia de distribuciones es exponencial k-paramétrica, entonces la familia de distribuciones asociadas a $(X_1,\ldots,X_n)$ (que es una m.a.s. de X) es también exponencial k-paramétrica:*

$$f_\theta^n(x_1,\ldots,x_n) = \exp\left[\sum_{h=1}^{k} Q_h(\theta)\sum_{i=1}^{n} T_h(x_i) + \sum_{i=1}^{n} S(x_i) + nD(\theta)\right], \qquad (x_1,\ldots,x_n) \in \chi^n$$

y se tiene:

1. *El estadístico $\left(\sum_{i=1}^{n} T_1(X_i),\ldots,\sum_{i=1}^{n} T_k(X_i)\right)$ es suficiente para θ.*
2. *Si $k \leqslant n$ y el conjunto imagen de la función $Q(\theta) = (Q_1(\theta),\ldots,Q_k(\theta))$ contiene a un abierto de $\mathbb{R}^k$, el estadístico $\left(\sum_{i=1}^{n} T_1(X_i),\ldots,\sum_{i=1}^{n} T_k(X_i)\right)$ es también completo.*

Demostración. Comprobemos que $(X_1,\ldots,X_n)$ es una familia exponencial k-paramétrica. Por ser la familia de distribuciones asociadas a X una familia exponencial k-paramétrica, tenemos que Θ es un intervalo de $\mathbb{R}^k$. Además, tenemos que el espacio muestral de $(X_1,\ldots,X_n)$ es independiente de θ, y es χ^n. Por último, tenemos que:

$$\begin{aligned} f_\theta^n(x_1,\ldots,x_n) = \prod_{i=1}^{n} f_\theta(x_i) &= \prod_{i=1}^{n} \exp\left[\sum_{h=1}^{k} Q_h(\theta)T_h(x_i) + S(x_i) + D(\theta)\right] = \\ &= \exp\left[\sum_{i=1}^{n}\sum_{h=1}^{k} Q_h(\theta)T_h(x_i) + \sum_{i=1}^{n} S(x_i) + \sum_{i=1}^{n} D(\theta)\right] = \\ &= \exp\left[\sum_{h=1}^{k} Q_h(\theta)\sum_{i=1}^{n} T_h(x_i) + \sum_{i=1}^{n} S(x_i) + nD(\theta)\right] \end{aligned}$$

Por tanto, identificando términos, tenemos que:

$$\begin{aligned} Q_h^n(\theta) &= Q_h(\theta) \\ T_h^n(x_1,\dots,x_n) &= \sum_{i=1}^n T_h(x_i) \\ S^n(x_1,\dots,x_n) &= \sum_{i=1}^n S(x_i) \\ D^n(\theta) &= nD(\theta) \end{aligned}$$

Por tanto, $(X_1,\dots,X_n)$ es una familia exponencial k-paramétrica. Veamos ahora que $\left(\sum_{i=1}^n T_1(X_i),\dots,\sum_{i=1}^n T_k(X_i)\right)$ es suficiente para θ.

$$\begin{aligned} f_\theta^n(x_1,\dots,x_n) &= \exp\left[\sum_{h=1}^k Q_h(\theta)\sum_{i=1}^n T_h(x_i) + \sum_{i=1}^n S(x_i) + nD(\theta)\right] = \\ &= \underbrace{\exp\left[\sum_{i=1}^n S(x_i)\right]}_{h(x_1,\dots,x_n)} \underbrace{\exp\left[\sum_{h=1}^k Q_h(\theta)\sum_{i=1}^n T_h(x_i) + nD(\theta)\right]}_{g_\theta\left(\sum_{i=1}^n T_1(x_i),\dots,\sum_{i=1}^n T_k(x_i)\right)} \end{aligned}$$

Por el Teorema de Factorización de Neyman-Fisher, tenemos que el estadístico $\left(\sum_{i=1}^n T_1(X_i),\dots,\sum_{i=1}^n T_k(X_i)\right)$ es suficiente para θ. Respecto a la complitud, al ser más complicado, no se incluye la demostración. □

Ejemplo. Sea X una v.a. con distribución $\mathcal{N}(\mu,\sigma^2)$ con $\mu\in\mathbb{R}$ y $\sigma^2>0$. Buscar un estadístico suficiente y completo basado en una muestra de tamaño n.

Como hemos visto en el ejemplo anterior, $\mathcal{N}(\mu,\sigma^2)$ es una familia exponencial bi-paramétrica en (μ,σ^2). Por tanto, por el Teorema anterior, tenemos que la familia de distribuciones asociadas a $(X_1,\dots,X_n)$ es también una familia exponencial bi-paramétrica. Por tanto, el estadístico:

$$\left(\sum_{i=1}^n X_i, \sum_{i=1}^n X_i^2\right)$$

es suficiente para (μ,σ^2). Además, veamos que la imagen de $Q(\mu,\sigma^2)$ contiene un abierto de $\mathbb{R}^2$. Consideremos la aplicación:

$$\begin{aligned} Q:\ \Theta=\mathbb{R}\times\mathbb{R}^+ &\longrightarrow \mathbb{R}^2 \\ (\mu,\sigma^2) &\longmapsto \left(\frac{\mu}{\sigma^2}, -\frac{1}{2\sigma^2}\right) \end{aligned}$$

Observemos que al variar $\sigma^2\in\mathbb{R}^+$, la segunda componente $Q_2 = {}^{-1}\!/_{2\sigma^2}$ recorre todo el intervalo $\mathbb{R}^-$. Para cualquier valor fijado de $Q_2\in\mathbb{R}^-$, al variar $\mu\in\mathbb{R}$, la

primera componente $Q_1 = -2\mu Q_2$ recorre todo $\mathbb{R}$. Por consiguiente, el conjunto imagen de Q es:

$$Q(\Theta) = \mathbb{R} \times \mathbb{R}^-$$

que es un abierto de $\mathbb{R}^2$. Por tanto, por el Teorema anterior, si $n \geqslant 2$, el estadístico:

$$\left(\sum_{i=1}^{n} X_i, \sum_{i=1}^{n} X_i^2 \right)$$

es también completo para (μ, σ^2).

1.4. Estimación puntual. Insesgadez y mínima varianza

Ejemplo. Sea $(X_1, \ldots, X_n)$ una muestra aleatoria simple de una variable aleatoria X con distribución $\mathcal{P}(\lambda)$, $\lambda > 0$. La media muestral $\overline{X}$ es un estimador de λ. Además, cualquier función medible de la muestra que sea independiente del parámetro λ y tome valores positivos es un estimador del parámetro.

$$\overline{X} = \frac{1}{n}\sum_{i=1}^{n} X_i \geqslant 0$$

donde la positividad de $\overline{X}$ se debe a que $X_i \geqslant 0$ para todo $i = 1, \ldots, n$.

Por lo tanto, $\overline{X}$ es un estimador de λ.

Ejemplo. Sea $(X_1, \ldots, X_n)$ una muestra aleatoria simple de una variable aleatoria X con distribución $\mathcal{B}(1, p)$, $p \in]0, 1[$. La media muestral $\overline{X}$ es un estimador de p. Además, cualquier función medible de la muestra que sea independiente del parámetro p y tome valores en el intervalo $(0, 1)$ es un estimador del parámetro.

$$\overline{X} = \frac{1}{n}\sum_{i=1}^{n} X_i \in [0, 1]$$

donde la pertenencia al intervalo $[0, 1]$ se debe a que $X_i \in \{0, 1\}$ para todo valor $i = 1, \ldots, n$. Estrictamente hablando, como p no puede tomar los valores 0 y 1, entonces $\overline{X}$ no podría tomar esos valores. No obstante, estos valores son muy particulares, puesto que implicarían que todos los X_i toman el mismo valor, lo que podría hacernos pensar que no se trata de un experimento aleatorio. Por tanto, en estos casos, que también contenga a los extremos del intervalo no es un problema.

Por lo tanto, $\overline{X}$ es un estimador de p.

Proposición 1.4.7. Sea X una v.a. con función de distribución en una familia de distribuciones paramétricas, $F \in \{F_\theta : \theta \in \Theta\}$ y $(X_1, \ldots, X_n)$ una m.a.s. de X. Sea $T = T(X_1, \ldots, X_n)$ un estimador de θ. El error cuadrático medio (ECM) de T se define como:

$$ECM_T(\theta) := E_\theta\left[(T - \theta)^2\right]$$

El ECM puede descomponerse en términos de la varianza y una función denominada sesgo:

$$ECM_T(\theta) = Var_\theta[T] + B_T^2(\theta) \qquad \text{donde } B_T(\theta) := E_\theta[T] - \theta$$

Demostración. Tenemos que:

$$\begin{aligned}
ECM_T(\theta) &= E_\theta\left[(T - \theta)^2\right] = E_\theta\left[(T - E_\theta[T] + E_\theta[T] - \theta)^2\right] \\
&= E_\theta\left[(T - E_\theta[T])^2 + 2(T - E_\theta[T])(E_\theta[T] - \theta) + (E_\theta[T] - \theta)^2\right] \\
&= Var_\theta[T] + 2(E_\theta[T] - \theta)E_\theta[T - E_\theta[T]] + (E_\theta[T] - \theta)^2 \\
&= Var_\theta[T] + 2(E_\theta[T] - \theta)\cancel{(E_\theta[T] - E_\theta[T])} + (E_\theta[T] - \theta)^2 \\
&= Var_\theta[T] + (E_\theta[T] - \theta)^2 \\
&= Var_\theta[T] + B_T^2(\theta)
\end{aligned}$$

□

Ejemplo. Sea $(X_1, \ldots, X_n)$ una muestra aleatoria simple de alguna población. Probar que, en general, la cuasidesviación típica no es un estimador insesgado de la desviación típica poblacional.

Demostración. Sea $(X_1, \ldots, X_n)$ una muestra aleatoria simple de $X \rightsquigarrow \mathcal{N}(\mu, \sigma^2)$, $\mu \in \mathbb{R}$ y $\sigma^2 > 0$. Sabemos que $E[S^2] = \sigma^2$. Queremos ver si $E[S] = \sigma$. Sabemos que:

$$Y = \frac{(n-1)S^2}{\sigma^2} \sim \chi^2(n-1)$$

Por tanto:

$$\begin{aligned} E\left[\sqrt{Y}\right] &= \int_0^\infty \sqrt{y} f_Y(y) dy = \int_0^\infty \sqrt{y} \frac{1}{2^{(n-1)/2}\Gamma((n-1)/2)} y^{(n-3)/2} e^{-y/2} dy = \\ &= \frac{1}{2^{(n-1)/2}\Gamma((n-1)/2)} \int_0^\infty y^{n/2-1} e^{-y/2} dy \overset{(*)}{=} \\ &\overset{(*)}{=} \frac{1}{2^{(n-1)/2}\Gamma((n-1)/2)} \cdot \frac{\Gamma(n/2)}{(1/2)^{n/2}} \end{aligned}$$

donde en $(*)$ hemos aplicado que la función de densidad de la distribución $\chi^2(n)$ integra 1. Por tanto:

$$E[\sqrt{Y}] = E\left[\sqrt{\frac{(n-1)S^2}{\sigma^2}}\right] = \frac{\sqrt{n-1}E[S]}{\sigma}$$

Por tanto:

$$E[S] = \frac{\sigma}{\sqrt{n-1}} E[\sqrt{Y}] = \frac{\sigma}{\sqrt{n-1}} \cdot \frac{1}{2^{(n-1)/2}\Gamma((n-1)/2)} \cdot \frac{\Gamma(n/2)}{(1/2)^{n/2}} \neq \sigma$$

Por tanto, S no es un estimador insesgado de σ. □

Ejemplo. Sea $(X_1, \ldots, X_n)$ una m.a.s. de una distribución binomial $\mathcal{B}(1, p)$. Probar que

$$\frac{T^2 - T}{n^2 - n}$$

con $T = \sum_{i=1}^{n} X_i$ es un estimador insesgado para la función paramétrica $g(p) = p^2$. Probar, además, que para $n = 1$ no existe un estimador insesgado de p^2.

Demostración. Es directo ver que se trata de un estimador. Veamos que es insesgado, para lo que calculamos su esperanza:

$$\begin{aligned} E\left[\frac{T^2 - T}{n^2 - n}\right] &= \frac{1}{n^2 - n} E[T^2 - T] = \frac{1}{n^2 - n}\left(E[T^2] - E[T]\right) \overset{(*)}{=} \\ &\overset{(*)}{=} \frac{1}{n^2 - n}\left(Var[T] + E[T]^2 - E[T]\right) = \frac{1}{n^2 - n}\left(np(1-p) + (np)^2 - np\right) = \\ &= \frac{1}{n^2 - n}\left(n^2p^2 - np^2\right) = p^2 \end{aligned}$$

donde en $(*)$ hemos aplicado la identidad $Var[T] = E[T^2] - E[T]^2$. Por tanto, $\dfrac{T^2 - T}{n^2 - n}$ es un estimador insesgado de p^2. Veamos ahora que para el valo de $n = 1$ no existe un estimador insesgado de p^2. Supongamos que existe un estimador insesgado $T(X)$ de p^2 basado en una muestra de tamaño 1. Entonces, por definición de insesgadez, se cumple que:

$$p^2 = E_p[T(X)] = T(0)(1-p) + T(1)p \Longrightarrow p^2 = T(0) - T(0)p + T(1)p$$

La expresión de la derecha es una ecuación polinómica de primer grado en p, mientras que p^2 es un polinomio de segundo grado en p. Llegamos por tanto a una contradicción, ya que no puede haber un polinomio de segundo grado igual a un polinomio de primer grado. Por tanto, no existe un estimador insesgado de p^2 basado en una muestra de tamaño 1. □

Ejemplo. Sea X una v.a. con distribución $\mathcal{P}(\lambda)$, ¿existe algún estimador insesgado de $1/\lambda$ basado en una muestra de tamaño 1?

Supongamos que existe un estimador insesgado $T(X)$ de $1/\lambda$ basado en una muestra de tamaño 1. Entonces, por definición de insesgadez, se cumple que:

$$\frac{1}{\lambda} = E_\lambda[T(X)] = \sum_{x=0}^{\infty} T(x)\frac{e^{-\lambda}\lambda^x}{x!} \Longrightarrow e^\lambda = \sum_{x=0}^{\infty} T(x)\frac{\lambda^{x+1}}{x!}$$

Empleando la serie de Taylor de e^λ, obtenemos:

$$\sum_{x=0}^{\infty} \frac{\lambda^x}{x!} = \sum_{x=0}^{\infty} T(x)\frac{\lambda^{x+1}}{x!}$$

La primera sumatoria tiene un término independiente de λ, mientras que la segunda sumatoria no. Como ha de ser cierta la igualdad para todo $\lambda > 0$, se llega a una contradicción. Por tanto, no existe un estimador insesgado de $1/\lambda$ basado en una muestra de tamaño 1.

Teorema 1.4.8 (Rao-Blackwell)**.** *Sea X una v.a. con función de distribución en una familia de distribuciones paramétricas, $F \in \{F_\theta : \theta \in \Theta\}$, y $(X_1, \ldots, X_n)$ una m.a.s. de X. Si $T(X_1, \ldots, X_n)$ es un estadístico suficiente para la familia $\{F_\theta : \theta \in \Theta\}$ y $S(X_1, \ldots, X_n)$ es un estimador insesgado de $g(\theta)$ con momento de segundo orden finito, entonces:*

1. *$E[S(X_1, \ldots, X_n) \mid T(X_1, \ldots, X_n)]$ es un estimador insesgado de $g(\theta)$ y tiene momento de segundo orden finito.*
2. *$Var_\theta\left[E[S(X_1, \ldots, X_n) \mid T(X_1, \ldots, X_n)]\right] \leqslant Var_\theta[S(X_1, \ldots, X_n)]$, $\forall \theta \in \Theta$.*

Demostración. Demostramos cada una de las afirmaciones por separado:

1. En primer lugar, veamos que $E[S(X_1, \ldots, X_n) \mid T(X_1, \ldots, X_n)]$ es un estadístico. Es claro que $E_\theta[S(X_1, \ldots, X_n) \mid T(X_1, \ldots, X_n)]$ es un función de la m.a.s., pero hemos de ver que no depende del parámetro θ:

$$E_\theta[S(X_1,\dots,X_n) \mid T(X_1,\dots,X_n)] = \\ = \int_{\chi^n} S(x_1,\dots,x_n) f_{X_1,\dots,X_n|T}(x_1,\dots,x_n)\, dx_1 \dots dx_n$$

Como T es un estadístico suficiente, la función de densidad condicionada $f_{X_1,\dots,X_n|T}(x_1,\dots,x_n)$ no depende de θ. Por tanto, $E[S(X_1,\dots,X_n) \mid T(X_1,\dots,X_n)]$ no depende del parámetro θ, luego es un estadístico. Además, como $S(X_1,\dots,X_n)$ es un estimador de $g(\theta)$, toma valores en el rango de $g(\theta)$, luego al tomar la esperanza condicionada también tomará valores en el rango de $g(\theta)$, luego es un estimador de $g(\theta)$. Además, como S es un estimador insesgado de $g(\theta)$, entonces $E_\theta[S(X_1,\dots,X_n)] = g(\theta)$, y por la propiedad de la esperanza condicionada, tenemos que:

$$E_\theta[E[S(X_1,\dots,X_n) \mid T(X_1,\dots,X_n)]] = E_\theta[S(X_1,\dots,X_n)] = g(\theta)$$

Por tanto, $E[S(X_1,\dots,X_n) \mid T(X_1,\dots,X_n)]$ es un estimador insesgado de $g(\theta)$.

Veamos ahora que tiene momento de segundo orden finito. Como S tiene momento de segundo orden finito, entonces su momento de segundo orden condicionado también es finito, luego:

$$Var_\theta[S(X_1,\dots,X_n) \mid T(X_1,\dots,X_n)] = \\ = E_\theta[S^2(X_1,\dots,X_n) \mid T(X_1,\dots,X_n)] - E_\theta[S(X_1,\dots,X_n) \mid T(X_1,\dots,X_n)]^2 \geqslant 0$$

Por tanto:

$$E_\theta[S^2(X_1,\dots,X_n) \mid T(X_1,\dots,X_n)] \geqslant E_\theta[S(X_1,\dots,X_n) \mid T(X_1,\dots,X_n)]^2$$

Tomando esperanza:

$$E_\theta[E_\theta[S(X_1,\dots,X_n) \mid T(X_1,\dots,X_n)]^2] \leqslant \\ \leqslant E_\theta[E_\theta[S^2(X_1,\dots,X_n) \mid T(X_1,\dots,X_n)]] = E_\theta[S^2(X_1,\dots,X_n)] < \infty$$

2. Empleamos la descomposición de la varianza:

$$Var_\theta[S(X_1,\dots,X_n)] = \\ = E_\theta[Var_\theta[S(X_1,\dots,X_n) \mid T(X_1,\dots,X_n)]] + Var_\theta[E[S(X_1,\dots,X_n) \mid T(X_1,\dots,X_n)]]$$

Como $E_\theta[Var_\theta[S(X_1,\dots,X_n) \mid T(X_1,\dots,X_n)]] \geqslant 0$, se sigue que:

$$Var_\theta[S(X_1,\dots,X_n)] \geqslant Var_\theta[E[S(X_1,\dots,X_n) \mid T(X_1,\dots,X_n)]]$$

□

Teorema 1.4.9 (Lehmann-Scheffé)**.** *Sea $T(X_1,\dots,X_n)$ un estadístico suficiente y completo para la familia de distribuciones consideradas, $\{F_\theta : \theta \in \Theta\}$. Si $g(\theta)$ admite un estimador insesgado con momento de segundo orden finito, $S(X_1,\dots,X_n)$, entonces existe el UMVUE de $g(\theta)$, que viene dado por:*

$$E[S(X_1,\dots,X_n) \mid T(X_1,\dots,X_n)]$$

Demostración. Sea $S(X_1, \ldots, X_n)$ el estimador insesgado de $g(\theta)$ con momento de segundo orden finito proporcionado por el enunciado, y supongamos otro estimador insesgado $S_2(X_1, \ldots, X_n)$ de $g(\theta)$ con momento de segundo orden finito. Por el teorema de Rao-Blackwell aplicado a S y S_2, tenemos que:

$$U(T(X_1, \ldots, X_n)) = E[S(X_1, \ldots, X_n) \mid T(X_1, \ldots, X_n)]$$
$$U_2(T(X_1, \ldots, X_n)) = E[S_2(X_1, \ldots, X_n) \mid T(X_1, \ldots, X_n)]$$

son estimadores insesgados de $g(\theta)$ con momento de segundo orden finito. Además, por el teorema de Rao-Blackwell, se cumple que:

$$Var_\theta[U] \leqslant Var_\theta[S]$$
$$Var_\theta[U_2] \leqslant Var_\theta[S_2]$$

Definimos ahora $h(T(X_1, \ldots, X_n)) = U(T(X_1, \ldots, X_n)) - U_2(T(X_1, \ldots, X_n))$. Como U y U_2 son insesgados de $g(\theta)$, se cumple que:

$$E_\theta[h(T(X_1, \ldots, X_n))] = E_\theta[U(T(X_1, \ldots, X_n))] - E_\theta[U_2(T(X_1, \ldots, X_n))] = g(\theta) - g(\theta) = 0$$

Como T es completo para θ, se sigue que:

$$P_\theta[h(T(X_1, \ldots, X_n)) = 0] = 1 \qquad \forall \theta \in \Theta$$

Por tanto:

$$P[U(T(X_1, \ldots, X_n)) = U_2(T(X_1, \ldots, X_n))] = 1 \qquad \forall \theta \in \Theta$$

De esta manera, se deduce que $Var_\theta[U] = Var_\theta[U_2]$, luego:

$$Var_\theta[U] \leqslant Var_\theta[S_2] \qquad \forall \theta \in \Theta$$

Por tanto, $U(T(X_1, \ldots, X_n))$ es el UMVUE de $g(\theta)$. □

Ejemplo. Sea $(X_1, \ldots, X_n)$ una m.a.s. con distribución $\mathcal{B}(1, p)$, $p \in [0, 1]$. Encontrar el UMVUE para p.

En el ejemplo de la página 25, vimos que:

$$T = \sum_{i=1}^{n} X_i$$

es un estadístico suficiente y completo para p. Además, $T \rightsquigarrow \mathcal{B}(n, p)$, por lo que:

$$E[T] = np \Longrightarrow E\left[\frac{T}{n}\right] = p$$

Por tanto, de ser $S = {}^{T}/_{n}$ estimador, es insesgado de p. Como X toma valores en $\{0, 1\}$, entonces T toma valores en $\{0, 1, \ldots, n\}$ y S toma valores en $\{0, {}^{1}/_{n}, \ldots, 1\}$. Por tanto, S es un estimador insesgado de p. Nos falta ver que tiene momento de segundo orden finito. Como S es una función de T, entonces:

$$Var[S] = Var\left[\frac{T}{n}\right] = \frac{1}{n^2} Var[T] = \frac{1}{n^2} np(1-p) < \infty$$

Por tanto, S es un estimador insesgado de p con momento de segundo orden finito. Por tanto, por el teorema de Lehmann-Scheffé, el UMVUE de p es:

$$E[S \mid T] = E\left[\frac{T}{n} \mid T\right] = \frac{T}{n} = \frac{1}{n}\sum_{i=1}^{n} X_i = \overline{X}$$

Por tanto, el UMVUE de p es la media muestral $\overline{X}$.

Ejemplo. Sea $(X_1, \ldots, X_n)$ una m.a.s. con distribución $\mathcal{U}(0, \theta)$, $\theta > 0$. Encontrar el UMVUE para θ y $1/\theta$.

En el ejemplo de la página 26, vimos que:

$$T = X_{(n)} = \text{máx}\{X_1, \ldots, X_n\}$$

es un estadístico suficiente y completo para θ. Además, su función de densidad es:

$$f_{X_{(n)}}(x) = \frac{n}{\theta^n} x^{n-1} \qquad \text{para } 0 < x < \theta$$

Por tanto:

$$E_\theta[X_{(n)}] = \int_0^\theta x \frac{n}{\theta^n} x^{n-1} dx = \frac{n}{\theta^n} \int_0^\theta x^n dx = \frac{n}{\theta^n}\left[\frac{x^{n+1}}{n+1}\right]_0^\theta = \frac{n}{\theta^n} \cdot \frac{\theta^{n+1}}{n+1} = \frac{n}{n+1}\theta$$

Por tanto, de ser $S = \dfrac{n+1}{n} X_{(n)}$ estimador, es insesgado de θ. Como $X_{(n)}$ toma valores en $]0, \theta[$, entonces S toma valores en $\left]0, \dfrac{n+1}{n}\theta\right[\subset \mathbb{R}^+$. Por tanto, S es un estimador insesgado de θ. Nos falta ver que tiene momento de segundo orden finito:

$$Var[S] = Var\left[\frac{n+1}{n} X_{(n)}\right] = \left(\frac{n+1}{n}\right)^2 Var[X_{(n)}] < \infty$$

Por tanto, por el teorema de Lehmann-Scheffé, el UMVUE de θ es:

$$E[S \mid T] = E\left[\frac{n+1}{n} X_{(n)} \mid X_{(n)}\right] = \frac{n+1}{n} X_{(n)}$$

Buscamos ahora el UMVUE de $1/\theta$. Para ello, buscamos una función $h(T)$ tal que:

$$E_\theta[h(T)] = \frac{1}{\theta}$$

Tenemos que:

$$E_\theta[h(T)] = \int_0^\theta h(x) \frac{n}{\theta^n} x^{n-1} dx = \frac{n}{\theta^n} \int_0^\theta h(x) x^{n-1} dx = \frac{1}{\theta}$$

Multiplicando por θ^n y dividiendo por n, obtenemos:

$$\int_0^\theta h(x) x^{n-1} dx = \frac{\theta^{n-1}}{n}$$

Por el teorema fundamental del cálculo, tenemos que:

$$h(\theta)\theta^{n-1} = \frac{(n-1)\theta^{n-2}}{n} \Longrightarrow h(\theta) = \frac{n-1}{n} \cdot \frac{1}{\theta}$$

Por tanto, consideramos el estadístico:

$$S = \frac{n-1}{n} \cdot \frac{1}{X_{(n)}}$$

Como $X_{(n)}$ toma valores en $]0, \theta[$, entonces S toma valores en un subconjunto de $\mathbb{R}^+$, luego es un estimador de $1/\theta$. Además, veamos que es insesgado:

$$E_\theta[S] = E_\theta\left[\frac{n-1}{n} \cdot \frac{1}{X_{(n)}}\right] = \frac{n-1}{n}\int_0^\theta \frac{1}{x}\frac{n}{\theta^n}x^{n-1}dx =$$
$$= \frac{n-1}{\theta^n}\int_0^\theta x^{n-2}dx = \frac{n-1}{\theta^n}\left[\frac{x^{n-1}}{n-1}\right]_0^\theta = \frac{1}{\theta}$$

Por tanto, S es un estimador insesgado de $1/\theta$. Nos falta ver que tiene momento de segundo orden finito:

$$Var[S] = Var\left[\frac{n-1}{n} \cdot \frac{1}{X_{(n)}}\right] = \left(\frac{n-1}{n}\right)^2 Var\left[\frac{1}{X_{(n)}}\right]$$

Comprobamos que $Var\left[\frac{1}{X_{(n)}}\right] < \infty$:

$$E\left[\frac{1}{X_{(n)}^2}\right] = \int_0^\theta \frac{1}{x^2}\frac{n}{\theta^n}x^{n-1}dx = \frac{n}{\theta^n}\int_0^\theta x^{n-3}dx = \frac{n}{\theta^n}\left[\frac{x^{n-2}}{n-2}\right]_0^\theta = \frac{n}{n-2} \cdot \frac{1}{\theta^2} < \infty$$

Por tanto, S tiene momento de segundo orden finito. Por tanto, por el teorema de Lehmann-Scheffé, el UMVUE de $1/\theta$ es:

$$E[S \mid T] = E\left[\frac{n-1}{n} \cdot \frac{1}{X_{(n)}} \mid X_{(n)}\right] = \frac{n-1}{n} \cdot \frac{1}{X_{(n)}}$$

Ejercicio 1.4.1. Sea $(X_1, \ldots, X_n)$ una m.a.s. con distribución $\mathcal{P}(\lambda)$, $\lambda > 0$. Encontrar el UMVUE de λ^s, $s \in \mathbb{N}$.

Buscamos un estadístico suficiente y completo. Por el Ejercicio 2.3.7.b), sabemos que:

$$T = \sum_{i=1}^n X_i$$

es un estadístico suficiente y completo para λ. Para encontrar el UMVUE de λ^s, buscamos una función $h(T)$ tal que:

$$E_\lambda[h(T)] = \lambda^s$$

Como $T \rightsquigarrow \mathcal{P}(n\lambda)$, tenemos que:

$$E_\lambda[h(T)] = \sum_{t=0}^\infty h(t)\frac{e^{-n\lambda}(n\lambda)^t}{t!} = \lambda^s \Longrightarrow e^{n\lambda}\lambda^s = \sum_{t=0}^\infty h(t)\frac{(n\lambda)^t}{t!}$$

Empleando la serie de Taylor de $e^{n\lambda}$, obtenemos:

$$\sum_{t=0}^{\infty} h(t)\frac{n^t}{t!}\lambda^t = \sum_{t=0}^{\infty} h(t)\frac{(n\lambda)^t}{t!} = \lambda^s \sum_{t=0}^{\infty} \frac{(n\lambda)^t}{t!} = \sum_{t=0}^{\infty} \frac{n^t}{t!}\lambda^{s+t}$$

En la sumatoria de la derecha, hacemos el cambio de variable $k = s+t$, de modo que $t = k - s$. Por tanto:

$$\sum_{t=0}^{\infty} h(t)\frac{n^t}{t!}\lambda^t = \sum_{k=s}^{\infty} \frac{n^{k-s}}{(k-s)!}\lambda^k$$

Como la igualdad ha de cumplirse para todo $\lambda > 0$, se sigue que:

- Para $t < s$:
$$h(t)\frac{n^t}{t!} = 0 \Longrightarrow h(t) = 0$$
- Para $t \geqslant s$:
$$h(t)\frac{n^t}{t!} = \frac{n^{t-s}}{(t-s)!} \Longrightarrow h(t) = \frac{n^{t-s}}{(t-s)!} \cdot \frac{t!}{n^t} = \frac{t!}{(t-s)!n^s}$$

Por tanto, consideramos el estadístico:

$$S = h(T) = \begin{cases} 0 & \text{si } T < s \\ \dfrac{T!}{(T-s)!n^s} & \text{si } T \geqslant s \end{cases}$$

Como T toma valores en $\mathbb{N}$, entonces S toma valores en $\mathbb{R}^+$, luego es un estimador de λ^s. Además, se ha construido de manera que es insesgado:

$$E_\lambda[S] = E_\lambda[h(T)] = \lambda^s$$

Nos falta ver que tiene momento de segundo orden finito:

$$Var[S] = Var[h(T)] < \infty$$

Por ser S un polinomio de T, y como T tiene momentos de todos los órdenes finitos, se sigue que S tiene momento de segundo orden finito. Por tanto, por el teorema de Lehmann-Scheffé, el UMVUE de λ^s es:

$$E[S \mid T] = E[h(T) \mid T] = h(T) = \begin{cases} 0 & \text{si } T < s \\ \dfrac{T!}{(T-s)!n^s} & \text{si } T \geqslant s \end{cases}$$

2. Relaciones de Ejercicios

2.1. Estadísticos muestrales

Ejercicio 2.1.1. Sea $(X_1, \ldots, X_n)$ una muestra aleatoria simple de una variable aleatoria X. Dar el espacio muestral y calcular la función masa de probabilidad de $(X_1, \ldots, X_n)$ en cada uno de los siguientes casos:

a) $X \rightsquigarrow \{\mathcal{B}(k_0, p) : p \in (0,1)\}$ Binomial.

El espacio muestral en este caso es $\mathcal{X}^n$, donde:

$$\mathcal{X} = \{0, 1, ..., k_0\}$$

Recordamos que si $X \rightsquigarrow \mathcal{B}(k_0, p)$, entonces:

$$P[X = x] = \binom{k_0}{x} p^x (1-p)^{k_0 - x} \qquad \forall x \in \mathcal{X}$$

Por tanto, para nuestra m.a.s. tendremos la función masa de probabilidad:

$$P[X_1 = x_1, \ldots, X_n = x_n] \overset{\text{indep.}}{=} \prod_{i=1}^{n} P[X_i = x_i] \overset{\text{id. d.}}{=} \prod_{i=1}^{n} P[X = x_i]$$

$$= \prod_{i=1}^{n} \binom{k_0}{x_i} p^{x_i} (1-p)^{k_0 - x_i} = p^{\sum_{i=1}^{n} x_i} (1-p)^{nk_0 - \sum_{i=1}^{n} x_i} \prod_{i=1}^{n} \binom{k_0}{x_i}$$

$$\forall (x_1, \ldots, x_n) \in \mathcal{X}^n$$

b) $X \rightsquigarrow \{\mathcal{P}(\lambda) : \lambda \in \mathbb{R}^+\}$ Poisson.

El espacio muestral en este caso es $\mathcal{X}^n$, donde:

$$\mathcal{X} = \mathbb{N} \cup \{0\}$$

Recordamos que si $X \rightsquigarrow \mathcal{P}(\lambda)$, entonces:

$$P[X = x] = e^{-\lambda} \frac{\lambda^x}{x!} \qquad \forall x \in \mathcal{X}$$

Por tanto:

$$P[X_1 = x_1, \ldots, X_n = x_n] \overset{\text{indep.}}{=} \prod_{i=1}^{n} P[X_i = x_i] \overset{\text{id. d.}}{=} \prod_{i=1}^{n} P[X = x_i]$$

$$= \prod_{i=1}^{n} e^{-\lambda} \frac{\lambda^{x_i}}{x_i!} = e^{-n\lambda} \prod_{i=1}^{n} \frac{\lambda^{x_i}}{x_i!} = e^{-n\lambda} \cdot \frac{\lambda^{\sum_{i=1}^{n} x_i}}{\prod_{i=1}^{n} x_i!} \qquad \forall (x_1, \ldots, x_n) \in \mathcal{X}^n$$

c) $X \rightsquigarrow \{BN(k_0, p) : p \in (0,1)\}$ Binomial Negativa.

El espacio muestral en este caso es $\mathcal{X}^n$, donde:

$$\mathcal{X} = \mathbb{N} \cup \{0\}$$

Recordamos que si $X \rightsquigarrow BN(k_0, p)$, entonces:

$$P[X = x] = \binom{x + k_0 - 1}{x}(1-p)^x p^{k_0} \qquad \forall x \in \mathcal{X}$$

Por tanto:

$$\begin{aligned} P[X_1 = x_1, \ldots, X_n = x_n] &\overset{\text{indep.}}{=} \prod_{i=1}^n P[X_i = x_i] \overset{\text{id. d.}}{=} \prod_{i=1}^n P[X = x_i] \\ &= \prod_{i=1}^n \binom{x_i + k_0 - 1}{x_i}(1-p)^{x_i} p^{k_0} = p^{nk_0}(1-p)^{\sum_{i=1}^n x_i} \prod_{i=1}^n \binom{x_i + k_0 - 1}{x_i} \\ &\forall (x_1, \ldots, x_n) \in \mathcal{X}^n \end{aligned}$$

d) $X \rightsquigarrow \{G(p) : p \in (0,1)\}$ Geométrica.

El espacio muestral en este caso es $\mathcal{X}^n$, donde:

$$\mathcal{X} = \mathbb{N} \cup \{0\}$$

Recordamos que $G(p) \equiv BN(1, p)$, por lo que si sustituimos en la fórmula obtenida en la Binomial Negativa $k_0 = 1$:

$$P[X_1 = x_1, \ldots, X_n = x_n] = p^n (1-p)^{\sum_{i=1}^n x_i} \qquad \forall (x_1, \ldots, x_n) \in \mathcal{X}^n$$

e) $X \rightsquigarrow \{P_N : N \in \mathbb{N}\}, \quad P_N[X = x] = \dfrac{1}{N}, \quad x = 1, \ldots, N.$

El espacio muestral en este caso es $\mathcal{X}^n$, donde (tal y como nos dan en el enunciado):

$$\mathcal{X} = \{1, \ldots, N\}$$

Calculemos la masa de probabilidad:

$$\begin{aligned} P[X_1 = x_1, \ldots, X_n = x_n] &\overset{\text{indep.}}{=} \prod_{i=1}^n P[X_i = x_i] \overset{\text{id. d.}}{=} \prod_{i=1}^n P[X = x_i] \\ &= \prod_{i=1}^n \frac{1}{N} = \left(\frac{1}{N}\right)^n \qquad \forall (x_1, \ldots, x_n) \in \mathcal{X}^n \end{aligned}$$

Ejercicio 2.1.2. Sea $(X_1, \ldots, X_n)$ una muestra aleatoria simple de una variable aleatoria X. Dar el espacio muestral y calcular la función de densidad de $(X_1, \ldots, X_n)$ en cada uno de los siguientes casos:

a) $X \rightsquigarrow \{\mathcal{U}(a,b) : a,b \in \mathbb{R}, a < b\}$ Uniforme.

El espacio muestral en este caso es $\mathcal{X}^n$, donde:

$$\mathcal{X} = [a,b]$$

Recordamos que si $X \rightsquigarrow \mathcal{U}(a,b)$, entonces:

$$f_X(x) = \frac{1}{b-a} \qquad \forall x \in [a,b]$$

Por lo que:

$$f_{(X_1,\dots,X_n)}(x_1,\dots,x_n) \overset{\text{indep.}}{=} \prod_{i=1}^{n} f_{X_i}(x_i) \overset{\text{id. d.}}{=} \prod_{i=1}^{n} f_X(x_i) = \prod_{i=1}^{n} \frac{1}{b-a}$$
$$= \left(\frac{1}{b-a}\right)^n \qquad \forall (x_1,\dots,x_n) \in \mathcal{X}^n$$

b) $X \rightsquigarrow \{\mathcal{N}(\mu,\sigma^2) : \mu \in \mathbb{R}, \sigma^2 \in \mathbb{R}^+\}$ Normal.

El espacio muestral en este caso es $\mathcal{X}^n$, donde $\mathcal{X} = \mathbb{R}$. Recordamos que si $X \rightsquigarrow \mathcal{N}(\mu,\sigma^2)$, entonces:

$$f_X(x) = \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(x-\mu)^2}{2\sigma^2}} \qquad \forall x \in \mathbb{R}$$

Por lo que:

$$f_{(X_1,\dots,X_n)}(x_1,\dots,x_n) \overset{\text{indep.}}{=} \prod_{i=1}^{n} f_{X_i}(x_i) \overset{\text{id. d.}}{=} \prod_{i=1}^{n} f_X(x_i) = \prod_{i=1}^{n} \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(x_i-\mu)^2}{2\sigma^2}}$$
$$= \left(\frac{1}{\sqrt{2\pi}\sigma}\right)^n \prod_{i=1}^{n} e^{-\frac{(x_i-\mu)^2}{2\sigma^2}} = \left(\frac{1}{\sqrt{2\pi}\sigma}\right)^n e^{-\sum_{i=1}^{n} \frac{(x_i-\mu)^2}{2\sigma^2}}$$
$$= \left(\frac{1}{\sqrt{2\pi}\sigma}\right)^n e^{\frac{-1}{2\sigma^2}\sum_{i=1}^{n}(x_i-\mu)^2} \qquad \forall (x_1,\dots,x_n) \in \mathbb{R}^n$$

c) $X \rightsquigarrow \{\Gamma(p,a) : p,a \in \mathbb{R}^+\}$ Gamma.

El espacio muestral en este caso es $\mathcal{X}^n$, donde $\mathcal{X} = \mathbb{R}_0^+$. Recordamos que si $X \rightsquigarrow \Gamma(p,a)$, entonces:

$$f_X(x) = \frac{a^p}{\Gamma(p)} x^{p-1} e^{-ax} \qquad \forall x \in \mathbb{R}_0^+$$

Por lo que:

$$f_{(X_1,\dots,X_n)}(x_1,\dots,x_n) \overset{\text{indep.}}{=} \prod_{i=1}^{n} f_{X_i}(x_i) \overset{\text{id. d.}}{=} \prod_{i=1}^{n} f_X(x_i) = \prod_{i=1}^{n} \frac{a^p}{\Gamma(p)} x_i^{p-1} e^{-ax_i}$$
$$= \left(\frac{a^p}{\Gamma(p)}\right)^n \cdot e^{-a\sum_{i=1}^{n} x_i} \cdot \prod_{i=1}^{n} x_i^{p-1} \qquad \forall (x_1,\dots,x_n) \in \mathcal{X}^n$$

d) $X \rightsquigarrow \{\beta(p,q) : p,q \in \mathbb{R}^+\}$ Beta.

El espacio muestral en este caso es $\mathcal{X}^n$, donde $\mathcal{X} = [0,1]$. Recordamos que si $X \rightsquigarrow \beta(p,q)$, entonces:

$$f_X(x) = \frac{1}{\beta(p,q)} x^{p-1}(1-x)^{q-1} \qquad \forall x \in [0,1]$$

Donde:

$$\beta(p,q) = \frac{\Gamma(p)\Gamma(q)}{\Gamma(p+q)}$$

Por tanto:

$$f_{(X_1,\dots,X_n)}(x_1,\dots,x_n) \overset{\text{indep.}}{=} \prod_{i=1}^n f_{X_i}(x_i) \overset{\text{id. d.}}{=} \prod_{i=1}^n f_X(x_i) = \prod_{i=1}^n \frac{1}{\beta(p,q)} x_i^{p-1}(1-x_i)^{q-1}$$
$$= \frac{1}{\beta(p,q)^n} \prod_{i=1}^n x_i^{p-1}(1-x_i)^{q-1} \qquad \forall (x_1,\dots,x_n) \in \mathcal{X}^n$$

e) $X \rightsquigarrow \{P_\theta : \theta \in \mathbb{R}^+\}, \quad f_\theta(x) = \dfrac{1}{2\sqrt{x\theta}}, \quad 0 < x < \theta.$

El espacio muestral en este caso es $\mathcal{X}^n$, donde (tal y como nos dan en el enunciado):

$$\mathcal{X} =]0,\theta[$$

Calculamos la función de densidad conjunta:

$$f_{(X_1,\dots,X_n)}(x_1,\dots,x_n) \overset{\text{indep.}}{=} \prod_{i=1}^n f_{X_i}(x_i) \overset{\text{id. d.}}{=} \prod_{i=1}^n f_X(x_i) = \prod_{i=1}^n \frac{1}{2\sqrt{x_i\theta}}$$
$$= \frac{1}{\left(2\sqrt{\theta}\right)^n} \prod_{i=1}^n \frac{1}{\sqrt{x_i}} \qquad \forall (x_1,\dots,x_n) \in \mathcal{X}^n$$

Ejercicio 2.1.3. Se miden los tiempos de sedimentación de una muestra de partículas flotando en un líquido. Los tiempos observados son:

11,5; 1,8; 7,3; 12,1; 1,8; 21,3; 7,3; 15,2; 7,3; 12,1; 15,2;
7,3; 12,1; 1,8; 10,5; 15,2; 21,3; 10,5; 15,2; 11,5

1. Construir la función de distribución muestral asociada a a dichas observaciones.

   En primer lugar, ordenamos los datos de menor a mayor, puesto que nos será de utilidad para construir la función de distribución muestral:

   1,8; 1,8; 1,8; 7,3; 7,3; 7,3; 7,3; 10,5; 10,5; 11,5;
   11,5; 12,1; 12,1; 12,1; 15,2; 15,2; 15,2; 15,2; 21,3; 21,3

Si aplicamos la definición de función de distribución muestral obtenemos que esta viene dada por la siguiente ecuación, y está mostrada en la Figura 2.1:

$$F_n^*(x) = \begin{cases} 0 & \text{si } x < 1{,}8 \\ 3/20 & \text{si } 1{,}8 \leqslant x < 7{,}3 \\ 7/20 & \text{si } 7{,}3 \leqslant x < 10{,}5 \\ 9/20 & \text{si } 10{,}5 \leqslant x < 11{,}5 \\ 11/20 & \text{si } 11{,}5 \leqslant x < 12{,}1 \\ 14/20 & \text{si } 12{,}1 \leqslant x < 15{,}2 \\ 18/20 & \text{si } 15{,}2 \leqslant x < 21{,}3 \\ 20/20 & \text{si } x \geqslant 21{,}3 \end{cases}$$

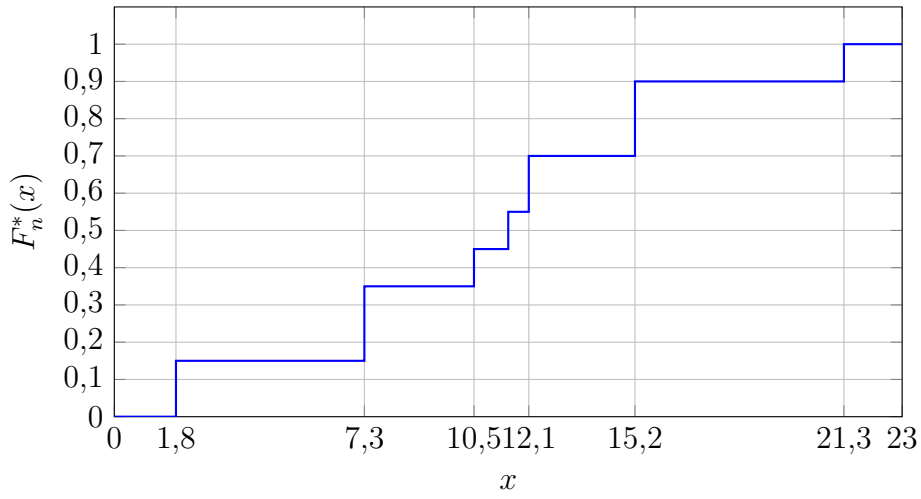


Figura 2.1: Gráfica de la función de distribución muestral.

2. Hallar los valores de los tres primeros momentos muestrales respecto al origen y respecto a la media.

Calculamos primero los tres primeros momentos respecto al origen para luego

calcular los centrados respecto a la media a partir de ellos:

$$a_1 = \sum_{i=1}^{n} f_i x_i = 10{,}915 \qquad a_2 = \sum_{i=1}^{n} f_i x_i^2 = 148{,}9325$$

$$a_3 = \sum_{i=1}^{n} f_i x_i^3 = 2280{,}98365$$

$$b_1 = \sum_{i=1}^{n} f_i (x_i - \overline{x}) = 0$$

$$\begin{aligned} b_2 &= \frac{1}{n}\sum_{i=1}^{n} (x_i - \overline{x})^2 = \frac{1}{n}\sum_{i=1}^{n} (x_i^2 - 2x_i\overline{x} + \overline{x}^2) \\ &= \frac{1}{n}\sum_{i=1}^{n} x_i^2 - \frac{2\overline{x}}{n}\sum_{i=1}^{n} x_i + \overline{x}^2 = a_2 - 2a_1^2 + a_1^2 = a_2 - a_1^2 \\ &= 148{,}9325 - 10{,}915^2 = 29{,}795275 \end{aligned}$$

$$\begin{aligned} b_3 &= \frac{1}{n}\sum_{i=1}^{n} (x_i - \overline{x})^3 = \frac{1}{n}\sum_{i=1}^{n} \left(x_i^3 - 3x_i^2\overline{x} + 3x_i\overline{x}^2 - \overline{x}^3\right) \\ &= \frac{1}{n}\sum_{i=1}^{n} x_i^3 - \frac{3\overline{x}}{n}\sum_{i=1}^{n} x_i^2 + \frac{3\overline{x}^2}{n}\sum_{i=1}^{n} x_i - \overline{x}^3 = a_3 - 3a_1a_2 + 3a_1^3 - a_1^3 \\ &= a_3 - 3a_1a_2 + 2a_1^3 = 4{,}95455925 \end{aligned}$$

3. Determinar los valores de los cuartiles muestrales y el percentil 70.

   Para obtener los cuartiles, primero ordenamos los datos de menor a mayor y los agrupamos en grupos de $^{20}/_{4} = 5$ en 5:

   $$1{,}8;\ 1{,}8;\ 1{,}8;\ 7{,}3;\ 7{,}3;\ 7{,}3;\ 7{,}3;\ 10{,}5;\ 10{,}5;\ 11{,}5;\ 11{,}5;\ 12{,}1;\ 12{,}1;$$
   $$12{,}1;\ 15{,}2;\ 15{,}2;\ 15{,}2;\ 15{,}2;\ 21{,}3;\ 21{,}3$$

   Como en los cambios de agrupaciones de números estos se repiten, hemos obtenido el valor de los cuartiles:

   $$q_1 = 7{,}3 \qquad q_2 = 11{,}5 \qquad q_3 = 15{,}2 \qquad q_4 = 21{,}3$$

   Para el percentil 70, calculamos:

   $$0{,}7 \cdot 20 = 14$$

   Como hemos obtenido un número entero, el percentil 70 será:

   $$c_{70} = \frac{X_{(14)} + X_{(15)}}{2} = \frac{12{,}1 + 15{,}2}{2} = 13{,}65$$

   En el caso de haber obtenido un número no entero (por ejemplo, 14,2), sería $X_{(15)}$.

Ejercicio 2.1.4. Se dispone de una muestra aleatoria simple de tamaño 40 de una distribución exponencial de media 3, ¿cuál es la probabilidad de que los valores de

la función de distribución muestral y la teórica, en $x = 1$, difieran menos de 0,01? Aproximadamente, ¿cuál debe ser el tamaño muestral para que dicha probabilidad sea como mínimo 0,98?

Como dice el enunciado, tenemos una m.a.s. $(X_1, \ldots, X_n)$ con $n = 40$, todas ellas idénticamente distribuidas a $X \rightsquigarrow \exp(\lambda)$. Sabemos de la asignatura de Probabilidad que:

$$E[X] = \frac{1}{\lambda} = 3 \Longrightarrow \lambda = \frac{1}{3}$$

Por lo que $X \rightsquigarrow \exp(1/3)$. Denotaremos por comodidad:

$$F_n^*(x) = F^*_{(X_1,\ldots,X_n)}(x)$$

Y el enunciado nos pregunta por:

$$P[|F_n^*(1) - F_X(1)| < 0{,}01]$$

Para ello, primero calculamos $F_X(1)$, que por comodidad denotaremos por α:

$$F_X(1) = 1 - e^{-\lambda \cdot 1} = 1 - e^{-\lambda} = 1 - e^{-1/3} =: \alpha$$

Por lo que nos disponemos ya a calcular la probabilidad:

$$\begin{aligned} P[|F_n^*(1) - F_X(1)| < 0{,}01] &= P[|F_n^*(1) - \alpha| < 0{,}01] = P[-0{,}01 < F_n^*(1) - \alpha < 0{,}01] \\ &= P[-0{,}01 + \alpha < F_n^*(1) < 0{,}01 + \alpha] \\ &= P[40(-0{,}01 + \alpha) < 40F_n^*(1) < 40(0{,}01 + \alpha)] \end{aligned}$$

Y como sabemos que $Y = 40F_n^*(1) \rightsquigarrow \mathcal{B}(40, F_X(1)) \equiv \mathcal{B}(40, \alpha)$:

$$P[|F_n^*(1) - F_X(1)| < 0{,}01] = P[40(-0{,}01 + \alpha) < Y < 40(0{,}01 + \alpha)]$$

Si ahora tomamos:

$$\alpha = 1 - e^{-1/3} \approx 0{,}283469$$

Entonces:

$$\begin{aligned} 40(0{,}01 + \alpha) &\approx 40(0{,}01 + 0{,}283469) = 11{,}73876 \\ 40(-0{,}01 + \alpha) &\approx 40(-0{,}01 + 0{,}283469) = 10{,}93876 \end{aligned}$$

Por lo que, usando que Y es una variable aleatoria discreta, tenemos que:

$$P[|F_n^*(1) - F_X(1)| < 0{,}01] \approx P[10{,}93876 < Y < 11{,}73876] = P[Y = 11]$$

De donde usando la masa de probabilidad de la Binomial:

$$P[Y = 11] = \binom{40}{11} (0{,}283469)^{11} (1 - 0{,}283469)^{40-11} \approx 0{,}139$$

Por tanto, la probabilidad de que los valores de la función de distribución muestral y la teórica, en $x = 1$, difieran menos de 0,01 es aproximadamente 0,139, luego la probabilidad es baja. Para aumentar dicha probabilidad, necesitamos un tamaño

muestral mayor, que es lo que nos piden en el segundo apartado.

Para el segundo apartado, como para $n = 40$ obtenemos una probabilidad de 0,139, podemos intuir que para que dicha probabilidad sea como mínimo 0,98, nos es necesario un valor de n grande, por lo que podemos suponer que:

$$F_n^*(1) \rightsquigarrow \mathcal{N}\left(\alpha, \frac{\alpha(1-\alpha)}{n}\right)$$

De donde:

$$Z = \frac{\sqrt{n}(F_n^*(1) - \alpha)}{\sqrt{\alpha(1-\alpha)}} \rightsquigarrow \mathcal{N}(0,1)$$

Buscamos el valor de n que verifica:

$$0{,}98 \leqslant P[|F_n^*(1) - F_X(1)| < 0{,}01] = P\left[|Z| < \frac{\sqrt{n}0{,}01}{\sqrt{\alpha(1-\alpha)}}\right]$$

Si aplicamos propiedades conocidas de la función de distribución de una variable aleatoria, si $a \in \mathbb{R}$, entonces:

$$P[|Z| < a] = P[-a < Z < a] = P[Z < a] - P[Z \leqslant -a] = P[Z < a] - P[Z < -a]$$

Pero, empleando las particularidades de la distribución normal, sabemos que:

$$P[Z < -a] = P[Z > a] = 1 - P[Z < a]$$

Por lo que:

$$P[|Z| < a] = P[Z < a] - P[Z < -a] = 2P[Z < a] - 1$$

Volviendo al caso que nos interesa:

$$0{,}98 \leqslant P\left[|Z| < \frac{\sqrt{n}0{,}01}{\sqrt{\alpha(1-\alpha)}}\right] = 2P\left[Z < \frac{\sqrt{n}0{,}01}{\sqrt{\alpha(1-\alpha)}}\right] - 1$$

Luego:

$$0{,}99 = \frac{0{,}98+1}{2} \leqslant P\left[Z < \frac{\sqrt{n}0{,}01}{\sqrt{\alpha(1-\alpha)}}\right]$$

Si consultamos la tabla de la normal $\mathcal{N}(0,1)$, observamos que el primer valor que supera la probbailidad de 0,99 es 2,33, por lo que:

$$2{,}33 = \frac{\sqrt{n}0{,}01}{\sqrt{\alpha(1-\alpha)}} = \frac{\sqrt{n}0{,}01}{\sqrt{0{,}283469(1-0{,}283469)}} \approx 0{,}0221886\sqrt{n}$$

De donde:

$$5{,}4289 = (2{,}33)^2 = (0{,}0221886\sqrt{n})^2 = 0{,}00049233n \Longrightarrow n = \frac{5{,}4289}{0{,}00049233} = 11026{,}95347$$

Por lo que para $n \geqslant 11027$ podemos asegurar que la probabilidad es como mínimo 0,98.

Ejercicio 2.1.5. Se dispone de una muestra aleatoria simple de tamaño 50 de una distribución de Poisson de media 2, ¿cuál es la probabilidad de que los valores de la función de distribución muestral y la teórica, en $x = 2$, difieran menos de 0,02? Aproximadamente, ¿qué tamaño muestral hay que tomar para que dicha probabilidad sea como mínimo 0,99?

Tenemos una m.a.s. $(X_1, \ldots, X_n)$ con $n = 50$ idénticamente distribuidas a $X \rightsquigarrow \mathcal{P}(\lambda)$. Como $E[X] = \lambda = 2$, tenemos que $X \rightsquigarrow \mathcal{P}(2)$. Notamos por comodidad:

$$F^*_{(X_1,\ldots,X_n)}(x) = F^*_n(x)$$

Nos preguntan por:

$$P[|F^*_n(2) - F_X(2)| < 0{,}02]$$

Para ello primero calculamos:

$$F_X(2) = \sum_{k=0}^{2} e^{-2}\frac{2^k}{k!} = e^{-2}\left(\frac{2^0}{0!} + \frac{2^1}{1!} + \frac{2^2}{2!}\right) = e^{-2}(1+2+2) \approx 0{,}6767$$

Por lo que:

$$P[|F^*_n(2) - 0{,}6767| < 0{,}02] = P[-0{,}02 < F^*_n(2) - 0{,}6767 < 0{,}02] = P[0{,}6567 < F^*_n(2) < 0{,}6967]$$

Como sabemos por lo visto en teoría que:

$$Y = 50F^*_n(2) \rightsquigarrow \mathcal{B}(50, F_X(2)) \equiv \mathcal{B}(50, \quad 0{,}6767)$$

Multiplicamos por 50 la última expresión:

$$\begin{aligned} P[|F^*_n(2) - 0{,}6767| < 0{,}02] = P[0{,}6567 < F^*_n(2) < 0{,}6967] = P[32{,}835 < Y < 34{,}835] \\ \overset{(*)}{=} P[Y = 33] + P[Y = 34] \end{aligned}$$

donde en $(*)$ hemos empleado la naturaleza discreta de la variable aleatoria Y. Calculamos estas dos probabilidades:

$$\begin{aligned} P[Y = 33] &= \binom{50}{33}(0{,}6767)^{33}(1 - 0{,}6767)^{50-33} \approx 0{,}114734 \\ P[Y = 34] &= \binom{50}{34}(0{,}6767)^{34}(1 - 0{,}6767)^{50-34} \approx 0{,}120075 \end{aligned}$$

Por lo que:

$$P[|F^*_n(2) - 0{,}6767| < 0{,}02] \approx 0{,}114734 + 0{,}120075 = 0{,}234809$$

Para el segundo apartado, como para $n = 50$ obtenemos una probabilidad de 0,234809, podemos intuir que para que dicha probabilidad sea como mínimo 0,99, nos es necesario un valor de n grande, por lo que podemos suponer que:

$$F^*_n(2) \rightsquigarrow \mathcal{N}\left(0{,}6767, \frac{0{,}6767(1 - 0{,}6767)}{n}\right) \equiv \mathcal{N}\left(0{,}6767, \frac{0{,}218777}{n}\right)$$

Por lo que:

$$Z = \frac{\sqrt{n}(F_n^*(2) - 0{,}6767)}{\sqrt{0{,}218777}} \rightsquigarrow \mathcal{N}(0,1)$$

En dicho caso, buscamos n de forma que:

$$0{,}99 \leqslant P[|F_n^*(2) - F_X(2)| < 0{,}02] = P\left[|Z| < \frac{\sqrt{n}0{,}02}{\sqrt{0{,}218777}}\right]$$

De forma análoga al ejercicio anterior:

$$P\left[|Z| < \frac{\sqrt{n}0{,}02}{\sqrt{0{,}218777}}\right] = 2P\left[Z < \frac{\sqrt{n}0{,}02}{\sqrt{0{,}218777}}\right] - 1$$

Luego:

$$0{,}995 = \frac{0{,}99+1}{2} \leqslant P\left[Z < \frac{\sqrt{n}0{,}02}{\sqrt{0{,}218777}}\right]$$

Y si miramos la tabla de la Normal observamos que el primer valor que supera la probabilidad de 0,995 es 2,58, luego:

$$2{,}58 = \frac{\sqrt{n}0{,}02}{\sqrt{0{,}218777}} = 0{,}042759\sqrt{n}$$

Por lo que:

$$6{,}6564 = (2{,}58)^2 = (0{,}042759\sqrt{n})^2 = 0{,}00182833n$$

Luego:

$$n = \frac{6{,}6564}{0{,}00182833} \approx 3640{,}7$$

Por lo que para $n \geqslant 3641$ podemos asegurar que la probabilidad es como mínimo 0,99.

Ejercicio 2.1.6. Sea $X \rightsquigarrow \mathcal{B}(1,p)$ y (X_1, X_2, X_3) una muestra aleatoria simple de X. Calcular la función masa de probabilidad de los estadísticos $\overline{X}$, S^2, mín X_i y máx X_i.

Para resolver este ejercicio, como X sigue una distribución discreta, buscamos aplicar el teorema de cambio de variable de discreta a discreta. Para ello, la forma más cómoda será analizar cada uno de los valores que puede tomar la muestra aleatoria simple (X_1, X_2, X_3) y determinar en consecuencia cada uno de los valores que toman $\overline{X}$, S^2, mín X_i y máx X_i. Acompañaremos la tabla junto con la probabilidad de que la muestra tome dicho valor, es decir, en la fila correpondiente a (x_1, x_2, x_3) incluiremos $P[X_1 = x_1, X_2 = x_2, X_3 = x_3]$:

P	(X_1, X_2, X_3)	$\overline{X}$	S^2	mín X_i	máx X_i
$(1-p)^3$	$(0,0,0)$	0	0	0	0
$p(1-p)^2$	$(0,0,1)$	$1/3$	$1/3$	0	1
$p(1-p)^2$	$(0,1,0)$	$1/3$	$1/3$	0	1
$p^2(1-p)$	$(0,1,1)$	$2/3$	$1/3$	0	1
$p(1-p)^2$	$(1,0,0)$	$1/3$	$1/3$	0	1
$p^2(1-p)$	$(1,0,1)$	$2/3$	$1/3$	0	1
$p^2(1-p)$	$(1,1,0)$	$2/3$	$1/3$	0	1
p^3	$(1,1,1)$	1	0	1	1

Podemos ya calcular la función masa de probabilidad de cada uno de los estadísticos, simplemente sumando las probabilidades de la tabla que corresponden a cada valor del espacio muestral de cada estadístico:

- Para $\overline{X}$:

$$P[\overline{X} = 0] = P[X_1 = 0, X_2 = 0, X_3 = 0] = (1-p)^3$$
$$P[\overline{X} = 1/3] = \sum_{i=1}^{3} p(1-p)^2 = 3p(1-p)^2$$
$$P[\overline{X} = 2/3] = \sum_{i=1}^{3} p^2(1-p) = 3p^2(1-p)$$
$$P[\overline{X} = 1] = P[X_1 = 1, X_2 = 1, X_3 = 1] = p^3$$

- Para S^2:

$$P[S^2 = 0] = P[X_1 = 0, X_2 = 0, X_3 = 0] + P[X_1 = 1, X_2 = 1, X_3 = 1] = p^3 + (1-p)^3$$
$$P[S^2 = 1/3] = \sum_{i=1}^{3} p(1-p)^2 + \sum_{i=1}^{3} p^2(1-p) = 3p(1-p)(p+1-p) = 3p(1-p)$$

- Para mín X_i:

$$P[\text{mín}\, X_i = 1] = P[X_1 = 1, X_2 = 1, X_3 = 1] = p^3$$
$$P[\text{mín}\, X_i = 0] = 1 - P[\text{mín}\, X_i = 1] = 1 - p^3$$

- Para máx X_i:

$$P[\text{máx}\, X_i = 0] = P[X_1 = 0, X_2 = 0, X_3 = 0] = (1-p)^3$$
$$P[\text{máx}\, X_i = 1] = 1 - P[\text{máx}\, X_i = 0] = 1 - (1-p)^3$$

Ejercicio 2.1.7. Obtener la función masa de probabilidad o función de densidad de $\overline{X}$ en el muestreo de una variable de Bernoulli, de una Poisson y de una exponencial.

Calculamos la masa de probabilidad o función de densidad en cada caso, suponiendo que tenemos $(X_1, \ldots, X_n)$ una muestra aleatoria simple con variables aleatorias idénticamente distribuidas a X, que sigue una distribución distinta en cada caso y estaremos interesados en calcular la masa de:

$$\overline{X} = \frac{1}{n} \sum_{i=1}^{n} X_i$$

Bernoulli. Veamos dos opciones:

Opción 1 Supuesto que $X \rightsquigarrow \mathcal{B}(1,p)$ para cierto $p \in]0,1[$, si tomamos:

$$Y = \sum_{i=1}^{n} X_i$$

Por la propiedad reproductiva de la Bernoulli, tenemos que $Y \rightsquigarrow \mathcal{B}(n,p)$. En dicho caso:

$$P[Y=k] = \binom{n}{k} p^k (1-p)^{n-k} \qquad \forall k \in \{0,\dots,n\}$$

Por tanto, tendremos que:

$$P[\overline{X}=x] = P\left[\frac{1}{n}\sum_{i=1}^{n} X_i = x\right] = P[Y=nx]$$

Como Y es una variable aleatoria discreta, nx debe ser un número entero entre 0 y n, por lo que x debe ser de la forma k/n para cierto $k \in \{0,\dots,n\}$. Por lo que:

$$P\left[\overline{X}=\frac{k}{n}\right] = P[Y=k] = \binom{n}{k} p^k (1-p)^{n-k} \qquad \forall k \in \{0,\dots,n\}$$

Opción 2 Calculemos la función generatriz de momentos de $\overline{X}$, que por la igualdad $(*)$ vista en teoría, tenemos que:

$$M_{\overline{X}}(t) \overset{(*)}{=} (M_X(t/n))^n = \left(pe^{t/n} + (1-p)\right)^n = \left(pe^{t/n} + (1-p)\right)^n$$

Observamos que obtenemos una función generatriz de momentos para $\overline{X}$ igual que para una variable aleatoria de distribución $\mathcal{B}(n,p)$, en la que los valores posibles de $\overline{X}$ son k/n para cierto $k \in \{0,\dots,n\}$.

Poisson. Supuesto que $X \rightsquigarrow \mathcal{P}(\lambda)$ para cierto $\lambda \in \mathbb{R}^+$, si tomamos:

$$Y = \sum_{i=1}^{n} X_i$$

Por la propiedad reproductiva de la Poisson, tendremos que:

$$Y \rightsquigarrow \mathcal{P}\left(\sum_{i=1}^{n} \lambda\right) \equiv \mathcal{P}(n\lambda)$$

En dicho caso:

$$P[Y=x] = e^{-n\lambda}\frac{(n\lambda)^x}{x!} \qquad \forall x \in \mathbb{N}$$

Por lo que, empleando la misma idea que en el caso de la Bernoulli, tendremos que:

$$P[\overline{X}=x/n] = P[Y=x] = e^{-n\lambda}\frac{(n\lambda)^x}{x!} \qquad \forall x \in \mathbb{N}$$

Exponencial. Supuesto ahora que $X \rightsquigarrow \exp(\lambda)$ para cierto $\lambda \in \mathbb{R}^+$, tendremos entonces que:

$$M_X(t) = \frac{\lambda}{\lambda - t} \qquad t < \lambda$$

Si aplicamos la igualdad $(*)$ vista en teoría:

$$M_{\overline{X}}(t) \overset{(*)}{=} (M_X(t/n))^n = \left(\frac{\lambda}{\lambda - t/n}\right)^n = \left(\frac{n\lambda}{n\lambda - t}\right)^n$$

Observamos que obtenemos una función generatriz de momentos para $\overline{X}$ igual que para una variable aleatoria de distribución $\Gamma(n, n\lambda)$. Como la función generatriz de momentos de una variable aleatoria caracteriza su distribución, concluimos que $\overline{X} \rightsquigarrow \Gamma(n, n\lambda)$. Por tanto, la función de densidad de $\overline{X}$ es:

$$f_{\overline{X}}(x) = \frac{(n\lambda)^n}{\Gamma(n)} x^{n-1} e^{-n\lambda x} \qquad \forall x > 0$$

Ejercicio 2.1.8. Calcular las funciones de densidad de los estadísticos $\max X_i$ y $\min X_i$ en el muestreo de una variable X con funcion de densidad:

$$f_\theta(x) = e^{\theta - x}, \qquad x > \theta.$$

Calculamos primero la función de distribución, para calcular con mayor comodidad las funciones de distribución de $X_{(n)}$ y $X_{(1)}$:

$$F_\theta(x) = \int_\theta^x f_\theta(t)\, dt = \int_\theta^x e^{\theta - t}\, dt = \left[-e^{\theta - t}\right]_\theta^x = 1 - e^{\theta - x} \qquad \forall x > \theta$$

Supuesto ahora que disponemos de una m.a.s. $(X_1, \ldots, X_n)$ idénticamente distribuidas a X cuya función de densidad es la anteriormente dicha, podemos aplicar las fórmulas obtenidas en teoría para calcular las funciones de distribución del mínimo y del máximo. Para el máximo:

$$F_{X_{(n)}}(x) = (F_X(x))^n = (1 - e^{\theta - x})^n \Longrightarrow f_{X_{(n)}}(x) = n(1 - e^{\theta - x})^{n-1} e^{\theta - x} \qquad \forall x > \theta$$

Para el mínimo:

$$F_{X_{(1)}}(x) = 1 - (1 - F_X(n))^n = 1 - (1 - 1 + e^{\theta - x})^n = 1 - e^{n(\theta - x)} \qquad \forall x > \theta$$

de donde:

$$f_{X_{(1)}}(x) = n e^{n(\theta - x)} \qquad \forall x > \theta$$

Ejercicio 2.1.9. El número de pacientes que visitan diariamente una determinada consulta médica es una variable aleatoria con varianza de 16 personas. Se supone que el número de visitas de cada día es independiente de cualquier otro. Si se observa el número de visitas diarias durante 64 días, calcular aproximadamente la probabilidad de que la media muestral no difiera en más de una persona del valor medio verdadero de visitas diarias.

Sea X una variable aleatoria que indica el número de pacientes que visitan diariamente dicha consulta médica. Por cómo nos definen X sabemos que $X \rightsquigarrow \mathcal{P}(\lambda)$. Como además nos dicen que la varianza de dicha variable aleatoria es 16, tenemos que $Var(X) = \lambda = 16$. Si tenemos ahora una muestra aleatoria simple $(X_1, \ldots, X_n)$ con $n = 64$, nos preguntan por:

$$P[|\overline{X} - E[X]| \leqslant 1]$$

Notemos que se incluye el valor 1 en la desigualdad.

Donde $E[X] = \lambda = 16$, ya que $X \rightsquigarrow \mathcal{P}(16)$. Calculamos:

$$P[|\overline{X} - E[X]| \leqslant 1] = P[-1 \leqslant \overline{X} - 16 \leqslant 1] = P[15 \leqslant \overline{X} \leqslant 17]$$

Aplicamos ahora lo visto en el Ejercicio 2.1.7, ya que si $X \rightsquigarrow \mathcal{P}(\lambda)$, entonces tendremos que $n\overline{X} \rightsquigarrow \mathcal{P}(n\lambda)$, gracias a la propiedad reproductiva de la Poisson:

$$\begin{aligned} P[|\overline{X} - E[X]| \leqslant 1] = P[15 \leqslant \overline{X} \leqslant 17] &= P[64 \cdot 15 \leqslant 64\overline{X} \leqslant 64 \cdot 17] \\ &= P[960 \leqslant 64\overline{X} \leqslant 1088] \end{aligned}$$

Donde $64\overline{X} \rightsquigarrow \mathcal{P}(64 \cdot 16) \equiv \mathcal{P}(1024)$. Para calcular dicha probabilidad, aproximaremos la Poisson a una distribución normal empleando el Teorema Central del Límite, ya que $n = 64$ es un tamaño muestral suficientemente grande. Por lo que:

$$\mathcal{P}(1024) \approx \mathcal{N}(1024, 1024)$$

Por lo que:

$$\begin{aligned} P[|\overline{X} - E[X]| \leqslant 1] = P[960 \leqslant 64\overline{X} \leqslant 1088] &\approx P\left[\frac{960 - 1024}{\sqrt{1024}} \leqslant Z \leqslant \frac{1088 - 1024}{\sqrt{1024}}\right] \\ &= P[-2 \leqslant Z \leqslant 2] = 2P[Z \leqslant 2] - 1 \\ &= 2 \cdot 0{,}97725 - 1 = 0{,}9545 \end{aligned}$$

Ejercicio 2.1.10. Una máquina de refrescos está arreglada para que la cantidad de bebida que sirve sea una variable aleatoria con media 200 ml. y desviación típica 15 ml. Calcular de forma aproximada la probabilidad de que la cantidad media servida en una muestra aleatoria de tamaño 36 sea al menos 204 ml.

Sea $(X_1, \ldots, X_n)$ una muestra aleatoria simple idénticamente distribuida a la variable aleatoria X de tamaño $n = 36$. De la información que nos dan, sabemos que $E[X] = 200$ y $Var(X) = 15^2$, pero no conocemos la distribución de X.

Una primera aproximación sería emplear el Teorema Central del Límite para aproximar la distribución X a una distribución normal, y de ahí intentar obtener la distribución de $\overline{X}$. No obstante, un resultado más directo es directamente calcular $E[\overline{X}]$ y $Var(\overline{X})$.

$$E[\overline{X}] = E\left[\frac{1}{n}\sum_{i=1}^{n} X_i\right] = \frac{1}{n}\sum_{i=1}^{n} E[X_i] = \frac{1}{n}\sum_{i=1}^{n} E[X] = E[X] = 200$$

$$Var[\overline{X}] = Var\left[\frac{1}{n}\sum_{i=1}^{n} X_i\right] = \frac{1}{n^2}\sum_{i=1}^{n} Var[X_i] = \frac{1}{n^2}\sum_{i=1}^{n} Var[X] = \frac{Var[X]}{n} = \frac{15^2}{36}$$

Por tanto, aplicando ahora el Teorema Central del Límite, obtenemos que $\overline{X} \rightsquigarrow \mathcal{N}\left(200, \frac{15^2}{36}\right)$. Calculamos la probabilidad:

$$\begin{aligned} P[\overline{X} \geqslant 204] \overset{\text{tipificamos}}{\approx} P\left[Z \geqslant \frac{\sqrt{36}(204 - 200)}{15}\right] &= P[Z \geqslant 1{,}6] = 1 - P[Z < 1{,}6] \\ &= 1 - 0{,}9452 = 0{,}0548 \end{aligned}$$

Ejercicios Adicionales

Ejercicio 2.1.11 (Reto)**.** Sea $(X_1, \ldots, X_n)$ una muestra aleatoria simple de una variable aleatoria X con función de densidad:

$$f_\theta(x) = \theta x^{\theta-1}, \qquad 0 < x < 1, \quad \theta > 0$$

Obtener la función de densidad de $X_{(n)}$ y de $X_{(1)}$.

Obtenemos primero la función de distribución de X:

$$F_\theta(x) = \int_0^x f_\theta(t)\ dt = \int_0^x \theta t^{\theta-1}\ dt = \left[t^\theta\right]_0^x = x^\theta \qquad \forall x \in]0,1[$$

Pasamos ahora a calcular la función de distribución de $X_{(n)}$:

$$F_{X_{(n)}}(x) = P[X_{(n)} \leqslant x] = P[X_1 \leqslant x, \ldots, X_n \leqslant x] \overset{\text{idd}}{=} \prod_{i=1}^n P[X \leqslant x] = (F_\theta(x))^n = x^{n\theta} \qquad \forall x \in]0,1[$$

Derivando, obtenemos la función de densidad de $X_{(n)}$:

$$f_{X_{(n)}}(x) = n\theta x^{n\theta-1} \qquad \forall x \in]0,1[$$

Pasamos ahora a calcular la función de distribución de $X_{(1)}$:

$$F_{X_{(1)}}(x) = P[X_{(1)} \leqslant x] = 1 - P[X_{(1)} > x] = 1 - P[X_1 > x, \ldots, X_n > x] \overset{\text{idd}}{=}$$
$$\overset{\text{idd}}{=} 1 - \prod_{i=1}^n P[X > x] = 1 - (1 - F_\theta(x))^n = 1 - (1 - x^\theta)^n \qquad \forall x \in]0,1[$$

Derivando, obtenemos la función de densidad de $X_{(1)}$:

$$f_{X_{(1)}}(x) = n\theta x^{\theta-1}(1 - x^\theta)^{n-1} \qquad \forall x \in]0,1[$$

2.2. Distribuciones en el muestreo de poblaciones normales

Ejercicio 2.2.1. Se toma una muestra aleatoria simple de tamaño 5 de una variable aleatoria con distribución $\mathcal{N}(2{,}5,\ 36)$. Calcular:

a) Probabilidad de que la cuasivarianza muestral esté comprendida entre 1,863 y 2,674.

Tenemos una m.a.s. $(X_1, X_2, X_3, X_4, X_5)$, todas ellas idénticamente distribuidas a $X \rightsquigarrow \mathcal{N}(2{,}5,\ 36)$. Tomamos la cuasivarianza de dichos datos:

$$S^2 = \frac{1}{n-1}\sum_{i=1}^{n}\left(X_i - \overline{X}\right)^2$$

Y queremos calcular la probabilidad:

$$P\left[1{,}863 < S^2 < 2{,}674\right]$$

Puesto que no es fácil obtener la distribución de S^2, vamos a usar la distribución χ^2 para calcular dicha probabilidad. Para ello, en teoría hemos visto que como estamos muestreando de una población normal, se cumple que:

$$\frac{(n-1)S^2}{\sigma^2} = \frac{4S^2}{36} \rightsquigarrow \chi^2(4) \equiv \chi^2(n-1)$$

Por tanto:

$$\begin{aligned} P[1{,}863 < S^2 < 2{,}674] &= P\left[\frac{4\cdot 1{,}863}{36} < \frac{4S^2}{36} < \frac{4\cdot 2{,}674}{36}\right] \\ &= P\left[0{,}207 < \frac{4S^2}{36} < 0{,}2971\right] \\ &= P\left[\frac{4S^2}{36} > 0{,}207\right] - P\left[\frac{4S^2}{36} > 0{,}2971\right] \end{aligned}$$

Si consultamos la tabla de la $\chi^2(4)$:

$$P\left[\frac{4S^2}{36} > 0{,}207\right] \approx 0{,}995, \qquad P\left[\frac{4S^2}{36} > 0{,}2971\right] \approx 0{,}99$$

Por lo que:

$$\begin{aligned} P[1{,}863 < S^2 < 2{,}674] &= P\left[\frac{4S^2}{36} > 0{,}207\right] - P\left[\frac{4S^2}{36} > 0{,}2971\right] \approx 0{,}995 - 0{,}99 \\ &= 0{,}005 \end{aligned}$$

b) Probabilidad de que la media muestral esté comprendida entre 1,3 y 3,5, supuesto que la cuasivarianza muestral está entre 30 y 40.

En la situación del apartado anterior, ahora tenemos también en consideración la media muestral:

$$\overline{X} = \frac{1}{n}\sum_{i=1}^{n} X_i$$

Bajo estas condiciones, el Lema de Fisher nos dice que S^2 y $\overline{X}$ son independientes, por lo que la probabilidad de que la media muestral esté comprendida entre 1,3 y 3,5 suponiendo que la cuasivarianza muestral está comprendida entre 30 y 40 es igual a la probabilidad de que la media muestral esté comprendida entre 1,3 y 3,5:

$$P[1{,}3 < \overline{X} < 3{,}5 \mid 30 < S^2 < 40] = P[1{,}3 < \overline{X} < 3{,}5]$$

Sabemos que $\overline{X} \rightsquigarrow \mathcal{N}\left(\mu, \frac{\sigma^2}{n}\right)$, nos disponemos a calcular dicha probabilidad:

$$\begin{aligned} P[1{,}3 < \overline{X} < 3{,}5] &\overset{\text{tipificamos}}{=} P\left[\frac{\sqrt{5}(1{,}3-2{,}5)}{\sqrt{36}} < Z < \frac{\sqrt{5}(3{,}5-2{,}5)}{\sqrt{36}}\right] \\ &= P[-0{,}447214 < Z < 0{,}372678] \\ &= P[Z < 0{,}372678] - P[Z > 0{,}447214] \\ &= P[Z < 0{,}372678] - 1 + P[Z < 0{,}447214] \\ &\approx 0{,}64431 - 1 + 0{,}67003 = 0{,}31434 \end{aligned}$$

Ejercicio 2.2.2. La longitud craneal en una determinada población humana es una variable aleatoria que sigue una distribución normal con media 185,6 mm y desviación típica 12,78 mm. ¿Cuál es la probabilidad de que una muestra aleatoria simple de tamaño 20 de esa población tenga media mayor que 190 mm?

Tenemos una población que sigue una variable aleatoria $X \rightsquigarrow \mathcal{N}(\mu, \sigma^2)$ con parámetros $\mu = 185{,}6$ y $\sigma = 12{,}78$. Tomamos una m.a.s. $(X_1, \ldots, X_n)$ con $n = 20$ y tomamos la media muestral:

$$\overline{X} = \frac{1}{n}\sum_{i=1}^{n}(X_i - \mu)^2$$

Queremos calcular:

$$P\left[\overline{X} > 190\right]$$

Para ello, sabemos por lo visto en teoría que $\overline{X} \rightsquigarrow \mathcal{N}\left(\mu, \frac{\sigma^2}{n}\right)$, por lo que:

$$\begin{aligned} P\left[\overline{X} > 190\right] &\overset{\text{tipificamos}}{=} P\left[Z > \frac{\sqrt{20}(190-185{,}6)}{12{,}78}\right] = P[Z > 1{,}5397] \\ &= 1 - P[Z < 1{,}5397] \approx 1 - 0{,}93822 = 0{,}06178 \end{aligned}$$

Ejercicio 2.2.3. ¿De qué tamaño mínimo habría que seleccionar una muestra de una variable con distribución normal $\mathcal{N}(\mu, 4)$ para poder afirmar, con probabilidad mayor que 0,9, que la media muestral diferirá de la poblacional menos de 0,1?

Supuesto que tenemos una m.a.s. $(X_1, \ldots, X_n)$ de tamaño $n \in \mathbb{N}$ de variables aleatorias idénticamente distribuidas a $X \rightsquigarrow \mathcal{N}(\mu, 4)$, queremos buscar el menor n de forma que:

$$0{,}9 < P\left[|\overline{X} - \mu| < 0{,}1\right]$$

Para ello, usaremos que hemos visto en teoría que $\overline{X} \rightsquigarrow \mathcal{N}\left(\mu, \frac{\sigma^2}{n}\right)$:

$$0{,}9 < P[|\overline{X} - \mu| < 0{,}1] = P[-0{,}1 < \overline{X} - \mu < 0{,}1] = P\left[\frac{-\sqrt{n}0{,}1}{2} < Z < \frac{\sqrt{n}0{,}1}{2}\right]$$
$$= P\left[-\sqrt{n}0{,}05 < Z < \sqrt{n}0{,}05\right] = 2P\left[Z < \sqrt{n}0{,}05\right] - 1$$

De donde:

$$0{,}95 = \frac{0{,}9+1}{2} < P[Z < \sqrt{n}0{,}05]$$

De donde mirando la tabla de la normal $\mathcal{N}(0,1)$:

$$\sqrt{n}0{,}05 \geqslant 1{,}65 \Longrightarrow n \geqslant \left(\frac{1{,}65}{0{,}05}\right)^2 = 1089$$

Por lo que habría que seleccionar como mínimo una muestra de tamaño 1089 para poder afirmar con probabilidad mayor que 0,9 que la media muestral difiere de la poblacional menos de 0,1.

Ejercicio 2.2.4. Sea $(X_1, \ldots, X_n)$ una muestra aleatoria simple de una variable con distribución normal. Calcular la probabilidad de que la cuasivarianza muestral sea menor que un 50 % de la varianza poblacional para $n = 16$ y para $n = 1000$.

Dicha muestra aleatoria simple es de variables idénticamente distribuidas a $X \rightsquigarrow \mathcal{N}(\mu, \sigma^2)$. Bajo estas condiciones, sabemos por lo visto en teoría que:

$$\frac{(n-1)S^2}{\sigma^2} \rightsquigarrow \chi^2(n-1)$$

Y queremos calcular:

$$P[S^2 < 0{,}5\sigma^2] = P\left[\frac{(n-1)S^2}{\sigma^2} < \frac{(n-1)0{,}5\cancel{\sigma^2}}{\cancel{\sigma^2}}\right] = 1 - P\left[\frac{(n-1)S^2}{\sigma^2} > (n-1)0{,}5\right]$$

- Para $n = 16$, mirando en la tabla de $\chi^2(15)$ tenemos que:

$$P[S^2 < 0{,}5\sigma^2] = 1 - P\left[\frac{(n-1)S^2}{\sigma^2} > 7{,}5\right] \approx 1 - 0{,}95 = 0{,}05$$

- Para $n = 1000$, no disponemos de tabla para $\chi^2(999)$, por lo que aproximaremos $\chi^2(999)$ por $\mathcal{N}(999, 2 \cdot 999) \equiv \mathcal{N}(999, 1998)$. De esta forma, si tomamos:

$$\frac{(n-1)S^2}{\sigma^2} \rightsquigarrow \chi^2(999) \approx \mathcal{N}(999, 1998)$$

Tenemos entonces que:

$$P[S^2 < 0{,}5\sigma^2] = P\left[\frac{(n-1)S^2}{\sigma^2} < \frac{(n-1)0{,}5\cancel{\sigma^2}}{\cancel{\sigma^2}}\right] = P\left[\frac{(n-1)S^2}{\sigma^2} < 499{,}5\right] \approx$$
$$\overset{\text{tipificamos}}{\approx} P\left[Z < \frac{499{,}5 - 999}{\sqrt{1998}}\right] = P[Z < -11{,}17] =$$
$$= 1 - P[Z < 11{,}17] \approx 1 - 1 = 0$$

Ejercicio 2.2.5. Sean S_1^2 y S_2^2 las cuasivarianzas muestrales de dos muestras independientes de tamaños $n_1 = 5$ y $n_2 = 4$ de dos poblaciones normales con la misma varianza. Calcular la probabilidad de que S_1^2/S_2^2 sea menor que 5,34 o mayor que 9,12.

Bajo estas hipótesis, sabemos por lo visto en teoría que (como $\sigma_1 = \sigma_2$):

$$\frac{S_1^2}{S_2^2} \rightsquigarrow F(n_1 - 1, n_2 - 1) \equiv F(4, 3)$$

Por tanto, notando $Y = \frac{S_1^2}{S_2^2}$ por comodidad, calculamos (son sucesos disjuntos):

$$P[Y < 5{,}34 \text{ o } Y > 9{,}12] = P[Y < 5{,}34] + P[Y > 9{,}12]$$

Observamos la tabla de $F(4, 3)$:

$$\begin{aligned} &P[Y < 5{,}34] \approx 0{,}9 \\ &P[Y > 9{,}12] \approx 1 - P[Y < 9{,}12] = 1 - 0{,}95 = 0{,}05 \end{aligned}$$

En definitiva:

$$P[Y < 5{,}34 \text{ o } Y > 9{,}12] = P[Y < 5{,}34] + P[Y > 9{,}12] \approx 0{,}95$$

Ejercicio 2.2.6. Se consideran dos poblaciones de bombillas cuyas longitudes de vida siguen una ley normal con la misma media y desviaciones típicas 425 y 375 horas, respectivamente. Con objeto de realizar un estudio comparativo de ambas poblaciones, se considera una muestra aleatoria simple de 10 bombillas en la primera población y una de tamaño 6 en la segunda. ¿Cuál es la probabilidad de que la media muestral del primer grupo menos la del segundo sea menor que la observada en dos realizaciones muestrales que dieron 1325 horas y 1215 horas, respectivamente?

Como describe el enunciado, tenemos una m.a.s. $(X_1, \ldots, X_n)$ de tamaño $n = 10$ de variables aleatorias idénticamente distribuidas a $X \rightsquigarrow \mathcal{N}\left(\mu, 425^2\right)$; y otra m.a.s. $(Y_1, \ldots, Y_m)$ de tamaño $m = 6$ de variables aleatorias idénticamente distribuidas a $Y \rightsquigarrow \mathcal{N}\left(\mu, 375^2\right)$. Nos piden calcular:

$$P[\overline{X} - \overline{Y} < 1325 - 1215]$$

Bajo estas condiciones, sabemos por lo visto en teoría que:

$$\frac{\overline{X} - \overline{Y}}{\sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}}} = \frac{\overline{X} - \overline{Y} - (\mu - \mu)}{\sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}}} \rightsquigarrow \mathcal{N}(0, 1)$$

De esta forma, si notamos a esta última variable como Z (pues es una normal estándar), tenemos que:

$$\begin{aligned} P[\overline{X} - \overline{Y} < 1325 - 1215] &= P\left[Z < \frac{1325 - 1215}{\sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}}}\right] = P\left[Z < \frac{1325 - 1215}{\sqrt{\frac{425^2}{10} + \frac{375^2}{6}}}\right] \\ &= P[Z < 0{,}5399] \approx 0{,}7054 \end{aligned}$$

Ejercicio 2.2.7. Sean $X_1, \ldots, X_n, X_{n+1}$ variables aleatorias independientes e idénticamente distribuidas según una $\mathcal{N}(\mu, \sigma^2)$, y sean $\overline{X}$ y S^2 la media y la cuasivarianza muestral de $(X_1, \ldots, X_n)$. Calcular la distribución de

$$\frac{X_{n+1} - \overline{X}}{S}\sqrt{\frac{n}{n+1}}$$

Bajo dichas hipótesis, tenemos:

$$\left.\begin{array}{l} X_{n+1} \rightsquigarrow \mathcal{N}(\mu, \sigma^2) \\ \overline{X} \rightsquigarrow \mathcal{N}\left(\mu, \frac{\sigma^2}{n}\right) \end{array}\right\} \Longrightarrow X_{n+1} - \overline{X} \rightsquigarrow \mathcal{N}\left(\mu - \mu, \sigma^2 + \frac{\sigma^2}{n}\right) \equiv \mathcal{N}\left(0, \sigma^2\left(1 + \frac{1}{n}\right)\right)$$

de donde, si tipificamos la variable:

$$\frac{X_{n+1} - \overline{X}}{\sqrt{\sigma^2\left(1 + \frac{1}{n}\right)}} = \frac{X_{n+1} - \overline{X}}{\sigma\sqrt{\frac{n+1}{n}}} = \frac{X_{n+1} - \overline{X}}{\sigma}\sqrt{\frac{n}{n+1}} \rightsquigarrow \mathcal{N}(0,1)$$

Notemos que esta distribución es similar a la que buscamos, salvo que en el denominador tenemos σ en lugar de S. Podemos emplear el siguiente resultado, visto en teoría, que relaciona la cuasivarianza muestral con la varianza poblacional:

$$\frac{(n-1)S^2}{\sigma^2} \rightsquigarrow \chi^2(n-1)$$

En vistas de aplicar la cosntrucción de la distribución t de Student, necesitamos que las variables aleatorias con las que trabajamos sean independientes. La primera es función de $\overline{X}$ y X_{n+1}, mientras que la segunda es función de S^2. Por tanto, nos basta con ver que $(\overline{X}, X_{n+1})$ es independiente de S^2. Esto se cumple, ya que $\overline{X}$ y S^2 son independientes por el Lema de Fisher, y X_{n+1} es independiente de $(X_1, \ldots, X_n)$, por lo que $(\overline{X}, X_{n+1})$ es independiente de S^2. Podemos por tanto aplicar la construccion de la distribución t de Student:

$$\left.\begin{array}{l} U \rightsquigarrow \mathcal{N}(0,1) \\ V \rightsquigarrow \chi^2(n) \\ U \text{ y } V \text{ independientes} \end{array}\right\} \Longrightarrow \frac{U}{\sqrt{V/n}} \rightsquigarrow t(n)$$

Si lo aplicamos a nuestras variables:

$$\frac{\frac{X_{n+1} - \overline{X}}{\sigma}\sqrt{\frac{n}{n+1}}}{\sqrt{\frac{(n-1)S^2}{\sigma^2(n-1)}}} = \frac{\frac{X_{n+1} - \overline{X}}{\sigma}\sqrt{\frac{n}{n+1}}}{\frac{S}{\sigma}} = \frac{X_{n+1} - \overline{X}}{S}\sqrt{\frac{n}{n+1}} \rightsquigarrow t(n-1)$$

Ejercicio 2.2.8. Sean $(X_1, \ldots, X_n)$, $(Y_1, \ldots, Y_m)$ muestras aleatorias simples independientes de poblaciones $\mathcal{N}(\mu_1, \sigma^2)$ y $\mathcal{N}(\mu_2, \sigma^2)$, respectivamente. Sean $\alpha, \beta \in \mathbb{R}$ y $\overline{X}, \overline{Y}, S_1^2, S_2^2$ las medias y cuasivarianzas de las dos muestras. Calcular la distribución de

$$\frac{\alpha\left(\overline{X} - \mu_1\right) + \beta\left(\overline{Y} - \mu_2\right)}{\sqrt{\frac{(n-1)S_1^2 + (m-1)S_2^2}{n+m-2}}\sqrt{\frac{\alpha^2}{n} + \frac{\beta^2}{m}}}$$

Sabemos que:

$$\left.\begin{array}{l}\overline{X} \rightsquigarrow \mathcal{N}\left(\mu_1, \frac{\sigma^2}{n}\right) \\ \overline{Y} \rightsquigarrow \mathcal{N}\left(\mu_2, \frac{\sigma^2}{m}\right)\end{array}\right\} \Longrightarrow \left.\begin{array}{l}\overline{X} - \mu_1 \rightsquigarrow \mathcal{N}\left(0, \frac{\sigma^2}{n}\right) \\ \overline{Y} - \mu_2 \rightsquigarrow \mathcal{N}\left(0, \frac{\sigma^2}{m}\right)\end{array}\right\} \Longrightarrow \left.\begin{array}{l}\alpha(\overline{X} - \mu_1) \rightsquigarrow \mathcal{N}\left(0, \frac{\alpha^2\sigma^2}{n}\right) \\ \beta(\overline{Y} - \mu_2) \rightsquigarrow \mathcal{N}\left(0, \frac{\beta^2\sigma^2}{m}\right)\end{array}\right\}$$

Como ambas son independientes, podemos aplicar la propeidad reproductiva de la normal:

$$\alpha(\overline{X} - \mu_1) + \beta(\overline{Y} - \mu_2) \rightsquigarrow \mathcal{N}\left(0, \frac{\alpha^2\sigma^2}{n} + \frac{\beta^2\sigma^2}{m}\right) \equiv \mathcal{N}\left(0, \sigma^2\left(\frac{\alpha^2}{n} + \frac{\beta^2}{m}\right)\right)$$

Si tipificamos la variable:

$$\frac{\alpha(\overline{X} - \mu_1) + \beta(\overline{Y} - \mu_2)}{\sigma\sqrt{\frac{\alpha^2}{n} + \frac{\beta^2}{m}}} \rightsquigarrow \mathcal{N}(0,1)$$

Por otra parte, tenemos que:

$$\frac{(n-1)S_1^2}{\sigma^2} \rightsquigarrow \chi^2(n-1), \qquad \frac{(m-1)S_2^2}{\sigma^2} \rightsquigarrow \chi^2(m-1)$$

Como ambas son independientes por ser S_1^2 y S_2^2 independientes (ya que las muestras aleatorias simples eran independientes), podemos aplicar la propiedad reproductiva de χ^2, obteniendo que:

$$\frac{(n-1)S_1^2}{\sigma^2} + \frac{(m-1)S_2^2}{\sigma^2} = \frac{(n-1)S_1^2 + (m-1)S_2^2}{\sigma^2} \rightsquigarrow \chi^2(n+m-2)$$

Finalmente, la extensión del Lema de Fisher nos dice que $(\overline{X}, \overline{Y})$ es independiente de (S_1^2, S_2^2), por lo que las dos variables aleatorias con las que trabajamos son independientes, lo que nos permite aplicar la construcción de la distribución t de Student:

$$\frac{\frac{\alpha(\overline{X} - \mu_1) + \beta(\overline{Y} - \mu_2)}{\cancel{\sigma}\sqrt{\frac{\alpha^2}{n} + \frac{\beta^2}{m}}}}{\sqrt{\frac{\frac{(n-1)S_1^2 + (m-1)S_2^2}{\cancel{\sigma^2}}}{n+m-2}}} = \frac{\alpha\left(\overline{X} - \mu_1\right) + \beta\left(\overline{Y} - \mu_2\right)}{\sqrt{\frac{(n-1)S_1^2 + (m-1)S_2^2}{n+m-2}}\sqrt{\frac{\alpha^2}{n} + \frac{\beta^2}{m}}} \rightsquigarrow t(n+m-2)$$

Ejercicios Adicionales

Ejercicio 2.2.9 (Reto)**.** Sea $(X_1, \ldots, X_{10})$ una muestra aleatoria simple de una variable con distribución normal $\mathcal{N}(5, \sigma^2)$ e $(Y_1, \ldots, Y_{10})$ una muestra aleatoria simple de una variable con distribución normal $\mathcal{N}(\mu_Y, \sigma^2)$, siendo ambas muestras independientes. Calcular:

$$P\left[\frac{\sum_{i=1}^{10}(X_i - 5)^2}{S_Y^2} > 31{,}4\right]$$

Buscamos obtener la distribución de la variable aleatoria:

$$\frac{\sum_{i=1}^{10}(X_i-5)^2}{S_Y^2}$$

Fijado $i \in \{1,\dots,10\}$, tenemos que $X_i \rightsquigarrow \mathcal{N}(5,\sigma^2)$, luego su variable tipificada $Z_i \rightsquigarrow \mathcal{N}(0,1)$, y por tanto, por la construcción de la distribución χ^2 a partir de variables normales, tenemos que:

$$\frac{1}{\sigma^2}\sum_{i=1}^{10}(X_i-5)^2 = \sum_{i=1}^{10} {Z_i}^2 \rightsquigarrow \chi^2(n)$$

Por otra parte, sabemos que:

$$\frac{(n-1)S_Y^2}{\sigma^2} \rightsquigarrow \chi^2(n-1)$$

Ahora, como las muestras aleatorias simples son independientes, S_Y^2 es independiente de $(X_1,\dots,X_{10})$, y por tanto, $\sum_{i=1}^{10}(X_i-5)^2$ es independiente de S_Y^2. Por tanto, podemos aplicar la construcción de la distribución F de Snedecor:

$$U := \frac{\frac{1}{\cancel{\sigma^2}}\sum_{i=1}^{10}(X_i-5)^2}{n} \cdot \frac{\cancel{n-1}}{\frac{(\cancel{n-1})S_Y^2}{\cancel{\sigma^2}}} = \frac{\sum_{i=1}^{10}(X_i-5)^2}{S_Y^2}\cdot\frac{1}{n} \rightsquigarrow F(n,n-1) \equiv F(10,9)$$

Por tanto, la probabilidad que nos piden es:

$$P\left[\frac{\sum_{i=1}^{10}(X_i-5)^2}{S_Y^2} > 31{,}4\right] = P\left[\frac{\sum_{i=1}^{10}(X_i-5)^2}{S_Y^2}\cdot\frac{1}{n} > \frac{31{,}4}{n}\right] = P\left[U > 3{,}14\right] =$$
$$= 1 - P[U < 3{,}14] = 1 - 0{,}95 = 0{,}05$$

Ejercicio 2.2.10. Sean $X_1, X_2, \dots, X_{12}$ una muestra aleatoria simple de una variable aleatoria con distribución $\mathcal{N}(\mu,\sigma^2)$.

Se divide la muestra en dos submuestras disjuntas de tamaños $n_1 = 4$ y $n_2 = 8$:

- Submuestra 1: $\{X_1,\dots,X_4\}$
- Submuestra 2: $\{X_5,\dots,X_{12}\}$

Se define el estadístico:

$$T = \frac{\sqrt{8}\,(\overline{X}_1 - \overline{X}_2)}{\sqrt{3\,S_1^2 + 7\,S_2^2}}.$$

1. Determinar razonadamente la distribución exacta de T, justificando la distribución del numerador, la del denominador y la independencia estocástica entre ambos.

   Para hallar la distribución exacta de T, puesto que en el denominador hay una raíz cuadrada, buscamos una construcción de la distribución t de Student:

   $$\left.\begin{array}{l} Z \rightsquigarrow \mathcal{N}(0,1) \\ V \rightsquigarrow \chi^2(k) \\ Z \text{ y } V \text{ independientes} \end{array}\right\} \Longrightarrow \frac{Z}{\sqrt{V/k}} \rightsquigarrow t(k)$$

   Puesto que $X \rightsquigarrow \mathcal{N}(\mu, \sigma^2)$, tenemos que:

   $$\overline{X}_1 \sim \mathcal{N}\left(\mu, \frac{\sigma^2}{4}\right), \qquad \overline{X}_2 \sim \mathcal{N}\left(\mu, \frac{\sigma^2}{8}\right).$$

   Al ser combinación lineal de normales independientes, la diferencia $\overline{X}_1 - \overline{X}_2$ es también una variable normal con parámetros:

   $$\mathbb{E}[\overline{X}_1 - \overline{X}_2] = \mathbb{E}[\overline{X}_1] - \mathbb{E}[\overline{X}_2] = \mu - \mu = 0,$$

   $$\mathrm{Var}(\overline{X}_1 - \overline{X}_2) = \mathrm{Var}(\overline{X}_1) + \mathrm{Var}(\overline{X}_2) = \frac{\sigma^2}{4} + \frac{\sigma^2}{8} = \frac{3\sigma^2}{8}.$$

   Tipificando la variable, obtenemos:

   $$Z = \frac{\overline{X}_1 - \overline{X}_2}{\sqrt{\frac{3\sigma^2}{8}}} = \frac{\sqrt{8}(\overline{X}_1 - \overline{X}_2)}{\sigma\sqrt{3}} \sim \mathcal{N}(0,1).$$

   Por teoría, sabemos que:

   $$\frac{(n_1-1)S_1^2}{\sigma^2} = \frac{3S_1^2}{\sigma^2} \sim \chi^2(3), \qquad \frac{(n_2-1)S_2^2}{\sigma^2} = \frac{7S_2^2}{\sigma^2} \sim \chi^2(7).$$

   Dado que provienen de submuestras disjuntas, S_1^2 y S_2^2 son mutuamente independientes. Por la propiedad aditiva de la distribución chi-cuadrado:

   $$V = \frac{3S_1^2}{\sigma^2} + \frac{7S_2^2}{\sigma^2} = \frac{3S_1^2 + 7S_2^2}{\sigma^2} \sim \chi^2(3+7) \equiv \chi^2(10).$$

   Por el Lema de Fisher, dentro de la primera submuestra $\overline{X}_1$ y S_1^2 son independientes. Análogamente, en la segunda submuestra $\overline{X}_2$ y S_2^2 son independientes. Como ambas submuestras proceden de elementos disjuntos de una m.a.s., el vector $(\overline{X}_1, \overline{X}_2)$ es independiente del vector (S_1^2, S_2^2). Por tanto, cualquier función medible de las medias (en particular $\overline{X}_1 - \overline{X}_2$) es independiente de cualquier función de las cuasivarianzas (en particular $3S_1^2 + 7S_2^2$).

   Construyendo el cociente:

   $$\frac{Z}{\sqrt{V/10}} = \frac{\frac{\sqrt{8}(\overline{X}_1 - \overline{X}_2)}{\sigma\sqrt{3}}}{\sqrt{\frac{3S_1^2 + 7S_2^2}{10\sigma^2}}} = \sqrt{\frac{10}{3}} \cdot \frac{\sqrt{8}(\overline{X}_1 - \overline{X}_2)}{\sqrt{3S_1^2 + 7S_2^2}} = \sqrt{\frac{10}{3}}\, T \sim t(10).$$

   En consecuencia:

   $$T = \sqrt{\frac{3}{10}}\, U, \quad \text{donde } U \sim t(10).$$

2. Expresar la suma total de cuadrados de las desviaciones Q en función de S_1^2, S_2^2 y $(\overline{X}_1 - \overline{X}_2)^2$:

$$Q = \sum_{i=1}^{12}(X_i - \overline{X})^2$$

La media muestral global es:

$$\overline{X} = \frac{1}{12}\left(\sum_{i=1}^{4} X_i + \sum_{i=5}^{12} X_i\right) = \frac{4\overline{X}_1 + 8\overline{X}_2}{12} = \frac{\overline{X}_1 + 2\overline{X}_2}{3}.$$

Descomponemos la suma total de cuadrados de desviaciones Q:

$$Q = \sum_{i=1}^{12}(X_i - \overline{X})^2 = \sum_{i=1}^{4}(X_i - \overline{X})^2 + \sum_{i=5}^{12}(X_i - \overline{X})^2.$$

Sumando y restando la media del grupo correspondiente dentro de cada sumatorio:

$$\sum_{i=1}^{4}(X_i - \overline{X})^2 = \sum_{i=1}^{4}\left[(X_i - \overline{X}_1) + (\overline{X}_1 - \overline{X})\right]^2 =$$
$$= \sum_{i=1}^{4}(X_i - \overline{X}_1)^2 + 4(\overline{X}_1 - \overline{X})^2 + 2(\overline{X}_1 - \overline{X})\sum_{i=1}^{4}(X_i - \overline{X}_1).$$

Puesto que el momento centrado de primer orden es cero, el término del doble producto se anula. Aplicando el mismo desarrollo al segundo bloque:

$$Q = \sum_{i=1}^{4}(X_i - \overline{X}_1)^2 + 4(\overline{X}_1 - \overline{X})^2 + \sum_{i=5}^{12}(X_i - \overline{X}_2)^2 + 8(\overline{X}_2 - \overline{X})^2.$$

Aplicando la definición de cuasivarianza muestral:

$$Q = 3S_1^2 + 7S_2^2 + 4(\overline{X}_1 - \overline{X})^2 + 8(\overline{X}_2 - \overline{X})^2.$$

Expresamos las desviaciones de las medias locales respecto a la media global:

$$\overline{X}_1 - \overline{X} = \overline{X}_1 - \frac{\overline{X}_1 + 2\overline{X}_2}{3} = \frac{2}{3}(\overline{X}_1 - \overline{X}_2),$$

$$\overline{X}_2 - \overline{X} = \overline{X}_2 - \frac{\overline{X}_1 + 2\overline{X}_2}{3} = -\frac{1}{3}(\overline{X}_1 - \overline{X}_2).$$

Sustituyendo estos valores:

$$4\left(\frac{2}{3}(\overline{X}_1 - \overline{X}_2)\right)^2 + 8\left(-\frac{1}{3}(\overline{X}_1 - \overline{X}_2)\right)^2 = \left(\frac{16}{9} + \frac{8}{9}\right)(\overline{X}_1 - \overline{X}_2)^2 = \frac{8}{3}(\overline{X}_1 - \overline{X}_2)^2.$$

Por tanto, la descomposición exacta de Q es:

$$Q = (3S_1^2 + 7S_2^2) + \frac{8}{3}(\overline{X}_1 - \overline{X}_2)^2.$$

3. Deducir la distribución exacta del estadístico:

$$W = \frac{\frac{8}{3}(\overline{X}_1 - \overline{X}_2)^2}{\frac{3S_1^2 + 7S_2^2}{10}}.$$

Del primer apartado, sabemos que:

$$Z = \frac{\sqrt{8}(\overline{X}_1 - \overline{X}_2)}{\sigma\sqrt{3}} \rightsquigarrow \mathcal{N}(0,1) \implies Z^2 \rightsquigarrow \chi^2(1),$$
$$V = \frac{3S_1^2 + 7S_2^2}{\sigma^2} \rightsquigarrow \chi^2(10),$$

y Z y V son independientes, luego Z^2 y V también lo son. Por tanto, podemos aplicar la construcción de la distribución F de Snedecor:

$$\left.\begin{array}{l} Z^2 \rightsquigarrow \chi^2(1) \\ V \rightsquigarrow \chi^2(10) \\ Z^2 \text{ y } V \text{ independientes} \end{array}\right\} \implies \frac{Z^2/1}{V/10} \rightsquigarrow F(1,10)$$

Calculamos el cociente de las variables aleatorias:

$$\frac{Z^2/1}{V/10} = \frac{\frac{\frac{8}{3}(\overline{X}_1 - \overline{X}_2)^2}{\cancel{\sigma^2}}}{\frac{\frac{3S_1^2 + 7S_2^2}{\cancel{\sigma^2}}}{10}} = \frac{\frac{8}{3}(\overline{X}_1 - \overline{X}_2)^2}{\frac{3S_1^2 + 7S_2^2}{10}} = W \rightsquigarrow F(1,10).$$

4. Calcular $P[W > 4{,}96]$.

Puesto que $W \rightsquigarrow F(1,10)$, calculamos la probabilidad solicitada empleando la tabla de la distribución F:

$$P[W > 4{,}96] = 1 - P[W \leq 4{,}96] = 1 - 0{,}95 = 0{,}05.$$

2.3. Suficiencia y completitud

Ejercicio 2.3.1. Sea $(X_1, \ldots, X_n)$ una muestra aleatoria simple de una variable $X \rightsquigarrow \{\mathcal{B}(k,p) : p \in]0,1[\}$ y sea $T(X_1, \ldots, X_n) = \sum_{i=1}^{n} X_i$. Probar que T es suficiente para p:

1. Usando la definición:

   Si notamos para abreviar $T = T(X_1, \ldots, X_n)$, tenemos que probar que la distribución de la muestra condicionada a cualquier valor del estadístico no depende del parámetro p para probar que T es suficiente para p. Para ello:

   $$P_p[X_1 = x_1, \ldots, X_n = x_n \mid T = t] = \frac{P_p[X_1 = x_1, \ldots, X_n = x_n, T = t]}{P_p[T = t]}$$
   $$= \begin{cases} 0 & \text{si } T(x_1, \ldots, x_n) \neq t \\ \dfrac{P_p[X_1 = x_1, \ldots, X_n = x_n]}{P_p[T = t]} & \text{si } T(x_1, \ldots, x_n) = t \end{cases}$$

   Como 0 obviamente no depende de p, el caso $T(x_1, \ldots, x_2) \neq t$ se encuentra ya estudiado, por lo que nos centramos en el caso $T(x_1, \ldots, x_2) = t$:

   $$\frac{P_p[X_1 = x_1, \ldots, X_n = x_n]}{P_p[T = t]} \overset{\text{iid.}}{=} \frac{\prod_{i=1}^{n} P_p[X = x_i]}{P_p[T = t]} \overset{(*)}{=} \frac{\prod_{i=1}^{n} \binom{k}{x_i} p^{x_i}(1-p)^{k-x_i}}{\binom{nk}{t} p^t (1-p)^{nk-t}}$$
   $$= \frac{p^{\sum_{i=1}^{n} x_i}(1-p)^{nk-\sum_{i=1}^{n} x_i} \prod_{i=1}^{n} \binom{k}{x_i}}{\binom{nk}{t} p^t (1-p)^{nk-t}} \overset{(**)}{=} \frac{\prod_{i=1}^{n} \binom{k}{x_i}}{\binom{nk}{t}}$$

   Donde en $(*)$ hemos usado que $(X_1, \ldots, X_n)$ es una m.a.s. (variables independientes) y la reproductividad de la Binomial, por lo que $T \rightsquigarrow \mathcal{B}(nk, p)$; y en $(**)$ hemos usado que $t = T(x_1, \ldots, x_n) = \sum_{i=1}^{n} x_i$. En definitiva, hemos obtenido que la distribución de la muestra condicionada a cualquier valor del estadístico no dependende del parámetro p, por lo que T es suficiente para p.

2. Aplicando el teorema de factorización:

   Si podemos usar el Teorema de factorización, escribimos la función masa de probabilidad de la distribución conjunta de la muestra aleatoria simple:

   $$P[X_1 = x_1, \ldots, X_n = x_n] \overset{\text{iid.}}{=} \prod_{i=1}^{n} P[X = x_i] = \prod_{i=1}^{n} \binom{k}{x_i} p^{x_i}(1-p)^{k-x_i}$$
   $$= p^{\sum_{i=1}^{n} x_i}(1-p)^{nk-\sum_{i=1}^{n} x_i} \prod_{i=1}^{n} \binom{k}{x_i}$$

   Si tomamos:

   $$h(x_1, \ldots, x_n) = \prod_{i=1}^{n} \binom{k}{x_i}, \qquad T(X_1, \ldots, X_n) = \sum_{i=1}^{n} X_i, \qquad g_p(t) = p^t (1-p)^{nk-t}$$

   Podemos aplicar el Teorema de Factorización de Neymann-Fisher, obteniendo que T es un estadístico suficiente para p.

Ejercicio 2.3.2. Sea $(X_1, \ldots, X_n)$ una muestra aleatoria simple de una variable $X \rightsquigarrow \{\mathcal{P}(\lambda) : \lambda \in \mathbb{R}^+\}$ y sea $T(X_1, \ldots, X_n) = \sum_{i=1}^{n} X_i$. Probar que T es suficiente para λ:

1. Usando la definición:

   Notando $T = T(X_1, \ldots, X_n)$, seguimos los mismos pasos que en el ejercicio anterior:

   $$P_\lambda[X_1 = x_1, \ldots, X_n = x_n \mid T = t] = \frac{P_\lambda[X_1 = x_1, \ldots, X_n = x_n, T = t]}{P_\lambda[T = t]}$$
   $$= \begin{cases} 0 & \text{si } T(x_1, \ldots, x_n) \neq t \\ \dfrac{P_\lambda[X_1 = x_1, \ldots, X_n = x_n]}{P_\lambda[T = t]} & \text{si } T(x_1, \ldots, x_n) = t \end{cases}$$

   Y ahora nos interesamos por el segundo término, que es el que puede depender de λ:

   $$\frac{P_\lambda[X_1 = x_1, \ldots, X_n = x_n]}{P_\lambda[T = t]} \overset{\text{iid.}}{=} \frac{\prod_{i=1}^{n} P_\lambda[X = x_i]}{P_\lambda[T = t]} \overset{(*)}{=} \frac{\prod_{i=1}^{n} e^{-\lambda}\frac{\lambda^{x_i}}{x_i!}}{e^{-n\lambda}\frac{(n\lambda)^t}{t!}} = \frac{e^{-n\lambda} \cdot \frac{\lambda^{\sum_{i=1}^{n} x_i}}{\prod_{i=1}^{n} x_i!}}{e^{-n\lambda} \cdot \frac{n^t\lambda^t}{t!}}$$
   $$\overset{(**)}{=} \frac{t!}{n^t \prod_{i=1}^{n} x_i!}$$

   Donde en $(*)$ usamos que $T \rightsquigarrow \mathcal{P}(n\lambda)$, por la reproductividad de la Poisson y en $(**)$ usamos que $t = T(x_1, \ldots, x_n) = \sum_{i=1}^{n} x_i$. Obtenemos una cantidad que no depende de λ, por lo que T es suficiente para λ.

2. Aplicando el teorema de factorización:

   Si podemos aplicar el Teorema de factorización, escribimos:

   $$P_\lambda[X_1 = x_1, \ldots, X_n = x_n] \overset{\text{iid.}}{=} \prod_{i=1}^{n} P_\lambda[X = x_i] = \prod_{i=1}^{n} e^{-\lambda}\frac{\lambda^{x_i}}{x_i!} = e^{-n\lambda} \cdot \frac{\lambda^{\sum_{i=1}^{n} x_i}}{\prod_{i=1}^{n} x_i!}$$

   Si tomamos:

   $$h(x_1, \ldots, x_n) = \frac{1}{\prod_{i=1}^{n} x_i!}, \qquad T(X_1, \ldots, X_n) = \sum_{i=1}^{n} X_i, \qquad g_\lambda(t) = e^{-n\lambda} \cdot \lambda^t$$

   Por el Teorema de Factorización de Neymann-Fisher obtenemos que T es suficiente para λ.

Ejercicio 2.3.3. Sea (X_1, X_2, X_3) una muestra aleatoria simple de una variable $X \rightsquigarrow \{\mathcal{B}(1,p) : p \in]0,1[\}$. Probar que el estadístico $X_1+2X_2+3X_3$ no es suficiente.

Consideramos el estadístico $T(X_1, X_2, X_3) = X_1+2X_2+3X_3$. El espacio muestral de X es $\mathcal{X} = \{0,1\}$, por lo que el espacio muestral de T es $\mathcal{T} = \{0,1,2,3,4,5,6\}$. Sabemos por un ejemplo visto en teoría que el "truco" para demostrar que $T(X_1, X_2, X_3)$ no es suficiente para p es buscar un valor del espacio muestral $\mathcal{T}$ que provenga de varias combinaciones de estados del espacio muestral $\mathcal{X}^3$. Como $0, 1, 2$ solo provienen de una combinación del espacio muestral $\mathcal{X}^3$ (son $(0,0,0)$, $(1,0,0)$ y $(0,1,0)$ respectivamente), probamos buscar el contraejemplo con $t = 3$, que proviene de considerar las observaciones de la muestra $(1,1,0)$ y $(0,0,1)$.

Una vez explicado el procedimiento para buscar cuál es el valor de t que funciona, procedemos a probar que la distribución de la muestra condicionada a dicho valor de t depende del parámetro p. Para ello:

$$P_p[X_1 = x_1, X_2 = x_2, X_3 = x_3 \mid T = 3] = \frac{P_p[X_1 = x_1, X_2 = x_2, X_3 = x_3, T = 3]}{P_p[T = 3]}$$
$$= \begin{cases} 0 & \text{si } T(x_1, x_2, x_2) \neq 3 \\ \dfrac{P_p[X_1 = x_1, X_2 = x_2, X_3 = x_3]}{P_p[T = 3]} & \text{si } T(x_1, x_2, x_3) = 3 \end{cases}$$

Vemos que el primer caso no puede depender nunca de p, por lo que buscamos probar que el segundo caso sí que depende de p. Para ello:

$$\frac{P_p[X_1 = x_1, X_2 = x_2, X_3 = x_3]}{P_p[T = 3]} \overset{\text{iid.}}{=} \frac{P_p[X = x_1]P_p[X = x_2]P_p[X = x_3]}{P_p[T = 3]}$$
$$\overset{(*)}{=} \frac{p^{x_1}(1-p)^{1-x_1}p^{x_2}(1-p)^{1-x_2}p^{x_3}(1-p)^{1-x_3}}{P_p[X_1 = 1, X_2 = 1, X_3 = 0] + P_p[X_1 = 0, X_2 = 0, X_3 = 1]}$$
$$= \frac{p^{x_1}(1-p)^{1-x_1}p^{x_2}(1-p)^{1-x_2}p^{x_3}(1-p)^{1-x_3}}{p \cdot p \cdot (1-p) + (1-p)(1-p)p}$$

Donde en $(*)$ se ha usado la propiedad reproductiva de la Binomial, por lo que $T \rightsquigarrow \mathcal{B}(3,p)$, así como que la condición $t = 3$ provenía de los valores $(1,1,0)$ y $(0,0,1)$. Ahora, si tomamos $(x_1, x_2, x_3) = (1,1,0)$, tenemos que:

$$\frac{P_p[X_1 = 1, X_2 = 1, X_3 = 0]}{P_p[T = 3]} = \frac{p^1(1-p)^0p^1(1-p)^0p^0(1-p)^1}{p \cdot p \cdot (1-p) + (1-p)(1-p)p}$$
$$= \frac{pp(1-p)}{pp(1-p) + (1-p)(1-p)p}$$
$$= \frac{p^2(1-p)}{p(1-p)\cancel{(p+1-p)}^{1}} = p$$

Que claramente depende de p, por lo que T no es suficiente para p.

Ejercicio 2.3.4. Aplicando el teorema de factorización, y basándose en una muestra de tamaño arbitrario, encontrar un estadístico suficiente para cada una de las siguientes familias de distribuciones (en las familias biparamétricas, suponer los casos de sólo un parámetro desconocido y de los dos desconocidos).

a) $X \rightsquigarrow \{\mathcal{U}(-\theta/2, \theta/2) : \theta > 0\}$

b) $X \rightsquigarrow \{\Gamma(p, a) : p, a > 0\}$

c) $X \rightsquigarrow \{\beta(p, q) : p, q > 0\}$

d) $X \rightsquigarrow \{P_{N_1,N_2} : N_1, N_2 \in \mathbb{N}, N_1 \leqslant N_2\}$ y la masa de probabilidad viene dada por:

$$P_{N_1,N_2}[X = x] = \frac{1}{N_2 - N_1 + 1} \qquad x \in \{N_1, \dots, N_2\}$$

En lo que sigue, supondremos que tenemos una m.a.s. $(X_1, \dots, X_n)$ de variables idénticamente distribuidas a la respectiva variable X:

a) Si $X \rightsquigarrow \mathcal{U}(-\theta/2, \theta/2)$ con $\theta > 0$:

$$f(x_1, \dots, x_n) \overset{\text{iid.}}{=} \prod_{i=1}^{n} f(x_i) = \prod_{i=1}^{n} \frac{1}{\theta} = \frac{1}{\theta^n} \qquad x_i \in \,]-\theta/2, \theta/2[\,, \quad \forall i \in \{1, \dots, n\}$$

Por lo que tendremos $-\theta/2 < X_{(1)} \leqslant X_{(n)} < \theta/2$:

$$f(x_1, \dots, x_n) = \frac{1}{\theta^n} \, \mathrm{I}_{]0,+\infty[}(X_{(1)} + \theta/2) \, \mathrm{I}_{]-\infty,0[}(X_{(n)} - \theta/2)$$

Si tomamos:

$$h(x_1, \dots, x_n) = 1, \qquad T(X_1, \dots, X_n) = (X_{(1)}, X_{(n)})$$
$$g_\theta(t_1, t_2) = \frac{1}{\theta^n} \, \mathrm{I}_{]0,+\infty[}(t_1 + \theta/2) \, \mathrm{I}_{]-\infty,0[}(t_2 - \theta/2)$$

Por el Teorema de factorización, tenemos que $T(X_1, \dots, X_n)$ es un estadístico suficiente para θ.

b) Si $X \rightsquigarrow \Gamma(p, a)$ con $p, a > 0$:

$$f(x_1, \dots, x_n) \overset{\text{iid.}}{=} \prod_{i=1}^{n} f(x_i) = \prod_{i=1}^{n} \frac{a^p}{\Gamma(p)} x_i^{p-1} e^{-a x_i} = \left(\frac{a^p}{\Gamma(p)}\right)^n e^{-a \sum_{i=1}^{n} x_i} \prod_{i=1}^{n} x_i^{p-1}$$
$$= \left(\frac{a^p}{\Gamma(p)}\right)^n e^{-a \sum_{i=1}^{n} x_i} \left(\prod_{i=1}^{n} x_i\right)^{p-1} \qquad x_i \geqslant 0 \qquad \forall i \in \{1, \dots, n\}$$

- Suponiendo que p es conocida, podemos tomar:

$$h(x_1, \dots, x_n) = \left(\prod_{i=1}^{n} x_i\right)^{p-1}, \qquad T(X_1, \dots, X_n) = \sum_{i=1}^{n} X_i$$
$$g_a(t) = \left(\frac{a^p}{\Gamma(p)}\right)^n e^{-at}$$

- Suponiendo ahora que a es conocida:

$$h(x_1, \dots, x_n) = e^{-a \sum_{i=1}^{n} x_i}, \qquad T(X_1, \dots, X_n) = \prod_{i=1}^{n} x_i$$
$$g_p(t) = \left(\frac{a^p}{\Gamma(p)}\right)^n t^{p-1}$$

- Si ahora tanto p como a son desconocidas, podemos tomar:

$$h(x_1,\dots,x_n)=1, \qquad T(X_1,\dots,X_n)=\left(\sum_{i=1}^n X_i, \prod_{i=1}^n X_i\right)$$
$$g_{(a,p)}(t_1,t_2)=\left(\frac{a^p}{\Gamma(p)}\right)^n e^{-at_1}t_2^{p-1}$$

c) Si $X \rightsquigarrow \beta(p,q)$ con $p,q>0$:

$$f(x_1,\dots,x_n) \overset{\text{iid.}}{=} \prod_{i=1}^n f(x_i) = \prod_{i=1}^n \frac{1}{\beta(p,q)} x_i^{p-1}(1-x_i)^{q-1}$$
$$= \frac{1}{\beta(p,q)^n}\left(\prod_{i=1}^n x_i\right)^{p-1}\left(\prod_{i=1}^n (1-x_i)\right)^{q-1} \qquad x_i\in[0,1], \forall i\in\{1,\dots,n\}$$

- Si p es conocida, tomamos:

$$h(x_1,\dots,x_n)=\left(\prod_{i=1}^n x_i\right)^{p-1}, \qquad T(X_1,\dots,X_n)=\prod_{i=1}^n (1-X_i)$$
$$g_q(t)=\frac{1}{\beta(p,q)^n}t^{q-1}$$

- Si q es conocida:

$$h(x_1,\dots,x_n)=\left(\prod_{i=1}^n (1-x_i)\right)^{q-1}, \qquad T(X_1,\dots,X_n)=\prod_{i=1}^n X_i$$
$$g_p(t)=\frac{1}{\beta(p,q)^n}t^{p-1}$$

- Si tanto p como q son parámetros:

$$h(x_1,\dots,x_n)=1, \qquad T(X_1,\dots,X_n)=\left(\prod_{i=1}^n X_i, \prod_{i=1}^n (1-X_i)\right)$$
$$g_{(p,q)}(t_1,t_2)=\frac{1}{\beta(p,q)^n}t_1^{p-1}t_2^{q-1}$$

d) Si $X \rightsquigarrow P_{N_1,N_2}$ con $N_1,N_2\in\mathbb{N}$, $N_1\leqslant N_2$, entonces:

$$P[X_1=x_1,\dots,X_n=x_n] \overset{\text{iid.}}{=} \prod_{i=1}^n P[X=x_i] = \prod_{i=1}^n \frac{1}{N_2-N_1+1}$$
$$= \frac{1}{(N_2-N_1+1)^n}, \quad x_i\in\{N_1,\dots N_2\}$$

Como se tiene $N_1\leqslant X_{(1)}\leqslant X_{(n)}\leqslant N_2$, entonces:

$$P[X_1=x_1,\dots,X_n=x_n]=\frac{\mathrm{I}_{\mathbb{N}_0}(X_{(1)}-N_1)\,\mathrm{I}_{-\mathbb{N}_0}(X_{(n)}-N_2)}{(N_2-N_1+1)^n}$$

- Si N_1 es conocido:

$$h(x_1,\dots,x_n) = \mathrm{I}_{\mathbb{N}_0}(X_{(1)} - N_1), \qquad T(X_1,\dots,X_n) = X_{(n)}$$
$$g_{N_2}(t) = \frac{\mathrm{I}_{-\mathbb{N}_0}(t - N_2)}{(N_2 - N_1 + 1)^n}$$

- Si N_2 es conocida:

$$h(x_1,\dots,x_n) = \mathrm{I}_{-\mathbb{N}_0}(X_{(n)} - N_2), \qquad T(X_1,\dots,X_n) = X_{(1)}$$
$$g_{N_1}(t) = \frac{\mathrm{I}_{\mathbb{N}_0}(t - N_1)}{(N_2 - N_1 + 1)^n}$$

- Si tanto N_1 como N_2 son parámetros:

$$h(x_1,\dots,x_n) = 1, \qquad T(X_1,\dots,X_n) = \big(X_{(1)}, X_{(n)}\big)$$
$$g_{(N_1,N_2)}(t_1,t_2) = \frac{\mathrm{I}_{\mathbb{N}_0}(t_1 - N_1)\,\mathrm{I}_{-\mathbb{N}_0}(t_2 - N_2)}{(N_2 - N_1 + 1)^n}$$

Por lo que en cualquier caso obtenemos un estadístico suficiente, por el Teorema de Factorización.

Ejercicio 2.3.5. Sea $X \rightsquigarrow \{P_N : N \in \mathbb{N}\}$, siendo P_N la distribución uniforme en los puntos $\{1,\dots,N\}$, y sea $(X_1,\dots,X_n)$ una muestra aleatoria simple de X. Probar que máx$(X_1,\dots,X_n)$ es un estadístico suficiente y completo.

Buscamos aplicar el Teorema de factorización de Neymann-Fisher:

$$P[X_1 = x_1,\dots,X_n = x_n] \overset{\text{iid.}}{=} \prod_{i=1}^{n} P[X = x_i] = \prod_{i=1}^{n} \frac{1}{N}, \quad x_i \in \{1,\dots,N\}, \forall i \in \{1,\dots,n\}$$

Por lo que $1 \leqslant X_{(1)} \leqslant X_{(n)} \leqslant N$:

$$P[X_1 = x_1,\dots,X_n = x_n] = \frac{\mathrm{I}_{\mathbb{N}_0}(X_{(1)} - 1)\,\mathrm{I}_{-\mathbb{N}_0}(X_{(n)} - N)}{N^n}$$

De donde podemos tomar:

$$h(x_1,\dots,x_n) = \mathrm{I}_{\mathbb{N}_0}(X_{(1)} - 1), \qquad T(X_1,\dots,X_n) = X_{(n)}$$
$$g_N(t) = \frac{\mathrm{I}_{-\mathbb{N}_0}(t - N)}{N^n}$$

Por el Teorema de factorización de Neymann-Fisher, tenemos que el estadístico $T(X_1,\dots,X_n) = X_{(n)}$ es suficiente. Comprobamos que también es completo: sea g cualquier función medible, supongamos que (abreviaremos $T(X_1,\dots,X_n) = T$):

$$0 = E[g(T)] = \sum_{t=1}^{N} g(t)P[T = t] \qquad \forall N \in \mathbb{N}$$

Calculamos la función masa de probabilidad de T:

$$F_T(t) = (F_X(t))^n \Longrightarrow P[T = t] = P[T \leqslant t] - P[T \leqslant t-1] = (F_X(t))^n - (F_X(t-1))^n$$

Como $F_X(t) = \frac{t}{N}$, tenemos entonces que:

$$P[T = t] = (F_X(t))^n - (F_X(t-1))^n = \frac{t^n}{N^n} - \frac{(t-1)^n}{N^n} = \frac{t^n - (t-1)^n}{N^n}$$

Por lo que:

$$0 = E[g(T)] = \sum_{t=1}^{N} g(t)\frac{t^n - (t-1)^n}{N^n} = \frac{1}{N^n}\sum_{t=1}^{N} g(t)(t^n - (t-1)^n) \qquad \forall N \in \mathbb{N}$$

de donde:

$$\sum_{t=1}^{N} g(t)(t^n - (t-1)^n) = 0 \qquad \forall N \in \mathbb{N}$$

Puesto que la potencia $n-$ésima es una función estrictamente creciente en el intervalo $[0, +\infty[$, tenemos que $t^n - (t-1)^n > 0$ para todo $t \in \mathbb{N}$. Para que una suma de términos positivos sea cero, todos los sumandos han de ser cero, por lo que $g(t) = 0$ para todo $t \in \mathbb{N}$. En definitiva, tenemos que:

$$\mathbb{N} \subseteq \{t : g(t) = 0\}$$

Por lo que:

$$1 \geqslant P[g(T) = 0] \geqslant P[T \in \mathbb{N}] = 1 \Longrightarrow P[g(T) = 0] = 1$$

Lo que demuestra que $X_{(n)}$ es completo.

Ejercicio 2.3.6. Basándose en una muestra de tamaño arbitrario, obtener un estadístico suficiente y completo para la familia de distribuciones definidas por todas las densidades de la forma

$$f_\theta(x) = e^{\theta - x}, \qquad x > \theta$$

Sea $(X_1, \ldots, X_n)$ una m.a.s. de tamaño $n \in \mathbb{N}$:

$$f_\theta(x_1, \ldots, x_n) \overset{\text{iid.}}{=} \prod_{i=1}^{n} f_\theta(x_i) = \prod_{i=1}^{n} e^{\theta - x_i} = e^{n\theta - \sum_{i=1}^{n} x_i} = \frac{e^{n\theta}}{e^{\sum_{i=1}^{n} x_i}}, \quad x_i > \theta \ \forall i \in \{1, \ldots, n\}$$

Por lo que ha de ser $\theta < X_{(1)}$:

$$f_\theta(x_1, \ldots, x_n) = \frac{e^{n\theta} \cdot \mathrm{I}_{]0,\infty[}(X_{(1)} - \theta)}{e^{\sum_{i=1}^{n} x_i}} \qquad x_i \in \mathbb{R}, \forall i \in \{1, \ldots, n\}$$

Si tomamos:

$$h(x_1, \ldots, x_n) = e^{-\sum_{i=1}^{n} x_i}, \qquad T(X_1, \ldots, X_n) = X_{(1)}$$
$$g_\theta(t) = e^{n\theta} \cdot \mathrm{I}_{]0,\infty[}(t - \theta)$$

Por el Teorema de factorización de Neymann-Fisher tenemos que el estadístico $X_{(1)}$ es suficiente para θ. Comprobemos si es completo: sea g cualquier función medible, suponemos que (y escribimos $T = T(X_1, \ldots, X_n)$ para abreviar):

$$0 = E[g(T)] = \int_\theta^{+\infty} g(t) f_T(t)\ dt \qquad \forall \theta \in \mathbb{R}$$

Como $T = X_{(1)}$, tenemos que:

$$F_T(t) = 1 - (1 - F_\theta(t))^n \Longrightarrow f_T(t) = n(1 - F_\theta(t))^{n-1} f_\theta(t)$$

donde:

$$F_\theta(t) = \int_\theta^t e^{\theta - x}\ dx = \left[-e^{\theta - x}\right]_\theta^t = 1 - e^{\theta - t}, \qquad t > \theta$$

por lo que:

$$f_T(t) = n\left(e^{\theta - t}\right)^{n-1} e^{\theta - t} = n\left(e^{\theta - t}\right)^n, \qquad t > \theta$$

volviendo al caso que nos interesa:

$$0 = E[g(T)] = \int_\theta^{+\infty} g(t) n\left(e^{\theta - t}\right)^n\ dt = n e^{n\theta} \int_\theta^{+\infty} g(t) e^{-nt}\ dt \qquad \forall \theta \in \mathbb{R}$$

por lo que:

$$\int_\theta^{+\infty} g(t) e^{-nt}\ dt = 0 \qquad \forall \theta \in \mathbb{R}$$

Por simplicidad de cálculos, supondremos que g es continua, con lo que si $G(t)$ es una primitiva de $g(t)e^{-nt}$, entonces:

$$\int_\theta^{+\infty} g(t) e^{-nt}\ dt = \lim_{n \to \infty} \int_\theta^n g(t) e^{-nt}\ dt = \lim_{n \to \infty} G(n) - G(\theta) = 0 \qquad \forall \theta \in \mathbb{R}$$

Si derivamos ahora respecto a θ, tenemos que:

$$-g(\theta) e^{-n\theta} = 0 \qquad \forall \theta \in \mathbb{R}$$

con lo que $g(\theta) = 0 \quad \forall \theta \in \mathbb{R}$. Es decir:

$$\mathbb{R} \subseteq \{t : g(t) = 0\}$$

luego:

$$1 \geqslant P[g(T) = 0] \geqslant P[T \in \mathbb{R}] = 1 \Longrightarrow P[g(T) = 0] = 1$$

por lo que T es completo.

Ejercicio 2.3.7. Comprobar que las siguientes familias de distribuciones son exponenciales uniparamétricas y, considerando una muestra aleatoria simple de una variable con distribución en dicha familia, obtener, si existe, un estadístico suficiente y completo.

a) $\{\mathcal{B}(k_0, p) : 0 < p < 1\}$

Comprobamos todas las condiciones:

1. El espacio paramétrico es: $]0,1[$ intervalo de $\mathbb{R}$.
2. El espacio muestral es $\mathcal{X} = \{0, \dots, k_0\}$, que no depende de p.
3. Para la tercera condición:

$$\begin{aligned} P[X = x]_p &= \binom{k_0}{x} p^x (1-p)^{k_0 - x} = \exp\left[\ln\left(\binom{k_0}{x} p^x (1-p)^{k_0-x}\right)\right] \\ &= \exp\left[\ln\binom{k_0}{x} + x\ln p + (k_0 - x)\ln(1-p)\right] \\ &= \exp\left[\ln\binom{k_0}{x} + x\ln p + k_0\ln(1-p) - x\ln(1-p)\right] \\ &= \exp\left[\ln\binom{k_0}{x} + k_0\ln(1-p) + x\ln\left(\frac{p}{1-p}\right)\right] \end{aligned}$$

Tomando:

$$\begin{aligned} T(x) &= x, & S(x) &= \ln\binom{k_0}{x} \\ Q(p) &= \ln\left(\frac{p}{1-p}\right), & D(p) &= k_0\ln(1-p) \end{aligned}$$

obtenemos la tercera condición.

Sea $(X_1, \dots, X_n)$ una m.a.s. de variables aleatorias idénticamente distribuidas a $X \rightsquigarrow \mathcal{B}(k_0, p)$ con $p \in]0,1[$, el Teorema visto en teoría para las familias de distribuciones exponenciales nos dice que el estadístico:

$$T = T(X_1, \dots, X_n) = \sum_{i=1}^n T(X_i) = \sum_{i=1}^n X_i$$

es suficiente para p. Para ver que T es también completo, hemos de ver que $\operatorname{Im} Q$ contiene un abierto de $\mathbb{R}$:

Opción 1. Como $Q :]0,1[\to \mathbb{R}$ es continua y definida sobre un conexo (un intervalo), su imagen ha de ser un conexo. Como en $\mathbb{R}$ los únicos conjuntos conexos son los intervalos y los puntos, y Q es claramente no constante, su imagen ha de ser un intervalo, que es un abierto de $\mathbb{R}$, por lo que T es completo.

Opción 2.

$$\operatorname{Im} Q = \left\{\ln\left(\frac{p}{1-p}\right) : p \in]0,1[\right\}$$

Definimos la siguiente función:

$$\begin{aligned} f : \ ]0,1[&\longrightarrow \mathbb{R}^+ \\ t &\longmapsto \frac{t}{1-t} \end{aligned}$$

- Está bien definida, puesto que si $t \in]0,1[$, entonces $1 - t > 0$, con lo que $f(t) \in \mathbb{R}^+$.

- Sea $y \in \mathbb{R}^+$, tenemos que:

$$\frac{t}{1-t} = y \iff t = y(1-t) \iff t = y - yt \iff t(1+y) = y \iff t = \frac{y}{y+1} < 1$$

Por lo que $f(t) = y$ con $t \in]0,1[$, con lo que f es sobreyectiva.

Por tanto, $\operatorname{Im} f = \mathbb{R}^+$, de donde deducimos que:

$$\operatorname{Im} Q = \left\{ \ln\left(\frac{p}{1-p}\right) : p \in]0,1[\right\} = \{\ln(f(p)) : p \in]0,1[\} = \ln(\operatorname{Im} f) = \ln(\mathbb{R}^+) = \mathbb{R}$$

Como obviamente $\mathbb{R}$ contiene algún abierto de $\mathbb{R}$, deducimos que T era un estadístico completo.

b) $\{\mathcal{P}(\lambda) : \lambda > 0\}$

Comprobamos las condiciones:

1. El espacio paramétrico es $\mathbb{R}^+$ intervalo de $\mathbb{R}$.
2. El espacio muestral es $\mathcal{X} = \mathbb{N} \cup \{0\}$, que no depende de λ.
3. Para la tercera condición:

$$P_\lambda[X = x] = e^{-\lambda}\frac{\lambda^x}{x!} = \exp\left[\ln\left(e^{-\lambda}\frac{\lambda^x}{x!}\right)\right] = \exp[-\lambda + x\ln\lambda - \ln(x!)]$$

Tomando:

$$\begin{aligned} T(x) &= x, & S(x) &= -\ln(x!) \\ Q(\lambda) &= \ln\lambda, & D(\lambda) &= -\lambda \end{aligned}$$

obtenemos la tercera condición.

Sea $(X_1, \ldots, X_n)$ una m.a.s. de variables aleatorias idénticamente distribuidas a $X \rightsquigarrow \mathcal{P}(\lambda)$ con $\lambda \in \mathbb{R}^+$, el Teorema visto en teoría para las familias de distribuciones exponenciales nos dice que el estadístico:

$$T = T(X_1, \ldots, X_n) = \sum_{i=1}^n T(X_i) = \sum_{i=1}^n X_i$$

es suficiente para λ. Para ver que T es también completo, hemos de ver que $\operatorname{Im} Q$ contiene un abierto de $\mathbb{R}$. Como:

$$\operatorname{Im} Q = \{\ln(\lambda) : \lambda \in \mathbb{R}^+\} = \ln(\mathbb{R}^+) = \mathbb{R}$$

Tenemos que $\operatorname{Im} Q = \mathbb{R}$ claramente contiene un abierto de $\mathbb{R}$, por lo que T es completo.

c) $\{BN(k_0, p) : 0 < p < 1\}$

Comprobamos las condiciones:

1. El espacio paramétrico es $]0,1[$ intervalo de $\mathbb{R}$.

2. El espacio muestral es $\mathcal{X} = \mathbb{N} \cup \{0\}$, que no depende de p.
3. Para la tercera condición:

$$P_p[X = x] = \binom{x + k_0 - 1}{x}(1-p)^x p^{k_0} = \exp\left[\ln\left(\binom{x + k_0 - 1}{x}(1-p)^x p^{k_0}\right)\right]$$
$$= \exp\left[\ln\binom{x + k_0 - 1}{x} + x\ln(1-p) + k_0 \ln p\right]$$

Tomando:

$$T(x) = x, \qquad S(x) = \ln\binom{x + k_0 - 1}{x}$$
$$Q(p) = \ln(1-p), \qquad D(p) = k_0 \ln p$$

Obtenemos la tercera condición.

Sea $(X_1, \ldots, X_n)$ una m.a.s. de variables aleatorias idénticamente distribuidas a $X \rightsquigarrow BN(k_0, p)$ con $p \in]0,1[$, el Teorema visto en teoría para las familias de distribuciones exponenciales nos dice que el estadístico:

$$T = T(X_1, \ldots, X_n) = \sum_{i=1}^{n} T(X_i) = \sum_{i=1}^{n} X_i$$

es suficiente para p. Para ver que T es también completo, hemos de ver que $\operatorname{Im} Q$ contiene un abierto de $\mathbb{R}$. Como $Q :]0,1[\to \mathbb{R}$ es una función continua, no constante y definida en un intervalo, tenemos que su imagen es un intervalo, por lo que contiene abiertos de $\mathbb{R}$, de donde T es completo.

d) $\{\exp(\lambda) : \lambda > 0\}$

Comprobamos las condiciones:

1. El espacio paramétrico es $\mathbb{R}^+$ intervalo de $\mathbb{R}$.
2. El espacio muestral es $\mathcal{X} = \mathbb{R}^+$, que no depende de λ.
3. Para la tercera condición:

$$f_\lambda(x) = \lambda e^{-\lambda x} = \exp\left[\ln\left(\lambda e^{-\lambda x}\right)\right] = \exp\left[\ln(\lambda) - \lambda x\right]$$

Tomando:

$$T(x) = x, \qquad S(x) = 0$$
$$Q(\lambda) = -\lambda, \qquad D(\lambda) = \ln(\lambda)$$

tenemos la tercera condición.

Sea $(X_1, \ldots, X_n)$ una m.a.s. de variables aleatorias idénticamente distribuidas a $X \rightsquigarrow \exp(\lambda)$ con $\lambda \in \mathbb{R}^+$, el Teorema visto en teoría para las familias de distribuciones exponenciales nos dice que el estadístico:

$$T = T(X_1, \ldots, X_n) = \sum_{i=1}^{n} T(X_i) = \sum_{i=1}^{n} X_i$$

es suficiente para λ. Para ver que T es también completo, hemos de ver que $\operatorname{Im} Q$ contiene un abierto de $\mathbb{R}$. Como $Q : \mathbb{R}^+ \to \mathbb{R}$ es una función continua, no constante y definida en un intervalo, tenemos que su imagen es un intervalo, por lo que contiene abiertos de $\mathbb{R}$, de donde T es completo.

Ejercicio 2.3.8. Estudiar si las siguientes familias de distribuciones son exponenciales biparamétricas. En caso afirmativo, considerando una muestra aleatoria simple de una variable con distribución en dicha familia, obtener, si existe, un estadístico suficiente y completo.

a) $\{\Gamma(p,a) : p, a > 0\}$

Comprobamos las condiciones:

1. El espacio paramétrico es $\mathbb{R}^+ \times \mathbb{R}^+$ intervalo de $\mathbb{R}^2$.
2. El espacio muestral es $\mathbb{R}^+$, que no depende de p ni de a.
3. Para la tercera condición:

$$\begin{aligned} f_{(p,a)}(x) = \frac{a^p}{\Gamma(p)} x^{p-1} e^{-ax} &= \exp\left[\ln\left(\frac{a^p}{\Gamma(p)} x^{p-1} e^{-ax}\right)\right] \\ &= \exp\left[\ln\left(\frac{a^p}{\Gamma(p)}\right) + (p-1)\ln x - ax\right] \end{aligned}$$

Tomando:

$$\begin{aligned} T_1(x) = \ln x, \qquad & T_2(x) = x, \qquad & S(x) = 0 \\ Q_1(p,a) = (p-1), \qquad & Q_2(p,a) = -a, \qquad & D(p,a) = \ln\left(\frac{a^p}{\Gamma(p)}\right) \end{aligned}$$

Tenemos la tercera condición.

Sea $(X_1, \ldots, X_n)$ una m.a.s. de variables aleatorias idénticamente distribuidas a $X \rightsquigarrow \Gamma(p,a)$ con $p, a \in \mathbb{R}^+$, el Teorema visto en teoría para las familias de distribuciones exponenciales multiparamétricas nos dice que el estadístico:

$$T = T(X_1, \ldots, X_n) = \left(\sum_{i=1}^n T_1(X_i), \sum_{i=1}^n T_2(X_i)\right) = \left(\sum_{i=1}^n \ln(X_i), \sum_{i=1}^n X_i\right)$$

es suficiente para (p,a). Para ver que T es también completo, hemos de ver que $\operatorname{Im} Q$ contiene un abierto de $\mathbb{R}^2$, donde $Q : (\mathbb{R}^+)^2 \to \mathbb{R}^2$, con $Q = (Q_1, Q_2)$. Para ello:

$$\begin{aligned} \operatorname{Im} Q = \left\{(p-1, -a) : (p,a) \in (\mathbb{R}^+)^2\right\} &= \{(x-1, y) : x \in \mathbb{R}^+, y \in \mathbb{R}^-\} \\ &=]-1, +\infty[\times \mathbb{R}^- \end{aligned}$$

Como claramente $]-1, +\infty[\times \mathbb{R}^-$ contiene un abierto de $\mathbb{R}^2$, tenemos que T es completo.

Además, puesto que la suma de logaritmos es el logaritmo del producto y la exponencial es una función biyectiva, podemos tomar como estadístico suficiente y completo:

$$T(X_1, \ldots, X_n) = \left(\prod_{i=1}^n X_i, \sum_{i=1}^n X_i\right)$$

b) $\{\beta(p,q) : p,q > 0\}$

Comprobamos las condiciones:

1. El espacio paramétrico es $\mathbb{R}^+ \times \mathbb{R}^+$ intervalo de $\mathbb{R}^2$.
2. El espacio muestral es $[0,1]$, que no depende de p ni de q.
3. Para la tercera condición:

$$f_{(p,q)}(x) = \frac{1}{\beta(p,q)} x^{p-1}(1-x)^{q-1} = \exp\left[\ln\left(\frac{1}{\beta(p,q)} x^{p-1}(1-x)^{q-1}\right)\right]$$
$$= \exp\left[\ln\left(\frac{1}{\beta(p,q)}\right) + (p-1)\ln x + (q-1)\ln(1-x)\right]$$

Tomando:

$$T_1(x) = \ln x, \qquad T_2(x) = \ln(1-x), \qquad S(x) = 0$$
$$Q_1(p,q) = p-1, \qquad Q_2(p,q) = q-1, \qquad D(p,q) = \ln\left(\frac{1}{\beta(p,q)}\right)$$

Tenemos la tercera condición.

Sea $(X_1, \ldots, X_n)$ una m.a.s. de variables aleatorias idénticamente distribuidas a $X \rightsquigarrow \beta(p,q)$ con $p,q \in \mathbb{R}^+$, el Teorema visto en teoría para las familias de distribuciones exponenciales multiparamétricas nos dice que el estadístico:

$$T = T(X_1, \ldots, X_n) = \left(\sum_{i=1}^n T_1(X_i), \sum_{i=1}^n T_2(X_i)\right) = \left(\sum_{i=1}^n \ln(X_i), \sum_{i=1}^n \ln(1-X_i)\right)$$

es suficiente para (p,q). Para ver que T es también completo, hemos de ver que $\operatorname{Im} Q$ contiene un abierto de $\mathbb{R}^2$, donde $Q : (\mathbb{R}^+)^2 \to \mathbb{R}^2$, con $Q = (Q_1, Q_2)$. Para ello:

$$\operatorname{Im} Q = \{(p-1, q-1) : p,q \in \mathbb{R}^+\} =]-1, +\infty[\times]-1, +\infty[$$

Como claramente este conjunto contiene un abierto de $\mathbb{R}^2$, tenemos que T es completo. De esta forma, podemos tomar como estadístico suficiente y completo:

$$T(X_1, \ldots, X_n) = \left(\prod_{i=1}^n X_i, \prod_{i=1}^n (1-X_i)\right)$$

Ejercicios Adicionales

Ejercicio 2.3.9. Sea $X_1, X_2, \ldots, X_n$ una muestra aleatoria simple de una variable aleatoria continua X con distribución de Rayleigh de parámetro $\theta > 0$ desconocido, cuya función de densidad viene dada por:

$$f_\theta(x) = \frac{x}{\theta^2} \exp\left(-\frac{x^2}{2\theta^2}\right), \quad x > 0.$$

1. Demostrar que la familia de distribuciones $\{f_\theta : \theta \in \mathbb{R}^+\}$ es una familia exponencial uniparamétrica.

   Comprobamos las condiciones de la definición de familia exponencial uniparamétrica:

   - El espacio paramétrico es $\Theta = \mathbb{R}^+$ intervalo de $\mathbb{R}$.
   - El espacio muestral es $\mathcal{X} = \mathbb{R}^+$, el cual no depende del parámetro θ.
   - Para cada $\theta \in \Theta$ y $x \in \mathcal{X}$, expresamos la función de densidad en forma exponencial:

   $$f_\theta(x) = \frac{x}{\theta^2}\exp\left(-\frac{x^2}{2\theta^2}\right) = \exp\left(\ln\left(\frac{x}{\theta^2}\exp\left(-\frac{x^2}{2\theta^2}\right)\right)\right) = \\ = \exp\left(-\frac{1}{2\theta^2}x^2 - 2\ln(\theta) + \ln(x)\right).$$

   Identificando términos con la estructura canónica:

   $$Q(\theta) = -\frac{1}{2\theta^2}, \quad T(x) = x^2, \quad D(\theta) = -2\ln(\theta), \quad S(x) = \ln(x).$$

   Por tanto, la familia $\{f_\theta : \theta > 0\}$ es una familia exponencial uniparamétrica.

2. Obtener de forma justificada un estadístico suficiente y completo para el parámetro θ.

   Aplicamos el teorema de las familias exponenciales para muestras aleatorias simples:

   - Al ser la familia individual exponencial uniparamétrica, el estadístico:

   $$T^*(X_1, \ldots, X_n) = \sum_{i=1}^n T(X_i) = \sum_{i=1}^n X_i^2$$

   es suficiente para el parámetro θ.
   - Para la completitud, como Q es una función continua y no constante definida en un intervalo, su imagen $\operatorname{Im} Q$ contiene un abierto de $\mathbb{R}$. Por lo tanto, el estadístico $T^*(X_1, \ldots, X_n)$ también es completo para θ.

   En consecuencia, por el teorema de las familias exponenciales, el estadístico $T^*(X_1, \ldots, X_n) = \sum_{i=1}^n X_i^2$ es suficiente y completo para θ.