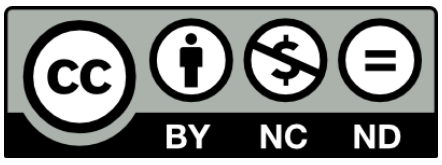
Inferencia Estadística



Los Del DGIIM, losdeldgiim.github.io

Doble Grado en Ingeniería Informática y Matemáticas
Universidad de Granada



Esta obra está bajo una Licencia Creative Commons Atribución-NoComercial-SinDerivadas 4.0 Internacional (CC BY-NC-ND 4.0).

Eres libre de compartir y redistribuir el contenido de esta obra en cualquier medio o formato, siempre y cuando des el crédito adecuado a los autores originales y no persigas fines comerciales.

Inferencia Estadística

Los Del DGIIM, losdeldgiim.github.io

José Juan Urrutia Milán

Granada, 2025

Índice general

1. Ejercicios de clase **5**
1.1. Estadísticos muestrales 5
1.2. Distribuciones en el muestreo de poblaciones normales 10
1.2.1. Muestreo en una población normal unidimensional 12
1.2.2. Muestreo en dos poblaciones normales unidimensionales 16
1.3. Suficiencia y completitud 20
1.4. Estimación puntual. Insesgadez y mínima varianza 32
1.5. Estimación de máxima verosimilitud y otros métodos 52
1.6. Estimación por intervalos de confianza 65

2. Relaciones de Ejercicios **69**
2.1. Estadísticos muestrales 69
2.2. Distribuciones en el muestreo de poblaciones normales 84
2.3. Suficiencia y completitud 94
2.4. Estimación puntual. Insesgadez y mínima varianza 110
2.5. Estimación de máxima verosimilitud y otros métodos 134

1. Ejercicios de clase

Este capítulo tiene el propósito de recoger todos los ejercicios propuestos en clase por parte de la profesora que acompañan a los contenidos teóricos. No se pretende que sean ejercicios de examen, sino que son ejercicios de práctica para afianzar los conceptos teóricos.

1.1. Estadísticos muestrales

Ejemplo. Obtener la función masa de probabilidad conjunta de una m.a.s. de $X \rightsquigarrow \mathcal{B}(k_0, p)$ y la función de densidad de una m.a.s. de $X \rightsquigarrow U(a, b)$.

Recordamos que si $X \rightsquigarrow \mathcal{B}(k_0, p)$, entonces:

$$P[X = x] = \binom{k_0}{x} p^x (1-p)^{n-x} \qquad \forall x \in \{0, \dots, k_0\}$$

Por lo que si tenemos una m.a.s. de n variables independientes e idénticamente distribuidas a X, $(X_1, \dots, X_n)$, su función de densidad vendrá dada por:

$$\begin{aligned} P[X_1 = x_1, \dots, X_n = x_n] &\overset{\text{indep.}}{=} \prod_{i=1}^{n} P[X_i = x_i] \overset{\text{id. d.}}{=} \prod_{i=1}^{n} P[X = x_i] \\ &= \prod_{i=1}^{n} \binom{k_0}{x_i} p^{x_i} (1-p)^{k_0 - x_i} = p^{\sum_{i=1}^{n} x_i} (1-p)^{nk_0 - \sum_{i=1}^{n} x_i} \prod_{i=1}^{n} \binom{k_0}{x_i} \\ &\quad \forall x_i \in \{0, \dots, k_0\} \end{aligned}$$

Si ahora $X \rightsquigarrow U(a, b)$ para ciertos $a, b \in \mathbb{R}$ con $a < b$, entonces:

$$f_X(x) = \frac{1}{b-a} \qquad \forall x \in [a, b]$$

de donde:

$$f_{(X_1,\dots,X_n)}(x_1, \dots, x_n) \overset{\text{indep.}}{=} \prod_{i=1}^{n} f_{X_i}(x_i) \overset{\text{id. d.}}{=} \prod_{i=1}^{n} f_X(x_i) = \prod_{i=1}^{n} \frac{1}{b-a} = \frac{1}{(b-a)^n} \qquad \forall x \in [a, b]$$

Ejemplo. Para cada realización muestral, $(x_1, \dots, x_n) \in \mathcal{X}^n$, $F^*_{x_1,\dots,x_n}$ es una función de distribución en $\mathbb{R}$. En particular es una función a saltos, con saltos de amplitud $1/n$ en los sucesivos valores muestrales ordenados de menor a mayor, supuestos que

sean distintos, y de saltos múltiplos en el caso de que varios valores muestrales coincidieran.

En las condiciones del enunciado, es decir, suponiendo que $x_1, \ldots, x_n$ están ordenados de menor a mayor y son distintos, entonces es fácil ver que:

$$F^*_{x_1,\ldots,x_n}(x) = \begin{cases} 0 & \text{si } x < x_1 \\ 1/n & \text{si } x_1 \leqslant x < x_2 \\ & \vdots \\ 1 & \text{si } x > x_n \end{cases} \qquad \forall x \in \mathbb{R}$$

Por lo que es claro que $F^*_{x_1,\ldots,x_n}$ es no decreciente, continua por la derecha, con límite 0 en $-\infty$ y con límite 1 en $+\infty$.

Ejemplo. Para todo $x \in \mathbb{R}$, $F^*_{X_1,\ldots,X_n}(x)$ es una variable aleatoria tal que $nF^*_{X_1,\ldots,X_n}(x) \rightsquigarrow \mathcal{B}(n, F(x))$ y:

$$E[F^*_{X_1,\ldots,X_n}(x)] = F(x), \qquad Var[F^*_{X_1,\ldots,X_n}(x)] = \frac{F(x)(1-F(x))}{n}$$

donde $F(x)$ es la función de distribución de X.

Recordamos que:

$$F^*_{X_1,\ldots,X_n}(x) = \frac{1}{n}\sum_{i=1}^{n} I_{]-\infty,x]}(X_i) \qquad \forall x \in \mathbb{R}$$

Fijado $x \in \mathbb{R}$, tenemos que $I_{]-\infty,x]}(X) \rightsquigarrow \mathcal{B}(1, P[X \leqslant x]) \equiv \mathcal{B}(1, F(x))$, por lo que por la propiedad reproductiva de la binomial tenemos que:

$$nF^*_{X_1,\ldots,X_n}(x) \rightsquigarrow \mathcal{B}(n, F(x))$$

Por lo que:

$$nE[F^*_{X_1,\ldots,X_n}(x)] = E[nF^*_{X_1,\ldots,X_n}(x)] = nF(x) \Longrightarrow E[F^*_{X_1,\ldots,X_n}(x)] = F(x)$$

Para la varianza:

$$n^2 Var[F^*_{X_1,\ldots,X_n}(x)] = Var[nF^*_{X_1,\ldots,X_n}(x)] = nF(x)(1-F(x)) \Longrightarrow$$
$$\Longrightarrow Var[F^*_{X_1,\ldots,X_n}(x)] = \frac{F(x)(1-F(x))}{n}$$

Ejemplo. Para valores grandes de n, en virtual del Teorema Central del Límite:

$$F^*_{X_1,\ldots,X_n}(x) \rightsquigarrow \mathcal{N}\left(F(x), \frac{F(x)(1-F(x))}{n}\right)$$

Sea $(X_1, \ldots, X_n)$ una m.a.s. de n muestras, sea:

$$S_n = \sum_{i=1}^{n} I_{]-\infty,x]}(X_i) \qquad \forall n \in \mathbb{N}$$

Por el Teorema Central del Límite tenemos que:

$$\frac{S_n - E[S_n]}{\sqrt{Var[S_n]}} \overset{n\to\infty}{\rightsquigarrow} \mathcal{N}(0,1) \Longrightarrow S_n \overset{n\to\infty}{\rightsquigarrow} \mathcal{N}\left(E[S_n], Var[S_n]\right)$$

Como $S_n \rightsquigarrow \mathcal{B}(n, F(x))$, entonces tenemos que:

$$\begin{aligned} E[S_n] &= nF(x) \\ Var[S_n] &= nF(x)(1-F(x)) \end{aligned}$$

Por lo que:

$$F^*_{X_1,\ldots,X_n}(x) = \frac{1}{n} S_n \overset{n\to\infty}{\rightsquigarrow} \mathcal{N}\left(F(x), \frac{F(x)(1-F(x))}{n}\right)$$

Ejemplo. Dada una muestra aleatoria simple formada por las observaciones $(3, 8, 5, 4, 5)$, obtener su función de distribución muestral y realizar la representación gráfica.

Aplicando la definición de la función de distribución muestral obtenemos que:

$$F^*_{(3,8,5,4,5)}(x) = \begin{cases} 0 & \text{si } x < 3 \\ 1/5 & \text{si } 3 \leqslant x < 4 \\ 2/5 & \text{si } 4 \leqslant x < 5 \\ 4/5 & \text{si } 5 \leqslant x < 8 \\ 1 & \text{si } x \geqslant 8 \end{cases}$$

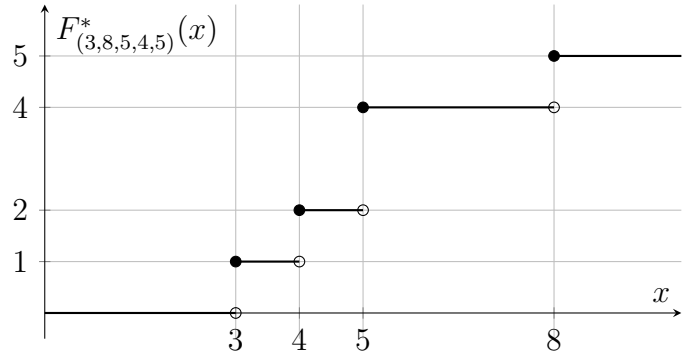


Figura 1.1: Representación gráfica de $F^*_{(3,8,5,4,5)}(x)$.

Ejemplo. Sea X una variable aleatoria con distribución $\mathcal{B}(1,p)$ con $p \in (0,1)$. Se toma una muestra de tamaño 5, $(X_1, X_2, X_3, X_4, X_5)$, y se obtiene la siguiente observación $(0, 1, 1, 0, 0)$. Determinar el valor de los estadísticos estudiados en la observación.

Aplicando las fórmulas vistas en clase obtenemos:

- Media:

$$\overline{X} = \frac{0+1+1+0+0}{5} = 0{,}4$$

- Varianza muestral:

$$\sigma^2 = \frac{(0-0{,}4)^2 + (1-0{,}4)^2 + (1-0{,}4)^2 + (0-0{,}4)^2 + (0-0{,}4)^2}{5} = \frac{1{,}2}{5} = 0{,}24$$

- Cuasivarianza:

$$s^2 = \frac{(0-0{,}4)^2 + (1-0{,}4)^2 + (1-0{,}4)^2 + (0-0{,}4)^2 + (0-0{,}4)^2}{5-1} = \frac{1{,}2}{4} = 0{,}3$$

- Estadísticos ordenados:

$$x_{(1)} = 0, \quad x_{(2)} = 0, \quad x_{(3)} = 0, \quad x_{(4)} = 1, \quad x_{(5)} = 1$$

Ejemplo. Sea $(X_1, \ldots, X_n)$ una m.a.s. y $\overline{X} = \dfrac{1}{n}\sum_{i=1}^{n} X_i$, entonces:

$$M_{\overline{X}}(t) = (M_X(t/n))^n$$

$$M_{\overline{X}}(t) = E\left[e^{t\overline{X}}\right] = E\left[e^{\frac{t}{n}\sum_{i=1}^{n} X_i}\right] = M_{\sum_{i=1}^{n} X_i}\left(\frac{t}{n}\right) \overset{\text{indep.}}{=} \prod_{i=1}^{n} M_{X_i}\left(\frac{t}{n}\right) \overset{\text{id. d.}}{=} \left(M_X\left(\frac{t}{n}\right)\right)^n$$

Ejemplo. Obtener la distribución muestral de $\overline{X}$ para $(X_1, \ldots, X_n)$ una m.a.s. de $X \rightsquigarrow \mathcal{N}(\mu, \sigma^2)$.

$$M_{\overline{X}}(t) = \left(M_X\left(\frac{t}{n}\right)\right)^n = \left(e^{\frac{\mu t}{n} + \frac{\sigma^2 t^2}{2n^2}}\right)^n = e^{\mu t + \frac{\sigma^2 t^2}{2n}}$$

Luego $\overline{X} \rightsquigarrow \mathcal{N}\left(\mu, \frac{\sigma^2}{n}\right)$, ya que la función generatriz de momentos caracteriza la distribución.

Proposición 1.1.1. Si tenemos una m.a.s. $(X_1, \ldots, X_n)$, entonces:

$$F_{X_{(n)}}(x) = (F_X(x))^n \qquad \forall x \in \mathbb{R}$$
$$F_{X_{(1)}}(x) = 1 - (1 - F_X(x))^n$$

Demostración. Para la distribución del máximo:

$$F_{X_{(n)}}(x) = P[X_{(n)} \leqslant x] = P[X_1 \leqslant x, \ldots, X_n \leqslant x] \overset{\text{indep.}}{=} \prod_{i=1}^{n} P[X_i \leqslant x]$$
$$\overset{\text{id. d.}}{=} \prod_{i=1}^{n} P[X \leqslant x] = (F_X(x))^n$$

Para la del mínimo:

$$F_{X_{(1)}}(x) = P[X_{(1)} \leqslant x] = 1 - P[X_{(1)} > x] = 1 - P[X_1 > x, \ldots, X_n > x]$$
$$\overset{\text{indep.}}{=} 1 - \prod_{i=1}^{n} P[X_i > x] \overset{\text{id. d.}}{=} 1 - (P[X > x])^n = 1 - (1 - F_X(x))^n$$

□

Ejemplo. Obtener las distribuciones muestrales de $X_{(1)}$ y $X_{(n)}$ para $X \rightsquigarrow U(a,b)$.

Si $X \rightsquigarrow U(a,b)$, entonces:

$$F_X(x) = \frac{x-a}{b-a} \qquad \forall x \in [a,b]$$

Por lo que aplicando la Proposición superior:

$$F_{X_{(n)}}(x) = (F_X(x))^n = \left(\frac{x-a}{b-a}\right)^n \qquad \forall x \in [a,b]$$

$$F_{X_{(1)}}(x) = 1-(1-F_X(x))^n = 1-\left(1-\frac{x-a}{b-a}\right)^n = 1-\left(\frac{b-x}{b-a}\right)^n \qquad \forall x \in [a,b]$$

Ejemplo. Sea $(X_1,\ldots,X_n)$ una m.a.s. de X. Entonces, para los momentos no centrados de orden k de la m.a.s. se tiene que:

$$E\left[A_k\right] = E[X^k]$$
$$Var\left[A_k\right] = \frac{Var[X^k]}{n}$$

Demostremos la primera igualdad:

$$E\left[A_k\right] = E\left[\frac{1}{n}\sum_{i=1}^n X_i^k\right] = \frac{1}{n}\sum_{i=1}^n E[X_i^k] \overset{\text{id. d.}}{=} \frac{1}{n}\sum_{i=1}^n E[X^k] = E[X^k]$$

Demostremos la segunda igualdad:

$$Var\left[A_k\right] = Var\left[\frac{1}{n}\sum_{i=1}^n X_i^k\right] = \frac{1}{n^2}Var\left[\sum_{i=1}^n X_i^k\right] \overset{\text{indep.}}{=} \frac{1}{n^2}\sum_{i=1}^n Var[X_i^k] \overset{\text{id. d.}}{=}$$
$$\overset{\text{id. d.}}{=} \frac{1}{n^2}\sum_{i=1}^n Var[X^k] = \frac{Var[X^k]}{n}$$

1.2. Distribuciones en el muestreo de poblaciones normales

Proposición 1.2.2. Sea $X \rightsquigarrow \mathcal{N}(0,1)$, entonces $X^2 \rightsquigarrow \chi^2(1)$.

Demostración. Sea $Y = X^2 = h(X)$, entonces $X = \pm\sqrt{Y} = h^{-1}(y)$, por lo que:

$$f_Y(y) = f_X(h_1^{-1}(y)) \left| \frac{dh_1^{-1}(y)}{dy} \right| + f_X(h_2^{-1}(y)) + \left| \frac{dh_2^{-1}(y)}{dy} \right|$$

Como $X \rightsquigarrow \mathcal{N}(0,1)$, entonces:

$$f_X(x) = \frac{1}{\sqrt{2\pi}} e^{\frac{-x^2}{2}} \qquad \forall x \in \mathbb{R}$$

De donde:

$$f_Y(y) = \frac{1}{\sqrt{2\pi}} e^{\frac{-(\sqrt{y})^2}{2}} \left| \frac{1}{2\sqrt{y}} \right| + \frac{1}{\sqrt{2\pi}} e^{\frac{-(-\sqrt{y})^2}{2}} \left| \frac{-1}{2\sqrt{y}} \right| = \frac{1}{\sqrt{2\pi y}} e^{\frac{-y}{2}} \qquad \forall y > 0$$

Por lo que $Y \rightsquigarrow \chi^2(1)$. □

Ejemplo. Calcula el valor de k o la probabilidad inducida:

a) $P[\chi^2(10) \geqslant k] = 0{,}005$.

Consultando la tabla de la distribución χ^2, obtenemos que $k = 25{,}1881$.

b) $P[\chi^2(45) \leqslant k] = 0{,}005$.

Tenemos que:

$$P[\chi^2(45) \leqslant k] = 1 - P[\chi^2(45) \geqslant k] = 0{,}005 \Longrightarrow P[\chi^2(45) \geqslant k] = 0{,}995$$

Consultando la tabla de la distribución χ^2, obtenemos que $k = 24{,}3110$.

c) $P[\chi^2(14) \geqslant 21{,}06]$

En este caso, no podemos consultar de forma directa los encabezados de la tabla de la distribución χ^2 y obtener el valor de la probabilidad, sino que tenemos que buscar qué columna de la tabla contiene el valor buscado. Podemos ver que:

$$P[\chi^2(14) \geqslant 21{,}06] \approx 0{,}1$$

d) $P[\chi^2(20) \leqslant 12{,}44]$

Tenemos que:

$$P[\chi^2(20) \leqslant 12{,}44] = 1 - P[\chi^2(20) \geqslant 12{,}44] \overset{(*)}{=} 1 - 0{,}9 = 0{,}1$$

donde en $(*)$ hemos consultado la tabla de la distribución χ^2.

Ejemplo. Calcula el valor de k o la probabilidad inducida:

a) $P[t(26) \geqslant k] = 0{,}05$

Consultando la tabla de la distribución t de Student, obtenemos que $k = 1{,}706$.

b) $P[t(20) \leqslant k] = 0{,}25$

Por la simetría de la distribución t de Student, tenemos que:

$$0{,}25 = P[t(20) \leqslant k] = P[t(20) \geqslant -k]$$

Consultando la tabla de la distribución t de Student, obtenemos que $-k = 0{,}6870$, luego $k = -0{,}6870$.

c) $P[t(26) \geqslant k] = 0{,}9$

Tenemos que:

$$0{,}9 = P[t(26) \geqslant k] = 1 - P[t(26) \leqslant k] = 1 - P[t(26) \geqslant -k] \Longrightarrow P[t(26) \geqslant -k] = 0{,}1$$

Consultando la tabla de la distribución t de Student, obtenemos que $-k = 1{,}3150$, luego $k = -1{,}3150$.

d) $P[t(21) \geqslant 1{,}721]$

Consultando la tabla de la distribución t de Student, obtenemos que:

$$P[t(21) \geqslant 1{,}721] \approx 0{,}05$$

e) $P[t(11) \leqslant 0{,}697]$

Consultando la tabla de la distribución t de Student, obtenemos que:

$$P[t(11) \leqslant 0{,}697] = 1 - P[t(11) \geqslant 0{,}697] \approx 1 - 0{,}25 = 0{,}75$$

f) $P[t(8) \leqslant -2{,}306]$

Tenemos que:

$$P[t(8) \leqslant -2{,}306] = P[t(8) \geqslant 2{,}306] = 0{,}025$$

Ejemplo. Calcula el valor de k o la probabilidad inducida:

a) $P[F(7,3) \leqslant k] = 0{,}95$

Consultando de manera directa la tabla de la distribución F de Snedecor, obtenemos que $k = 8{,}89$.

b) $P[F(8,4) \geqslant k] = 0{,}01$

$$0{,}01 = P[F(8,4) \geqslant k] = 1 - P[F(8,4) \leqslant k] \Longrightarrow P[F(8,4) \leqslant k] = 0{,}99$$

Consultando la tabla de la distribución F de Snedecor, obtenemos que $k = 14{,}8$.

c) $P[F(2,2) \leqslant 19]$

Consultando la tabla de la distribución F de Snedecor, obtenemos que:

$$P[F(2,2) \leqslant 19] = 0{,}95$$

d) $P[F(3,5) \geqslant 12{,}1]$

$$P[F(3,5) \geqslant 12{,}1] = 1 - P[F(3,5) \leqslant 12{,}1] \overset{(*)}{=} 1 - 0{,}99 = 0{,}01$$

donde en $(*)$ hemos consultado la tabla de la distribución F de Snedecor.

e) $P[F(60,40) \leqslant k] = 0{,}05$

Consultando la tabla de la distribución F de Snedecor, obtenemos que $k = 0{,}627$.

1.2.1. Muestreo en una población normal unidimensional

En lo que sigue, sea una $(X_1, \ldots, X_n)$ m.a.s. con $X \rightsquigarrow \mathcal{N}(\mu, \sigma^2)$.

Proposición 1.2.3. En dichas condiciones, veamos que:

$$\overline{X}, (X_1 - \overline{X}, \ldots, X_n - \overline{X}) \text{ son independientes}$$

Demostración. Para ellos, usaremos la caracterización de independencia de vectores aleatorios por la función generatriz de momentos conjunta. Es decir, buscamos probar

$$M_{\overline{X}, X_1 - \overline{X}, \ldots, X_n - \overline{X}}(t, t_1, \ldots, t_n) \overset{?}{=} M_{\overline{X}}(t) M_{X_1 - \overline{X}, \ldots, X_n - \overline{X}}(t_1, \ldots, t_n)$$

Por la reproductividad de la normal, todas las variables aleatorias que aparecen son normales, luego su función característica de momentos está definida en todo $\mathbb{R}$.

Por tanto, para todo $(t, t_1, \ldots, t_n) \in \mathbb{R}^{n+1}$, tenemos que:

$$
\begin{aligned}
M_{\overline{X}, X_1-\overline{X}, \ldots, X_n-\overline{X}}(t, t_1, \ldots, t_n) &= E\left[e^{(t,t_1,\ldots,t_n)\cdot(\overline{X}, X_1-\overline{X}, \ldots, X_n-\overline{X})}\right] = E\left[e^{t\overline{X}+\sum_{i=1}^{n}(X_i-\overline{X})t_i}\right] = \\
&= E\left[e^{\frac{t}{n}\sum_{i=1}^{n}X_i+\sum_{i=1}^{n}X_it_i-\sum_{i=1}^{n}\overline{X}t_i}\right] = E\left[e^{\frac{t}{n}\sum_{i=1}^{n}X_i+\sum_{i=1}^{n}X_it_i-\overline{X}\sum_{i=1}^{n}t_i}\right] = \\
&= E\left[e^{\frac{t}{n}\sum_{i=1}^{n}X_i+\sum_{i=1}^{n}X_it_i-\frac{1}{n}\sum_{i=1}^{n}X_i\sum_{i=1}^{n}t_i}\right] = E\left[e^{\frac{t}{n}\sum_{i=1}^{n}X_i+\sum_{i=1}^{n}X_it_i-\sum_{i=1}^{n}X_i\frac{1}{n}\sum_{i=1}^{n}t_i}\right] = \\
&= E\left[e^{\frac{t}{n}\sum_{i=1}^{n}X_i+\sum_{i=1}^{n}X_it_i-\sum_{i=1}^{n}X_i\bar{t}}\right] = E\left[e^{\sum_{i=1}^{n}X_i\frac{t}{n}+\sum_{i=1}^{n}X_it_i-\sum_{i=1}^{n}X_i\bar{t}}\right] = \\
&= E\left[e^{\sum_{i=1}^{n}X_i\left(\frac{t}{n}+t_i-\bar{t}\right)}\right] = E\left[\prod_{i=1}^{n}e^{X_i\left(\frac{t}{n}+t_i-\bar{t}\right)}\right] \overset{\text{indep.}}{=} \prod_{i=1}^{n}E\left[e^{X_i\left(\frac{t}{n}+t_i-\bar{t}\right)}\right] = \\
&= \prod_{i=1}^{n}M_{X_i}\left(\frac{t}{n}+t_i-\bar{t}\right) \overset{(*)}{=} \prod_{i=1}^{n}\exp\left[\left(\frac{t}{n}+t_i-\bar{t}\right)\mu+\left(\frac{t}{n}+t_i-\bar{t}\right)^2\frac{\sigma^2}{2}\right] = \\
&= \exp\left[\sum_{i=1}^{n}\left[\left(\frac{t}{n}+t_i-\bar{t}\right)\mu+\frac{\sigma^2}{2}\left(\frac{t^2}{n^2}+\left(t_i-\bar{t}\right)^2+2\frac{t}{n}(t_i-\bar{t})\right)\right]\right] = \\
&= \exp\left[\sum_{i=1}^{n}\frac{\mu t}{n}+\sum_{i=1}^{n}\mu(t_i-\bar{t})+\frac{\sigma^2}{2}\left(\sum_{i=1}^{n}\frac{t^2}{n^2}+\sum_{i=1}^{n}(t_i-\bar{t})^2+2\sum_{i=1}^{n}\frac{t}{n}(t_i-\bar{t})\right)\right] \overset{(**)}{=} \\
&\overset{(**)}{=} \exp\left[\frac{\cancel{n}\mu t}{\cancel{n}}+\mu\cancel{\sum_{i=1}^{n}(t_i-\bar{t})}+\frac{\sigma^2}{2}\left(\frac{\cancel{n}t^2}{n\cancel{^2}}+\sum_{i=1}^{n}(t_i-\bar{t})^2+2\frac{t}{n}\cancel{\sum_{i=1}^{n}(t_i-\bar{t})}\right)\right] = \\
&= \exp\left[\mu t+\frac{\sigma^2t^2}{2n}+\frac{\sigma^2}{2}\sum_{i=1}^{n}(t_i-\bar{t})^2\right]
\end{aligned}
$$

donde en $(*)$ hemos usado que todas las variables son idénticamente distribuidas a una $\mathcal{N}(\mu, \sigma^2)$; y en $(**)$ hemos usado que el momento centrado de primer orden es cero. Sabemos que:

$$
\begin{aligned}
M_{\overline{X}}(t) &= M_{\left(\overline{X}, X_1-\overline{X}, \ldots, X_n-\overline{X}\right)}(t, 0, ..., 0) = e^{\mu t+\frac{\sigma^2t^2}{2n}} \\
M_{(X_1-\overline{X}, \ldots, X_n-\overline{X})}(t_1, ..., t_n) &= M_{(\overline{X}, X_1-\overline{X}, \ldots, X_n-\overline{X})}(0, t_1, \ldots, t_n) \\
&= e^{\frac{\sigma^2}{2}\sum_{i=1}^{n}(t_i-\bar{t})^2}
\end{aligned}
$$

Por tanto, tenemos que el producto de las funciones generatrices de momentos es la generatriz de mmoentos conjunta, luego las variables son independientes. □

Corolario 1.2.3.1. En dichas condiciones, tenemos que:

1. $\overline{X} \rightsquigarrow \mathcal{N}(\mu, \frac{\sigma^2}{n})$
2. (Lema de Fisher): $\overline{X}$ y S^2 son independientes.
3. $\dfrac{(n-1)S^2}{\sigma^2} \rightsquigarrow \chi^2(n-1)$

4. $\dfrac{\overline{X}-\mu}{S/\sqrt{n}} \rightsquigarrow t(n-1)$

Demostración. Demostramos cada una de las afirmaciones:

1. Se vio ya en el ejemplo 1.1.

2. Como S^2 es función del vector de la Proposición anterior, tenemos que es independiente a $\overline{X}$, ya que las funciones de variables independientes son independientes.

3. Queremos demostrar que:

$$\frac{(n-1)S^2}{\sigma^2} = \frac{\sum_{i=1}^{n}\left(X_i-\overline{X}\right)^2}{\sigma^2} \rightsquigarrow \chi^2(n-1)$$

Tenemos que:

$$\begin{aligned}\frac{\sum_{i=1}^{n}\left(X_i-\mu\right)^2}{\sigma^2} &= \frac{\sum_{i=1}^{n}\left(X_i-\overline{X}+\overline{X}-\mu\right)^2}{\sigma^2}\\ &= \frac{\sum_{i=1}^{n}\left(X_i-\overline{X}\right)^2+\sum_{i=1}^{n}\left(\overline{X}-\mu\right)^2+2\cancel{\sum_{i=1}^{n}(X_i-\overline{X})}(\overline{X}-\mu)}{\sigma^2}\\ &= \frac{\sum_{i=1}^{n}\left(X_i-\overline{X}\right)^2}{\sigma^2}+n\frac{\left(\overline{X}-\mu\right)^2}{\sigma^2}\end{aligned}$$

Notemos que estamos interesados en conocer la distribución de la primera parte de la suma. Notemos por A a la suma completa, por B a la primera parte y por C a la segunda parte, de forma que $A = B + C$. Veamos la distribución de cada término:

- Por un lado para A, tenemos que:

$$A = \frac{\sum_{i=1}^{n}\left(X_i-\mu\right)^2}{\sigma^2} = \sum_{i=1}^{n}\left(\frac{X_i-\mu}{\sigma}\right)^2 \overset{(*)}{=} \sum_{i=1}^{n} Z_i^2 \rightsquigarrow \chi^2(n)$$

  donde en $(*)$ hemos usado que $X_i \rightsquigarrow \mathcal{N}(\mu,\sigma^2)$, por lo que su variable tipificada $Z_i \rightsquigarrow \mathcal{N}(0,1)$. Además, en la última igualdad hemos empleado la construcción de la distribución χ^2 a partir de variables normales.

- Por otro lado, para C, del ejemplo 1.1, tenemos que $\overline{X} \rightsquigarrow \mathcal{N}(\mu, \frac{\sigma^2}{n})$, por lo que, tipificando

$$\frac{\overline{X}-\mu}{\sqrt{\sigma^2/n}} = \frac{\overline{X}-\mu}{\sigma/\sqrt{n}} = \sqrt{n}\frac{\overline{X}-\mu}{\sigma} \rightsquigarrow \mathcal{N}(0,1)$$

  Elevando al cuadrado y empleando la construcción de la distribución χ^2, obtenemos que:

$$C = n\frac{\left(\overline{X}-\mu\right)^2}{\sigma^2} \rightsquigarrow \chi^2(1)$$

Buscamos la distribución de B, y para ello, buscamos su caracterización por la función generatriz de momentos. Tenemos que $B = f(S^2)$, mientras que $C = g(\overline{X})$. Como, por el Lema de Fisher, $\overline{X}$ y S^2 son independientes, tenemos que B y C son independientes. Por lo que:

$$M_{A=B+C}(t) \overset{\text{indep.}}{=} M_B(t)M_C(t)$$

Veamos la función generatriz de momentos de A y C:

- Para A, tenemos que $A \rightsquigarrow \chi^2(n)$, por lo que:
$$M_A(t) = \frac{1}{(1-2t)^{n/2}} \qquad t < \frac{1}{2}$$
- Para C, tenemos que $C \rightsquigarrow \chi^2(1)$, por lo que:
$$M_C(t) = \frac{1}{(1-2t)^{\frac{1}{2}}} \qquad t < \frac{1}{2}$$

Por tanto, tenemos que:

$$M_B(t) = \frac{M_A(t)}{M_C(t)} = \frac{\dfrac{1}{(1-2t)^{\frac{n}{2}}}}{\dfrac{1}{(1-2t)^{\frac{1}{2}}}} = \frac{1}{(1-2t)^{\frac{n-1}{2}}} \qquad t < \frac{1}{2}$$

De aquí, deducimos que $B \rightsquigarrow \chi^2(n-1)$.

4. Queremos ver que $\dfrac{\overline{X}-\mu}{S/\sqrt{n}} \rightsquigarrow t(n-1)$.

Para ello, al igual que la χ^2, lo más sencillo es ir a la construcción de t:

$$\left.\begin{array}{l} X \rightsquigarrow \mathcal{N}(0,1) \\ Y \rightsquigarrow \chi^2(n) \\ X \text{ e } Y \text{ independientes} \end{array}\right\} \Longrightarrow \frac{X}{\sqrt{Y/n}} \rightsquigarrow t(n)$$

Por un lado, como $\overline{X} \rightsquigarrow \mathcal{N}(\mu, \frac{\sigma^2}{n})$, tenemos que:

$$\frac{\overline{X}-\mu}{\sigma/\sqrt{n}} \rightsquigarrow \mathcal{N}(0,1)$$

Por otro lado, del punto anterior, tenemos que:

$$\frac{(n-1)S^2}{\sigma^2} \rightsquigarrow \chi^2(n-1)$$

Como $\overline{X}$ y S^2 son independientes por el Lema de Fisher, tenemos que ambas variables aleatorias consideradas son independientes, por lo que podemos aplicar la construcción de la distribución t:

$$\frac{\dfrac{\overline{X}-\mu}{\sigma/\sqrt{n}}}{\sqrt{\dfrac{\cancel{(n-1)}S^2}{\sigma^2\cancel{(n-1)}}}} = \frac{\dfrac{\overline{X}-\mu}{\cancel{\sigma}/\sqrt{n}}}{\dfrac{S}{\cancel{\sigma}}} = \frac{\overline{X}-\mu}{S/\sqrt{n}} \rightsquigarrow t(n-1)$$

□

Gracias a este corolario, podemos inferir sobre μ y σ^2 de la población normal a partir de una m.a.s. de la misma. En particular, tenemos que los siguientes resultados, con demostración evidente a partir del corolario anterior:

1. Si queremos inferir sobre μ:

   a) Si conocemos σ_0^2 (notaremos con el subíndice 0 que es un valor conocido), entonces:
   $$\frac{\overline{X}-\mu}{\sigma_0/\sqrt{n}} \rightsquigarrow \mathcal{N}(0,1)$$

   b) Si no conocemos σ^2, entonces:
   $$\frac{\overline{X}-\mu}{S/\sqrt{n}} \rightsquigarrow t(n-1)$$

2. Si queremos inferir sobre σ^2:

   a) Si conocemos μ_0, entonces:
   $$\frac{\sum_{i=1}^{n}(X_i-\mu_0)^2}{\sigma^2} \rightsquigarrow \chi^2(n)$$

   b) Si no conocemos μ, entonces:
   $$\frac{\sum_{i=1}^{n}(X_i-\overline{X})^2}{\sigma^2} \rightsquigarrow \chi^2(n-1)$$

1.2.2. Muestreo en dos poblaciones normales unidimensionales

En lo que sigue, sean $(X_1,\ldots,X_{n_1})$ y $(Y_1,\ldots,Y_{n_2})$ m.a.s. independientes con $X \rightsquigarrow \mathcal{N}(\mu_1,\sigma_1^2)$ y $Y \rightsquigarrow \mathcal{N}(\mu_2,\sigma_2^2)$.

Teorema 1.2.4 (Extensión del Lema de Fisher)**.** *Los vectores* $(\overline{X},\overline{Y})$*,* (S_1^2,S_2^2) *son independientes.*

Demostración. Usemos la función generatriz de momentos, ya que son independientes si y solo si:

$$M_{\left(\overline{X},\overline{Y},S_1^2,S_2^2\right)}(t_1,t_2,s_1,s_2) \stackrel{?}{=} M_{\left(\overline{X},\overline{Y}\right)}(t_1,t_2)M_{\left(S_1^2,S_2^2\right)}(s_1,s_2)$$

Como $\left(\overline{X},S_1^2\right) = f(X_1,\ldots,X_{n_1})$ y $\left(\overline{Y},S_2^2\right) = g(Y_1,\ldots,Y_{n_2})$, tenemos que ambos vectores son independientes, por lo que:

$$M_{\left(\overline{X},\overline{Y},S_1^2,S_2^2\right)}(t_1,t_2,s_1,s_2) = M_{\left(\overline{X},S_1^2\right)}(t_1,s_1)M_{\left(\overline{Y},S_2^2\right)}(t_2,s_2)$$

Aplicando ahora el Lema de Fisher a cada uno de los vectores, tenemos que:

$$M_{\left(\overline{X},\overline{Y},S_1^2,S_2^2\right)}(t_1,t_2,s_1,s_2) = M_{\overline{X}}(t_1)M_{S_1^2}(s_1)M_{\overline{Y}}(t_2)M_{S_2^2}(s_2)$$

Nuevamente, como $\overline{X} = f(X_1, \ldots, X_{n_1})$ y $\overline{Y} = g(Y_1, \ldots, Y_{n_2})$, y $S_1^2 = h(X_1, \ldots, X_{n_1})$ y $S_2^2 = k(Y_1, \ldots, Y_{n_2})$, tenemos que $\overline{X}$ y $\overline{Y}$ son independientes, y S_1^2 y S_2^2 son independientes. Por tanto:

$$M_{\left(\overline{X},\overline{Y},S_1^2,S_2^2\right)}(t_1, t_2, s_1, s_2) = M_{\left(\overline{X},\overline{Y}\right)}(t_1, t_2) M_{\left(S_1^2,S_2^2\right)}(s_1, s_2)$$

De aquí deducimos que los vectores $(\overline{X}, \overline{Y})$ y (S_1^2, S_2^2) son independientes. □

Corolario 1.2.4.1. En dichas condiciones, tenemos que:

1. $$\frac{n_2}{n_1}\frac{\sigma_2^2}{\sigma_1^2}\frac{\sum_{i=1}^{n_1}(X_i - \mu_1)^2}{\sum_{i=1}^{n_2}(Y_i - \mu_2)^2} \rightsquigarrow F(n_1, n_2)$$

2. $\frac{S_1^2/\sigma_1^2}{S_2^2/\sigma_2^2} \rightsquigarrow F(n_1 - 1, n_2 - 1)$.
   En particular, si $\sigma_1 = \sigma_2$, se tiene:
   $$\frac{S_1^2}{S_2^2} \rightsquigarrow F(n_1 - 1, n_2 - 1)$$

3. $$\frac{\overline{X} - \overline{Y} - (\mu_1 - \mu_2)}{\sqrt{\frac{(n_1-1)S_1^2}{\sigma_1^2} + \frac{(n_2-1)S_2^2}{\sigma_2^2}}} \cdot \sqrt{\frac{n_1 + n_2 - 2}{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}}} \rightsquigarrow t(n_1 + n_2 - 2).$$
   En particular, si $\sigma_1 = \sigma_2$, se tiene:
   $$\frac{\overline{X} - \overline{Y} - (\mu_1 - \mu_2)}{\sqrt{(n_1-1)S_1^2 + (n_2-1)S_2^2}} \cdot \sqrt{\frac{n_1 + n_2 - 2}{\frac{1}{n_1} + \frac{1}{n_2}}} \rightsquigarrow t(n_1 + n_2 - 2)$$

Demostración. Demostramos cada una de las afirmaciones:

1. Partiremos de la construcción de la distribución F de Snedecor:
   $$\left.\begin{array}{l} X \rightsquigarrow \chi^2(m) \\ Y \rightsquigarrow \chi^2(n) \\ X \text{ e } Y \text{ independientes} \end{array}\right\} \Longrightarrow \frac{X/m}{Y/n} \rightsquigarrow F(m, n)$$

   Por otro lado, como $X \rightsquigarrow \mathcal{N}(\mu_1, \sigma_1^2)$ y $Y \rightsquigarrow \mathcal{N}(\mu_2, \sigma_2^2)$, y haciendo uso de la construcción de la distribución χ^2 a partir de variables normales, tenemos que:
   $$\frac{\sum_{i=1}^{n_1}(X_i - \mu_1)^2}{\sigma_1^2} \rightsquigarrow \chi^2(n_1) \qquad \frac{\sum_{i=1}^{n_2}(Y_i - \mu_2)^2}{\sigma_2^2} \rightsquigarrow \chi^2(n_2)$$

   Como las m.a.s. son independientes y ambas distribuciones χ^2 son funciones de las m.a.s., tenemos que ambas variables son independientes. Por tanto, podemos aplicar la construcción de la distribución F de Snedecor:
   $$\frac{\frac{\sum_{i=1}^{n_1}(X_i-\mu_1)^2}{n_1\sigma_1^2}}{\frac{\sum_{i=1}^{n_2}(Y_i-\mu_2)^2}{n_2\sigma_2^2}} = \frac{n_2}{n_1}\frac{\sigma_2^2}{\sigma_1^2}\frac{\sum_{i=1}^{n_1}(X_i - \mu_1)^2}{\sum_{i=1}^{n_2}(Y_i - \mu_2)^2} \rightsquigarrow F(n_1, n_2)$$

2. Seguimos buscando la construcción de F de Snedecor. Por el Colorario 1.2.3.1 sabemos que:

$$\frac{(n_1-1)S_1^2}{\sigma_1^2} \rightsquigarrow \chi^2(n_1-1) \qquad \frac{(n_2-1)S_2^2}{\sigma_2^2} \rightsquigarrow \chi^2(n_2-1)$$

Estas son independientes por ser funciones de ambas m.a.s., que son independientes. Dividimos:

$$\frac{\frac{\cancel{(n_1-1)}S_1^2}{\cancel{\sigma_1^2(n_1-1)}}}{\frac{\cancel{(n_2-1)}S_2^2}{\cancel{\sigma_2^2(n_2-1)}}} = \frac{S_1^2/\sigma_1^2}{S_2^2/\sigma_2^2} \rightsquigarrow F(n_1-1, n_2-1)$$

3. En este caso, buscamos aplicar la construcción de la distribución t de Student:

$$\left.\begin{array}{l} X \rightsquigarrow \mathcal{N}(0,1) \\ Y \rightsquigarrow \chi^2(n) \\ X \text{ e } Y \text{ independientes} \end{array}\right\} \Longrightarrow \frac{X}{\sqrt{Y/n}} \rightsquigarrow t(n)$$

Queremos probar:

$$\frac{\overline{X}-\overline{Y}-(\mu_1-\mu_2)}{\sqrt{\frac{(n_1-1)S_1^2}{\sigma_1^2}+\frac{(n_2-1)S_2^2}{\sigma_2^2}}}\sqrt{\frac{n_1+n_2-2}{\frac{\sigma_1^2}{n_1}+\frac{\sigma_2}{n_2}}} \rightsquigarrow t(n_1+n_2-2)$$

Tenemos que $\overline{X} \rightsquigarrow \mathcal{N}(\mu_1, \sigma_1^2/n_1)$ y $\overline{Y} \rightsquigarrow \mathcal{N}(\mu_2, \sigma_2^2/n_2)$. Además, tenemos que:

$$-\overline{Y} \rightsquigarrow \mathcal{N}(-\mu_2, \sigma_2^2/n_2)$$

Como $\overline{X}$ e $-\overline{Y}$ son funciones de m.a.s. independientes, tenemos que son independientes. Por tanto, por la reproductividad de la distribución normal, tenemos que:

$$\overline{X}-\overline{Y} \rightsquigarrow \mathcal{N}\left(\mu_1-\mu_2, \frac{\sigma_1^2}{n_1}+\frac{\sigma_2^2}{n_2}\right)$$

Tipificando, tenemos que:

$$\frac{\overline{X}-\overline{Y}-(\mu_1-\mu_2)}{\sqrt{\frac{\sigma_1^2}{n_1}+\frac{\sigma_2^2}{n_2}}} \rightsquigarrow \mathcal{N}(0,1)$$

Por otro lado, del Corolario 1.2.3.1, tenemos que:

$$\frac{(n_1-1)S_1^2}{\sigma_1^2} \rightsquigarrow \chi^2(n_1-1) \qquad \frac{(n_2-1)S_2^2}{\sigma_2^2} \qquad \rightsquigarrow \chi^2(n_2-1)$$

Como las m.a.s. son independientes, tenemos que estas dos variables aleatorias son independientes. Por la reproductividad de la distribución χ^2, tenemos que:

$$\frac{(n_1-1)S_1^2}{\sigma_1^2}+\frac{(n_2-1)S_2^2}{\sigma_2^2} \rightsquigarrow \chi^2(n_1+n_2-2)$$

Por la extensión del Lema de Fisher tenemos que las dos variables aleatorias que hemos calculado son independientes. Procedemos ahora a aplicar la construcción de la t de Student:

$$\frac{\dfrac{\overline{X}-\overline{Y}-(\mu_1-\mu_2)}{\sqrt{\frac{\sigma_1^2}{n_1}+\frac{\sigma_2^2}{n_2}}}}{\sqrt{\dfrac{\frac{(n_1-1)S_1^2}{\sigma_1^2}+\frac{(n_2-1)S_2^2}{\sigma_2^2}}{n_1+n_2-2}}} \rightsquigarrow t(n_1+n_2-2)$$

□

Gracias a estos resultados, podemos inferir sobre $\mu_1-\mu_2$ y σ_1^2/σ_2^2 a partir de dos m.a.s. independientes de poblaciones normales. En particular, tenemos los siguientes resultados:

1. Si queremos inferir sobre $\mu_1-\mu_2$ (comparación de medias):

   a) Si conocemos las varianzas poblacionales σ_{10}^2 y σ_{20}^2, entonces:

   $$\frac{(\overline{X}-\overline{Y})-(\mu_1-\mu_2)}{\sqrt{\frac{\sigma_{10}^2}{n_1}+\frac{\sigma_{20}^2}{n_2}}} \rightsquigarrow \mathcal{N}(0,1)$$

   b) Si las varianzas son desconocidas pero iguales ($\sigma_1^2=\sigma_2^2=\sigma^2$), entonces:

   $$\frac{(\overline{X}-\overline{Y})-(\mu_1-\mu_2)}{\sqrt{(n_1-1)S_1^2+(n_2-1)S_2^2}}\sqrt{\frac{n_1+n_2-2}{\frac{1}{n_1}+\frac{1}{n_2}}} \rightsquigarrow t(n_1+n_2-2)$$

2. Si queremos inferir sobre σ_1^2/σ_2^2 (comparación de varianzas):

   a) Si conocemos las medias μ_{10} y μ_{20}, entonces:

   $$\frac{n_1\sigma_1^2\sum_{i=1}^{n_2}(Y_i-\mu_{20})^2}{n_2\sigma_2^2\sum_{i=1}^{n_1}(X_i-\mu_{10})^2} \rightsquigarrow F(n_2,n_1)$$

   b) Si no conocemos las medias μ_1 y μ_2, entonces:

   $$\frac{\sigma_1^2S_2^2}{\sigma_2^2S_1^2} \rightsquigarrow F(n_2-1,n_1-1)$$

1.3. Suficiencia y completitud

Ejemplo. Sean X_1, X_2 variables aleatorias independientes tal que $X_1, X_2 \rightsquigarrow \mathcal{P}(\lambda)$. Probar que $X_1 + X_2$ es suficiente para λ pero $X_1 + 2X_2$ no lo es.

Demostración. Notamos por P_λ a la función masa de probabilidad, que dependerá de λ. Queremos probar que, condicionada a un valor de $X_1 + X_2$, no depende de λ. Fijado $k \in \mathbb{N}$, tenemos que:

$$P_\lambda[X_1 = x_1, X_2 = x_2 \mid X_1 + X_2 = k] = \frac{P_\lambda[X_1 = x_1, X_2 = x_2, X_1 + X_2 = k]}{P_\lambda[X_1 + X_2 = k]} = \\ = \begin{cases} \dfrac{P_\lambda[X_1 = x_1, X_2 = x_2]}{P_\lambda[X_1 + X_2 = k]} & \text{si } x_1 + x_2 = k \\ 0 & \text{si } x_1 + x_2 \neq k \end{cases}$$

Puesto que X_1 y X_2 son independientes, para $x_1 + x_2 = k$ tenemos que:

$$P_\lambda[X_1 = x_1, X_2 = x_2 \mid X_1 + X_2 = k] = \frac{P_\lambda[X_1 = x_1]P_\lambda[X_2 = x_2]}{P_\lambda[X_1 + X_2 = k]} \overset{(*)}{=} \frac{e^{-\lambda}\frac{\lambda^{x_1}}{x_1!} \cdot e^{-\lambda}\frac{\lambda^{x_2}}{x_2!}}{e^{-2\lambda}\frac{(2\lambda)^k}{k!}} = \\ = \frac{k!}{2^k x_1! x_2!}$$

donde en $(*)$ hemos usado la reproductividad de la distribución Poisson, que nos dice que $X_1 + X_2 \rightsquigarrow \mathcal{P}(2\lambda)$. Notemos que el resultado no depende de λ, por lo que $X_1 + X_2$ es suficiente para λ.

Por otro lado, queremos ver que $X_1 + 2X_2$ no es suficiente para λ. Para ello, no es necesario probarlo para todos los valores posibles, sino que basta con encontrar un contraejemplo. Tomemos $k = 2$ y la muestra $(x_1, x_2) = (0, 1)$, de forma que $x_1 + 2x_2 = 2$. Tenemos que:

$$P_\lambda[X_1 = 0, X_2 = 1 \mid X_1 + 2X_2 = 2] = \frac{P_\lambda[X_1 = 0, X_2 = 1, X_1 + 2X_2 = 2]}{P_\lambda[X_1 + 2X_2 = 2]} = \\ = \frac{P_\lambda[X_1 = 0, X_2 = 1]}{P_\lambda[X_1 + 2X_2 = 2]}$$

Por el Teorema de Cambio de Variable, tenemos que:

$$P_\lambda[X_1 + 2X_2 = 2] = \sum_{\substack{x_1, x_2 \in \mathbb{N} \\ x_1 + 2x_2 = 2}} P_\lambda[X_1 = x_1, X_2 = x_2] = \\ = P_\lambda[X_1 = 0, X_2 = 1] + P_\lambda[X_1 = 2, X_2 = 0]$$

Por tanto, tenemos que:

$$P_\lambda[X_1 = 0, X_2 = 1 \mid X_1 + 2X_2 = 2] = \frac{P_\lambda[X_1 = 0]P_\lambda[X_2 = 1]}{P_\lambda[X_1 = 0]P_\lambda[X_2 = 1] + P_\lambda[X_1 = 2]P_\lambda[X_2 = 0]} = \\ = \frac{e^{-\lambda}\frac{\lambda^0}{0!} \cdot e^{-\lambda}\frac{\lambda^1}{1!}}{e^{-\lambda}\frac{\lambda^0}{0!} \cdot e^{-\lambda}\frac{\lambda^1}{1!} + e^{-\lambda}\frac{\lambda^2}{2!} \cdot e^{-\lambda}\frac{\lambda^0}{0!}} = \frac{\lambda}{\lambda + \frac{\lambda^2}{2}} = \frac{2}{2 + \lambda}$$

Notemos que el resultado depende de λ, por lo que $X_1 + 2X_2$ no es suficiente para λ. □

Ejemplo. En n lanzamientos de una moneda, el número de caras es suficiente para la probabilidad de cara (notada p).

Demostración. Sea X la v.a. que representa el número de caras en un lanzamiento de la moneda, de forma que $X \rightsquigarrow \mathcal{B}(1,p)$. Sea $(X_1,\ldots,X_n)$ una m.a.s. de n lanzamientos de la moneda, y sea $T=\sum_{i=1}^{n} X_i$ el número total de caras en los n lanzamientos. Queremos ver que Y es suficiente para p. Para ello, fijado un valor $k\in\{0,\ldots,n\}$, tenemos que:

$$P_p[X_1=x_1,\ldots,X_n=x_n \mid T=k] = \frac{P_p[X_1=x_1,\ldots,X_n=x_n,T=k]}{P_p[T=k]} = \\ = \begin{cases} \dfrac{P_p[X_1=x_1,\ldots,X_n=x_n]}{P_p[T=k]} & \text{si } x_1+\ldots+x_n=k \\ 0 & \text{si } x_1+\ldots+x_n\neq k \end{cases}$$

Por otro lado, como $X_1,\ldots,X_n$ son independientes, en el caso de que se tenga que $x_1+\ldots+x_n=k$, tenemos que:

$$P_p[X_1=x_1,\ldots,X_n=x_n \mid T=k] = \frac{P_p[X_1=x_1]\cdots P_p[X_n=x_n]}{P_p[T=k]} \overset{(*)}{=} \\ \overset{(*)}{=} \frac{\prod_{i=1}^{n} p^{x_i}(1-p)^{1-x_i}}{\binom{n}{k}p^k(1-p)^{n-k}} = \frac{p^{\sum_{i=1}^{n} x_i}(1-p)^{\sum_{i=1}^{n} 1-x_i}}{\binom{n}{k}p^k(1-p)^{n-k}} = \\ = \frac{p^k(1-p)^{n-k}}{\binom{n}{k}p^k(1-p)^{n-k}} = \frac{1}{\binom{n}{k}}$$

donde en $(*)$ hemos usado que $T\rightsquigarrow\mathcal{B}(n,p)$. Notemos que el resultado no depende de p, por lo que T es suficiente para p. □

Ejemplo. Se supone que se ha lanzado una moneda 100 veces, y se sabe que se han obtenido 60 caras pero se han perdido los datos originales de si salió cara o cruz en cada tirada. Reconstruir la muestra.

Sea X la v.a. que representa el número de caras en un lanzamiento de la moneda, de forma que $X \rightsquigarrow \mathcal{B}(1,p)$. Sea $(X_1,\ldots,X_{100})$ una m.a.s. de 100 lanzamientos de la moneda, y sea $T=\sum_{i=1}^{100} X_i$ el número total de caras en los 100 lanzamientos, que sabemos que es suficiente para p, luego la información que nos da la muestra original se encuentra en T. Por tanto, podemos reconstruir la muestra original muestreando de la distribución condicional de $(X_1,\ldots,X_{100})$ dado que $T=60$, que en el ejemplo anterior hemos visto que es:

$$P[X_1=x_1,\ldots,X_{100}=x_{100} \mid T=60] = \begin{cases} \dfrac{1}{\binom{100}{60}} & \text{si } x_1+\ldots+x_{100}=60 \\ 0 & \text{si } x_1+\ldots+x_{100}\neq 60 \end{cases}$$

Por tanto, si $(X_1^*,\ldots,X_{100}^*)$ es una m.a.s. de la distribución condicionada al valor de $T=60$, tenemos que $(X_1^*,\ldots,X_{100}^*)$ sigue una distribución uniforme discreta

sobre el conjunto de todas las muestras posibles de 100 lanzamientos de la moneda que contienen exactamente 60 caras; es decir, $(X_1^*, \ldots, X_{100}^*) \rightsquigarrow \mathcal{U}(\mathcal{S})$, donde:

$$\mathcal{S} = \left\{(x_1, \ldots, x_{100}) \in \{0,1\}^{100} : x_1 + \ldots + x_{100} = 60\right\}$$

Teorema 1.3.5 (de Factorización de Neyman-Fisher (Discreto))**.** *Sea una v. a. $X \rightsquigarrow F \in \{F_\theta : \theta \in \Theta\}$, y sea $(X_1, \ldots, X_n)$ una m.a.s. de X. Sea f_θ la función masa de probabilidad de F_θ. Sea $T = T(X_1, \ldots, X_n)$ un estadístico. Entonces, T es suficiente para θ si y solo si existen funciones g_θ y h tales que:*

$$f_\theta(x_1, \ldots, x_n) = h(x_1, \ldots, x_n) g_\theta(T(x_1, \ldots, x_n)) \qquad \forall (x_1, \ldots, x_n) \in \mathcal{X}^n,\ \forall \theta \in \Theta$$

donde h no depende de θ.

Demostración. Demostramos cada una de las implicaciones:

$\Longrightarrow$) Supongamos que T es suficiente para θ. Entonces, para todo $(x_1, \ldots, x_n) \in \mathcal{X}^n$, $\theta \in \Theta$, y para cualquier $t \in T(\mathcal{X}^n)$ fijo, tenemos que:

$$P[X_1 = x_1, \ldots, X_n = x_n \mid T = t] = \frac{P_\theta[X_1 = x_1, \ldots, X_n = x_n, T = t]}{P_\theta[T = t]}$$

Evaluando en $t = T(x_1, \ldots, x_n)$, tenemos que:

$$P[X_1 = x_1, \ldots, X_n = x_n \mid T = t] = \frac{P_\theta[X_1 = x_1, \ldots, X_n = x_n]}{P_\theta[T = t]}$$

Despejando, tenemos que:

$$P_\theta[X_1 = x_1, \ldots, X_n = x_n] = P_\theta[T = t] P[X_1 = x_1, \ldots, X_n = x_n \mid T = t]$$

Por tanto, identificando

$$g_\theta(t) = P_\theta[T = t] \qquad h(x_1, \ldots, x_n) = P[X_1 = x_1, \ldots, X_n = x_n \mid T = T(x_1, \ldots, x_n)]$$

tenemos que:

$$P_\theta[X_1 = x_1, \ldots, X_n = x_n] = h(x_1, \ldots, x_n) g_\theta(T(x_1, \ldots, x_n))$$

$\Longleftarrow$) Supongamos que existen funciones g_θ y h tales que, para todo $(x_1, \ldots, x_n) \in \mathcal{X}^n$ y $\theta \in \Theta$, se cumple que:

$$P_\theta[X_1 = x_1, \ldots, X_n = x_n] = h(x_1, \ldots, x_n) g_\theta(T(x_1, \ldots, x_n))$$

Entonces, para cualquier $t \in T(\mathcal{X}^n)$, tenemos que:

$$P_\theta[X_1 = x_1, \ldots, X_n = x_n \mid T = t] = \frac{P_\theta[X_1 = x_1, \ldots, X_n = x_n, T = t]}{P_\theta[T = t]} =$$

$$= \begin{cases} \dfrac{P_\theta[X_1 = x_1, \ldots, X_n = x_n]}{P_\theta[T = t]} & \text{si } T(x_1, \ldots, x_n) = t \\ 0 & \text{si } T(x_1, \ldots, x_n) \neq t \end{cases}$$

En el caso de que $T(x_1, \ldots, x_n) = t$, tenemos que:

$$P_\theta[X_1 = x_1, \ldots, X_n = x_n \mid T = t] = \frac{h(x_1, \ldots, x_n) g_\theta(T(x_1, \ldots, x_n))}{\sum\limits_{\substack{(x_1,\ldots,x_n)\in\mathcal{X}^n \\ T(x_1,\ldots,x_n)=t}} P_\theta[X_1 = x_1, \ldots, X_n = x_n]} =$$

$$= \frac{h(x_1, \ldots, x_n) g_\theta(t)}{\sum\limits_{\substack{(x_1,\ldots,x_n)\in\mathcal{X}^n \\ T(x_1,\ldots,x_n)=t}} h(x_1, \ldots, x_n) g_\theta(t)} =$$

$$= \frac{h(x_1, \ldots, x_n)}{\sum\limits_{\substack{(x_1,\ldots,x_n)\in\mathcal{X}^n \\ T(x_1,\ldots,x_n)=t}} h(x_1, \ldots, x_n)}$$

Notemos que el resultado no depende de θ, por lo que T es suficiente para θ. □

Ejemplo. Sea X una v.a. tal que $X \rightsquigarrow F \in \{\mathcal{N}(\mu, \sigma^2) : \mu \in \mathbb{R}, \sigma^2 > 0\}$. Estudiar la suficiencia en los casos de:

1. σ_0^2 conocida.

   Consideramos una m.a.s. $(X_1, \ldots, X_n)$ de X. Sea $T = T(X_1, \ldots, X_n)$ un estadístico. Por el Teorema de Factorización de Neyman-Fisher, T es suficiente para μ si y solo si existen funciones g_μ y h tales que:

   $$f_\mu(x_1, \ldots, x_n) = h(x_1, \ldots, x_n) g_\mu(T(x_1, \ldots, x_n)) \qquad \forall (x_1, \ldots, x_n) \in \mathbb{R}^n, \, \forall \mu \in \mathbb{R}$$

   Tenemos que:

   $$f_\mu(x_1, \ldots, x_n) \overset{\text{i.i.d.}}{=} \prod_{i=1}^n f_\mu(x_i) = \prod_{i=1}^n \frac{1}{\sqrt{2\pi\sigma_0^2}} \exp\left(-\frac{(x_i - \mu)^2}{2\sigma_0^2}\right) =$$

   $$= \frac{1}{(2\pi\sigma_0^2)^{n/2}} \exp\left(-\frac{\sum\limits_{i=1}^n (x_i - \mu)^2}{2\sigma_0^2}\right) =$$

   $$= \frac{1}{(2\pi\sigma_0^2)^{n/2}} \exp\left(-\frac{\sum\limits_{i=1}^n (x_i^2 - 2\mu x_i + \mu^2)}{2\sigma_0^2}\right) =$$

   $$= \frac{1}{(2\pi\sigma_0^2)^{n/2}} \exp\left(-\frac{\sum\limits_{i=1}^n x_i^2 - 2\mu \sum\limits_{i=1}^n x_i + n\mu^2}{2\sigma_0^2}\right) =$$

   $$= \frac{1}{(2\pi\sigma_0^2)^{n/2}} \exp\left(-\frac{\sum\limits_{i=1}^n x_i^2}{2\sigma_0^2}\right) \exp\left(-\frac{-2\mu \sum\limits_{i=1}^n x_i + n\mu^2}{2\sigma_0^2}\right)$$

Por tanto, identificando términos, tenemos que:

$$h(x_1, \ldots, x_n) = \frac{1}{(2\pi\sigma_0^2)^{n/2}} \exp\left(-\frac{\sum_{i=1}^{n} x_i^2}{2\sigma_0^2} \right)$$
$$g_\mu(T(x_1, \ldots, x_n)) = \exp\left(-\frac{-2\mu T(x_1, \ldots, x_n) + n\mu^2}{2\sigma_0^2} \right)$$

Por tanto, por el Teorema de Factorización de Neyman-Fisher, tenemos que $T(X_1, \ldots, X_n) = \sum_{i=1}^{n} X_i$ es suficiente para μ. En particular, como $\overline{X} = 1/n \cdot T$, tenemos que $\overline{X}$ es suficiente para μ.

2. μ_0 conocida.

   En este caso, identificando términos, tenemos que:

$$h(x_1, \ldots, x_n) = 1$$
$$g_{\sigma^2}(T(x_1, \ldots, x_n)) = \frac{1}{(2\pi\sigma^2)^{n/2}} \exp\left(-\frac{T(x_1, \ldots, x_n)}{2\sigma^2} \right)$$

   Por tanto, por el Teorema de Factorización de Neyman-Fisher, tenemos que $T(X_1, \ldots, X_n) = \sum_{i=1}^{n} (X_i - \mu_0)^2$ es suficiente para σ^2. Como $\mu_0 = E[X] = E[\overline{X}]$, tenemos que $S^2 = 1/n-1 \cdot T$ es suficiente para σ^2.

3. μ y σ^2 desconocidas.

   En este caso, identificando términos, tenemos de forma directa que:

$$h(x_1, \ldots, x_n) = 1$$

   Puesto que el parámetro es bidimensional, el estadístico suficiente debe ser, al menos, bidimensional. Por tanto, podemos tomar como estadístico suficiente (T_1, T_2), donde:

$$T_1(X_1, \ldots, X_n) = \sum_{i=1}^{n} X_i \qquad T_2(X_1, \ldots, X_n) = \sum_{i=1}^{n} (X_i)^2$$

   De esta forma, tenemos que:

$$g_{\mu,\sigma^2}(T_1(x_1, \ldots, x_n), T_2(x_1, \ldots, x_n)) = \\ = \frac{1}{(2\pi\sigma^2)^{n/2}} \exp\left(-\frac{T_2(x_1, \ldots, x_n) - 2\mu T_1(x_1, \ldots, x_n) + n\mu^2}{2\sigma^2} \right)$$

   De esta forma, por el Teorema de Factorización de Neyman-Fisher, tenemos que (T_1, T_2) es suficiente para (μ, σ^2).

Ejemplo. Sea $(X_1, \ldots, X_n)$ una m.a.s de la v.a. $X \rightsquigarrow \mathcal{B}(1,p)$, con $p \in]0,1[$. Encontrar un estadístico suficiente y completo asociado a la muestra.

Buscamos un estadístico suficiente. Por el Teorema de Factorización de Neyman-Fisher, T es suficiente para p si y solo si existen funciones g_p y h tales que:

$$P_p[X_1 = x_1, \ldots, X_n = x_n] = h(x_1, \ldots, x_n) g_p(T(x_1, \ldots, x_n)) \qquad \forall (x_1, \ldots, x_n) \in \{0,1\}^n,\ \forall p \in]0,1[$$

Tenemos que:

$$P_p[X_1 = x_1, \ldots, X_n = x_n] \overset{\text{i.i.d.}}{=} \prod_{i=1}^n P_p[X_i = x_i] = \prod_{i=1}^n p^{x_i}(1-p)^{1-x_i} = p^{\sum_{i=1}^n x_i}(1-p)^{\sum_{i=1}^n 1-x_i} =$$
$$= p^{\sum_{i=1}^n x_i}(1-p)^{n-\sum_{i=1}^n x_i}$$

Por tanto, identificando términos, tenemos que:

$$h(x_1, \ldots, x_n) = 1$$
$$g_p(T(x_1, \ldots, x_n)) = p^{T(x_1,\ldots,x_n)}(1-p)^{n-T(x_1,\ldots,x_n)}$$

Por tanto, por el Teorema de Factorización de Neyman-Fisher, tenemos que $T(X_1, \ldots, X_n) = \sum_{i=1}^n X_i$ es suficiente para p. Veamos ahora si T es completo. Sea g una función medible tal que $E_p[g(T)] = 0$ para todo $p \in]0,1[$. Probemos que $P_p[g(T) = 0] = 1$ para todo $p \in]0,1[$. Por reproductividad, se tiene $T \rightsquigarrow \mathcal{B}(n,p)$. Por tanto, para todo $p \in]0,1[$, tenemos que:

$$E_p[g(T)] = \sum_{k=0}^n g(k) P_p[T = k] = \sum_{k=0}^n g(k) \binom{n}{k} p^k (1-p)^{n-k} =$$
$$= (1-p)^n \sum_{k=0}^n g(k) \binom{n}{k} \left(\frac{p}{1-p}\right)^k = 0$$

Sea $q = p/1-p$. Entonces, para todo $q \in]0, +\infty[$, tenemos que:

$$\sum_{k=0}^n g(k) \binom{n}{k} q^k = 0$$

Notemos que el polinomio $\sum_{k=0}^n g(k)\binom{n}{k} q^k$ tiene grado a lo sumo n. Por tanto, como tiene infinitas raíces, debe ser el polinomio nulo. Por tanto, tenemos que:

$$g(k)\binom{n}{k} = 0 \qquad \forall k \in \{0, \ldots, n\}$$

Por tanto, tenemos que $g(k) = 0$ para todo $k \in \{0, \ldots, n\}$. Por tanto, hemos visto que:

$$\{0, \ldots, n\} \subset \{k \in \mathbb{N} : g(k) = 0\}$$

Por tanto:

$$1 = P_p[T \in \{0, \ldots, n\}] \leqslant P_p[g(T) = 0] \leqslant 1$$

Por tanto, $P_p[g(T) = 0] = 1$ para todo $p \in]0,1[$; luego T es completo para p.

Ejemplo. Sea $(X_1, \ldots, X_n)$ una m.a.s. de la v.a. $X \rightsquigarrow \mathcal{U}(0, \theta)$, con $\theta > 0$. Encontrar un estadístico suficiente y completo asociado a la muestra.

Buscamos un estadístico suficiente. Por el Teorema de Factorización de Neyman-Fisher, T es suficiente para θ si y solo si existen funciones g_θ y h tales que:

$$f_\theta(x_1, \ldots, x_n) = h(x_1, \ldots, x_n) g_\theta(T(x_1, \ldots, x_n)) \qquad \forall (x_1, \ldots, x_n) \in \mathbb{R}^n, \ \forall \theta > 0$$

Tenemos que:

$$f_\theta(x_1, \ldots, x_n) \overset{\text{i.i.d.}}{=} \prod_{i=1}^n f_\theta(x_i) = \prod_{i=1}^n \frac{1}{\theta} = \frac{1}{\theta^n} \qquad \text{si } (x_1, \ldots, x_n) \in [0, \theta]^n$$

Notemos que la función de densidad no depende de $(x_1, \ldots, x_n)$, salvo por la condición de que $(x_1, \ldots, x_n) \in [0, \theta]^n$. Por tanto, hemos de emplear la función indicadora para expresar la dependencia de $(x_1, \ldots, x_n)$. Notemos que:

$$f_\theta(x_1, \ldots, x_n) = \frac{1}{\theta^n} \, \mathrm{I}_{[0,\infty]}(x_{(1)}) \, \mathrm{I}_{]-\infty,0]}(x_{(n)} - \theta) \qquad \forall (x_1, \ldots, x_n) \in \mathbb{R}^n, \ \forall \theta > 0$$

Por tanto, identificando términos, tenemos que:

$$h(x_1, \ldots, x_n) = \mathrm{I}_{[0,\infty]}(x_{(1)})$$
$$g_\theta(T(x_1, \ldots, x_n)) = \frac{1}{\theta^n} \, \mathrm{I}_{]-\infty,0]}(T(x_1, \ldots, x_n) - \theta)$$

Por tanto, por el Teorema de Factorización de Neyman-Fisher, tenemos que $T(X_1, \ldots, X_n) = X_{(n)}$ es suficiente para θ. Para estudiar su completitud, hemos de calcular en primer lugar la función de densidad de T. Tenemos que:

$$F_{X_{(n)}}(x) = P[X_{(n)} \leqslant x] = P[X_1 \leqslant x, \ldots, X_n \leqslant x] = \prod_{i=1}^n P[X_i \leqslant x] = \prod_{i=1}^n F_X(x) = F_X(x)^n$$

Por tanto, tenemos que:

$$f_{X_{(n)}}(x) = \frac{d}{dx} F_{X_{(n)}}(x) = n F_X(x)^{n-1} f_X(x) = n \left(\frac{x}{\theta}\right)^{n-1} \frac{1}{\theta} = \frac{n x^{n-1}}{\theta^n} \qquad \text{si } x \in [0, \theta]$$

Sea g una función medible tal que $E_\theta[g(T)] = 0$ para todo $\theta > 0$. Probemos que $P_\theta[g(T) = 0] = 1$ para todo $\theta > 0$. Tenemos que:

$$E_\theta[g(T)] = \int_0^\theta g(x) f_{X_{(n)}}(x) dx = \int_0^\theta g(x) \frac{n x^{n-1}}{\theta^n} dx = \frac{n}{\theta^n} \int_0^\theta g(x) x^{n-1} dx = 0 \qquad \forall \theta > 0$$

Por tanto, como el primer término no se puede anular, se tiene:

$$\int_0^\theta g(x) x^{n-1} dx = 0 \qquad \forall \theta > 0$$

Aunque g no es continua, podemos aplicar el Teorema Fundamental del Cálculo, luego derivando con respecto a θ, tenemos que:

$$g(\theta) \theta^{n-1} = 0 \qquad \forall \theta > 0$$

Esto implica que $g(\theta) = 0$ para todo $\theta > 0$, luego:

$$\mathbb{R}^+ \subset \{x \in \mathbb{R} : g(x) = 0\}$$

Por tanto:

$$1 = P_\theta[T \in \mathbb{R}^+] \leqslant P_\theta[g(T) = 0] \leqslant 1$$

Por tanto, $P_\theta[g(T) = 0] = 1$ para todo $\theta > 0$; luego T es completo para θ.

Ejemplo. Demostrar que las siguientes familias de distribuciones son una familia exponencial uniparamétrica:

1. $\mathcal{P}(\lambda)$, con $\lambda > 0$

   En primer lugar, tenemos que $\lambda \in \Theta = \mathbb{R}^+$. Además, tenemos que:

   $$\chi = \mathbb{N} \qquad \forall \lambda \in \Theta$$

   Por último, para cada $\lambda \in \Theta$ y $x \in \chi$, tenemos que:

   $$P_\lambda[X = x] = e^{-\lambda}\frac{\lambda^x}{x!} = \exp\left(-\lambda + \ln\left(\frac{\lambda^x}{x!}\right)\right) = \exp\left(\ln(\lambda)x - \lambda - \ln(x!)\right)$$

   Por tanto, identificando términos, tenemos que:

   $$\begin{aligned} Q(\lambda) &= \ln(\lambda) \\ T(x) &= x \\ D(\lambda) &= -\lambda \\ S(x) &= -\ln(x!) \end{aligned}$$

   Por tanto, $\mathcal{P}(\lambda)$ es una familia exponencial uniparamétrica.

2. $\mathcal{B}(k_0, p)$, con $p \in]0,1[$ y $k_0 \in \mathbb{N}$ fijo.

   En primer lugar, tenemos que $p \in \Theta =]0,1[$. Además, tenemos que:

   $$\chi = \{0, 1, \ldots, k_0\} \qquad \forall p \in \Theta$$

   Por último, tenemos que:

   $$\begin{aligned} P_p[X = x] = \binom{k_0}{x} p^x (1-p)^{k_0 - x} &= \exp\left(\ln\left(\binom{k_0}{x} p^x (1-p)^{k_0-x}\right)\right) = \\ &= \exp\left(\ln\left(\binom{k_0}{x}\right) + x\ln(p) + (k_0 - x)\ln(1-p)\right) = \\ &= \exp\left(\ln\left(\binom{k_0}{x}\right) + x\ln\left(\frac{p}{1-p}\right) + k_0\ln(1-p)\right) \qquad \forall x \in \chi,\ \forall p \in \Theta \end{aligned}$$

   Por tanto, identificando términos, tenemos que:

   $$\begin{aligned} Q(p) &= \ln\left(\frac{p}{1-p}\right) \\ T(x) &= x \\ D(p) &= k_0 \ln(1-p) \\ S(x) &= \ln\left(\binom{k_0}{x}\right) \end{aligned}$$

Ejemplo. La $\mathcal{N}(\mu, \sigma^2)$ es una familia exponencial uniparamétrica en cada parámetro y bi-paramétrica en los dos parámetros.

Veamos primero que $\mathcal{N}(\mu, \sigma^2)$ es una familia exponencial uniparamétrica en μ para σ^2 conocida. En este caso, tenemos que:

$$\begin{aligned}
\Theta &= \mathbb{R} \\
\chi &= \mathbb{R} \\
f_\mu(x) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(x-\mu)^2}{2\sigma^2}\right) &= \exp\left(-\frac{(x-\mu)^2}{2\sigma^2} - \frac{1}{2}\ln(2\pi\sigma^2)\right) = \\
= \exp\left(-\frac{x^2 - 2\mu x + \mu^2}{2\sigma^2} - \frac{1}{2}\ln(2\pi\sigma^2)\right) &= \exp\left(\frac{\mu x}{\sigma^2} - \frac{\mu^2}{2\sigma^2} - \frac{x^2}{2\sigma^2} - \frac{1}{2}\ln(2\pi\sigma^2)\right)
\end{aligned}$$

Por tanto, identificando términos, tenemos que:

$$\begin{aligned}
Q(\mu) &= \frac{\mu}{\sigma^2} \\
T(x) &= x \\
D(\mu) &= -\frac{\mu^2}{2\sigma^2} \\
S(x) &= -\frac{x^2}{2\sigma^2} - \frac{1}{2}\ln(2\pi\sigma^2)
\end{aligned}$$

Vemos por tanto que $\mathcal{N}(\mu, \sigma^2)$ es una familia exponencial uniparamétrica en μ para σ^2 conocida. Veamos ahora que $\mathcal{N}(\mu, \sigma^2)$ es una familia exponencial uniparamétrica en σ^2 para μ conocida. En este caso, tenemos que:

$$\begin{aligned}
\Theta &= \mathbb{R}^+ \\
\chi &= \mathbb{R} \\
f_{\sigma^2}(x) &= \exp\left(-\frac{(x-\mu)^2}{2\sigma^2} - \frac{1}{2}\ln(2\pi\sigma^2)\right)
\end{aligned}$$

Por tanto, identificando términos, tenemos que:

$$\begin{aligned}
Q(\sigma^2) &= -\frac{1}{2\sigma^2} \\
T(x) &= (x-\mu)^2 \\
D(\sigma^2) &= -\frac{1}{2}\ln(2\pi\sigma^2) \\
S(x) &= 0
\end{aligned}$$

Por tanto, $\mathcal{N}(\mu, \sigma^2)$ es una familia exponencial uniparamétrica en σ^2 para μ conocida. Veamos por último que $\mathcal{N}(\mu, \sigma^2)$ es una familia exponencial bi-paramétrica en (μ, σ^2). En este caso, tenemos que:

$$\begin{aligned}
\Theta &= \mathbb{R} \times \mathbb{R}^+ \\
\chi &= \mathbb{R} \\
f_{\mu,\sigma^2}(x) &= \exp\left(\frac{\mu x}{\sigma^2} - \frac{\mu^2}{2\sigma^2} - \frac{x^2}{2\sigma^2} - \frac{1}{2}\ln(2\pi\sigma^2)\right)
\end{aligned}$$

Por tanto, identificando términos, tenemos que:

$$\begin{aligned} Q_1(\mu,\sigma^2) &= \frac{\mu}{\sigma^2} \\ Q_2(\mu,\sigma^2) &= -\frac{1}{2\sigma^2} \\ T_1(x) &= x \\ T_2(x) &= x^2 \\ D(\mu,\sigma^2) &= -\frac{\mu^2}{2\sigma^2} - \frac{1}{2}\ln(2\pi\sigma^2) \\ S(x) &= 0 \end{aligned}$$

Por tanto, $\mathcal{N}(\mu,\sigma^2)$ es una familia exponencial bi-paramétrica en (μ,σ^2).

Teorema 1.3.6. *Si se tiene una v.a. $X \rightsquigarrow \{F_\theta, \theta \in \Theta\}$ con familia de funciones asociadas, $\{f_\theta(x), \theta \in \Theta\}$, siendo f.d.d. o f.m.p. según el caso, donde la familia de distribuciones es exponencial k-paramétrica, entonces la familia de distribuciones asociadas a $(X_1,\ldots,X_n)$ (que es una m.a.s. de X) es también exponencial k-paramétrica:*

$$f_\theta^n(x_1,\ldots,x_n) = \exp\left[\sum_{h=1}^{k} Q_h(\theta)\sum_{i=1}^{n} T_h(x_i) + \sum_{i=1}^{n} S(x_i) + nD(\theta)\right], \qquad (x_1,\ldots,x_n) \in \chi^n$$

y se tiene:

1. *El estadístico $\left(\sum_{i=1}^{n} T_1(X_i),\ldots,\sum_{i=1}^{n} T_k(X_i)\right)$ es suficiente para θ.*
2. *Si $k \leqslant n$ y el conjunto imagen de la función $Q(\theta) = (Q_1(\theta),\ldots,Q_k(\theta))$ contiene a un abierto de $\mathbb{R}^k$, el estadístico $\left(\sum_{i=1}^{n} T_1(X_i),\ldots,\sum_{i=1}^{n} T_k(X_i)\right)$ es también completo.*

Demostración. Comprobemos que $(X_1,\ldots,X_n)$ es una familia exponencial k-paramétrica. Por ser la familia de distribuciones asociadas a X una familia exponencial k-paramétrica, tenemos que Θ es un intervalo de $\mathbb{R}^k$. Además, tenemos que el espacio muestral de $(X_1,\ldots,X_n)$ es independiente de θ, y es χ^n. Por último, tenemos que:

$$\begin{aligned} f_\theta^n(x_1,\ldots,x_n) = \prod_{i=1}^{n} f_\theta(x_i) &= \prod_{i=1}^{n} \exp\left[\sum_{h=1}^{k} Q_h(\theta)T_h(x_i) + S(x_i) + D(\theta)\right] = \\ &= \exp\left[\sum_{i=1}^{n}\sum_{h=1}^{k} Q_h(\theta)T_h(x_i) + \sum_{i=1}^{n} S(x_i) + \sum_{i=1}^{n} D(\theta)\right] = \\ &= \exp\left[\sum_{h=1}^{k} Q_h(\theta)\sum_{i=1}^{n} T_h(x_i) + \sum_{i=1}^{n} S(x_i) + nD(\theta)\right] \end{aligned}$$

Por tanto, identificando términos, tenemos que:

$$\begin{aligned} Q_h^n(\theta) &= Q_h(\theta) \\ T_h^n(x_1,\dots,x_n) &= \sum_{i=1}^n T_h(x_i) \\ S^n(x_1,\dots,x_n) &= \sum_{i=1}^n S(x_i) \\ D^n(\theta) &= nD(\theta) \end{aligned}$$

Por tanto, $(X_1,\dots,X_n)$ es una familia exponencial k-paramétrica. Veamos ahora que $\left(\sum_{i=1}^n T_1(X_i),\dots,\sum_{i=1}^n T_k(X_i)\right)$ es suficiente para θ.

$$\begin{aligned} f_\theta^n(x_1,\dots,x_n) &= \exp\left[\sum_{h=1}^k Q_h(\theta)\sum_{i=1}^n T_h(x_i) + \sum_{i=1}^n S(x_i) + nD(\theta)\right] = \\ &= \underbrace{\exp\left[\sum_{i=1}^n S(x_i)\right]}_{h(x_1,\dots,x_n)} \underbrace{\exp\left[\sum_{h=1}^k Q_h(\theta)\sum_{i=1}^n T_h(x_i) + nD(\theta)\right]}_{g_\theta\left(\sum_{i=1}^n T_1(x_i),\dots,\sum_{i=1}^n T_k(x_i)\right)} \end{aligned}$$

Por el Teorema de Factorización de Neyman-Fisher, tenemos que el estadístico $\left(\sum_{i=1}^n T_1(X_i),\dots,\sum_{i=1}^n T_k(X_i)\right)$ es suficiente para θ. Respecto a la complitud, al ser más complicado, no se incluye la demostración. □

Ejemplo. Sea X una v.a. con distribución $\mathcal{N}(\mu,\sigma^2)$ con $\mu\in\mathbb{R}$ y $\sigma^2>0$. Buscar un estadístico suficiente y completo basado en una muestra de tamaño n.

Como hemos visto en el ejemplo anterior, $\mathcal{N}(\mu,\sigma^2)$ es una familia exponencial bi-paramétrica en (μ,σ^2). Por tanto, por el Teorema anterior, tenemos que la familia de distribuciones asociadas a $(X_1,\dots,X_n)$ es también una familia exponencial bi-paramétrica. Por tanto, el estadístico:

$$\left(\sum_{i=1}^n X_i, \sum_{i=1}^n X_i^2\right)$$

es suficiente para (μ,σ^2). Además, veamos que la imagen de $Q(\mu,\sigma^2)$ contiene un abierto de $\mathbb{R}^2$. Consideremos la aplicación:

$$\begin{aligned} Q:\ \Theta=\mathbb{R}\times\mathbb{R}^+ &\longrightarrow \mathbb{R}^2 \\ (\mu,\sigma^2) &\longmapsto \left(\frac{\mu}{\sigma^2}, -\frac{1}{2\sigma^2}\right) \end{aligned}$$

Observemos que al variar $\sigma^2\in\mathbb{R}^+$, la segunda componente $Q_2 = {}^{-1}\!/_{2\sigma^2}$ recorre todo el intervalo $\mathbb{R}^-$. Para cualquier valor fijado de $Q_2\in\mathbb{R}^-$, al variar $\mu\in\mathbb{R}$, la

primera componente $Q_1 = -2\mu Q_2$ recorre todo $\mathbb{R}$. Por consiguiente, el conjunto imagen de Q es:

$$Q(\Theta) = \mathbb{R} \times \mathbb{R}^-$$

que es un abierto de $\mathbb{R}^2$. Por tanto, por el Teorema anterior, si $n \geqslant 2$, el estadístico:

$$\left(\sum_{i=1}^{n} X_i, \sum_{i=1}^{n} X_i^2 \right)$$

es también completo para (μ, σ^2).

1.4. Estimación puntual. Insesgadez y mínima varianza

Ejemplo. Sea $(X_1, \ldots, X_n)$ una muestra aleatoria simple de una variable aleatoria X con distribución $\mathcal{P}(\lambda)$, $\lambda > 0$. La media muestral $\overline{X}$ es un estimador de λ. Además, cualquier función medible de la muestra que sea independiente del parámetro λ y tome valores positivos es un estimador del parámetro.

$$\overline{X} = \frac{1}{n}\sum_{i=1}^{n} X_i \geqslant 0$$

donde la positividad de $\overline{X}$ se debe a que $X_i \geqslant 0$ para todo $i = 1, \ldots, n$. Por lo tanto, $\overline{X}$ es un estimador de λ.

Ejemplo. Sea $(X_1, \ldots, X_n)$ una muestra aleatoria simple de una variable aleatoria X con distribución $\mathcal{B}(1, p)$, $p \in]0, 1[$. La media muestral $\overline{X}$ es un estimador de p. Además, cualquier función medible de la muestra que sea independiente del parámetro p y tome valores en el intervalo $(0, 1)$ es un estimador del parámetro.

$$\overline{X} = \frac{1}{n}\sum_{i=1}^{n} X_i \in [0, 1]$$

donde la pertenencia al intervalo $[0, 1]$ se debe a que $X_i \in \{0, 1\}$ para todo valor $i = 1, \ldots, n$. Estrictamente hablando, como p no puede tomar los valores 0 y 1, entonces $\overline{X}$ no podría tomar esos valores. No obstante, estos valores son muy particulares, puesto que implicarían que todos los X_i toman el mismo valor, lo que podría hacernos pensar que no se trata de un experimento aleatorio. Por tanto, en estos casos, que también contenga a los extremos del intervalo no es un problema. Por lo tanto, $\overline{X}$ es un estimador de p.

Proposición 1.4.7. Sea X una v.a. con función de distribución en una familia de distribuciones paramétricas, $F \in \{F_\theta : \theta \in \Theta\}$ y $(X_1, \ldots, X_n)$ una m.a.s. de X. Sea $T = T(X_1, \ldots, X_n)$ un estimador de θ. El error cuadrático medio (ECM) de T se define como:

$$ECM_T(\theta) := E_\theta\left[(T - \theta)^2\right]$$

El ECM puede descomponerse en términos de la varianza y una función denominada sesgo:

$$ECM_T(\theta) = Var_\theta[T] + B_T^2(\theta) \qquad \text{donde } B_T(\theta) := E_\theta[T] - \theta$$

Demostración. Tenemos que:

$$\begin{aligned}
ECM_T(\theta) &= E_\theta\left[(T-\theta)^2\right] = E_\theta\left[(T - E_\theta[T] + E_\theta[T] - \theta)^2\right] \\
&= E_\theta\left[(T - E_\theta[T])^2 + 2(T - E_\theta[T])(E_\theta[T] - \theta) + (E_\theta[T] - \theta)^2\right] \\
&= Var_\theta[T] + 2(E_\theta[T] - \theta)E_\theta[T - E_\theta[T]] + (E_\theta[T] - \theta)^2 \\
&= Var_\theta[T] + 2(E_\theta[T] - \theta)\cancel{(E_\theta[T] - E_\theta[T])} + (E_\theta[T] - \theta)^2 \\
&= Var_\theta[T] + (E_\theta[T] - \theta)^2 \\
&= Var_\theta[T] + B_T^2(\theta)
\end{aligned}$$

□

Ejemplo. Sea $(X_1, \ldots, X_n)$ una muestra aleatoria simple de alguna población. Probar que, en general, la cuasidesviación típica no es un estimador insesgado de la desviación típica poblacional.

Demostración. Sea $(X_1, \ldots, X_n)$ una muestra aleatoria simple de $X \rightsquigarrow \mathcal{N}(\mu, \sigma^2)$, $\mu \in \mathbb{R}$ y $\sigma^2 > 0$. Sabemos que $E[S^2] = \sigma^2$. Queremos ver si $E[S] = \sigma$. Sabemos que:

$$Y = \frac{(n-1)S^2}{\sigma^2} \sim \chi^2(n-1)$$

Por tanto:

$$\begin{aligned} E\left[\sqrt{Y}\right] &= \int_0^\infty \sqrt{y} f_Y(y) dy = \int_0^\infty \sqrt{y} \frac{1}{2^{(n-1)/2}\Gamma((n-1)/2)} y^{(n-3)/2} e^{-y/2} dy = \\ &= \frac{1}{2^{(n-1)/2}\Gamma((n-1)/2)} \int_0^\infty y^{n/2-1} e^{-y/2} dy \overset{(*)}{=} \\ &\overset{(*)}{=} \frac{1}{2^{(n-1)/2}\Gamma((n-1)/2)} \cdot \frac{\Gamma(n/2)}{(1/2)^{n/2}} \end{aligned}$$

donde en $(*)$ hemos aplicado que la función de densidad de la distribución $\chi^2(n)$ integra 1. Por tanto:

$$E[\sqrt{Y}] = E\left[\sqrt{\frac{(n-1)S^2}{\sigma^2}}\right] = \frac{\sqrt{n-1}E[S]}{\sigma}$$

Por tanto:

$$E[S] = \frac{\sigma}{\sqrt{n-1}} E[\sqrt{Y}] = \frac{\sigma}{\sqrt{n-1}} \cdot \frac{1}{2^{(n-1)/2}\Gamma((n-1)/2)} \cdot \frac{\Gamma(n/2)}{(1/2)^{n/2}} \neq \sigma$$

Por tanto, S no es un estimador insesgado de σ. □

Ejemplo. Sea $(X_1, \ldots, X_n)$ una m.a.s. de una distribución binomial $\mathcal{B}(1, p)$. Probar que

$$\frac{T^2 - T}{n^2 - n}$$

con $T = \sum_{i=1}^{n} X_i$ es un estimador insesgado para la función paramétrica $g(p) = p^2$. Probar, además, que para $n = 1$ no existe un estimador insesgado de p^2.

Demostración. Es directo ver que se trata de un estimador. Veamos que es insesgado, para lo que calculamos su esperanza:

$$\begin{aligned} E\left[\frac{T^2 - T}{n^2 - n}\right] &= \frac{1}{n^2 - n} E[T^2 - T] = \frac{1}{n^2 - n}\left(E[T^2] - E[T]\right) \overset{(*)}{=} \\ &\overset{(*)}{=} \frac{1}{n^2 - n}\left(Var[T] + E[T]^2 - E[T]\right) = \frac{1}{n^2 - n}\left(np(1-p) + (np)^2 - np\right) = \\ &= \frac{1}{n^2 - n}\left(n^2p^2 - np^2\right) = p^2 \end{aligned}$$

donde en $(*)$ hemos aplicado la identidad $Var[T] = E[T^2] - E[T]^2$. Por tanto, $\dfrac{T^2 - T}{n^2 - n}$ es un estimador insesgado de p^2. Veamos ahora que para el valo de $n = 1$ no existe un estimador insesgado de p^2. Supongamos que existe un estimador insesgado $T(X)$ de p^2 basado en una muestra de tamaño 1. Entonces, por definición de insesgadez, se cumple que:

$$p^2 = E_p[T(X)] = T(0)(1-p) + T(1)p \Longrightarrow p^2 = T(0) - T(0)p + T(1)p$$

La expresión de la derecha es una ecuación polinómica de primer grado en p, mientras que p^2 es un polinomio de segundo grado en p. Llegamos por tanto a una contradicción, ya que no puede haber un polinomio de segundo grado igual a un polinomio de primer grado. Por tanto, no existe un estimador insesgado de p^2 basado en una muestra de tamaño 1. □

Ejemplo. Sea X una v.a. con distribución $\mathcal{P}(\lambda)$, ¿existe algún estimador insesgado de $1/\lambda$ basado en una muestra de tamaño 1?

Supongamos que existe un estimador insesgado $T(X)$ de $1/\lambda$ basado en una muestra de tamaño 1. Entonces, por definición de insesgadez, se cumple que:

$$\frac{1}{\lambda} = E_\lambda[T(X)] = \sum_{x=0}^{\infty} T(x)\frac{e^{-\lambda}\lambda^x}{x!} \Longrightarrow e^\lambda = \sum_{x=0}^{\infty} T(x)\frac{\lambda^{x+1}}{x!}$$

Empleando la serie de Taylor de e^λ, obtenemos:

$$\sum_{x=0}^{\infty} \frac{\lambda^x}{x!} = \sum_{x=0}^{\infty} T(x)\frac{\lambda^{x+1}}{x!}$$

La primera sumatoria tiene un término independiente de λ, mientras que la segunda sumatoria no. Como ha de ser cierta la igualdad para todo $\lambda > 0$, se llega a una contradicción. Por tanto, no existe un estimador insesgado de $1/\lambda$ basado en una muestra de tamaño 1.

Teorema 1.4.8 (Rao-Blackwell)**.** *Sea X una v.a. con función de distribución en una familia de distribuciones paramétricas, $F \in \{F_\theta : \theta \in \Theta\}$, y $(X_1, \ldots, X_n)$ una m.a.s. de X. Si $T(X_1, \ldots, X_n)$ es un estadístico suficiente para la familia $\{F_\theta : \theta \in \Theta\}$ y $S(X_1, \ldots, X_n)$ es un estimador insesgado de $g(\theta)$ con momento de segundo orden finito, entonces:*

1. *$E[S(X_1, \ldots, X_n) \mid T(X_1, \ldots, X_n)]$ es un estimador insesgado de $g(\theta)$ y tiene momento de segundo orden finito.*
2. *$Var_\theta\left[E[S(X_1, \ldots, X_n) \mid T(X_1, \ldots, X_n)]\right] \leqslant Var_\theta[S(X_1, \ldots, X_n)]$, $\forall \theta \in \Theta$.*

Demostración. Demostramos cada una de las afirmaciones por separado:

1. En primer lugar, veamos que $E[S(X_1, \ldots, X_n) \mid T(X_1, \ldots, X_n)]$ es un estadístico. Es claro que $E_\theta[S(X_1, \ldots, X_n) \mid T(X_1, \ldots, X_n)]$ es un función de la m.a.s., pero hemos de ver que no depende del parámetro θ:

$$E_\theta[S(X_1,\dots,X_n) \mid T(X_1,\dots,X_n)] = \\ = \int_{\chi^n} S(x_1,\dots,x_n) f_{X_1,\dots,X_n|T}(x_1,\dots,x_n)\, dx_1 \dots dx_n$$

Como T es un estadístico suficiente, la función de densidad condicionada $f_{X_1,\dots,X_n|T}(x_1,\dots,x_n)$ no depende de θ. Por tanto, $E[S(X_1,\dots,X_n) \mid T(X_1,\dots,X_n)]$ no depende del parámetro θ, luego es un estadístico. Además, como $S(X_1,\dots,X_n)$ es un estimador de $g(\theta)$, toma valores en el rango de $g(\theta)$, luego al tomar la esperanza condicionada también tomará valores en el rango de $g(\theta)$, luego es un estimador de $g(\theta)$. Además, como S es un estimador insesgado de $g(\theta)$, entonces $E_\theta[S(X_1,\dots,X_n)] = g(\theta)$, y por la propiedad de la esperanza condicionada, tenemos que:

$$E_\theta[E[S(X_1,\dots,X_n) \mid T(X_1,\dots,X_n)]] = E_\theta[S(X_1,\dots,X_n)] = g(\theta)$$

Por tanto, $E[S(X_1,\dots,X_n) \mid T(X_1,\dots,X_n)]$ es un estimador insesgado de $g(\theta)$.

Veamos ahora que tiene momento de segundo orden finito. Como S tiene momento de segundo orden finito, entonces su momento de segundo orden condicionado también es finito, luego:

$$Var_\theta[S(X_1,\dots,X_n) \mid T(X_1,\dots,X_n)] = \\ = E_\theta[S^2(X_1,\dots,X_n) \mid T(X_1,\dots,X_n)] - E_\theta[S(X_1,\dots,X_n) \mid T(X_1,\dots,X_n)]^2 \geqslant 0$$

Por tanto:

$$E_\theta[S^2(X_1,\dots,X_n) \mid T(X_1,\dots,X_n)] \geqslant E_\theta[S(X_1,\dots,X_n) \mid T(X_1,\dots,X_n)]^2$$

Tomando esperanza:

$$E_\theta[E_\theta[S(X_1,\dots,X_n) \mid T(X_1,\dots,X_n)]^2] \leqslant \\ \leqslant E_\theta[E_\theta[S^2(X_1,\dots,X_n) \mid T(X_1,\dots,X_n)]] = E_\theta[S^2(X_1,\dots,X_n)] < \infty$$

2. Empleamos la descomposición de la varianza:

$$Var_\theta[S(X_1,\dots,X_n)] = \\ = E_\theta[Var_\theta[S(X_1,\dots,X_n) \mid T(X_1,\dots,X_n)]] + Var_\theta[E[S(X_1,\dots,X_n) \mid T(X_1,\dots,X_n)]]$$

Como $E_\theta[Var_\theta[S(X_1,\dots,X_n) \mid T(X_1,\dots,X_n)]] \geqslant 0$, se sigue que:

$$Var_\theta[S(X_1,\dots,X_n)] \geqslant Var_\theta[E[S(X_1,\dots,X_n) \mid T(X_1,\dots,X_n)]]$$

□

Teorema 1.4.9 (Lehmann-Scheffé)**.** *Sea $T(X_1,\dots,X_n)$ un estadístico suficiente y completo para la familia de distribuciones consideradas, $\{F_\theta : \theta \in \Theta\}$. Si $g(\theta)$ admite un estimador insesgado con momento de segundo orden finito, $S(X_1,\dots,X_n)$, entonces existe el UMVUE de $g(\theta)$, que viene dado por:*

$$E[S(X_1,\dots,X_n) \mid T(X_1,\dots,X_n)]$$

Demostración. Sea $S(X_1, \ldots, X_n)$ el estimador insesgado de $g(\theta)$ con momento de segundo orden finito proporcionado por el enunciado, y supongamos otro estimador insesgado $S_2(X_1, \ldots, X_n)$ de $g(\theta)$ con momento de segundo orden finito. Por el teorema de Rao-Blackwell aplicado a S y S_2, tenemos que:

$$U(T(X_1, \ldots, X_n)) = E[S(X_1, \ldots, X_n) \mid T(X_1, \ldots, X_n)]$$
$$U_2(T(X_1, \ldots, X_n)) = E[S_2(X_1, \ldots, X_n) \mid T(X_1, \ldots, X_n)]$$

son estimadores insesgados de $g(\theta)$ con momento de segundo orden finito. Además, por el teorema de Rao-Blackwell, se cumple que:

$$Var_\theta[U] \leqslant Var_\theta[S]$$
$$Var_\theta[U_2] \leqslant Var_\theta[S_2]$$

Definimos ahora $h(T(X_1, \ldots, X_n)) = U(T(X_1, \ldots, X_n)) - U_2(T(X_1, \ldots, X_n))$. Como U y U_2 son insesgados de $g(\theta)$, se cumple que:

$$E_\theta[h(T(X_1, \ldots, X_n))] = E_\theta[U(T(X_1, \ldots, X_n))] - E_\theta[U_2(T(X_1, \ldots, X_n))] = g(\theta) - g(\theta) = 0$$

Como T es completo para θ, se sigue que:

$$P_\theta[h(T(X_1, \ldots, X_n)) = 0] = 1 \qquad \forall \theta \in \Theta$$

Por tanto:

$$P[U(T(X_1, \ldots, X_n)) = U_2(T(X_1, \ldots, X_n))] = 1 \qquad \forall \theta \in \Theta$$

De esta manera, se deduce que $Var_\theta[U] = Var_\theta[U_2]$, luego:

$$Var_\theta[U] \leqslant Var_\theta[S_2] \qquad \forall \theta \in \Theta$$

Por tanto, $U(T(X_1, \ldots, X_n))$ es el UMVUE de $g(\theta)$. □

Ejemplo. Sea $(X_1, \ldots, X_n)$ una m.a.s. con distribución $\mathcal{B}(1, p)$, $p \in [0, 1]$. Encontrar el UMVUE para p.

En el ejemplo de la página 25, vimos que:

$$T = \sum_{i=1}^{n} X_i$$

es un estadístico suficiente y completo para p. Además, $T \rightsquigarrow \mathcal{B}(n, p)$, por lo que:

$$E[T] = np \Longrightarrow E\left[\frac{T}{n}\right] = p$$

Por tanto, de ser $S = {}^{T}/_{n}$ estimador, es insesgado de p. Como X toma valores en $\{0, 1\}$, entonces T toma valores en $\{0, 1, \ldots, n\}$ y S toma valores en $\{0, {}^{1}/_{n}, \ldots, 1\}$. Por tanto, S es un estimador insesgado de p. Nos falta ver que tiene momento de segundo orden finito. Como S es una función de T, entonces:

$$Var[S] = Var\left[\frac{T}{n}\right] = \frac{1}{n^2} Var[T] = \frac{1}{n^2} np(1-p) < \infty$$

Por tanto, S es un estimador insesgado de p con momento de segundo orden finito. Por tanto, por el teorema de Lehmann-Scheffé, el UMVUE de p es:

$$E[S \mid T] = E\left[\frac{T}{n} \mid T\right] = \frac{T}{n} = \frac{1}{n}\sum_{i=1}^{n} X_i = \overline{X}$$

Por tanto, el UMVUE de p es la media muestral $\overline{X}$.

Ejemplo. Sea $(X_1, \ldots, X_n)$ una m.a.s. con distribución $\mathcal{U}(0, \theta)$, $\theta > 0$. Encontrar el UMVUE para θ y $1/\theta$.

En el ejemplo de la página 26, vimos que:

$$T = X_{(n)} = \text{máx}\{X_1, \ldots, X_n\}$$

es un estadístico suficiente y completo para θ. Además, su función de densidad es:

$$f_{X_{(n)}}(x) = \frac{n}{\theta^n} x^{n-1} \qquad \text{para } 0 < x < \theta$$

Por tanto:

$$E_\theta[X_{(n)}] = \int_0^\theta x \frac{n}{\theta^n} x^{n-1} dx = \frac{n}{\theta^n} \int_0^\theta x^n dx = \frac{n}{\theta^n} \left[\frac{x^{n+1}}{n+1}\right]_0^\theta = \frac{n}{\theta^n} \cdot \frac{\theta^{n+1}}{n+1} = \frac{n}{n+1}\theta$$

Por tanto, de ser $S = \dfrac{n+1}{n} X_{(n)}$ estimador, es insesgado de θ. Como $X_{(n)}$ toma valores en $]0, \theta[$, entonces S toma valores en $\left]0, \dfrac{n+1}{n}\theta\right[\subset \mathbb{R}^+$. Por tanto, S es un estimador insesgado de θ. Nos falta ver que tiene momento de segundo orden finito:

$$E[S^2] = E\left[\left(\frac{n+1}{n} X_{(n)}\right)^2\right] = \left(\frac{n+1}{n}\right)^2 E[X_{(n)}^2]$$

Comprobamos que $E[X_{(n)}^2] < \infty$:

$$E[X_{(n)}^2] = \int_0^\theta x^2 \frac{n}{\theta^n} x^{n-1} dx = \frac{n}{\theta^n} \int_0^\theta x^{n+1} dx < \infty$$

Donde la integral es finita, ya que $n \geqslant 1$. Por tanto, S tiene momento de segundo orden finito. Por tanto, por el teorema de Lehmann-Scheffé, el UMVUE de θ es:

$$E[S \mid T] = E\left[\frac{n+1}{n} X_{(n)} \mid X_{(n)}\right] = \frac{n+1}{n} X_{(n)}$$

Buscamos ahora el UMVUE de $1/\theta$. Para ello, buscamos una función $h(T)$ tal que:

$$E_\theta[h(T)] = \frac{1}{\theta}$$

Tenemos que:

$$E_\theta[h(T)] = \int_0^\theta h(x)\frac{n}{\theta^n}x^{n-1}dx = \frac{n}{\theta^n}\int_0^\theta h(x)x^{n-1}dx = \frac{1}{\theta}$$

Multiplicando por θ^n y dividiendo por n, obtenemos:

$$\int_0^\theta h(x)x^{n-1}dx = \frac{\theta^{n-1}}{n}$$

Por el teorema fundamental del cálculo, tenemos que:

$$h(\theta)\theta^{n-1} = \frac{(n-1)\theta^{n-2}}{n} \Longrightarrow h(\theta) = \frac{n-1}{n}\cdot\frac{1}{\theta}$$

Por tanto, para $n > 1$, consideramos el estadístico:

$$S = \frac{n-1}{n}\cdot\frac{1}{X_{(n)}}$$

Como $X_{(n)}$ toma valores en $]0,\theta[$, entonces S toma valores en un subconjunto de $\mathbb{R}^+$, luego es un estimador de $1/\theta$. Además, veamos que es insesgado:

$$E_\theta[S] = E_\theta\left[\frac{n-1}{n}\cdot\frac{1}{X_{(n)}}\right] = \frac{n-1}{n}\int_0^\theta \frac{1}{x}\frac{n}{\theta^n}x^{n-1}dx =$$
$$= \frac{n-1}{\theta^n}\int_0^\theta x^{n-2}dx = \frac{n-1}{\theta^n}\left[\frac{x^{n-1}}{n-1}\right]_0^\theta = \frac{1}{\theta}$$

Por tanto, S es un estimador insesgado de $1/\theta$. Nos falta ver que tiene momento de segundo orden finito:

$$Var[S] = Var\left[\frac{n-1}{n}\cdot\frac{1}{X_{(n)}}\right] = \left(\frac{n-1}{n}\right)^2 Var\left[\frac{1}{X_{(n)}}\right]$$

Comprobamos que $Var\left[\frac{1}{X_{(n)}}\right] < \infty$:

$$E\left[\frac{1}{X_{(n)}^2}\right] = \int_0^\theta \frac{1}{x^2}\frac{n}{\theta^n}x^{n-1}dx = \frac{n}{\theta^n}\int_0^\theta x^{n-3}dx < \infty \iff n \geqslant 3$$

Por tanto, para $n \geqslant 3$, S tiene momento de segundo orden finito. Por tanto, por el teorema de Lehmann-Scheffé, el UMVUE de $1/\theta$ es:

$$E[S \mid T] = E\left[\frac{n-1}{n}\cdot\frac{1}{X_{(n)}} \mid X_{(n)}\right] = \frac{n-1}{n}\cdot\frac{1}{X_{(n)}}$$

Ejercicio 1.4.1. Sea $(X_1,\ldots,X_n)$ una m.a.s. con distribución $\mathcal{P}(\lambda)$, $\lambda > 0$. Encontrar el UMVUE de λ^s, $s \in \mathbb{N}$.

Buscamos un estadístico suficiente y completo. Por el Ejercicio 2.3.7.b), sabemos que:

$$T = \sum_{i=1}^n X_i$$

es un estadístico suficiente y completo para λ. Para encontrar el UMVUE de λ^s, buscamos una función $h(T)$ tal que:

$$E_\lambda[h(T)] = \lambda^s$$

Como $T \rightsquigarrow \mathcal{P}(n\lambda)$, tenemos que:

$$E_\lambda[h(T)] = \sum_{t=0}^{\infty} h(t)\frac{e^{-n\lambda}(n\lambda)^t}{t!} = \lambda^s \Longrightarrow e^{n\lambda}\lambda^s = \sum_{t=0}^{\infty} h(t)\frac{(n\lambda)^t}{t!}$$

Empleando la serie de Taylor de $e^{n\lambda}$, obtenemos:

$$\sum_{t=0}^{\infty} h(t)\frac{n^t}{t!}\lambda^t = \sum_{t=0}^{\infty} h(t)\frac{(n\lambda)^t}{t!} = \lambda^s \sum_{t=0}^{\infty} \frac{(n\lambda)^t}{t!} = \sum_{t=0}^{\infty} \frac{n^t}{t!}\lambda^{s+t}$$

En la sumatoria de la derecha, hacemos el cambio de variable $k = s+t$, de modo que $t = k - s$. Por tanto:

$$\sum_{t=0}^{\infty} h(t)\frac{n^t}{t!}\lambda^t = \sum_{k=s}^{\infty} \frac{n^{k-s}}{(k-s)!}\lambda^k$$

Como la igualdad ha de cumplirse para todo $\lambda > 0$, se sigue que:

- Para $t < s$:

$$h(t)\frac{n^t}{t!} = 0 \Longrightarrow h(t) = 0$$

- Para $t \geqslant s$:

$$h(t)\frac{n^t}{t!} = \frac{n^{t-s}}{(t-s)!} \Longrightarrow h(t) = \frac{n^{t-s}}{(t-s)!} \cdot \frac{t!}{n^t} = \frac{t!}{(t-s)!n^s}$$

Por tanto, consideramos el estadístico:

$$S = h(T) = \begin{cases} 0 & \text{si } T < s \\ \dfrac{T!}{(T-s)!n^s} & \text{si } T \geqslant s \end{cases}$$

Como T toma valores en $\mathbb{N}$, entonces S toma valores en $\mathbb{R}^+$, luego es un estimador de λ^s. Además, se ha construido de manera que es insesgado:

$$E_\lambda[S] = E_\lambda[h(T)] = \lambda^s$$

Nos falta ver que tiene momento de segundo orden finito:

$$Var[S] = Var[h(T)] < \infty$$

Por ser S un polinomio de T, y como T tiene momentos de todos los órdenes finitos, se sigue que S tiene momento de segundo orden finito. Por tanto, por el teorema de Lehmann-Scheffé, el UMVUE de λ^s es:

$$E[S \mid T] = E[h(T) \mid T] = h(T) = \begin{cases} 0 & \text{si } T < s \\ \dfrac{T!}{(T-s)!n^s} & \text{si } T \geqslant s \end{cases}$$

Lema 1.4.10 (Caso discreto de la 3ª condición de regularidad)**.** Sea X una v.a. con función de distribución en una familia de distribuciones paramétricas, $F \in \{F_\theta : \theta \in \Theta\}$. Sea f_θ la función masa de probabilidad de X para cada $\theta \in \Theta$. Entonces, si $f_\theta(x)$ es derivable respecto a θ para todo $x \in \chi$, se cumple que:

$$E_\theta\left[\frac{\partial}{\partial\theta}\ln f_\theta(X)\right] = 0 \iff \sum_{x\in\chi}\frac{\partial}{\partial\theta}f_\theta(x) = 0$$

Demostración. Tenemos que, para todo $\theta \in \Theta$:

$$E_\theta\left[\frac{\partial}{\partial\theta}\ln f_\theta(X)\right] = \sum_{x\in\chi}\frac{\partial}{\partial\theta}\ln f_\theta(x) f_\theta(x) = \sum_{x\in\chi}\frac{1}{\cancel{f_\theta(x)}}\frac{\partial}{\partial\theta}f_\theta(x)\cancel{f_\theta(x)} = \sum_{x\in\chi}\frac{\partial}{\partial\theta}f_\theta(x)$$

□

Teorema 1.4.11. *Si X es una v.a. con función de distribución en una familia de distribuciones paramétricas, $F \in \{F_\theta : \theta \in \Theta\}$, cuya familia de distribuciones es regular, entonces la familia de distribuciones de una m.a.s. $(X_1, \ldots, X_n)$ de X también es regular.*

Demostración. Comprobamos cada una de las condiciones de regularidad:

1. Θ no cambia, por lo que sigue siendo un intervalo abierto de $\mathbb{R}$.

2. La función de densidad conjunta de $(X_1, \ldots, X_n)$ es:

$$f_\theta(x_1, \ldots, x_n) = \prod_{i=1}^n f_\theta(x_i)$$

   Por tanto, el conjunto de soporte de $(X_1, \ldots, X_n)$ es el mismo que el de X, y no depende de θ.

3. Como $f_\theta(x)$ es derivable respecto a θ para todo $x \in \chi$, entonces $f_\theta(x_1, \ldots, x_n)$ también es derivable respecto a θ para todo $(x_1, \ldots, x_n) \in \chi^n$. En tal caso, se cumple que:

$$E_\theta\left[\frac{\partial}{\partial\theta}\ln f_\theta(X_1, \ldots, X_n)\right] = E_\theta\left[\frac{\partial}{\partial\theta}\ln\prod_{i=1}^n f_\theta(X_i)\right] = E_\theta\left[\sum_{i=1}^n\frac{\partial}{\partial\theta}\ln f_\theta(X_i)\right] =$$
$$= \sum_{i=1}^n E_\theta\left[\frac{\partial}{\partial\theta}\ln f_\theta(X_i)\right] = 0$$

   donde se ha aplicado que el logaritmo de un producto es la suma de los logaritmos, que la derivada de una suma es la suma de las derivadas, y que la esperanza de una suma es la suma de las esperanzas.

Por tanto, la familia de distribuciones de una m.a.s. $(X_1, \ldots, X_n)$ de X también es regular. □

Proposición 1.4.12. Sea $X \rightsquigarrow F \in \{F_\theta : \theta \in \Theta\}$ una familia de distribuciones regular. Entonces:

$$I_{X_1,\ldots,X_n}(\theta) = nI_X(\theta) \qquad \forall\theta \in \Theta$$

Demostración. Sea $(X_1, \ldots, X_n)$ una m.a.s. de X. Por la definición de información de Fisher:

$$I_{X_1,\ldots,X_n}(\theta) = Var_\theta\left[\frac{\partial}{\partial\theta}\ln f_\theta(X_1,\ldots,X_n)\right] = Var_\theta\left[\frac{\partial}{\partial\theta}\ln\prod_{i=1}^{n} f_\theta(X_i)\right] = Var_\theta\left[\sum_{i=1}^{n}\frac{\partial}{\partial\theta}\ln f_\theta(X_i)\right]$$

Como $X_1, \ldots, X_n$ son independientes y las derivadas respecto a θ del logaritmo de sus funciones de densidad son funciones de cada X_i, estas últimas son independientes. Por tanto, la varianza de la suma es la suma de las varianzas:

$$I_{X_1,\ldots,X_n}(\theta) = \sum_{i=1}^{n} Var_\theta\left[\frac{\partial}{\partial\theta}\ln f_\theta(X_i)\right] = \sum_{i=1}^{n} I_{X_i}(\theta) = nI_X(\theta)$$

□

Teorema 1.4.13 (Cota de Fréchet-Cramér-Rao)**.** *Sea $(X_1, \ldots, X_n)$ una m.a.s. de $X \rightsquigarrow F \in \{F_\theta : \theta \in \Theta\}$, cuya familia de distribuciones es regular y se cumple $0 < I_X(\theta) < +\infty\ \forall\theta \in \Theta$. Si $T(X_1, \ldots, X_n)$ es un estadístico regular, de segundo orden e insesgado en una función paramétrica derivable $g(\theta)$, entonces se tiene:*

1. $Var_\theta[T(X_1,\ldots,X_n)] \geqslant \dfrac{(g'(\theta))^2}{I_{X_1,\ldots,X_n}(\theta)} \qquad \forall\theta \in \Theta.$

2. *Para los puntos θ_0 tales que $g'(\theta_0) \neq 0$, se dará la igualdad si y sólo si existe $a(\theta_0) \neq 0$ tal que:*

$$P_{\theta_0}\left[\frac{\partial}{\partial\theta}\ln f_\theta(X_1,\ldots,X_n)\bigg|_{\theta=\theta_0} = a(\theta_0)[T(X_1,\ldots,X_n) - g(\theta_0)]\right] = 1$$

Demostración. Demostramos cada resultado por separado.

1. Como T es un estadístico insesgado de $g(\theta)$ (derivable), se cumple que:

$$E_\theta[T(X_1,\ldots,X_n)] = g(\theta) \Longrightarrow g'(\theta) = \frac{\partial}{\partial\theta}E_\theta[T(X_1,\ldots,X_n)]$$

Como T es un estadístico regular, se cumple que:

$$g'(\theta) = \frac{\partial}{\partial\theta}E_\theta[T(X_1,\ldots,X_n)] = E_\theta\left[T(X_1,\ldots,X_n)\frac{\partial}{\partial\theta}\ln f_\theta^n(X_1,\ldots,X_n)\right]$$

En vistas de la desigualdad de Cauchy-Schwarz, centramos el primer factor de la esperanza:

$$\begin{aligned} g'(\theta) &= E_\theta\left[T(X_1,\ldots,X_n)\frac{\partial}{\partial\theta}\ln f_\theta^n(X_1,\ldots,X_n)\right] = \\ &= E_\theta\left[(T(X_1,\ldots,X_n) - g(\theta))\frac{\partial}{\partial\theta}\ln f_\theta^n(X_1,\ldots,X_n)\right] + g(\theta)E_\theta\left[\frac{\partial}{\partial\theta}\ln f_\theta^n(X_1,\ldots,X_n)\right] \end{aligned}$$

Como la familia de distribuciones es regular, se cumple que:

$$E_\theta\left[\frac{\partial}{\partial\theta}\ln f_\theta^n(X_1,\dots,X_n)\right]=0$$

Por tanto:

$$g'(\theta)=E_\theta\left[(T(X_1,\dots,X_n)-g(\theta))\frac{\partial}{\partial\theta}\ln f_\theta^n(X_1,\dots,X_n)\right]$$

Para poder aplicar la desigualdad de Cauchy-Schwarz, necesitamos que ambos factores de la esperanza tengan momento de segundo orden finito. Como T es un estadístico de segundo orden, se cumple que:

$$E_\theta\left[(T(X_1,\dots,X_n)-g(\theta))^2\right]=Var_\theta[T(X_1,\dots,X_n)]<\infty$$

Por otro lado, como la familia de distribuciones es regular, se cumple que:

$$E_\theta\left[\left(\frac{\partial}{\partial\theta}\ln f_\theta^n(X_1,\dots,X_n)\right)^2\right]=Var_\theta\left[\frac{\partial}{\partial\theta}\ln f_\theta^n(X_1,\dots,X_n)\right]=$$
$$=I_{X_1,\dots,X_n}(\theta)=nI_X(\theta)<\infty$$

Por la Desigualdad de Cauchy-Schwarz, se cumple que:

$$g'(\theta)^2\leqslant E_\theta\left[(T(X_1,\dots,X_n)-g(\theta))^2\right]E_\theta\left[\left(\frac{\partial}{\partial\theta}\ln f_\theta^n(X_1,\dots,X_n)\right)^2\right]$$
$$=Var_\theta[T(X_1,\dots,X_n)]I_{X_1,\dots,X_n}(\theta)$$

Por tanto, como $I_{X_1,\dots,X_n}(\theta)=nI_X(\theta)>0$, pasándolo al otro lado de la desigualdad, obtenemos lo pedido.

2. Sea $\theta_0\in\Theta$ tal que $g'(\theta_0)\neq 0$. Consideramos las variables aleatorias

$$X=T(X_1,\dots,X_n)-g(\theta_0),\qquad Y=\frac{\partial}{\partial\theta}\ln f_\theta^n(X_1,\dots,X_n)\Big|_{\theta=\theta_0}.$$

Por lo visto en el primer apartado, existen $E_{\theta_0}[X^2]$ y $E_{\theta_0}[Y^2]$, luego podemos aplicar la desigualdad de Cauchy-Schwarz. Veamos en primer lugar que ninguna de las variables es degenerada:

- Y no es degenerada, pues $Var_{\theta_0}[Y]=I_{X_1,\dots,X_n}(\theta_0)>0$.
- X no es degenerada. Si lo fuera, como $E_{\theta_0}[X]=0$, sería $P_{\theta_0}[X=0]=1$, y entonces $g'(\theta_0)=E_{\theta_0}[XY]=0$, lo que contradice $g'(\theta_0)\neq 0$.

Por tanto, ninguna de las variables es degenerada, y podemos aplicar que la desigualdad de Cauchy-Schwarz se da en igualdad si y sólo si existe $\alpha\neq 0$ y $\beta\neq 0$ tales que

$$P_{\theta_0}[\alpha X+\beta Y=0]=1$$

Como $\beta\neq 0$, consideramos $a(\theta_0)=-\alpha/\beta\neq 0$. Entonces, la condición anterior se puede reescribir como

$$P_{\theta_0}[Y=a(\theta_0)X]=1$$ □

Lema 1.4.14. Sea $\{F_\theta : \theta \in \Theta\}$ regular, $0 < I_X(\theta) < +\infty$ para todo $\theta \in \Theta$ y $g(\theta)$ una función paramétrica derivable. Una condición necesaria para que $g(\theta)$ admita un estimador eficiente $T(X_1, \ldots, X_n)$ es que se cumpla una de las siguientes condiciones:

1. $g(\theta)$ es constante y en tal caso $T(X_1, \ldots, X_n)$ es degenerado.

2. $g(\theta)$ es estrictamente monótona: $g'(\theta) > 0 \ \forall \theta \in \Theta$ o $g'(\theta) < 0 \ \forall \theta \in \Theta$.

Demostración. Supongamos que $T(X_1, \ldots, X_n)$ es un estimador eficiente de $g(\theta)$, y supongamos que $g(\theta)$ no es estrictamente monótona.

Entonces, existen $\theta_0 \in \Theta$ tal que $g'(\theta_0) = 0$. Como el estimador es eficiente, se alcanza la cota de Fréchet-Cramér-Rao, por lo que se cumple que:

$$Var_{\theta_0}[T(X_1, \ldots, X_n)] = \frac{(g'(\theta_0))^2}{I_{X_1,\ldots,X_n}(\theta_0)} = 0$$

Por tanto, $T(X_1, \ldots, X_n)$ es degenerado, luego $\exists c \in \mathbb{R}$ tal que se cumple que $P_{\theta_0}[T(X_1, \ldots, X_n) = c] = 1$. Por tanto, se tiene que:

$$1 \geqslant P_\theta[T(X_1, \ldots, X_n) = c] \geqslant P_{\theta_0}[T(X_1, \ldots, X_n) = c] = 1 \qquad \forall \theta \in \Theta$$

Por tanto, $T(X_1, \ldots, X_n)$ es degenerado para todo $\theta \in \Theta$. Como $T(X_1, \ldots, X_n)$ es un estimador insesgado de $g(\theta)$, se cumple que:

$$E_\theta[T(X_1, \ldots, X_n)] = g(\theta) = c \qquad \forall \theta \in \Theta$$

Por tanto, $g(\theta)$ es constante. □

Teorema 1.4.15 (Caracterización de estimadores eficientes)**.** *Sea $(X_1, \ldots, X_n)$ una m.a.s. de $X \rightsquigarrow F \in \{F_\theta : \theta \in \Theta\}$ regular, con $0 < I_X(\theta) < +\infty \ \forall \theta \in \Theta$, $g(\theta)$ una función paramétrica derivable, con $g'(\theta) \neq 0 \ \forall \theta \in \Theta$ y $T(X_1, \ldots, X_n)$ es un estimador de $g(\theta)$. Se afirma que T es eficiente si y solo si, para todo $\theta \in \Theta$, existe $a(\theta) \neq 0$ tal que:*

1. $P_\theta\left[\dfrac{\partial}{\partial\theta} \ln f_\theta^n(X_1, \ldots, X_n) = a(\theta)[T(X_1, \ldots, X_n) - g(\theta)]\right] = 1$

2. $I_{X_1,\ldots,X_n}(\theta) = a(\theta)g'(\theta)$

Demostración. Demostramos cada implicación por separado.

$\Longrightarrow$) Como T es eficiente, se alcanza la cota de Fréchet-Cramér-Rao. Como $g'(\theta) \neq 0 \ \forall \theta \in \Theta$, el Teorema de la cota de Fréchet-Cramér-Rao nos garantiza que existe $a(\theta) \neq 0$ tal que:

$$P_\theta\left[\frac{\partial}{\partial\theta} \ln f_\theta^n(X_1, \ldots, X_n) = a(\theta)[T(X_1, \ldots, X_n) - g(\theta)]\right] = 1$$

Por otro lado:

$$I_{X_1,\dots,X_n}(\theta) = Var_\theta\left[\frac{\partial}{\partial\theta}\ln f_\theta^n(X_1,\dots,X_n)\right] = Var_\theta[a(\theta)(T(X_1,\dots,X_n)-g(\theta))] =$$
$$= a(\theta)^2 Var_\theta[T(X_1,\dots,X_n)] \overset{(*)}{=} a(\theta)^2\frac{(g'(\theta))^2}{I_{X_1,\dots,X_n}(\theta)}$$

donde en $(*)$ se ha aplicado que T es eficiente. Pasando $I_{X_1,\dots,X_n}(\theta)$ al otro lado de la igualdad, obtenemos:

$$I_{X_1,\dots,X_n}(\theta)^2 = a(\theta)^2(g'(\theta))^2 \Longrightarrow I_{X_1,\dots,X_n}(\theta) = |a(\theta)g'(\theta)|$$

Tan solo nos falta ver que $\text{sgn}(a(\theta)) = \text{sgn}(g'(\theta))$. De la relación lineal entre T y la derivada del logaritmo de la función de densidad, se sigue que:

$$\text{sgn}(a(\theta)) = \text{sgn}\left(Cov\left[\frac{\partial}{\partial\theta}\ln f_\theta^n(X_1,\dots,X_n), T(X_1,\dots,X_n)\right]\right)$$

Calculamos dicha covarianza:

$$Cov\left[\frac{\partial}{\partial\theta}\ln f_\theta^n(X_1,\dots,X_n), T(X_1,\dots,X_n)\right] =$$
$$= E_\theta\left[\frac{\partial}{\partial\theta}\ln f_\theta^n(X_1,\dots,X_n)T(X_1,\dots,X_n)\right] - E_\theta\left[\frac{\partial}{\partial\theta}\ln f_\theta^n(X_1,\dots,X_n)\right]E_\theta[T(X_1,\dots,X_n)] =$$
$$\overset{(*)}{=} E_\theta\left[\frac{\partial}{\partial\theta}\ln f_\theta^n(X_1,\dots,X_n)T(X_1,\dots,X_n)\right] - 0\cdot g(\theta) =$$
$$= E_\theta\left[\frac{\partial}{\partial\theta}\ln f_\theta^n(X_1,\dots,X_n)T(X_1,\dots,X_n)\right]$$

donde en $(*)$ se ha aplicado que la familia de distribuciones es regular. Por otro lado, como T es un estimador insesgado de $g(\theta)$, se cumple que:

$$\frac{\partial}{\partial\theta}E_\theta[T(X_1,\dots,X_n)] = E_\theta\left[\frac{\partial}{\partial\theta}\ln f_\theta^n(X_1,\dots,X_n)T(X_1,\dots,X_n)\right]$$

Por último, como T es un estimador insesgado de $g(\theta)$, se cumple que:

$$\frac{\partial}{\partial\theta}E_\theta[T(X_1,\dots,X_n)] = \frac{\partial}{\partial\theta}g(\theta) = g'(\theta)$$

Por tanto, se cumple que:

$$\text{sgn}(a(\theta)) = \text{sgn}\left(Cov\left[\frac{\partial}{\partial\theta}\ln f_\theta^n(X_1,\dots,X_n), T(X_1,\dots,X_n)\right]\right) = \text{sgn}(g'(\theta))$$

$\Longleftarrow$) Supongamos que existe $a(\theta)\neq 0$ tal que se cumple:

$$\frac{\partial}{\partial\theta}\ln f_\theta^n(X_1,\dots,X_n) = a(\theta)[T(X_1,\dots,X_n)-g(\theta)] \qquad \text{c.p.d. } \forall\theta\in\Theta$$

y $I_{X_1,\ldots,X_n}(\theta) = a(\theta)g'(\theta)$.

Tomando esperanza en ambos lados de la primera igualdad, obtenemos:

$$E_\theta\left[\frac{\partial}{\partial\theta}\ln f_\theta^n(X_1,\ldots,X_n)\right] = a(\theta)E_\theta[T(X_1,\ldots,X_n) - g(\theta)]$$

Como la familia de distribuciones es regular, se cumple que:

$$0 = a(\theta)E_\theta[T(X_1,\ldots,X_n) - g(\theta)] \Longrightarrow E_\theta[T(X_1,\ldots,X_n)] = g(\theta)$$

Por tanto, T es un estimador insesgado de $g(\theta)$. Vemos ahora que alcanza la cota de Fréchet-Cramér-Rao:

$$I_{X_1,\ldots,X_n}(\theta) = E_\theta\left[\left(\frac{\partial}{\partial\theta}\ln f_\theta^n(X_1,\ldots,X_n)\right)^2\right] = a^2(\theta)E_\theta\left[(T(X_1,\ldots,X_n) - g(\theta))^2\right]$$

Como $E_\theta\left[T(X_1,\ldots,X_n)\right] = g(\theta)$, se cumple que:

$$\begin{aligned} Var_\theta[T(X_1,\ldots,X_n)] &= E_\theta\left[(T(X_1,\ldots,X_n) - g(\theta))^2\right] - (E_\theta[T(X_1,\ldots,X_n) - g(\theta)])^2 = \\ &= E_\theta\left[(T(X_1,\ldots,X_n) - g(\theta))^2\right] \end{aligned}$$

Por tanto:

$$I_{X_1,\ldots,X_n}(\theta) = a^2(\theta)Var_\theta[T(X_1,\ldots,X_n)]$$

Como $I_{X_1,\ldots,X_n}(\theta) = a(\theta)g'(\theta)$, pasándolo al otro lado de la igualdad, obtenemos:

$$Var_\theta[T(X_1,\ldots,X_n)] = \frac{I_{X_1,\ldots,X_n}(\theta)}{a^2(\theta)} = \frac{a(\theta)g'(\theta)}{a^2(\theta)} = \frac{g'(\theta)}{a(\theta)}$$

Por tanto, T alcanza la cota de Fréchet-Cramér-Rao. Tan solo nos falta ver que se trata de un estimador regular. De la expresión de la derivada del logaritmo de la función de densidad, obtenemos:

$$\begin{aligned} &E_\theta\left[T(X_1,\ldots,X_n)\frac{\partial}{\partial\theta}\ln f_\theta^n(X_1,\ldots,X_n)\right] = a(\theta)E_\theta\left[T(X_1,\ldots,X_n)(T(X_1,\ldots,X_n) - g(\theta))\right] \\ &= a(\theta)E_\theta\left[T(X_1,\ldots,X_n)^2 - g(\theta)T(X_1,\ldots,X_n)\right] = \\ &= a(\theta)\left(E_\theta\left[T(X_1,\ldots,X_n)^2\right] - g(\theta)E_\theta\left[T(X_1,\ldots,X_n)\right]\right) = \\ &= a(\theta)\left(E_\theta\left[T(X_1,\ldots,X_n)^2\right] - E_\theta\left[T(X_1,\ldots,X_n)\right]^2\right) = a(\theta)Var_\theta[T(X_1,\ldots,X_n)] = \\ &= a(\theta)\frac{g'(\theta)}{a(\theta)} = g'(\theta) = \frac{\partial}{\partial\theta}E_\theta[T(X_1,\ldots,X_n)] \end{aligned}$$

Por tanto, T es un estimador regular de $g(\theta)$. Como T es un estimador insesgado y regular de $g(\theta)$ que alcanza la cota de Fréchet-Cramér-Rao, se cumple que T es eficiente. □

Corolario 1.4.15.1. Sea $(X_1, \ldots, X_n)$ una m.a.s. de $X \rightsquigarrow F \in \{F_\theta : \theta \in \Theta\}$ regular, con $0 < I_X(\theta) < +\infty \ \forall \theta \in \Theta$, y sea $g(\theta)$ una función paramétrica derivable, con $g'(\theta) \neq 0 \ \forall \theta \in \Theta$. Entonces, si $T(X_1, \ldots, X_n)$ es un estimador eficiente de $g(\theta)$, las únicas funciones paramétricas que admiten estimadores eficientes son las de la forma $ag(\theta) + b$, y los correspondientes estimadores eficientes son $aT + b$, con probabilidad 1, bajo todas las distribuciones de la familia.

Demostración. Como T es un estimador eficiente de $g(\theta)$, por el Teorema de caracterización de estimadores eficientes, se cumple que existe $a(\theta) \neq 0$ tal que:

$$P_\theta \left[\frac{\partial}{\partial \theta} \ln f_\theta^n(X_1, \ldots, X_n) = a(\theta)[T(X_1, \ldots, X_n) - g(\theta)] \right] = 1$$

y $I_{X_1,\ldots,X_n}(\theta) = a(\theta)g'(\theta)$. Supongamos que existe otra función paramétrica $h(\theta)$, con $h'(\theta) \neq 0 \ \forall \theta \in \Theta$, que admite un estimador eficiente $S(X_1, \ldots, X_n)$. Entonces, por el Teorema de caracterización de estimadores eficientes, se cumple que existe $b(\theta) \neq 0$ tal que:

$$P_\theta \left[\frac{\partial}{\partial \theta} \ln f_\theta^n(X_1, \ldots, X_n) = b(\theta)[S(X_1, \ldots, X_n) - h(\theta)] \right] = 1$$

y $I_{X_1,\ldots,X_n}(\theta) = b(\theta)h'(\theta)$. Empleando las igualdades de la derivada del logaritmo de la función de densidad, obtenemos:

$$a(\theta)[T(X_1, \ldots, X_n) - g(\theta)] = b(\theta)[S(X_1, \ldots, X_n) - h(\theta)] \qquad \text{c.p.d. } \forall \theta \in \Theta$$

Como $a(\theta) \neq 0$ y $b(\theta) \neq 0$, podemos despejar $S(X_1, \ldots, X_n)$:

$$S(X_1, \ldots, X_n) = \frac{a(\theta)}{b(\theta)} T(X_1, \ldots, X_n) - \frac{a(\theta)}{b(\theta)} g(\theta) + h(\theta) \qquad \text{c.p.d. } \forall \theta \in \Theta$$

De la igualdad de las informaciones de Fisher, obtenemos:

$$a(\theta)g'(\theta) = b(\theta)h'(\theta) \Longrightarrow \frac{a(\theta)}{b(\theta)} = \frac{h'(\theta)}{g'(\theta)} \qquad \forall \theta \in \Theta$$

Por tanto, podemos reescribir $S(X_1, \ldots, X_n)$ como:

$$S(X_1, \ldots, X_n) = \frac{h'(\theta)}{g'(\theta)} T(X_1, \ldots, X_n) - \frac{h'(\theta)}{g'(\theta)} g(\theta) + h(\theta) \qquad \text{c.p.d. } \forall \theta \in \Theta$$

Como S es un estimador, este no puede depender de θ, por lo que $\frac{h'(\theta)}{g'(\theta)}$ debe ser constante, digamos $a \in \mathbb{R}^*$. Por tanto, se cumple que:

$$h'(\theta) = ag'(\theta) \qquad \forall \theta \in \Theta$$

Integrando ambos lados, obtenemos:

$$h(\theta) = ag(\theta) + b \qquad \forall \theta \in \Theta$$

Por tanto, las únicas funciones paramétricas que admiten estimadores eficientes son las de la forma $ag(\theta) + b$, y los correspondientes estimadores eficientes son:

$$S(X_1, \ldots, X_n) = aT(X_1, \ldots, X_n) - ag(\theta) + h(\theta) = aT(X_1, \ldots, X_n) + b \qquad \text{c.p.d. } \forall \theta \in \Theta$$

□

Corolario 1.4.15.2. Si una función paramétrica admite dos estimadores eficientes, estos son iguales con probabilidad 1, bajo todas las distribuciones de la familia.

Demostración. Si $g(\theta)$ admite dos estimadores eficientes $T(X_1, \ldots, X_n)$ y $S(X_1, \ldots, X_n)$, por el Corolario anterior, se cumple que:

$$S(X_1, \ldots, X_n) = aT(X_1, \ldots, X_n) + b \qquad \text{c.p.d. } \forall \theta \in \Theta$$

Tomando la esperanza de ambos lados, como T y S son estimadores insesgados de $g(\theta)$, se cumple que:

$$g(\theta) = E_\theta[S(X_1, \ldots, X_n)] = aE_\theta[T(X_1, \ldots, X_n)] + b = ag(\theta) + b \qquad \forall \theta \in \Theta$$

Como $g(\theta)$ no es constante, se sigue que $a = 1$ y $b = 0$. Por tanto, se cumple que:

$$S(X_1, \ldots, X_n) = T(X_1, \ldots, X_n) \qquad \text{c.p.d. } \forall \theta \in \Theta$$

□

Corolario 1.4.15.3. Solo existen estimadores eficientes en familias de tipo exponencial.

Demostración. Sea $X \rightsquigarrow F \in \{F_\theta : \theta \in \Theta\}$ una familia de distribuciones regular, con $0 < I_X(\theta) < +\infty \ \forall \theta \in \Theta$, y sea $g(\theta)$ una función paramétrica derivable, con $g'(\theta) \neq 0 \ \forall \theta \in \Theta$. Supongamos que $g(\theta)$ admite un estimador eficiente $T(X_1, \ldots, X_n)$. Por el Teorema de caracterización de estimadores eficientes, se cumple que existe $a(\theta) \neq 0$ tal que:

$$\frac{\partial}{\partial \theta} \ln f_\theta^n(X_1, \ldots, X_n) = a(\theta)[T(X_1, \ldots, X_n) - g(\theta)] \qquad \text{c.p.d. } \forall \theta \in \Theta$$

Integrando ambos lados respecto a θ, obtenemos:

$$\ln f_\theta^n(X_1, \ldots, X_n) = \int_\Theta a(\theta)[T(X_1, \ldots, X_n) - g(\theta)]d\theta = T(X_1, \ldots, X_n) \int_\Theta a(\theta)d\theta - \int_\Theta a(\theta)g(\theta)d\theta$$

Exponenciando ambos lados, obtenemos:

$$f_\theta^n(X_1, \ldots, X_n) = \exp\left(T(X_1, \ldots, X_n) \int_\Theta a(\theta)d\theta - \int_\Theta a(\theta)g(\theta)d\theta\right)$$

□

Ejemplo. Buscar la clase de funciones paramétricas que admiten estimadores eficientes para las siguientes familias de distribuciones y calcular dichos estimadores:

1. $\{\mathcal{B}(k_0, p), p \in]0, 1[\}$,

   Buscamos ver en primer lugar que esta familia es regular. Tenemos que:

   a) $\Theta =]0, 1[$ es un intervalo abierto de $\mathbb{R}$.

   b) El conjunto de los valores posibles de la variable aleatoria es $\{0, 1, \ldots, k_0\}$, que no depende de p.

c) Para cada $x \in \{0, 1, \ldots, k_0\}$, la función de densidad es derivable respecto a p. Tenemos que:

$$\ln f_p(x) = \ln \binom{k_0}{x} + x \ln p + (k_0 - x) \ln(1-p)$$
$$\frac{\partial}{\partial p} \ln f_p(x) = \frac{x}{p} - \frac{k_0 - x}{1-p}$$
$$E\left[\frac{X}{p} - \frac{k_0 - X}{1-p}\right] = \frac{E[X]}{p} - \frac{k_0 - E[X]}{1-p} = \frac{k_0 p}{p} - \frac{k_0 - k_0 p}{1-p} = k_0 - k_0 = 0$$

Por tanto, la familia es regular. Calculamos ahora la información de Fisher:

$$I_X(p) = Var\left[\frac{\partial}{\partial p} \ln f_p(X)\right] = Var\left[\frac{X}{p} - \frac{k_0 - X}{1-p}\right] = Var\left[\frac{X - k_0 p}{p(1-p)}\right] =$$
$$= \frac{1}{p^2(1-p)^2} Var[X] = \frac{1}{p^2(1-p)^2} \cdot k_0 p(1-p) = \frac{k_0}{p(1-p)}$$

Por tanto, $0 < I_X(p) < +\infty$ para todo $p \in]0, 1[$. En vistas de emplear el Teorema de Caracterización de los estimadores eficientes, tenemos que:

$$\frac{\partial}{\partial p} \ln f_p^n(x_1, \ldots, x_n) = \sum_{i=1}^n \frac{\partial}{\partial p} \ln f_p(x_i) = \sum_{i=1}^n \left(\frac{x_i}{p} - \frac{k_0 - x_i}{1-p}\right) =$$
$$= \frac{\sum_{i=1}^n x_i}{p} - \frac{nk_0 - \sum_{i=1}^n x_i}{1-p} = \frac{1}{p(1-p)} \left(\sum_{i=1}^n x_i - nk_0 p\right)$$

Por tanto, definimos:

$$T(X_1, \ldots, X_n) = \sum_{i=1}^n X_i$$
$$a(p) = \frac{1}{p(1-p)}$$
$$g(p) = nk_0 p$$

Hemos de comprobar que T es un estimador de $g(p)$. Tenemos que $T(X_1, \ldots, X_n)$ es siempre positivo, y $g(p) = nk_0 p \in \mathbb{R}^+ \ \forall p \in]0, 1[$. Por tanto, T es un estimador de $g(p)$. Además, tenemos que:

$$g'(p) = nk_0 \neq 0 \ \forall p \in]0, 1[$$

Por último, hemos de comprobar que $I_{X_1,\ldots,X_n}(p) = a(p)g'(p)$. Tenemos que:

$$I_{X_1,\ldots,X_n}(p) = nI_X(p) = n\frac{k_0}{p(1-p)} = \frac{1}{p(1-p)} nk_0 = a(p)g'(p) \qquad \forall p \in]0, 1[$$

Por tanto, por el Teorema de Caracterización de los estimadores eficientes, T es un estimador eficiente de $g(p) = nk_0 p$. Además, por el Corolario de

funciones paramétricas que admiten estimadores eficientes, las únicas funciones paramétricas que admiten estimadores eficientes son las de la forma $ag(p)+b = ank_0p+b$, y los correspondientes estimadores eficientes son $aT+b = a\sum_{i=1}^{n} X_i+b$, con probabilidad 1, bajo todas las distribuciones de la familia.

2. $\{\mathcal{N}(\mu, \sigma_0^2), \mu \in \mathbb{R}\}$,

   Buscamos ver en primer lugar que esta familia es regular. Tenemos que:

   a) $\Theta = \mathbb{R}$ es un intervalo abierto de $\mathbb{R}$.

   b) El conjunto de los valores posibles de la variable aleatoria es $\mathbb{R}$, que no depende de μ.

   c) Para cada $x \in \mathbb{R}$, la función de densidad es derivable respecto a μ. Tenemos que:

$$\ln f_\mu(x) = -\frac{1}{2}\ln(2\pi\sigma_0^2) - \frac{(x-\mu)^2}{2\sigma_0^2} = -\frac{1}{2}\ln(2\pi\sigma_0^2) - \frac{x^2 - 2x\mu + \mu^2}{2\sigma_0^2}$$

$$\frac{\partial}{\partial\mu}\ln f_\mu(x) = \frac{x-\mu}{\sigma_0^2}$$

$$E\left[\frac{X-\mu}{\sigma_0^2}\right] = \frac{E[X]-\mu}{\sigma_0^2} = 0$$

Por tanto, la familia es regular. Calculamos ahora la información de Fisher:

$$I_X(\mu) = Var\left[\frac{\partial}{\partial\mu}\ln f_\mu(X)\right] = Var\left[\frac{X-\mu}{\sigma_0^2}\right] = \frac{1}{\sigma_0^4}Var[X] = \frac{1}{\sigma_0^4}\cdot\sigma_0^2 = \frac{1}{\sigma_0^2}$$

Por tanto, $0 < I_X(\mu) < +\infty$ para todo $\mu \in \mathbb{R}$. En vistas de emplear el Teorema de Caracterización de los estimadores eficientes, tenemos que:

$$\frac{\partial}{\partial\mu}\ln f_\mu^n(x_1,\ldots,x_n) = \sum_{i=1}^{n}\frac{\partial}{\partial\mu}\ln f_\mu(x_i) = \sum_{i=1}^{n}\frac{x_i-\mu}{\sigma_0^2} = \frac{\sum_{i=1}^{n} x_i - n\mu}{\sigma_0^2} = \frac{1}{\sigma_0^2}\left(\sum_{i=1}^{n} x_i - n\mu\right)$$

Por tanto, definimos:

$$T(X_1,\ldots,X_n) = \sum_{i=1}^{n} X_i$$
$$a(\mu) = \frac{1}{\sigma_0^2}$$
$$g(\mu) = n\mu$$

Hemos de comprobar que T es un estimador de $g(\mu)$. Tenemos que $T(X_1,\ldots,X_n)$ es siempre positivo, y $g(\mu) = n\mu \in \mathbb{R}\ \forall\mu \in \mathbb{R}$. Por tanto, T es un estimador de $g(\mu)$. Además, tenemos que:

$$g'(\mu) = n \neq 0\ \forall\mu \in \mathbb{R}$$

Por último, hemos de comprobar que $I_{X_1,\dots,X_n}(\mu) = a(\mu)g'(\mu)$. Tenemos que:

$$I_{X_1,\dots,X_n}(\mu) = nI_X(\mu) = n\frac{1}{\sigma_0^2} = \frac{1}{\sigma_0^2}n = a(\mu)g'(\mu) \qquad \forall \mu \in \mathbb{R}$$

Por tanto, por el Teorema de Caracterización de los estimadores eficientes, T es un estimador eficiente de $g(\mu) = n\mu$. Además, por el Corolario de funciones paramétricas que admiten estimadores eficientes, las únicas funciones paramétricas que admiten estimadores eficientes son las de la forma $ag(\mu)+b = an\mu+b$, y los correspondientes estimadores eficientes son $aT + b = a\sum_{i=1}^{n} X_i + b$, con probabilidad 1, bajo todas las distribuciones de la familia.

3. $\{\mathcal{N}(\mu_0, \sigma^2), \sigma^2 > 0\}$.

Buscamos ver en primer lugar que esta familia es regular. Tenemos que:

a) $\Theta = \mathbb{R}^+$ es un intervalo abierto de $\mathbb{R}$.

b) El conjunto de los valores posibles de la variable aleatoria es $\mathbb{R}$, que no depende de σ^2.

c) Para cada $x \in \mathbb{R}$, la función de densidad es derivable respecto a σ^2. Tenemos que:

$$\begin{aligned}
\ln f_{\sigma^2}(x) &= -\frac{1}{2}\ln(2\pi\sigma^2) - \frac{(x-\mu_0)^2}{2\sigma^2} = \\
&= -\frac{1}{2}\ln(2\pi) - \frac{1}{2}\ln(\sigma^2) - \frac{(x-\mu_0)^2}{2\sigma^2} \\
\frac{\partial}{\partial\sigma^2}\ln f_{\sigma^2}(x) &= -\frac{1}{2\sigma^2} + \frac{(x-\mu_0)^2}{2\sigma^4} \\
E\left[-\frac{1}{2\sigma^2} + \frac{(X-\mu_0)^2}{2\sigma^4}\right] &= -\frac{1}{2\sigma^2} + \frac{E[(X-\mu_0)^2]}{2\sigma^4} = -\frac{1}{2\sigma^2} + \frac{\sigma^2}{2\sigma^4} = 0
\end{aligned}$$

Por tanto, la familia es regular. Calculamos ahora la información de Fisher:

$$\begin{aligned}
I_X(\sigma^2) &= Var\left[\frac{\partial}{\partial\sigma^2}\ln f_{\sigma^2}(X)\right] = Var\left[-\frac{1}{2\sigma^2} + \frac{(X-\mu_0)^2}{2\sigma^4}\right] = Var\left[\frac{(X-\mu_0)^2}{2\sigma^4}\right] = \\
&= \frac{1}{4\sigma^4}Var\left[\left(\frac{X-\mu_0}{\sigma}\right)^2\right]
\end{aligned}$$

Estamos calculando la varianza de una $\chi^2(1)$, que sabemos que es $2 \cdot 1 = 2$. Por tanto:

$$I_X(\sigma^2) = \frac{1}{4\sigma^4} \cdot 2 = \frac{1}{2\sigma^4} \Longrightarrow 0 < I_X(\sigma^2) < +\infty \ \forall \sigma^2 > 0$$

En vistas de emplear el Teorema de Caracterización de los estimadores eficientes, tenemos que:

$$\frac{\partial}{\partial\sigma^2}\ln f^n_{\sigma^2}(x_1,\dots,x_n)=\sum_{i=1}^n\frac{\partial}{\partial\sigma^2}\ln f_{\sigma^2}(x_i)=\sum_{i=1}^n\left(-\frac{1}{2\sigma^2}+\frac{(x_i-\mu_0)^2}{2\sigma^4}\right)=$$
$$=-\frac{n}{2\sigma^2}+\frac{\sum_{i=1}^n(x_i-\mu_0)^2}{2\sigma^4}=\frac{n}{2\sigma^4}\left(\frac{\sum_{i=1}^n(x_i-\mu_0)^2}{n}-\sigma^2\right)$$

Por tanto, definimos:

$$T(X_1,\dots,X_n)=\frac{\sum_{i=1}^n(X_i-\mu_0)^2}{n}$$
$$a(\sigma^2)=\frac{n}{2\sigma^4}$$
$$g(\sigma^2)=\sigma^2$$

Hemos de comprobar que T es un estimador de $g(\sigma^2)$. Tenemos que $T(X_1,\dots,X_n)$ es siempre positivo, y $g(\sigma^2)=\sigma^2>0\ \forall\sigma^2>0$. Por tanto, T es un estimador de $g(\sigma^2)$. Además, tenemos que:

$$g'(\sigma^2)=1\neq 0\ \forall\sigma^2>0$$

Por último, hemos de comprobar que $I_{X_1,\dots,X_n}(\sigma^2)=a(\sigma^2)g'(\sigma^2)$. Tenemos que:

$$I_{X_1,\dots,X_n}(\sigma^2)=nI_X(\sigma^2)=\frac{n}{2\sigma^4}=a(\sigma^2)g'(\sigma^2)\qquad\forall\sigma^2>0$$

Por tanto, por el Teorema de Caracterización de los estimadores eficientes, $T(X_1,\dots,X_n)$ es un estimador eficiente de $g(\sigma^2)=\sigma^2$. Por el corolario de dicho teorema, las únicas funciones paramétricas que admiten estimadores eficientes son de la forma $a\sigma^2+b$, y los correspondientes estimadores eficientes son $aT(X_1,\dots,X_n)+b$, para todo $a,b\in\mathbb{R}$, con probabilidad 1, bajo todas las distribuciones de la familia.

1.5. Estimación de máxima verosimilitud y otros métodos

Ejemplo. Sea $X_1, \ldots, X_n$ una m.a.s. de $X \rightsquigarrow \mathcal{N}(\mu, \sigma^2)$, $\mu \in \mathbb{R}$, $\sigma^2 > 0$. Encontrar el EMV para μ y σ^2, en el caso de un parámetro conocido y cuando ambos parámetros son desconocidos. Además, deducir que el EMV no tiene por qué ser insesgado.

1. σ_0^2 conocido: La función de verosimilitud es

$$L_{x_1,\ldots,x_n}(\mu) = \prod_{i=1}^{n} f_{X_i}(x_i; \mu, \sigma_0^2) = \prod_{i=1}^{n} \frac{1}{\sqrt{2\pi\sigma_0^2}} \exp(-\frac{(x_i-\mu)^2}{2\sigma_0^2}) =$$
$$= \left(\frac{1}{\sqrt{2\pi\sigma_0^2}}\right)^n \exp\left(-\frac{1}{2\sigma_0^2}\sum_{i=1}^{n}(x_i-\mu)^2\right) \qquad \forall \mu \in \mathbb{R}.$$

   Puesto que el logaritmo es una función estrictamente creciente, podemos trabajar con la log-verosimilitud:

$$\ln(L_{x_1,\ldots,x_n}(\mu)) = -\frac{n}{2}\ln(2\pi\sigma_0^2) - \frac{1}{2\sigma_0^2}\sum_{i=1}^{n}(x_i-\mu)^2 \qquad \forall \mu \in \mathbb{R}.$$

   Como buscamos el máximo, derivamos e igualamos a cero:

$$\frac{d}{d\mu}\ln(L_{x_1,\ldots,x_n}(\mu)) = -\frac{1}{2\sigma_0^2}\sum_{i=1}^{n} 2(x_i-\mu)(-1) = \frac{1}{\sigma_0^2}\sum_{i=1}^{n}(x_i-\mu) = 0 \implies$$
$$\implies \sum_{i=1}^{n} x_i - n\mu = 0 \implies \mu = \frac{1}{n}\sum_{i=1}^{n} x_i$$

   Sería necesario comprobar que efectivamente se trata de un máximo, pero como la función es cuadrática con coeficiente principal negativo, podemos concluir que efectivamente se trata de un máximo. Por lo tanto, el candidato a EMV para μ es

$$\hat{\mu} = \frac{1}{n}\sum_{i=1}^{n} X_i = \overline{X}.$$

   Sería necesario comprobar que este estadístico efectivamente es un estimador de μ. Como $\mu \in \mathbb{R}$ y $\hat{\mu} \in \mathbb{R}$, podemos concluir que efectivamente $\hat{\mu}$ es un estimador de μ, y por lo tanto, $\hat{\mu}$ es el EMV de μ.

2. μ_0 conocido: La función de verosimilitud es

$$L_{x_1,\ldots,x_n}(\sigma^2) = \prod_{i=1}^{n} f_{X_i}(x_i; \mu_0, \sigma^2) = \prod_{i=1}^{n} \frac{1}{\sqrt{2\pi\sigma^2}} \exp(-\frac{(x_i-\mu_0)^2}{2\sigma^2}) =$$
$$= \left(\frac{1}{\sqrt{2\pi\sigma^2}}\right)^n \exp\left(-\frac{1}{2\sigma^2}\sum_{i=1}^{n}(x_i-\mu_0)^2\right) \qquad \forall \sigma^2 > 0.$$

Puesto que el logaritmo es una función estrictamente creciente, podemos trabajar con la log-verosimilitud:

$$\ln(L_{x_1,\dots,x_n}(\sigma^2)) = -\frac{n}{2}\ln(2\pi\sigma^2) - \frac{1}{2\sigma^2}\sum_{i=1}^{n}(x_i-\mu_0)^2 \qquad \forall \sigma^2 > 0.$$

Como buscamos el máximo, derivamos e igualamos a cero:

$$\frac{d}{d\sigma^2}\ln(L_{x_1,\dots,x_n}(\sigma^2)) = -\frac{n}{2\sigma^2} + \frac{1}{2(\sigma^2)^2}\sum_{i=1}^{n}(x_i-\mu_0)^2 = 0 \implies$$
$$\implies -n\sigma^2 + \sum_{i=1}^{n}(x_i-\mu_0)^2 = 0 \implies \sigma^2 = \frac{1}{n}\sum_{i=1}^{n}(x_i-\mu_0)^2$$

Se puede comprobar que efectivamente se trata de un máximo. Por lo tanto, el candidato a EMV para σ^2 es

$$\hat{\sigma}^2 = \frac{1}{n}\sum_{i=1}^{n}(X_i-\mu_0)^2.$$

Sería necesario comprobar que este estadístico efectivamente es un estimador de σ^2. Como $\sigma^2 > 0$ y $\hat{\sigma}^2 > 0$, podemos concluir que efectivamente $\hat{\sigma}^2$ es un estimador de σ^2, y por lo tanto, $\hat{\sigma}^2$ es el EMV de σ^2.

3. μ y σ^2 desconocidos: Repidiendo el procedimiento anterior, se obtiene que los candidatos a EMV son

$$\hat{\mu} = \frac{1}{n}\sum_{i=1}^{n}X_i = \overline{X}$$
$$\hat{\sigma}^2 = \frac{1}{n}\sum_{i=1}^{n}(X_i-\hat{\mu})^2 = \frac{1}{n}\sum_{i=1}^{n}(X_i-\overline{X})^2$$

Ejemplo. Sea $X_1,\dots,X_n$ una m.a.s. de $X \rightsquigarrow \mathcal{U}\{1,\dots,N\}$, $N \in \mathbb{N}$. Encontrar el EMV para N.

La función de verosimilitud es:

$$L_{x_1,\dots,x_n}(N) = \prod_{i=1}^{n} f_{X_i}(x_i;N) = \prod_{i=1}^{n}\frac{1}{N} = \frac{1}{N^n} \qquad \forall N \in \mathbb{N}, N \geqslant \text{máx}\{x_1,\dots,x_n\} = x_{(n)}.$$

Por tanto, podemos escribir la función de verosimilitud como:

$$L_{x_1,\dots,x_n}(N) = \begin{cases} \dfrac{1}{N^n} & N \in \mathbb{N}, N \geqslant x_{(n)} \\ \\ 0 & N \in \mathbb{N}, N < x_{(n)} \end{cases}$$

La función de verosimilitud no es continua, por lo que tampoco es diferenciable. Por tanto, no podemos derivar e igualar a cero para encontrar el máximo. Para encontrar el máximo, nos restringimos a $N \geqslant x_{(n)}$; $g = (L_{x_1,\dots,x_n})_{|_{N \geqslant x_{(n)}}}$. Esta sí es derivable, luego:

$$g(N) = \frac{1}{N^n} \implies g'(N) = -\frac{n}{N^{n+1}} < 0 \qquad \forall N > x_{(n)}.$$

Como además $g(x_{(n)}) > 0$, el máximo de la función de verosimilitud se alcanza en $N = x_{(n)}$, el candidato a EMV es:

$$\hat{N} = X_{(n)} = \text{máx}\{X_1, \dots, X_n\}.$$

Como $N \in \mathbb{N}$ y $\hat{N} \in \mathbb{N}$, podemos concluir que efectivamente $\hat{N}$ es un estimador de N, y por lo tanto, $\hat{N}$ es el EMV de N.

Ejemplo. Sea $X_1, \dots, X_n$ una m.a.s. de $X \rightsquigarrow \mathcal{U}(\theta - 1/2, \theta + 1/2)$, $\theta \in \mathbb{R}$. Encontrar un EMV para θ y deducir que el EMV no tiene por qué ser único.

La función de verosimilitud es:

$$L_{x_1,\dots,x_n}(\theta) = \prod_{i=1}^{n} f_{X_i}(x_i;\theta) = \prod_{i=1}^{n} 1 = 1 \qquad \forall \theta \in \mathbb{R}, \theta - \frac{1}{2} \leqslant x_i \leqslant \theta + \frac{1}{2}, i = 1, \dots, n.$$

Por tanto, considerando $x_{(1)} = \text{mín}\{x_1, \dots, x_n\}$ y $x_{(n)} = \text{máx}\{x_1, \dots, x_n\}$, podemos escribir la función de verosimilitud como:

$$L_{x_1,\dots,x_n}(\theta) = \begin{cases} 1 & \theta \in [x_{(n)} - 1/2, x_{(1)} + 1/2] \\ 0 & \theta \in \mathbb{R} \setminus [x_{(n)} - 1/2, x_{(1)} + 1/2] \end{cases}$$

En este caso, no es necesario derivar para encontrar el máximo. Por tanto, el máximo de la función de verosimilitud se alcanza en cualquier $\theta \in [x_{(n)} - 1/2, x_{(1)} + 1/2]$, por lo que los candidatos a EMV son:

$$\hat{\theta} \in [X_{(n)} - 1/2, X_{(1)} + 1/2].$$

Además, como $\theta \in \mathbb{R}$ y $\hat{\theta} \in \mathbb{R}$, podemos concluir que efectivamente $\hat{\theta}$ es un estimador de θ, y por lo tanto, $\hat{\theta}$ es un EMV de θ.

Ejemplo. Sea X una v.a. con distribución $\mathcal{B}(1, p)$ con $p \in [1/4, 3/4]$. Calcular el EMV de p, para una muestra de tamaño 1, ver que no es insesgado y calcular su error cuadrático medio: $E[\hat{p} - p]^2$. Comprobar que el estimador $T(X) = 1/2$ es mejor que $\hat{p}$ en el sentido del ECM. (El EMV no tiene porque ser el mejor en el sentido del menor error cuadrático medio).

La función de verosimilitud es:

$$L_{x_1,\dots,x_n}(p) = \prod_{i=1}^{n} f_{X_i}(x_i;p) = \prod_{i=1}^{n} p^{x_i}(1-p)^{1-x_i} = p^{\sum_{i=1}^{n} x_i}(1-p)^{n-\sum_{i=1}^{n} x_i} \qquad \forall p \in \left[\frac{1}{4}, \frac{3}{4}\right].$$

Por tanto, la función de verosimilitud para una muestra de tamaño 1 es:

$$L_{x_1}(p) = p^{x_1}(1-p)^{1-x_1} \qquad \forall p \in \left[\frac{1}{4}, \frac{3}{4}\right].$$

Definiéndola por partes, tenemos que:

$$L_{x_1}(p) = \begin{cases} p^{x_1}(1-p)^{1-x_1} & p \in [1/4, 3/4] \\ 0 & p \in \mathbb{R} \setminus [1/4, 3/4] \end{cases}$$

Por tanto, para encontrar el máximo de la función de verosimilitud, nos restringimos a $p \in [1/4, 3/4]$. Como $x_1 \in \{0, 1\}$, tenemos dos casos:

1. $x_1 = 0$: En este caso, la función de verosimilitud es $L_0(p) = 1 - p$, que es decreciente en $[1/4, 3/4]$. Por tanto, el máximo se alcanza en $p = 1/4$, y el EMV es $\hat{p} = 1/4$.

2. $x_1 = 1$: En este caso, la función de verosimilitud es $L_1(p) = p$, que es creciente en $[1/4, 3/4]$. Por tanto, el máximo se alcanza en $p = 3/4$, y el EMV es $\hat{p} = 3/4$.

Por tanto, el candidato a EMV es:

$$\hat{p} = \frac{1}{4}(1 - X) + \frac{3}{4}X = \frac{1}{4} + \frac{1}{2}X.$$

Como $p \in [1/4, 3/4]$ y $\hat{p} \in \{1/4, 3/4\}$, podemos concluir que efectivamente $\hat{p}$ es un estimador de p, y por lo tanto, $\hat{p}$ es el EMV de p. Vemos que $\hat{p}$ no es insesgado, ya que:

$$E_p[\hat{p}] = \frac{1}{4} + \frac{1}{2}E_p[X] = \frac{1}{4} + \frac{1}{2}p \qquad \forall p \in \left[\frac{1}{4}, \frac{3}{4}\right].$$

Tenemos que:

$$E_p[\hat{p}] = p \iff \frac{1}{4} + \frac{1}{2}p = p \iff \frac{1}{4} = \frac{1}{2}p \iff p = \frac{1}{2}.$$

Por tanto, como tendría que cumplirse para todo $p \in [1/4, 3/4]$, podemos concluir que $\hat{p}$ no es insesgado. Calculamos el error cuadrático medio de $\hat{p}$:

$$\begin{aligned} E_p[(\hat{p} - p)^2] &= E_p\left[\left(\frac{1}{4} + \frac{1}{2}X - p\right)^2\right] = E_p\left[\left(\frac{1}{4} - p + \frac{1}{2}X\right)^2\right] \\ &= \left(\frac{1}{4} - p\right)^2 + \frac{1}{4}E_p[X^2] + \left(\frac{1}{4} - p\right)E_p[X] = \\ &= \left(\frac{1}{4} - p\right)^2 + \frac{1}{4}p + \left(\frac{1}{4} - p\right)p = \left(\frac{1}{4} - p\right)^2 + p\left(\frac{1}{2} - p\right) = \\ &= \frac{1}{16} - \frac{1}{2}p + p^2 + \frac{1}{2}p - p^2 = \frac{1}{16} \qquad \forall p \in \left[\frac{1}{4}, \frac{3}{4}\right]. \end{aligned}$$

Por otro lado, para el estimador $T(X) = 1/2$, tenemos:

$$E_p[(T(X) - p)^2] = \left(\frac{1}{2} - p\right)^2.$$

Dado que $p \in [1/4, 3/4]$, se tiene que:

$$-\frac{1}{4} \leq p - \frac{1}{2} \leq \frac{1}{4} \implies \left|p - \frac{1}{2}\right| \leq \frac{1}{4}.$$

Elevando al cuadrado:

$$E_p[(T(X) - p)^2] = \left(p - \frac{1}{2}\right)^2 \leq \left(\frac{1}{4}\right)^2 = \frac{1}{16} = E_p[(\hat{p} - p)^2] \qquad \forall p \in \left[\frac{1}{4}, \frac{3}{4}\right].$$

alcanzándose la igualdad únicamente en los extremos $p = 1/4$ y $p = 3/4$, y siendo estrictamente positiva en todo el interior $]1/4, 3/4[$. Por tanto, concluimos que $T(X) = 1/2$ es un estimador estrictamente mejor que el EMV $\hat{p}$ en el interior del espacio paramétrico según el criterio del error cuadrático medio.

Teorema 1.5.16 (Relación entre EMV y estadístico suficiente)**.** *Sea X una v.a. con distribución en una familia paramétrica de distribuciones, $\{F_\theta, \theta \in \Theta\}$. Sea $X_1, \ldots, X_n$ una m.a.s. de X. Supongamos que la familia admite un estadístico suficiente $T(X_1, \ldots, X_n)$. Entonces, si existe un EMV de θ, es una función (no constante) de $T(X_1, \ldots, X_n)$.*

Demostración. Sea $T(X_1, \ldots, X_n)$ un estadístico suficiente para θ. Por el Teorema de Factorización de Neyman-Fisher, la función de verosimilitud puede escribirse como:

$$L_{x_1,\ldots,x_n}(\theta) = f_{X_1,\ldots,X_n}(x_1, \ldots, x_n) = g_\theta(T(x_1, \ldots, x_n))h(x_1, \ldots, x_n) \qquad \forall \theta \in \Theta.$$

Si existe un EMV $\hat{\theta}(X_1, \ldots, X_n)$ de θ, entonces para cualquier $(x_1, \ldots, x_n) \in \mathbb{R}^n$:

$$\max_{\theta \in \Theta} L_{x_1,\ldots,x_n}(\theta) = L_{x_1,\ldots,x_n}(\hat{\theta}(x_1, \ldots, x_n)) = g_{\hat{\theta}(x_1,\ldots,x_n)}(T(x_1, \ldots, x_n))h(x_1, \ldots, x_n)$$

Como $h(x_1, \ldots, x_n)$ no depende de θ, maximizar $L_{x_1,\ldots,x_n}(\theta)$ respecto a θ es equivalente a maximizar $g_\theta(T(x_1, \ldots, x_n))$ respecto a θ. Por tanto, para cualquier $(x_1, \ldots, x_n) \in \mathbb{R}^n$, se tiene que:

$$\max_{\theta \in \Theta} g_\theta(T(x_1, \ldots, x_n)) = g_{\hat{\theta}(x_1,\ldots,x_n)}(T(x_1, \ldots, x_n)).$$

Por tanto, $\hat{\theta}(x_1, \ldots, x_n)$ es el valor de θ que maximiza $g_\theta(T(x_1, \ldots, x_n))$, y por tanto, $\hat{\theta}(x_1, \ldots, x_n)$ es una función (no constante) de $T(x_1, \ldots, x_n)$. □

Ejemplo. Sea $X_1, \ldots, X_n$ una m.a.s. de $X \rightsquigarrow \mathcal{U}(\theta, \theta + 1)$, $\theta \in \mathbb{R}$. Calcular el estadístico suficiente, un EMV para θ, y comprobar que no coinciden.

En vistas de aplicar el Teorema de Factorización de Neyman-Fisher, calculamos la función de densidad conjunta:

$$f_\theta^n(x_1,\dots,x_n)=\prod_{i=1}^n f_\theta(x_i)=\prod_{i=1}^n 1=1 \qquad \forall x_i\in[\theta,\theta+1], i=1,\dots,n.$$

Por tanto, considerando $x_{(1)}=\text{mín}\{x_1,\dots,x_n\}$ y $x_{(n)}=\text{máx}\{x_1,\dots,x_n\}$, podemos escribir la función de densidad conjunta como:

$$f_\theta^n(x_1,\dots,x_n)=\mathrm{I}_{\mathbb{R}^+}(x_{(1)}-\theta)\,\mathrm{I}_{\mathbb{R}^+}(\theta+1-x_{(n)}) \qquad \forall\theta\in\mathbb{R}.$$

Por el Teorema de Factorización de Neyman-Fisher, el estadístico suficiente es:

$$T(X_1,\dots,X_n)=(X_{(1)},X_{(n)})=(\text{mín}\{X_1,\dots,X_n\},\text{máx}\{X_1,\dots,X_n\}).$$

Por otro lado, la función de verosimilitud es:

$$L_{x_1,\dots,x_n}(\theta)=\prod_{i=1}^n f_\theta(x_i)=\prod_{i=1}^n 1=1 \qquad \forall\theta\in[x_{(n)}-1,x_{(1)}].$$

Por tanto, el máximo de la función de verosimilitud se alcanza en cualquier $\theta\in[x_{(n)}-1,x_{(1)}]$, por lo que los candidatos a EMV son:

$$\hat\theta\in[X_{(n)}-1,X_{(1)}].$$

En particular, podemos tomar $\hat\theta=X_{(1)}$ o $\hat\theta=X_{(n)}-1$. Concluimos que el EMV no coincide con el estadístico suficiente, ya que $T(X_1,\dots,X_n)=(X_{(1)},X_{(n)})$ y $\hat\theta\in[X_{(n)}-1,X_{(1)}]$. No obstante, sí es una función (no constante) del estadístico suficiente.

Teorema 1.5.17 (Relación entre EMV y estimador eficiente)**.** *Sea X una v.a. con distribución en una familia paramétrica de distribuciones, $\{F_\theta,\theta\in\Theta\}$, regular con $0<I_X(\theta)<\infty$. Sea $X_1,\dots,X_n$ una m.a.s. de X. Si $T(X_1,\dots,X_n)$ es un estimador eficiente para θ, entonces existe un único EMV y coincide con $T(X_1,\dots,X_n)$.*

Demostración. Sea $T(X_1,\dots,X_n)$ un estimador eficiente para θ. Por la caracterización de los estimadores eficientes, para todo $\theta\in\Theta$ existe $a(\theta)\neq 0$ tal que:

$$\frac{\partial}{\partial\theta}\ln(L_{X_1,\dots,X_n}(\theta))=a(\theta)(T(X_1,\dots,X_n)-\theta).$$

Consideramos la función de verosimilitud $L_{x_1,\dots,x_n}(\theta)$ para una muestra $(x_1,\dots,x_n)\in\mathbb{R}^n$:

$$L_{x_1,\dots,x_n}(\theta)=f_{X_1,\dots,X_n}(x_1,\dots,x_n) \qquad \forall\theta\in\Theta.$$

Como el logaritmo es una función estrictamente creciente, podemos trabajar con la log-verosimilitud:

$$\ln(L_{x_1,\dots,x_n}(\theta))=\ln(f_{X_1,\dots,X_n}(x_1,\dots,x_n)) \qquad \forall\theta\in\Theta.$$

Como se trata de buscar el máximo de la función de verosimilitud, derivamos e igualamos a cero:

$$\frac{\partial}{\partial\theta}\ln(L_{x_1,\dots,x_n}(\theta)) = \frac{\partial}{\partial\theta}\ln(f_{X_1,\dots,X_n}(x_1,\dots,x_n)) = a(\theta)(T(x_1,\dots,x_n)-\theta) = 0.$$

Como $a(\theta)\neq 0$, se tiene que:

$$T(x_1,\dots,x_n)-\theta = 0 \implies \theta = T(x_1,\dots,x_n).$$

Por tanto, el único candidato a EMV es:

$$\hat{\theta} = T(X_1,\dots,X_n).$$

Como $T(X_1,\dots,X_n)$ es un estimador de θ, podemos concluir que efectivamente $\hat{\theta}$ es un estimador de θ, y por lo tanto, $\hat{\theta}$ es el único EMV de θ. □

Teorema 1.5.18 (Invariancia de Zehna)**.** *Sea X una v.a. con distribución en una familia paramétrica de distribuciones, $\{F_\theta, \theta\in\Theta\}$. Sea $X_1,\dots,X_n$ una m.a.s. de X. Sea g una función medible. Si $\hat{\theta}(X_1,\dots,X_n)$ es EMV de θ, entonces $g(\hat{\theta}(X_1,\dots,X_n))$ es EMV de $g(\theta)$.*

Demostración. Sea $\hat{\theta}(X_1,\dots,X_n)$ un EMV de θ. Por definición, para cualquier $(x_1,\dots,x_n)\in\mathbb{R}^n$:

$$\max_{\theta\in\Theta} L_{x_1,\dots,x_n}(\theta) = L_{x_1,\dots,x_n}(\hat{\theta}(x_1,\dots,x_n)).$$

Veamos que $g(\hat{\theta}(X_1,\dots,X_n))$ es EMV de $g(\theta)$. Para ello, consideramos la función de verosimilitud respecto a $g(\theta)$:

$$M_{x_1,\dots,x_n}(g(\theta)) = \sup_{\theta^*\in\Theta: g(\theta^*)=g(\theta)} L_{x_1,\dots,x_n}(\theta^*) \qquad \forall g(\theta)\in g(\Theta).$$

Queremos ver que:

$$M_{x_1,\dots,x_n}(g(\hat{\theta}(x_1,\dots,x_n))) = \max_{g(\theta)\in g(\Theta)} M_{x_1,\dots,x_n}(g(\theta)).$$

Tenemos que:

$$\begin{aligned} M_{x_1,\dots,x_n}(g(\hat{\theta}(x_1,\dots,x_n))) &= \sup_{\theta^*\in\Theta: g(\theta^*)=g(\hat{\theta}(x_1,\dots,x_n))} L_{x_1,\dots,x_n}(\theta^*) \\ &= L_{x_1,\dots,x_n}(\hat{\theta}(x_1,\dots,x_n)) \\ &= \max_{\theta\in\Theta} L_{x_1,\dots,x_n}(\theta) \\ &\geqslant \sup_{\theta^*\in\Theta: g(\theta^*)=g(\theta)} L_{x_1,\dots,x_n}(\theta^*) = M_{x_1,\dots,x_n}(g(\theta)) \qquad \forall g(\theta)\in g(\Theta). \end{aligned}$$

Por tanto, $g(\hat{\theta}(X_1,\dots,X_n))$ es EMV de $g(\theta)$. □

Ejemplo. La duración de cierto tipo de lámparas sigue una distribución exponencial con media θ, desconocida. Después de observar el tiempo de vida de n lámparas, estimar por máxima verosimilitud la probabilidad de que la duración de una lámpara sea superior a 500 horas.

Sea X una variable aleatoria que representa la duración de una lámpara, con distribución $X \rightsquigarrow \exp(a)$, $a > 0$. Sabiendo la que la esperanza de X es θ, tenemos que:

$$E[X] = \theta = \frac{1}{a} \implies a = \frac{1}{\theta}.$$

Por tanto, $X \rightsquigarrow \exp(1/\theta)$, $\theta > 0$. Buscamos el EMV de $P_\theta[X > 500]$. En primer lugar, calculamos:

$$P_\theta[X > 500] = \int_{500}^{\infty} \frac{1}{\theta} \exp\left(-\frac{x}{\theta}\right) dx = \left[-\exp\left(-\frac{x}{\theta}\right)\right]_{500}^{\infty} = \exp\left(-\frac{500}{\theta}\right)$$

Por tanto, buscamos el EMV de $g(\theta) = P_\theta[X > 500] = \exp(-500/\theta)$. Por el Teorema de Invariancia de Zehna, si $\hat{\theta}$ es el EMV de θ, entonces:

$$g(\hat{\theta}) = \exp\left(-\frac{500}{\hat{\theta}}\right)$$

es el EMV de $g(\theta) = P_\theta[X > 500]$. Por tanto, nos centramos en calcular el EMV de θ. La función de verosimilitud es:

$$L_{x_1,\ldots,x_n}(\theta) = \prod_{i=1}^{n} f_{X_i}(x_i;\theta) = \prod_{i=1}^{n} \frac{1}{\theta} \exp\left(-\frac{x_i}{\theta}\right) = \frac{1}{\theta^n} \exp\left(-\frac{1}{\theta}\sum_{i=1}^{n} x_i\right) \qquad \forall \theta > 0$$

Puesto que el logaritmo es una función estrictamente creciente, podemos trabajar con la log-verosimilitud:

$$\ln(L_{x_1,\ldots,x_n}(\theta)) = -n\ln(\theta) - \frac{1}{\theta}\sum_{i=1}^{n} x_i \qquad \forall \theta > 0$$

Como buscamos el máximo, derivamos e igualamos a cero:

$$\frac{d}{d\theta}\ln(L_{x_1,\ldots,x_n}(\theta)) = -\frac{n}{\theta} + \frac{1}{\theta^2}\sum_{i=1}^{n} x_i = 0 \implies -n\theta + \sum_{i=1}^{n} x_i = 0 \implies \theta = \frac{1}{n}\sum_{i=1}^{n} x_i$$

Sería necesario comprobar que efectivamente se trata de un máximo, pero se tiene. Por tanto, el candidato a EMV de θ es:

$$\hat{\theta} = \frac{1}{n}\sum_{i=1}^{n} X_i = \overline{X}.$$

Como $\theta > 0$ y $\hat{\theta} > 0$, podemos concluir que efectivamente $\hat{\theta}$ es un estimador de θ, y por lo tanto, $\hat{\theta}$ es el EMV de θ. Por el Teorema de Invariancia de Zehna, si $\hat{\theta}$ es el EMV de θ, entonces:

$$g(\hat{\theta}) = \exp\left(-\frac{500}{\hat{\theta}}\right)$$

es el EMV de $g(\theta) = P_\theta[X > 500]$. Por tanto, el EMV de $P_\theta[X > 500]$ es:

$$\widehat{P_\theta[X > 500]} = \exp\left(-\frac{500}{\hat{\theta}}\right) = \exp\left(-\frac{500}{\overline{X}}\right).$$

Ejemplo. En el muestreo de una v.a. $X \rightsquigarrow \mathcal{P}(\lambda)$, $\lambda > 0$, se obtiene que en n observaciones aparece y veces el valor 0. Obtener un EMV de λ a partir de esta información.

Como primer enfoque, buscaríamos definir la función de verosimilitud de λ, $L_{x_1,\ldots,x_n}(\lambda)$. No obstante, como no conocemos los valores de las observaciones, no podemos seguir este enfoque. Definimos la variable auxiliar Y como el número de veces que aparece el valor 0 en la muestra, luego:

$$Y = \sum_{i=1}^{n} I_{\{0\}}(X_i) \rightsquigarrow \mathcal{B}(n, P[X = 0]) = \mathcal{B}(n, e^{-\lambda}).$$

Por tanto, la función de verosimilitud de $e^{-\lambda}$ es:

$$L_y(e^{-\lambda}) = P[Y = y] = \binom{n}{y}(e^{-\lambda})^y(1 - e^{-\lambda})^{n-y} \qquad \forall e^{-\lambda} \in]0, 1[$$

Puesto que el logaritmo es una función estrictamente creciente, podemos trabajar con la log-verosimilitud:

$$\ln(L_y(e^{-\lambda})) = \ln\left(\binom{n}{y}\right) + y\ln(e^{-\lambda}) + (n - y)\ln(1 - e^{-\lambda}) \qquad \forall e^{-\lambda} \in]0, 1[$$

Como buscamos el máximo, derivamos e igualamos a cero:

$$\begin{aligned}\frac{d}{d(e^{-\lambda})}\ln(L_y(e^{-\lambda})) = \frac{y}{e^{-\lambda}} - \frac{n-y}{1-e^{-\lambda}} = 0 \implies \\ \implies y(1 - e^{-\lambda}) - (n - y)e^{-\lambda} = 0 \implies \\ \implies y - ne^{-\lambda} = 0 \implies e^{-\lambda} = \frac{y}{n}\end{aligned}$$

Sería necesario comprobar que efectivamente se trata de un máximo, pero se tiene. Por tanto, el candidato a EMV de $e^{-\lambda}$ es:

$$\widehat{e^{-\lambda}} = \frac{Y}{n}.$$

Como $e^{-\lambda} \in]0, 1[$ y $\widehat{e^{-\lambda}} \in [0, 1]$, podemos concluir que efectivamente $\widehat{e^{-\lambda}}$ es un estimador de $e^{-\lambda}$, y por lo tanto, $\widehat{e^{-\lambda}}$ es el EMV de $e^{-\lambda}$. Por el Teorema de Invariancia de Zehna, si $\widehat{\lambda}$ es el EMV de λ, entonces:

$$e^{-\widehat{\lambda}} = \widehat{e^{-\lambda}} \implies \widehat{\lambda} = -\ln(\widehat{e^{-\lambda}}) = -\ln\left(\frac{Y}{n}\right) = \ln\left(\frac{n}{Y}\right).$$

Ejemplo. Estimar mediante el método de los momentos los parámetros de las siguientes distribuciones:

1. $X \rightsquigarrow \mathcal{N}(\mu, \sigma^2)$.

   Puesto que tenemos dos parámetros, necesitamos dos momentos. Por tanto, calculamos el primer y segundo momento poblacionales:

   $$m_1 = E[X] = \mu$$
   $$m_2 = E[X^2] = Var[X] + (E[X])^2 = \sigma^2 + \mu^2$$

   Por otro lado, calculamos el primer y segundo momento muestrales:

   $$A_1 = \frac{1}{n}\sum_{i=1}^{n} X_i = \overline{X}$$
   $$A_2 = \frac{1}{n}\sum_{i=1}^{n} X_i^2$$

   Por el método de los momentos, igualamos los momentos poblacionales con los muestrales:

   $$m_1 = A_1 \implies \mu = \overline{X}$$
   $$m_2 = A_2 \implies \sigma^2 + \mu^2 = A_2 \implies \sigma^2 = \frac{1}{n}\sum_{i=1}^{n} X_i^2 - \overline{X}^2 = Var[X_1, \ldots, X_n]$$

   Por tanto, los estimadores por el método de los momentos son:

   $$\hat{\mu} = \overline{X}, \qquad \hat{\sigma}^2 = Var[X_1, \ldots, X_n]$$

   Sería necesario comprobar que efectivamente $\hat{\mu}$ y $\hat{\sigma}^2$ son estimadores de μ y σ^2, respectivamente, pero se tiene. Por tanto, podemos concluir que $\hat{\mu}$ y $\hat{\sigma}^2$ son los estimadores por el método de los momentos de μ y σ^2, respectivamente. Como podemos ver, los estimadores por el método de los momentos no tienen por qué ser insesgados.

2. $X \rightsquigarrow \mathcal{U}(a, b)$.

   Puesto que tenemos dos parámetros, necesitamos dos momentos. Por tanto, calculamos el primer y segundo momento poblacionales:

   $$m_1 = E[X] = \frac{a+b}{2}$$
   $$m_2 = E[X^2] = Var[X] + (E[X])^2 = \frac{(b-a)^2}{12} + \left(\frac{a+b}{2}\right)^2 =$$
   $$= \frac{b^2 + a^2 - 2ab + 3a^2 + 3b^2 + 6ab}{12} = \frac{a^2 + ab + b^2}{3}$$

   Por otro lado, calculamos el primer y segundo momento muestrales:

   $$A_1 = \frac{1}{n}\sum_{i=1}^{n} X_i = \overline{X}$$
   $$A_2 = \frac{1}{n}\sum_{i=1}^{n} X_i^2$$

Por el método de los momentos, igualamos los momentos poblacionales con los muestrales:

$$m_1 = A_1 \implies \frac{a+b}{2} = \overline{X} \implies a + b = 2\overline{X}$$
$$m_2 = A_2 \implies \frac{a^2 + ab + b^2}{3} = A_2$$

Resolviendo el sistema de ecuaciones, obtenemos:

$$a = \overline{X} - \sqrt{3}\sqrt{A_2 - \overline{X}^2}b \qquad = \overline{X} + \sqrt{3}\sqrt{A_2 - \overline{X}^2}$$

Por tanto, los estimadores por el método de los momentos son:

$$\hat{a} = \overline{X} - \sqrt{3}\sqrt{A_2 - \overline{X}^2}, \qquad \hat{b} = \overline{X} + \sqrt{3}\sqrt{A_2 - \overline{X}^2}$$

Sería necesario comprobar que efectivamente $\hat{a}$ y $\hat{b}$ son estimadores de a y b, respectivamente, pero se tiene. Por tanto, podemos concluir que $\hat{a}$ y $\hat{b}$ son los estimadores por el método de los momentos de a y b, respectivamente.

3. $X \rightsquigarrow \mathcal{P}(\lambda)$.

Puesto que tenemos un parámetro, necesitamos un momento. Por tanto, calculamos el primer momento poblacional:

$$m_1 = E[X] = \lambda$$

Por otro lado, calculamos el primer momento muestral:

$$A_1 = \frac{1}{n}\sum_{i=1}^{n} X_i = \overline{X}$$

Por el método de los momentos, igualamos los momentos poblacionales con los muestrales:

$$m_1 = A_1 \implies \lambda = \overline{X}$$

Por tanto, el estimador por el método de los momentos es:

$$\hat{\lambda} = \overline{X}$$

Observación. Notemos que, si hubiésemos incluido las igualdades relacionadas con el segundo momento, habríamos obtenido $\hat{\lambda} = Var[X_1, \ldots, X_n]$, por lo que es importante añadir tan solo las igualdades necesarias para obtener el número de ecuaciones igual al número de parámetros.

4. $X \rightsquigarrow \mathcal{U}(0, \theta)$.

   Puesto que tenemos un parámetro, necesitamos un momento. Por tanto, calculamos el primer momento poblacional:

$$m_1 = E[X] = \frac{\theta}{2}$$

   Por otro lado, calculamos el primer momento muestral:

$$A_1 = \frac{1}{n}\sum_{i=1}^{n} X_i = \overline{X}$$

   Por el método de los momentos, igualamos los momentos poblacionales con los muestrales:

$$m_1 = A_1 \implies \frac{\theta}{2} = \overline{X} \implies \theta = 2\overline{X}$$

   Por tanto, el estimador por el método de los momentos es:

$$\hat{\theta} = 2\overline{X}$$

   Sería necesario comprobar que efectivamente $\hat{\theta}$ es un estimador de θ, pero se tiene. Por tanto, podemos concluir que $\hat{\theta}$ es el estimador por el método de los momentos de θ.

   Observación. Veamos qué ocurre si la muestra que consideramos es $(2, 4, 9, 1)$. En este caso:

$$\hat{\theta} = 2\overline{X} = 2 \cdot \frac{2+4+9+1}{4} = 2 \cdot \frac{16}{4} = 8$$

   Por tanto, el estimador por el método de los momentos nos da $\hat{\theta} = 8$, luego podríamos pensar que $X \rightsquigarrow \mathcal{U}(0, 8)$. No obstante, esto no es posible, ya que la muestra contiene el valor 9, que no pertenece al intervalo $[0, 8]$. Por tanto, el estimador por el método de los momentos no siempre es adecuado.

Ejemplo. Para estmar la aceleración de la gravedad en una ciudad, θ, se deja caer un objeto durante tiempos $t_1, \ldots, t_n$ y se mide el espacio recorrido en cada tiempo. Si X_i representa la medida correspondiente al espacio recorrido en el tiempo t_i, con error de medida ε_i, estimar θ por el método de mínimos cuadrados.

Por la ecuación del movimiento rectilíneo uniformemente acelerado, tenemos que:

$$X_i = \frac{1}{2}\theta t_i^2 + \varepsilon_i \implies \varepsilon_i = X_i - \frac{1}{2}\theta t_i^2$$

Por el método de mínimos cuadrados, buscamos minimizar la suma de los cuadrados de los errores:

$$S(\theta) = \sum_{i=1}^{n} \varepsilon_i^2 = \sum_{i=1}^{n} \left(x_i - \frac{1}{2}\theta t_i^2 \right)^2$$

Como buscamos el mínimo, derivamos e igualamos a cero:

$$\frac{d}{d\theta}S(\theta) = \sum_{i=1}^{n} 2\left(x_i - \frac{1}{2}\theta t_i^2\right)\left(-\frac{1}{2}t_i^2\right) = 0 \implies \sum_{i=1}^{n} t_i^2 x_i - \frac{1}{2}\theta \sum_{i=1}^{n} t_i^4 = 0$$

Por tanto, obtenemos:

$$\theta = \frac{2\sum_{i=1}^{n} t_i^2 x_i}{\sum_{i=1}^{n} t_i^4}$$

Por tanto, el estimador por el método de mínimos cuadrados es:

$$\hat{\theta} = \frac{2\sum_{i=1}^{n} t_i^2 X_i}{\sum_{i=1}^{n} t_i^4}$$

1.6. Estimación por intervalos de confianza

Ejemplo. Sea $X_1, \ldots, X_n$ una muestra aleatoria simple de una variable aleatoria $X \rightsquigarrow \mathcal{N}(\mu, \sigma_0^2)$, con $\mu \in \mathbb{R}$. Construir un intervalo de confianza para μ al nivel de confianza $1-\alpha$ de la forma $\left]\overline{X} - C_1, \overline{X} + C_2\right[$.

Buscamos obtener C_1 y C_2 tales que:

$$P_\mu[\overline{X} - C_1 < \mu < \overline{X} + C_2] \geqslant 1 - \alpha$$

La única variable aleatoria que aparece en la desigualdad es $\overline{X}$, por lo que podemos reescribirla como:

$$P_\mu[\mu - C_2 < \overline{X} < \mu + C_1] \geqslant 1 - \alpha$$

Tipificando $\overline{X}$ sabiendo que $\overline{X} \rightsquigarrow \mathcal{N}\left(\mu, \sigma_0^2/n\right)$, obtenemos:

$$P_\mu\left[\frac{\mu - C_2 - \mu}{\sigma_0/\sqrt{n}} < \frac{\overline{X} - \mu}{\sigma_0/\sqrt{n}} < \frac{\mu + C_1 - \mu}{\sigma_0/\sqrt{n}}\right] \geqslant 1 - \alpha$$

Notando por Z a la variable aleatoria tipificada de $\overline{X}$, $Z \rightsquigarrow \mathcal{N}(0,1)$, podemos reescribir la desigualdad como:

$$P_\mu\left[\frac{-C_2}{\sigma_0/\sqrt{n}} < Z < \frac{C_1}{\sigma_0/\sqrt{n}}\right] \geqslant 1 - \alpha$$

Aunque habría muchas formas de elegir $\frac{C_1}{\sigma_0/\sqrt{n}}$ y $\frac{-C_2}{\sigma_0/\sqrt{n}}$, una forma natural de hacerlo es que sean simétricos respecto a 0, pues será el intervalo de confianza más pequeño posible. Por lo tanto, podemos imponer que:

$$\frac{C_1}{\sigma_0/\sqrt{n}} = \frac{-C_2}{\sigma_0/\sqrt{n}} \Longrightarrow C_1 = C_2 = C$$

En ese caso, tenemos que:

$$\frac{C}{\sigma_0/\sqrt{n}} = z_{\alpha/2}$$

donde $P[Z \geqslant z_{\alpha/2}] = \alpha/2$. Por lo tanto, obtenemos que:

$$C = z_{\alpha/2}\frac{\sigma_0}{\sqrt{n}}$$

Por lo tanto, el intervalo de confianza para μ al nivel de confianza $1-\alpha$ es:

$$\left]\overline{X} - z_{\alpha/2}\frac{\sigma_0}{\sqrt{n}}, \overline{X} + z_{\alpha/2}\frac{\sigma_0}{\sqrt{n}}\right[$$

En el caso típico de $\alpha = 0{,}05$, tenemos que $z_{\alpha/2} = z_{0{,}025} = 1{,}96$, por lo que el intervalo de confianza para μ al nivel de confianza 95 % es:

$$\left]\overline{X} - 1{,}96\frac{\sigma_0}{\sqrt{n}}, \overline{X} + 1{,}96\frac{\sigma_0}{\sqrt{n}}\right[$$

Ejemplo. Obtener, utilizando la desigualdad de Chebychev, un intervalo de confianza para la media poblacional, μ, basado en una muestra de tamaño n de una variable aleatoria cuya varianza, σ_0^2, es conocida.

Sea $X_1, \ldots, X_n$ una muestra aleatoria simple de una variable aleatoria X con $E[X] = \mu$ y $Var[X] = \sigma_0^2$, conocida. Consideramos la media muestral $\overline{X}$. Tenemos que:

$$E[\overline{X}] = E[X] = \mu, \quad Var[\overline{X}] = \frac{Var[X]}{n} = \frac{\sigma_0^2}{n}$$

Por tanto, por la desigualdad de Chebychev, para cualquier $k > 0$:

$$P_\mu[|\overline{X} - \mu| \geqslant k] \geqslant 1 - \frac{Var[\overline{X}]}{k^2} = 1 - \frac{\sigma_0^2}{nk^2}$$

Reescribiendo la desigualdad, obtenemos:

$$P_\mu[k - \mu < \overline{X} < k + \mu] \geqslant 1 - \frac{\sigma_0^2}{nk^2}$$

Como en un intervalo de confianza queremos calcular la probabilidad de que el intervalo contenga a μ, podemos reescribir la desigualdad como:

$$P_\mu[\overline{X} - k < \mu < \overline{X} + k] \geqslant 1 - \frac{\sigma_0^2}{nk^2}$$

Por lo tanto, para obtener un intervalo de confianza al nivel de confianza $1 - \alpha$, debemos imponer que:

$$1 - \frac{\sigma_0^2}{nk^2} = 1 - \alpha \Longrightarrow k = \sqrt{\frac{\sigma_0^2}{n\alpha}}$$

Por lo tanto, el intervalo de confianza para μ al nivel de confianza $1 - \alpha$ es:

$$\left]\overline{X} - \sqrt{\frac{\sigma_0^2}{n\alpha}}, \overline{X} + \sqrt{\frac{\sigma_0^2}{n\alpha}}\right[$$

Ejemplo. Sea X una variable aleatoria con función de densidad:

$$f_\theta(x) = \theta x^{\theta-1}, \quad 0 < x < 1$$

Determinar un intervalo de confianza para θ utilizando el método de la cantidad pivotal.

Como X una variable aleatoria continua con función de densidad $f_\theta(x)$, hemos de emplear la siguiente función pivote:

$$T(X_1, \ldots, X_n; \theta) = -2 \sum_{i=1}^{n} \ln(F_\theta(X_i)) \rightsquigarrow \chi^2(2n)$$

Por tanto, buscamos la función de distribución de X:

$$F_\theta(x) = \int_0^x f_\theta(t)dt = \int_0^x \theta t^{\theta-1}dt = \left[t^\theta\right]_0^x = x^\theta$$

Por lo tanto, la función pivote es:

$$T(X_1,\ldots,X_n;\theta) = -2\sum_{i=1}^n \ln(X_i^\theta) = -2\sum_{i=1}^n \theta\ln(X_i) = -2\theta\sum_{i=1}^n \ln(X_i) \rightsquigarrow \chi^2(2n)$$

Comprobemos las hipótesis para poder emplear el método de la cantidad pivotal.

- Veamos que $T(X_1,\ldots,X_n;\theta)$ es estrictamente monótona en θ.

$$\frac{\partial T(X_1,\ldots,X_n;\theta)}{\partial\theta} = -2\sum_{i=1}^n \ln(X_i)$$

  Como $0 < X_i < 1$, tenemos que $\ln(X_i) < 0$, por lo que la derivada es positiva, y por tanto $T(X_1,\ldots,X_n;\theta)$ es estrictamente creciente en θ.

- Veamos que la siguiente igualdad siempre tiene solución para θ:

$$T(X_1,\ldots,X_n;\theta) = -2\theta\sum_{i=1}^n \ln(X_i) = \lambda \Longrightarrow \theta = -\frac{\lambda}{2\sum\limits_{i=1}^n \ln(X_i)}$$

Por tanto, podemos emplear el método de la cantidad pivotal. Sean $\lambda_1, \lambda_2 \in \mathbb{R}$ tales que:

$$P[\lambda_1 < T(X_1,\ldots,X_n;\theta) < \lambda_2] = 1-\alpha$$

Como $T(X_1,\ldots,X_n;\theta) \rightsquigarrow \chi^2(2n)$, aunque habría muchas formas de elegir λ_1 y λ_2, una forma natural de hacerlo es que cada uno de ellos deje una probabilidad de $\alpha/2$ a su izquierda y derecha, respectivamente, para que el intervalo de confianza sea lo más pequeño posible. Por lo tanto, podemos imponer que:

$$\lambda_1 = \chi^2_{1-\alpha/2}(2n), \quad \lambda_2 = \chi^2_{\alpha/2}(2n)$$

Por lo tanto, tenemos que:

$$P[\chi^2_{1-\alpha/2}(2n) < T(X_1,\ldots,X_n;\theta) < \chi^2_{\alpha/2}(2n)] = 1-\alpha$$

Aplicando el método de la cantidad pivotal y empleando que $T(X_1,\ldots,X_n;\theta)$ es estrictamente creciente en θ, obtenemos:

$$P\left[-\frac{\chi^2_{1-\alpha/2}(2n)}{2\sum\limits_{i=1}^n \ln(X_i)} < \theta < -\frac{\chi^2_{\alpha/2}(2n)}{2\sum\limits_{i=1}^n \ln(X_i)}\right] = 1-\alpha$$

Por lo tanto, el intervalo de confianza para θ al nivel de confianza $1-\alpha$ es:

$$\left]-\frac{\chi^2_{1-\alpha/2}(2n)}{2\sum\limits_{i=1}^n \ln(X_i)}, -\frac{\chi^2_{\alpha/2}(2n)}{2\sum\limits_{i=1}^n \ln(X_i)}\right[$$

Ejemplo. Sea $(X_1, \ldots, X_n)$ una muestra aleatoria simple de una variable aleatoria $X \rightsquigarrow \mathcal{N}(\mu, \sigma_0^2)$. Empleando como cantidad pivotal

$$T(X_1, \ldots, X_n; \mu) = \frac{\overline{X} - \mu}{\sigma_0/\sqrt{n}} \rightsquigarrow \mathcal{N}(0, 1)$$

Se obtiene un intervalo de confianza para μ al nivel de confianza $1 - \alpha$, que es de menor longitud esperada:

$$\left]\overline{X} - z_{\alpha/2}\frac{\sigma_0}{\sqrt{n}}, \overline{X} + z_{\alpha/2}\frac{\sigma_0}{\sqrt{n}}\right[$$

Comparar este intervalo con el que se obtuvo como ejemplo utilizando la desigualdad de Chebychev (ejemplo de la página 66).

En dicho ejemplo, el intervalo de confianza para μ al nivel de confianza $1 - \alpha$ era:

$$\left]\overline{X} - \sqrt{\frac{\sigma_0^2}{n\alpha}}, \overline{X} + \sqrt{\frac{\sigma_0^2}{n\alpha}}\right[$$

- La longitud del intervalo de confianza obtenido mediante la desigualdad de Chebychev es:

$$L_C = 2\sqrt{\frac{\sigma_0^2}{n\alpha}}$$

- La longitud del intervalo de confianza obtenido mediante la cantidad pivotal es:

$$L_P = 2z_{\alpha/2}\frac{\sigma_0}{\sqrt{n}}$$

Notemos que, aun siendo variables aleatorias, estas son degeneradas, por lo que su longitud esperada es la misma que su longitud. Por lo tanto, para comparar ambos intervalos de confianza, basta con comparar sus longitudes. Veamos algunos ejemplos de comparación de longitudes para distintos valores de α:

- Para $\alpha = 0{,}05$, tenemos que $z_{\alpha/2} = z_{0{,}025} = 1{,}96$:

$$\frac{L_C}{L_P} = \frac{\sqrt{\frac{1}{\alpha}}}{z_{\alpha/2}} = \frac{\sqrt{\frac{1}{0{,}05}}}{1{,}96} \approx 2{,}28$$

- Para $\alpha = 0{,}01$, tenemos que $z_{\alpha/2} = z_{0{,}005} = 2{,}58$:

$$\frac{L_C}{L_P} = \frac{\sqrt{\frac{1}{\alpha}}}{z_{\alpha/2}} = \frac{\sqrt{\frac{1}{0{,}01}}}{2{,}58} \approx 3{,}87$$

Como se puede observar, el intervalo de confianza obtenido mediante la cantidad pivotal es más pequeño que el obtenido mediante la desigualdad de Chebychev, y la diferencia entre ambos aumenta a medida que disminuye α.

2. Relaciones de Ejercicios

2.1. Estadísticos muestrales

Ejercicio 2.1.1. Sea $(X_1, \ldots, X_n)$ una muestra aleatoria simple de una variable aleatoria X. Dar el espacio muestral y calcular la función masa de probabilidad de $(X_1, \ldots, X_n)$ en cada uno de los siguientes casos:

a) $X \rightsquigarrow \{\mathcal{B}(k_0, p) : p \in (0,1)\}$ Binomial.

El espacio muestral en este caso es $\mathcal{X}^n$, donde:

$$\mathcal{X} = \{0, 1, ..., k_0\}$$

Recordamos que si $X \rightsquigarrow \mathcal{B}(k_0, p)$, entonces:

$$P[X = x] = \binom{k_0}{x} p^x (1-p)^{k_0 - x} \qquad \forall x \in \mathcal{X}$$

Por tanto, para nuestra m.a.s. tendremos la función masa de probabilidad:

$$P[X_1 = x_1, \ldots, X_n = x_n] \overset{\text{indep.}}{=} \prod_{i=1}^{n} P[X_i = x_i] \overset{\text{id. d.}}{=} \prod_{i=1}^{n} P[X = x_i]$$

$$= \prod_{i=1}^{n} \binom{k_0}{x_i} p^{x_i} (1-p)^{k_0 - x_i} = p^{\sum_{i=1}^{n} x_i} (1-p)^{nk_0 - \sum_{i=1}^{n} x_i} \prod_{i=1}^{n} \binom{k_0}{x_i}$$

$$\forall (x_1, \ldots, x_n) \in \mathcal{X}^n$$

b) $X \rightsquigarrow \{\mathcal{P}(\lambda) : \lambda \in \mathbb{R}^+\}$ Poisson.

El espacio muestral en este caso es $\mathcal{X}^n$, donde:

$$\mathcal{X} = \mathbb{N} \cup \{0\}$$

Recordamos que si $X \rightsquigarrow \mathcal{P}(\lambda)$, entonces:

$$P[X = x] = e^{-\lambda} \frac{\lambda^x}{x!} \qquad \forall x \in \mathcal{X}$$

Por tanto:

$$P[X_1 = x_1, \ldots, X_n = x_n] \overset{\text{indep.}}{=} \prod_{i=1}^{n} P[X_i = x_i] \overset{\text{id. d.}}{=} \prod_{i=1}^{n} P[X = x_i]$$

$$= \prod_{i=1}^{n} e^{-\lambda} \frac{\lambda^{x_i}}{x_i!} = e^{-n\lambda} \prod_{i=1}^{n} \frac{\lambda^{x_i}}{x_i!} = e^{-n\lambda} \cdot \frac{\lambda^{\sum_{i=1}^{n} x_i}}{\prod_{i=1}^{n} x_i!} \qquad \forall (x_1, \ldots, x_n) \in \mathcal{X}^n$$

c) $X \rightsquigarrow \{BN(k_0, p) : p \in (0,1)\}$ Binomial Negativa.

El espacio muestral en este caso es $\mathcal{X}^n$, donde:

$$\mathcal{X} = \mathbb{N} \cup \{0\}$$

Recordamos que si $X \rightsquigarrow BN(k_0, p)$, entonces:

$$P[X = x] = \binom{x + k_0 - 1}{x}(1-p)^x p^{k_0} \qquad \forall x \in \mathcal{X}$$

Por tanto:

$$\begin{aligned} P[X_1 = x_1, \ldots, X_n = x_n] &\overset{\text{indep.}}{=} \prod_{i=1}^n P[X_i = x_i] \overset{\text{id. d.}}{=} \prod_{i=1}^n P[X = x_i] \\ &= \prod_{i=1}^n \binom{x_i + k_0 - 1}{x_i}(1-p)^{x_i} p^{k_0} = p^{nk_0}(1-p)^{\sum_{i=1}^n x_i} \prod_{i=1}^n \binom{x_i + k_0 - 1}{x_i} \\ &\forall (x_1, \ldots, x_n) \in \mathcal{X}^n \end{aligned}$$

d) $X \rightsquigarrow \{G(p) : p \in (0,1)\}$ Geométrica.

El espacio muestral en este caso es $\mathcal{X}^n$, donde:

$$\mathcal{X} = \mathbb{N} \cup \{0\}$$

Recordamos que $G(p) \equiv BN(1, p)$, por lo que si sustituimos en la fórmula obtenida en la Binomial Negativa $k_0 = 1$:

$$P[X_1 = x_1, \ldots, X_n = x_n] = p^n (1-p)^{\sum_{i=1}^n x_i} \qquad \forall (x_1, \ldots, x_n) \in \mathcal{X}^n$$

e) $X \rightsquigarrow \{P_N : N \in \mathbb{N}\}, \quad P_N[X = x] = \dfrac{1}{N}, \quad x = 1, \ldots, N.$

El espacio muestral en este caso es $\mathcal{X}^n$, donde (tal y como nos dan en el enunciado):

$$\mathcal{X} = \{1, \ldots, N\}$$

Calculemos la masa de probabilidad:

$$\begin{aligned} P[X_1 = x_1, \ldots, X_n = x_n] &\overset{\text{indep.}}{=} \prod_{i=1}^n P[X_i = x_i] \overset{\text{id. d.}}{=} \prod_{i=1}^n P[X = x_i] \\ &= \prod_{i=1}^n \frac{1}{N} = \left(\frac{1}{N}\right)^n \qquad \forall (x_1, \ldots, x_n) \in \mathcal{X}^n \end{aligned}$$

Ejercicio 2.1.2. Sea $(X_1, \ldots, X_n)$ una muestra aleatoria simple de una variable aleatoria X. Dar el espacio muestral y calcular la función de densidad de $(X_1, \ldots, X_n)$ en cada uno de los siguientes casos:

a) $X \rightsquigarrow \{\mathcal{U}(a,b) : a,b \in \mathbb{R}, a < b\}$ Uniforme.

El espacio muestral en este caso es $\mathcal{X}^n$, donde:

$$\mathcal{X} = [a,b]$$

Recordamos que si $X \rightsquigarrow \mathcal{U}(a,b)$, entonces:

$$f_X(x) = \frac{1}{b-a} \qquad \forall x \in [a,b]$$

Por lo que:

$$f_{(X_1,\dots,X_n)}(x_1,\dots,x_n) \overset{\text{indep.}}{=} \prod_{i=1}^{n} f_{X_i}(x_i) \overset{\text{id. d.}}{=} \prod_{i=1}^{n} f_X(x_i) = \prod_{i=1}^{n} \frac{1}{b-a}$$
$$= \left(\frac{1}{b-a}\right)^n \qquad \forall (x_1,\dots,x_n) \in \mathcal{X}^n$$

b) $X \rightsquigarrow \{\mathcal{N}(\mu,\sigma^2) : \mu \in \mathbb{R}, \sigma^2 \in \mathbb{R}^+\}$ Normal.

El espacio muestral en este caso es $\mathcal{X}^n$, donde $\mathcal{X} = \mathbb{R}$. Recordamos que si $X \rightsquigarrow \mathcal{N}(\mu,\sigma^2)$, entonces:

$$f_X(x) = \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(x-\mu)^2}{2\sigma^2}} \qquad \forall x \in \mathbb{R}$$

Por lo que:

$$f_{(X_1,\dots,X_n)}(x_1,\dots,x_n) \overset{\text{indep.}}{=} \prod_{i=1}^{n} f_{X_i}(x_i) \overset{\text{id. d.}}{=} \prod_{i=1}^{n} f_X(x_i) = \prod_{i=1}^{n} \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(x_i-\mu)^2}{2\sigma^2}}$$
$$= \left(\frac{1}{\sqrt{2\pi}\sigma}\right)^n \prod_{i=1}^{n} e^{-\frac{(x_i-\mu)^2}{2\sigma^2}} = \left(\frac{1}{\sqrt{2\pi}\sigma}\right)^n e^{-\sum_{i=1}^{n} \frac{(x_i-\mu)^2}{2\sigma^2}}$$
$$= \left(\frac{1}{\sqrt{2\pi}\sigma}\right)^n e^{\frac{-1}{2\sigma^2}\sum_{i=1}^{n}(x_i-\mu)^2} \qquad \forall (x_1,\dots,x_n) \in \mathbb{R}^n$$

c) $X \rightsquigarrow \{\Gamma(p,a) : p,a \in \mathbb{R}^+\}$ Gamma.

El espacio muestral en este caso es $\mathcal{X}^n$, donde $\mathcal{X} = \mathbb{R}_0^+$. Recordamos que si $X \rightsquigarrow \Gamma(p,a)$, entonces:

$$f_X(x) = \frac{a^p}{\Gamma(p)} x^{p-1} e^{-ax} \qquad \forall x \in \mathbb{R}_0^+$$

Por lo que:

$$f_{(X_1,\dots,X_n)}(x_1,\dots,x_n) \overset{\text{indep.}}{=} \prod_{i=1}^{n} f_{X_i}(x_i) \overset{\text{id. d.}}{=} \prod_{i=1}^{n} f_X(x_i) = \prod_{i=1}^{n} \frac{a^p}{\Gamma(p)} x_i^{p-1} e^{-ax_i}$$
$$= \left(\frac{a^p}{\Gamma(p)}\right)^n \cdot e^{-a\sum_{i=1}^{n} x_i} \cdot \prod_{i=1}^{n} x_i^{p-1} \qquad \forall (x_1,\dots,x_n) \in \mathcal{X}^n$$

d) $X \rightsquigarrow \{\beta(p,q) : p,q \in \mathbb{R}^+\}$ Beta.

El espacio muestral en este caso es $\mathcal{X}^n$, donde $\mathcal{X} = [0,1]$. Recordamos que si $X \rightsquigarrow \beta(p,q)$, entonces:

$$f_X(x) = \frac{1}{\beta(p,q)} x^{p-1}(1-x)^{q-1} \qquad \forall x \in [0,1]$$

Donde:

$$\beta(p,q) = \frac{\Gamma(p)\Gamma(q)}{\Gamma(p+q)}$$

Por tanto:

$$f_{(X_1,\dots,X_n)}(x_1,\dots,x_n) \overset{\text{indep.}}{=} \prod_{i=1}^n f_{X_i}(x_i) \overset{\text{id. d.}}{=} \prod_{i=1}^n f_X(x_i) = \prod_{i=1}^n \frac{1}{\beta(p,q)} x_i^{p-1}(1-x_i)^{q-1}$$
$$= \frac{1}{\beta(p,q)^n} \prod_{i=1}^n x_i^{p-1}(1-x_i)^{q-1} \qquad \forall (x_1,\dots,x_n) \in \mathcal{X}^n$$

e) $X \rightsquigarrow \{P_\theta : \theta \in \mathbb{R}^+\}, \quad f_\theta(x) = \dfrac{1}{2\sqrt{x\theta}}, \quad 0 < x < \theta.$

El espacio muestral en este caso es $\mathcal{X}^n$, donde (tal y como nos dan en el enunciado):

$$\mathcal{X} =]0,\theta[$$

Calculamos la función de densidad conjunta:

$$f_{(X_1,\dots,X_n)}(x_1,\dots,x_n) \overset{\text{indep.}}{=} \prod_{i=1}^n f_{X_i}(x_i) \overset{\text{id. d.}}{=} \prod_{i=1}^n f_X(x_i) = \prod_{i=1}^n \frac{1}{2\sqrt{x_i\theta}}$$
$$= \frac{1}{\left(2\sqrt{\theta}\right)^n} \prod_{i=1}^n \frac{1}{\sqrt{x_i}} \qquad \forall (x_1,\dots,x_n) \in \mathcal{X}^n$$

Ejercicio 2.1.3. Se miden los tiempos de sedimentación de una muestra de partículas flotando en un líquido. Los tiempos observados son:

11,5; 1,8; 7,3; 12,1; 1,8; 21,3; 7,3; 15,2; 7,3; 12,1; 15,2;
7,3; 12,1; 1,8; 10,5; 15,2; 21,3; 10,5; 15,2; 11,5

1. Construir la función de distribución muestral asociada a a dichas observaciones.

   En primer lugar, ordenamos los datos de menor a mayor, puesto que nos será de utilidad para construir la función de distribución muestral:

   1,8; 1,8; 1,8; 7,3; 7,3; 7,3; 7,3; 10,5; 10,5; 11,5;
   11,5; 12,1; 12,1; 12,1; 15,2; 15,2; 15,2; 15,2; 21,3; 21,3

Si aplicamos la definición de función de distribución muestral obtenemos que esta viene dada por la siguiente ecuación, y está mostrada en la Figura 2.1:

$$F_n^*(x) = \begin{cases} 0 & \text{si } x < 1{,}8 \\ 3/20 & \text{si } 1{,}8 \leqslant x < 7{,}3 \\ 7/20 & \text{si } 7{,}3 \leqslant x < 10{,}5 \\ 9/20 & \text{si } 10{,}5 \leqslant x < 11{,}5 \\ 11/20 & \text{si } 11{,}5 \leqslant x < 12{,}1 \\ 14/20 & \text{si } 12{,}1 \leqslant x < 15{,}2 \\ 18/20 & \text{si } 15{,}2 \leqslant x < 21{,}3 \\ 20/20 & \text{si } x \geqslant 21{,}3 \end{cases}$$

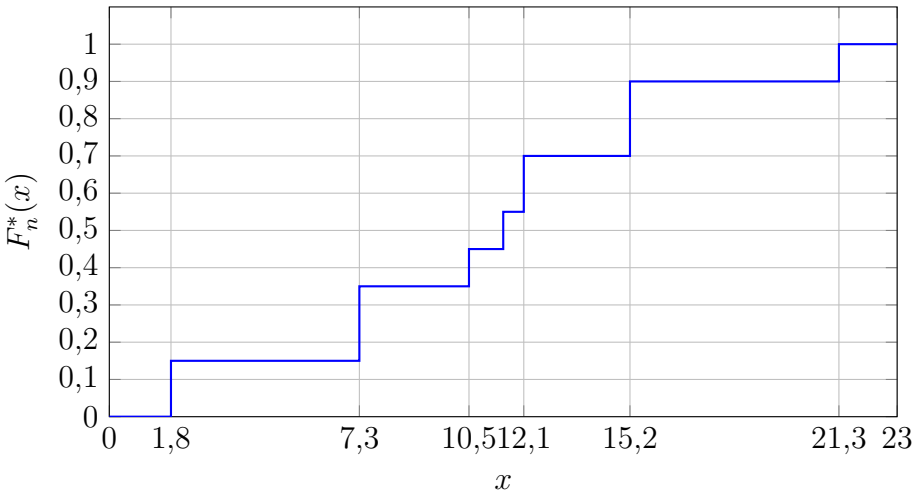


Figura 2.1: Gráfica de la función de distribución muestral.

2. Hallar los valores de los tres primeros momentos muestrales respecto al origen y respecto a la media.

Calculamos primero los tres primeros momentos respecto al origen para luego

calcular los centrados respecto a la media a partir de ellos:

$$a_1 = \sum_{i=1}^{n} f_i x_i = 10{,}915 \qquad a_2 = \sum_{i=1}^{n} f_i x_i^2 = 148{,}9325$$

$$a_3 = \sum_{i=1}^{n} f_i x_i^3 = 2280{,}98365$$

$$b_1 = \sum_{i=1}^{n} f_i (x_i - \overline{x}) = 0$$

$$\begin{aligned} b_2 &= \frac{1}{n}\sum_{i=1}^{n} (x_i - \overline{x})^2 = \frac{1}{n}\sum_{i=1}^{n} (x_i^2 - 2x_i\overline{x} + \overline{x}^2) \\ &= \frac{1}{n}\sum_{i=1}^{n} x_i^2 - \frac{2\overline{x}}{n}\sum_{i=1}^{n} x_i + \overline{x}^2 = a_2 - 2a_1^2 + a_1^2 = a_2 - a_1^2 \\ &= 148{,}9325 - 10{,}915^2 = 29{,}795275 \end{aligned}$$

$$\begin{aligned} b_3 &= \frac{1}{n}\sum_{i=1}^{n} (x_i - \overline{x})^3 = \frac{1}{n}\sum_{i=1}^{n} \left(x_i^3 - 3x_i^2\overline{x} + 3x_i\overline{x}^2 - \overline{x}^3\right) \\ &= \frac{1}{n}\sum_{i=1}^{n} x_i^3 - \frac{3\overline{x}}{n}\sum_{i=1}^{n} x_i^2 + \frac{3\overline{x}^2}{n}\sum_{i=1}^{n} x_i - \overline{x}^3 = a_3 - 3a_1a_2 + 3a_1^3 - a_1^3 \\ &= a_3 - 3a_1a_2 + 2a_1^3 = 4{,}95455925 \end{aligned}$$

3. Determinar los valores de los cuartiles muestrales y el percentil 70.

   Para obtener los cuartiles, primero ordenamos los datos de menor a mayor y los agrupamos en grupos de $^{20}/_{4} = 5$ en 5:

   $$1{,}8;\ 1{,}8;\ 1{,}8;\ 7{,}3;\ 7{,}3;\ 7{,}3;\ 7{,}3;\ 10{,}5;\ 10{,}5;\ 11{,}5;\ 11{,}5;\ 12{,}1;\ 12{,}1;\ 12{,}1;\ 15{,}2;\ 15{,}2;\ 15{,}2;\ 15{,}2;\ 21{,}3;\ 21{,}3$$

   Como en los cambios de agrupaciones de números estos se repiten, hemos obtenido el valor de los cuartiles:

   $$q_1 = 7{,}3 \qquad q_2 = 11{,}5 \qquad q_3 = 15{,}2 \qquad q_4 = 21{,}3$$

   Para el percentil 70, calculamos:

   $$0{,}7 \cdot 20 = 14$$

   Como hemos obtenido un número entero, el percentil 70 será:

   $$c_{70} = \frac{X_{(14)} + X_{(15)}}{2} = \frac{12{,}1 + 15{,}2}{2} = 13{,}65$$

   En el caso de haber obtenido un número no entero (por ejemplo, 14,2), sería $X_{(15)}$.

Ejercicio 2.1.4. Se dispone de una muestra aleatoria simple de tamaño 40 de una distribución exponencial de media 3, ¿cuál es la probabilidad de que los valores de

la función de distribución muestral y la teórica, en $x = 1$, difieran menos de 0,01? Aproximadamente, ¿cuál debe ser el tamaño muestral para que dicha probabilidad sea como mínimo 0,98?

Como dice el enunciado, tenemos una m.a.s. $(X_1, \ldots, X_n)$ con $n = 40$, todas ellas idénticamente distribuidas a $X \rightsquigarrow \exp(\lambda)$. Sabemos de la asignatura de Probabilidad que:

$$E[X] = \frac{1}{\lambda} = 3 \Longrightarrow \lambda = \frac{1}{3}$$

Por lo que $X \rightsquigarrow \exp(1/3)$. Denotaremos por comodidad:

$$F_n^*(x) = F^*_{(X_1,\ldots,X_n)}(x)$$

Y el enunciado nos pregunta por:

$$P[|F_n^*(1) - F_X(1)| < 0{,}01]$$

Para ello, primero calculamos $F_X(1)$, que por comodidad denotaremos por α:

$$F_X(1) = 1 - e^{-\lambda \cdot 1} = 1 - e^{-\lambda} = 1 - e^{-1/3} =: \alpha$$

Por lo que nos disponemos ya a calcular la probabilidad:

$$\begin{aligned} P[|F_n^*(1) - F_X(1)| < 0{,}01] &= P[|F_n^*(1) - \alpha| < 0{,}01] = P[-0{,}01 < F_n^*(1) - \alpha < 0{,}01] \\ &= P[-0{,}01 + \alpha < F_n^*(1) < 0{,}01 + \alpha] \\ &= P[40(-0{,}01 + \alpha) < 40F_n^*(1) < 40(0{,}01 + \alpha)] \end{aligned}$$

Y como sabemos que $Y = 40F_n^*(1) \rightsquigarrow \mathcal{B}(40, F_X(1)) \equiv \mathcal{B}(40, \alpha)$:

$$P[|F_n^*(1) - F_X(1)| < 0{,}01] = P[40(-0{,}01 + \alpha) < Y < 40(0{,}01 + \alpha)]$$

Si ahora tomamos:

$$\alpha = 1 - e^{-1/3} \approx 0{,}283469$$

Entonces:

$$\begin{aligned} 40(0{,}01 + \alpha) &\approx 40(0{,}01 + 0{,}283469) = 11{,}73876 \\ 40(-0{,}01 + \alpha) &\approx 40(-0{,}01 + 0{,}283469) = 10{,}93876 \end{aligned}$$

Por lo que, usando que Y es una variable aleatoria discreta, tenemos que:

$$P[|F_n^*(1) - F_X(1)| < 0{,}01] \approx P[10{,}93876 < Y < 11{,}73876] = P[Y = 11]$$

De donde usando la masa de probabilidad de la Binomial:

$$P[Y = 11] = \binom{40}{11} (0{,}283469)^{11} (1 - 0{,}283469)^{40-11} \approx 0{,}139$$

Por tanto, la probabilidad de que los valores de la función de distribución muestral y la teórica, en $x = 1$, difieran menos de 0,01 es aproximadamente 0,139, luego la probabilidad es baja. Para aumentar dicha probabilidad, necesitamos un tamaño

muestral mayor, que es lo que nos piden en el segundo apartado.

Para el segundo apartado, como para $n = 40$ obtenemos una probabilidad de 0,139, podemos intuir que para que dicha probabilidad sea como mínimo 0,98, nos es necesario un valor de n grande, por lo que podemos suponer que:

$$F_n^*(1) \rightsquigarrow \mathcal{N}\left(\alpha, \frac{\alpha(1-\alpha)}{n}\right)$$

De donde:

$$Z = \frac{\sqrt{n}(F_n^*(1) - \alpha)}{\sqrt{\alpha(1-\alpha)}} \rightsquigarrow \mathcal{N}(0,1)$$

Buscamos el valor de n que verifica:

$$0{,}98 \leqslant P[|F_n^*(1) - F_X(1)| < 0{,}01] = P\left[|Z| < \frac{\sqrt{n}0{,}01}{\sqrt{\alpha(1-\alpha)}}\right]$$

Si aplicamos propiedades conocidas de la función de distribución de una variable aleatoria, si $a \in \mathbb{R}$, entonces:

$$P[|Z| < a] = P[-a < Z < a] = P[Z < a] - P[Z \leqslant -a] = P[Z < a] - P[Z < -a]$$

Pero, empleando las particularidades de la distribución normal, sabemos que:

$$P[Z < -a] = P[Z > a] = 1 - P[Z < a]$$

Por lo que:

$$P[|Z| < a] = P[Z < a] - P[Z < -a] = 2P[Z < a] - 1$$

Volviendo al caso que nos interesa:

$$0{,}98 \leqslant P\left[|Z| < \frac{\sqrt{n}0{,}01}{\sqrt{\alpha(1-\alpha)}}\right] = 2P\left[Z < \frac{\sqrt{n}0{,}01}{\sqrt{\alpha(1-\alpha)}}\right] - 1$$

Luego:

$$0{,}99 = \frac{0{,}98+1}{2} \leqslant P\left[Z < \frac{\sqrt{n}0{,}01}{\sqrt{\alpha(1-\alpha)}}\right]$$

Si consultamos la tabla de la normal $\mathcal{N}(0,1)$, observamos que el primer valor que supera la probbailidad de 0,99 es 2,33, por lo que:

$$2{,}33 = \frac{\sqrt{n}0{,}01}{\sqrt{\alpha(1-\alpha)}} = \frac{\sqrt{n}0{,}01}{\sqrt{0{,}283469(1-0{,}283469)}} \approx 0{,}0221886\sqrt{n}$$

De donde:

$$5{,}4289 = (2{,}33)^2 = (0{,}0221886\sqrt{n})^2 = 0{,}00049233n \Longrightarrow n = \frac{5{,}4289}{0{,}00049233} = 11026{,}95347$$

Por lo que para $n \geqslant 11027$ podemos asegurar que la probabilidad es como mínimo 0,98.

Ejercicio 2.1.5. Se dispone de una muestra aleatoria simple de tamaño 50 de una distribución de Poisson de media 2, ¿cuál es la probabilidad de que los valores de la función de distribución muestral y la teórica, en $x = 2$, difieran menos de 0,02? Aproximadamente, ¿qué tamaño muestral hay que tomar para que dicha probabilidad sea como mínimo 0,99?

Tenemos una m.a.s. $(X_1, \ldots, X_n)$ con $n = 50$ idénticamente distribuidas a $X \rightsquigarrow \mathcal{P}(\lambda)$. Como $E[X] = \lambda = 2$, tenemos que $X \rightsquigarrow \mathcal{P}(2)$. Notamos por comodidad:

$$F^*_{(X_1,\ldots,X_n)}(x) = F^*_n(x)$$

Nos preguntan por:

$$P[|F^*_n(2) - F_X(2)| < 0{,}02]$$

Para ello primero calculamos:

$$F_X(2) = \sum_{k=0}^{2} e^{-2}\frac{2^k}{k!} = e^{-2}\left(\frac{2^0}{0!} + \frac{2^1}{1!} + \frac{2^2}{2!}\right) = e^{-2}(1+2+2) \approx 0{,}6767$$

Por lo que:

$$P[|F^*_n(2) - 0{,}6767| < 0{,}02] = P[-0{,}02 < F^*_n(2) - 0{,}6767 < 0{,}02] = P[0{,}6567 < F^*_n(2) < 0{,}6967]$$

Como sabemos por lo visto en teoría que:

$$Y = 50F^*_n(2) \rightsquigarrow \mathcal{B}(50, F_X(2)) \equiv \mathcal{B}(50, \quad 0{,}6767)$$

Multiplicamos por 50 la última expresión:

$$\begin{aligned} P[|F^*_n(2) - 0{,}6767| < 0{,}02] = P[0{,}6567 < F^*_n(2) < 0{,}6967] = P[32{,}835 < Y < 34{,}835] \\ \overset{(*)}{=} P[Y = 33] + P[Y = 34] \end{aligned}$$

donde en $(*)$ hemos empleado la naturaleza discreta de la variable aleatoria Y. Calculamos estas dos probabilidades:

$$\begin{aligned} P[Y = 33] &= \binom{50}{33}(0{,}6767)^{33}(1 - 0{,}6767)^{50-33} \approx 0{,}114734 \\ P[Y = 34] &= \binom{50}{34}(0{,}6767)^{34}(1 - 0{,}6767)^{50-34} \approx 0{,}120075 \end{aligned}$$

Por lo que:

$$P[|F^*_n(2) - 0{,}6767| < 0{,}02] \approx 0{,}114734 + 0{,}120075 = 0{,}234809$$

Para el segundo apartado, como para $n = 50$ obtenemos una probabilidad de 0,234809, podemos intuir que para que dicha probabilidad sea como mínimo 0,99, nos es necesario un valor de n grande, por lo que podemos suponer que:

$$F^*_n(2) \rightsquigarrow \mathcal{N}\left(0{,}6767, \frac{0{,}6767(1 - 0{,}6767)}{n}\right) \equiv \mathcal{N}\left(0{,}6767, \frac{0{,}218777}{n}\right)$$

Por lo que:

$$Z = \frac{\sqrt{n}(F_n^*(2) - 0{,}6767)}{\sqrt{0{,}218777}} \rightsquigarrow \mathcal{N}(0,1)$$

En dicho caso, buscamos n de forma que:

$$0{,}99 \leqslant P[|F_n^*(2) - F_X(2)| < 0{,}02] = P\left[|Z| < \frac{\sqrt{n}0{,}02}{\sqrt{0{,}218777}}\right]$$

De forma análoga al ejercicio anterior:

$$P\left[|Z| < \frac{\sqrt{n}0{,}02}{\sqrt{0{,}218777}}\right] = 2P\left[Z < \frac{\sqrt{n}0{,}02}{\sqrt{0{,}218777}}\right] - 1$$

Luego:

$$0{,}995 = \frac{0{,}99+1}{2} \leqslant P\left[Z < \frac{\sqrt{n}0{,}02}{\sqrt{0{,}218777}}\right]$$

Y si miramos la tabla de la Normal observamos que el primer valor que supera la probabilidad de 0,995 es 2,58, luego:

$$2{,}58 = \frac{\sqrt{n}0{,}02}{\sqrt{0{,}218777}} = 0{,}042759\sqrt{n}$$

Por lo que:

$$6{,}6564 = (2{,}58)^2 = (0{,}042759\sqrt{n})^2 = 0{,}00182833n$$

Luego:

$$n = \frac{6{,}6564}{0{,}00182833} \approx 3640{,}7$$

Por lo que para $n \geqslant 3641$ podemos asegurar que la probabilidad es como mínimo 0,99.

Ejercicio 2.1.6. Sea $X \rightsquigarrow \mathcal{B}(1,p)$ y (X_1, X_2, X_3) una muestra aleatoria simple de X. Calcular la función masa de probabilidad de los estadísticos $\overline{X}$, S^2, mín X_i y máx X_i.

Para resolver este ejercicio, como X sigue una distribución discreta, buscamos aplicar el teorema de cambio de variable de discreta a discreta. Para ello, la forma más cómoda será analizar cada uno de los valores que puede tomar la muestra aleatoria simple (X_1, X_2, X_3) y determinar en consecuencia cada uno de los valores que toman $\overline{X}$, S^2, mín X_i y máx X_i. Acompañaremos la tabla junto con la probabilidad de que la muestra tome dicho valor, es decir, en la fila correpondiente a (x_1, x_2, x_3) incluiremos $P[X_1 = x_1, X_2 = x_2, X_3 = x_3]$:

P	(X_1, X_2, X_3)	$\overline{X}$	S^2	mín X_i	máx X_i
$(1-p)^3$	$(0,0,0)$	0	0	0	0
$p(1-p)^2$	$(0,0,1)$	$1/3$	$1/3$	0	1
$p(1-p)^2$	$(0,1,0)$	$1/3$	$1/3$	0	1
$p^2(1-p)$	$(0,1,1)$	$2/3$	$1/3$	0	1
$p(1-p)^2$	$(1,0,0)$	$1/3$	$1/3$	0	1
$p^2(1-p)$	$(1,0,1)$	$2/3$	$1/3$	0	1
$p^2(1-p)$	$(1,1,0)$	$2/3$	$1/3$	0	1
p^3	$(1,1,1)$	1	0	1	1

Podemos ya calcular la función masa de probabilidad de cada uno de los estadísticos, simplemente sumando las probabilidades de la tabla que corresponden a cada valor del espacio muestral de cada estadístico:

- Para $\overline{X}$:

$$P[\overline{X} = 0] = P[X_1 = 0, X_2 = 0, X_3 = 0] = (1-p)^3$$
$$P[\overline{X} = 1/3] = \sum_{i=1}^{3} p(1-p)^2 = 3p(1-p)^2$$
$$P[\overline{X} = 2/3] = \sum_{i=1}^{3} p^2(1-p) = 3p^2(1-p)$$
$$P[\overline{X} = 1] = P[X_1 = 1, X_2 = 1, X_3 = 1] = p^3$$

- Para S^2:

$$P[S^2 = 0] = P[X_1 = 0, X_2 = 0, X_3 = 0] + P[X_1 = 1, X_2 = 1, X_3 = 1] = p^3 + (1-p)^3$$
$$P[S^2 = 1/3] = \sum_{i=1}^{3} p(1-p)^2 + \sum_{i=1}^{3} p^2(1-p) = 3p(1-p)(p+1-p) = 3p(1-p)$$

- Para $\min X_i$:

$$P[\min X_i = 1] = P[X_1 = 1, X_2 = 1, X_3 = 1] = p^3$$
$$P[\min X_i = 0] = 1 - P[\min X_i = 1] = 1 - p^3$$

- Para $\max X_i$:

$$P[\max X_i = 0] = P[X_1 = 0, X_2 = 0, X_3 = 0] = (1-p)^3$$
$$P[\max X_i = 1] = 1 - P[\max X_i = 0] = 1 - (1-p)^3$$

Ejercicio 2.1.7. Obtener la función masa de probabilidad o función de densidad de $\overline{X}$ en el muestreo de una variable de Bernoulli, de una Poisson y de una exponencial.

Calculamos la masa de probabilidad o función de densidad en cada caso, suponiendo que tenemos $(X_1, \ldots, X_n)$ una muestra aleatoria simple con variables aleatorias idénticamente distribuidas a X, que sigue una distribución distinta en cada caso y estaremos interesados en calcular la masa de:

$$\overline{X} = \frac{1}{n} \sum_{i=1}^{n} X_i$$

Bernoulli. Veamos dos opciones:

Opción 1 Supuesto que $X \rightsquigarrow \mathcal{B}(1,p)$ para cierto $p \in]0,1[$, si tomamos:

$$Y = \sum_{i=1}^{n} X_i$$

Por la propiedad reproductiva de la Bernoulli, tenemos que $Y \rightsquigarrow \mathcal{B}(n,p)$. En dicho caso:

$$P[Y=k] = \binom{n}{k} p^k (1-p)^{n-k} \qquad \forall k \in \{0,\dots,n\}$$

Por tanto, tendremos que:

$$P[\overline{X}=x] = P\left[\frac{1}{n}\sum_{i=1}^{n} X_i = x\right] = P[Y=nx]$$

Como Y es una variable aleatoria discreta, nx debe ser un número entero entre 0 y n, por lo que x debe ser de la forma k/n para cierto $k \in \{0,\dots,n\}$. Por lo que:

$$P\left[\overline{X}=\frac{k}{n}\right] = P[Y=k] = \binom{n}{k} p^k (1-p)^{n-k} \qquad \forall k \in \{0,\dots,n\}$$

Opción 2 Calculemos la función generatriz de momentos de $\overline{X}$, que por la igualdad $(*)$ vista en teoría, tenemos que:

$$M_{\overline{X}}(t) \overset{(*)}{=} (M_X(t/n))^n = \left(pe^{t/n} + (1-p)\right)^n = \left(pe^{t/n} + (1-p)\right)^n$$

Observamos que obtenemos una función generatriz de momentos para $\overline{X}$ igual que para una variable aleatoria de distribución $\mathcal{B}(n,p)$, en la que los valores posibles de $\overline{X}$ son k/n para cierto $k \in \{0,\dots,n\}$.

Poisson. Supuesto que $X \rightsquigarrow \mathcal{P}(\lambda)$ para cierto $\lambda \in \mathbb{R}^+$, si tomamos:

$$Y = \sum_{i=1}^{n} X_i$$

Por la propiedad reproductiva de la Poisson, tendremos que:

$$Y \rightsquigarrow \mathcal{P}\left(\sum_{i=1}^{n} \lambda\right) \equiv \mathcal{P}(n\lambda)$$

En dicho caso:

$$P[Y=x] = e^{-n\lambda}\frac{(n\lambda)^x}{x!} \qquad \forall x \in \mathbb{N}$$

Por lo que, empleando la misma idea que en el caso de la Bernoulli, tendremos que:

$$P[\overline{X}=x/n] = P[Y=x] = e^{-n\lambda}\frac{(n\lambda)^x}{x!} \qquad \forall x \in \mathbb{N}$$

Exponencial. Supuesto ahora que $X \rightsquigarrow \exp(\lambda)$ para cierto $\lambda \in \mathbb{R}^+$, tendremos entonces que:

$$M_X(t) = \frac{\lambda}{\lambda - t} \qquad t < \lambda$$

Si aplicamos la igualdad $(*)$ vista en teoría:

$$M_{\overline{X}}(t) \overset{(*)}{=} (M_X(t/n))^n = \left(\frac{\lambda}{\lambda - t/n}\right)^n = \left(\frac{n\lambda}{n\lambda - t}\right)^n$$

Observamos que obtenemos una función generatriz de momentos para $\overline{X}$ igual que para una variable aleatoria de distribución $\Gamma(n, n\lambda)$. Como la función generatriz de momentos de una variable aleatoria caracteriza su distribución, concluimos que $\overline{X} \rightsquigarrow \Gamma(n, n\lambda)$. Por tanto, la función de densidad de $\overline{X}$ es:

$$f_{\overline{X}}(x) = \frac{(n\lambda)^n}{\Gamma(n)} x^{n-1} e^{-n\lambda x} \qquad \forall x > 0$$

Ejercicio 2.1.8. Calcular las funciones de densidad de los estadísticos $\max X_i$ y $\min X_i$ en el muestreo de una variable X con funcion de densidad:

$$f_\theta(x) = e^{\theta - x}, \qquad x > \theta.$$

Calculamos primero la función de distribución, para calcular con mayor comodidad las funciones de distribución de $X_{(n)}$ y $X_{(1)}$:

$$F_\theta(x) = \int_\theta^x f_\theta(t)\, dt = \int_\theta^x e^{\theta - t}\, dt = \left[-e^{\theta - t}\right]_\theta^x = 1 - e^{\theta - x} \qquad \forall x > \theta$$

Supuesto ahora que disponemos de una m.a.s. $(X_1, \ldots, X_n)$ idénticamente distribuidas a X cuya función de densidad es la anteriormente dicha, podemos aplicar las fórmulas obtenidas en teoría para calcular las funciones de distribución del mínimo y del máximo. Para el máximo:

$$F_{X_{(n)}}(x) = (F_X(x))^n = (1 - e^{\theta - x})^n \Longrightarrow f_{X_{(n)}}(x) = n(1 - e^{\theta - x})^{n-1} e^{\theta - x} \qquad \forall x > \theta$$

Para el mínimo:

$$F_{X_{(1)}}(x) = 1 - (1 - F_X(n))^n = 1 - (1 - 1 + e^{\theta - x})^n = 1 - e^{n(\theta - x)} \qquad \forall x > \theta$$

de donde:

$$f_{X_{(1)}}(x) = n e^{n(\theta - x)} \qquad \forall x > \theta$$

Ejercicio 2.1.9. El número de pacientes que visitan diariamente una determinada consulta médica es una variable aleatoria con varianza de 16 personas. Se supone que el número de visitas de cada día es independiente de cualquier otro. Si se observa el número de visitas diarias durante 64 días, calcular aproximadamente la probabilidad de que la media muestral no difiera en más de una persona del valor medio verdadero de visitas diarias.

Sea X una variable aleatoria que indica el número de pacientes que visitan diariamente dicha consulta médica. Por cómo nos definen X sabemos que $X \rightsquigarrow \mathcal{P}(\lambda)$. Como además nos dicen que la varianza de dicha variable aleatoria es 16, tenemos que $Var(X) = \lambda = 16$. Si tenemos ahora una muestra aleatoria simple $(X_1, \ldots, X_n)$ con $n = 64$, nos preguntan por:

$$P[|\overline{X} - E[X]| \leqslant 1]$$

Notemos que se incluye el valor 1 en la desigualdad.

Donde $E[X] = \lambda = 16$, ya que $X \rightsquigarrow \mathcal{P}(16)$. Calculamos:

$$P[|\overline{X} - E[X]| \leqslant 1] = P[-1 \leqslant \overline{X} - 16 \leqslant 1] = P[15 \leqslant \overline{X} \leqslant 17]$$

Aplicamos ahora lo visto en el Ejercicio 2.1.7, ya que si $X \rightsquigarrow \mathcal{P}(\lambda)$, entonces tendremos que $n\overline{X} \rightsquigarrow \mathcal{P}(n\lambda)$, gracias a la propiedad reproductiva de la Poisson:

$$\begin{aligned} P[|\overline{X} - E[X]| \leqslant 1] = P[15 \leqslant \overline{X} \leqslant 17] &= P[64 \cdot 15 \leqslant 64\overline{X} \leqslant 64 \cdot 17] \\ &= P[960 \leqslant 64\overline{X} \leqslant 1088] \end{aligned}$$

Donde $64\overline{X} \rightsquigarrow \mathcal{P}(64 \cdot 16) \equiv \mathcal{P}(1024)$. Para calcular dicha probabilidad, aproximaremos la Poisson a una distribución normal empleando el Teorema Central del Límite, ya que $n = 64$ es un tamaño muestral suficientemente grande. Por lo que:

$$\mathcal{P}(1024) \approx \mathcal{N}(1024, 1024)$$

Por lo que:

$$\begin{aligned} P[|\overline{X} - E[X]| \leqslant 1] = P[960 \leqslant 64\overline{X} \leqslant 1088] &\approx P\left[\frac{960 - 1024}{\sqrt{1024}} \leqslant Z \leqslant \frac{1088 - 1024}{\sqrt{1024}}\right] \\ &= P[-2 \leqslant Z \leqslant 2] = 2P[Z \leqslant 2] - 1 \\ &= 2 \cdot 0{,}97725 - 1 = 0{,}9545 \end{aligned}$$

Ejercicio 2.1.10. Una máquina de refrescos está arreglada para que la cantidad de bebida que sirve sea una variable aleatoria con media 200 ml. y desviación típica 15 ml. Calcular de forma aproximada la probabilidad de que la cantidad media servida en una muestra aleatoria de tamaño 36 sea al menos 204 ml.

Sea $(X_1, \ldots, X_n)$ una muestra aleatoria simple idénticamente distribuida a la variable aleatoria X de tamaño $n = 36$. De la información que nos dan, sabemos que $E[X] = 200$ y $Var(X) = 15^2$, pero no conocemos la distribución de X.

Una primera aproximación sería emplear el Teorema Central del Límite para aproximar la distribución X a una distribución normal, y de ahí intentar obtener la distribución de $\overline{X}$. No obstante, un resultado más directo es directamente calcular $E[\overline{X}]$ y $Var(\overline{X})$.

$$E[\overline{X}] = E\left[\frac{1}{n}\sum_{i=1}^{n} X_i\right] = \frac{1}{n}\sum_{i=1}^{n} E[X_i] = \frac{1}{n}\sum_{i=1}^{n} E[X] = E[X] = 200$$

$$Var[\overline{X}] = Var\left[\frac{1}{n}\sum_{i=1}^{n} X_i\right] = \frac{1}{n^2}\sum_{i=1}^{n} Var[X_i] = \frac{1}{n^2}\sum_{i=1}^{n} Var[X] = \frac{Var[X]}{n} = \frac{15^2}{36}$$

Por tanto, aplicando ahora el Teorema Central del Límite, obtenemos que $\overline{X} \rightsquigarrow \mathcal{N}\left(200, \frac{15^2}{36}\right)$. Calculamos la probabilidad:

$$\begin{aligned} P[\overline{X} \geqslant 204] \overset{\text{tipificamos}}{\approx} P\left[Z \geqslant \frac{\sqrt{36}(204 - 200)}{15}\right] &= P[Z \geqslant 1{,}6] = 1 - P[Z < 1{,}6] \\ &= 1 - 0{,}9452 = 0{,}0548 \end{aligned}$$

Ejercicios Adicionales

Ejercicio 2.1.11 (Reto)**.** Sea $(X_1, \ldots, X_n)$ una muestra aleatoria simple de una variable aleatoria X con función de densidad:

$$f_\theta(x) = \theta x^{\theta-1}, \qquad 0 < x < 1, \quad \theta > 0$$

Obtener la función de densidad de $X_{(n)}$ y de $X_{(1)}$.

Obtenemos primero la función de distribución de X:

$$F_\theta(x) = \int_0^x f_\theta(t)\ dt = \int_0^x \theta t^{\theta-1}\ dt = \left[t^\theta\right]_0^x = x^\theta \qquad \forall x \in]0,1[$$

Pasamos ahora a calcular la función de distribución de $X_{(n)}$:

$$F_{X_{(n)}}(x) = P[X_{(n)} \leqslant x] = P[X_1 \leqslant x, \ldots, X_n \leqslant x] \overset{\text{idd}}{=} \prod_{i=1}^n P[X \leqslant x] = (F_\theta(x))^n = x^{n\theta} \qquad \forall x \in]0,1[$$

Derivando, obtenemos la función de densidad de $X_{(n)}$:

$$f_{X_{(n)}}(x) = n\theta x^{n\theta-1} \qquad \forall x \in]0,1[$$

Pasamos ahora a calcular la función de distribución de $X_{(1)}$:

$$F_{X_{(1)}}(x) = P[X_{(1)} \leqslant x] = 1 - P[X_{(1)} > x] = 1 - P[X_1 > x, \ldots, X_n > x] \overset{\text{idd}}{=}$$
$$\overset{\text{idd}}{=} 1 - \prod_{i=1}^n P[X > x] = 1 - (1 - F_\theta(x))^n = 1 - (1 - x^\theta)^n \qquad \forall x \in]0,1[$$

Derivando, obtenemos la función de densidad de $X_{(1)}$:

$$f_{X_{(1)}}(x) = n\theta x^{\theta-1}(1 - x^\theta)^{n-1} \qquad \forall x \in]0,1[$$

2.2. Distribuciones en el muestreo de poblaciones normales

Ejercicio 2.2.1. Se toma una muestra aleatoria simple de tamaño 5 de una variable aleatoria con distribución $\mathcal{N}(2{,}5,\ 36)$. Calcular:

a) Probabilidad de que la cuasivarianza muestral esté comprendida entre 1,863 y 2,674.

Tenemos una m.a.s. $(X_1, X_2, X_3, X_4, X_5)$, todas ellas idénticamente distribuidas a $X \rightsquigarrow \mathcal{N}(2{,}5,\ 36)$. Tomamos la cuasivarianza de dichos datos:

$$S^2 = \frac{1}{n-1}\sum_{i=1}^{n}\left(X_i - \overline{X}\right)^2$$

Y queremos calcular la probabilidad:

$$P\left[1{,}863 < S^2 < 2{,}674\right]$$

Puesto que no es fácil obtener la distribución de S^2, vamos a usar la distribución χ^2 para calcular dicha probabilidad. Para ello, en teoría hemos visto que como estamos muestreando de una población normal, se cumple que:

$$\frac{(n-1)S^2}{\sigma^2} = \frac{4S^2}{36} \rightsquigarrow \chi^2(4) \equiv \chi^2(n-1)$$

Por tanto:

$$\begin{aligned} P[1{,}863 < S^2 < 2{,}674] &= P\left[\frac{4\cdot 1{,}863}{36} < \frac{4S^2}{36} < \frac{4\cdot 2{,}674}{36}\right] \\ &= P\left[0{,}207 < \frac{4S^2}{36} < 0{,}2971\right] \\ &= P\left[\frac{4S^2}{36} > 0{,}207\right] - P\left[\frac{4S^2}{36} > 0{,}2971\right] \end{aligned}$$

Si consultamos la tabla de la $\chi^2(4)$:

$$P\left[\frac{4S^2}{36} > 0{,}207\right] \approx 0{,}995, \qquad P\left[\frac{4S^2}{36} > 0{,}2971\right] \approx 0{,}99$$

Por lo que:

$$\begin{aligned} P[1{,}863 < S^2 < 2{,}674] &= P\left[\frac{4S^2}{36} > 0{,}207\right] - P\left[\frac{4S^2}{36} > 0{,}2971\right] \approx 0{,}995 - 0{,}99 \\ &= 0{,}005 \end{aligned}$$

b) Probabilidad de que la media muestral esté comprendida entre 1,3 y 3,5, supuesto que la cuasivarianza muestral está entre 30 y 40.

En la situación del apartado anterior, ahora tenemos también en consideración la media muestral:

$$\overline{X} = \frac{1}{n}\sum_{i=1}^{n} X_i$$

Bajo estas condiciones, el Lema de Fisher nos dice que S^2 y $\overline{X}$ son independientes, por lo que la probabilidad de que la media muestral esté comprendida entre 1,3 y 3,5 suponiendo que la cuasivarianza muestral está comprendida entre 30 y 40 es igual a la probabilidad de que la media muestral esté comprendida entre 1,3 y 3,5:

$$P[1{,}3 < \overline{X} < 3{,}5 \mid 30 < S^2 < 40] = P[1{,}3 < \overline{X} < 3{,}5]$$

Sabemos que $\overline{X} \rightsquigarrow \mathcal{N}\left(\mu, \frac{\sigma^2}{n}\right)$, nos disponemos a calcular dicha probabilidad:

$$\begin{aligned} P[1{,}3 < \overline{X} < 3{,}5] &\overset{\text{tipificamos}}{=} P\left[\frac{\sqrt{5}(1{,}3-2{,}5)}{\sqrt{36}} < Z < \frac{\sqrt{5}(3{,}5-2{,}5)}{\sqrt{36}}\right] \\ &= P[-0{,}447214 < Z < 0{,}372678] \\ &= P[Z < 0{,}372678] - P[Z > 0{,}447214] \\ &= P[Z < 0{,}372678] - 1 + P[Z < 0{,}447214] \\ &\approx 0{,}64431 - 1 + 0{,}67003 = 0{,}31434 \end{aligned}$$

Ejercicio 2.2.2. La longitud craneal en una determinada población humana es una variable aleatoria que sigue una distribución normal con media 185,6 mm y desviación típica 12,78 mm. ¿Cuál es la probabilidad de que una muestra aleatoria simple de tamaño 20 de esa población tenga media mayor que 190 mm?

Tenemos una población que sigue una variable aleatoria $X \rightsquigarrow \mathcal{N}(\mu, \sigma^2)$ con parámetros $\mu = 185{,}6$ y $\sigma = 12{,}78$. Tomamos una m.a.s. $(X_1, \ldots, X_n)$ con $n = 20$ y tomamos la media muestral:

$$\overline{X} = \frac{1}{n}\sum_{i=1}^{n}(X_i - \mu)^2$$

Queremos calcular:

$$P\left[\overline{X} > 190\right]$$

Para ello, sabemos por lo visto en teoría que $\overline{X} \rightsquigarrow \mathcal{N}\left(\mu, \frac{\sigma^2}{n}\right)$, por lo que:

$$\begin{aligned} P\left[\overline{X} > 190\right] &\overset{\text{tipificamos}}{=} P\left[Z > \frac{\sqrt{20}(190-185{,}6)}{12{,}78}\right] = P[Z > 1{,}5397] \\ &= 1 - P[Z < 1{,}5397] \approx 1 - 0{,}93822 = 0{,}06178 \end{aligned}$$

Ejercicio 2.2.3. ¿De qué tamaño mínimo habría que seleccionar una muestra de una variable con distribución normal $\mathcal{N}(\mu, 4)$ para poder afirmar, con probabilidad mayor que 0,9, que la media muestral diferirá de la poblacional menos de 0,1?

Supuesto que tenemos una m.a.s. $(X_1, \ldots, X_n)$ de tamaño $n \in \mathbb{N}$ de variables aleatorias idénticamente distribuidas a $X \rightsquigarrow \mathcal{N}(\mu, 4)$, queremos buscar el menor n de forma que:

$$0{,}9 < P\left[|\overline{X} - \mu| < 0{,}1\right]$$

Para ello, usaremos que hemos visto en teoría que $\overline{X} \rightsquigarrow \mathcal{N}\left(\mu, \frac{\sigma^2}{n}\right)$:

$$0{,}9 < P[|\overline{X} - \mu| < 0{,}1] = P[-0{,}1 < \overline{X} - \mu < 0{,}1] = P\left[\frac{-\sqrt{n}0{,}1}{2} < Z < \frac{\sqrt{n}0{,}1}{2}\right]$$
$$= P\left[-\sqrt{n}0{,}05 < Z < \sqrt{n}0{,}05\right] = 2P\left[Z < \sqrt{n}0{,}05\right] - 1$$

De donde:

$$0{,}95 = \frac{0{,}9+1}{2} < P[Z < \sqrt{n}0{,}05]$$

De donde mirando la tabla de la normal $\mathcal{N}(0,1)$:

$$\sqrt{n}0{,}05 \geqslant 1{,}65 \Longrightarrow n \geqslant \left(\frac{1{,}65}{0{,}05}\right)^2 = 1089$$

Por lo que habría que seleccionar como mínimo una muestra de tamaño 1089 para poder afirmar con probabilidad mayor que 0,9 que la media muestral difiere de la poblacional menos de 0,1.

Ejercicio 2.2.4. Sea $(X_1, \ldots, X_n)$ una muestra aleatoria simple de una variable con distribución normal. Calcular la probabilidad de que la cuasivarianza muestral sea menor que un 50 % de la varianza poblacional para $n = 16$ y para $n = 1000$.

Dicha muestra aleatoria simple es de variables idénticamente distribuidas a $X \rightsquigarrow \mathcal{N}(\mu, \sigma^2)$. Bajo estas condiciones, sabemos por lo visto en teoría que:

$$\frac{(n-1)S^2}{\sigma^2} \rightsquigarrow \chi^2(n-1)$$

Y queremos calcular:

$$P[S^2 < 0{,}5\sigma^2] = P\left[\frac{(n-1)S^2}{\sigma^2} < \frac{(n-1)0{,}5\cancel{\sigma^2}}{\cancel{\sigma^2}}\right] = 1 - P\left[\frac{(n-1)S^2}{\sigma^2} > (n-1)0{,}5\right]$$

- Para $n = 16$, mirando en la tabla de $\chi^2(15)$ tenemos que:

$$P[S^2 < 0{,}5\sigma^2] = 1 - P\left[\frac{(n-1)S^2}{\sigma^2} > 7{,}5\right] \approx 1 - 0{,}95 = 0{,}05$$

- Para $n = 1000$, no disponemos de tabla para $\chi^2(999)$, por lo que aproximaremos $\chi^2(999)$ por $\mathcal{N}(999, 2 \cdot 999) \equiv \mathcal{N}(999, 1998)$. De esta forma, si tomamos:

$$\frac{(n-1)S^2}{\sigma^2} \rightsquigarrow \chi^2(999) \approx \mathcal{N}(999, 1998)$$

Tenemos entonces que:

$$P[S^2 < 0{,}5\sigma^2] = P\left[\frac{(n-1)S^2}{\sigma^2} < \frac{(n-1)0{,}5\cancel{\sigma^2}}{\cancel{\sigma^2}}\right] = P\left[\frac{(n-1)S^2}{\sigma^2} < 499{,}5\right] \approx$$
$$\overset{\text{tipificamos}}{\approx} P\left[Z < \frac{499{,}5 - 999}{\sqrt{1998}}\right] = P[Z < -11{,}17] =$$
$$= 1 - P[Z < 11{,}17] \approx 1 - 1 = 0$$

Ejercicio 2.2.5. Sean S_1^2 y S_2^2 las cuasivarianzas muestrales de dos muestras independientes de tamaños $n_1 = 5$ y $n_2 = 4$ de dos poblaciones normales con la misma varianza. Calcular la probabilidad de que S_1^2/S_2^2 sea menor que 5,34 o mayor que 9,12.

Bajo estas hipótesis, sabemos por lo visto en teoría que (como $\sigma_1 = \sigma_2$):

$$\frac{S_1^2}{S_2^2} \rightsquigarrow F(n_1 - 1, n_2 - 1) \equiv F(4, 3)$$

Por tanto, notando $Y = \frac{S_1^2}{S_2^2}$ por comodidad, calculamos (son sucesos disjuntos):

$$P[Y < 5{,}34 \text{ o } Y > 9{,}12] = P[Y < 5{,}34] + P[Y > 9{,}12]$$

Observamos la tabla de $F(4, 3)$:

$$\begin{aligned} &P[Y < 5{,}34] \approx 0{,}9 \\ &P[Y > 9{,}12] \approx 1 - P[Y < 9{,}12] = 1 - 0{,}95 = 0{,}05 \end{aligned}$$

En definitiva:

$$P[Y < 5{,}34 \text{ o } Y > 9{,}12] = P[Y < 5{,}34] + P[Y > 9{,}12] \approx 0{,}95$$

Ejercicio 2.2.6. Se consideran dos poblaciones de bombillas cuyas longitudes de vida siguen una ley normal con la misma media y desviaciones típicas 425 y 375 horas, respectivamente. Con objeto de realizar un estudio comparativo de ambas poblaciones, se considera una muestra aleatoria simple de 10 bombillas en la primera población y una de tamaño 6 en la segunda. ¿Cuál es la probabilidad de que la media muestral del primer grupo menos la del segundo sea menor que la observada en dos realizaciones muestrales que dieron 1325 horas y 1215 horas, respectivamente?

Como describe el enunciado, tenemos una m.a.s. $(X_1, \ldots, X_n)$ de tamaño $n = 10$ de variables aleatorias idénticamente distribuidas a $X \rightsquigarrow \mathcal{N}\left(\mu, 425^2\right)$; y otra m.a.s. $(Y_1, \ldots, Y_m)$ de tamaño $m = 6$ de variables aleatorias idénticamente distribuidas a $Y \rightsquigarrow \mathcal{N}\left(\mu, 375^2\right)$. Nos piden calcular:

$$P[\overline{X} - \overline{Y} < 1325 - 1215]$$

Bajo estas condiciones, sabemos por lo visto en teoría que:

$$\frac{\overline{X} - \overline{Y}}{\sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}}} = \frac{\overline{X} - \overline{Y} - (\mu - \mu)}{\sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}}} \rightsquigarrow \mathcal{N}(0, 1)$$

De esta forma, si notamos a esta última variable como Z (pues es una normal estándar), tenemos que:

$$\begin{aligned} P[\overline{X} - \overline{Y} < 1325 - 1215] &= P\left[Z < \frac{1325 - 1215}{\sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}}}\right] = P\left[Z < \frac{1325 - 1215}{\sqrt{\frac{425^2}{10} + \frac{375^2}{6}}}\right] \\ &= P[Z < 0{,}5399] \approx 0{,}7054 \end{aligned}$$

Ejercicio 2.2.7. Sean $X_1, \ldots, X_n, X_{n+1}$ variables aleatorias independientes e idénticamente distribuidas según una $\mathcal{N}(\mu, \sigma^2)$, y sean $\overline{X}$ y S^2 la media y la cuasivarianza muestral de $(X_1, \ldots, X_n)$. Calcular la distribución de

$$\frac{X_{n+1} - \overline{X}}{S}\sqrt{\frac{n}{n+1}}$$

Bajo dichas hipótesis, tenemos:

$$\left.\begin{array}{l} X_{n+1} \rightsquigarrow \mathcal{N}(\mu, \sigma^2) \\ \overline{X} \rightsquigarrow \mathcal{N}\left(\mu, \frac{\sigma^2}{n}\right) \end{array}\right\} \Longrightarrow X_{n+1} - \overline{X} \rightsquigarrow \mathcal{N}\left(\mu - \mu, \sigma^2 + \frac{\sigma^2}{n}\right) \equiv \mathcal{N}\left(0, \sigma^2\left(1 + \frac{1}{n}\right)\right)$$

de donde, si tipificamos la variable:

$$\frac{X_{n+1} - \overline{X}}{\sqrt{\sigma^2\left(1 + \frac{1}{n}\right)}} = \frac{X_{n+1} - \overline{X}}{\sigma\sqrt{\frac{n+1}{n}}} = \frac{X_{n+1} - \overline{X}}{\sigma}\sqrt{\frac{n}{n+1}} \rightsquigarrow \mathcal{N}(0,1)$$

Notemos que esta distribución es similar a la que buscamos, salvo que en el denominador tenemos σ en lugar de S. Podemos emplear el siguiente resultado, visto en teoría, que relaciona la cuasivarianza muestral con la varianza poblacional:

$$\frac{(n-1)S^2}{\sigma^2} \rightsquigarrow \chi^2(n-1)$$

En vistas de aplicar la cosntrucción de la distribución t de Student, necesitamos que las variables aleatorias con las que trabajamos sean independientes. La primera es función de $\overline{X}$ y X_{n+1}, mientras que la segunda es función de S^2. Por tanto, nos basta con ver que $(\overline{X}, X_{n+1})$ es independiente de S^2. Esto se cumple, ya que $\overline{X}$ y S^2 son independientes por el Lema de Fisher, y X_{n+1} es independiente de $(X_1, \ldots, X_n)$, por lo que $(\overline{X}, X_{n+1})$ es independiente de S^2. Podemos por tanto aplicar la construccion de la distribución t de Student:

$$\left.\begin{array}{l} U \rightsquigarrow \mathcal{N}(0,1) \\ V \rightsquigarrow \chi^2(n) \\ U \text{ y } V \text{ independientes} \end{array}\right\} \Longrightarrow \frac{U}{\sqrt{V/n}} \rightsquigarrow t(n)$$

Si lo aplicamos a nuestras variables:

$$\frac{\frac{X_{n+1} - \overline{X}}{\sigma}\sqrt{\frac{n}{n+1}}}{\sqrt{\frac{(n-1)S^2}{\sigma^2(n-1)}}} = \frac{\frac{X_{n+1} - \overline{X}}{\sigma}\sqrt{\frac{n}{n+1}}}{\frac{S}{\sigma}} = \frac{X_{n+1} - \overline{X}}{S}\sqrt{\frac{n}{n+1}} \rightsquigarrow t(n-1)$$

Ejercicio 2.2.8. Sean $(X_1, \ldots, X_n)$, $(Y_1, \ldots, Y_m)$ muestras aleatorias simples independientes de poblaciones $\mathcal{N}(\mu_1, \sigma^2)$ y $\mathcal{N}(\mu_2, \sigma^2)$, respectivamente. Sean $\alpha, \beta \in \mathbb{R}$ y $\overline{X}, \overline{Y}, S_1^2, S_2^2$ las medias y cuasivarianzas de las dos muestras. Calcular la distribución de

$$\frac{\alpha\left(\overline{X} - \mu_1\right) + \beta\left(\overline{Y} - \mu_2\right)}{\sqrt{\frac{(n-1)S_1^2 + (m-1)S_2^2}{n+m-2}}\sqrt{\frac{\alpha^2}{n} + \frac{\beta^2}{m}}}$$

Sabemos que:

$$\left.\begin{array}{l}\overline{X} \rightsquigarrow \mathcal{N}\left(\mu_1, \frac{\sigma^2}{n}\right) \\ \overline{Y} \rightsquigarrow \mathcal{N}\left(\mu_2, \frac{\sigma^2}{m}\right)\end{array}\right\} \Longrightarrow \left.\begin{array}{l}\overline{X} - \mu_1 \rightsquigarrow \mathcal{N}\left(0, \frac{\sigma^2}{n}\right) \\ \overline{Y} - \mu_2 \rightsquigarrow \mathcal{N}\left(0, \frac{\sigma^2}{m}\right)\end{array}\right\} \Longrightarrow \left.\begin{array}{l}\alpha(\overline{X} - \mu_1) \rightsquigarrow \mathcal{N}\left(0, \frac{\alpha^2\sigma^2}{n}\right) \\ \beta(\overline{Y} - \mu_2) \rightsquigarrow \mathcal{N}\left(0, \frac{\beta^2\sigma^2}{m}\right)\end{array}\right\}$$

Como la combinación lineal de variables aleatorias normales es normal, tenemos que:

$$\alpha(\overline{X} - \mu_1) + \beta(\overline{Y} - \mu_2) \rightsquigarrow \mathcal{N}\left(0, \frac{\alpha^2\sigma^2}{n} + \frac{\beta^2\sigma^2}{m}\right) \equiv \mathcal{N}\left(0, \sigma^2\left(\frac{\alpha^2}{n} + \frac{\beta^2}{m}\right)\right)$$

Si tipificamos la variable:

$$\frac{\alpha(\overline{X} - \mu_1) + \beta(\overline{Y} - \mu_2)}{\sigma\sqrt{\frac{\alpha^2}{n} + \frac{\beta^2}{m}}} \rightsquigarrow \mathcal{N}(0,1)$$

Por otra parte, tenemos que:

$$\frac{(n-1)S_1^2}{\sigma^2} \rightsquigarrow \chi^2(n-1), \qquad \frac{(m-1)S_2^2}{\sigma^2} \rightsquigarrow \chi^2(m-1)$$

Como ambas son independientes por ser S_1^2 y S_2^2 independientes (ya que las muestras aleatorias simples eran independientes), podemos aplicar la propiedad reproductiva de χ^2, obteniendo que:

$$\frac{(n-1)S_1^2}{\sigma^2} + \frac{(m-1)S_2^2}{\sigma^2} = \frac{(n-1)S_1^2 + (m-1)S_2^2}{\sigma^2} \rightsquigarrow \chi^2(n+m-2)$$

Finalmente, la extensión del Lema de Fisher nos dice que $(\overline{X}, \overline{Y})$ es independiente de (S_1^2, S_2^2), por lo que las dos variables aleatorias con las que trabajamos son independientes, lo que nos permite aplicar la construcción de la distribución t de Student:

$$\frac{\frac{\alpha(\overline{X} - \mu_1) + \beta(\overline{Y} - \mu_2)}{\cancel{\sigma}\sqrt{\frac{\alpha^2}{n} + \frac{\beta^2}{m}}}}{\sqrt{\frac{\frac{(n-1)S_1^2 + (m-1)S_2^2}{\cancel{\sigma^2}}}{n+m-2}}} = \frac{\alpha\left(\overline{X} - \mu_1\right) + \beta\left(\overline{Y} - \mu_2\right)}{\sqrt{\frac{(n-1)S_1^2 + (m-1)S_2^2}{n+m-2}}\sqrt{\frac{\alpha^2}{n} + \frac{\beta^2}{m}}} \rightsquigarrow t(n+m-2)$$

Ejercicios Adicionales

Ejercicio 2.2.9 (Reto)**.** Sea $(X_1, \ldots, X_{10})$ una muestra aleatoria simple de una variable con distribución normal $\mathcal{N}(5, \sigma^2)$ e $(Y_1, \ldots, Y_{10})$ una muestra aleatoria simple de una variable con distribución normal $\mathcal{N}(\mu_Y, \sigma^2)$, siendo ambas muestras independientes. Calcular:

$$P\left[\frac{\sum_{i=1}^{10}(X_i - 5)^2}{S_Y^2} > 31{,}4\right]$$

Buscamos obtener la distribución de la variable aleatoria:

$$\frac{\sum_{i=1}^{10}(X_i-5)^2}{S_Y^2}$$

Fijado $i \in \{1,\dots,10\}$, tenemos que $X_i \rightsquigarrow \mathcal{N}(5,\sigma^2)$, luego su variable tipificada $Z_i \rightsquigarrow \mathcal{N}(0,1)$, y por tanto, por la construcción de la distribución χ^2 a partir de variables normales, tenemos que:

$$\frac{1}{\sigma^2}\sum_{i=1}^{10}(X_i-5)^2 = \sum_{i=1}^{10} {Z_i}^2 \rightsquigarrow \chi^2(n)$$

Por otra parte, sabemos que:

$$\frac{(n-1)S_Y^2}{\sigma^2} \rightsquigarrow \chi^2(n-1)$$

Ahora, como las muestras aleatorias simples son independientes, S_Y^2 es independiente de $(X_1,\dots,X_{10})$, y por tanto, $\sum_{i=1}^{10}(X_i-5)^2$ es independiente de S_Y^2. Por tanto, podemos aplicar la construcción de la distribución F de Snedecor:

$$U := \frac{\frac{1}{\cancel{\sigma^2}}\sum_{i=1}^{10}(X_i-5)^2}{n} \cdot \frac{\cancel{n-1}}{\frac{(\cancel{n-1})S_Y^2}{\cancel{\sigma^2}}} = \frac{\sum_{i=1}^{10}(X_i-5)^2}{S_Y^2}\cdot\frac{1}{n} \rightsquigarrow F(n,n-1) \equiv F(10,9)$$

Por tanto, la probabilidad que nos piden es:

$$P\left[\frac{\sum_{i=1}^{10}(X_i-5)^2}{S_Y^2} > 31{,}4\right] = P\left[\frac{\sum_{i=1}^{10}(X_i-5)^2}{S_Y^2}\cdot\frac{1}{n} > \frac{31{,}4}{n}\right] = P\left[U > 3{,}14\right] =$$
$$= 1 - P[U < 3{,}14] = 1 - 0{,}95 = 0{,}05$$

Ejercicio 2.2.10. Sean $X_1, X_2, \dots, X_{12}$ una muestra aleatoria simple de una variable aleatoria con distribución $\mathcal{N}(\mu,\sigma^2)$.

Se divide la muestra en dos submuestras disjuntas de tamaños $n_1 = 4$ y $n_2 = 8$:

- Submuestra 1: $\{X_1,\dots,X_4\}$
- Submuestra 2: $\{X_5,\dots,X_{12}\}$

Se define el estadístico:

$$T = \frac{\sqrt{8}\,(\overline{X}_1 - \overline{X}_2)}{\sqrt{3\,S_1^2 + 7\,S_2^2}}.$$

1. Determinar razonadamente la distribución exacta de T, justificando la distribución del numerador, la del denominador y la independencia estocástica entre ambos.

   Para hallar la distribución exacta de T, puesto que en el denominador hay una raíz cuadrada, buscamos una construcción de la distribución t de Student:

   $$\left.\begin{array}{l} Z \rightsquigarrow \mathcal{N}(0,1) \\ V \rightsquigarrow \chi^2(k) \\ Z \text{ y } V \text{ independientes} \end{array}\right\} \Longrightarrow \frac{Z}{\sqrt{V/k}} \rightsquigarrow t(k)$$

   Puesto que $X \rightsquigarrow \mathcal{N}(\mu, \sigma^2)$, tenemos que:

   $$\overline{X}_1 \rightsquigarrow \mathcal{N}\left(\mu, \frac{\sigma^2}{4}\right), \qquad \overline{X}_2 \rightsquigarrow \mathcal{N}\left(\mu, \frac{\sigma^2}{8}\right).$$

   Al ser combinación lineal de normales independientes, la diferencia $\overline{X}_1 - \overline{X}_2$ es también una variable normal con parámetros:

   $$E[\overline{X}_1 - \overline{X}_2] = E[\overline{X}_1] - E[\overline{X}_2] = \mu - \mu = 0,$$

   $$\mathrm{Var}(\overline{X}_1 - \overline{X}_2) = \mathrm{Var}(\overline{X}_1) + \mathrm{Var}(\overline{X}_2) = \frac{\sigma^2}{4} + \frac{\sigma^2}{8} = \frac{3\sigma^2}{8}.$$

   Tipificando la variable, obtenemos:

   $$Z = \frac{\overline{X}_1 - \overline{X}_2}{\sqrt{\frac{3\sigma^2}{8}}} = \frac{\sqrt{8}(\overline{X}_1 - \overline{X}_2)}{\sigma\sqrt{3}} \rightsquigarrow \mathcal{N}(0,1).$$

   Por teoría, sabemos que:

   $$\frac{(n_1-1)S_1^2}{\sigma^2} = \frac{3S_1^2}{\sigma^2} \rightsquigarrow \chi^2(3), \qquad \frac{(n_2-1)S_2^2}{\sigma^2} = \frac{7S_2^2}{\sigma^2} \rightsquigarrow \chi^2(7).$$

   Dado que provienen de submuestras disjuntas, S_1^2 y S_2^2 son mutuamente independientes. Por la propiedad reproductiva de la distribución chi-cuadrado:

   $$V = \frac{3S_1^2}{\sigma^2} + \frac{7S_2^2}{\sigma^2} = \frac{3S_1^2 + 7S_2^2}{\sigma^2} \rightsquigarrow \chi^2(3+7) \equiv \chi^2(10).$$

   Por el Lema de Fisher, dentro de la primera submuestra $\overline{X}_1$ y S_1^2 son independientes. Análogamente, en la segunda submuestra $\overline{X}_2$ y S_2^2 son independientes. Como ambas submuestras proceden de elementos disjuntos de una m.a.s., el vector $(\overline{X}_1, \overline{X}_2)$ es independiente del vector (S_1^2, S_2^2). Por tanto, cualquier función medible de las medias (en particular $\overline{X}_1 - \overline{X}_2$) es independiente de cualquier función de las cuasivarianzas (en particular $3S_1^2 + 7S_2^2$).

   Construyendo el cociente:

   $$\frac{Z}{\sqrt{V/10}} = \frac{\frac{\sqrt{8}(\overline{X}_1 - \overline{X}_2)}{\sigma\sqrt{3}}}{\sqrt{\frac{3S_1^2 + 7S_2^2}{10\sigma^2}}} = \sqrt{\frac{10}{3}} \cdot \frac{\sqrt{8}(\overline{X}_1 - \overline{X}_2)}{\sqrt{3S_1^2 + 7S_2^2}} = \sqrt{\frac{10}{3}}\, T \rightsquigarrow t(10).$$

   En consecuencia:

   $$T = \sqrt{\frac{3}{10}}\, U, \quad \text{donde } U \rightsquigarrow t(10).$$

2. Expresar la suma total de cuadrados de las desviaciones Q en función de S_1^2, S_2^2 y $(\overline{X}_1 - \overline{X}_2)^2$:

$$Q = \sum_{i=1}^{12}(X_i - \overline{X})^2$$

La media muestral global es:

$$\overline{X} = \frac{1}{12}\left(\sum_{i=1}^{4} X_i + \sum_{i=5}^{12} X_i\right) = \frac{4\overline{X}_1 + 8\overline{X}_2}{12} = \frac{\overline{X}_1 + 2\overline{X}_2}{3}.$$

Descomponemos la suma total de cuadrados de desviaciones Q:

$$Q = \sum_{i=1}^{12}(X_i - \overline{X})^2 = \sum_{i=1}^{4}(X_i - \overline{X})^2 + \sum_{i=5}^{12}(X_i - \overline{X})^2.$$

Sumando y restando la media del grupo correspondiente dentro de cada sumatorio:

$$\sum_{i=1}^{4}(X_i - \overline{X})^2 = \sum_{i=1}^{4}\left[(X_i - \overline{X}_1) + (\overline{X}_1 - \overline{X})\right]^2 =$$
$$= \sum_{i=1}^{4}(X_i - \overline{X}_1)^2 + 4(\overline{X}_1 - \overline{X})^2 + 2(\overline{X}_1 - \overline{X})\sum_{i=1}^{4}(X_i - \overline{X}_1).$$

Puesto que el momento centrado de primer orden es cero, el término del doble producto se anula. Aplicando el mismo desarrollo al segundo bloque:

$$Q = \sum_{i=1}^{4}(X_i - \overline{X}_1)^2 + 4(\overline{X}_1 - \overline{X})^2 + \sum_{i=5}^{12}(X_i - \overline{X}_2)^2 + 8(\overline{X}_2 - \overline{X})^2.$$

Aplicando la definición de cuasivarianza muestral:

$$Q = 3S_1^2 + 7S_2^2 + 4(\overline{X}_1 - \overline{X})^2 + 8(\overline{X}_2 - \overline{X})^2.$$

Expresamos las desviaciones de las medias locales respecto a la media global:

$$\overline{X}_1 - \overline{X} = \overline{X}_1 - \frac{\overline{X}_1 + 2\overline{X}_2}{3} = \frac{2}{3}(\overline{X}_1 - \overline{X}_2),$$

$$\overline{X}_2 - \overline{X} = \overline{X}_2 - \frac{\overline{X}_1 + 2\overline{X}_2}{3} = -\frac{1}{3}(\overline{X}_1 - \overline{X}_2).$$

Sustituyendo estos valores:

$$4\left(\frac{2}{3}(\overline{X}_1 - \overline{X}_2)\right)^2 + 8\left(-\frac{1}{3}(\overline{X}_1 - \overline{X}_2)\right)^2 = \left(\frac{16}{9} + \frac{8}{9}\right)(\overline{X}_1 - \overline{X}_2)^2 = \frac{8}{3}(\overline{X}_1 - \overline{X}_2)^2.$$

Por tanto, la descomposición exacta de Q es:

$$Q = (3S_1^2 + 7S_2^2) + \frac{8}{3}(\overline{X}_1 - \overline{X}_2)^2.$$

3. Deducir la distribución exacta del estadístico:

$$W = \frac{\frac{8}{3}(\overline{X}_1 - \overline{X}_2)^2}{\frac{3S_1^2 + 7S_2^2}{10}}.$$

Del primer apartado, sabemos que:

$$Z = \frac{\sqrt{8}(\overline{X}_1 - \overline{X}_2)}{\sigma\sqrt{3}} \rightsquigarrow \mathcal{N}(0,1) \implies Z^2 \rightsquigarrow \chi^2(1),$$
$$V = \frac{3S_1^2 + 7S_2^2}{\sigma^2} \rightsquigarrow \chi^2(10),$$

y Z y V son independientes, luego Z^2 y V también lo son. Por tanto, podemos aplicar la construcción de la distribución F de Snedecor:

$$\left.\begin{array}{l} Z^2 \rightsquigarrow \chi^2(1) \\ V \rightsquigarrow \chi^2(10) \\ Z^2 \text{ y } V \text{ independientes} \end{array}\right\} \implies \frac{Z^2/1}{V/10} \rightsquigarrow F(1,10)$$

Calculamos el cociente de las variables aleatorias:

$$\frac{Z^2/1}{V/10} = \frac{\frac{\frac{8}{3}(\overline{X}_1 - \overline{X}_2)^2}{\cancel{\sigma^2}}}{\frac{\frac{3S_1^2 + 7S_2^2}{\cancel{\sigma^2}}}{10}} = \frac{\frac{8}{3}(\overline{X}_1 - \overline{X}_2)^2}{\frac{3S_1^2 + 7S_2^2}{10}} = W \rightsquigarrow F(1,10).$$

4. Calcular $P[W > 4{,}96]$.

Puesto que $W \rightsquigarrow F(1,10)$, calculamos la probabilidad solicitada empleando la tabla de la distribución F:

$$P[W > 4{,}96] = 1 - P[W \leq 4{,}96] = 1 - 0{,}95 = 0{,}05.$$

2.3. Suficiencia y completitud

Ejercicio 2.3.1. Sea $(X_1, \ldots, X_n)$ una muestra aleatoria simple de una variable $X \rightsquigarrow \{\mathcal{B}(k,p) : p \in]0,1[\}$ y sea $T(X_1, \ldots, X_n) = \sum_{i=1}^{n} X_i$. Probar que T es suficiente para p:

1. Usando la definición:

   Si notamos para abreviar $T = T(X_1, \ldots, X_n)$, tenemos que probar que la distribución de la muestra condicionada a cualquier valor del estadístico no depende del parámetro p para probar que T es suficiente para p. Para ello:

   $$P_p[X_1 = x_1, \ldots, X_n = x_n \mid T = t] = \frac{P_p[X_1 = x_1, \ldots, X_n = x_n, T = t]}{P_p[T = t]}$$
   $$= \begin{cases} 0 & \text{si } T(x_1, \ldots, x_n) \neq t \\ \dfrac{P_p[X_1 = x_1, \ldots, X_n = x_n]}{P_p[T = t]} & \text{si } T(x_1, \ldots, x_n) = t \end{cases}$$

   Como 0 obviamente no depende de p, el caso $T(x_1, \ldots, x_2) \neq t$ se encuentra ya estudiado, por lo que nos centramos en el caso $T(x_1, \ldots, x_2) = t$:

   $$\frac{P_p[X_1 = x_1, \ldots, X_n = x_n]}{P_p[T = t]} \overset{\text{iid.}}{=} \frac{\prod_{i=1}^{n} P_p[X = x_i]}{P_p[T = t]} \overset{(*)}{=} \frac{\prod_{i=1}^{n} \binom{k}{x_i} p^{x_i}(1-p)^{k-x_i}}{\binom{nk}{t} p^t (1-p)^{nk-t}}$$
   $$= \frac{p^{\sum_{i=1}^{n} x_i}(1-p)^{nk-\sum_{i=1}^{n} x_i} \prod_{i=1}^{n} \binom{k}{x_i}}{\binom{nk}{t} p^t (1-p)^{nk-t}} \overset{(**)}{=} \frac{\prod_{i=1}^{n} \binom{k}{x_i}}{\binom{nk}{t}}$$

   Donde en $(*)$ hemos usado que $(X_1, \ldots, X_n)$ es una m.a.s. (variables independientes) y la reproductividad de la Binomial, por lo que $T \rightsquigarrow \mathcal{B}(nk, p)$; y en $(**)$ hemos usado que $t = T(x_1, \ldots, x_n) = \sum_{i=1}^{n} x_i$. En definitiva, hemos obtenido que la distribución de la muestra condicionada a cualquier valor del estadístico no dependende del parámetro p, por lo que T es suficiente para p.

2. Aplicando el teorema de factorización:

   Si podemos usar el Teorema de factorización, escribimos la función masa de probabilidad de la distribución conjunta de la muestra aleatoria simple:

   $$P[X_1 = x_1, \ldots, X_n = x_n] \overset{\text{iid.}}{=} \prod_{i=1}^{n} P[X = x_i] = \prod_{i=1}^{n} \binom{k}{x_i} p^{x_i}(1-p)^{k-x_i}$$
   $$= p^{\sum_{i=1}^{n} x_i}(1-p)^{nk-\sum_{i=1}^{n} x_i} \prod_{i=1}^{n} \binom{k}{x_i}$$

   Si tomamos:

   $$h(x_1, \ldots, x_n) = \prod_{i=1}^{n} \binom{k}{x_i}, \qquad T(X_1, \ldots, X_n) = \sum_{i=1}^{n} X_i, \qquad g_p(t) = p^t (1-p)^{nk-t}$$

   Podemos aplicar el Teorema de Factorización de Neymann-Fisher, obteniendo que T es un estadístico suficiente para p.

Ejercicio 2.3.2. Sea $(X_1, \ldots, X_n)$ una muestra aleatoria simple de una variable $X \rightsquigarrow \{\mathcal{P}(\lambda) : \lambda \in \mathbb{R}^+\}$ y sea $T(X_1, \ldots, X_n) = \sum_{i=1}^{n} X_i$. Probar que T es suficiente para λ:

1. Usando la definición:

   Notando $T = T(X_1, \ldots, X_n)$, seguimos los mismos pasos que en el ejercicio anterior:

   $$P_\lambda[X_1 = x_1, \ldots, X_n = x_n \mid T = t] = \frac{P_\lambda[X_1 = x_1, \ldots, X_n = x_n, T = t]}{P_\lambda[T = t]}$$
   $$= \begin{cases} 0 & \text{si } T(x_1, \ldots, x_n) \neq t \\ \dfrac{P_\lambda[X_1 = x_1, \ldots, X_n = x_n]}{P_\lambda[T = t]} & \text{si } T(x_1, \ldots, x_n) = t \end{cases}$$

   Y ahora nos interesamos por el segundo término, que es el que puede depender de λ:

   $$\frac{P_\lambda[X_1 = x_1, \ldots, X_n = x_n]}{P_\lambda[T = t]} \overset{\text{iid.}}{=} \frac{\prod_{i=1}^{n} P_\lambda[X = x_i]}{P_\lambda[T = t]} \overset{(*)}{=} \frac{\prod_{i=1}^{n} e^{-\lambda}\frac{\lambda^{x_i}}{x_i!}}{e^{-n\lambda}\frac{(n\lambda)^t}{t!}} = \frac{e^{-n\lambda} \cdot \frac{\lambda^{\sum_{i=1}^{n} x_i}}{\prod_{i=1}^{n} x_i!}}{e^{-n\lambda} \cdot \frac{n^t\lambda^t}{t!}}$$
   $$\overset{(**)}{=} \frac{t!}{n^t \prod_{i=1}^{n} x_i!}$$

   Donde en $(*)$ usamos que $T \rightsquigarrow \mathcal{P}(n\lambda)$, por la reproductividad de la Poisson y en $(**)$ usamos que $t = T(x_1, \ldots, x_n) = \sum_{i=1}^{n} x_i$. Obtenemos una cantidad que no depende de λ, por lo que T es suficiente para λ.

2. Aplicando el teorema de factorización:

   Si podemos aplicar el Teorema de factorización, escribimos:

   $$P_\lambda[X_1 = x_1, \ldots, X_n = x_n] \overset{\text{iid.}}{=} \prod_{i=1}^{n} P_\lambda[X = x_i] = \prod_{i=1}^{n} e^{-\lambda}\frac{\lambda^{x_i}}{x_i!} = e^{-n\lambda} \cdot \frac{\lambda^{\sum_{i=1}^{n} x_i}}{\prod_{i=1}^{n} x_i!}$$

   Si tomamos:

   $$h(x_1, \ldots, x_n) = \frac{1}{\prod_{i=1}^{n} x_i!}, \qquad T(X_1, \ldots, X_n) = \sum_{i=1}^{n} X_i, \qquad g_\lambda(t) = e^{-n\lambda} \cdot \lambda^t$$

   Por el Teorema de Factorización de Neymann-Fisher obtenemos que T es suficiente para λ.

Ejercicio 2.3.3. Sea (X_1, X_2, X_3) una muestra aleatoria simple de una variable $X \rightsquigarrow \{\mathcal{B}(1,p) : p \in]0,1[\}$. Probar que el estadístico $X_1+2X_2+3X_3$ no es suficiente.

Consideramos el estadístico $T(X_1, X_2, X_3) = X_1+2X_2+3X_3$. El espacio muestral de X es $\mathcal{X} = \{0,1\}$, por lo que el espacio muestral de T es $\mathcal{T} = \{0,1,2,3,4,5,6\}$. Sabemos por un ejemplo visto en teoría que el "truco" para demostrar que $T(X_1, X_2, X_3)$ no es suficiente para p es buscar un valor del espacio muestral $\mathcal{T}$ que provenga de varias combinaciones de estados del espacio muestral $\mathcal{X}^3$. Como $0, 1, 2$ solo provienen de una combinación del espacio muestral $\mathcal{X}^3$ (son $(0,0,0)$, $(1,0,0)$ y $(0,1,0)$ respectivamente), probamos buscar el contraejemplo con $t = 3$, que proviene de considerar las observaciones de la muestra $(1,1,0)$ y $(0,0,1)$.

Una vez explicado el procedimiento para buscar cuál es el valor de t que funciona, procedemos a probar que la distribución de la muestra condicionada a dicho valor de t depende del parámetro p. Para ello:

$$P_p[X_1 = x_1, X_2 = x_2, X_3 = x_3 \mid T = 3] = \frac{P_p[X_1 = x_1, X_2 = x_2, X_3 = x_3, T = 3]}{P_p[T = 3]}$$
$$= \begin{cases} 0 & \text{si } T(x_1, x_2, x_2) \neq 3 \\ \dfrac{P_p[X_1 = x_1, X_2 = x_2, X_3 = x_3]}{P_p[T = 3]} & \text{si } T(x_1, x_2, x_3) = 3 \end{cases}$$

Vemos que el primer caso no puede depender nunca de p, por lo que buscamos probar que el segundo caso sí que depende de p. Para ello:

$$\frac{P_p[X_1 = x_1, X_2 = x_2, X_3 = x_3]}{P_p[T = 3]} \overset{\text{iid.}}{=} \frac{P_p[X = x_1]P_p[X = x_2]P_p[X = x_3]}{P_p[T = 3]}$$
$$\overset{(*)}{=} \frac{p^{x_1}(1-p)^{1-x_1}p^{x_2}(1-p)^{1-x_2}p^{x_3}(1-p)^{1-x_3}}{P_p[X_1 = 1, X_2 = 1, X_3 = 0] + P_p[X_1 = 0, X_2 = 0, X_3 = 1]}$$
$$= \frac{p^{x_1}(1-p)^{1-x_1}p^{x_2}(1-p)^{1-x_2}p^{x_3}(1-p)^{1-x_3}}{p \cdot p \cdot (1-p) + (1-p)(1-p)p}$$

Donde en $(*)$ se ha usado la propiedad reproductiva de la Binomial, por lo que $T \rightsquigarrow \mathcal{B}(3,p)$, así como que la condición $t = 3$ provenía de los valores $(1,1,0)$ y $(0,0,1)$. Ahora, si tomamos $(x_1, x_2, x_3) = (1,1,0)$, tenemos que:

$$\frac{P_p[X_1 = 1, X_2 = 1, X_3 = 0]}{P_p[T = 3]} = \frac{p^1(1-p)^0p^1(1-p)^0p^0(1-p)^1}{p \cdot p \cdot (1-p) + (1-p)(1-p)p}$$
$$= \frac{pp(1-p)}{pp(1-p) + (1-p)(1-p)p}$$
$$= \frac{p^2(1-p)}{p(1-p)\cancel{(p + 1 - p)}^{1}} = p$$

Que claramente depende de p, por lo que T no es suficiente para p.

Ejercicio 2.3.4. Aplicando el teorema de factorización, y basándose en una muestra de tamaño arbitrario, encontrar un estadístico suficiente para cada una de las siguientes familias de distribuciones (en las familias biparamétricas, suponer los casos de sólo un parámetro desconocido y de los dos desconocidos).

a) $X \rightsquigarrow \{\mathcal{U}(-\theta/2, \theta/2) : \theta > 0\}$

b) $X \rightsquigarrow \{\Gamma(p, a) : p, a > 0\}$

c) $X \rightsquigarrow \{\beta(p, q) : p, q > 0\}$

d) $X \rightsquigarrow \{P_{N_1,N_2} : N_1, N_2 \in \mathbb{N}, N_1 \leqslant N_2\}$ y la masa de probabilidad viene dada por:

$$P_{N_1,N_2}[X = x] = \frac{1}{N_2 - N_1 + 1} \qquad x \in \{N_1, \dots, N_2\}$$

En lo que sigue, supondremos que tenemos una m.a.s. $(X_1, \dots, X_n)$ de variables idénticamente distribuidas a la respectiva variable X:

a) Si $X \rightsquigarrow \mathcal{U}(-\theta/2, \theta/2)$ con $\theta > 0$:

$$f(x_1, \dots, x_n) \overset{\text{iid.}}{=} \prod_{i=1}^{n} f(x_i) = \prod_{i=1}^{n} \frac{1}{\theta} = \frac{1}{\theta^n} \qquad x_i \in \,]-\theta/2, \theta/2[\,, \quad \forall i \in \{1, \dots, n\}$$

Caso directo (pero bidimensional) En este caso, tendremos la desigualdad $-\theta/2 < X_{(1)} \leqslant X_{(n)} < \theta/2$:

$$f(x_1, \dots, x_n) = \frac{1}{\theta^n} \, \mathrm{I}_{]0,+\infty[}(X_{(1)} + \theta/2) \, \mathrm{I}_{]-\infty,0[}(X_{(n)} - \theta/2)$$

Si tomamos:

$$h(x_1, \dots, x_n) = 1, \qquad T(X_1, \dots, X_n) = (X_{(1)}, X_{(n)})$$
$$g_\theta(t_1, t_2) = \frac{1}{\theta^n} \, \mathrm{I}_{]0,+\infty[}(t_1 + \theta/2) \, \mathrm{I}_{]-\infty,0[}(t_2 - \theta/2)$$

Por el Teorema de factorización, tenemos que $T(X_1, \dots, X_n)$ es un estadístico suficiente para θ.

Caso Unidimensional Tenemos que $|x_i| < \theta/2$ para todo $i \in \{1, \dots, n\}$, por lo que $|X|_{(n)} < \theta/2$. Por lo que:

$$f(x_1, \dots, x_n) = \frac{1}{\theta^n} \, \mathrm{I}_{]0,+\infty[}(\theta/2 - |X|_{(n)})$$

Si tomamos:

$$h(x_1, \dots, x_n) = 1, \qquad T(X_1, \dots, X_n) = |X|_{(n)}$$
$$g_\theta(t) = \frac{1}{\theta^n} \, \mathrm{I}_{]0,+\infty[}(\theta/2 - t)$$

Por el Teorema de factorización, tenemos que $T(X_1, \dots, X_n)$ es un estadístico suficiente para θ.

b) Si $X \rightsquigarrow \Gamma(p, a)$ con $p, a > 0$:

$$f(x_1, \dots, x_n) \overset{\text{iid.}}{=} \prod_{i=1}^{n} f(x_i) = \prod_{i=1}^{n} \frac{a^p}{\Gamma(p)} x_i^{p-1} e^{-a x_i} = \left(\frac{a^p}{\Gamma(p)}\right)^n e^{-a \sum_{i=1}^{n} x_i} \prod_{i=1}^{n} x_i^{p-1}$$
$$= \left(\frac{a^p}{\Gamma(p)}\right)^n e^{-a \sum_{i=1}^{n} x_i} \left(\prod_{i=1}^{n} x_i\right)^{p-1} \qquad x_i \geqslant 0 \qquad \forall i \in \{1, \dots, n\}$$

- Suponiendo que p es conocida, podemos tomar:

$$h(x_1,\dots,x_n)=\left(\prod_{i=1}^n x_i\right)^{p-1},\qquad T(X_1,\dots,X_n)=\sum_{i=1}^n X_i$$
$$g_a(t)=\left(\frac{a^p}{\Gamma(p)}\right)^n e^{-at}$$

- Suponiendo ahora que a es conocida:

$$h(x_1,\dots,x_n)=e^{-a\sum\limits_{i=1}^n x_i},\qquad T(X_1,\dots,X_n)=\prod_{i=1}^n x_i$$
$$g_p(t)=\left(\frac{a^p}{\Gamma(p)}\right)^n t^{p-1}$$

- Si ahora tanto p como a son desconocidas, podemos tomar:

$$h(x_1,\dots,x_n)=1,\qquad T(X_1,\dots,X_n)=\left(\sum_{i=1}^n X_i,\prod_{i=1}^n X_i\right)$$
$$g_{(a,p)}(t_1,t_2)=\left(\frac{a^p}{\Gamma(p)}\right)^n e^{-at_1}t_2^{p-1}$$

c) Si $X\rightsquigarrow\beta(p,q)$ con $p,q>0$:

$$f(x_1,\dots,x_n)\overset{\text{iid.}}{=}\prod_{i=1}^n f(x_i)=\prod_{i=1}^n\frac{1}{\beta(p,q)}x_i^{p-1}(1-x_i)^{q-1}$$
$$=\frac{1}{\beta(p,q)^n}\left(\prod_{i=1}^n x_i\right)^{p-1}\left(\prod_{i=1}^n(1-x_i)\right)^{q-1}\qquad x_i\in[0,1],\forall i\in\{1,\dots,n\}$$

- Si p es conocida, tomamos:

$$h(x_1,\dots,x_n)=\left(\prod_{i=1}^n x_i\right)^{p-1},\qquad T(X_1,\dots,X_n)=\prod_{i=1}^n(1-X_i)$$
$$g_q(t)=\frac{1}{\beta(p,q)^n}t^{q-1}$$

- Si q es conocida:

$$h(x_1,\dots,x_n)=\left(\prod_{i=1}^n(1-x_i)\right)^{q-1},\qquad T(X_1,\dots,X_n)=\prod_{i=1}^n X_i$$
$$g_p(t)=\frac{1}{\beta(p,q)^n}t^{p-1}$$

- Si tanto p como q son parámetros:

$$h(x_1,\dots,x_n)=1,\qquad T(X_1,\dots,X_n)=\left(\prod_{i=1}^n X_i,\prod_{i=1}^n(1-X_i)\right)$$
$$g_{(p,q)}(t_1,t_2)=\frac{1}{\beta(p,q)^n}t_1^{p-1}t_2^{q-1}$$

d) Si $X \rightsquigarrow P_{N_1,N_2}$ con $N_1, N_2 \in \mathbb{N}$, $N_1 \leqslant N_2$, entonces:

$$P[X_1 = x_1, \ldots, X_n = x_n] \overset{\text{iid.}}{=} \prod_{i=1}^{n} P[X = x_i] = \prod_{i=1}^{n} \frac{1}{N_2 - N_1 + 1}$$
$$= \frac{1}{(N_2 - N_1 + 1)^n}, \quad x_i \in \{N_1, \ldots N_2\}$$

Como se tiene $N_1 \leqslant X_{(1)} \leqslant X_{(n)} \leqslant N_2$, entonces:

$$P[X_1 = x_1, \ldots, X_n = x_n] = \frac{\mathrm{I}_{\mathbb{N}_0}(X_{(1)} - N_1)\, \mathrm{I}_{-\mathbb{N}_0}(X_{(n)} - N_2)}{(N_2 - N_1 + 1)^n}$$

- Si N_1 es conocido:

$$h(x_1, \ldots, x_n) = \mathrm{I}_{\mathbb{N}_0}(X_{(1)} - N_1), \qquad T(X_1, \ldots, X_n) = X_{(n)}$$
$$g_{N_2}(t) = \frac{\mathrm{I}_{-\mathbb{N}_0}(t - N_2)}{(N_2 - N_1 + 1)^n}$$

- Si N_2 es conocida:

$$h(x_1, \ldots, x_n) = \mathrm{I}_{-\mathbb{N}_0}(X_{(n)} - N_2), \qquad T(X_1, \ldots, X_n) = X_{(1)}$$
$$g_{N_1}(t) = \frac{\mathrm{I}_{\mathbb{N}_0}(t - N_1)}{(N_2 - N_1 + 1)^n}$$

- Si tanto N_1 como N_2 son parámetros:

$$h(x_1, \ldots, x_n) = 1, \qquad T(X_1, \ldots, X_n) = \left(X_{(1)}, X_{(n)}\right)$$
$$g_{(N_1,N_2)}(t_1, t_2) = \frac{\mathrm{I}_{\mathbb{N}_0}(t_1 - N_1)\, \mathrm{I}_{-\mathbb{N}_0}(t_2 - N_2)}{(N_2 - N_1 + 1)^n}$$

Por lo que en cualquier caso obtenemos un estadístico suficiente, por el Teorema de Factorización.

Ejercicio 2.3.5. Sea $X \rightsquigarrow \{P_N : N \in \mathbb{N}\}$, siendo P_N la distribución uniforme en los puntos $\{1, \ldots, N\}$, y sea $(X_1, \ldots, X_n)$ una muestra aleatoria simple de X. Probar que máx$(X_1, \ldots, X_n)$ es un estadístico suficiente y completo.

Buscamos aplicar el Teorema de factorización de Neymann-Fisher:

$$P[X_1 = x_1, \ldots, X_n = x_n] \overset{\text{iid.}}{=} \prod_{i=1}^{n} P[X = x_i] = \prod_{i=1}^{n} \frac{1}{N}, \quad x_i \in \{1, \ldots, N\}, \forall i \in \{1, \ldots, n\}$$

Por lo que $1 \leqslant X_{(1)} \leqslant X_{(n)} \leqslant N$:

$$P[X_1 = x_1, \ldots, X_n = x_n] = \frac{\mathrm{I}_{\mathbb{N}_0}(X_{(1)} - 1)\, \mathrm{I}_{-\mathbb{N}_0}(X_{(n)} - N)}{N^n}$$

De donde podemos tomar:

$$h(x_1, \ldots, x_n) = \mathrm{I}_{\mathbb{N}_0}(X_{(1)} - 1), \qquad T(X_1, \ldots, X_n) = X_{(n)}$$
$$g_N(t) = \frac{\mathrm{I}_{-\mathbb{N}_0}(t - N)}{N^n}$$

Por el Teorema de factorización de Neymann-Fisher, tenemos que el estadístico $T(X_1, \ldots, X_n) = X_{(n)}$ es suficiente. Comprobamos que también es completo: sea g cualquier función medible, supongamos que (abreviaremos $T(X_1, \ldots, X_n) = T$):

$$0 = E[g(T)] = \sum_{t=1}^{N} g(t)P[T = t] \qquad \forall N \in \mathbb{N}$$

Calculamos la función masa de probabilidad de T:

$$F_T(t) = (F_X(t))^n \Longrightarrow P[T = t] = P[T \leqslant t] - P[T \leqslant t-1] = (F_X(t))^n - (F_X(t-1))^n$$

Como $F_X(t) = \frac{t}{N}$, tenemos entonces que:

$$P[T = t] = (F_X(t))^n - (F_X(t-1))^n = \frac{t^n}{N^n} - \frac{(t-1)^n}{N^n} = \frac{t^n - (t-1)^n}{N^n}$$

Por lo que:

$$0 = E[g(T)] = \sum_{t=1}^{N} g(t)\frac{t^n - (t-1)^n}{N^n} = \frac{1}{N^n}\sum_{t=1}^{N} g(t)(t^n - (t-1)^n) \qquad \forall N \in \mathbb{N}$$

de donde:

$$\sum_{t=1}^{N} g(t)(t^n - (t-1)^n) = 0 \qquad \forall N \in \mathbb{N}$$

Puesto que la potencia $n-$ésima es una función estrictamente creciente en el intervalo $[0, +\infty[$, tenemos que $t^n - (t-1)^n > 0$ para todo $t \in \mathbb{N}$. Veamos por inducción que $g(t) = 0$ para todo $t \in \mathbb{N}$:

- Para $t = 1$: Como la igualdad ha de ser cierta para todo $N \in \mathbb{N}$, tomamos $N = 1$:
$$g(1)(1^n - (1-1)^n) = g(1) = 0$$
- Supongamos que $g(t) = 0$ para todo $t < n_0$: Tomamos $N = n_0$:
$$\sum_{t=1}^{n_0} g(t)(t^n - (t-1)^n) = \sum_{t=1}^{n_0-1} g(t)(t^n - (t-1)^n) + g(n_0)(n_0^n - (n_0-1)^n)$$
Por hipótesis de inducción, $g(t) = 0$ para todo $t < n_0$, por lo que:
$$g(n_0)(n_0^n - (n_0-1)^n) = 0$$
Como $n_0^n - (n_0-1)^n > 0$, tenemos que $g(n_0) = 0$.

Por inducción, tenemos que $g(t) = 0$ para todo $t \in \mathbb{N}$, por lo que:

$$\mathbb{N} \subseteq \{t : g(t) = 0\}$$

Por lo que:

$$1 \geqslant P[g(T) = 0] \geqslant P[T \in \mathbb{N}] = 1 \Longrightarrow P[g(T) = 0] = 1$$

Lo que demuestra que $X_{(n)}$ es completo.

Ejercicio 2.3.6. Basándose en una muestra de tamaño arbitrario, obtener un estadístico suficiente y completo para la familia de distribuciones definidas por todas las densidades de la forma

$$f_\theta(x) = e^{\theta - x}, \qquad x > \theta$$

Sea $(X_1, \ldots, X_n)$ una m.a.s. de tamaño $n \in \mathbb{N}$:

$$f_\theta(x_1, \ldots, x_n) \overset{\text{iid.}}{=} \prod_{i=1}^{n} f_\theta(x_i) = \prod_{i=1}^{n} e^{\theta - x_i} = e^{n\theta - \sum_{i=1}^{n} x_i} = \frac{e^{n\theta}}{e^{\sum_{i=1}^{n} x_i}}, \quad x_i > \theta \ \forall i \in \{1, \ldots, n\}$$

Por lo que ha de ser $\theta < X_{(1)}$:

$$f_\theta(x_1, \ldots, x_n) = \frac{e^{n\theta} \cdot \mathrm{I}_{]0,\infty[}(X_{(1)} - \theta)}{e^{\sum_{i=1}^{n} x_i}} \qquad x_i \in \mathbb{R}, \forall i \in \{1, \ldots, n\}$$

Si tomamos:

$$h(x_1, \ldots, x_n) = e^{-\sum_{i=1}^{n} x_i}, \qquad T(X_1, \ldots, X_n) = X_{(1)}$$
$$g_\theta(t) = e^{n\theta} \cdot \mathrm{I}_{]0,\infty[}(t - \theta)$$

Por el Teorema de factorización de Neymann-Fisher tenemos que el estadístico $X_{(1)}$ es suficiente para θ. Comprobemos si es completo: sea g cualquier función medible, suponemos que (y escribimos $T = T(X_1, \ldots, X_n)$ para abreviar):

$$0 = E[g(T)] = \int_\theta^{+\infty} g(t) f_T(t)\, dt \qquad \forall \theta \in \mathbb{R}$$

Como $T = X_{(1)}$, tenemos que:

$$F_T(t) = 1 - (1 - F_\theta(t))^n \Longrightarrow f_T(t) = n(1 - F_\theta(t))^{n-1} f_\theta(t)$$

donde:

$$F_\theta(t) = \int_\theta^t e^{\theta - x}\, dx = \left[-e^{\theta - x}\right]_\theta^t = 1 - e^{\theta - t}, \qquad t > \theta$$

por lo que:

$$f_T(t) = n\left(e^{\theta - t}\right)^{n-1} e^{\theta - t} = n\left(e^{\theta - t}\right)^n, \qquad t > \theta$$

volviendo al caso que nos interesa:

$$0 = E[g(T)] = \int_\theta^{+\infty} g(t) n\left(e^{\theta - t}\right)^n dt = n e^{n\theta} \int_\theta^{+\infty} g(t) e^{-nt}\, dt \qquad \forall \theta \in \mathbb{R}$$

por lo que:

$$\int_\theta^{+\infty} g(t) e^{-nt}\, dt = 0 \qquad \forall \theta \in \mathbb{R}$$

Aunque g es medible, podemos aplicar el Teorema Fundamental del Cálculo, luego si $G(t)$ es una primitiva de $g(t)e^{-nt}$, entonces:

$$\int_\theta^{+\infty} g(t) e^{-nt}\, dt = \lim_{n\to\infty} \int_\theta^n g(t) e^{-nt}\, dt = \lim_{n\to\infty} G(n) - G(\theta) = 0 \qquad \forall \theta \in \mathbb{R}$$

Si derivamos ahora respecto a θ, tenemos que:

$$-g(\theta)e^{-n\theta} = 0 \qquad \forall\theta \in \mathbb{R}$$

con lo que $g(\theta) = 0 \quad \forall\theta \in \mathbb{R}$. Es decir:

$$\mathbb{R} \subseteq \{t : g(t) = 0\}$$

luego:

$$1 \geqslant P[g(T) = 0] \geqslant P[T \in \mathbb{R}] = 1 \Longrightarrow P[g(T) = 0] = 1$$

por lo que T es completo.

Ejercicio 2.3.7. Comprobar que las siguientes familias de distribuciones son exponenciales uniparamétricas y, considerando una muestra aleatoria simple de una variable con distribución en dicha familia, obtener, si existe, un estadístico suficiente y completo.

a) $\{\mathcal{B}(k_0, p) : 0 < p < 1\}$

Comprobamos todas las condiciones:

1. El espacio paramétrico es: $]0, 1[$ intervalo de $\mathbb{R}$.
2. El espacio muestral es $\mathcal{X} = \{0, \ldots, k_0\}$, que no depende de p.
3. Para la tercera condición:

$$\begin{aligned} P[X = x]_p &= \binom{k_0}{x} p^x (1-p)^{k_0-x} = \exp\left[\ln\left(\binom{k_0}{x} p^x (1-p)^{k_0-x}\right)\right] \\ &= \exp\left[\ln\binom{k_0}{x} + x\ln p + (k_0 - x)\ln(1-p)\right] \\ &= \exp\left[\ln\binom{k_0}{x} + x\ln p + k_0\ln(1-p) - x\ln(1-p)\right] \\ &= \exp\left[\ln\binom{k_0}{x} + k_0\ln(1-p) + x\ln\left(\frac{p}{1-p}\right)\right] \end{aligned}$$

Tomando:

$$T(x) = x, \qquad S(x) = \ln\binom{k_0}{x}$$

$$Q(p) = \ln\left(\frac{p}{1-p}\right), \qquad D(p) = k_0\ln(1-p)$$

obtenemos la tercera condición.

Sea $(X_1, \ldots, X_n)$ una m.a.s. de variables aleatorias idénticamente distribuidas a $X \rightsquigarrow \mathcal{B}(k_0, p)$ con $p \in]0, 1[$, el Teorema visto en teoría para las familias de distribuciones exponenciales nos dice que el estadístico:

$$T = T(X_1, \ldots, X_n) = \sum_{i=1}^{n} T(X_i) = \sum_{i=1}^{n} X_i$$

es suficiente para p. Para ver que T es también completo, hemos de ver que $\operatorname{Im} Q$ contiene un abierto de $\mathbb{R}$:

Opción 1. Como $Q :]0,1[\to \mathbb{R}$ es continua y definida sobre un conexo (un intervalo), su imagen ha de ser un conexo. Como en $\mathbb{R}$ los únicos conjuntos conexos son los intervalos y los puntos, y Q es claramente no constante, su imagen ha de ser un intervalo, que es un abierto de $\mathbb{R}$, por lo que T es completo.

Opción 2.

$$\operatorname{Im} Q = \left\{ \ln\left(\frac{p}{1-p}\right) : p \in]0,1[\right\}$$

Definimos la siguiente función:

$$\begin{array}{rccc} f: &]0,1[& \longrightarrow & \mathbb{R}^+ \\ & t & \longmapsto & \dfrac{t}{1-t} \end{array}$$

- Está bien definida, puesto que si $t \in]0,1[$, entonces $1-t>0$, con lo que $f(t) \in \mathbb{R}^+$.
- Sea $y \in \mathbb{R}^+$, tenemos que:

$$\frac{t}{1-t} = y \iff t = y(1-t) \iff t = y - yt \iff t(1+y) = y \iff t = \frac{y}{y+1} < 1$$

Por lo que $f(t) = y$ con $t \in]0,1[$, con lo que f es sobreyectiva.

Por tanto, $\operatorname{Im} f = \mathbb{R}^+$, de donde deducimos que:

$$\operatorname{Im} Q = \left\{ \ln\left(\frac{p}{1-p}\right) : p \in]0,1[\right\} = \{\ln(f(p)) : p \in]0,1[\} = \ln(\operatorname{Im} f) = \ln(\mathbb{R}^+) = \mathbb{R}$$

Como obviamente $\mathbb{R}$ contiene algún abierto de $\mathbb{R}$, deducimos que T era un estadístico completo.

b) $\{\mathcal{P}(\lambda) : \lambda > 0\}$

Comprobamos las condiciones:

1. El espacio paramétrico es $\mathbb{R}^+$ intervalo de $\mathbb{R}$.
2. El espacio muestral es $\mathcal{X} = \mathbb{N} \cup \{0\}$, que no depende de λ.
3. Para la tercera condición:

$$P_\lambda[X = x] = e^{-\lambda}\frac{\lambda^x}{x!} = \exp\left[\ln\left(e^{-\lambda}\frac{\lambda^x}{x!}\right)\right] = \exp[-\lambda + x\ln\lambda - \ln(x!)]$$

Tomando:

$$\begin{array}{rr} T(x) = x, & S(x) = -\ln(x!) \\ Q(\lambda) = \ln\lambda, & D(\lambda) = -\lambda \end{array}$$

obtenemos la tercera condición.

Sea $(X_1, \ldots, X_n)$ una m.a.s. de variables aleatorias idénticamente distribuidas a $X \rightsquigarrow \mathcal{P}(\lambda)$ con $\lambda \in \mathbb{R}^+$, el Teorema visto en teoría para las familias de distribuciones exponenciales nos dice que el estadístico:

$$T = T(X_1, \ldots, X_n) = \sum_{i=1}^{n} T(X_i) = \sum_{i=1}^{n} X_i$$

es suficiente para λ. Para ver que T es también completo, hemos de ver que $\operatorname{Im} Q$ contiene un abierto de $\mathbb{R}$. Como:

$$\operatorname{Im} Q = \{\ln(\lambda) : \lambda \in \mathbb{R}^+\} = \ln(\mathbb{R}^+) = \mathbb{R}$$

Tenemos que $\operatorname{Im} Q = \mathbb{R}$ claramente contiene un abierto de $\mathbb{R}$, por lo que T es completo.

c) $\{BN(k_0, p) : 0 < p < 1\}$

Comprobamos las condiciones:

1. El espacio paramétrico es $]0, 1[$ intervalo de $\mathbb{R}$.
2. El espacio muestral es $\mathcal{X} = \mathbb{N} \cup \{0\}$, que no depende de p.
3. Para la tercera condición:

$$\begin{aligned} P_p[X = x] &= \binom{x + k_0 - 1}{x}(1-p)^x p^{k_0} = \exp\left[\ln\left(\binom{x + k_0 - 1}{x}(1-p)^x p^{k_0}\right)\right] \\ &= \exp\left[\ln\binom{x + k_0 - 1}{x} + x\ln(1-p) + k_0 \ln p\right] \end{aligned}$$

Tomando:

$$\begin{aligned} T(x) = x, \qquad & S(x) = \ln\binom{x + k_0 - 1}{x} \\ Q(p) = \ln(1-p), \qquad & D(p) = k_0 \ln p \end{aligned}$$

Obtenemos la tercera condición.

Sea $(X_1, \ldots, X_n)$ una m.a.s. de variables aleatorias idénticamente distribuidas a $X \rightsquigarrow BN(k_0, p)$ con $p \in]0, 1[$, el Teorema visto en teoría para las familias de distribuciones exponenciales nos dice que el estadístico:

$$T = T(X_1, \ldots, X_n) = \sum_{i=1}^{n} T(X_i) = \sum_{i=1}^{n} X_i$$

es suficiente para p. Para ver que T es también completo, hemos de ver que $\operatorname{Im} Q$ contiene un abierto de $\mathbb{R}$. Como $Q :]0, 1[\to \mathbb{R}$ es una función continua, no constante y definida en un intervalo, tenemos que su imagen es un intervalo, por lo que contiene abiertos de $\mathbb{R}$, de donde T es completo.

d) $\{\exp(\lambda) : \lambda > 0\}$

Comprobamos las condiciones:

1. El espacio paramétrico es $\mathbb{R}^+$ intervalo de $\mathbb{R}$.
2. El espacio muestral es $\mathcal{X} = \mathbb{R}^+$, que no depende de λ.
3. Para la tercera condición:

$$f_\lambda(x) = \lambda e^{-\lambda x} = \exp\left[\ln\left(\lambda e^{-\lambda x}\right)\right] = \exp\left[\ln(\lambda) - \lambda x\right]$$

Tomando:

$$\begin{aligned} T(x) &= x, & S(x) &= 0 \\ Q(\lambda) &= -\lambda, & D(\lambda) &= \ln(\lambda) \end{aligned}$$

tenemos la tercera condición.

Sea $(X_1, \ldots, X_n)$ una m.a.s. de variables aleatorias idénticamente distribuidas a $X \rightsquigarrow \exp(\lambda)$ con $\lambda \in \mathbb{R}^+$, el Teorema visto en teoría para las familias de distribuciones exponenciales nos dice que el estadístico:

$$T = T(X_1, \ldots, X_n) = \sum_{i=1}^{n} T(X_i) = \sum_{i=1}^{n} X_i$$

es suficiente para λ. Para ver que T es también completo, hemos de ver que $\operatorname{Im} Q$ contiene un abierto de $\mathbb{R}$. Como $Q : \mathbb{R}^+ \to \mathbb{R}$ es una función continua, no constante y definida en un intervalo, tenemos que su imagen es un intervalo, por lo que contiene abiertos de $\mathbb{R}$, de donde T es completo.

Ejercicio 2.3.8. Estudiar si las siguientes familias de distribuciones son exponenciales biparamétricas. En caso afirmativo, considerando una muestra aleatoria simple de una variable con distribución en dicha familia, obtener, si existe, un estadístico suficiente y completo.

a) $\{\Gamma(p, a) : p, a > 0\}$

Comprobamos las condiciones:

1. El espacio paramétrico es $\mathbb{R}^+ \times \mathbb{R}^+$ intervalo de $\mathbb{R}^2$.
2. El espacio muestral es $\mathbb{R}^+$, que no depende de p ni de a.
3. Para la tercera condición:

$$\begin{aligned} f_{(p,a)}(x) = \frac{a^p}{\Gamma(p)} x^{p-1} e^{-ax} &= \exp\left[\ln\left(\frac{a^p}{\Gamma(p)} x^{p-1} e^{-ax}\right)\right] \\ &= \exp\left[\ln\left(\frac{a^p}{\Gamma(p)}\right) + (p-1)\ln x - ax\right] \end{aligned}$$

Tomando:

$$\begin{aligned} T_1(x) &= \ln x, & T_2(x) &= x, & S(x) &= 0 \\ Q_1(p,a) &= (p-1), & Q_2(p,a) &= -a, & D(p,a) &= \ln\left(\frac{a^p}{\Gamma(p)}\right) \end{aligned}$$

Tenemos la tercera condición.

Sea $(X_1, \ldots, X_n)$ una m.a.s. de variables aleatorias idénticamente distribuidas a $X \rightsquigarrow \Gamma(p, a)$ con $p, a \in \mathbb{R}^+$, el Teorema visto en teoría para las familias de distribuciones exponenciales multiparamétricas nos dice que el estadístico:

$$T = T(X_1, \ldots, X_n) = \left(\sum_{i=1}^{n} T_1(X_i), \sum_{i=1}^{n} T_2(X_i) \right) = \left(\sum_{i=1}^{n} \ln(X_i), \sum_{i=1}^{n} X_i \right)$$

es suficiente para (p, a). Para ver que T es también completo, hemos de ver que $\operatorname{Im} Q$ contiene un abierto de $\mathbb{R}^2$, donde $Q : (\mathbb{R}^+)^2 \to \mathbb{R}^2$, con $Q = (Q_1, Q_2)$. Para ello:

$$\begin{aligned} \operatorname{Im} Q = \left\{ (p-1, -a) : (p, a) \in (\mathbb{R}^+)^2 \right\} &= \{(x-1, y) : x \in \mathbb{R}^+, y \in \mathbb{R}^-\} \\ &=]-1, +\infty[\times \mathbb{R}^- \end{aligned}$$

Como claramente $]-1, +\infty[\times \mathbb{R}^-$ contiene un abierto de $\mathbb{R}^2$, tenemos que T es completo.

Además, puesto que la suma de logaritmos es el logaritmo del producto y la exponencial es una función biyectiva, podemos tomar como estadístico suficiente y completo:

$$T(X_1, \ldots, X_n) = \left(\prod_{i=1}^{n} X_i, \sum_{i=1}^{n} X_i \right)$$

b) $\{\beta(p, q) : p, q > 0\}$

Comprobamos las condiciones:

1. El espacio paramétrico es $\mathbb{R}^+ \times \mathbb{R}^+$ intervalo de $\mathbb{R}^2$.
2. El espacio muestral es $[0, 1]$, que no depende de p ni de q.
3. Para la tercera condición:

$$\begin{aligned} f_{(p,q)}(x) = \frac{1}{\beta(p,q)} x^{p-1}(1-x)^{q-1} &= \exp\left[\ln\left(\frac{1}{\beta(p,q)} x^{p-1}(1-x)^{q-1} \right) \right] \\ &= \exp\left[\ln\left(\frac{1}{\beta(p,q)} \right) + (p-1)\ln x + (q-1)\ln(1-x) \right] \end{aligned}$$

Tomando:

$$\begin{aligned} T_1(x) = \ln x, \qquad T_2(x) = \ln(1-x), \qquad S(x) = 0 \\ Q_1(p,q) = p-1, \qquad Q_2(p,q) = q-1, \qquad D(p,q) = \ln\left(\frac{1}{\beta(p,q)} \right) \end{aligned}$$

Tenemos la tercera condición.

Sea $(X_1, \ldots, X_n)$ una m.a.s. de variables aleatorias idénticamente distribuidas a $X \rightsquigarrow \beta(p, q)$ con $p, q \in \mathbb{R}^+$, el Teorema visto en teoría para las familias de distribuciones exponenciales multiparamétricas nos dice que el estadístico:

$$T = T(X_1, \ldots, X_n) = \left(\sum_{i=1}^{n} T_1(X_i), \sum_{i=1}^{n} T_2(X_i) \right) = \left(\sum_{i=1}^{n} \ln(X_i), \sum_{i=1}^{n} \ln(1-X_i) \right)$$

es suficiente para (p, q). Para ver que T es también completo, hemos de ver que $\operatorname{Im} Q$ contiene un abierto de $\mathbb{R}^2$, donde $Q : (\mathbb{R}^+)^2 \to \mathbb{R}^2$, con $Q = (Q_1, Q_2)$. Para ello:

$$\operatorname{Im} Q = \{(p-1, q-1) : p, q \in \mathbb{R}^+\} =]-1, +\infty[\times]-1, +\infty[$$

Como claramente este conjunto contiene un abierto de $\mathbb{R}^2$, tenemos que T es completo. De esta forma, podemos tomar como estadístico suficiente y completo:

$$T(X_1, \ldots, X_n) = \left(\prod_{i=1}^{n} X_i, \prod_{i=1}^{n} (1 - X_i) \right)$$

Ejercicios Adicionales

Ejercicio 2.3.9. Sea $X_1, X_2, \ldots, X_n$ una muestra aleatoria simple de una variable aleatoria continua X con distribución de Rayleigh de parámetro $\theta > 0$ desconocido, cuya función de densidad viene dada por:

$$f_\theta(x) = \frac{x}{\theta^2} \exp\left(-\frac{x^2}{2\theta^2} \right), \quad x > 0.$$

1. Demostrar que la familia de distribuciones $\{f_\theta : \theta \in \mathbb{R}^+\}$ es una familia exponencial uniparamétrica.

   Comprobamos las condiciones de la definición de familia exponencial uniparamétrica:

   - El espacio paramétrico es $\Theta = \mathbb{R}^+$ intervalo de $\mathbb{R}$.
   - El espacio muestral es $\mathcal{X} = \mathbb{R}^+$, el cual no depende del parámetro θ.
   - Para cada $\theta \in \Theta$ y $x \in \mathcal{X}$, expresamos la función de densidad en forma exponencial:

   $$f_\theta(x) = \frac{x}{\theta^2} \exp\left(-\frac{x^2}{2\theta^2} \right) = \exp\left(\ln\left(\frac{x}{\theta^2} \exp\left(-\frac{x^2}{2\theta^2} \right) \right) \right) =$$
   $$= \exp\left(-\frac{1}{2\theta^2} x^2 - 2\ln(\theta) + \ln(x) \right).$$

   Identificando términos con la estructura canónica:

   $$Q(\theta) = -\frac{1}{2\theta^2}, \quad T(x) = x^2, \quad D(\theta) = -2\ln(\theta), \quad S(x) = \ln(x).$$

   Por tanto, la familia $\{f_\theta : \theta > 0\}$ es una familia exponencial uniparamétrica.

2. Obtener de forma justificada un estadístico suficiente y completo para el parámetro θ.

   Aplicamos el teorema de las familias exponenciales para muestras aleatorias simples:

- Al ser la familia individual exponencial uniparamétrica, el estadístico:

$$T^*(X_1,\dots,X_n)=\sum_{i=1}^n T(X_i)=\sum_{i=1}^n X_i^2$$

es suficiente para el parámetro θ.

- Para la completitud, como Q es una función continua y no constante definida en un intervalo, su imagen $\operatorname{Im} Q$ contiene un abierto de $\mathbb{R}$. Por lo tanto, el estadístico $T^*(X_1,\dots,X_n)$ también es completo para θ.

En consecuencia, por el teorema de las familias exponenciales, el estadístico $T^*(X_1,\dots,X_n)=\sum_{i=1}^n X_i^2$ es suficiente y completo para θ.

Ejercicio 2.3.10 (Reto)**.** Sea $(X_1,\dots,X_n)$ una muestra aleatoria simple de una variable aleatoria continua X con función de densidad:

$$f_\theta(x)=\frac{4x^3}{(\theta-1)^4}\qquad 0<x<\theta-1\qquad \theta>1$$

Calcular un estadístico T suficiente y completo para θ.

Buscamos un estadístico suficiente aplicando el Teorema de Factorización de Neyman-Fisher. Para ello, consideremos la función de densidad conjunta de la muestra $(X_1,\dots,X_n)$:

$$f_\theta(x_1,\dots,x_n)=\prod_{i=1}^n f_\theta(x_i)=\prod_{i=1}^n\frac{4x_i^3}{(\theta-1)^4}=\frac{4^n}{(\theta-1)^{4n}}\prod_{i=1}^n x_i^3\qquad \forall x_i\in\,]0,\theta-1[$$

Ha de ser por tanto:

- $\theta-1>x_i\quad\forall i\in\{1,\dots,n\}$, es decir, $\theta-1>X_{(n)}$, luego $X_{(n)}-(\theta-1)<0$, luego hemos de incluir $\mathrm{I}_{]-\infty,0[}(X_{(n)}-(\theta-1))$.
- $x_i>0\quad\forall i\in\{1,\dots,n\}$, es decir, $X_{(1)}>0$, luego hemos de incluir $\mathrm{I}_{]0,\infty[}(X_{(1)})$.

Por tanto:

$$f_\theta(x_1,\dots,x_n)=\frac{4^n}{(\theta-1)^{4n}}\prod_{i=1}^n x_i^3\ \mathrm{I}_{]0,\infty[}(x_{(1)})\ \mathrm{I}_{]-\infty,0[}(x_{(n)}-(\theta-1))$$

Identificando términos con la estructura canónica:

$$h(x_1,\dots,x_n)=4^n\prod_{i=1}^n x_i^3\ \mathrm{I}_{]0,\infty[}(x_{(1)})$$
$$T(X_1,\dots,X_n)=X_{(n)}$$
$$g_\theta(t)=\frac{1}{(\theta-1)^{4n}}\,\mathrm{I}_{]-\infty,0[}(t-(\theta-1))$$

Por el Teorema de Factorización de Neyman-Fisher, $T(X_1, \ldots, X_n) = X_{(n)}$ es suficiente para θ.

Veamos ahora que T es completo. Sea g una función medible tal que:

$$E_\theta[g(T)] = 0 \qquad \forall \theta \in]1, +\infty[$$

Calculamos la función de distribución de T. Para todo $t \in \mathbb{R}$:

$$F_T(t) = P[T \leqslant t] = P[X_{(n)} \leqslant t] = P[X_1 \leqslant t, \ldots, X_n \leqslant t] = \prod_{i=1}^{n} P[X_i \leqslant t] = \prod_{i=1}^{n} F_\theta(t) = (F_\theta(t))^n$$

Calculamos ahora la función de distribución de X:

$$F_\theta(t) = \int_0^t f_\theta(x)\ dx = \int_0^t \frac{4x^3}{(\theta-1)^4}\ dx = \left[\frac{x^4}{(\theta-1)^4}\right]_0^t = \frac{t^4}{(\theta-1)^4} \qquad 0 < t < \theta - 1$$

Por tanto, tenemos que la función de densidad de T es:

$$f_T(t) = n(F_\theta(t))^{n-1} f_\theta(t) = n\frac{t^{4(n-1)}}{(\theta-1)^{4(n-1)}}\frac{4t^3}{(\theta-1)^4} = \frac{4nt^{4n-1}}{(\theta-1)^{4n}} \qquad 0 < t < \theta - 1$$

Por tanto, calculamos la esperanza de $g(T)$:

$$0 = E_\theta[g(T)] = \int_0^{\theta-1} g(t) f_T(t)\ dt = \int_0^{\theta-1} g(t)\frac{4nt^{4n-1}}{(\theta-1)^{4n}}\ dt = \frac{4n}{(\theta-1)^{4n}}\int_0^{\theta-1} g(t)t^{4n-1}\ dt$$

Por tanto, tenemos que:

$$\int_0^{\theta-1} g(t)t^{4n-1}\ dt = 0 \qquad \forall \theta \in]1, +\infty[$$

Aunque g es medible, podemos aplicar el Teorema Fundamental del Cálculo, luego derivando:

$$g(\theta-1)(\theta-1)^{4n-1} = 0 \qquad \forall \theta \in]1, +\infty[$$

Como $\theta - 1 > 0$, podemos dividir entre $(\theta-1)^{4n-1}$, obteniendo:

$$g(\theta-1) = 0 \qquad \forall \theta \in]1, +\infty[$$

Esto implica que $g(t) = 0$ para todo $t > 0$, luego:

$$\mathbb{R}^+ \subseteq \{t \in \mathbb{R} : g(t) = 0\}$$

Por tanto:

$$1 \geqslant P[g(T) = 0] \geqslant P[T \in \mathbb{R}^+] = 1 \Longrightarrow P[g(T) = 0] = 1$$

Por tanto, T es completo.

2.4. Estimación puntual. Insesgadez y mínima varianza

Ejercicio 2.4.1. Sea $(X_1, \ldots, X_n)$ una muestra de una variable $X \rightsquigarrow \mathcal{N}(\mu, \sigma^2)$ con $\mu \in \mathbb{R}$, $\sigma \in \mathbb{R}^+$. Probar que

$$T(X_1, \ldots, X_n) = \begin{cases} 1 & \text{si } \overline{X} \leqslant 0 \\ 0 & \text{si } \overline{X} > 0 \end{cases}$$

es un estimador insesgado de la función paramétrica $\Phi\left(\frac{-\mu\sqrt{n}}{\sigma}\right)$, siendo Φ la función de distribución de la $\mathcal{N}(0,1)$.

Tenemos $T(X_1, \ldots, X_n) = I_{]-\infty,0]}(\overline{X})$. Como $X \rightsquigarrow \mathcal{N}(\mu, \sigma^2)$, sabemos por lo visto en el Tema 1 que entonces:

$$\overline{X} \rightsquigarrow \mathcal{N}\left(\mu, \frac{\sigma^2}{n}\right)$$

de donde (escribiendo $T = T(X_1, \ldots, X_n)$):

$$T = I_{]-\infty,0]}(\overline{X}) \rightsquigarrow \mathcal{B}(1, P[\overline{X} \leqslant 0])$$

Estamos ya en condiciones de ver que T es insesgado para dicha función:

$$E[T] \overset{(*)}{=} P[\overline{X} \leqslant 0] \overset{\text{tipif.}}{=} P\left[Z \leqslant \frac{-\mu\sqrt{n}}{\sigma}\right] = \Phi\left(\frac{-\mu\sqrt{n}}{\sigma}\right)$$

donde en $(*)$ usamos que conocemos bien la esperanza de una distribución Bernoulli.

Ejercicio 2.4.2. Sea $(X_1, \ldots, X_n)$ una muestra aleatoria simple de $X \rightsquigarrow \mathcal{B}(1,p)$ con $p \in]0,1[$ y sea $T = \sum_{i=1}^{n} X_i$.

1. Probar que si $k \in \mathbb{N}$ y $k \leqslant n$, el estadístico

$$\frac{T(T-1)\cdot \ldots \cdot (T-k+1)}{n(n-1)\cdot \ldots \cdot (n-k+1)}$$

es un estimador insesgado de p^k. ¿Es este estimador el UMVUE?

Sea $k \in \mathbb{N}$ con $k \leqslant n$, definimos:

$$h(T) = \frac{T(T-1)\cdot \ldots \cdot (T-k+1)}{n(n-1)\cdot \ldots \cdot (n-k+1)} = \prod_{j=0}^{k-1} \frac{T-j}{n-j}$$

Veamos en primer lugar que $h(T)$ es un estimador de p^k. Como $p \in]0,1[$, tenemos que $p^k \in]0,1[$, por lo que basta ver que $h(T) \in [0,1]$ para todo valor de T. Sabemos que $T \in \{0,1,\ldots,n\}$, para todo $j \in \{0,\ldots,k-1\}$, por lo que:

- Si $T \in \{0,\ldots,k-1\}$, entonces $T - j = 0$ para algún $j \in \{0,\ldots,k-1\}$, por lo que el producto se anula y $h(T) = 0$.

- Si $T \in \{k, \ldots, n\}$, entonces $T - j > 0$ para todo $j \in \{0, \ldots, k-1\}$, por lo que el producto es positivo. Además, como $T \leqslant n$, tenemos que $T - j \leqslant n - j$ para todo $j \in \{0, \ldots, k-1\}$, de donde deducimos que:

$$\frac{T-j}{n-j} \leqslant 1 \quad \Longrightarrow \quad \prod_{j=0}^{k-1} \frac{T-j}{n-j} \leqslant 1$$

Por tanto, $h(T) \in [0,1]$ para todo T, por lo que $h(T)$ es un estimador de p^k. Veamos que $h(T)$ es insesgado para p^k. En primer lugar, observemos que por la reproductividad de la binomial $T \rightsquigarrow \mathcal{B}(n,p)$:

$$E[h(T)] = \frac{E[T(T-1)\cdot \ldots \cdot (T-k+1)]}{n(n-1)\cdot \ldots \cdot (n-k+1)} = \frac{(n-k)!}{n!} E[T(T-1)\cdot \ldots \cdot (T-k+1)]$$

Calculamos ahora la esperanza:

$$\begin{aligned}
E[T(T-1)\cdot \ldots \cdot (T-k+1)] &= \sum_{t=0}^{n} t(t-1)\cdot \ldots \cdot (t-k+1) P[T=t] \\
&= \sum_{t=0}^{n} t(t-1)\cdot \ldots \cdot (t-k+1) \binom{n}{t} p^t (1-p)^{n-t} \\
&= \sum_{t=k}^{n} t(t-1)\cdot \ldots \cdot (t-k+1) \binom{n}{t} p^t (1-p)^{n-t} \\
&= \sum_{t=k}^{n} \frac{t!}{(t-k)!} \frac{n!}{t!(n-t)!} p^t (1-p)^{n-t} \\
&= \sum_{t=k}^{n} \frac{n!}{(t-k)!(n-t)!} p^t (1-p)^{n-t}
\end{aligned}$$

Si desarrollamos ahora los primeros términos, observamos que:

$$\begin{aligned}
E[T(T-1)\cdot \ldots \cdot (T-k+1)] &= \sum_{t=k}^{n} \frac{n!}{(t-k)!(n-t)!} p^t (1-p)^{n-t} \\
&= \frac{n!}{(n-k)!} p^k (1-p)^{n-k} + \frac{n!}{(n-k-1)!} p^{k+1} (1-p)^{n-k-1} + \ldots
\end{aligned}$$

donde podemos ver que podemos sacar factor común de la sumatoria ciertos

términos:

$$E[T(T-1)\cdot\ldots\cdot(T-k+1)] = \sum_{t=k}^{n} \frac{n!}{(t-k)!(n-t)!} p^t (1-p)^{n-t}$$
$$= \frac{n!\cdot p^k}{(n-k)!} \sum_{t=k}^{n} p^{t-k}(1-p)^{n-t} \frac{(n-k)!}{(t-k)!(n-t)!}$$
$$= \frac{n!\cdot p^k}{(n-k)!} \sum_{t=0}^{n-k} p^{t}(1-p)^{n-k-t} \frac{(n-k)!}{t!(n-k-t)!}$$
$$= \frac{n!\cdot p^k}{(n-k)!} \sum_{t=0}^{n-k} \binom{n-k}{t} p^t (1-p)^{n-k-t}$$
$$= \frac{n!\cdot p^k}{(n-k)!} \sum_{t=0}^{n-k} P[S=t] = \frac{n!\cdot p^k}{(n-k)!} P[0 \leqslant S \leqslant n-k] \overset{(*)}{=} \frac{n!\cdot p^k}{(n-k)!}$$

para cierta variable aleatoria $S \rightsquigarrow \mathcal{B}(n-k,p)$, donde en $(*)$ usamos que $P[0 \leqslant S \leqslant n-k] = 1$. Ahora, vemos que:

$$E[h(T)] = \frac{(n-k)!}{n!} \frac{n!}{(n-k)!} p^k = p^k$$

por lo que $h(T)$ es insesgado para p^k.

Veamos ahora que $h(T)$ es el UMVUE de p^k. Para ello, veamos en primer lugar que T es un estadístico suficiente y completo. Veamos que $\{\mathcal{B}(1,p) : p \in]0,1[\}$ es una familia exponencial:

a) El espacio paramétrico es $]0,1[\subseteq \mathbb{R}$.

b) El soporte es $\chi = \{0,1\}$, que no depende de p.

c) Observamos que:

$$P_p[X=x] = p^x(1-p)^{1-x} = \exp\left[\ln\left(p^x(1-p)^{1-x}\right)\right] = \exp\left[x\ln p + (1-x)\ln(1-p)\right] =$$
$$= \exp\left[x\ln\frac{p}{1-p} + \ln(1-p)\right]$$

por lo que basta tomar:

$$Q(p) = \ln\frac{p}{1-p}, \qquad T(x) = x, \qquad D(p) = \ln(1-p), \qquad S(x) = 0$$

Por tanto, $\{\mathcal{B}(1,p) : p \in]0,1[\}$ es una familia exponencial. Por tanto, $T(X_1,\ldots,X_n) = \sum_{i=1}^{n} X_i$ es un estadístico suficiente. Además, como Q es una aplicación continua no constante definida en un conexo, $Q(]0,1[)$ es un conexo no trivial de $\mathbb{R}$, por lo que es un intervalo abierto, y por tanto T es un estadístico completo. Por último, veamos que $h(T)$ tiene momento de segundo orden finito:

$$E\left[(h(T))^2\right] = \sum_{t=0}^{n} (h(t))^2 P[T=t] < \infty$$

Por tanto, por el Teorema de Lehmann-Scheffé, $h(T)$ es el UMVUE de p^k.

2. Probar que si $k > n$, no existe ningún estimador insesgado para p^k.

   Sea ahora $k > n$, veamos que no puede existir ningun estimador insesgado para p^k. Para ello, por reducción al absurdo, supongamos que $h(T)$ es un estimador insesgado para p^k, con lo que:

   $$p^k = E[h(T)] = \sum_{t=0}^{n} h(t)P[T=t] = \sum_{t=0}^{n} h(t)\binom{n}{t}p^t(1-p)^{n-t}$$

   de donde:

   $$1 = \sum_{t=0}^{n} h(t)\binom{n}{t}p^{t-k}(1-p)^{n-t} \qquad \forall p \in]0,1[$$

   en particular, tomando $p \to 0$, como $t - k < 0$ para todo $t \in \{0, \dots, k\}$, tenemos que:

   $$1 = \lim_{p\to 0} \sum_{t=0}^{n} h(t)\binom{n}{t}p^{t-k}(1-p)^{n-t} = \infty$$

   contradicción, con lo que para $k > n$ no puede existir un estimador insesgado para p^k. También podríamos haber justificado que son dos polinomios de distinto grado, para llegar a contradicción.

3. ¿Puede afirmarse que $\frac{T}{n}\left(1 - \frac{T}{n}\right)^2$ es insesgado para $p(1-p)^2$?

   Buscamos ahora comprobar si $h(T) = \frac{T}{n}\left(1 - \frac{T}{n}\right)^2$ es insesgado para $p(1-p)^2$.

   $$E[h(T)] = \sum_{t=0}^{n} \frac{t}{n}\left(1 - \frac{t}{n}\right)^2 \binom{n}{t}p^t(1-p)^{n-t} \overset{(*)}{=} \sum_{t=1}^{n-1} \frac{t}{n}\left(1 - \frac{t}{n}\right)^2 \binom{n}{t}p^t(1-p)^{n-t}$$

   donde en $(*)$ hemos usado que la función $t \mapsto \frac{t}{n}\left(1 - \frac{t}{n}\right)^2$ evaluada en 0 y n es igual a cero. Sospechando que no es insesgado, vamos a tomar $n = 2$ para ver si se cumple la igualdad (por ser un caso más sencillo):

   $$E[h(T)] = \frac{1}{2}\left(1 - \frac{1}{2}\right)^2 \binom{2}{1}p(1-p)^1 = \frac{p(1-p)}{4} \qquad \forall p \in]0,1[$$

   Por tanto, para que $h(T)$ sea insesgado para $p(1-p)^2$, tendríamos que tener:

   $$E[h(T)] = \frac{p(1-p)}{4} = p(1-p)^2 \iff \frac{1}{4} = 1 - p \iff p = \frac{3}{4}$$

   Esto no es cierto para todo $p \in]0,1[$, por lo que dicho estimador no es insesgado para $p(1-p)^2$.

Ejercicio 2.4.3. Sea $(X_1, \dots, X_n)$ una muestra aleatoria simple de una variable $X \rightsquigarrow \mathcal{P}(\lambda)$ con $\lambda \in \mathbb{R}^+$. Encontrar, si existe, el UMVUE para λ^s, siendo $s \in \mathbb{N}$ arbitrario.

Observación. Resuelto de otra forma distinta en el Ejemplo de la página 38.

Veamos que $T(X_1, \ldots, X_n) = \sum_{i=1}^{n} X_i$ es un estadístico suficiente y completo. Para ello, recordemos que $\{\mathcal{P}(\lambda) : \lambda > 0\}$ es una familia exponencial:

1. El espacio paramétrico es $\mathbb{R}^+ \subseteq \mathbb{R}$.
2. El espacio muestral es $\mathcal{X} = \mathbb{N} \cup \{0\}$, que no depende de λ.
3. Observamos que:

$$P_\lambda[X = x] = e^{-\lambda}\frac{\lambda^x}{x!} = \exp\left[\ln\left(e^{-\lambda}\frac{\lambda^x}{x!}\right)\right] = \exp\left(-\lambda + x\ln\lambda - \ln(x!)\right)$$

por lo que basta tomar:

$$Q(\lambda) = \ln\lambda, \qquad T(x) = x \qquad D(\lambda) = -\lambda, \qquad S(x) = -\ln(x!)$$

En consecuencia, por un Teorema visto en teoría, tenemos que el estadístico:

$$T(X_1, \ldots, X_n) = \sum_{i=1}^{n} T(X_i) = \sum_{i=1}^{n} X_i$$

es suficiente y completo para λ. Observemos que por la reproductividad de la Poisson tenemos que (notando $T = T(X_1, \ldots, X_n)$):

$$T \rightsquigarrow \mathcal{P}\left(\sum_{i=1}^{n} \lambda\right) \equiv \mathcal{P}(n\lambda)$$

Ahora, para buscar el UMVUE, buscamos una función h medible de forma que:

$$\lambda^s = E[h(T)] = \sum_{t\in\mathbb{N}\cup\{0\}} h(t)P[T = t] = \sum_{t\in\mathbb{N}\cup\{0\}} h(t)e^{-n\lambda}\frac{(n\lambda)^t}{t!}$$

por lo que:

$$\lambda^s e^{n\lambda} = \sum_{t\in\mathbb{N}\cup\{0\}} h(t)\frac{(n\lambda)^t}{t!}$$

y si aplicamos el desarrollo en serie de la exponencial, obtenemos:

$$\lambda^s \sum_{t\in\mathbb{N}\cup\{0\}} \frac{(n\lambda)^t}{t!} = \lambda^s e^{n\lambda} = \sum_{t\in\mathbb{N}\cup\{0\}} h(t)\frac{(n\lambda)^t}{t!}$$

Si desarrollamos cada uno de los términos:

$$\lambda^s + \lambda^{s+1}n + \frac{\lambda^{s+2}n^2}{2!} + \ldots = h(0) + h(1)(n\lambda) + \ldots + h(s)\frac{(n\lambda)^s}{s!} + \ldots$$

Observamos que, tomando:

$$h(0) = \ldots = h(s-1) = 0, \quad h(s) = \frac{s!}{n^s}$$
$$h(s+1) = \frac{(s+1)!}{n^s}, \quad \ldots \quad h(s+k) = \frac{(s+k)!}{n^s k!}$$

es decir, tomando:

$$h(T) = \begin{cases} 0 & \text{si } T < s \\ \dfrac{T!}{n^s(T-s)!} & \text{si } T \geqslant s \end{cases}$$

tenemos que $h(T)$ es insesgado para λ^s. Es claro además que $h(t) \in \mathbb{R}^+$ para cualquier valor de t, con lo que $h(T)$ es un estimador de λ^s. Finalmente, observemos que:

$$\begin{aligned} E\left[(h(T))^2\right] &= \sum_{t\in\mathbb{N}\cup\{0\}} (h(t))^2 P[T=t] = \sum_{t\geqslant s} \left(\frac{t!}{n^s(t-s)!}\right)^2 e^{-n\lambda}\frac{(n\lambda)^t}{t!} \\ &= \frac{1}{n^s e^{n\lambda}} \sum_{t\geqslant s} \frac{(n\lambda)^t t!}{((t-s)!)^2} \end{aligned}$$

como:

$$\frac{\dfrac{(n\lambda)^{t+1}(t+1)!}{((t+1-s)!)^2}}{\dfrac{(n\lambda)^t t!}{((t-s)!)^2}} = \frac{(n\lambda)^{t+1}(t+1)!((t-s)!)^2}{(n\lambda)^t t!((t+1-s)!)^2} = \frac{n\lambda(t+1)}{(t+1-s)^2} \to 0 < 1$$

por el Criterio del cociente, tenemos que:

$$\sum_{t\geqslant s} \frac{(n\lambda)^t t!}{((t-s)!)^2} < \infty \Longrightarrow E\left[(h(T))^2\right] = \frac{1}{n^s e^{n\lambda}} \sum_{t\geqslant s} \frac{(n\lambda)^t t!}{((t-s)!)^2} < \infty$$

en consecuencia, tenemos que $h(T)$ es un estimador insesgado para λ^s y de momento de segundo orden finito y es función de un estadístico suficiente y completo, con lo que el Teorema de Lehmann-Scheffé nos dice que:

$$E[h(T)/T] = h(T)$$

es un UMVUE para λ^s.

Ejercicio 2.4.4. Sea $(X_1, \ldots, X_n)$ una muestra aleatoria simple de una variable con distribución uniforme discreta en los puntos $\{1, \ldots, N\}$, siendo N un número natural arbitrario. Encontrar el UMVUE para N.

En el Ejercicio 2.3.5 vimos que $T(X_1, \ldots, X_n) = X_{(n)}$ era un estadístico suficiente y completo. Si notamos $T = T(X_1, \ldots, X_n)$, tenemos que:

$$F_T(t) = (F_X(t))^n \Longrightarrow P[T=t] = P[T \leqslant t] - P[T \leqslant t-1] = (F_X(t))^n - (F_X(t-1))^n$$

como $F_X(t) = \frac{t}{N}$ para $t \in \{1, \ldots, N\}$, tenemos:

$$P[T=t] = (F_X(t))^n - (F_X(t-1))^n = \frac{t^n - (t-1)^n}{N^n}$$

Buscamos ahora una función h medible de forma que:

$$N = E[h(T)] = \sum_{t=1}^{N} h(t)P[T=t] = \sum_{t=1}^{N} h(t)\frac{t^n-(t-1)^n}{N^n} \Longrightarrow N^{n+1} = \sum_{t=1}^{N} h(t)(t^n-(t-1)^n)$$

Opción 1 Si desarrollamos la suma para $h(t) = 1$, observamos un comportamiento telescópico:

$$\sum_{t=1}^{N}(t^n - (t-1)^n) = N^n - (N-1)^n + (N-1)^n - (N-2)^n + \ldots + 2^n - 1 + 1 - 0$$
$$= N^n$$

No hemos obteniedo lo que queríamos, puesto que queríamos que el resultado de la suma fuera N^{n+1}. No obstante, nuestro objetivo es que cada sumando del término general tenga exponente $n+1$, por lo que podemos intentar con:

$$h(t) = \frac{t^{n+1} - (t-1)^{n+1}}{t^n - (t-1)^n}$$

Opción 2 Este resultado ha de ser válido para todo $N \in \mathbb{N}$.

- Para N:
$$N^{n+1} = \sum_{t=1}^{N} h(t)(t^n - (t-1)^n)$$
- Para $N-1$:
$$(N-1)^{n+1} = \sum_{t=1}^{N-1} h(t)(t^n - (t-1)^n)$$

Restando ambas ecuaciones, obtenemos:

$$N^{n+1} - (N-1)^{n+1} = h(N)(N^n - (N-1)^n) \Longrightarrow h(N) = \frac{N^{n+1} - (N-1)^{n+1}}{N^n - (N-1)^n}$$

y como esto ha de cumplirse para todo $N \in \mathbb{N}$, tenemos que:

$$h(t) = \frac{t^{n+1} - (t-1)^{n+1}}{t^n - (t-1)^n}$$

En cualquier caso, tenemos que:

$$E[h(T)] = \frac{1}{N^n}\sum_{t=1}^{N} h(t)(t^n - (t-1)^n) = \frac{1}{N^n}\sum_{t=1}^{N} t^{n+1} - (t-1)^{n+1} = \frac{N^{n+1}}{N^n} = N$$

Por lo que el estadístico $h(T)$ es insesgado para N. Nos falta comprobar si es un estimador y si tiene momento de segundo orden finito:

- No es estimador, puesto que $h(\mathbb{N}) \nsubseteq \mathbb{N}$. Sin embargo, podemos realizar aproximaciones y quedarnos con el natural más próximo. Es decir, no va a haber un UMVUE pero podemos quedarnos con este estadístico, que es aquello que podemos conseguir más próximo a un UMVUE.

- Para el momento de segundo orden, observamos que:

$$E[(h(T))^2] = \frac{1}{N^n}\sum_{t=1}^{N}(h(t))^2(t^n-(t-1)^n) < \infty$$

al ser una suma finita.

Ejercicio 2.4.5. Sea $(X_1,\ldots,X_n)$ una muestra aleatoria simple de una variable aleatoria X cuya función de densidad es de la forma

$$f_\theta(x) = \frac{1}{2\sqrt{x\theta}}, \quad 0<x<\theta$$

Calcular, si existe, el UMVUE para θ.

En primer lugar, buscamos un estadístico suficiente y completo:

$$f_\theta^n(x_1,\ldots,x_n) \overset{\text{iid.}}{=} \prod_{i=1}^{n} f_\theta(x_i) = \prod_{i=1}^{n}\frac{1}{2\sqrt{x_i\theta}} = \frac{1}{\left(2\sqrt{\theta}\right)^n}\prod_{i=1}^{n}\frac{1}{\sqrt{x_i}} \qquad x_i \in]0,\theta[$$

Si consideramos $0 < X_{(1)} \leqslant X_{(n)} < \theta$, podemos escribir:

$$f_\theta^n(x_1,\ldots,x_n) = \frac{I_{]0,+\infty[}(X_{(1)}-0)\cdot I_{]-\infty,0[}(X_{(n)}-\theta)}{\left(2\sqrt{\theta}\right)^n}\prod_{i=1}^{n}\frac{1}{\sqrt{x_i}}$$

Tomando:

$$h(x_1,\ldots,x_n) = \prod_{i=1}^{n}\frac{1}{\sqrt{x_i}}\cdot I_{]0,+\infty[}(X_{(1)}-0), \qquad T(X_1,\ldots,X_n) = X_{(n)}$$

$$g_\theta(t) = \frac{I_{]-\infty,0[}(t-\theta)}{\left(2\sqrt{\theta}\right)^n}$$

por el Teorema de factorización de Neymann-Fisher tenemos que el estadístico $X_{(n)}$ es suficiente para θ. Buscamos ahora ver que es completo. Notando $T = X_{(n)}$ para abreviar, calculamos la distribución de T:

$$F_T(t) = (F_X(t))^n \quad \Longrightarrow \quad f_T(t) = n(F_X(t))^{n-1}f_\theta(t)$$

Calculamos la distribución de X:

$$F_X(t) = \int_0^t \frac{1}{2\sqrt{x\theta}}\,dx = \frac{1}{2\sqrt{\theta}}\int_0^t \frac{1}{\sqrt{x}}\,dx = \sqrt{\frac{t}{\theta}} \qquad t \in]0,\theta[$$

Por lo que:

$$f_T(t) = n(F_X(t))^{n-1}f_\theta(t) = n\left(\sqrt{\frac{t}{\theta}}\right)^{n-1}\frac{1}{2\sqrt{t\theta}} = \frac{n\left(\sqrt{t}\right)^{n-2}}{2\left(\sqrt{\theta}\right)^n} \qquad t \in]0,\theta[$$

Sea ahora h una función medible de forma que:

$$0 = E[h(T)] = \int_0^\theta h(t) f_T(t)\ dt = \frac{n}{2\Big(\sqrt{\theta}\Big)^n} \int_0^\theta h(t) \Big(\sqrt{t}\Big)^{n-2}\ dt \qquad \forall \theta \in \mathbb{R}^+$$

Tenemos entonces que:

$$\int_0^\theta h(t) \Big(\sqrt{t}\Big)^{n-2}\ dt = 0 \qquad \forall \theta \in \mathbb{R}^+$$

Aunque h no sea continua, podemos aplicar el Teorema Fundamental del Cálculo. Derivando respecto a θ:

$$h(\theta) \Big(\sqrt{\theta}\Big)^{n-2} = 0 \Longrightarrow h(\theta) = 0 \qquad \forall \theta \in \mathbb{R}^+$$

En conclusión, tenemos que:

$$\mathbb{R}^+ \subseteq \{t : h(t) = 0\}$$

Por lo que:

$$1 \geqslant P[h(T) = 0] \geqslant P[T \in \mathbb{R}^+] = 1 \quad \Longrightarrow \quad P[h(T) = 0] = 1$$

lo que demustra que T es un estadístico completo. Ahora, tratamos de buscar un estimador insesgado para θ, que será nuestro candidato a UMVUE. Buscamos una función medible h de forma que:

$$\theta = E[h(T)] = \frac{n}{2\Big(\sqrt{\theta}\Big)^n} \int_0^\theta h(t) \Big(\sqrt{t}\Big)^{n-2}\ dt \Longrightarrow \frac{2}{n}\theta^{\frac{n}{2}+1} = \int_0^\theta h(t) \Big(\sqrt{t}\Big)^{n-2}\ dt$$

De igual manera que antes, derivando respecto a θ:

$$\frac{2}{n}\left(\frac{n}{2}+1\right)\theta^{\frac{n}{2}} = h(\theta)\Big(\sqrt{\theta}\Big)^{n-2} \Longrightarrow h(\theta) = \frac{2}{n}\left(\frac{n}{2}+1\right)\theta^{\frac{n}{2}}\Big(\sqrt{\theta}\Big)^{2-n} = \frac{n+2}{n}\cdot\theta$$

Por tanto, tomamos:

$$h(t) = \frac{n+2}{n}\cdot t$$

De esta manera, tenemos que:

$$\begin{aligned} E[h(T)] &= \int_0^\theta \frac{n+2}{n} t \frac{n}{2} \frac{\big(\sqrt{t}\big)^{n-2}}{\Big(\sqrt{\theta}\Big)^n}\ dt = \frac{n+2}{2\Big(\sqrt{\theta}\Big)^n} \int_0^\theta t \Big(\sqrt{t}\Big)^{n-2}\ dt \\ &= \frac{n+2}{2\Big(\sqrt{\theta}\Big)^n} \int_0^\theta \Big(\sqrt{t}\Big)^n\ dt = \frac{n+2}{2\Big(\sqrt{\theta}\Big)^n} \frac{2}{n+2} \Big(\sqrt{\theta}\Big)^n \theta = \theta \qquad \forall \theta \in \mathbb{R}^+ \end{aligned}$$

Por lo que $h(T)$ es insesgado para θ. Ahora, si $t \in \mathbb{R}^+$, tendremos entonces que:

$$h(t) = \frac{n+2}{n}\cdot t \geqslant t \in \mathbb{R}^+ \quad \Longrightarrow \quad h(t) \in \mathbb{R}^+$$

por lo que $h(T)$ es además un estimador. Si calculamos ahora:

$$E\left[(h(T))^2\right] = \frac{n}{2\left(\sqrt{\theta}\right)^n}\int_0^\theta (h(t))^2(\sqrt{t})^{n-2}\,dt$$

Tenemos la integral en un compacto de una función continua, por lo que sabemos que $E[(h(T))^2] < \infty$. En conclusión, tenemos por el Teorema de Lehmann-Scheffé que: $E[h(T)/T] = h(T)$ es el UMVUE.

Ejercicio 2.4.6. Sea $(X_1, \ldots, X_n)$ una muestra aleatoria simple de una variable aleatoria X con función de densidad

$$f_\theta(x) = \frac{\theta}{x^2}, \quad x > \theta > 0$$

Calcular, si existen, los UMVUE para θ y para $1/\theta$.

Calculamos en primer lugar un estadístico suficiente y completo para θ:

$$f_\theta(x_1, \ldots, x_n) \overset{\text{iid.}}{=} \prod_{i=1}^n f_\theta(x_i) = \prod_{i=1}^n \frac{\theta \cdot I_{]0,+\infty[}(X_{(1)} - \theta)}{x_i^2} = \theta^n \cdot I_{]0,+\infty[}(X_{(1)} - \theta)\prod_{i=1}^n \frac{1}{x_i^2}$$

Tomando:

$$h(x_1, \ldots, x_n) = \prod_{i=1}^n \frac{1}{x_i^2}, \qquad T(X_1, \ldots, X_n) = X_{(1)}$$
$$g_\theta(t) = \theta^n \cdot I_{]0,+\infty[}(t - \theta)$$

Podemos aplicar el Teorema de factorización de Neymann-Fisher, obteniendo que T es suficiente para θ. Notando $T = X_{(1)}$ para abreviar, calculamos la distribución de T:

$$F_T(t) = 1 - (1 - F_X(t))^n \quad \Longrightarrow \quad f_T(t) = n(1 - F_X(t))^{n-1} f_\theta(t)$$

Si calculamos:

$$F_X(t) = \int_\theta^t \frac{\theta}{x^2}\,dx = \theta\int_\theta^t \frac{1}{x^2}\,dx = \theta\left[\frac{-1}{x}\right]_\theta^t = \theta\left(\frac{-1}{t} + \frac{1}{\theta}\right) = \frac{t-\theta}{t} \qquad t > \theta$$

Tenemos que:

$$f_T(t) = n\left(1 - \frac{t-\theta}{t}\right)^{n-1}\frac{\theta}{t^2} = n \cdot \frac{\theta^n}{t^{n+1}}$$

Sea h una función medible de forma que:

$$0 = E[h(T)] = \int_\theta^{+\infty} h(t)f_T(t)\,dt = \lim_{n\to\infty}\int_\theta^n \underbrace{h(t) \cdot n \cdot \frac{\theta^n}{t^{n+1}}}_{(*)}\,dt \qquad \forall\theta \in \mathbb{R}^+$$

Sea $H(t)$ una primitiva de $(*)$, tenemos entonces que:

$$0 = \lim_{n\to\infty} H(n) - H(\theta) \qquad \forall\theta \in \mathbb{R}^+$$

con lo que derivando respecto θ:

$$0 = h(\theta) \cdot n \cdot \frac{\theta^n}{\theta^{n+1}} = h(\theta) \cdot \frac{n}{\theta} \quad \Longrightarrow \quad h(\theta) = 0 \qquad \forall \theta \in \mathbb{R}^+$$

Por lo que:

$$\mathbb{R}^+ \subseteq \{t : h(t) = 0\}$$

de donde:

$$1 \geqslant P[h(T) = 0] \geqslant P[T \in \mathbb{R}^+] = 1 \quad \Longrightarrow \quad P[h(T) = 0] = 1$$

Luego tenemos que T es completo. Si calculamos la esperanza de T:

$$\begin{aligned} E[T] &= \int_\theta^\infty t \cdot n \cdot \frac{\theta^n}{t^{n+1}}\, dt = \int_\theta^{+\infty} \frac{n\theta^n}{t^n}\, dt = n\theta^n \int_\theta^{+\infty} \frac{1}{t^n}\, dt = \frac{-n\theta^n}{n-1} \left[\frac{1}{t^{n-1}}\right]_\theta^\infty \\ &= \frac{n\theta^n}{(n-1)\theta^{n-1}} = \frac{n\theta}{n-1} \end{aligned}$$

Por lo que tomando:

$$h(t) = \frac{n-1}{n} \cdot t$$

tenemos que:

$$E[h(T)] = \frac{n-1}{n} E[T] = \theta$$

Es decir, $h(T)$ es un estadístico insesgado para θ. Veamos que es estimador y que tiene momento de segundo orden:

- Si $t \in \mathbb{R}^+$, tenemos entonces que $h(t) \in \mathbb{R}_0^+$ para $n > 1$, por lo que $h(T)$ es estimador.
- Calculamos para $n > 2$:

$$\begin{aligned} E[(h(T))^2] &= \int_\theta^{+\infty} (h(t))^2 \frac{n\theta^n}{t^{n+1}}\, dt = \left(\frac{n-1}{n}\right)^2 \int_\theta^{+\infty} \frac{n\theta^n t^2}{t^{n+1}}\, dt \\ &= n\theta^n \left(\frac{n-1}{n}\right)^2 \int_\theta^{+\infty} \frac{1}{t^{n-1}}\, dt = n\theta^n \left(\frac{n-1}{n}\right)^2 \left[\frac{1}{(-n+2)t^{n-2}}\right]_\theta^{+\infty} \\ &= n\theta^n \left(\frac{n-1}{n}\right)^2 \frac{1}{(n-2)\theta^{n-2}} = \left(\frac{n-1}{n}\right)^2 \frac{n}{(n-2)} \theta^2 < \infty \end{aligned}$$

Por lo que $h(T) = \frac{n-1}{n} \cdot T$ es UMVUE para θ. Si buscamos ahora un UMVUE para $1/\theta$, observamos que tomando $h(t) = \frac{n+1}{n} \cdot \frac{1}{t}$, tenemos que:

$$\begin{aligned} E[h(T)] &= \int_\theta^{+\infty} h(t) \frac{n\theta^n}{t^{n+1}}\, dt = (n+1)\theta^n \int_\theta^{+\infty} \frac{1}{t^{n+2}}\, dt = (n+1)\theta^n \left[\frac{1}{-(n+1)t^{n+1}}\right]_\theta^{+\infty} \\ &= \frac{\theta^n}{\theta^{n+1}} = \frac{1}{\theta} \end{aligned}$$

por lo que $h(T)$ es insesgado para $1/\theta$. Observamos además que:

- Si $t \in \mathbb{R}^+$, entonces $h(t) \in \mathbb{R}^+$, por lo que $h(T)$ es un estimador.
- Calculamos si $n+3>1$:

$$E[(h(T))^2] = \int_\theta^{+\infty} (h(t))^2 \frac{n\theta^n}{t^{n+1}}\, dt = \frac{\theta^n (n+1)^2}{n} \int_\theta^{+\infty} \frac{1}{t^{n+3}}\, dt$$
$$= \frac{\theta^n (n+1)^2}{n} \left[\frac{1}{-(n+2)t^{n+2}}\right]_\theta^{+\infty} = \frac{(n+1)^2}{n(n+2)\theta^2} < \infty$$

Aplicando el Teorema de Lehmann-Scheffé, tenemos que $E[h(T)/T] = h(T)$ es UMVUE para $1/\theta$.

Ejercicio 2.4.7. Sea $X \rightsquigarrow P_\theta$ siendo P_θ una distribución con función de densidad

$$f_\theta(x) = e^{\theta - x}, \quad x \geqslant \theta$$

Dada una muestra aleatoria simple de tamaño arbitrario, encontrar los UMVUE de θ y de e^θ.

Calculamos en primer lugar un estadístico suficiente y completo para θ:

$$f_\theta(x_1,\dots,x_n) \overset{\text{iid.}}{=} \prod_{i=1}^n f_\theta(x_i) = \prod_{i=1}^n e^{\theta - x_i} \cdot I_{[0,+\infty[}(X_{(1)} - \theta) = I_{[0,+\infty[}(X_{(1)} - \theta) e^{n\theta} \prod_{i=1}^n e^{-x_i}$$

Tomando:

$$h(x_1,\dots,x_n) = \prod_{i=1}^n e^{-x_i}, \qquad T(X_1,\dots,X_n) = X_{(1)}$$
$$g_\theta(t) = I_{[0,+\infty[}(t-\theta)\cdot e^{n\theta}$$

Tenemos por el Teorema de factorización de Neymann-Fisher que $T = X_{(1)}$ es suficiente para θ. Calculamos la distribución de T:

$$F_T(t) = 1 - (1 - F_X(t))^n \quad \Longrightarrow \quad f_T(t) = n(1-F_X(t))^{n-1} f_\theta(t)$$

Si calculamos:

$$F_X(t) = \int_\theta^t e^{\theta - x}\, dx = e^\theta \int_\theta^t e^{-x}\, dx = e^\theta [-e^{-x}]_\theta^t = e^\theta \left(e^{-\theta} - e^{-t}\right) = 1 - e^{\theta - t}, \quad t \geqslant \theta$$

Tenemos entonces que:

$$f_T(t) = n\left(e^{\theta - t}\right)^{n-1} e^{\theta - t} = n\left(e^{\theta - t}\right)^n$$

Sea h una función medible de forma que:

$$0 = E[h(T)] = \int_\theta^{+\infty} h(t) n \left(e^{\theta - t}\right)^n\, dt = n e^{n\theta} \int_\theta^{+\infty} h(t) e^{-nt}\, dt \qquad \forall \theta \in \mathbb{R}$$

Tenemos entonces que:

$$0 = \lim_{n\to\infty} \int_\theta^n h(t) e^{-nt}\, dt \qquad \forall \theta \in \mathbb{R}$$

Sea $H(t)$ una primiriva de $h(t)e^{-nt}$, tenemos que:

$$0 = \lim_{n\to\infty} H(n) - H(\theta) \qquad \forall\theta \in \mathbb{R}$$

derivando respecto θ obtenemos:

$$0 = -h(\theta)e^{-n\theta} \quad \Longrightarrow \quad h(\theta) = 0 \qquad \forall\theta \in \mathbb{R}$$

Por lo que:

$$\mathbb{R} \subseteq \{t : h(t) = 0\}$$

de donde deducimos que T es completo:

$$1 \geqslant P[h(t) = 0] \geqslant P[T \in \mathbb{R}] = 1 \quad \Longrightarrow \quad P[h(t) = 0] = 1$$

Buscamos ahora un estadístico insesgado para θ, es decir, buscamos una función h medible de forma que:

$$\theta = E[h(T)] = \int_\theta^{+\infty} h(t)n(e^{\theta-t})^n \, dt = ne^{n\theta} \int_\theta^{+\infty} h(t)e^{-nt} \, dt$$

Sea $H(t)$ una primitiva de $h(t)e^{-nt}$, tenemos entonces que:

$$\theta = ne^{n\theta}\left(\lim_{n\to\infty} H(n) - H(\theta)\right) \Longrightarrow \frac{\theta}{ne^{n\theta}} = \left(\lim_{n\to\infty} H(n) - H(\theta)\right)$$

y si derivamos a ambos lados:

$$\frac{e^{-n\theta}}{n} - \theta e^{-n\theta} = -h(\theta)e^{-n\theta} \quad \Longrightarrow \quad h(\theta) = \theta - \frac{1}{n}$$

Por lo que si tomamos:

$$h(T) = T - \frac{1}{n}$$

Por la manera de construcción, $h(T)$ es insesgado para θ. Además, se trata de un estimador (puesto que el espacio paramétrico es $\mathbb{R}$). Finalmente, vemos que:

$$Var[h(T)] = Var[T] < \infty \iff E[T^2] < \infty$$

$$E[T^2] = \int_\theta^{+\infty} t^2 n\big(e^{\theta-t}\big)^n \, dt = ne^{n\theta} \int_\theta^{+\infty} t^2 e^{-nt} \, dt$$

Calculamos dicha integral:

$$\begin{aligned}
\int_\theta^{+\infty} t^2 e^{-nt}\,dt &= \lim_{b\to+\infty}\int_\theta^b t^2 e^{-nt}\,dt \\
&= \left\{\begin{array}{ll} u = t^2 & \Longrightarrow\ du = 2t\,dt \\ dv = e^{-nt}\,dt & \Longrightarrow\ v = -\dfrac{1}{n}e^{-nt}\end{array}\right\} \\
&= \lim_{b\to+\infty}\left(\left[-\frac{t^2}{n}e^{-nt}\right]_\theta^b - \int_\theta^b\left(-\frac{1}{n}e^{-nt}\right)(2t)\,dt\right) \\
&= \lim_{b\to+\infty}\left(\left[-\frac{t^2}{n}e^{-nt}\right]_\theta^b + \frac{2}{n}\int_\theta^b te^{-nt}\,dt\right) \\
&= \left\{\begin{array}{ll} u_1 = t & \Longrightarrow\ du_1 = dt \\ dv_1 = e^{-nt}\,dt & \Longrightarrow\ v_1 = -\dfrac{1}{n}e^{-nt}\end{array}\right\} \\
&= \lim_{b\to+\infty}\left(\left[-\frac{t^2}{n}e^{-nt}\right]_\theta^b + \frac{2}{n}\left(\left[-\frac{t}{n}e^{-nt}\right]_\theta^b - \int_\theta^b\left(-\frac{1}{n}e^{-nt}\right)dt\right)\right) \\
&= \lim_{b\to+\infty}\left(\left[-\frac{t^2}{n}e^{-nt}\right]_\theta^b + \frac{2}{n}\left[-\frac{t}{n}e^{-nt}\right]_\theta^b - \frac{2}{n^2}\left[\frac{1}{n}e^{-nt}\right]_\theta^b\right) \\
&= \lim_{b\to+\infty}\left[-e^{-nt}\left(\frac{t^2}{n}+\frac{2t}{n^2}+\frac{2}{n^3}\right)\right]_\theta^b \\
&= \lim_{b\to+\infty}\left(-e^{-nb}\left(\frac{b^2}{n}+\frac{2b}{n^2}+\frac{2}{n^3}\right)\right) - \left(-e^{-n\theta}\left(\frac{\theta^2}{n}+\frac{2\theta}{n^2}+\frac{2}{n^3}\right)\right) \\
&= 0 + e^{-n\theta}\left(\frac{\theta^2}{n}+\frac{2\theta}{n^2}+\frac{2}{n^3}\right) \\
&= \frac{e^{-n\theta}}{n^3}\left(n^2\theta^2+2n\theta+2\right) < \infty
\end{aligned}$$

En definitiva, $E[(h(T))^2] < \infty$, por lo que aplicando el Teorema de Lehmann-Scheffé, obtenemos que $E[h(T)/T] = h(T)$ es UMVUE.

Si buscamos ahora un estadístico insesgado para e^θ, sea h una función medible de forma que:

$$e^\theta = E[h(T)] = \int_\theta^{+\infty} h(t)n(e^{\theta-t})^n\ dt = ne^{n\theta}\int_\theta^{+\infty} h(t)e^{-nt}\ dt$$

Sea $H(t)$ una primitiva de $h(t)e^{-nt}$ tenemos entonces que:

$$e^\theta = ne^{n\theta}\left(\lim_{n\to\infty} H(n) - H(\theta)\right) \Longrightarrow \frac{e^{\theta(1-n)}}{n} = \lim_{n\to\infty} H(n) - H(\theta)$$

y si derivamos a ambos lados:

$$\frac{(1-n)e^{\theta(1-n)}}{n} = -h(\theta)e^{-n\theta} \Longrightarrow h(t) = \frac{n-1}{n}e^t$$

Obtenemos que claramente $h(T)$ es estimador, así como que:

$$E[(h(T))^2] = \int_\theta^{+\infty} \left(\frac{n-1}{n}\right)^2 e^{2t} n e^{n\theta - nt}\, dt = \left(\frac{n-1}{n}\right)^2 n e^{n\theta} \int_\theta^{+\infty} e^{(2-n)t}\, dt$$
$$= \frac{1}{2-n}\left[e^{(2-n)t}\right]_\theta^\infty = \frac{e^{(2-n)\theta}}{n-2} < \infty \qquad \text{si } n > 2$$

Por lo que aplicando el Teorema de Lehmann-Scheffé, obtenemos que $E[h(T)/T] = h(T)$ es UMVUE para e^θ.

Ejercicios de estimadores eficientes

Ejercicio 2.4.8. Sea X la variable que describe el número de fracasos antes del primer éxito en una sucesión de pruebas de Bernoulli con probabilidad de éxito $\theta \in]0,1[$, y sea $(X_1, \ldots, X_n)$ una muestra aleatoria simple de X.

1. Probar que la familia de distribuciones de X es regular y calcular la función de información asociada a la muestra.

   Según el enunciado, "X modela el número de fracasos antes del primer éxito en una sucesión de pruebas de Bernoulli con probabilidad de éxito $\theta \in]0,1[$", por lo que X sigue una distribución geométrica con probabilidad de éxito θ, $X \rightsquigarrow G(\theta)$, $\theta \in]0,1[$. Para ver que la familia de distribuciones de X es regular:

   a) El espacio paramétrico es $\Theta =]0,1[$, un intervalo abierto de $\mathbb{R}$.

   b) El espacio muestral es $\mathcal{X} = \mathbb{N} \cup \{0\}$, que no depende de θ.

   c) Para comprobar la tercera condición, recordamos que la función masa de probabilidad viene dada por:

   $$P_\theta[X = x] = (1-\theta)^x \theta$$

   que es derivable respecto θ. Calculamos la derivada del logaritmo de la función masa de probabilidad:

   $$\ln P_\theta[X = x] = \ln\left((1-\theta)^x \theta\right) = x \ln(1-\theta) + \ln\theta$$
   $$\frac{\partial \ln P_\theta[X = x]}{\partial \theta} = \frac{-x}{1-\theta} + \frac{1}{\theta} = \frac{1-\theta-x\theta}{\theta(1-\theta)}$$

   Y si calculamos su esperanza:

   $$E\left[\frac{1-\theta-X\theta}{\theta(1-\theta)}\right] = \frac{1-\theta-\theta E[X]}{\theta(1-\theta)} \overset{(*)}{=} \frac{1-\theta-(1-\theta)}{\theta(1-\theta)} = 0$$

   donde en $(*)$ usamos que $E[X] = \frac{1-\theta}{\theta}$. En definitiva, se cumple también la tercera condición de las familias regulares.

Calculamos ahora la función de información asociada a la muestra:

$$I_X(\theta) = Var\left(\frac{1-\theta-X\theta}{\theta(1-\theta)}\right) = \frac{\cancel{\theta^2}}{\cancel{\theta^2}(1-\theta)^2} Var(X) \overset{(*)}{=} \frac{1-\theta}{(1-\theta)^2\theta^2} = \frac{1}{\theta^2(1-\theta)}$$

donde en $(*)$ hemos usado que $Var(X) = \frac{1-\theta}{\theta^2}$.

2. Especificar la clase de funciones paramétricas que admiten estimadores eficientes y los correspondientes estimadores.

   Una vez que sabemos que la familia es regular y que $0 < I_X(\theta) < \infty$, lo que hacemos es buscar las funciones $a(\theta)$ y $g(\theta)$ que se usan en el enunciado del Teorema de caracterización de los estimadores eficientes. Para ello:

$$\frac{\partial \ln P_\theta[X_1 = x_1, \ldots, X_n = x_n]}{\partial \theta} = \sum_{i=1}^{n} \frac{\partial \ln P_\theta[X = x_i]}{\partial \theta} = \sum_{i=1}^{n} \left(\frac{1 - \theta - x_i\theta}{\theta(1-\theta)} \right)$$
$$= \frac{n(1-\theta) - \theta \sum_{i=1}^{n} x_i}{\theta(1-\theta)} = \frac{\sum_{i=1}^{n} x_i - \frac{n(1-\theta)}{\theta}}{\theta - 1}$$

   Por lo que tomando:

$$T(X_1, \ldots, X_n) = \sum_{i=1}^{n} X_i, \qquad g(\theta) = \frac{n(1-\theta)}{\theta}, \qquad a(\theta) = \frac{1}{\theta - 1}$$

   Tenemos que $a(\theta) \neq 0 \quad \forall \theta \in]0,1[$, que g es derivable, con:

$$g'(\theta) = \frac{-n}{\theta^2} \neq 0 \qquad \forall \theta \in]0,1[$$

   Además, observamos que:

$$a(\theta)g'(\theta) = \frac{-n}{\theta^2(\theta-1)} = \frac{n}{\theta^2(1-\theta)} = nI_X(\theta) = I_{(X_1,\ldots,X_n)}(\theta) \qquad \forall \theta \in]0,1[$$

   Así como que T es un estimador, pues:

$$T(\mathcal{X}^n) = [0, n] \cap \mathbb{N} \subset g(]0,1[)$$

   Finalmente, por un Corolario visto en teoría sabemos que las únicas funciones paramétricas que admiten estimadores eficientes son de la forma:

$$a \cdot \frac{n(1-\theta)}{\theta} + b, \qquad a, b \in \mathbb{R}, \quad a \neq 0$$

   y que sus estimadores eficientes son de la forma:

$$a \cdot \sum_{i=1}^{n} X_i + b$$

3. Calcular la varianza de cada estimador eficiente y comprobar que coincide con las correspondiente cota de Fréchet-Cramér-Rao.

   Si calculamos ahora la varianza de $T = a \cdot \sum_{i=1}^{n} X_i$ y la cota de Fréchet-Cramér-Rao:

$$Var(T) = Var\left(a \cdot \sum_{i=1}^{n} X_i + b \right) \overset{\text{indep.}}{=} a^2 \sum_{i=1}^{n} Var(X_i) = a^2 \sum_{i=1}^{n} \left(\frac{1-\theta}{\theta^2} \right)$$
$$= \frac{a^2 n(1-\theta)}{\theta^2}$$
$$\frac{(ag'(\theta))^2}{I_{(X_1,\ldots,X_n)}(\theta)} = \frac{\left(\frac{-an}{\theta^2}\right)^2}{\frac{n}{\theta^2(1-\theta)}} = \frac{a^2 n(1-\theta)}{\theta^2}$$

4. Calcular, si existen, los UMVUE para $P_\theta[X=0]$ y para $E_\theta[X]$ y decir si son eficientes.

   - Para $P_\theta[X=0]$:
   $$P_\theta[X=0] = (1-\theta)^0\theta = \theta$$
   Como ya hemos demostrado que $T = \sum_{i=1}^{n} X_i$ es un estimador eficiente para $g(\theta) = \frac{n(1-\theta)}{\theta}$, tenemos automáticamente que T es un estadístico suficiente. Tomando ahora $Q(\theta)$ como una primitiva de $a(\theta)$, por ejemplo $Q(\theta) = \ln(|\theta-1|)$, como:
   $$Q(]0,1[) =]-\infty, 0[$$
   claramente contiene un abierto de $\mathbb{R}$ concluimos que T es completo. Buscamos ahora una función h medible de forma que $h(T)$ sea insesgado para θ, sabiendo que $T \rightsquigarrow BN(n,\theta)$, con función masa de probabilidad:
   $$P_\theta[T=t] = \binom{t+n-1}{t}(1-\theta)^t\theta^n$$
   Buscamos pues una función h medible de forma que:
   $$E[h(T)] = \sum_{t=0}^{\infty} h(t)\frac{(t+n-1)!}{t!(n-1)!}(1-\theta)^t\theta^n = \theta$$
   Es decir, que cumpla (dividiendo todo entre θ):
   $$E[h(T)] = \sum_{t=0}^{\infty} h(t)\frac{(t+n-1)!}{t!(n-1)!}(1-\theta)^t\theta^{n-1} = 1$$
   Notemos que si $Y \rightsquigarrow \mathcal{B}(n-1,\theta)$, tendremos entonces que:
   $$P[Y=t] = \binom{t+n-2}{t}(1-\theta)^t\theta^{n-1} = \frac{(t+n-2)!}{t!(n-2)!}(1-\theta)^t\theta^{n-1}$$
   Por lo que ha de ser (por ser una función masa de probabilidad):
   $$1 = \sum_{t=0}^{\infty} \frac{(t+n-2)!}{t!(n-2)!}(1-\theta)^t\theta^{n-1}$$
   Por tanto, si tomamos:
   $$h(t) = \frac{n-1}{t+n-1}$$
   obtenemos lo buscado. Observamos ahora que:
   - $h(T)$ es un estimador, puesto que $h(T) \in]0,1[$.

- Calculamos su momento de segundo orden:

$$E[(h(t))^2] = \sum_{t=0}^{\infty} (h(t))^2 \frac{(t+n-1)!}{t!(n-1)!}(1-\theta)^t\theta^n$$
$$= \sum_{t=0}^{\infty} \left(\frac{n-1}{t+n-1}\right)^2 \frac{(t+n-1)!}{t!(n-1)!}(1-\theta)^t\theta^n$$

  Como tenemos que $h(t) \in]0,1[$ para todo $t \in \mathbb{N}$, tenemos que $(h(t))^2 \in]0,1[$, por lo que cada sumando de esta nueva serie es menor o igual que cada sumando de la serie $E[h(t)]$, que era convergente, por lo que por el criterio de comparación esta nueva serie también será convergente, $E[(h(t))^2] < \infty$.

En definitiva, el UMVUE para $P_\theta[X=0] = \theta$ es $h(T)$, por el Teorema de Lehmann-Scheffé.

- Para $E_\theta[X]$:

$$E[X] = \frac{1-\theta}{\theta}$$

Por el apartado anterior tenemos ya que $T = \sum_{i=1}^{n} X_i$ es un estadístico suficiente y completo. Buscamos ahora una función h medible tal que $h(T)$ sea insesgado para $\frac{1-\theta}{\theta}$, es decir:

$$E[h(T)] = \sum_{t=0}^{\infty} h(t)\frac{(t+n-1)!}{t!(n-1)!}(1-\theta)^t\theta^n = \frac{1-\theta}{\theta}$$

Escribiendo los términos en el mismo lado para igualar a 1:

$$\sum_{t=0}^{\infty} h(t)\frac{(t+n-1)!}{t!(n-1)!}(1-\theta)^{t-1}\theta^{n+1} = 1 \tag{2.1}$$

Si $Y \rightsquigarrow BN(n+1,\theta)$, entonces:

$$P[Y=t] = \binom{n+t}{t}(1-\theta)^t\theta^{n+1} = \frac{(t+n)!}{t!n!}(1-\theta)^t\theta^{n+1}$$

De donde sabemos que:

$$\sum_{t=0}^{\infty} \frac{(t+n)!}{t!n!}(1-\theta)^t\theta^{n+1} = 1$$

Si sacamos fuera de la suma de (2.1) el primer sumando, tenemos:

$$h(0)\frac{\theta}{1-\theta} + \sum_{t=1}^{\infty} h(t)\frac{(t+n-1)!}{t!(n-1)!}(1-\theta)^{t-1}\theta^{n+1}$$

y podemos comenzar a numerar la serie desde 0:

$$h(0)\frac{\theta}{1-\theta} + \sum_{t=0}^{\infty} h(t+1)\frac{(t+n)!}{(t+1)!(n-1)!}(1-\theta)^t\theta^{n+1}$$

De esta forma, si tomamos:

$$h(t) = \frac{t}{n}$$

tendremos en particular que $h(0) = 0$, con lo que el primer sumando se anula y el segundo coincide con la suma en $\mathbb{N}$ de la función masa de probablidad de una variable aleatoria con distribución binomial negativa, que ha de sumar 1, como queríamos en la igualdad (2.1). Observemos ahora que:

- $h(t) \in [0, 1]$ para todo $t \in \{0, \dots, n\}$, por lo que $h(T)$ es un estimador.
- Para el momento de segundo orden:

$$E[(h(t))^2] = \sum_{t=0}^{\infty} \frac{t^2}{n^2} \frac{(t+n-1)!}{t!(n-1)!} (1-\theta)^t \theta^n$$

Aplicamos el criterio del cociente:

$$\frac{\frac{(t+1)^2(t+n)!}{\cancel{n^2}(t+1)!\cancel{(n-1)!}}(1-\theta)^{t+1}\cancel{\theta^n}}{\frac{t^2(t+n-1)!}{\cancel{n^2}t!\cancel{(n-1)!}}(1-\theta)^t\cancel{\theta^n}} = \frac{(t+1)^2(t+n)!t!(1-\theta)}{(t+1)!t^2(t+n-1)!}$$

$$= \frac{(t+1)^2(t+n)(1-\theta)}{t^2(t+1)} = \frac{(t+1)(t+n)(1-\theta)}{t^2} \to 1-\theta$$

Con $\theta \in]0, 1[$, por lo que $1 - \theta \in]0, 1[$, de donde la serie es convergente.

En definitiva, el UMVUE para $E_\theta[X] = \frac{1-\theta}{\theta}$ es $h(T)$, por el Teorema de Lehmann-Scheffé.

En los apartados anteriores observamos que la familia de funciones paramétricas que admitían estimadores eficientes eran las de la forma:

$$a \cdot \frac{n(1-\theta)}{\theta} + b \qquad a, b \in \mathbb{R}, \quad a \neq 0$$

Y sus estimadores eficientes eran:

$$a \cdot \sum_{i=1}^{n} X_i + b$$

Por lo que:

- Como θ no está en dicha familia de funciones paramétricas, el UMVUE obtenido para θ no puede ser eficiente.
- Si tomamos $a = \frac{1}{n}$ y $b = 0$, tenemos que l UMVUE obtenido para $\frac{1-\theta}{\theta}$ coincide con el estimador eficiente en dicho caso.

Ejercicio 2.4.9. Sea $(X_1, \dots, X_n)$ una muestra aleatoria simple de una variable aleatoria X con distribución exponencial.

a) Probar que la familia de distribuciones de X es regular.

Supuesto que $X \rightsquigarrow exp(\lambda)$ con $\lambda \in \mathbb{R}^+$, la función de densidad de X viene dada por:

$$f_\lambda(x) = \lambda e^{-\lambda x} \qquad x \geqslant 0$$

Y se cumple:

$$E[X] = \frac{1}{\lambda}, \qquad Var(X) = \frac{1}{\lambda^2}$$

Comprobamos cada una de las propiedades:

i) El espacio paramétrico es $\Theta = \mathbb{R}^+$, intervalo abierto de $\mathbb{R}$.

ii) El espacio muestral es $\mathbb{R}_0^+$, que no depende de λ.

iii) Para la tercera, observamos que f_λ es derivable respecto λ, con:

$$\ln f_\lambda(X) = \ln\left(\lambda e^{-\lambda X}\right) = \ln\lambda - \lambda X \quad \Longrightarrow \quad \frac{\partial \ln f_\lambda(X)}{\partial \lambda} = \frac{1}{\lambda} - X$$

Y si calculamos:

$$E\left[\frac{\partial \ln f_\lambda(X)}{\partial \lambda}\right] = E\left[\frac{1}{\lambda} - X\right] = \frac{1}{\lambda} - E[X] = \frac{1}{\lambda} - \frac{1}{\lambda} = 0$$

b) Encontrar la clase de funciones paramétricas que admiten estimador eficiente y el estimador correspondiente. Calcular la varianza de estos estimadores.

Calculamos primero la función de información de Fisher:

$$I_X(\lambda) = Var\left(\frac{\partial \ln f_\lambda(X)}{\partial \lambda}\right) = Var\left(\frac{1}{\lambda} - X\right) = Var(X) = \frac{1}{\lambda^2}$$

que como vemos verifica $0 < I_X(\lambda) < \infty$. Buscamos ahora las funciones a y g:

$$\frac{\partial \ln f_\lambda^n(x_1, \ldots, x_n)}{\partial \lambda} = \sum_{i=1}^n \frac{\partial \ln f_\lambda(x_i)}{\partial \lambda} = \sum_{i=1}^n \left(\frac{1}{\lambda} - x_i\right) = \frac{n}{\lambda} - \sum_{i=1}^n x_i = -\left(\sum_{i=1}^n x_i - \frac{n}{\lambda}\right)$$

Por lo que tomando:

$$T(X_1, \ldots, X_n) = \sum_{i=1}^n X_i, \qquad g(\lambda) = \frac{n}{\lambda}, \qquad a(\lambda) = -1$$

Tenemos que $a(\lambda) \neq 0 \quad \forall \lambda \in \mathbb{R}^+$, que g es derivable con:

$$g'(\lambda) = \frac{-n}{\lambda^2} \neq 0 \qquad \forall \lambda \in \mathbb{R}^+$$

y que T es un estimador, pues $T(\mathbb{R}^+) = \mathbb{R}^+ = g(\mathbb{R}^+)$. Finalmente, falta comprobar que:

$$a(\lambda)g'(\lambda) = \frac{n}{\lambda^2} = nI_X(\lambda) = I_{(X_1,\ldots,X_n)}(\lambda)$$

Por lo que podemos deducir ya por el Teorema de caracterización de los estimadores eficientes que T es un estimador eficiente. Más aún, por un Corolario

del mismo, tenemos que las únicas funciones paramétricas de dicha familia que admiten estimadores eficientes son de la forma:

$$a \cdot \frac{n}{\lambda} + b, \qquad a, b \in \mathbb{R} \quad a \neq 0$$

y que dichos estimadores son $a \cdot T + b$. Nos disponemos a calcular la varianza de estos estimadores:

$$Var\left(a \cdot T + b\right) = a^2 Var\left(\sum_{i=1}^{n} X_i\right) = a^2 \sum_{i=1}^{n} Var(X) = a^2 \sum_{i=1}^{n} \left(\frac{1}{\lambda^2}\right) = \frac{na^2}{\lambda^2}$$

Veamos que coincide con la cota de Fréchet-Cramér-Rao, para comprobar nuestro trabajo calculando la familia de estimadores eficientes:

$$\frac{\left(ag'(\lambda)\right)^2}{I_{(X_1,\ldots,X_n)}(\lambda)} = \frac{\left(\frac{-an}{\lambda^2}\right)^2}{\frac{n}{\lambda^2}} = \frac{na^2}{\lambda^2} = Var(a \cdot T + b)$$

c) Basándose en el apartado anterior, encontrar el UMVUE para la media de X.

Como ya sabemos que $T = \sum_{i=1}^{n} X_i$ es un estimador eficiente para $g(\lambda)$, tenemos automáticamente que T es suficiente. Para ver que T es completo, sea Q una primitiva de a, podemos tomar $Q(\lambda) = -\lambda$, tenemos que claramente $Q(\mathbb{R}^+)$ contiene un abierto de $\mathbb{R}$, por lo que T es completo.

Como en el apartado anterior vimos que T es eficiente para $g(\lambda) = \frac{n}{\lambda}$, tenemos entonces que $\frac{T}{n}$ es eficiente para $\tilde{g}(\lambda) = \frac{g(\lambda)}{n} = \frac{1}{\lambda}$. Como la correspondencia $t \mapsto \frac{t}{n}$ es biunívoca, $\frac{T}{n}$ también será suficiente y completo (para ver que es completo no hace falta que la corresponencia sea unívoca). Por un Corolario del Teorema de caracterización de estimadores eficientes tenemos que T es UMVUE para $\frac{1}{\lambda} = E[X]$.

d) Dar la cota de Fréchet-Cramér-Rao para la varianza de estimadores insesgados y regulares de λ^3. ¿Es alcanzable dicha cota?

Si tomamos $g(\lambda) = \lambda^3$, la cota de Fréchet-Cramér-Rao tiene la forma:

$$\frac{\left(g'(\lambda)\right)^2}{I_{(X_1,\ldots,X_n)}(\lambda)} = \frac{\left(3\lambda^2\right)^2}{\frac{n}{\lambda^2}} = \frac{9\lambda^6}{n}$$

y como $g(\lambda)$ no es de la forma $a \cdot \frac{n}{\lambda} + b$, para ciertos $a, b \in \mathbb{R}$, sabemos que esta cota no es alcanzable.

Ejercicio 2.4.10. Sea X una variable aleatoria con función de densidad de la forma

$$f_\theta(x) = \theta x^{\theta-1}, \quad 0 < x < 1$$

a) Sabiendo que $E_\theta[\ln X] = -\frac{1}{\theta}$ y $Var_\theta[\ln X] = \frac{1}{\theta^2}$, comprobar que esta familia de distribuciones es regular.

Veamos las propiedades, suponiendo que $\theta > 0$.

i) El espacio paramétrico es $\Theta = \mathbb{R}^+$, intervalo abierto de $\mathbb{R}$.

ii) El espacio muestral es $\mathcal{X} =]0,1[$, que no depende de θ.

iii) La función de densidad es derivable respecto θ, calculamos la derivada del logaritmo de la función de densidad:

$$\ln f_\theta(X) = \ln(\theta X^{\theta-1}) = \ln\theta + (\theta-1)\ln X \quad \Longrightarrow \quad \frac{\partial \ln f_\theta(X)}{\partial\theta} = \frac{1}{\theta} + \ln X$$

Con lo que:

$$E\left[\frac{\partial \ln f_\theta(X)}{\partial\theta}\right] = E\left[\frac{1}{\theta} + \ln X\right] = \frac{1}{\theta} + E[\ln X] = \frac{1}{\theta} - \frac{1}{\theta} = 0$$

b) Basándose en una muestra aleatoria simple de X, dar la clase de funciones paramétricas con estimador eficiente, los estimadores y su varianza.

Sea $(X_1, \ldots, X_n)$ una muestra aleatoria simple de X, en primer lugar calculamos la función de información de Fisher:

$$I_X(\theta) = Var\left(\frac{\partial \ln f_\theta(X)}{\partial\theta}\right) = Var\left(\frac{1}{\theta} + \ln X\right) = Var\left(\ln X\right) = \frac{1}{\theta^2}$$

y observamos que $0 < I_X(\theta) < \infty$. Ahora, buscamos las funciones g y a:

$$\frac{\partial \ln f^n_\theta(x_1, \ldots, x_n)}{\partial\theta} = \sum_{i=1}^n \frac{\partial \ln f_\theta(x_i)}{\partial\theta} = \sum_{i=1}^n \left(\frac{1}{\theta} + \ln x_i\right) = \frac{n}{\theta} + \sum_{i=1}^n \ln x_i$$

Tomando:

$$T(X_1, \ldots, X_n) = \sum_{i=1}^n \ln X_i, \qquad g(\theta) = \frac{-n}{\theta}, \qquad a(\theta) = 1$$

tenemos que $a(\theta) \neq 0$ para todo $\theta \in \mathbb{R}^+$, que g es derivable con:

$$g'(\theta) = \frac{n}{\theta^2} \neq 0 \qquad \forall\theta \in \mathbb{R}^+$$

además de que T es un estimador, puesto que:

$$T((]0,1[)^n) \subseteq]-\infty, 0[= g(\mathbb{R}^+)$$

Comprobemos que:

$$a(\theta)g'(\theta) = \frac{n}{\theta^2} = nI_X(\theta) = I_{(X_1,\ldots,X_n)}(\theta)$$

Por lo que T es un estimador eficiente para $g(\theta) = \frac{-n}{\theta}$, luego las únicas funciones paramétricas que admiten estimadores eficientes son las de la forma:

$$a \cdot \frac{-n}{\theta} + b, \qquad a, b \in \mathbb{R}, \quad a \neq 0$$

cuyos estimadores eficientes son:

$$a \cdot T + b$$

Calculemos sus varianzas y veamos que coinciden con la cota de Fréchet-Cramér-Rao:

$$Var(a \cdot T + b) = a^2 Var\left(\sum_{i=1}^{n} \ln X_i\right) \overset{\text{indep.}}{=} a^2 \sum_{i=1}^{n} Var(\ln X_i) = a^2 \sum_{i=1}^{n} \frac{1}{\theta^2} = \frac{a^2 n}{\theta^2}$$

$$\frac{(ag'(\theta))^2}{I_{(X_1,\ldots,X_n)}(\theta)} = \frac{\left(\frac{an}{\theta^2}\right)^2}{\frac{n}{\theta^2}} = \frac{a^2 n}{\theta^2}$$

Ejercicios Adicionales

Ejercicio 2.4.11 (Reto)**.** Sea $X_1, \ldots, X_n$ una muestra aleatoria simple de una variable aleatoria X confunción de densidad:

$$f_\theta(x) = \frac{1}{2\theta\sqrt{x-1}} \quad 1 < x < \theta^2 + 1$$

Sabiendo que $T = X_{(n)}$ es un estadístico suficiente y completo con función de densidad:

$$f_\theta^T(t) = \frac{n(t-1)^{n/2-1}}{2\theta^n} \quad 1 < t < \theta^2 + 1$$

Calcular el UMVUE para $g(\theta) = 2/\theta$.

Como T es suficiente y completo, por el Teorema de Lehmann-Scheffé, basta con encontrar una función h medible tal que $h(T)$ sea insesgado para $g(\theta) = 2/\theta$, es decir:

$$\frac{2}{\theta} = E[h(T)] = \int_1^{\theta^2+1} h(t)\frac{n(t-1)^{n/2-1}}{2\theta^n}dt = \frac{n}{2\theta^n}\int_1^{\theta^2+1} h(t)(t-1)^{n/2-1}dt \qquad \forall\theta > 0$$

Por tanto, tenemos que:

$$\int_1^{\theta^2+1} h(t)(t-1)^{n/2-1}dt = \frac{4}{n}\theta^{n-1} \qquad \forall\theta > 0$$

Derivando respecto θ:

$$h(\theta^2+1)\cdot 2\theta\cdot(\theta^2)^{n/2-1} = \frac{4(n-1)}{n}\theta^{n-2} \quad \Longrightarrow \quad h(\theta^2+1) = \frac{2(n-1)}{n}\theta^{n-3}\cdot\frac{1}{\theta^{n-2}} = \frac{2(n-1)}{n\theta}$$

Aplicando la correspondencia biunívoca $t \mapsto \sqrt{t-1}$, tenemos que:

$$h(t) = \frac{2(n-1)}{n\sqrt{t-1}}$$

Por tanto, el candidato a UMVUE para $g(\theta) = 2/\theta$ es:

$$h(T) = \frac{2(n-1)}{n\sqrt{T-1}} = \frac{2(n-1)}{n\sqrt{X_{(n)}-1}}$$

Por construcción, sabemos que para $n > 1$ es insesgado. Además, como $\theta > 0$ y $h(T) > 0$, $h(T)$ es un estimador. Falta por comprobar que tiene momento de segundo orden finito:

$$E[(h(T))^2] = \int_1^{\theta^2+1} (h(t))^2 \frac{n(t-1)^{n/2-1}}{2\theta^n} dt = \int_1^{\theta^2+1} \left(\frac{2(n-1)}{n\sqrt{t-1}}\right)^2 \frac{n(t-1)^{n/2-1}}{2\theta^n} dt =$$
$$= \frac{2(n-1)^2}{n\theta^n} \int_1^{\theta^2+1} (t-1)^{n/2-2} dt$$

Dicha integral converge si y solo si:

$$\frac{n}{2} - 2 > -1 \iff n > 2$$

Por tanto, para $n > 2$, $E[(h(T))^2] < \infty$ y por el Teorema de Lehmann-Scheffé, $h(T)$ es el UMVUE para $g(\theta) = 2/\theta$.

2.5. Estimación de máxima verosimilitud y otros métodos

Ejercicio 2.5.1. Sea $X \rightsquigarrow P_\theta$ con $\theta \in \mathbb{R}$ siendo P_θ una distribución con función de densidad

$$f_\theta(x) = e^{\theta - x}, \qquad x \geqslant \theta$$

Dada una muestra aleatoria simple de tamaño n, encontrar los estimadores máximo verosímiles de θ y de e^θ. Basándose en los resultados del Ejercicio 2.4.7, decir si estos estimadores son insesgados.

Sea $(X_1, \ldots, X_n)$ una m.a.s. de $X \rightsquigarrow P_\theta$, tenemos que:

$$f_\theta^n(x_1, \ldots, x_n) \overset{\text{iid.}}{=} \prod_{i=1}^n f_\theta(x_i) = \prod_{i=1}^n e^{\theta - x} = e^{n\theta - \sum_{i=1}^n x_i} \qquad \forall x_i \geqslant \theta$$

Por lo que si consideramos $x_{(1)} = \min\limits_{i \in \{1,\ldots,n\}} \{x_i\}$:

$$L_{x_1,\ldots,x_n}(\theta) = f_\theta^n(x_1, \ldots, x_n) = \begin{cases} e^{n\theta - \sum_{i=1}^n x_i} & \text{si } \theta \leqslant x_{(1)} \\ 0 & \text{en otro caso} \end{cases}$$

Observamos que $L_{x_1,\ldots,x_n}(\theta)$ es una función creciente en $\left]-\infty, x_{(1)}\right]$, por lo que alcanza su máximo en $x_{(1)}$. Como el espacio paramétrico es $\Theta = \mathbb{R}$, tenemos que $\widehat{\theta}(X_1, \ldots, X_n) = X_{(1)}$ es un estimador de θ, con lo que es el EMV, al maximizar la función de verosimilitud. Además, el Teorema de Zehna nos dice que:

$$\widehat{e^\theta} = e^{\widehat{\theta}} = e^{X_{(1)}}$$

Por lo que $e^{X_{(1)}}$ es EMV para e^θ.

Buscamos ahora razonar si los estimadores obtenidos son o no insesgados, a partir de los resultados del Ejercicio 2.4.7.

Opción 1 Si suponemos que los EMVs que hemos obtenido son insesgados, vimos anteriormente en dicho ejercicio que el mínimo era suficiente y completo, por lo que tendríamos una función del suficiente y completo que es insesgada. Si comprobamos que también tiene momento de segundo orden finito y que es estimador (se hizo en el ejercicio anterior), tendríamos que es un UMVUE distinto al anterior, pero la unicidad del UMVUE nos dice que estos han de ser iguales, contradicción que viene de suponer que los EMVs son insesgados.

Opción 2 En el Ejercicio 2.4.7 vimos que:

- El UMVUE de θ era:

$$X_{(1)} - \frac{1}{n}$$

  Como el UMVUE es insesgado, tenemos que:

$$E\left[X_{(1)} - \frac{1}{n}\right] = \theta \Longrightarrow E[X_{(1)}] = \theta + \frac{1}{n} \neq \theta$$

Por lo que $X_{(1)}$ no es insesgado, y por lo tanto el EMV de θ no es insesgado.

- En dicho ejercicio también vimos que el UMVUE de e^θ era:

$$\frac{n-1}{n}e^{X_{(1)}}$$

Como el UMVUE es insesgado, tenemos que:

$$E\left[\frac{n-1}{n}e^{X_{(1)}}\right] = e^\theta \Longrightarrow E[e^{X_{(1)}}] = \frac{n}{n-1}e^\theta \neq e^\theta$$

Por lo que $e^{X_{(1)}}$ no es insesgado, y por lo tanto el EMV de e^θ no es insesgado.

Ejercicio 2.5.2. Sea $(X_1, \ldots, X_n)$ una muestra aleatoria simple de una variable aleatoria X con distribución exponencial. Basándose en los resultados del Ejercicio 2.4.9, encontrar los estimadores máximo verosímiles de la media y de la varianza de X.

Sea $X \rightsquigarrow \exp(\lambda)$ con $\lambda \in \mathbb{R}^+$, nos piden encontrar EMVs para:

$$E[X] = \frac{1}{\lambda}, \qquad Var[X] = \frac{1}{\lambda^2}$$

En el Ejercicio 2.4.9 obtuvimos que dicha familia de distribuciones es regular, con $0 < I_X(\lambda) < \infty$. Además, vimos que las únicas funciones paramétricas de dicha familia de distribuciones que admiten estimadores eficientes son las de la forma:

$$a \cdot \frac{n}{\lambda} + b \qquad a, b \in \mathbb{R}, \quad a \neq 0$$

y sus estimadores eficientes correspondientes son:

$$a \cdot \sum_{i=1}^{n} X_i + b$$

Tomando $a = 1/n, b = 0$, obtenemos que el estimador $T = \frac{\sum_{i=1}^{n} X_i}{n}$ es eficiente para $E[X] = 1/\lambda$, por lo que un Teorema visto en teoría nos asegura que T es el único EMV que podemos considerar para $1/\lambda = E[X]$, luego:

$$\widehat{E[X]} = \widehat{\left(\frac{1}{\lambda}\right)} = \frac{\sum_{i=1}^{n} X_i}{n}$$

Por tanto, por el Teorema de Zehna, tenemos que el EMV de $Var[X]$ es:

$$\widehat{Var[X]} = \widehat{\left(\frac{1}{\lambda^2}\right)} = \widehat{\left(\frac{1}{\lambda}\right)}^2 = \left(\frac{\sum_{i=1}^{n} X_i}{n}\right)^2$$

Ejercicio 2.5.3. Sea X una variable aleatoria con función de densidad de la forma

$$f_\theta(x) = \theta x^{\theta-1}, \qquad 0 < x < 1$$

a) Calcular un estimador máximo verosímil para θ.

Maximizamos la función de verosimilitud de θ:

$$L_{x_1,\dots,x_n}(\theta) = f_\theta^n(x_1,\dots,x_n) \overset{\text{iid.}}{=} \prod_{i=1}^n f_\theta(x_i) = \prod_{i=1}^n \theta x_i^{\theta-1} = \theta^n \prod_{i=1}^n x_i^{\theta-1}$$

Puesto que el logaritmo es una función creciente, podemos maximizar la función de verosimilitud aplicando logaritmo, el cual no modifica la abcisa del máximo:

$$\ln L_{x_1,\dots,x_n}(\theta) = n\ln\theta + (\theta-1)\sum_{i=1}^n \ln x_i$$

Como buscamos el máximo, derivamos e igualamos a cero para hayar los puntos críticos:

$$\frac{\partial \ln L_{x_1,\dots,x_n}(\theta)}{\partial\theta} = \frac{n}{\theta} + \sum_{i=1}^n \ln x_i = \frac{n + \theta\sum\limits_{k=1}^n \ln x_i}{\theta} = 0 \iff \theta = \frac{-n}{\sum\limits_{k=1}^n \ln x_i}$$

Sería necesario comprobar que efectivamente es un máximo, pero se entiende que es así. Por tanto, el EMV de θ (a esperas de comprobar que es un estimador) es:

$$\widehat{\theta}(X_1,\dots,X_n) = \frac{-n}{\sum\limits_{i=1}^n \ln X_i}$$

Notemos que $\theta > 0$, y que como $0 < X_i < 1$, tenemos que $\ln X_i < 0$, por lo que $\sum\limits_{i=1}^n \ln X_i < 0$, y por tanto $\widehat{\theta} > 0$. Por tanto, tenemos que $\widehat{\theta}$ es un estimador de θ, luego es EMV para θ.

b) Deducir dicho estimador a partir de los resultados del Ejercicio 2.4.10.

En el Ejercicio 2.4.10 vimos que la familia de distribuciones en cuestión es regular, con $0 < I_X(\theta) < \infty$. Además, vimos que las únicas funciones paramétricas que admiten un estimador eficiente son las de la forma:

$$a \cdot \frac{-n}{\theta} + b \qquad a, b \in \mathbb{R}, \quad a \neq 0$$

y sus estimadores eficientes son:

$$a \cdot \sum_{i=1}^n \ln X_i + b$$

Tomando $a = {}^{-1}/_{n}, b = 0$, tenemos que el estimador:

$$T = \frac{\sum_{i=1}^{n} \ln X_i}{-n}$$

es eficiente para $\frac{1}{\theta}$, por lo que T es el EMV de $\frac{1}{\theta}$. Si aplicamos el Teorema de Zehna, tenemos que:

$$\widehat{\left(\frac{1}{\theta}\right)} = \frac{1}{\widehat{\theta}} \Longrightarrow \widehat{\theta} = \frac{1}{\widehat{\left(\frac{1}{\theta}\right)}} = \frac{-n}{\sum_{i=1}^{n} \ln X_i}$$

Observamos que obtenemos el mismo resultado que en el primer apartado.

Ejercicio 2.5.4. Sea $(X_1, \ldots, X_n)$ una muestra de una variable $X \rightsquigarrow \mathcal{B}(k_0, p)$ para cierto $k_0 \in \mathbb{N}$ y $p \in]0, 1[$. Estimar, por máxima verosimilitud y por el método de los momentos, el parámetro p y la varianza de X.

Aplicación: Se lanza 10 veces un dado cargado y se cuenta el número de veces que sale un 4. Este experimento se realiza 100 veces de forma independiente, obteniéndose los siguientes resultados:

nº de 4	0	1	2	3
frecuencia	84	15	1	0

Estimar, a partir de estos datos, la probabilidad de salir un cuatro.

Por máxima verosimilitud. Tenemos:

$$\begin{aligned} P[X_1 = x_1, \ldots, X_n = x_n] &\overset{\text{iid.}}{=} \prod_{i=1}^{n} P[X = x_i] = \prod_{i=1}^{n} \binom{k_0}{x_i} p^{x_i} (1-p)^{k_0 - x_i} \\ &= p^{\sum_{i=1}^{n} x_i} (1-p)^{nk_0 - \sum_{i=1}^{n} x_i} \prod_{i=1}^{n} \binom{k_0}{n} \end{aligned}$$

Puesto que el logaritmo es una función creciente, podemos maximizar la función de verosimilitud aplicando logaritmo, el cual no modifica la abcisa del máximo:

$$\ln L_{x_1,\ldots,x_n}(p) = \ln p \sum_{i=1}^{n} x_i + \ln(1-p) \left(nk_0 - \sum_{i=1}^{n} x_i \right) + \sum_{k=1}^{n} \ln \binom{k_0}{n}$$

Como buscamos el máximo, derivamos e igualamos a cero para hayar los puntos críticos:

$$\begin{aligned} \frac{\partial \ln L_{x_1,\ldots,x_n}(p)}{\partial p} &= \frac{1}{p} \sum_{i=1}^{n} x_i - \frac{1}{1-p} \left(nk_0 - \sum_{i=1}^{n} x_i \right) = \frac{(1-p) \sum_{i=1}^{n} x_i - pnk_0 + p \sum_{i=1}^{n} x_i}{p(1-p)} \\ &= \frac{\sum_{i=1}^{n} x_i - pnk_0}{p(1-p)} = 0 \Longleftrightarrow p = \frac{\sum_{i=1}^{n} x_i}{nk_0} \end{aligned}$$

Como $\sum_{i=1}^{n} x_i \leqslant nk_0$, tenemos entonces que $p \in [0,1]$, por lo que esta fórmula nos dará una estimador, con lo que el EMV es:

$$\widehat{p} = \frac{1}{nk_0}\sum_{i=1}^{n} X_i = \frac{1}{k_0}\overline{X}$$

Para $Var[X] = k_0 p(1-p)$, si aplicamos el Teorema de Zehna tenemos que:

$$\widehat{Var[X]} = k_0\widehat{p(1-p)} = k_0\widehat{p}(1-\widehat{p}) = \frac{1}{n}\sum_{i=1}^{n} X_i\left(1 - \frac{1}{nk_0}\sum_{i=1}^{n} X_i\right) = \overline{X}\left(1 - \frac{1}{k_0}\overline{X}\right)$$

Por el método de los momentos. Por el método de los momentos:

$$\begin{cases} k_0 p = E[X] = \overline{X} = \frac{1}{n}\sum_{i=1}^{n} X_i \\ k_0 p(1-p) = Var[X] = \frac{1}{n}\left(\sum_{k=1}^{n} X_i^2 - \overline{X}^2\right) \end{cases}$$

De la primera ecuación obtenemos que:

$$\widehat{p} = \frac{1}{nk_0}\sum_{i=1}^{n} X_i = \frac{1}{k_0}\overline{X}$$

De la segunda ecuación obtenemos que:

$$\widehat{Var[X]} = \frac{1}{n}\left(\sum_{k=1}^{n} X_i^2 - \overline{X}^2\right)$$

Para estimar a partir de los datos mencionados la probabilidad de salir un cuatro, lo que hacemos primero es considerar:

$$Y \equiv \text{“Número de veces que sale un 4 en 10 tiradas del dado”} \rightsquigarrow \mathcal{B}(10,p)$$

donde estimaremos el valor de p mediante la estimación obtenida:

$$p = \frac{1}{nk_0}\sum_{i=1}^{n} y_i = \frac{1}{1000}(0\cdot 84 + 1\cdot 15 + 2\cdot 1 + 3\cdot 0) = \frac{15+2}{1000} = \frac{17}{1000} = 0{,}017$$

Por tanto, la estimación de la probabilidad de que salga un cuatro es 0,017.

Ejercicio 2.5.5. Se lanza un dado hasta que salga un 4 y se anota el número de lanzamientos necesarios; este experimento se efectúa veinte veces de forma independiente. A partir de los resultados obtenidos, estimar la probabilidad de sacar un 4 por máxima verosimilitud.

Sea X una variable aleatoria que representa el número de lanzamientos hasta que salga un 4, es decir:

$$X \equiv \text{“número de lanzamientos antes del lanzamiento en el que sale 4”}$$

Tenemos que, si p es la probabilidad de que salga un 4, entonces X sigue una distribución geométrica de parámetro p: $X \rightsquigarrow G(p)$. Como se realiza el experimento 20 veces de forma independientes, disponemos de una muestra $x_1, \ldots, x_n$ donde $n = 20$. Estimamos p por máxima verosimilitud:

$$L_{x_1,\ldots,x_n}(p) = P_p[X_1 = x_1, \ldots, X_n = x_n] \overset{\text{indep.}}{=} \prod_{i=1}^{n} P_p[X = x_i] = \prod_{i=1}^{n} (1-p)^{x_i} p = p^n (1-p)^{\sum_{i=1}^{n} x_i}$$

Como el logaritmo es una función creciente, podemos maximizar la función de verosimilitud aplicando logaritmo, el cual no modifica la abcisa del máximo:

$$\ln L_{x_1,\ldots,x_n}(p) = n \cdot \ln p + \ln(1-p) \sum_{i=1}^{n} x_i$$

Derivando con respecto a p e igualando a cero para hallar los puntos críticos:

$$\frac{\partial \ln L_{x_1,\ldots,x_n}(p)}{\partial p} = \frac{n}{p} - \frac{\sum_{i=1}^{n} x_i}{1-p} = \frac{n - np - p\left(\sum_{i=1}^{n} x_i\right)}{p(1-p)} = \frac{n - p\left(\sum_{i=1}^{n} x_i + n\right)}{p(1-p)}$$

Obtenemos por tanto que:

$$\frac{\partial \ln L_{x_1,\ldots,x_n}(p)}{\partial p} = 0 \iff p = \frac{n}{\sum_{i=1}^{n} x_i + n}$$

Como siempre se tiene que dicho valor está en $[0, 1]$, tenemos que es un estimador, con lo que el EMV es:

$$\widehat{p} = \frac{n}{\sum_{i=1}^{n} X_i + n} = \frac{20}{\sum_{i=1}^{20} X_i + 20} = \frac{1}{1 + \overline{X}}$$

Ejercicio 2.5.6. En 20 días muy fríos, una granjera pudo arrancar su tractor en el primer, tercer, quinto, primer, segundo, primer, tercer, séptimo, segundo, cuarto, cuarto, octavo, primer, tercer, sexto, quinto, segundo, primer, sexto y segundo intento. Suponiendo que la probabilidad de arrancar en cada intento es constante, y que las observaciones se han obtenido de forma independiente, dar la estimación más verosímil de la probabilidad de que el tractor arranque en el segundo intento.

Reunimos en primer lugar los datos proporcionados por el enunciado en la Tabla 2.1.

Primer	Segundo	Tercero	Cuarto	Quinto	Sexto	Séptimo	Octavo
5	4	3	2	2	2	1	1

Tabla 2.1: Veces que arrancó en cada intento.

Consideramos la variable aleatoria dada por:

$$X \equiv \text{“Número de intentos fallidos de arrancar el tractor”}$$

Tenemos que $X \rightsquigarrow G(p)$, donde p es la probabilidad de arrancar el tractor en un intento. Tenemos a nuestra disposición de una muestra de X, $x_1, \ldots, x_n$, de tamaño $n = 20$. Si observamos la similitud con el Ejercicio 2.5.5, estamos bajo las mismas hipótesis, por lo que al calcular el EMV para p obtendremos:

$$\widehat{p} = \frac{1}{1+\overline{X}}$$

Sin embargo, en este caso no se nos pide estimar p, sino la probabilidad de que el tractor arranque en el segundo intento, es decir, $P_p[X = 1]$:

$$P_p[X = 1] = (1-p)p$$

Si amplicamos el Teorema de Zehna, podemos obtener el EMV de $P_p[X = 1]$ a partir de $\widehat{p}$:

$$\widehat{P_p[X=1]} = \widehat{(1-p)}p = (1-\widehat{p})\,\widehat{p} = \left(1 - \frac{1}{1+\overline{X}}\right)\frac{1}{1+\overline{X}} = \frac{\overline{X}}{1+\overline{X}}\cdot\frac{1}{1+\overline{X}} = \frac{\overline{X}}{(1+\overline{X})^2}$$

Por tanto, una vez se ha obtenido el EMV de $P_p[X = 1]$, solo nos queda sustituir los valores de la muestra para obtener la estimación. Calculamos en primer lugar la estimación de $\overline{X}$:

$$\overline{X}(x_1, \ldots, x_n) = \frac{1}{n}\sum_{i=1}^{n} x_i = \frac{1}{20}\left(0\cdot 5 + 1\cdot 4 + 2\cdot 3 + 3\cdot 2 + 4\cdot 2 + 5\cdot 2 + 6\cdot 1 + 7\cdot 1\right) = \frac{47}{20} = 2{,}35$$

Por tanto, la estimación máximo verosímil de la probabilidad de que el tractor arranque en el segundo intento es:

$$\widehat{P_p[X=1]}(x_1, \ldots, x_n) = \frac{\overline{X}}{(1+\overline{X})^2} = \frac{2{,}35}{(1+2{,}35)^2} = \frac{940}{4489} \approx 0{,}2094$$

Ejercicio 2.5.7. Una variable aleatoria discreta toma los valores 0, 1 y 2 con las siguientes probabilidades

$$P_p[X = 0] = p^2, \qquad P_p[X = 1] = 2p(1-p), \qquad P_p[X = 2] = (1-p)^2$$

siendo p un parámetro desconocido. En una muestra aleatoria simple de tamaño 100, se ha presentado 22 veces el 0, 53 veces el 1 y 25 veces el 2. Calcular la función de verosimilitud asociada a dicha muestra y dar la estimación más verosímil de p.

Los datos obtenidos son:

Dato	0	1	2
Veces	22	53	25

Opción 1. Sea X una variable aleatoria cuya función masa de probabilidad nos viene dada, tenemos una muestra $X_1, \ldots, X_n$ de tamaño $n = 100$. La función

de verosimilitud asociada a la muestra es:

$$\begin{aligned} L_{x_1,\dots,x_n}(p) &= P_p[X_1 = x_1, \dots, X_n = x_n] \overset{\text{iid.}}{=} \prod_{i=1}^{n} P_p[X = x_i] \\ &= \prod_{i=1}^{22} P_p[X = 0] \prod_{i=1}^{53} P_p[X = 1] \prod_{i=1}^{25} P_p[X = 2] \\ &= \prod_{i=1}^{22} p^2 \prod_{i=1}^{53} 2p(1-p) \prod_{i=1}^{25} (1-p)^2 \\ &= p^{44} \cdot 2^{53} p^{53} (1-p)^{53} \cdot (1-p)^{50} = 2^{53} p^{97} (1-p)^{103} \end{aligned}$$

Puesto que el logaritmo es una función creciente, podemos maximizar la función de verosimilitud aplicando logaritmo, el cual no modifica la abcisa del máximo:

$$\ln L_{x_1,\dots,x_n}(p) = 53 \ln 2 + 97 \ln p + 103 \ln(1-p)$$

Derivando con respecto a p e igualando a cero para hallar los puntos críticos:

$$\frac{\partial \ln L_{x_1,\dots,x_n}(p)}{\partial p} = \frac{97}{p} - \frac{103}{1-p} = \frac{97(1-p) - 103p}{p(1-p)} = \frac{97 - 200p}{p(1-p)} = 0 \iff p = \frac{97}{200}$$

Por tanto, como $p \in [0,1]$, tenemos que $\frac{97}{200}$ es la estimación máximo verosímil de p:

$$\widehat{p} = \frac{97}{200}$$

Notemos que este enfoque nos proporciona una estimación máximo verosímil de p, pero no nos proporciona el EMV de p como función de la muestra, sino que nos da un valor concreto. Para obtener el EMV de p como función de la muestra, podemos utilizar el enfoque de la Opción 2.

Opción 2. Sea X la variable aleatoria cuya función masa de probabilidad nos viene dada, y vemos que:

$$P[X = k] = \binom{2}{k} (1-p)^k p^{2-k}, \qquad k = 0, 1, 2$$

Por tanto, $X \rightsquigarrow B(2, 1-p)$, y tenemos una m.a.s. $X_1, \dots, X_n$ de tamaño $n = 100$. La función de verosimilitud asociada a la muestra es:

$$\begin{aligned} L_{x_1,\dots,x_n}(p) &= P_p[X_1 = x_1, \dots, X_n = x_n] \overset{\text{iid.}}{=} \prod_{i=1}^{n} P_p[X = x_i] \\ &= \prod_{i=1}^{n} \binom{2}{x_i} (1-p)^{x_i} p^{2-x_i} = \prod_{i=1}^{n} \binom{2}{x_i} (1-p)^{\sum_{i=1}^{n} x_i} p^{2n - \sum_{i=1}^{n} x_i} \end{aligned}$$

Puesto que el logaritmo es una función creciente, podemos maximizar la función de verosimilitud aplicando logaritmo, el cual no modifica la abcisa del máximo:

$$\ln L_{x_1,\dots,x_n}(p) = \sum_{i=1}^{n} \ln \binom{2}{x_i} + \ln(1-p) \sum_{i=1}^{n} x_i + \ln p \left(2n - \sum_{i=1}^{n} x_i \right)$$

Derivando con respecto a p e igualando a cero para hallar los puntos críticos:

$$\frac{\partial \ln L_{x_1,\dots,x_n}(p)}{\partial p} = -\frac{\sum_{i=1}^{n} x_i}{1-p} + \frac{2n - \sum_{i=1}^{n} x_i}{p} = \frac{-p\sum_{i=1}^{n} x_i + (1-p)(2n - \sum_{i=1}^{n} x_i)}{p(1-p)} =$$
$$= \frac{2n - 2np - \sum_{i=1}^{n} x_i}{p(1-p)} = 0 \Longleftrightarrow p = \frac{2n - \sum_{i=1}^{n} x_i}{2n} = 1 - \frac{\sum_{i=1}^{n} x_i}{2n}$$

Habría que comprobar que efectivamente es un máximo, pero se entiende que es así. Por tanto, el EMV de p (de nuevo, a esperas de comprobar que es un estimador) es:

$$\widehat{p} = 1 - \frac{\sum_{i=1}^{n} X_i}{2n} = 1 - \frac{\overline{X}}{2}$$

Como $X_i \in \{0, 1, 2\}$, tenemos que $\overline{X} \in [0, 2]$, por lo que $\widehat{p} \in [0, 1]$, con lo que $\widehat{p}$ es un estimador de p y por tanto es EMV para p. Sustituyendo los valores de la muestra obtenemos:

$$\widehat{p} = 1 - \frac{\overline{X}}{2} = 1 - \frac{1}{2} \cdot \frac{1}{100}(0 \cdot 22 + 1 \cdot 53 + 2 \cdot 25) = 1 - \frac{1}{2} \cdot \frac{103}{100} = 1 - \frac{103}{200} = \frac{97}{200}$$

Por tanto, la estimación máximo verosímil de p es:

$$\widehat{p} = \frac{97}{200}$$

Ejercicio 2.5.8. En el muestreo de una variable aleatoria con distribución $\mathcal{N}(\mu, 1)$, $\mu \in \mathbb{R}$, se observa que no se obtiene un valor menor que -1 hasta la quinta observación. Dar una estimación máximo verosímil de μ.

Sea $Y \rightsquigarrow \mathcal{N}(\mu, 1)$. Consideramos la siguiente variable aleatoria:

$X \equiv$ "número de observaciones hasta obtener una menor que -1 (sin incluirla)"

Considerando que X es el número de ensayos hasta obtener un éxito, siendo el éxito el hecho de que la observación sea menor que -1, tenemos que $X \rightsquigarrow G(p)$, donde p es la probabilidad de que una observación sea menor que -1, es decir, $p = P[Y < -1]$. Por tanto:

$$P_p[X = x] = (1-p)^x p$$

Calculamos ahora $P[Y < -1]$:

$$P[Y < -1] = P\left[\frac{Y - \mu}{1} < \frac{-1 - \mu}{1}\right] = P[Z < -1 - \mu] =$$
$$= P[Z > 1 + \mu] = 1 - P[Z < 1 + \mu] = 1 - \Phi(1 + \mu)$$

donde Φ es la función de distribución de una $\mathcal{N}(0,1)$. Usando que Φ es biyectiva, tenemos que:

$$\mu = \Phi^{-1}(1-p) - 1$$

Por tanto, si obtenemos el EMV de p, podemos obtener el EMV de μ aplicando el Teorema de Invarianza de Zehna. Buscamos por tanto el EMV de p a partir de la muestra de X. Tenemos que la función de verosimilitud asociada a la muestra es:

$$L_{x_1,\dots,x_n}(p) = P_p[X_1 = x_1, \dots, X_n = x_n] \overset{\text{iid.}}{=} \prod_{i=1}^{n} P_p[X = x_i] =$$

$$= \prod_{i=1}^{n} (1-p)^{x_i} p = p^n (1-p)^{\sum_{i=1}^{n} x_i}$$

Como el logaritmo es una función creciente, podemos maximizar la función de verosimilitud aplicando logaritmo, el cual no modifica la abcisa del máximo:

$$\ln L_{x_1,\dots,x_n}(p) = n \ln p + \ln(1-p) \sum_{i=1}^{n} x_i$$

Derivando con respecto a p e igualando a cero para hallar los puntos críticos:

$$\frac{\partial \ln L_{x_1,\dots,x_n}(p)}{\partial p} = \frac{n}{p} - \frac{\sum_{i=1}^{n} x_i}{1-p} = \frac{n - np - p\sum_{i=1}^{n} x_i}{p(1-p)} = \frac{n - p\left(n + \sum_{i=1}^{n} x_i\right)}{p(1-p)} = 0 \iff p = \frac{n}{n + \sum_{i=1}^{n} x_i}$$

Por tanto, de ser un estimador, el EMV de p es:

$$\widehat{p} = \frac{n}{n + \sum_{i=1}^{n} X_i} = \frac{1}{1 + \overline{X}}$$

Como $X_i \in \mathbb{N}$, tenemos que $\overline{X} \geqslant 0$, por lo que $\widehat{p} \in [0,1]$, con lo que $\widehat{p}$ es un estimador de p y por tanto es EMV para p. Por tanto, aplicando el Teorema de Invarianza de Zehna, tenemos que el EMV de μ es:

$$\widehat{\mu} = \Phi^{-1}(1 - \widehat{p}) - 1$$

Evaluando la muestra obtenida, tenemos que $n = 1$ y $x_1 = 5 - 1 = 4$, por lo que $\overline{X} = 4$, y por tanto:

$$\widehat{p} = \frac{1}{1 + \overline{X}} = \frac{1}{1+4} = \frac{1}{5}$$

Por tanto, la estimación máximo verosímil de μ es:

$$\widehat{\mu} = \Phi^{-1}(1 - \widehat{p}) - 1 = \Phi^{-1}\left(1 - \frac{1}{5}\right) - 1 = \Phi^{-1}(0{,}8) - 1$$

Si consultamos la tabla de la normal $\mathcal{N}(0,1)$, obtenemos que $\Phi^{-1}(0{,}8) \approx 0{,}84$, por lo que:

$$\widehat{\mu} \approx 0{,}84 - 1 = -0{,}16$$

es la estimación máximo verosímil de μ.

Ejercicio 2.5.9. En la producción de filamentos eléctricos la medida de interés, X, es el tiempo de vida de cada filamento, que tiene una distribución exponencial de parámetro θ. Se eligen n de tales filamentos de forma aleatoria e independiente, pero, por razones de economía, no conviene esperar a que todos se quemen y la observación acaba en el tiempo T. Dar el estimador máximo verosímil para la media de X a partir del número de filamentos quemados durante el tiempo de observación.

Sea $X \rightsquigarrow \exp(\theta)$, y consideramos la siguiente variable aleatoria:

$$Y \equiv \text{“número de filamentos con tiempo de vida menor que } T \text{ en una muestra de tamaño } n\text{”}$$

Tenemos que $Y \rightsquigarrow B(n,p)$, donde p es la probabilidad de que el tiempo de vida de un filamento sea menor que T, es decir, $p = P[X < T]$. Sabemos que el parámetro a estimar es:

$$E[X] = \frac{1}{\theta}$$

Por tanto, por el Teorema de Invarianza de Zehna, si obtenemos el EMV de θ, podemos obtener el EMV de $E[X]$ a partir de él. Calculamos ahora el valor de p:

$$p = P[X < T] = \int_0^T \theta e^{-\theta x} dx = \left[-e^{-\theta x}\right]_0^T = 1 - e^{-\theta T} \Longrightarrow e^{-\theta T} = 1 - p \Longrightarrow \theta = \frac{-\ln(1-p)}{T}$$

Por tanto, como el valor de T es conocido, si obtenemos el EMV de p, podemos obtener el EMV de θ a partir de él, y por tanto el EMV de $E[X]$. Buscamos por tanto el EMV de p a partir de la muestra de Y, que es de tamaño 1 (notemos que la muestra de Y es de tamaño 1 porque solo se realiza un experimento, que consiste en observar el número de filamentos quemados en una muestra de tamaño n. No se debe confundir con la muestra de tamaño n de filamentos, que es la que se utiliza para definir Y). Por tanto, tenemos que la función de verosimilitud asociada a la muestra es:

$$L_{y_1}(p) = P_p[Y = y_1] = \binom{n}{y} p^{y_1} (1-p)^{n-y_1}$$

Puesto que el logaritmo es una función creciente, podemos maximizar la función de verosimilitud aplicando logaritmo, el cual no modifica la abcisa del máximo:

$$\ln L_{y_1}(p) = \ln \binom{n}{y_1} + y_1 \ln p + (n - y_1) \ln(1-p)$$

Derivando con respecto a p e igualando a cero para hallar los puntos críticos:

$$\frac{\partial \ln L_{y_1}(p)}{\partial p} = \frac{y_1}{p} - \frac{n - y_1}{1-p} = \frac{y_1 - y_1 p - np + y_1 p}{p(1-p)} = \frac{y_1 - np}{p(1-p)} = 0 \Longleftrightarrow p = \frac{y_1}{n}$$

Por tanto, de ser un estimador, el EMV de p es:

$$\widehat{p} = \frac{Y}{n}$$

Como $Y \in \{0, 1, \ldots, n\}$, tenemos que $\widehat{p} \in [0, 1]$, con lo que $\widehat{p}$ es un estimador de p y por tanto es EMV para p. Por tanto, aplicando el Teorema de Invarianza de Zehna, tenemos que el EMV de θ es:

$$\widehat{\theta} = \frac{-\ln(1-\widehat{p})}{T} = \frac{-\ln\left(1-{}^{Y}/_{n}\right)}{T}$$

Aplicando de nuevo el Teorema de Invarianza de Zehna, tenemos que el EMV de $E[X]$ es:

$$\widehat{E[X]} = \frac{1}{\widehat{\theta}} = \frac{-T}{\ln(1-\widehat{p})} = \frac{-T}{\ln\left(1-{}^{Y}/_{n}\right)}$$

Ejercicio 2.5.10. Sean $X_1, \ldots, X_n$ observaciones independientes de una variable $X \rightsquigarrow \{\Gamma(p, a) : p, a > 0\}$. Estimar ambos parámetros mediante el método de los momentos.

Aplicación: Ciertos neumáticos radiales tuvieron vidas útiles de 35200, 41000, 44700, 38600 y 41500 kilómetros. Suponiendo que estos datos son observaciones independientes de una variable con distribución exponencial de parámetro θ, dar una estimación de dicho parámetro por el método de los momentos.

Planteamos el sistema a resolver, sabiendo que si $X \rightsquigarrow \Gamma(p, a)$, entonces:

$$E[X] = \frac{p}{a}, \qquad Var[X] = \frac{p}{a^2}$$

Como tratamos estimar dos parámetros, necesitamos dos ecuaciones. Respecto al momento de primer orden no centrado, tenemos que:

$$E[X] = \frac{p}{a} = A_1 = \overline{X}$$

Respecto al momento de segundo orden centrado, tenemos que:

$$Var[X] = \frac{p}{a^2} = A_2 - \overline{X}^2$$

Por tanto, tenemos el siguiente sistema de ecuaciones con dos incógnitas:

$$\begin{cases} {}^{p}/_{a} &= \overline{X} \\ {}^{p}/_{a^2} &= A_2 - \left(\overline{X}\right)^2 \end{cases}$$

De la primera ecuación tenemos que:

$$p = a\overline{X}$$

Si sustituimos en la segunda, obtenemos el valor de a:

$$\frac{\overline{X}}{a} = A_2 - \left(\overline{X}\right)^2 \Longrightarrow a = \frac{\overline{X}}{A_2 - \left(\overline{X}\right)^2}$$

Sustituyendo ahora a en la expresión de p, obtenemos el valor de p:

$$p = \frac{\left(\overline{X}\right)^2}{A_2 - \left(\overline{X}\right)^2}$$

Por tanto, los estimadores de a y p por el método de los momentos son:

$$\widehat{a} = \frac{\overline{X}}{A_2 - \left(\overline{X}\right)^2}, \qquad \widehat{p} = \frac{\left(\overline{X}\right)^2}{A_2 - \left(\overline{X}\right)^2}$$

Sea $X \rightsquigarrow \exp(\theta)$. Notemos que, aunque la exponencial sea un caso particular de la gamma, con $p = 1$ y $a = \theta$, no podemos aplicar directamente los estimadores obtenidos para la gamma, ya que en este caso solo tenemos un parámetro a estimar. Por tanto, aplicamos el método de los momentos directamente a la exponencial. Sabemos que:

$$E[X] = \frac{1}{\theta} = A_1 = \overline{X}$$

De esta ecuación, despejamos θ:

$$\theta = \frac{1}{\overline{X}}$$

Por tanto, la estimación de θ por el método de los momentos es:

$$\widehat{\theta} = \frac{1}{\overline{X}}$$

Calculamos ahora $\overline{X}$:

$$\overline{X} = \frac{35200 + 41000 + 44700 + 38600 + 41500}{5} = 40200$$

Por tanto, la estimación de θ por el método de los momentos es:

$$\widehat{\theta} = \frac{1}{\overline{X}} = \frac{1}{40200} \approx 2{,}488 \cdot 10^{-5}$$

Ejercicios Adicionales

Ejercicio 2.5.11 (Reto)**.** Sea $X_1, \ldots, X_n$ una muestra aleatoria simple de una variable X con función de densidad:

$$f_\theta(x) = \frac{-2x}{(1-\theta)^2} \qquad 1 - \theta < x < 0$$

Calcular el EMV de θ por el método de máxima verosimilitud y por el método de los momentos.

Por el Método de los Momentos

Buscamos el primer momento de la variable X:

$$E[X] = \int_{1-\theta}^{0} x f_\theta(x) dx = \int_{1-\theta}^{0} x \frac{-2x}{(1-\theta)^2} dx = \frac{-2}{(1-\theta)^2} \int_{1-\theta}^{0} x^2 dx = \frac{-2}{(1-\theta)^2} \left[\frac{x^3}{3}\right]_{1-\theta}^{0} =$$
$$= \frac{-2}{(1-\theta)^2} \left(0 - \frac{(1-\theta)^3}{3}\right) = \frac{2(1-\theta)}{3}$$

Por el método de los momentos, igualamos la media muestral con la media poblacional:

$$\overline{X} = E[X] \Longrightarrow \overline{X} = \frac{2(1-\theta)}{3} \Longrightarrow 1-\theta = \frac{3\overline{X}}{2} \Longrightarrow \widehat{\theta} = 1 - \frac{3\overline{X}}{2}$$

Como $\theta > 1$ y $\overline{X} < 0$, tenemos que $\widehat{\theta} > 1$, luego la estimación obtenida es un estimador.

Por el Método de Máxima Verosimilitud

La función de verosimilitud es:

$$L_{x_1,\ldots,x_n}(\theta) = \prod_{i=1}^{n} f_\theta(x_i) = \prod_{i=1}^{n} \frac{-2x_i}{(1-\theta)^2} = \frac{(-2)^n \prod_{i=1}^{n} x_i}{(1-\theta)^{2n}} \qquad \theta < 1 - x_{(1)}$$

- Si $\theta \leqslant 1 + x_{(1)}$, entonces $L_{x_1,\ldots,x_n}(\theta) = 0$.
- Si $\theta > 1 + x_{(1)}$, entonces $L_{x_1,\ldots,x_n}(\theta) > 0$.

Veamos que la función de verosimilitud es creciente en el intervalo $\theta > 1 - x_{(1)}$:

$$\frac{\partial L_{x_1,\ldots,x_n}(\theta)}{\partial \theta} = \frac{(-2)^n \prod_{i=1}^{n} x_i}{(1-\theta)^{2n+1}} \cdot 2n > 0$$

Por tanto, el EMV de θ es:

$$\widehat{\theta} = 1 - X_{(1)}$$

Como $\theta > 1$ y $X_{(1)} < 0$, tenemos que $\widehat{\theta} > 1$, luego la estimación obtenida es un estimador.

Ejercicio 2.5.12. Sea $X_1, \ldots, X_n$ una muestra aleatoria simple de una variable aleatoria X, que sigue una distribución de Rayleigh de parámetro $\theta > 0$, con función de densidad dada por:

$$f_\theta(x) = \frac{x}{\theta^2} \exp\left(-\frac{x^2}{2\theta^2}\right), \qquad x \geqslant 0$$

a) Calcular el estimador de máxima verosimilitud de θ.

Calculamos en primer lugar la función de verosimilitud para la muestra $(x_1, \ldots, x_n)$:

$$\begin{aligned} L_{x_1,\ldots,x_n}(\theta) &= \prod_{i=1}^{n} f_\theta(x_i) = \prod_{i=1}^{n} \frac{x_i}{\theta^2} \exp\left(-\frac{x_i^2}{2\theta^2}\right) = \\ &= \left(\prod_{i=1}^{n} x_i\right) \frac{1}{\theta^{2n}} \exp\left(-\frac{1}{2\theta^2} \sum_{i=1}^{n} x_i^2\right) \qquad \forall \theta > 0. \end{aligned}$$

Puesto que el logaritmo es una función estrictamente creciente, podemos trabajar con la log-verosimilitud:

$$\ln L_{x_1,\ldots,x_n}(\theta) = \sum_{i=1}^{n} \ln x_i - 2n \ln \theta - \frac{1}{2\theta^2} \sum_{i=1}^{n} x_i^2 \qquad \forall \theta > 0.$$

Como buscamos el máximo, derivamos respecto a θ e igualamos a cero:

$$\frac{d}{d\theta}\ln L_{x_1,\dots,x_n}(\theta) = -\frac{2n}{\theta} + \frac{1}{\theta^3}\sum_{i=1}^{n} x_i^2 = 0 \implies$$
$$\implies -2n\theta^2 + \sum_{i=1}^{n} x_i^2 = 0 \implies \theta^2 = \frac{1}{2n}\sum_{i=1}^{n} x_i^2.$$

Dado que $\theta > 0$, despejamos:

$$\theta = \sqrt{\frac{1}{2n}\sum_{i=1}^{n} x_i^2}.$$

Sería necesario comprobar que efectivamente se trata de un máximo, pero se tiene. Por tanto, el candidato a EMV de θ es:

$$\widehat{\theta} = \sqrt{\frac{1}{2n}\sum_{i=1}^{n} X_i^2}.$$

Como $\theta > 0$ y $\widehat{\theta} > 0$, podemos concluir que efectivamente $\widehat{\theta}$ es un estimador de θ, y por lo tanto, $\widehat{\theta}$ es el EMV de θ.

b) Dada una constante conocida $c > 0$, calcular el estimador de máxima verosimilitud de $P_\theta[X > c]$.

En primer lugar, calculamos la probabilidad teórica para $c > 0$:

$$P_\theta[X > c] = \int_c^\infty \frac{x}{\theta^2}\exp\left(-\frac{x^2}{2\theta^2}\right)dx = \left[-\exp\left(-\frac{x^2}{2\theta^2}\right)\right]_c^\infty =$$
$$= 0 - \left(-\exp\left(-\frac{c^2}{2\theta^2}\right)\right) = \exp\left(-\frac{c^2}{2\theta^2}\right).$$

Por tanto, buscamos el EMV de la función paramétrica:

$$g(\theta) = P_\theta[X > c] = \exp\left(-\frac{c^2}{2\theta^2}\right).$$

Por el Teorema de Invarianza de Zehna, si $\widehat{\theta}$ es el EMV de θ, entonces:

$$g(\widehat{\theta}) = \exp\left(-\frac{c^2}{2\widehat{\theta^2}}\right)$$

es el EMV de $g(\theta) = P_\theta[X > c]$.

Sustituyendo la expresión obtenida para $\widehat{\theta}$ en el apartado anterior:

$$\widehat{\theta^2} = \frac{1}{2n}\sum_{i=1}^{n} X_i^2,$$

obtenemos que el EMV de $P_\theta[X > c]$ es:

$$\widehat{P_\theta[X > c]} = \exp\left(-\frac{c^2}{2\left(\frac{1}{2n}\sum_{i=1}^{n} X_i^2\right)}\right) = \exp\left(-\frac{nc^2}{\sum_{i=1}^{n} X_i^2}\right).$$

Ejercicio 2.5.13. Sea $(X_1, \ldots, X_n)$ una muestra aleatoria simple de una variable aleatoria $X \rightsquigarrow \mathcal{N}(\mu, \mu^2)$ con $\mu > 0$.

1. Calcula los estimadores de μ basados en el primer y en el segundo momento muestral por separado usando el método de los momentos.

   Sabemos que $E[X] = \mu$, $Var[X] = \mu^2$ y

   $$m_2 = E[X^2] = Var[X] + (E[X])^2 = \mu^2 + \mu^2 = 2\mu^2$$

   Si usamos el **primer momento**:

   $$m_1 = A_1 \implies \mu = \overline{X} \implies \widehat{\mu}_1 = \overline{X}$$

   Si usamos el **segundo momento**:

   $$m_2 = A_2 \implies 2\mu^2 = \frac{1}{n}\sum_{i=1}^{n} X_i^2 \implies \widehat{\mu}_2 = \sqrt{\frac{1}{2n}\sum_{i=1}^{n} X_i^2}$$

   Notemos que obtenemos dos estimadores distintos de μ a partir de los dos momentos muestrales.

2. Plantea la ecuación de máxima verosimilitud para μ y deduce el EMV. Demuestra algebraicamente cómo este EMV "fusiona" la información de los dos estimadores del método de los momentos que hallaste en el primer apartado.

   La función de verosimilitud es:

   $$L_{x_1,\ldots,x_n}(\mu) \overset{\text{iid}}{=} \prod_{i=1}^{n} \frac{1}{\sqrt{2\pi\mu^2}} \exp\left(-\frac{(x_i-\mu)^2}{2\mu^2}\right) = (2\pi\mu^2)^{-n/2} \exp\left(-\frac{1}{2\mu^2}\sum_{i=1}^{n}(x_i-\mu)^2\right)$$

   Desarrollamos el cuadrado en el sumatorio:

   $$\sum_{i=1}^{n}(x_i-\mu)^2 = \sum_{i=1}^{n} x_i^2 - 2\mu\sum_{i=1}^{n} x_i + n\mu^2$$

   Puesto que el logaritmo es una función estrictamente creciente, podemos trabajar con la log-verosimilitud:

   $$\ln L(\mu) = -\frac{n}{2}\ln(2\pi) - n\ln\mu - \frac{1}{2\mu^2}\sum_{i=1}^{n} x_i^2 + \frac{1}{\mu}\sum_{i=1}^{n} x_i - \frac{n}{2}$$

Derivamos respecto a μ e igualamos a cero:

$$\frac{\partial \ln L(\mu)}{\partial \mu} = -\frac{n}{\mu} + \frac{1}{\mu^3}\sum_{i=1}^{n} x_i^2 - \frac{1}{\mu^2}\sum_{i=1}^{n} x_i = 0$$

Multiplicando por μ^3 y dividiendo entre n, obtenemos:

$$-\mu^2 + \frac{1}{n}\sum_{i=1}^{n} x_i^2 - \mu\frac{1}{n}\sum_{i=1}^{n} x_i = 0 \iff \mu^2 + \overline{X}\mu - A_2 = 0$$

Despejando μ de la ecuación cuadrática, obtenemos:

$$\mu = \frac{-\overline{X} \pm \sqrt{\overline{X}^2 + 4A_2}}{2}$$

Como $A_2 \geq 0$, el discriminante siempre es mayor que $\overline{X}^2$, por lo que la raíz cuadrada es mayor que $|\overline{X}|$. Como el parámetro μ está definido estrictamente positivo ($\mu > 0$), la única solución matemáticamente posible es tomar el signo positivo en la ecuación anterior, por lo que el EMV de μ es:

$$\widehat{\mu} = \frac{-\overline{X} + \sqrt{\overline{X}^2 + 4A_2}}{2}$$

Notemos además que se trata de un estimador, ya que $\widehat{\mu} > 0$ para cualquier muestra $(X_1, \ldots, X_n)$. Si recordamos del primer apartado que $\widehat{\mu}_1 = \overline{X}$ y $A_2 = 2\widehat{\mu}_2^2$, el EMV se puede reescribir como:

$$\widehat{\mu} = \frac{-\widehat{\mu}_1 + \sqrt{\widehat{\mu}_1^2 + 8\widehat{\mu}_2^2}}{2}$$

El EMV de μ es una combinación de los dos estimadores obtenidos por el método de los momentos, lo que significa que el EMV "fusiona" la información de ambos estimadores. En particular, el EMV toma en cuenta tanto la media muestral como el segundo momento muestral para proporcionar una estimación más precisa del parámetro μ.

3. Aplica el Teorema de Invarianza de Zehna para encontrar el EMV de la probabilidad de que una medición aleatoria sea negativa, es decir, estimar $P_\mu[X < 0]$. Interpreta el resultado.

   La probabilidad de que una medición aleatoria sea negativa es:

   $$P_\mu[X < 0] = \Phi\left(\frac{0-\mu}{\mu}\right) = \Phi(-1) \approx 0{,}1587$$

   donde Φ es la función de distribución acumulada de la normal estándar. Notemos que esta probabilidad no depende de μ, sino que es una constante.

Por el Teorema de Invarianza de Zehna, si $\widehat{\mu}$ es el EMV de μ, entonces:

$$\widehat{P_\mu[X < 0]} = P_{\widehat{\mu}}[X < 0] = \Phi\left(\frac{0 - \widehat{\mu}}{\widehat{\mu}}\right) = \Phi(-1) \approx 0{,}1587$$

El estimador máximo verosímil de esta probabilidad no depende en absoluto de la muestra $(X_1, \ldots, X_n)$. La propia estructura del modelo $\mathcal{N}(\mu, \mu^2)$ impone matemáticamente que siempre habrá un $\approx 15{,}866\,\%$ de masa de probabilidad en el eje negativo, independientemente de la magnitud de la media.