

Inferencia Estadística

FACULTAD
DE
CIENCIAS
UNIVERSIDAD DE GRANADA



Los Del DGIIM, losdeldgiim.github.io

Doble Grado en Ingeniería Informática y Matemáticas
Universidad de Granada



Esta obra está bajo una Licencia Creative Commons Atribución-NoComercial-SinDerivadas 4.0 Internacional (CC BY-NC-ND 4.0).

Eres libre de compartir y redistribuir el contenido de esta obra en cualquier medio o formato, siempre y cuando des el crédito adecuado a los autores originales y no persigas fines comerciales.

Inferencia Estadística

Los Del DGIIM, losdeldgiim.github.io

José Juan Urrutia Milán

Granada, 2025

Índice general

1. Ejercicios de clase	5
1.1. Estadísticos muestrales	5
1.2. Distribuciones en el muestreo de poblaciones normales	9
1.2.1. Muestreo en una población normal unidimensional	12
1.2.2. Muestreo en dos poblaciones normales unidimensionales	16
1.3. Suficiencia y completitud	19
2. Relaciones de Ejercicios	31
2.1. Suficiencia y completitud	32

1. Ejercicios de clase

Este capítulo tiene el propósito de recoger todos los ejercicios propuestos en clase por parte de la profesora y que fueron resueltos por los alumnos en pizarra.

1.1. Estadísticos muestrales

Ejercicio 1.1.1. Obtener la función masa de probabilidad conjunta de una m.a.s. de $X \rightsquigarrow B(k_0, p)$ y la función de densidad de una m.a.s. de $X \rightsquigarrow U(a, b)$.

Recordamos que si $X \rightsquigarrow B(k_0, p)$, entonces:

$$P[X = x] = \binom{k_0}{x} p^x (1-p)^{n-x} \quad \forall x \in \{0, \dots, k_0\}$$

Por lo que si tenemos una m.a.s. de n variables independientes e idénticamente distribuidas a X , $(X_1, \dots, X_n)$, su función de densidad vendrá dada por:

$$\begin{aligned} P[X_1 = x_1, \dots, X_n = x_n] &\stackrel{\text{indep.}}{=} \prod_{i=1}^n P[X_i = x_i] \stackrel{\text{id. d.}}{=} \prod_{i=1}^n P[X = x_i] \\ &= \prod_{i=1}^n \binom{k_0}{x_i} p^{x_i} (1-p)^{k_0-x_i} = p^{\sum_{i=1}^n x_i} (1-p)^{nk_0 - \sum_{i=1}^n x_i} \prod_{i=1}^n \binom{k_0}{x_i} \\ &\quad \forall x_i \in \{0, \dots, k_0\} \end{aligned}$$

Si ahora $X \rightsquigarrow U(a, b)$ para ciertos $a, b \in \mathbb{R}$ con $a < b$, entonces:

$$f_X(x) = \frac{1}{b-a} \quad \forall x \in [a, b]$$

de donde:

$$f_{(X_1, \dots, X_n)}(x_1, \dots, x_n) \stackrel{\text{indep.}}{=} \prod_{i=1}^n f_{X_i}(x_i) \stackrel{\text{id. d.}}{=} \prod_{i=1}^n f_X(x_i) = \prod_{i=1}^n \frac{1}{b-a} = \frac{1}{(b-a)^n} \quad \forall x \in [a, b]$$

Ejercicio 1.1.2. Para cada realización muestral, $(x_1, \dots, x_n) \in \mathcal{X}^n$, $F_{x_1, \dots, x_n}^*$ es una función de distribución en $\mathbb{R}$. En particular es una función a saltos, con saltos de amplitud $1/n$ en los sucesivos valores muestrales ordenados de menor a mayor, supuestos que sean distintos, y de saltos múltiples en el caso de que varios valores muestrales coincidieran.

En las condiciones del enunciado, es decir, suponiendo que $x_1, \dots, x_n$ están ordenados de menor a mayor y son distintos, entonces es fácil ver que:

$$F_{x_1, \dots, x_n}^*(x) = \begin{cases} 0 & \text{si } x < x_1 \\ 1/n & \text{si } x_1 \leq x < x_2 \\ \vdots & \\ 1 & \text{si } x > x_n \end{cases} \quad \forall x \in \mathbb{R}$$

Por lo que es claro que $F_{x_1, \dots, x_n}^*$ es no decreciente, continua por la derecha, con límite 0 en $-\infty$ y con límite 1 en $+\infty$.

Ejercicio 1.1.3. Para todo $x \in \mathbb{R}$, $F_{X_1, \dots, X_n}^*(x)$ es una variable aleatoria tal que $nF_{X_1, \dots, X_n}^*(x) \rightsquigarrow B(n, F(x))$ y:

$$E[F_{X_1, \dots, X_n}^*(x)] = F(x), \quad \text{Var}[F_{X_1, \dots, X_n}^*(x)] = \frac{F(x)(1 - F(x))}{n}$$

donde $F(x)$ es la función de distribución de X .

Recordamos que:

$$F_{X_1, \dots, X_n}^*(x) = \frac{1}{n} \sum_{i=1}^n I_{]-\infty, x]}(X_i) \quad \forall x \in \mathbb{R}$$

Fijado $x \in \mathbb{R}$, tenemos que $I_{]-\infty, x]}(X) \rightsquigarrow B(1, P[X \leq x]) \equiv B(1, F(x))$, por lo que por la propiedad reproductiva de la binomial tenemos que:

$$nF_{X_1, \dots, X_n}^*(x) \rightsquigarrow B(n, F(x))$$

Por lo que:

$$nE[F_{X_1, \dots, X_n}^*(x)] = E[nF_{X_1, \dots, X_n}^*(x)] = nF(x) \implies E[F_{X_1, \dots, X_n}^*(x)] = F(x)$$

Para la varianza:

$$\begin{aligned} n^2 \text{Var}[F_{X_1, \dots, X_n}^*(x)] &= \text{Var}[nF_{X_1, \dots, X_n}^*(x)] = nF(x)(1 - F(x)) \implies \\ &\implies \text{Var}[F_{X_1, \dots, X_n}^*(x)] = \frac{F(x)(1 - F(x))}{n} \end{aligned}$$

Ejercicio 1.1.4. Para valores grandes de n , en virtual del Teorema Central del Límite:

$$F_{X_1, \dots, X_n}^*(x) \rightsquigarrow \mathcal{N}\left(F(x), \frac{F(x)(1 - F(x))}{n}\right)$$

Sea $(X_1, \dots, X_n)$ una m.a.s. de n muestras, sea:

$$S_n = \sum_{i=1}^n I_{]-\infty, x]}(X_i) \quad \forall n \in \mathbb{N}$$

Por el Teorema Central del Límite tenemos que:

$$\frac{S_n - E[S_n]}{\sqrt{\text{Var}[S_n]}} \xrightarrow{n \rightarrow \infty} \mathcal{N}(0, 1) \implies S_n \xrightarrow{n \rightarrow \infty} \mathcal{N}(E[S_n], \text{Var}[S_n])$$

Como $S_n \rightsquigarrow B(n, F(x))$, entonces tenemos que:

$$\begin{aligned} E[S_n] &= nF(x) \\ \text{Var}[S_n] &= nF(x)(1 - F(x)) \end{aligned}$$

Por lo que:

$$F_{X_1, \dots, X_n}^*(x) = \frac{1}{n} S_n \xrightarrow{n \rightarrow \infty} \mathcal{N}\left(F(x), \frac{F(x)(1 - F(x))}{n}\right)$$

Ejercicio 1.1.5. Dada una muestra aleatoria simple formada por las observaciones $(3, 8, 5, 4, 5)$, obtener su función de distribución muestral y realizar la representación gráfica.

Aplicando la definición de la función de distribución muestral obtenemos que:

$$F_{(3,8,5,4,5)}^*(x) = \begin{cases} 0 & \text{si } x < 3 \\ 1/5 & \text{si } 3 \leq x < 4 \\ 2/5 & \text{si } 4 \leq x < 5 \\ 4/5 & \text{si } 5 \leq x < 8 \\ 1 & \text{si } x \geq 8 \end{cases}$$




Figura 1.1: Representación gráfica de $F_{(3,8,5,4,5)}^*(x)$.

Ejercicio 1.1.6. Sea X una variable aleatoria con distribución $B(1, p)$ con $p \in (0, 1)$. Se toma una muestra de tamaño 5, $(X_1, X_2, X_3, X_4, X_5)$, y se obtiene la siguiente observación $(0, 1, 1, 0, 0)$. Determinar el valor de los estadísticos estudiados en la observación.

Aplicando las fórmulas vistas en clase obtenemos:

- Media:

$$\bar{X} = \frac{0 + 1 + 1 + 0 + 0}{5} = 0,4$$

- Varianza muestral:

$$\sigma^2 = \frac{(0 - 0,4)^2 + (1 - 0,4)^2 + (1 - 0,4)^2 + (0 - 0,4)^2 + (0 - 0,4)^2}{5} = \frac{1,2}{5} = 0,24$$

- Cuasivarianza:

$$s^2 = \frac{(0 - 0,4)^2 + (1 - 0,4)^2 + (1 - 0,4)^2 + (0 - 0,4)^2 + (0 - 0,4)^2}{5 - 1} = \frac{1,2}{4} = 0,3$$

- Estadísticos ordenados:

$$x_{(1)} = 0, \quad x_{(2)} = 0, \quad x_{(3)} = 0, \quad x_{(4)} = 1, \quad x_{(5)} = 1$$

Ejercicio 1.1.7. Sea $(X_1, \dots, X_n)$ una m.a.s. y $\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$, entonces:

$$M_{\bar{X}}(t) = (M_X(t/n))^n$$

$$M_{\bar{X}}(t) = E \left[e^{t\bar{X}} \right] = E \left[e^{\frac{t}{n} \sum_{i=1}^n X_i} \right] = M_{\sum_{i=1}^n X_i} \left(\frac{t}{n} \right) \stackrel{\text{indep.}}{=} \prod_{i=1}^n M_{X_i} \left(\frac{t}{n} \right) \stackrel{\text{id. d.}}{=} \left(M_X \left(\frac{t}{n} \right) \right)^n$$

Ejercicio 1.1.8. Obtener la distribución muestral de $\bar{X}$ para $(X_1, \dots, X_n)$ una m.a.s. de $X \rightsquigarrow \mathcal{N}(\mu, \sigma^2)$.

$$M_{\bar{X}}(t) = \left(M_X \left(\frac{t}{n} \right) \right)^n = \left(e^{\frac{\mu t}{n} + \frac{\sigma^2 t^2}{2n^2}} \right)^n = e^{\mu t + \frac{\sigma^2 t^2}{2n}}$$

Luego $\bar{X} \rightsquigarrow \mathcal{N} \left(\mu, \frac{\sigma^2}{n} \right)$, ya que la función generatriz de momentos caracteriza la distribución.

Proposición 1.1.1. Si tenemos una m.a.s. $(X_1, \dots, X_n)$, entonces:

$$\begin{aligned} F_{X_{(n)}}(x) &= (F_X(x))^n \quad \forall x \in \mathbb{R} \\ F_{X_{(1)}}(x) &= 1 - (1 - F_X(x))^n \end{aligned}$$

Demostración. Para la distribución del máximo:

$$\begin{aligned} F_{X_{(n)}}(x) &= P[X_{(n)} \leq x] = P[X_1 \leq x, \dots, X_n \leq x] \stackrel{\text{indep.}}{=} \prod_{i=1}^n P[X_i \leq x] \\ &\stackrel{\text{id. d.}}{=} \prod_{i=1}^n P[X \leq x] = (F_X(x))^n \end{aligned}$$

Para la del mínimo:

$$\begin{aligned} F_{X_{(1)}}(x) &= P[X_{(1)} \leq x] = 1 - P[X_{(1)} > x] = 1 - P[X_1 > x, \dots, X_n > x] \\ &\stackrel{\text{indep.}}{=} 1 - \prod_{i=1}^n P[X_i > x] \stackrel{\text{id. d.}}{=} 1 - (P[X > x])^n = 1 - (1 - F_X(x))^n \end{aligned}$$

□

Ejercicio 1.1.9. Obtener las distribuciones muestrales de $X_{(1)}$ y $X_{(n)}$ para $X \rightsquigarrow U(a, b)$.

Si $X \rightsquigarrow U(a, b)$, entonces:

$$F_X(x) = \frac{x-a}{b-a} \quad \forall x \in [a, b]$$

Por lo que aplicando la Proposición superior:

$$F_{X_{(n)}}(x) = (F_X(x))^n = \left(\frac{x-a}{b-a}\right)^n \quad \forall x \in [a, b]$$

$$F_{X_{(1)}}(x) = 1 - (1 - F_X(x))^n = 1 - \left(1 - \frac{x-a}{b-a}\right)^n = 1 - \left(\frac{b-x}{b-a}\right)^n \quad \forall x \in [a, b]$$

Ejercicio 1.1.10. Sea $(X_1, \dots, X_n)$ una m.a.s. de X . Entonces, para los momentos no centrados de orden k de la m.a.s. se tiene que:

$$\begin{aligned} E[A_k] &= E[X^k] \\ \text{Var}[A_k] &= \frac{\text{Var}[X^k]}{n} \end{aligned}$$

Demostremos la primera igualdad:

$$E[A_k] = E\left[\frac{1}{n} \sum_{i=1}^n X_i^k\right] = \frac{1}{n} \sum_{i=1}^n E[X_i^k] \stackrel{\text{id. d.}}{=} \frac{1}{n} \sum_{i=1}^n E[X^k] = E[X^k]$$

Demostremos la segunda igualdad:

$$\begin{aligned} \text{Var}[A_k] &= \text{Var}\left[\frac{1}{n} \sum_{i=1}^n X_i^k\right] = \frac{1}{n^2} \text{Var}\left[\sum_{i=1}^n X_i^k\right] \stackrel{\text{indep.}}{=} \frac{1}{n^2} \sum_{i=1}^n \text{Var}[X_i^k] \stackrel{\text{id. d.}}{=} \\ &\stackrel{\text{id. d.}}{=} \frac{1}{n^2} \sum_{i=1}^n \text{Var}[X^k] = \frac{\text{Var}[X^k]}{n} \end{aligned}$$

1.2. Distribuciones en el muestreo de poblaciones normales

Proposición 1.2.2. Sea $X \rightsquigarrow \mathcal{N}(0, 1)$, entonces $X^2 \rightsquigarrow \chi^2(1)$.

Demostración. Sea $Y = X^2 = h(X)$, entonces $X = \pm\sqrt{Y} = h^{-1}(y)$, por lo que:

$$f_Y(y) = f_X(h_1^{-1}(y)) \left| \frac{dh_1^{-1}(y)}{dy} \right| + f_X(h_2^{-1}(y)) \left| \frac{dh_2^{-1}(y)}{dy} \right|$$

Como $X \rightsquigarrow \mathcal{N}(0, 1)$, entonces:

$$f_X(x) = \frac{1}{\sqrt{2\pi}} e^{-\frac{x^2}{2}} \quad \forall x \in \mathbb{R}$$

De donde:

$$f_Y(y) = \frac{1}{\sqrt{2\pi}} e^{\frac{-(\sqrt{y})^2}{2}} \left| \frac{1}{2\sqrt{y}} \right| + \frac{1}{\sqrt{2\pi}} e^{\frac{-(-\sqrt{y})^2}{2}} \left| \frac{-1}{2\sqrt{y}} \right| = \frac{1}{\sqrt{2\pi y}} e^{\frac{-y}{2}} \quad \forall y > 0$$

Por lo que $Y \rightsquigarrow \chi^2(1)$. □

Ejercicio 1.2.1. Calcula el valor de k o la probabilidad inducida:

a) $P[\chi^2(10) \geq k] = 0,005$.

Consultando la tabla de la distribución χ^2 , obtenemos que $k = 25,1881$.

b) $P[\chi^2(45) \leq k] = 0,005$.

Tenemos que:

$$P[\chi^2(45) \leq k] = 1 - P[\chi^2(45) \geq k] = 0,005 \implies P[\chi^2(45) \geq k] = 0,995$$

Consultando la tabla de la distribución χ^2 , obtenemos que $k = 24,3110$.

c) $P[\chi^2(14) \geq 21,06]$

En este caso, no podemos consultar de forma directa los encabezados de la tabla de la distribución χ^2 y obtener el valor de la probabilidad, sino que tenemos que buscar qué columna de la tabla contiene el valor buscado. Podemos ver que:

$$P[\chi^2(14) \geq 21,06] \approx 0,1$$

d) $P[\chi^2(20) \leq 12,44]$

Tenemos que:

$$P[\chi^2(20) \leq 12,44] = 1 - P[\chi^2(20) \geq 12,44] \stackrel{(*)}{=} 1 - 0,9 = 0,1$$

donde en $(*)$ hemos consultado la tabla de la distribución χ^2 .

Ejercicio 1.2.2. Calcula el valor de k o la probabilidad inducida:

a) $P[t(26) \geq k] = 0,05$

Consultando la tabla de la distribución t de Student, obtenemos que $k = 1,706$.

b) $P[t(20) \leq k] = 0,25$

Por la simetría de la distribución t de Student, tenemos que:

$$0,25 = P[t(20) \leq k] = P[t(20) \geq -k]$$

Consultando la tabla de la distribución t de Student, obtenemos que $-k = 0,6870$, luego $k = -0,6870$.

c) $P[t(26) \geq k] = 0,9$

Tenemos que:

$$0,9 = P[t(26) \geq k] = 1 - P[t(26) \leq k] = 1 - P[t(26) \geq -k] \implies P[t(26) \geq -k] = 0,1$$

Consultando la tabla de la distribución t de Student, obtenemos que $-k = 1,3150$, luego $k = -1,3150$.

d) $P[t(21) \geq 1,721]$

Consultando la tabla de la distribución t de Student, obtenemos que:

$$P[t(21) \geq 1,721] \approx 0,05$$

e) $P[t(11) \leq 0,697]$

Consultando la tabla de la distribución t de Student, obtenemos que:

$$P[t(11) \leq 0,697] = 1 - P[t(11) \geq 0,697] \approx 1 - 0,25 = 0,75$$

f) $P[t(8) \leq -2,306]$

Tenemos que:

$$P[t(8) \leq -2,306] = P[t(8) \geq 2,306] = 0,025$$

Ejercicio 1.2.3. Calcula el valor de k o la probabilidad inducida:

a) $P[F(7, 3) \leq k] = 0,95$

Consultando de manera directa la tabla de la distribución F de Snedecor, obtenemos que $k = 8,89$.

b) $P[F(8, 4) \geq k] = 0,01$

$$0,01 = P[F(8, 4) \geq k] = 1 - P[F(8, 4) \leq k] \implies P[F(8, 4) \leq k] = 0,99$$

Consultando la tabla de la distribución F de Snedecor, obtenemos que $k = 14,8$.

c) $P[F(2, 2) \leq 19]$

Consultando la tabla de la distribución F de Snedecor, obtenemos que:

$$P[F(2, 2) \leq 19] = 0,95$$

d) $P[F(3, 5) \geq 12,1]$

$$P[F(3, 5) \geq 12,1] = 1 - P[F(3, 5) \leq 12,1] \stackrel{(*)}{=} 1 - 0,99 = 0,01$$

donde en $(*)$ hemos consultado la tabla de la distribución F de Snedecor.

e) $P[F(60, 40) \leq k] = 0,05$

Consultando la tabla de la distribución F de Snedecor, obtenemos que $k = 0,627$.

1.2.1. Muestreo en una población normal unidimensional

En lo que sigue, sea una $(X_1, \dots, X_n)$ m.a.s. con $X \rightsquigarrow \mathcal{N}(\mu, \sigma^2)$.

Proposición 1.2.3. En dichas condiciones, veamos que:

$$\bar{X}, (X_1 - \bar{X}, \dots, X_n - \bar{X}) \text{ son independientes}$$

Demostración. Para ellos, usaremos la caracterización de independencia de vectores aleatorios por la función generatriz de momentos conjunta. Es decir, busquemos probar

$$M_{\bar{X}, X_1 - \bar{X}, \dots, X_n - \bar{X}}(t, t_1, \dots, t_n) \stackrel{?}{=} M_{\bar{X}}(t) M_{X_1 - \bar{X}, \dots, X_n - \bar{X}}(t_1, \dots, t_n)$$

Por la reproductividad de la normal, todas las variables aleatorias que aparecen son normales, luego su función característica de momentos está definida en todo $\mathbb{R}$. Por tanto, para todo $(t, t_1, \dots, t_n) \in \mathbb{R}^{n+1}$, tenemos que:

$$\begin{aligned} M_{\bar{X}, X_1 - \bar{X}, \dots, X_n - \bar{X}}(t, t_1, \dots, t_n) &= E \left[e^{(t, t_1, \dots, t_n) \cdot (\bar{X}, X_1 - \bar{X}, \dots, X_n - \bar{X})} \right] = E \left[e^{t\bar{X} + \sum_{i=1}^n (X_i - \bar{X})t_i} \right] = \\ &= E \left[e^{\frac{t}{n} \sum_{i=1}^n X_i + \sum_{i=1}^n X_i t_i - \sum_{i=1}^n \bar{X} t_i} \right] = E \left[e^{\frac{t}{n} \sum_{i=1}^n X_i + \sum_{i=1}^n X_i t_i - \bar{X} \sum_{i=1}^n t_i} \right] = \\ &= E \left[e^{\frac{t}{n} \sum_{i=1}^n X_i + \sum_{i=1}^n X_i t_i - \frac{1}{n} \sum_{i=1}^n X_i \sum_{j=1}^n t_j} \right] = E \left[e^{\frac{t}{n} \sum_{i=1}^n X_i + \sum_{i=1}^n X_i t_i - \sum_{i=1}^n X_i \frac{1}{n} \sum_{j=1}^n t_j} \right] = \\ &= E \left[e^{\frac{t}{n} \sum_{i=1}^n X_i + \sum_{i=1}^n X_i t_i - \sum_{i=1}^n X_i \bar{t}} \right] = E \left[e^{\sum_{i=1}^n X_i \left(\frac{t}{n} + t_i - \bar{t} \right)} \right] = \\ &= E \left[e^{\sum_{i=1}^n X_i \left(\frac{t}{n} + t_i - \bar{t} \right)} \right] \stackrel{\text{indep.}}{=} \prod_{i=1}^n E \left[e^{X_i \left(\frac{t}{n} + t_i - \bar{t} \right)} \right] = \\ &= \prod_{i=1}^n M_{X_i} \left(\frac{t}{n} + t_i - \bar{t} \right) \stackrel{(*)}{=} \prod_{i=1}^n \exp \left[\left(\frac{t}{n} + t_i - \bar{t} \right) \mu + \left(\frac{t}{n} + t_i - \bar{t} \right)^2 \frac{\sigma^2}{2} \right] = \\ &= \exp \left[\sum_{i=1}^n \left[\left(\frac{t}{n} + t_i - \bar{t} \right) \mu + \frac{\sigma^2}{2} \left(\frac{t^2}{n^2} + (t_i - \bar{t})^2 + 2 \frac{t}{n} (t_i - \bar{t}) \right) \right] \right] = \\ &= \exp \left[\sum_{i=1}^n \frac{\mu t}{n} + \sum_{i=1}^n \mu (t_i - \bar{t}) + \frac{\sigma^2}{2} \left(\sum_{i=1}^n \frac{t^2}{n^2} + \sum_{i=1}^n (t_i - \bar{t})^2 + 2 \sum_{i=1}^n \frac{t}{n} (t_i - \bar{t}) \right) \right] \stackrel{(**)}{=} \\ &\stackrel{(**)}{=} \exp \left[\frac{\cancel{\mathcal{N}} \mu t}{\cancel{\mathcal{N}}} + \mu \sum_{i=1}^n \cancel{(t_i - \bar{t})} + \frac{\sigma^2}{2} \left(\frac{\cancel{\mathcal{N}} t^2}{\cancel{\mathcal{N}}} + \sum_{i=1}^n (t_i - \bar{t})^2 + 2 \frac{t}{n} \sum_{i=1}^n \cancel{(t_i - \bar{t})} \right) \right] = \\ &= \exp \left[\mu t + \frac{\sigma^2 t^2}{2n} + \frac{\sigma^2}{2} \sum_{i=1}^n (t_i - \bar{t})^2 \right] \end{aligned}$$

donde en $(*)$ hemos usado que todas las variables son idénticamente distribuidas a una $\mathcal{N}(\mu, \sigma^2)$; y en $(**)$ hemos usado que el momento centrado de primer orden es

cero. Sabemos que:

$$\begin{aligned} M_{\bar{X}}(t) &= M_{(\bar{X}, X_1 - \bar{X}, \dots, X_n - \bar{X})}(t, 0, \dots, 0) = e^{\mu t + \frac{\sigma^2 t^2}{2n}} \\ M_{(X_1 - \bar{X}, \dots, X_n - \bar{X})}(t_1, \dots, t_n) &= M_{(\bar{X}, X_1 - \bar{X}, \dots, X_n - \bar{X})}(0, t_1, \dots, t_n) \\ &= e^{\frac{\sigma^2}{2} \sum_{i=1}^n (t_i - \bar{t})^2} \end{aligned}$$

Por tanto, tenemos que el producto de las funciones generatrices de momentos es la generatriz de momentos conjunta, luego las variables son independientes. $\square$

Corolario 1.2.3.1. En dichas condiciones, tenemos que:

1. $\bar{X} \rightsquigarrow \mathcal{N}(\mu, \frac{\sigma^2}{n})$
2. (Lema de Fisher): $\bar{X}$ y S^2 son independientes.
3. $\frac{(n-1)S^2}{\sigma^2} \rightsquigarrow \chi^2(n-1)$
4. $\frac{\bar{X} - \mu}{S/\sqrt{n}} \rightsquigarrow t(n-1)$

Demostración. Demostramos cada una de las afirmaciones:

- Se vio ya en el Ejercicio 1.1.8.
- Como S^2 es función del vector de la Proposición anterior, tenemos que es independiente a $\bar{X}$, ya que las funciones de variables independientes son independientes.
- Queremos demostrar que:

$$\frac{(n-1)S^2}{\sigma^2} = \frac{\sum_{i=1}^n (X_i - \bar{X})^2}{\sigma^2} \rightsquigarrow \chi^2(n-1)$$

Tenemos que:

$$\begin{aligned} \frac{\sum_{i=1}^n (X_i - \mu)^2}{\sigma^2} &= \frac{\sum_{i=1}^n (X_i - \bar{X} + \bar{X} - \mu)^2}{\sigma^2} \\ &= \frac{\sum_{i=1}^n (X_i - \bar{X})^2 + \sum_{i=1}^n (\bar{X} - \mu)^2 + 2 \sum_{i=1}^n (X_i - \bar{X})(\bar{X} - \mu)}{\sigma^2} \\ &= \frac{\sum_{i=1}^n (X_i - \bar{X})^2}{\sigma^2} + n \frac{(\bar{X} - \mu)^2}{\sigma^2} \end{aligned}$$

Notemos que estamos interesados en conocer la distribución de la primera parte de la suma. Notemos por A a la suma completa, por B a la primera parte y por C a la segunda parte, de forma que $A = B + C$. Veamos la distribución de cada término:

- Por un lado para A , tenemos que:

$$A = \frac{\sum_{i=1}^n (X_i - \mu)^2}{\sigma^2} = \sum_{i=1}^n \left(\frac{X_i - \mu}{\sigma} \right)^2 \stackrel{(*)}{=} \sum_{i=1}^n Z_i^2 \rightsquigarrow \chi^2(n)$$

donde en $(*)$ hemos usado que $X_i \rightsquigarrow \mathcal{N}(\mu, \sigma^2)$, por lo que su variable tipificada $Z_i \rightsquigarrow \mathcal{N}(0, 1)$. Además, en la última igualdad hemos empleado la construcción de la distribución χ^2 a partir de variables normales.

- Por otro lado, para C , del Ejercicio 1.1.8, tenemos que $\bar{X} \rightsquigarrow \mathcal{N}(\mu, \frac{\sigma^2}{n})$, por lo que, tipificando

$$\frac{\bar{X} - \mu}{\sqrt{\sigma^2/n}} = \frac{\bar{X} - \mu}{\sigma/\sqrt{n}} = \sqrt{n} \frac{\bar{X} - \mu}{\sigma} \rightsquigarrow \mathcal{N}(0, 1)$$

Elevando al cuadrado y empleando la construcción de la distribución χ^2 , obtenemos que:

$$C = n \frac{(\bar{X} - \mu)^2}{\sigma^2} \rightsquigarrow \chi^2(1)$$

Buscamos la distribución de B , y para ello, buscamos su caracterización por la función generatriz de momentos. Tenemos que $B = f(S^2)$, mientras que $C = g(\bar{X})$. Como, por el Lema de Fisher, $\bar{X}$ y S^2 son independientes, tenemos que B y C son independientes. Por lo que:

$$M_{A=B+C}(t) \stackrel{\text{indep.}}{=} M_B(t) M_C(t)$$

Veamos la función generatriz de momentos de A y C :

- Para A , tenemos que $A \rightsquigarrow \chi^2(n)$, por lo que:

$$M_A(t) = \frac{1}{(1 - 2t)^{n/2}} \quad t < \frac{1}{2}$$

- Para C , tenemos que $C \rightsquigarrow \chi^2(1)$, por lo que:

$$M_C(t) = \frac{1}{(1 - 2t)^{\frac{1}{2}}} \quad t < \frac{1}{2}$$

Por tanto, tenemos que:

$$M_B(t) = \frac{M_A(t)}{M_C(t)} = \frac{\frac{1}{(1 - 2t)^{\frac{n}{2}}}}{\frac{1}{(1 - 2t)^{\frac{1}{2}}}} = \frac{1}{(1 - 2t)^{\frac{n-1}{2}}} \quad t < \frac{1}{2}$$

De aquí, deducimos que $B \rightsquigarrow \chi^2(n - 1)$.

- Queremos ver que $\frac{\bar{X} - \mu}{s/\sqrt{n}} \rightsquigarrow t(n-1)$.

Para ello, al igual que la χ^2 , lo más sencillo es ir a la construcción de t :

$$\left. \begin{array}{l} X \rightsquigarrow \mathcal{N}(0, 1) \\ Y \rightsquigarrow \chi^2(n) \\ X \text{ e } Y \text{ independientes} \end{array} \right\} \Rightarrow \frac{X}{\sqrt{Y/n}} \rightsquigarrow t(n)$$

Por un lado, como $\bar{X} \rightsquigarrow \mathcal{N}(\mu, \frac{\sigma^2}{n})$, tenemos que:

$$\frac{\bar{X} - \mu}{\sigma/\sqrt{n}} \rightsquigarrow \mathcal{N}(0, 1)$$

Por otro lado, del punto anterior, tenemos que:

$$\frac{(n-1)S^2}{\sigma^2} \rightsquigarrow \chi^2(n-1)$$

Como $\bar{X}$ y S^2 son independientes por el Lema de Fisher, tenemos que ambas variables aleatorias consideradas son independientes, por lo que podemos aplicar la construcción de la distribución t :

$$\frac{\frac{\bar{X} - \mu}{\sigma/\sqrt{n}}}{\sqrt{\frac{(n-1)S^2}{\sigma^2(n-1)}}} = \frac{\frac{\bar{X} - \mu}{\cancel{\sigma}/\sqrt{n}}}{\frac{S}{\cancel{\sigma}}} = \frac{\bar{X} - \mu}{s/\sqrt{n}} \rightsquigarrow t(n-1)$$

□

Gracias a este corolario, podemos inferir sobre μ y σ^2 de la población normal a partir de una m.a.s. de la misma. En particular, tenemos que los siguientes resultados, con demostración evidente a partir del corolario anterior:

1. Si queremos inferir sobre μ :
 - a) Si conocemos σ_0^2 (notaremos con el subíndice 0 que es un valor conocido), entonces:

$$\frac{\bar{X} - \mu}{\sigma_0/\sqrt{n}} \rightsquigarrow \mathcal{N}(0, 1)$$

- b) Si no conocemos σ^2 , entonces:

$$\frac{\bar{X} - \mu}{s/\sqrt{n}} \rightsquigarrow t(n-1)$$

2. Si queremos inferir sobre σ^2 :

- a) Si conocemos μ_0 , entonces:

$$\frac{\sum_{i=1}^n (X_i - \mu_0)^2}{\sigma^2} \rightsquigarrow \chi^2(n)$$

b) Si no conocemos μ , entonces:

$$\frac{\sum_{i=1}^n (X_i - \bar{X})^2}{\sigma^2} \rightsquigarrow \chi^2(n-1)$$

1.2.2. Muestreo en dos poblaciones normales unidimensionales

En lo que sigue, sean $(X_1, \dots, X_{n_1})$ y $(Y_1, \dots, Y_{n_2})$ m.a.s. independientes con $X \rightsquigarrow \mathcal{N}(\mu_1, \sigma_1^2)$ y $Y \rightsquigarrow \mathcal{N}(\mu_2, \sigma_2^2)$.

Teorema 1.2.4 (Extensión del Lema de Fisher). *Los vectores $(\bar{X}, \bar{Y})$, (S_1^2, S_2^2) son independientes.*

Demostración. Usemos la función generatriz de momentos, ya que son independientes si y solo si:

$$M_{(\bar{X}, \bar{Y}, S_1^2, S_2^2)}(t_1, t_2, s_1, s_2) \stackrel{?}{=} M_{(\bar{X}, \bar{Y})}(t_1, t_2) M_{(S_1^2, S_2^2)}(s_1, s_2)$$

Como $(\bar{X}, S_1^2) = f(X_1, \dots, X_{n_1})$ y $(\bar{Y}, S_2^2) = g(Y_1, \dots, Y_{n_2})$, tenemos que ambos vectores son independientes, por lo que:

$$M_{(\bar{X}, \bar{Y}, S_1^2, S_2^2)}(t_1, t_2, s_1, s_2) = M_{(\bar{X}, S_1^2)}(t_1, s_1) M_{(\bar{Y}, S_2^2)}(t_2, s_2)$$

Aplicando ahora el Lema de Fisher a cada uno de los vectores, tenemos que:

$$M_{(\bar{X}, \bar{Y}, S_1^2, S_2^2)}(t_1, t_2, s_1, s_2) = M_{\bar{X}}(t_1) M_{S_1^2}(s_1) M_{\bar{Y}}(t_2) M_{S_2^2}(s_2)$$

Nuevamente, como $\bar{X} = f(X_1, \dots, X_{n_1})$ y $\bar{Y} = g(Y_1, \dots, Y_{n_2})$, y $S_1^2 = h(X_1, \dots, X_{n_1})$ y $S_2^2 = k(Y_1, \dots, Y_{n_2})$, tenemos que $\bar{X}$ y $\bar{Y}$ son independientes, y S_1^2 y S_2^2 son independientes. Por tanto:

$$M_{(\bar{X}, \bar{Y}, S_1^2, S_2^2)}(t_1, t_2, s_1, s_2) = M_{(\bar{X}, \bar{Y})}(t_1, t_2) M_{(S_1^2, S_2^2)}(s_1, s_2)$$

De aquí deducimos que los vectores $(\bar{X}, \bar{Y})$ y (S_1^2, S_2^2) son independientes. $\square$

Corolario 1.2.4.1. En dichas condiciones, tenemos que:

$$1. \frac{n_2 \sigma_2^2 \sum_{i=1}^{n_1} (X_i - \mu_1)^2}{n_1 \sigma_1^2 \sum_{i=1}^{n_2} (Y_i - \mu_2)^2} \rightsquigarrow F(n_1, n_2)$$

$$2. \frac{S_1^2/\sigma_1^2}{S_2^2/\sigma_2^2} \rightsquigarrow F(n_1 - 1, n_2 - 1).$$

En particular, si $\sigma_1 = \sigma_2$, se tiene:

$$\frac{S_1^2}{S_2^2} \rightsquigarrow F(n_1 - 1, n_2 - 1)$$

$$3. \frac{\bar{X} - \bar{Y} - (\mu_1 - \mu_2)}{\sqrt{\frac{(n_1 - 1)S_1^2}{\sigma_1^2} + \frac{(n_2 - 1)S_2^2}{\sigma_2^2}}} \cdot \sqrt{\frac{n_1 + n_2 - 2}{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}}} \rightsquigarrow t(n_1 + n_2 - 2).$$

En particular, si $\sigma_1 = \sigma_2$, se tiene:

$$\frac{\bar{X} - \bar{Y} - (\mu_1 - \mu_2)}{\sqrt{(n_1 - 1)S_1^2 + (n_2 - 1)S_2^2}} \cdot \sqrt{\frac{n_1 + n_2 - 2}{\frac{1}{n_1} + \frac{1}{n_2}}} \rightsquigarrow t(n_1 + n_2 - 2)$$

Demostración. Demostramos cada una de las afirmaciones:

1. Partiremos de la construcción de la distribución F de Snedecor:

$$\left. \begin{array}{l} X \rightsquigarrow \chi^2(m) \\ Y \rightsquigarrow \chi^2(n) \\ X \text{ e } Y \text{ independientes} \end{array} \right\} \Rightarrow \frac{X/m}{Y/n} \rightsquigarrow F(m, n)$$

Por otro lado, como $X \rightsquigarrow \mathcal{N}(\mu_1, \sigma_1^2)$ y $Y \rightsquigarrow \mathcal{N}(\mu_2, \sigma_2^2)$, y haciendo uso de la construcción de la distribución χ^2 a partir de variables normales, tenemos que:

$$\frac{\sum_{i=1}^{n_1} (X_i - \mu_1)^2}{\sigma_1^2} \rightsquigarrow \chi^2(n_1) \quad \frac{\sum_{i=1}^{n_2} (Y_i - \mu_2)^2}{\sigma_2^2} \rightsquigarrow \chi^2(n_2)$$

Como las m.a.s. son independientes y ambas distribuciones χ^2 son funciones de las m.a.s., tenemos que ambas variables son independientes. Por tanto, podemos aplicar la construcción de la distribución F de Snedecor:

$$\frac{\frac{\sum_{i=1}^{n_1} (X_i - \mu_1)^2}{n_1 \sigma_1^2}}{\frac{\sum_{i=1}^{n_2} (Y_i - \mu_2)^2}{n_2 \sigma_2^2}} = \frac{n_2 \sigma_2^2}{n_1 \sigma_1^2} \frac{\sum_{i=1}^{n_1} (X_i - \mu_1)^2}{\sum_{i=1}^{n_2} (Y_i - \mu_2)^2} \rightsquigarrow F(n_1, n_2)$$

2. Seguimos buscando la construcción de F de Snedecor. Por el Corolario 1.2.3.1 sabemos que:

$$\frac{(n_1 - 1)S_1^2}{\sigma_1^2} \rightsquigarrow \chi^2(n_1 - 1) \quad \frac{(n_2 - 1)S_2^2}{\sigma_2^2} \rightsquigarrow \chi^2(n_2 - 1)$$

Estas son independientes por ser funciones de ambas m.a.s., que son independientes. Dividimos:

$$\frac{\frac{(n_1 - 1)S_1^2}{\sigma_1^2 (n_1 - 1)}}{\frac{(n_2 - 1)S_2^2}{\sigma_2^2 (n_2 - 1)}} = \frac{S_1^2/\sigma_1^2}{S_2^2/\sigma_2^2} \rightsquigarrow F(n_1 - 1, n_2 - 1)$$

3. En este caso, buscamos aplicar la construcción de la distribución t de Student:

$$\left. \begin{array}{l} X \rightsquigarrow \mathcal{N}(0, 1) \\ Y \rightsquigarrow \chi^2(n) \\ X \text{ e } Y \text{ independientes} \end{array} \right\} \Rightarrow \frac{X}{\sqrt{Y/n}} \rightsquigarrow t(n)$$

Queremos probar:

$$\frac{\bar{X} - \bar{Y} - (\mu_1 - \mu_2)}{\sqrt{\frac{(n_1 - 1)S_1^2}{\sigma_1^2} + \frac{(n_2 - 1)S_2^2}{\sigma_2^2}}} \sqrt{\frac{n_1 + n_2 - 2}{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}}} \rightsquigarrow t(n_1 + n_2 - 2)$$

Tenemos que $\bar{X} \rightsquigarrow \mathcal{N}(\mu_1, \sigma_1^2/n_1)$ y $\bar{Y} \rightsquigarrow \mathcal{N}(\mu_2, \sigma_2^2/n_2)$. Además, tenemos que:

$$-\bar{Y} \rightsquigarrow \mathcal{N}(-\mu_2, \sigma_2^2/n_2)$$

Como $\bar{X}$ e $-\bar{Y}$ son funciones de m.a.s. independientes, tenemos que son independientes. Por tanto, por la reproductividad de la distribución normal, tenemos que:

$$\bar{X} - \bar{Y} \rightsquigarrow \mathcal{N}\left(\mu_1 - \mu_2, \frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}\right)$$

Tipificando, tenemos que:

$$\frac{\bar{X} - \bar{Y} - (\mu_1 - \mu_2)}{\sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}}} \rightsquigarrow \mathcal{N}(0, 1)$$

Por otro lado, del Corolario 1.2.3.1, tenemos que:

$$\frac{(n_1 - 1)S_1^2}{\sigma_1^2} \rightsquigarrow \chi^2(n_1 - 1) \quad \frac{(n_2 - 1)S_2^2}{\sigma_2^2} \rightsquigarrow \chi^2(n_2 - 1)$$

Como las m.a.s. son independientes, tenemos que estas dos variables aleatorias son independientes. Por la reproductividad de la distribución χ^2 , tenemos que:

$$\frac{(n_1 - 1)S_1^2}{\sigma_1^2} + \frac{(n_2 - 1)S_2^2}{\sigma_2^2} \rightsquigarrow \chi^2(n_1 + n_2 - 2)$$

Por la extensión del Lema de Fisher tenemos que las dos variables aleatorias que hemos calculado son independientes. Procedemos ahora a aplicar la construcción de la t de Student:

$$\frac{\bar{X} - \bar{Y} - (\mu_1 - \mu_2)}{\sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}}} \sqrt{\frac{n_1 + n_2 - 2}{\frac{(n_1 - 1)S_1^2}{\sigma_1^2} + \frac{(n_2 - 1)S_2^2}{\sigma_2^2}}} \rightsquigarrow t(n_1 + n_2 - 2)$$

□

Gracias a estos resultados, podemos inferir sobre $\mu_1 - \mu_2$ y σ_1^2/σ_2^2 a partir de dos m.a.s. independientes de poblaciones normales. En particular, tenemos los siguientes resultados:

1. Si queremos inferir sobre $\mu_1 - \mu_2$ (comparación de medias):

a) Si conocemos las varianzas poblacionales σ_{10}^2 y σ_{20}^2 , entonces:

$$\frac{(\bar{X} - \bar{Y}) - (\mu_1 - \mu_2)}{\sqrt{\frac{\sigma_{10}^2}{n_1} + \frac{\sigma_{20}^2}{n_2}}} \rightsquigarrow \mathcal{N}(0, 1)$$

b) Si las varianzas son desconocidas pero iguales ($\sigma_1^2 = \sigma_2^2 = \sigma^2$), entonces:

$$\frac{(\bar{X} - \bar{Y}) - (\mu_1 - \mu_2)}{\sqrt{(n_1 - 1)S_1^2 + (n_2 - 1)S_2^2}} \sqrt{\frac{n_1 + n_2 - 2}{\frac{1}{n_1} + \frac{1}{n_2}}} \rightsquigarrow t(n_1 + n_2 - 2)$$

2. Si queremos inferir sobre σ_1^2/σ_2^2 (comparación de varianzas):

a) Si conocemos las medias μ_{10} y μ_{20} , entonces:

$$\frac{n_1 \sigma_1^2 \sum_{i=1}^{n_2} (Y_i - \mu_{20})^2}{n_2 \sigma_2^2 \sum_{i=1}^{n_1} (X_i - \mu_{10})^2} \rightsquigarrow F(n_2, n_1)$$

b) Si no conocemos las medias μ_1 y μ_2 , entonces:

$$\frac{\sigma_1^2 S_2^2}{\sigma_2^2 S_1^2} \rightsquigarrow F(n_2 - 1, n_1 - 1)$$

1.3. Suficiencia y completitud

Ejemplo. Sean X_1, X_2 variables aleatorias independientes tal que $X_1, X_2 \rightsquigarrow \mathcal{P}(\lambda)$. Probar que $X_1 + X_2$ es suficiente para λ pero $X_1 + 2X_2$ no lo es.

Demostración. Notamos por P_λ a la función masa de probabilidad, que dependerá de λ . Queremos probar que, condicionada a un valor de $X_1 + X_2$, no depende de λ . Fijado $k \in \mathbb{N}$, tenemos que:

$$\begin{aligned} P_\lambda[X_1 = x_1, X_2 = x_2 \mid X_1 + X_2 = k] &= \frac{P_\lambda[X_1 = x_1, X_2 = x_2, X_1 + X_2 = k]}{P_\lambda[X_1 + X_2 = k]} = \\ &= \begin{cases} \frac{P_\lambda[X_1 = x_1, X_2 = x_2]}{P_\lambda[X_1 + X_2 = k]} & \text{si } x_1 + x_2 = k \\ 0 & \text{si } x_1 + x_2 \neq k \end{cases} \end{aligned}$$

Puesto que X_1 y X_2 son independientes, para $x_1 + x_2 = k$ tenemos que:

$$\begin{aligned} P_\lambda[X_1 = x_1, X_2 = x_2 \mid X_1 + X_2 = k] &= \frac{P_\lambda[X_1 = x_1]P_\lambda[X_2 = x_2]}{P_\lambda[X_1 + X_2 = k]} \stackrel{(*)}{=} \frac{e^{-\lambda} \frac{\lambda^{x_1}}{x_1!} \cdot e^{-\lambda} \frac{\lambda^{x_2}}{x_2!}}{e^{-2\lambda} \frac{(2\lambda)^k}{k!}} = \\ &= \frac{k!}{2^k x_1! x_2!} \end{aligned}$$

donde en $(*)$ hemos usado la reproductividad de la distribución Poisson, que nos dice que $X_1 + X_2 \rightsquigarrow \mathcal{P}(2\lambda)$. Notemos que el resultado no depende de λ , por lo que $X_1 + X_2$ es suficiente para λ .

Por otro lado, queremos ver que $X_1 + 2X_2$ no es suficiente para λ . Para ello, no es necesario probarlo para todos los valores posibles, sino que basta con encontrar un contraejemplo. Tomemos $k = 2$ y la muestra $(x_1, x_2) = (0, 1)$, de forma que $x_1 + 2x_2 = 2$. Tenemos que:

$$\begin{aligned} P_\lambda[X_1 = 0, X_2 = 1 \mid X_1 + 2X_2 = 2] &= \frac{P_\lambda[X_1 = 0, X_2 = 1, X_1 + 2X_2 = 2]}{P_\lambda[X_1 + 2X_2 = 2]} = \\ &= \frac{P_\lambda[X_1 = 0, X_2 = 1]}{P_\lambda[X_1 + 2X_2 = 2]} \end{aligned}$$

Por el Teorema de Cambio de Variable, tenemos que:

$$\begin{aligned} P_\lambda[X_1 + 2X_2 = 2] &= \sum_{\substack{x_1, x_2 \in \mathbb{N} \\ x_1 + 2x_2 = 2}} P_\lambda[X_1 = x_1, X_2 = x_2] = \\ &= P_\lambda[X_1 = 0, X_2 = 1] + P_\lambda[X_1 = 2, X_2 = 0] \end{aligned}$$

Por tanto, tenemos que:

$$\begin{aligned} P_\lambda[X_1 = 0, X_2 = 1 \mid X_1 + 2X_2 = 2] &= \frac{P_\lambda[X_1 = 0]P_\lambda[X_2 = 1]}{P_\lambda[X_1 = 0]P_\lambda[X_2 = 1] + P_\lambda[X_1 = 2]P_\lambda[X_2 = 0]} = \\ &= \frac{e^{-\lambda} \frac{\lambda^0}{0!} \cdot e^{-\lambda} \frac{\lambda^1}{1!}}{e^{-\lambda} \frac{\lambda^0}{0!} \cdot e^{-\lambda} \frac{\lambda^1}{1!} + e^{-\lambda} \frac{\lambda^2}{2!} \cdot e^{-\lambda} \frac{\lambda^0}{0!}} = \frac{\lambda}{\lambda + \frac{\lambda^2}{2}} = \frac{2}{2 + \lambda} \end{aligned}$$

Notemos que el resultado depende de λ , por lo que $X_1 + 2X_2$ no es suficiente para λ . $\square$

Ejemplo. En n lanzamientos de una moneda, el número de caras es suficiente para la probabilidad de cara (notada p).

Demostración. Sea X la v.a. que representa el número de caras en un lanzamiento de la moneda, de forma que $X \rightsquigarrow \mathcal{B}(1, p)$. Sea $(X_1, \dots, X_n)$ una m.a.s. de n lanzamientos de la moneda, y sea $T = \sum_{i=1}^n X_i$ el número total de caras en los n lanzamientos. Queremos ver que T es suficiente para p . Para ello, fijado un valor $k \in \{0, \dots, n\}$, tenemos que:

$$\begin{aligned} P_p[X_1 = x_1, \dots, X_n = x_n \mid T = k] &= \frac{P_p[X_1 = x_1, \dots, X_n = x_n, T = k]}{P_p[T = k]} = \\ &= \begin{cases} \frac{P_p[X_1 = x_1, \dots, X_n = x_n]}{P_p[T = k]} & \text{si } x_1 + \dots + x_n = k \\ 0 & \text{si } x_1 + \dots + x_n \neq k \end{cases} \end{aligned}$$

Por otro lado, como $X_1, \dots, X_n$ son independientes, en el caso de que se tenga que $x_1 + \dots + x_n = k$, tenemos que:

$$\begin{aligned} P_p[X_1 = x_1, \dots, X_n = x_n \mid T = k] &= \frac{P_p[X_1 = x_1] \cdots P_p[X_n = x_n]}{P_p[T = k]} \stackrel{(*)}{=} \\ &\stackrel{(*)}{=} \frac{\prod_{i=1}^n p^{x_i} (1-p)^{1-x_i}}{\binom{n}{k} p^k (1-p)^{n-k}} = \frac{p^{\sum_{i=1}^n x_i} (1-p)^{\sum_{i=1}^n 1-x_i}}{\binom{n}{k} p^k (1-p)^{n-k}} = \\ &= \frac{p^k (1-p)^{n-k}}{\binom{n}{k} p^k (1-p)^{n-k}} = \frac{1}{\binom{n}{k}} \end{aligned}$$

donde en $(*)$ hemos usado que $T \rightsquigarrow \mathcal{B}(n, p)$. Notemos que el resultado no depende de p , por lo que T es suficiente para p . $\square$

Ejemplo. Se supone que se ha lanzado una moneda 100 veces, y se sabe que se han obtenido 60 caras pero se han perdido los datos originales de si salió cara o cruz en cada tirada. Reconstruir la muestra.

Sea X la v.a. que representa el número de caras en un lanzamiento de la moneda, de forma que $X \rightsquigarrow \mathcal{B}(1, p)$. Sea $(X_1, \dots, X_{100})$ una m.a.s. de 100 lanzamientos de la moneda, y sea $T = \sum_{i=1}^{100} X_i$ el número total de caras en los 100 lanzamientos, que sabemos que es suficiente para p , luego la información que nos da la muestra original se encuentra en T . Por tanto, podemos reconstruir la muestra original muestreando de la distribución condicional de $(X_1, \dots, X_{100})$ dado que $T = 60$, que en el ejercicio anterior hemos visto que es:

$$P[X_1 = x_1, \dots, X_{100} = x_{100} \mid T = 60] = \begin{cases} \frac{1}{\binom{100}{60}} & \text{si } x_1 + \dots + x_{100} = 60 \\ 0 & \text{si } x_1 + \dots + x_{100} \neq 60 \end{cases}$$

Por tanto, si $(X_1^*, \dots, X_{100}^*)$ es una m.a.s. de la distribución condicionada al valor de $T = 60$, tenemos que $(X_1^*, \dots, X_{100}^*)$ sigue una distribución uniforme discreta sobre el conjunto de todas las muestras posibles de 100 lanzamientos de la moneda que contienen exactamente 60 caras; es decir, $(X_1^*, \dots, X_{100}^*) \rightsquigarrow \mathcal{U}(\mathcal{S})$, donde:

$$\mathcal{S} = \{(x_1, \dots, x_{100}) \in \{0, 1\}^{100} : x_1 + \dots + x_{100} = 60\}$$

Teorema 1.3.5 (de Factorización de Neyman-Fisher (Discreto)). *Sea una v. a. $X \rightsquigarrow F \in \{F_\theta : \theta \in \Theta\}$, y sea $(X_1, \dots, X_n)$ una m.a.s. de X . Sea f_θ la función masa de probabilidad de F_θ . Sea $T = T(X_1, \dots, X_n)$ un estadístico. Entonces, T es suficiente para θ si y solo si existen funciones g_θ y h tales que:*

$$f_\theta(x_1, \dots, x_n) = h(x_1, \dots, x_n) g_\theta(T(x_1, \dots, x_n)) \quad \forall (x_1, \dots, x_n) \in \mathcal{X}^n, \forall \theta \in \Theta$$

donde h no depende de θ .

Demostración. Demostramos cada una de las implicaciones:

$\implies$) Supongamos que T es suficiente para θ . Entonces, para todo $(x_1, \dots, x_n) \in \mathcal{X}^n$, $\theta \in \Theta$, y para cualquier $t \in T(\mathcal{X}^n)$ fijo, tenemos que:

$$P_\theta[X_1 = x_1, \dots, X_n = x_n \mid T = t] = \frac{P_\theta[X_1 = x_1, \dots, X_n = x_n, T = t]}{P_\theta[T = t]}$$

Evaluando en $t = T(x_1, \dots, x_n)$, tenemos que:

$$P_\theta[X_1 = x_1, \dots, X_n = x_n \mid T = t] = \frac{P_\theta[X_1 = x_1, \dots, X_n = x_n]}{P_\theta[T = t]}$$

Despejando, tenemos que:

$$P_\theta[X_1 = x_1, \dots, X_n = x_n] = P_\theta[T = t]P_\theta[X_1 = x_1, \dots, X_n = x_n \mid T = t]$$

Por tanto, identificando

$$g_\theta(t) = P_\theta[T = t] \quad h(x_1, \dots, x_n) = P_\theta[X_1 = x_1, \dots, X_n = x_n \mid T = T(x_1, \dots, x_n)]$$

tenemos que:

$$P_\theta[X_1 = x_1, \dots, X_n = x_n] = h(x_1, \dots, x_n)g_\theta(T(x_1, \dots, x_n))$$

$\Leftarrow$) Supongamos que existen funciones g_θ y h tales que, para todo $(x_1, \dots, x_n) \in \mathcal{X}^n$ y $\theta \in \Theta$, se cumple que:

$$P_\theta[X_1 = x_1, \dots, X_n = x_n] = h(x_1, \dots, x_n)g_\theta(T(x_1, \dots, x_n))$$

Entonces, para cualquier $t \in T(\mathcal{X}^n)$, tenemos que:

$$\begin{aligned} P_\theta[X_1 = x_1, \dots, X_n = x_n \mid T = t] &= \frac{P_\theta[X_1 = x_1, \dots, X_n = x_n, T = t]}{P_\theta[T = t]} = \\ &= \begin{cases} \frac{P_\theta[X_1 = x_1, \dots, X_n = x_n]}{P_\theta[T = t]} & \text{si } T(x_1, \dots, x_n) = t \\ 0 & \text{si } T(x_1, \dots, x_n) \neq t \end{cases} \end{aligned}$$

En el caso de que $T(x_1, \dots, x_n) = t$, tenemos que:

$$\begin{aligned} P_\theta[X_1 = x_1, \dots, X_n = x_n \mid T = t] &= \frac{h(x_1, \dots, x_n)g_\theta(T(x_1, \dots, x_n))}{\sum_{\substack{(x_1, \dots, x_n) \in \mathcal{X}^n \\ T(x_1, \dots, x_n) = t}} P_\theta[X_1 = x_1, \dots, X_n = x_n]} = \\ &= \frac{h(x_1, \dots, x_n)g_\theta(t)}{\sum_{\substack{(x_1, \dots, x_n) \in \mathcal{X}^n \\ T(x_1, \dots, x_n) = t}} h(x_1, \dots, x_n)g_\theta(t)} = \\ &= \frac{h(x_1, \dots, x_n)}{\sum_{\substack{(x_1, \dots, x_n) \in \mathcal{X}^n \\ T(x_1, \dots, x_n) = t}} h(x_1, \dots, x_n)} \end{aligned}$$

Notemos que el resultado no depende de θ , por lo que T es suficiente para θ . $\square$

Ejemplo. Sea X una v.a. tal que $X \rightsquigarrow F \in \{\mathcal{N}(\mu, \sigma^2) : \mu \in \mathbb{R}, \sigma^2 > 0\}$. Estudiar la suficiencia en los casos de:

1. σ_0^2 conocida.

Consideramos una m.a.s. $(X_1, \dots, X_n)$ de X . Sea $T = T(X_1, \dots, X_n)$ un estadístico. Por el Teorema de Factorización de Neyman-Fisher, T es suficiente para μ si y solo si existen funciones g_μ y h tales que:

$$f_\mu(x_1, \dots, x_n) = h(x_1, \dots, x_n)g_\mu(T(x_1, \dots, x_n)) \quad \forall (x_1, \dots, x_n) \in \mathbb{R}^n, \forall \mu \in \mathbb{R}$$

Tenemos que:

$$\begin{aligned} f_\mu(x_1, \dots, x_n) &\stackrel{\text{i.i.d.}}{=} \prod_{i=1}^n f_\mu(x_i) = \prod_{i=1}^n \frac{1}{\sqrt{2\pi\sigma_0^2}} \exp\left(-\frac{(x_i - \mu)^2}{2\sigma_0^2}\right) = \\ &= \frac{1}{(2\pi\sigma_0^2)^{n/2}} \exp\left(-\frac{\sum_{i=1}^n (x_i - \mu)^2}{2\sigma_0^2}\right) = \\ &= \frac{1}{(2\pi\sigma_0^2)^{n/2}} \exp\left(-\frac{\sum_{i=1}^n (x_i^2 - 2\mu x_i + \mu^2)}{2\sigma_0^2}\right) = \\ &= \frac{1}{(2\pi\sigma_0^2)^{n/2}} \exp\left(-\frac{\sum_{i=1}^n x_i^2 - 2\mu \sum_{i=1}^n x_i + n\mu^2}{2\sigma_0^2}\right) = \\ &= \frac{1}{(2\pi\sigma_0^2)^{n/2}} \exp\left(-\frac{\sum_{i=1}^n x_i^2}{2\sigma_0^2}\right) \exp\left(-\frac{-2\mu \sum_{i=1}^n x_i + n\mu^2}{2\sigma_0^2}\right) \end{aligned}$$

Por tanto, identificando términos, tenemos que:

$$\begin{aligned} h(x_1, \dots, x_n) &= \frac{1}{(2\pi\sigma_0^2)^{n/2}} \exp\left(-\frac{\sum_{i=1}^n x_i^2}{2\sigma_0^2}\right) \\ g_\mu(T(x_1, \dots, x_n)) &= \exp\left(-\frac{-2\mu T(x_1, \dots, x_n) + n\mu^2}{2\sigma_0^2}\right) \end{aligned}$$

Por tanto, por el Teorema de Factorización de Neyman-Fisher, tenemos que $T(X_1, \dots, X_n) = \sum_{i=1}^n X_i$ es suficiente para μ . En particular, como $\bar{X} = 1/n \cdot T$, tenemos que $\bar{X}$ es suficiente para μ .

2. μ_0 conocida.

En este caso, identificando términos, tenemos que:

$$h(x_1, \dots, x_n) = 1$$

$$g_{\sigma^2}(T(x_1, \dots, x_n)) = \frac{1}{(2\pi\sigma^2)^{n/2}} \exp\left(-\frac{T(x_1, \dots, x_n)}{2\sigma^2}\right)$$

Por tanto, por el Teorema de Factorización de Neyman-Fisher, tenemos que $T(X_1, \dots, X_n) = \sum_{i=1}^n (X_i - \mu_0)^2$ es suficiente para σ^2 . Como $\mu_0 = E[X] = E[\bar{X}]$, tenemos que $S^2 = 1/n-1 \cdot T$ es suficiente para σ^2 .

3. μ y σ^2 desconocidas.

En este caso, identificando términos, tenemos de forma directa que:

$$h(x_1, \dots, x_n) = 1$$

Puesto que el parámetro es bidimensional, el estadístico suficiente debe ser, al menos, bidimensional. Por tanto, podemos tomar como estadístico suficiente (T_1, T_2) , donde:

$$T_1(X_1, \dots, X_n) = \sum_{i=1}^n X_i \quad T_2(X_1, \dots, X_n) = \sum_{i=1}^n (X_i)^2$$

De esta forma, tenemos que:

$$g_{\mu, \sigma^2}(T_1(x_1, \dots, x_n), T_2(x_1, \dots, x_n)) =$$

$$= \frac{1}{(2\pi\sigma^2)^{n/2}} \exp\left(-\frac{T_2(x_1, \dots, x_n) - 2\mu T_1(x_1, \dots, x_n) + n\mu^2}{2\sigma^2}\right)$$

De esta forma, por el Teorema de Factorización de Neyman-Fisher, tenemos que (T_1, T_2) es suficiente para (μ, σ^2) .

Ejemplo. Sea $(X_1, \dots, X_n)$ una m.a.s de la v.a. $X \rightsquigarrow \mathcal{B}(1, p)$, con $p \in]0, 1[$. Encontrar un estadístico suficiente y completo asociado a la muestra.

Buscamos un estadístico suficiente. Por el Teorema de Factorización de Neyman-Fisher, T es suficiente para p si y solo si existen funciones g_p y h tales que:

$$P_p[X_1 = x_1, \dots, X_n = x_n] = h(x_1, \dots, x_n) g_p(T(x_1, \dots, x_n)) \quad \forall (x_1, \dots, x_n) \in \{0, 1\}^n, \forall p \in]0, 1[$$

Tenemos que:

$$P_p[X_1 = x_1, \dots, X_n = x_n] \stackrel{\text{i.i.d.}}{=} \prod_{i=1}^n P_p[X_i = x_i] = \prod_{i=1}^n p^{x_i} (1-p)^{1-x_i} = p^{\sum_{i=1}^n x_i} (1-p)^{\sum_{i=1}^n 1-x_i} =$$

$$= p^{\sum_{i=1}^n x_i} (1-p)^{n - \sum_{i=1}^n x_i}$$

Por tanto, identificando términos, tenemos que:

$$h(x_1, \dots, x_n) = 1$$

$$g_p(T(x_1, \dots, x_n)) = p^{T(x_1, \dots, x_n)}(1-p)^{n-T(x_1, \dots, x_n)}$$

Por tanto, por el Teorema de Factorización de Neyman-Fisher, tenemos que $T(X_1, \dots, X_n) = \sum_{i=1}^n X_i$ es suficiente para p . Veamos ahora si T es completo. Sea g una función medible tal que $E_p[g(T)] = 0$ para todo $p \in]0, 1[$. Probemos que $P_p[g(T) = 0] = 1$ para todo $p \in]0, 1[$. Por reproductividad, sabemos que $T \rightsquigarrow \mathcal{B}(n, p)$. Por tanto, para todo $p \in]0, 1[$, tenemos que:

$$E_p[g(T)] = \sum_{k=0}^n g(k) P_p[T = k] = \sum_{k=0}^n g(k) \binom{n}{k} p^k (1-p)^{n-k} =$$

$$= (1-p)^n \sum_{k=0}^n g(k) \binom{n}{k} \left(\frac{p}{1-p}\right)^k = 0$$

Sea $q = p/(1-p)$. Entonces, para todo $q \in]0, +\infty[$, tenemos que:

$$\sum_{k=0}^n g(k) \binom{n}{k} q^k = 0$$

Notemos que el polinomio $\sum_{k=0}^n g(k) \binom{n}{k} q^k$ tiene grado a lo sumo n . Por tanto, como tiene infinitas raíces, debe ser el polinomio nulo. Por tanto, tenemos que:

$$g(k) \binom{n}{k} = 0 \quad \forall k \in \{0, \dots, n\}$$

Por tanto, tenemos que $g(k) = 0$ para todo $k \in \{0, \dots, n\}$. Por tanto, hemos visto que:

$$\{0, \dots, n\} \subset \{k \in \mathbb{N} : g(k) = 0\}$$

Por tanto:

$$1 = P_p[T \in \{0, \dots, n\}] \leq P_p[g(T) = 0] \leq 1$$

Por tanto, $P_p[g(T) = 0] = 1$ para todo $p \in]0, 1[$; luego T es completo para p .

Ejemplo. Sea $(X_1, \dots, X_n)$ una m.a.s. de la v.a. $X \rightsquigarrow \mathcal{U}(0, \theta)$, con $\theta > 0$. Encontrar un estadístico suficiente y completo asociado a la muestra.

Buscamos un estadístico suficiente. Por el Teorema de Factorización de Neyman-Fisher, T es suficiente para θ si y solo si existen funciones g_θ y h tales que:

$$f_\theta(x_1, \dots, x_n) = h(x_1, \dots, x_n) g_\theta(T(x_1, \dots, x_n)) \quad \forall (x_1, \dots, x_n) \in \mathbb{R}^n, \forall \theta > 0$$

Tenemos que:

$$f_\theta(x_1, \dots, x_n) \stackrel{\text{i.i.d.}}{=} \prod_{i=1}^n f_\theta(x_i) = \prod_{i=1}^n \frac{1}{\theta} = \frac{1}{\theta^n} \quad \text{si } (x_1, \dots, x_n) \in [0, \theta]^n$$

Notemos que la función de densidad no depende de $(x_1, \dots, x_n)$, salvo por la condición de que $(x_1, \dots, x_n) \in [0, \theta]^n$. Por tanto, hemos de emplear la función indicadora para expresar la dependencia de $(x_1, \dots, x_n)$. Notemos que:

$$f_\theta(x_1, \dots, x_n) = \frac{1}{\theta^n} I_{[0, \infty]}(x_{(1)}) I_{]-\infty, 0]}(x_{(n)} - \theta) \quad \forall (x_1, \dots, x_n) \in \mathbb{R}^n, \forall \theta > 0$$

Por tanto, identificando términos, tenemos que:

$$\begin{aligned} h(x_1, \dots, x_n) &= I_{[0, \infty]}(x_{(1)}) \\ g_\theta(T(x_1, \dots, x_n)) &= \frac{1}{\theta^n} I_{]-\infty, 0]}(T(x_1, \dots, x_n) - \theta) \end{aligned}$$

Por tanto, por el Teorema de Factorización de Neyman-Fisher, tenemos que $T(X_1, \dots, X_n) = X_{(n)}$ es suficiente para θ . Para estudiar su completitud, hemos de calcular en primer lugar la función de densidad de T . Tenemos que:

$$F_{X_{(n)}}(x) = P[X_{(n)} \leq x] = P[X_1 \leq x, \dots, X_n \leq x] = \prod_{i=1}^n P[X_i \leq x] = \prod_{i=1}^n F_X(x) = F_X(x)^n$$

Por tanto, tenemos que:

$$f_{X_{(n)}}(x) = \frac{d}{dx} F_{X_{(n)}}(x) = n F_X(x)^{n-1} f_X(x) = n \left(\frac{x}{\theta}\right)^{n-1} \frac{1}{\theta} = \frac{nx^{n-1}}{\theta^n} \quad \text{si } x \in [0, \theta]$$

Sea g una función medible tal que $E_\theta[g(T)] = 0$ para todo $\theta > 0$. Probemos que $P_\theta[g(T) = 0] = 1$ para todo $\theta > 0$. Tenemos que:

$$E_\theta[g(T)] = \int_0^\theta g(x) f_{X_{(n)}}(x) dx = \int_0^\theta g(x) \frac{nx^{n-1}}{\theta^n} dx = \frac{n}{\theta^n} \int_0^\theta g(x) x^{n-1} dx = 0 \quad \forall \theta > 0$$

Por tanto, como el primer término no se puede anular, se tiene:

$$\int_0^\theta g(x) x^{n-1} dx = 0 \quad \forall \theta > 0$$

Notemos que la función $g(x)x^{n-1}$ es continua, y por tanto integrable. Derivando con respecto a θ , tenemos que:

$$g(\theta)\theta^{n-1} = 0 \quad \forall \theta > 0$$

Esto implica que $g(\theta) = 0$ para todo $\theta > 0$, luego:

$$]0, \infty[\subset \{x \in \mathbb{R} : g(x) = 0\}$$

Por tanto:

$$1 = P_\theta[T \in]0, \infty[\leq P_\theta[g(T) = 0] \leq 1$$

Por tanto, $P_\theta[g(T) = 0] = 1$ para todo $\theta > 0$; luego T es completo para θ .

Ejemplo. Demostrar que las siguientes familias de distribuciones son una familia exponencial uniparamétrica:

1. $\mathcal{P}(\lambda)$, con $\lambda > 0$

En primer lugar, tenemos que $\lambda \in \Theta =]0, \infty[$. Además, tenemos que:

$$\chi = \mathbb{N} \quad \forall \lambda \in \Theta$$

Por último, para cada $\lambda \in \Theta$ y $x \in \chi$, tenemos que:

$$P_\lambda[X = x] = e^{-\lambda} \frac{\lambda^x}{x!} = \exp \left(-\lambda + \ln \left(\frac{\lambda^x}{x!} \right) \right) = \exp (\ln(\lambda)x - \lambda - \ln(x!))$$

Por tanto, identificando términos, tenemos que:

$$Q(\lambda) = \ln(\lambda)$$

$$T(x) = x$$

$$D(\lambda) = -\lambda$$

$$S(x) = -\ln(x!)$$

Por tanto, $\mathcal{P}(\lambda)$ es una familia exponencial uniparamétrica.

2. $\mathcal{B}(k_0, p)$, con $p \in]0, 1[$ y $k_0 \in \mathbb{N}$ fijo.

En primer lugar, tenemos que $p \in \Theta =]0, 1[$. Además, tenemos que:

$$\chi = \{0, 1, \dots, k_0\} \quad \forall p \in \Theta$$

Por último, tenemos que:

$$\begin{aligned} P_p[X = x] &= \binom{k_0}{x} p^x (1-p)^{k_0-x} = \exp \left(\ln \left(\binom{k_0}{x} p^x (1-p)^{k_0-x} \right) \right) = \\ &= \exp \left(\ln \left(\binom{k_0}{x} \right) + x \ln(p) + (k_0 - x) \ln(1-p) \right) = \\ &= \exp \left(\ln \left(\binom{k_0}{x} \right) + x \ln \left(\frac{p}{1-p} \right) + k_0 \ln(1-p) \right) \quad \forall x \in \chi, \forall p \in \Theta \end{aligned}$$

Por tanto, identificando términos, tenemos que:

$$Q(p) = \ln \left(\frac{p}{1-p} \right)$$

$$T(x) = x$$

$$D(p) = k_0 \ln(1-p)$$

$$S(x) = \ln \left(\binom{k_0}{x} \right)$$

Ejercicio 1.3.1. La $\mathcal{N}(\mu, \sigma^2)$ es una familia exponencial uniparamétrica en cada parámetro y bi-paramétrica en los dos parámetros.

Veamos primero que $\mathcal{N}(\mu, \sigma^2)$ es una familia exponencial uniparamétrica en μ para σ^2 conocida. En este caso, tenemos que:

$$\begin{aligned}\Theta &= \mathbb{R} \\ \chi &= \mathbb{R} \\ f_\mu(x) &= \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(x-\mu)^2}{2\sigma^2}\right) = \exp\left(-\frac{(x-\mu)^2}{2\sigma^2} - \frac{1}{2}\ln(2\pi\sigma^2)\right) = \\ &= \exp\left(-\frac{x^2 - 2\mu x + \mu^2}{2\sigma^2} - \frac{1}{2}\ln(2\pi\sigma^2)\right) = \exp\left(\frac{\mu x}{\sigma^2} - \frac{\mu^2}{2\sigma^2} - \frac{x^2}{2\sigma^2} - \frac{1}{2}\ln(2\pi\sigma^2)\right)\end{aligned}$$

Por tanto, identificando términos, tenemos que:

$$\begin{aligned}Q(\mu) &= \frac{\mu}{\sigma^2} \\ T(x) &= x \\ D(\mu) &= -\frac{\mu^2}{2\sigma^2} \\ S(x) &= -\frac{x^2}{2\sigma^2} - \frac{1}{2}\ln(2\pi\sigma^2)\end{aligned}$$

Vemos por tanto que $\mathcal{N}(\mu, \sigma^2)$ es una familia exponencial uniparamétrica en μ para σ^2 conocida. Veamos ahora que $\mathcal{N}(\mu, \sigma^2)$ es una familia exponencial uniparamétrica en σ^2 para μ conocida. En este caso, tenemos que:

$$\begin{aligned}\Theta &=]0, \infty[\\ \chi &= \mathbb{R} \\ f_{\sigma^2}(x) &= \exp\left(-\frac{(x-\mu)^2}{2\sigma^2} - \frac{1}{2}\ln(2\pi\sigma^2)\right)\end{aligned}$$

Por tanto, identificando términos, tenemos que:

$$\begin{aligned}Q(\sigma^2) &= -\frac{1}{2\sigma^2} \\ T(x) &= (x-\mu)^2 \\ D(\sigma^2) &= -\frac{1}{2}\ln(2\pi\sigma^2) \\ S(x) &= 0\end{aligned}$$

Por tanto, $\mathcal{N}(\mu, \sigma^2)$ es una familia exponencial uniparamétrica en σ^2 para μ conocida. Veamos por último que $\mathcal{N}(\mu, \sigma^2)$ es una familia exponencial bi-paramétrica en (μ, σ^2) . En este caso, tenemos que:

$$\begin{aligned}\Theta &= \mathbb{R} \times]0, \infty[\\ \chi &= \mathbb{R} \\ f_{\mu, \sigma^2}(x) &= \exp\left(-\frac{(x-\mu)^2}{2\sigma^2} - \frac{1}{2}\ln(2\pi\sigma^2)\right)\end{aligned}$$

Por tanto, identificando términos, tenemos que:

$$\begin{aligned} Q_1(\mu, \sigma^2) &= \frac{\mu}{\sigma^2} \\ Q_2(\mu, \sigma^2) &= -\frac{1}{2\sigma^2} \\ T_1(x) &= x \\ T_2(x) &= x^2 \\ D(\mu, \sigma^2) &= -\frac{\mu^2}{2\sigma^2} - \frac{1}{2} \ln(2\pi\sigma^2) \\ S(x) &= 0 \end{aligned}$$

Teorema 1.3.6. *Si se tiene una v.a. $X \rightsquigarrow \{F_\theta, \theta \in \Theta\}$ con familia de funciones asociadas, $\{f_\theta(x), \theta \in \Theta\}$, siendo f.d.d. o f.m.p. según el caso, donde la familia de distribuciones es exponencial k-paramétrica, entonces la familia de distribuciones asociadas a $(X_1, \dots, X_n)$ (que es una m.a.s. de X) es también exponencial k-paramétrica:*

$$f_\theta^n(x_1, \dots, x_n) = \exp \left[\sum_{h=1}^k Q_h(\theta) \sum_{i=1}^n T_h(x_i) + \sum_{i=1}^n S(x_i) + nD(\theta) \right], \quad (x_1, \dots, x_n) \in \chi^n$$

y se tiene:

1. El estadístico $(\sum_{i=1}^n T_1(X_i), \dots, \sum_{i=1}^n T_k(X_i))$ es suficiente para θ .
2. Si $k \leq n$ y el conjunto imagen de la función $Q(\theta) = (Q_1(\theta), \dots, Q_k(\theta))$ contiene a un abierto de $\mathbb{R}^k$, el estadístico $(\sum_{i=1}^n T_1(X_i), \dots, \sum_{i=1}^n T_k(X_i))$ es también completo.

Demostración. Comprobemos que $(X_1, \dots, X_n)$ es una familia exponencial k-paramétrica. Por ser la familia de distribuciones asociadas a X una familia exponencial k-paramétrica, tenemos que $\Theta \subset \mathbb{R}^k$. Además, tenemos que el espacio muestral de $(X_1, \dots, X_n)$ es independiente de θ , y es χ^n . Por último, tenemos que:

$$\begin{aligned} f_\theta^n(x_1, \dots, x_n) &= \prod_{i=1}^n f_\theta(x_i) = \prod_{i=1}^n \exp \left[\sum_{h=1}^k Q_h(\theta) T_h(x_i) + S(x_i) + D(\theta) \right] = \\ &= \exp \left[\sum_{i=1}^n \sum_{h=1}^k Q_h(\theta) T_h(x_i) + \sum_{i=1}^n S(x_i) + \sum_{i=1}^n D(\theta) \right] = \\ &= \exp \left[\sum_{h=1}^k Q_h(\theta) \sum_{i=1}^n T_h(x_i) + \sum_{i=1}^n S(x_i) + nD(\theta) \right] \end{aligned}$$

Por tanto, identificando términos, tenemos que:

$$\begin{aligned} Q_h^n(\theta) &= Q_h(\theta) \\ T_h^n(x_1, \dots, x_n) &= \sum_{i=1}^n T_h(x_i) \\ S^n(x_1, \dots, x_n) &= \sum_{i=1}^n S(x_i) \\ D^n(\theta) &= nD(\theta) \end{aligned}$$

Por tanto, $(X_1, \dots, X_n)$ es una familia exponencial k -paramétrica. Veamos ahora que $\left(\sum_{i=1}^n T_1(X_i), \dots, \sum_{i=1}^n T_k(X_i)\right)$ es suficiente para θ .

$$\begin{aligned} f_\theta^n(x_1, \dots, x_n) &= \exp \left[\sum_{h=1}^k Q_h(\theta) \sum_{i=1}^n T_h(x_i) + \sum_{i=1}^n S(x_i) + nD(\theta) \right] = \\ &= \underbrace{\exp \left[\sum_{i=1}^n S(x_i) \right]}_{h(x_1, \dots, x_n)} \underbrace{\exp \left[\sum_{h=1}^k Q_h(\theta) \sum_{i=1}^n T_h(x_i) + nD(\theta) \right]}_{g_\theta \left(\sum_{i=1}^n T_1(x_i), \dots, \sum_{i=1}^n T_k(x_i) \right)} \end{aligned}$$

Por el Teorema de Factorización de Neyman-Fisher, tenemos que el estadístico $\left(\sum_{i=1}^n T_1(X_i), \dots, \sum_{i=1}^n T_k(X_i)\right)$ es suficiente para θ . Respecto a la completitud, al ser más complicado, no se incluye la demostración. $\square$

Ejemplo. Sea X una v.a. con distribución $N(\mu, \sigma^2)$ con $\mu \in \mathbb{R}$ y $\sigma^2 > 0$. Buscar un estadístico suficiente y completo basado en una muestra de tamaño n .

2. Relaciones de Ejercicios

2.1. Suficiencia y completitud

Ejercicio 2.1.1. Sea $(X_1, \dots, X_n)$ una muestra aleatoria simple de una variable $X \rightsquigarrow \{B(k, p) : p \in]0, 1[\}$ y sea $T(X_1, \dots, X_n) = \sum_{i=1}^n X_i$. Probar que T es suficiente para p :

1. Usando la definición:

Si notamos para abreviar $T = T(X_1, \dots, X_n)$, tenemos que probar que la distribución de la muestra condicionada a cualquier valor del estadístico no depende del parámetro p para probar que T es suficiente para p . Para ello:

$$\begin{aligned} P_p[X_1 = x_1, \dots, X_n = x_n \mid T = t] &= \frac{P_p[X_1 = x_1, \dots, X_n = x_n, T = t]}{P_p[T = t]} \\ &= \begin{cases} 0 & \text{si } T(x_1, \dots, x_n) \neq t \\ \frac{P_p[X_1 = x_1, \dots, X_n = x_n]}{P_p[T = t]} & \text{si } T(x_1, \dots, x_n) = t \end{cases} \end{aligned}$$

Como 0 obviamente no depende de p , el caso $T(x_1, \dots, x_n) \neq t$ se encuentra ya estudiado, por lo que nos centramos en el caso $T(x_1, \dots, x_n) = t$:

$$\begin{aligned} \frac{P_p[X_1 = x_1, \dots, X_n = x_n]}{P_p[T = t]} &\stackrel{\text{iid.}}{=} \frac{\prod_{i=1}^n P_p[X = x_i]}{P_p[T = t]} \stackrel{(*)}{=} \frac{\prod_{i=1}^n \binom{k}{x_i} p^{x_i} (1-p)^{k-x_i}}{\binom{nk}{t} p^t (1-p)^{nk-t}} \\ &= \frac{p^{\sum_{i=1}^n x_i} (1-p)^{nk - \sum_{i=1}^n x_i} \prod_{i=1}^n \binom{k}{x_i}}{\binom{nk}{t} p^t (1-p)^{nk-t}} \stackrel{(**)}{=} \frac{\prod_{i=1}^n \binom{k}{x_i}}{\binom{nk}{t}} \end{aligned}$$

Donde en $(*)$ hemos usado que $(X_1, \dots, X_n)$ es una m.a.s. (variables independientes) y la reproductividad de la Binomial, por lo que $T \rightsquigarrow B(nk, p)$; y en $(**)$ hemos usado que $t = T(x_1, \dots, x_n) = \sum_{i=1}^n x_i$. En definitiva, hemos obtenido que la distribución de la muestra condicionada a cualquier valor del estadístico no depende del parámetro p , por lo que T es suficiente para p .

2. Aplicando el teorema de factorización:

Si podemos usar el Teorema de factorización, escribimos la función masa de probabilidad de la distribución conjunta de la muestra aleatoria simple:

$$\begin{aligned} P[X_1 = x_1, \dots, X_n = x_n] &\stackrel{\text{iid.}}{=} \prod_{i=1}^n P[X = x_i] = \prod_{i=1}^n \binom{k}{x_i} p^{x_i} (1-p)^{k-x_i} \\ &= p^{\sum_{i=1}^n x_i} (1-p)^{nk - \sum_{i=1}^n x_i} \prod_{i=1}^n \binom{k}{x_i} \end{aligned}$$

Si tomamos:

$$h(x_1, \dots, x_n) = \prod_{i=1}^n \binom{k}{x_i}, \quad T(X_1, \dots, X_n) = \sum_{i=1}^n X_i, \quad g_p(t) = p^t (1-p)^{nk-t}$$

Podemos aplicar el Teorema de Factorización de Neymann-Fisher, obteniendo que T es un estadístico suficiente para p .

Ejercicio 2.1.2. Sea $(X_1, \dots, X_n)$ una muestra aleatoria simple de una variable $X \rightsquigarrow \{\mathcal{P}(\lambda) : \lambda \in \mathbb{R}^+\}$ y sea $T(X_1, \dots, X_n) = \sum_{i=1}^n X_i$. Probar que T es suficiente para λ :

1. Usando la definición:

Notando $T = T(X_1, \dots, X_n)$, seguimos los mismos pasos que en el ejercicio anterior:

$$P_\lambda[X_1 = x_1, \dots, X_n = x_n \mid T = t] = \frac{P_\lambda[X_1 = x_1, \dots, X_n = x_n, T = t]}{P_\lambda[T = t]}$$

$$= \begin{cases} 0 & \text{si } T(x_1, \dots, x_n) \neq t \\ \frac{P_\lambda[X_1 = x_1, \dots, X_n = x_n]}{P_\lambda[T = t]} & \text{si } T(x_1, \dots, x_n) = t \end{cases}$$

Y ahora nos interesamos por el segundo término, que es el que puede depender de λ :

$$\frac{P_\lambda[X_1 = x_1, \dots, X_n = x_n]}{P_\lambda[T = t]} \stackrel{\text{iid.}}{=} \frac{\prod_{i=1}^n P_\lambda[X = x_i]}{P_\lambda[T = t]} \stackrel{(*)}{=} \frac{\prod_{i=1}^n e^{-\lambda} \frac{\lambda^{x_i}}{x_i!}}{e^{-n\lambda} \frac{(n\lambda)^t}{t!}} = \frac{e^{-n\lambda} \cdot \frac{\lambda^{\sum_{i=1}^n x_i}}{\prod_{i=1}^n x_i!}}{e^{-n\lambda} \cdot \frac{n^t \lambda^t}{t!}}$$

$$\stackrel{(**)}{=} \frac{t!}{n^t \prod_{i=1}^n x_i!}$$

Donde en $(*)$ usamos que $T \rightsquigarrow \mathcal{P}(n\lambda)$, por la reproductividad de la Poisson y en $(**)$ usamos que $t = T(x_1, \dots, x_n) = \sum_{i=1}^n x_i$. Obtenemos una cantidad que no depende de λ , por lo que T es suficiente para λ .

2. Aplicando el teorema de factorización:

Si podemos aplicar el Teorema de factorización, escribimos:

$$P_\lambda[X_1 = x_1, \dots, X_n = x_n] \stackrel{\text{iid.}}{=} \prod_{i=1}^n P_\lambda[X = x_i] = \prod_{i=1}^n e^{-\lambda} \frac{\lambda^{x_i}}{x_i!} = e^{-n\lambda} \cdot \frac{\lambda^{\sum_{i=1}^n x_i}}{\prod_{i=1}^n x_i!}$$

Si tomamos:

$$h(x_1, \dots, x_n) = \frac{1}{\prod_{i=1}^n x_i!}, \quad T(X_1, \dots, X_n) = \sum_{i=1}^n X_i, \quad g_\lambda(t) = e^{-n\lambda} \cdot \lambda^t$$

Por el Teorema de Factorización de Neymann-Fisher obtenemos que T es suficiente para λ .

Ejercicio 2.1.3. Sea (X_1, X_2, X_3) una muestra aleatoria simple de una variable $X \rightsquigarrow \{B(1, p) : p \in]0, 1[\}$. Probar que el estadístico $X_1 + 2X_2 + 3X_3$ no es suficiente.

Consideramos el estadístico $T(X_1, X_2, X_3) = X_1 + 2X_2 + 3X_3$. El espacio muestral de X es $\mathcal{X} = \{0, 1\}$, por lo que el espacio muestral de T es $\mathcal{T} = \{0, 1, 2, 3, 4, 5, 6\}$. Sabemos por un ejemplo visto en teoría que el “truco” para demostrar que $T(X_1, X_2, X_3)$ no es suficiente para p es buscar un valor del espacio muestral $\mathcal{T}$ que provenga de varias combinaciones de estados del espacio muestral $\mathcal{X}^3$. Como 0, 1, 2 solo provienen de una combinación del espacio muestral $\mathcal{X}^3$ (son (0, 0, 0), (1, 0, 0) y (0, 1, 0) respectivamente), probamos buscar el contraejemplo con $t = 3$, que proviene de considerar las observaciones de la muestra (1, 1, 0) y (0, 0, 1).

Una vez explicado el procedimiento para buscar cuál es el valor de t que funciona, procedemos a probar que la distribución de la muestra condicionada a dicho valor de t depende del parámetro p . Para ello:

$$\begin{aligned} P_p[X_1 = x_1, X_2 = x_2, X_3 = x_3 \mid T = 3] &= \frac{P_p[X_1 = x_1, X_2 = x_2, X_3 = x_3, T = 3]}{P_p[T = 3]} \\ &= \begin{cases} 0 & \text{si } T(x_1, x_2, x_3) \neq 3 \\ \frac{P_p[X_1 = x_1, X_2 = x_2, X_3 = x_3]}{P_p[T = 3]} & \text{si } T(x_1, x_2, x_3) = 3 \end{cases} \end{aligned}$$

Vemos que el primer caso no puede depender nunca de p , por lo que buscamos probar que el segundo caso sí que depende de p . Para ello:

$$\begin{aligned} \frac{P_p[X_1 = x_1, X_2 = x_2, X_3 = x_3]}{P_p[T = 3]} &\stackrel{\text{iid.}}{=} \frac{P_p[X = x_1]P_p[X = x_2]P_p[X = x_3]}{P_p[T = 3]} \\ &\stackrel{(*)}{=} \frac{p^{x_1}(1-p)^{1-x_1}p^{x_2}(1-p)^{1-x_2}p^{x_3}(1-p)^{1-x_3}}{P_p[X_1 = 1, X_2 = 1, X_3 = 0] + P_p[X_1 = 0, X_2 = 0, X_3 = 1]} \\ &= \frac{p^{x_1}(1-p)^{1-x_1}p^{x_2}(1-p)^{1-x_2}p^{x_3}(1-p)^{1-x_3}}{p \cdot p \cdot (1-p) + (1-p)(1-p)p} \end{aligned}$$

Donde en $(*)$ se ha usado la propiedad reproductiva de la Binomial, por lo que $T \rightsquigarrow B(3, p)$, así como que la condición $t = 3$ provenía de los valores (1, 1, 0) y (0, 0, 1). Ahora, si tomamos $(x_1, x_2, x_3) = (1, 1, 0)$, tenemos que:

$$\begin{aligned} \frac{P_p[X_1 = 1, X_2 = 1, X_3 = 0]}{P_p[T = 3]} &= \frac{p^1(1-p)^0p^1(1-p)^0p^0(1-p)^1}{p \cdot p \cdot (1-p) + (1-p)(1-p)p} \\ &= \frac{pp(1-p)}{pp(1-p) + (1-p)(1-p)p} \\ &= \frac{p^2(1-p)}{p(1-p)(p+1-p)} = p \end{aligned}$$

Que claramente depende de p , por lo que T no es suficiente para p .

Ejercicio 2.1.4. Aplicando el teorema de factorización, y basándose en una muestra de tamaño arbitrario, encontrar un estadístico suficiente para cada una de las siguientes familias de distribuciones (en las familias biparamétricas, suponer los casos de sólo un parámetro desconocido y de los dos desconocidos).

- a) $X \rightsquigarrow \{\mathcal{U}(-\theta/2, \theta/2) : \theta > 0\}$
 b) $X \rightsquigarrow \{\Gamma(p, a) : p, a > 0\}$
 c) $X \rightsquigarrow \{\beta(p, q) : p, q > 0\}$
 d) $X \rightsquigarrow \{P_{N_1, N_2} : N_1, N_2 \in \mathbb{N}, N_1 \leq N_2\}$ y la masa de probabilidad viene dada por:

$$P_{N_1, N_2}[X = x] = \frac{1}{N_2 - N_1 + 1} \quad x \in \{N_1, \dots, N_2\}$$

En lo que sigue, supondremos que tenemos una m.a.s. $(X_1, \dots, X_n)$ de variables idénticamente distribuidas a la respectiva variable X :

- a) Si $X \rightsquigarrow \mathcal{U}(-\theta/2, \theta/2)$ con $\theta > 0$:

$$f(x_1, \dots, x_n) \stackrel{\text{iid.}}{=} \prod_{i=1}^n f(x_i) = \prod_{i=1}^n \frac{1}{\theta} = \frac{1}{\theta^n} \quad x_i \in]-\theta/2, \theta/2[, \quad \forall i \in \{1, \dots, n\}$$

Por lo que tendremos $-\theta/2 < X_{(1)} \leq X_{(n)} < \theta/2$:

$$f(x_1, \dots, x_n) = \frac{1}{\theta^n} \mathbf{I}_{]0, +\infty[}(X_{(1)} + \theta/2) \mathbf{I}_{]-\infty, 0[}(X_{(n)} - \theta/2)$$

Si tomamos:

$$h(x_1, \dots, x_n) = 1, \quad T(X_1, \dots, X_n) = (X_{(1)}, X_{(n)})$$

$$g_\theta(t_1, t_2) = \frac{1}{\theta^n} \mathbf{I}_{]0, +\infty[}(t_1 + \theta/2) \mathbf{I}_{]-\infty, 0[}(t_2 - \theta/2)$$

Por el Teorema de factorización, tenemos que $T(X_1, \dots, X_n)$ es un estadístico suficiente para θ .

- b) Si $X \rightsquigarrow \Gamma(p, a)$ con $p, a > 0$:

$$f(x_1, \dots, x_n) \stackrel{\text{iid.}}{=} \prod_{i=1}^n f(x_i) = \prod_{i=1}^n \frac{a^p}{\Gamma(p)} x_i^{p-1} e^{-ax_i} = \left(\frac{a^p}{\Gamma(p)} \right)^n e^{-a \sum_{i=1}^n x_i} \prod_{i=1}^n x_i^{p-1}$$

$$= \left(\frac{a^p}{\Gamma(p)} \right)^n e^{-a \sum_{i=1}^n x_i} \left(\prod_{i=1}^n x_i \right)^{p-1} \quad x_i \geq 0 \quad \forall i \in \{1, \dots, n\}$$

- Suponiendo que p es conocida, podemos tomar:

$$h(x_1, \dots, x_n) = \left(\prod_{i=1}^n x_i \right)^{p-1}, \quad T(X_1, \dots, X_n) = \sum_{i=1}^n X_i$$

$$g_a(t) = \left(\frac{a^p}{\Gamma(p)} \right)^n e^{-at}$$

- Suponiendo ahora que a es conocida:

$$h(x_1, \dots, x_n) = e^{-a \sum_{i=1}^n x_i}, \quad T(X_1, \dots, X_n) = \sum_{i=1}^n x_i$$

$$g_p(t) = \left(\frac{a^p}{\Gamma(p)} \right)^n t^{p-1}$$

- Si ahora tanto p como a son desconocidas, podemos tomar:

$$h(x_1, \dots, x_n) = 1, \quad T(X_1, \dots, X_n) = \left(\sum_{i=1}^n X_i, \prod_{i=1}^n X_i \right)$$

$$g_{(a,p)}(t_1, t_2) = \left(\frac{a^p}{\Gamma(p)} \right)^n e^{-at_1} t_2^{p-1}$$

- c) Si $X \rightsquigarrow \beta(p, q)$ con $p, q > 0$:

$$f(x_1, \dots, x_n) \stackrel{\text{iid.}}{=} \prod_{i=1}^n f(x_i) = \prod_{i=1}^n \frac{1}{\beta(p, q)} x_i^{p-1} (1 - x_i)^{q-1}$$

$$= \frac{1}{\beta(p, q)^n} \left(\prod_{i=1}^n x_i \right)^{p-1} \left(\prod_{i=1}^n (1 - x_i) \right)^{q-1} \quad x_i \in [0, 1], \forall i \in \{1, \dots, n\}$$

- Si p es conocida, tomamos:

$$h(x_1, \dots, x_n) = \left(\prod_{i=1}^n x_i \right)^{p-1}, \quad T(X_1, \dots, X_n) = \prod_{i=1}^n (1 - X_i)$$

$$g_q(t) = \frac{1}{\beta(p, q)^n} t^{q-1}$$

- Si q es conocida:

$$h(x_1, \dots, x_n) = \left(\prod_{i=1}^n (1 - x_i) \right)^{q-1}, \quad T(X_1, \dots, X_n) = \prod_{i=1}^n X_i$$

$$g_p(t) = \frac{1}{\beta(p, q)^n} t^{p-1}$$

- Si tanto p como q son parámetros:

$$h(x_1, \dots, x_n) = 1, \quad T(X_1, \dots, X_n) = \left(\prod_{i=1}^n X_i, \prod_{i=1}^n (1 - X_i) \right)$$

$$g_{(p,q)}(t_1, t_2) = \frac{1}{\beta(p, q)^n} t_1^{p-1} t_2^{q-1}$$

- d) Si $X \rightsquigarrow P_{N_1, N_2}$ con $N_1, N_2 \in \mathbb{N}$, $N_1 \leq N_2$, entonces:

$$P[X_1 = x_1, \dots, X_n = x_n] \stackrel{\text{iid.}}{=} \prod_{i=1}^n P[X = x_i] = \prod_{i=1}^n \frac{1}{N_2 - N_1 + 1}$$

$$= \frac{1}{(N_2 - N_1 + 1)^n}, \quad x_i \in \{N_1, \dots, N_2\}$$

Como se tiene $N_1 \leq X_{(1)} \leq X_{(n)} \leq N_2$, entonces:

$$P[X_1 = x_1, \dots, X_n = x_n] = \frac{I_{N_0}(X_{(1)} - N_1) I_{-N_0}(X_{(n)} - N_2)}{(N_2 - N_1 + 1)^n}$$

- Si N_1 es conocido:

$$h(x_1, \dots, x_n) = I_{\mathbb{N}_0}(X_{(1)} - N_1), \quad T(X_1, \dots, X_n) = X_{(n)}$$

$$g_{N_2}(t) = \frac{I_{\mathbb{N}_0}(t - N_2)}{(N_2 - N_1 + 1)^n}$$

- Si N_2 es conocida:

$$h(x_1, \dots, x_n) = I_{\mathbb{N}_0}(X_{(n)} - N_2), \quad T(X_1, \dots, X_n) = X_{(1)}$$

$$g_{N_1}(t) = \frac{I_{\mathbb{N}_0}(t - N_1)}{(N_2 - N_1 + 1)^n}$$

- Si tanto N_1 como N_2 son parámetros:

$$h(x_1, \dots, x_n) = 1, \quad T(X_1, \dots, X_n) = (X_{(1)}, X_{(n)})$$

$$g_{(N_1, N_2)}(t_1, t_2) = \frac{I_{\mathbb{N}_0}(t_1 - N_1) I_{\mathbb{N}_0}(t_2 - N_2)}{(N_2 - N_1 + 1)^n}$$

Por lo que en cualquier caso obtenemos un estadístico suficiente, por el Teorema de Factorización.

Ejercicio 2.1.5. Sea $X \rightsquigarrow \{P_N : N \in \mathbb{N}\}$, siendo P_N la distribución uniforme en los puntos $\{1, \dots, N\}$, y sea $(X_1, \dots, X_n)$ una muestra aleatoria simple de X . Probar que $\max(X_1, \dots, X_n)$ es un estadístico suficiente y completo.

Buscamos aplicar el Teorema de factorización de Neymann-Fisher:

$$P[X_1 = x_1, \dots, X_n = x_n] \stackrel{\text{iid.}}{=} \prod_{i=1}^n P[X = x_i] = \prod_{i=1}^n \frac{1}{N}, \quad x_i \in \{1, \dots, N\}, \forall i \in \{1, \dots, n\}$$

Por lo que $1 \leq X_{(1)} \leq X_{(n)} \leq N$:

$$P[X_1 = x_1, \dots, X_n = x_n] = \frac{I_{\mathbb{N}_0}(X_{(1)} - 1) I_{\mathbb{N}_0}(X_{(n)} - N)}{N^n}$$

De donde podemos tomar:

$$h(x_1, \dots, x_n) = I_{\mathbb{N}_0}(X_{(1)} - 1), \quad T(X_1, \dots, X_n) = X_{(n)}$$

$$g_N(t) = \frac{I_{\mathbb{N}_0}(t - N)}{N^n}$$

Por el Teorema de factorización de Neymann-Fisher, tenemos que el estadístico $T(X_1, \dots, X_n) = X_{(n)}$ es suficiente. Comprobamos que también es completo: sea g cualquier función medible, supongamos que (abreviaremos $T(X_1, \dots, X_n) = T$):

$$0 = E[g(T)] = \sum_{t=1}^N g(t) P[T = t] \quad \forall N \in \mathbb{N}$$

Calculamos la función masa de probabilidad de T :

$$F_T(t) = (F_X(t))^n \implies P[T = t] = P[T \leq t] - P[T \leq t-1] = (F_X(t))^n - (F_X(t-1))^n$$

Como $F_X(t) = \frac{t}{N}$, tenemos entonces que:

$$P[T = t] = (F_X(t))^n - (F_X(t-1))^n = \frac{t^n}{N^n} - \frac{(t-1)^n}{N^n} = \frac{t^n - (t-1)^n}{N^n}$$

Por lo que:

$$0 = E[g(T)] = \sum_{t=1}^N g(t) \frac{t^n - (t-1)^n}{N^n} = \frac{1}{N^n} \sum_{t=1}^N g(t)(t^n - (t-1)^n) \quad \forall N \in \mathbb{N}$$

de donde:

$$\sum_{t=1}^N g(t)(t^n - (t-1)^n) = 0 \quad \forall N \in \mathbb{N}$$

Puesto que la potencia n -ésima es una función estrictamente creciente en el intervalo $[0, +\infty[$, tenemos que $t^n - (t-1)^n > 0$ para todo $t \in \mathbb{N}$. Para que una suma de términos positivos sea cero, todos los sumandos han de ser cero, por lo que $g(t) = 0$ para todo $t \in \mathbb{N}$. En definitiva, tenemos que:

$$\mathbb{N} \subseteq \{t : g(t) = 0\}$$

Por lo que:

$$1 \geq P[g(T) = 0] \geq P[T \in \mathbb{N}] = 1 \implies P[g(T) = 0] = 1$$

Lo que demuestra que $X_{(n)}$ es completo.

Ejercicio 2.1.6. Basándose en una muestra de tamaño arbitrario, obtener un estadístico suficiente y completo para la familia de distribuciones definidas por todas las densidades de la forma

$$f_\theta(x) = e^{\theta-x}, \quad x > \theta$$

Sea $(X_1, \dots, X_n)$ una m.a.s. de tamaño $n \in \mathbb{N}$:

$$f_\theta(x_1, \dots, x_n) \stackrel{\text{iid.}}{=} \prod_{i=1}^n f_\theta(x_i) = \prod_{i=1}^n e^{\theta-x_i} = e^{n\theta - \sum_{i=1}^n x_i} = \frac{e^{n\theta}}{e^{\sum_{i=1}^n x_i}}, \quad x_i > \theta \quad \forall i \in \{1, \dots, n\}$$

Por lo que ha de ser $\theta < X_{(1)}$:

$$f_\theta(x_1, \dots, x_n) = \frac{e^{n\theta} \cdot \mathbb{I}_{]0, \infty[}(X_{(1)} - \theta)}{e^{\sum_{i=1}^n x_i}} \quad x_i \in \mathbb{R}, \forall i \in \{1, \dots, n\}$$

Si tomamos:

$$h(x_1, \dots, x_n) = e^{-\sum_{i=1}^n x_i}, \quad T(X_1, \dots, X_n) = X_{(1)} \\ g_\theta(t) = e^{n\theta} \cdot \mathbb{I}_{]0, \infty[}(t - \theta)$$

Por el Teorema de factorización de Neymann-Fisher tenemos que el estadístico $X_{(1)}$ es suficiente para θ . Comprobemos si es completo: sea g cualquier función medible, suponemos que (y escribimos $T = T(X_1, \dots, X_n)$ para abreviar):

$$0 = E[g(T)] = \int_{\theta}^{+\infty} g(t) f_T(t) dt \quad \forall \theta \in \mathbb{R}$$

Como $T = X_{(1)}$, tenemos que:

$$F_T(t) = 1 - (1 - F_{\theta}(t))^n \implies f_T(t) = n(1 - F_{\theta}(t))^{n-1} f_{\theta}(t)$$

donde:

$$F_{\theta}(t) = \int_{\theta}^t e^{\theta-x} dx = [-e^{\theta-x}]_{\theta}^t = 1 - e^{\theta-t}, \quad t > \theta$$

por lo que:

$$f_T(t) = n(e^{\theta-t})^{n-1} e^{\theta-t} = n(e^{\theta-t})^n, \quad t > \theta$$

volviendo al caso que nos interesa:

$$0 = E[g(T)] = \int_{\theta}^{+\infty} g(t) n(e^{\theta-t})^n dt = ne^{n\theta} \int_{\theta}^{+\infty} g(t) e^{-nt} dt \quad \forall \theta \in \mathbb{R}$$

por lo que:

$$\int_{\theta}^{+\infty} g(t) e^{-nt} dt = 0 \quad \forall \theta \in \mathbb{R}$$

Por simplicidad de cálculos, supondremos que g es continua, con lo que si $G(t)$ es una primitiva de $g(t)e^{-nt}$, entonces:

$$\int_{\theta}^{+\infty} g(t) e^{-nt} dt = \lim_{n \rightarrow \infty} \int_{\theta}^n g(t) e^{-nt} dt = \lim_{n \rightarrow \infty} G(n) - G(\theta) = 0 \quad \forall \theta \in \mathbb{R}$$

Si derivamos ahora respecto a θ , tenemos que:

$$-g(\theta) e^{-n\theta} = 0 \quad \forall \theta \in \mathbb{R}$$

con lo que $g(\theta) = 0 \quad \forall \theta \in \mathbb{R}$. Es decir:

$$\mathbb{R} \subseteq \{t : g(t) = 0\}$$

luego:

$$1 \geq P[g(T) = 0] \geq P[T \in \mathbb{R}] = 1 \implies P[g(T) = 0] = 1$$

por lo que T es completo.

Ejercicio 2.1.7. Comprobar que las siguientes familias de distribuciones son exponenciales uniparamétricas y, considerando una muestra aleatoria simple de una variable con distribución en dicha familia, obtener, si existe, un estadístico suficiente y completo.

- a) $\{\mathcal{B}(k_0, p) : 0 < p < 1\}$

Comprobamos todas las condiciones:

1. El espacio paramétrico es: $]0, 1[\subseteq \mathbb{R}$.
2. El espacio muestral es $\mathcal{X} = \{0, \dots, k_0\}$, que no depende de p .
3. Para la tercera condición:

$$\begin{aligned}
 P[X = x]_p &= \binom{k_0}{x} p^x (1-p)^{k_0-x} = \exp \left[\ln \left(\binom{k_0}{x} p^x (1-p)^{k_0-x} \right) \right] \\
 &= \exp \left[\ln \binom{k_0}{x} + x \ln p + (k_0 - x) \ln(1-p) \right] \\
 &= \exp \left[\ln \binom{k_0}{x} + x \ln p + k_0 \ln(1-p) - x \ln(1-p) \right] \\
 &= \exp \left[\ln \binom{k_0}{x} + k_0 \ln(1-p) + x \ln \left(\frac{p}{1-p} \right) \right]
 \end{aligned}$$

Tomando:

$$\begin{aligned}
 T(x) &= x, & S(x) &= \ln \binom{k_0}{x} \\
 Q(p) &= \ln \left(\frac{p}{1-p} \right), & D(p) &= k_0 \ln(1-p)
 \end{aligned}$$

obtenemos la tercera condición.

Sea $(X_1, \dots, X_n)$ una m.a.s. de variables aleatorias idénticamente distribuidas a $X \rightsquigarrow \mathcal{B}(k_0, p)$ con $p \in]0, 1[$, el Teorema visto en teoría para las familias de distribuciones exponenciales nos dice que el estadístico:

$$T = T(X_1, \dots, X_n) = \sum_{i=1}^n T(X_i) = \sum_{i=1}^n X_i$$

es suficiente para p . Para ver que T es también completo, hemos de ver que $\text{Im } Q$ contiene un abierto de $\mathbb{R}$:

Opción 1. Como $Q :]0, 1[\rightarrow \mathbb{R}$ es continua y definida sobre un conexo (un intervalo), su imagen ha de ser un conexo. Como en $\mathbb{R}$ los únicos conjuntos conexos son los intervalos y los puntos, y Q es claramente no constante, su imagen ha de ser un intervalo, que es un abierto de $\mathbb{R}$, por lo que T es completo.

Opción 2.

$$\text{Im } Q = \left\{ \ln \left(\frac{p}{1-p} \right) : p \in]0, 1[\right\}$$

Definimos la siguiente función:

$$\begin{aligned}
 f :]0, 1[&\longrightarrow \mathbb{R}^+ \\
 t &\longmapsto \frac{t}{1-t}
 \end{aligned}$$

- Está bien definida, puesto que si $t \in]0, 1[$, entonces $1-t > 0$, con lo que $f(t) \in \mathbb{R}^+$.

- Sea $y \in \mathbb{R}^+$, tenemos que:

$$\frac{t}{1-t} = y \iff t = y(1-t) \iff t = y - yt \iff t(1+y) = y \iff t = \frac{y}{y+1} < 1$$

Por lo que $f(t) = y$ con $t \in]0, 1[$, con lo que f es sobreyectiva.

Por tanto, $\text{Im } f = \mathbb{R}^+$, de donde deducimos que:

$$\text{Im } Q = \left\{ \ln \left(\frac{p}{1-p} \right) : p \in]0, 1[\right\} = \{ \ln(f(p)) : p \in]0, 1[\} = \ln(\text{Im } f) = \ln(\mathbb{R}^+) = \mathbb{R}$$

Como obviamente $\mathbb{R}$ contiene algún abierto de $\mathbb{R}$, deducimos que T era un estadístico completo.

- b) $\{\mathcal{P}(\lambda) : \lambda > 0\}$

Comprobamos las condiciones:

1. El espacio paramétrico es $\mathbb{R}^+ \subseteq \mathbb{R}$.
2. El espacio muestral es $\mathcal{X} = \mathbb{N} \cup \{0\}$, que no depende de λ .
3. Para la tercera condición:

$$P_\lambda[X = x] = e^{-\lambda} \frac{\lambda^x}{x!} = \exp \left[\ln \left(e^{-\lambda} \frac{\lambda^x}{x!} \right) \right] = \exp[-\lambda + x \ln \lambda - \ln(x!)]$$

Tomando:

$$\begin{aligned} T(x) &= x, & S(x) &= -\ln(x!) \\ Q(\lambda) &= \ln \lambda, & D(\lambda) &= -\lambda \end{aligned}$$

obtenemos la tercera condición.

Sea $(X_1, \dots, X_n)$ una m.a.s. de variables aleatorias idénticamente distribuidas a $X \rightsquigarrow \mathcal{P}(\lambda)$ con $\lambda \in \mathbb{R}^+$, el Teorema visto en teoría para las familias de distribuciones exponenciales nos dice que el estadístico:

$$T = T(X_1, \dots, X_n) = \sum_{i=1}^n T(X_i) = \sum_{i=1}^n X_i$$

es suficiente para λ . Para ver que T es también completo, hemos de ver que $\text{Im } Q$ contiene un abierto de $\mathbb{R}$. Como:

$$\text{Im } Q = \{\ln(\lambda) : \lambda \in \mathbb{R}^+\} = \ln(\mathbb{R}^+) = \mathbb{R}$$

Tenemos que $\text{Im } Q = \mathbb{R}$ claramente contiene un abierto de $\mathbb{R}$, por lo que T es completo.

- c) $\{BN(k_0, p) : 0 < p < 1\}$

Comprobamos las condiciones:

1. El espacio paramétrico es $]0, 1[\subseteq \mathbb{R}$.

2. El espacio muestral es $\mathcal{X} = \mathbb{N} \cup \{0\}$, que no depende de p .
3. Para la tercera condición:

$$\begin{aligned} P_p[X = x] &= \binom{x + k_0 - 1}{x} (1-p)^x p^{k_0} = \exp \left[\ln \left(\binom{x + k_0 - 1}{x} (1-p)^x p^{k_0} \right) \right] \\ &= \exp \left[\ln \binom{x + k_0 - 1}{x} + x \ln(1-p) + k_0 \ln p \right] \end{aligned}$$

Tomando:

$$\begin{aligned} T(x) &= x, & S(x) &= \ln \binom{x + k_0 - 1}{x} \\ Q(p) &= \ln(1-p), & D(p) &= k_0 \ln p \end{aligned}$$

Obtenemos la tercera condición.

Sea $(X_1, \dots, X_n)$ una m.a.s. de variables aleatorias idénticamente distribuidas a $X \rightsquigarrow BN(k_0, p)$ con $p \in]0, 1[$, el Teorema visto en teoría para las familias de distribuciones exponenciales nos dice que el estadístico:

$$T = T(X_1, \dots, X_n) = \sum_{i=1}^n T(X_i) = \sum_{i=1}^n X_i$$

es suficiente para p . Para ver que T es también completo, hemos de ver que $\text{Im } Q$ contiene un abierto de $\mathbb{R}$. Como $Q :]0, 1[\rightarrow \mathbb{R}$ es una función continua, no constante y definida en un intervalo, tenemos que su imagen es un intervalo, por lo que contiene abiertos de $\mathbb{R}$, de donde T es completo.

d) $\{\exp(\lambda) : \lambda > 0\}$

Comprobamos las condiciones:

1. El espacio paramétrico es $\mathbb{R}^+ \subseteq \mathbb{R}$.
2. El espacio muestral es $\mathcal{X} = \mathbb{R}^+$, que no depende de λ .
3. Para la tercera condición:

$$f_\lambda(x) = \lambda e^{-\lambda x} = \exp [\ln (\lambda e^{-\lambda x})] = \exp [\ln(\lambda) - \lambda x]$$

Tomando:

$$\begin{aligned} T(x) &= x, & S(x) &= 0 \\ Q(\lambda) &= -\lambda, & D(\lambda) &= \ln(\lambda) \end{aligned}$$

tenemos la tercera condición.

Sea $(X_1, \dots, X_n)$ una m.a.s. de variables aleatorias idénticamente distribuidas a $X \rightsquigarrow \exp(\lambda)$ con $\lambda \in \mathbb{R}^+$, el Teorema visto en teoría para las familias de distribuciones exponenciales nos dice que el estadístico:

$$T = T(X_1, \dots, X_n) = \sum_{i=1}^n T(X_i) = \sum_{i=1}^n X_i$$

es suficiente para λ . Para ver que T es también completo, hemos de ver que $\text{Im } Q$ contiene un abierto de $\mathbb{R}$. Como $Q : \mathbb{R}^+ \rightarrow \mathbb{R}$ es una función continua, no constante y definida en un intervalo, tenemos que su imagen es un intervalo, por lo que contiene abiertos de $\mathbb{R}$, de donde T es completo.

Ejercicio 2.1.8. Estudiar si las siguientes familias de distribuciones son exponenciales biparamétricas. En caso afirmativo, considerando una muestra aleatoria simple de una variable con distribución en dicha familia, obtener, si existe, un estadístico suficiente y completo.

a) $\{\Gamma(p, a) : p, a > 0\}$

Comprobamos las condiciones:

1. El espacio paramétrico es $\mathbb{R}^+ \times \mathbb{R}^+ \subseteq \mathbb{R}^2$.
2. El espacio muestral es $\mathbb{R}^+$, que no depende de p ni de a .
3. Para la tercera condición:

$$\begin{aligned} f_{(p,a)}(x) &= \frac{a^p}{\Gamma(p)} x^{p-1} e^{-ax} = \exp \left[\ln \left(\frac{a^p}{\Gamma(p)} x^{p-1} e^{-ax} \right) \right] \\ &= \exp \left[\ln \left(\frac{a^p}{\Gamma(p)} \right) + (p-1) \ln x - ax \right] \end{aligned}$$

Tomando:

$$\begin{aligned} T_1(x) &= \ln x, & T_2(x) &= x, & S(x) &= 0 \\ Q_1(p, a) &= (p-1), & Q_2(p, a) &= -a, & D(p, a) &= \ln \left(\frac{a^p}{\Gamma(p)} \right) \end{aligned}$$

Tenemos la tercera condición.

Sea $(X_1, \dots, X_n)$ una m.a.s. de variables aleatorias idénticamente distribuidas a $X \rightsquigarrow \Gamma(p, a)$ con $p, a \in \mathbb{R}^+$, el Teorema visto en teoría para las familias de distribuciones exponenciales multiparamétricas nos dice que el estadístico:

$$T = T(X_1, \dots, X_n) = \left(\sum_{i=1}^n T_1(X_i), \sum_{i=1}^n T_2(X_i) \right) = \left(\sum_{i=1}^n \ln(X_i), \sum_{i=1}^n X_i \right)$$

es suficiente para (p, a) . Para ver que T es también completo, hemos de ver que $\text{Im } Q$ contiene un abierto de $\mathbb{R}^2$, donde $Q : (\mathbb{R}^+)^2 \rightarrow \mathbb{R}^2$, con $Q = (Q_1, Q_2)$. Para ello:

$$\begin{aligned} \text{Im } Q &= \left\{ (p-1, -a) : (p, a) \in (\mathbb{R}^+)^2 \right\} = \{(x-1, y) : x \in \mathbb{R}^+, y \in \mathbb{R}^-\} \\ &=]-1, +\infty[\times \mathbb{R}^- \end{aligned}$$

Como claramente $]-1, +\infty[\times \mathbb{R}^-$ contiene un abierto de $\mathbb{R}^2$, tenemos que T es completo.

Observemos que también podríamos haber tomado:

$$T(X_1, \dots, X_n) = \left(\prod_{i=1}^n X_i, \sum_{i=1}^n X_i \right)$$

b) $\{\beta(p, q) : p, q > 0\}$

Comprobamos las condiciones:

1. El espacio paramétrico es $\mathbb{R}^+ \times \mathbb{R}^+ \subseteq \mathbb{R}^2$.
2. El espacio muestral es $[0, 1]$, que no depende de p ni de q .
3. Para la tercera condición:

$$\begin{aligned} f_{(p,q)}(x) &= \frac{1}{\beta(p,q)} x^{p-1} (1-x)^{q-1} = \exp \left[\ln \left(\frac{1}{\beta(p,q)} x^{p-1} (1-x)^{q-1} \right) \right] \\ &= \exp \left[\ln \left(\frac{1}{\beta(p,q)} \right) + (p-1) \ln x + (q-1) \ln(1-x) \right] \end{aligned}$$

Tomando:

$$\begin{aligned} T_1(x) &= \ln x, & T_2(x) &= \ln(1-x), & S(x) &= 0 \\ Q_1(p, q) &= p-1, & Q_2(p, q) &= q-1, & D(p, q) &= \ln \left(\frac{1}{\beta(p, q)} \right) \end{aligned}$$

Tenemos la tercera condición.

Sea $(X_1, \dots, X_n)$ una m.a.s. de variables aleatorias idénticamente distribuidas a $X \rightsquigarrow \beta(p, q)$ con $p, q \in \mathbb{R}^+$, el Teorema visto en teoría para las familias de distribuciones exponenciales multiparamétricas nos dice que el estadístico:

$$T = T(X_1, \dots, X_n) = \left(\sum_{i=1}^n T_1(X_i), \sum_{i=1}^n T_2(X_i) \right) = \left(\sum_{i=1}^n \ln(X_i), \sum_{i=1}^n \ln(1-X_i) \right)$$

es suficiente para (p, q) . Para ver que T es también completo, hemos de ver que $\text{Im } Q$ contiene un abierto de $\mathbb{R}^2$, donde $Q : (\mathbb{R}^+)^2 \rightarrow \mathbb{R}^2$, con $Q = (Q_1, Q_2)$. Para ello:

$$\text{Im } Q = \{(p-1, q-1) : p, q \in \mathbb{R}^+\} =]-1, +\infty[\times]-1, +\infty[$$

Como claramente este conjunto contiene un abierto de $\mathbb{R}^2$, tenemos que T es completo.